



리서처 18기 런케이션 DLthon ## 0. DLThon 일정 ||
Day 1 (6월 30일) | Day 2 (7월 1일) | Day 3 (7월 2일) |
Day 4 (7월 3일) | (7월 16일) | | --- | --- | --- | --- | --- | --- ||
오전 | 팀빌딩 및 프로젝트 안내 | 프로젝트 진행 | 프로
젝트 진행 | 카카오 방문 및 커리어 세션 || | 오후 | 프로
젝트 진행 | 프로젝트 진행 | 프로젝트 진행 발표 자료 제
출 마감 | 발표회 | 최종 발표회 (19:00~) | ## 1. 과제 설
명 ### 오염된 태양광 데이터 정화 챌린지 ☒ 제주의 태
양광 패널은 생각보다 자주 더러워집니다. 제주는 '카본
프리 아일랜드'를 향해 섬 곳곳에 태양광 패널을 늘려왔
습니다. 그런데 바닷바람이 실어오는 염분, 봄철 황사,
화산토 먼지와 꽃가루가 패널 위에 쌓이면서 패널을 더
럽게 만듭니다. 먼지가 끼면 패널이 햇빛을 제대로 못
받아 발전 효율이 뚝 떨어집니다. 그렇다고 섬 전역의
수많은 패널을 사람이 일일이 점검하는 것도 힘들겠죠.
그래서 사진만 보고 "깨끗한가(Clean), 청소가 필요한가
(Dusty)"를 자동으로 가려내는 기술이 필요합니다. 태
양광 패널 이미지 데이터를 수집하고, 수집한 데이터를
기반으로 판별 모델을 개발하고, 개발된 모델을 활용해
서 제주시의 태양광 패널 청소 주기를 관리하는시스
템을 개발하는 전체 프로젝트 중에서, 여러분은 수집한 데
이터를 기반으로 판별 모델을 만드는 업무를 맡게 되었
습니다. 여러분의 목표는 주어진 데이터셋을 활용해서
최대한 높은 성능의 모델을 개발하는 것입니다. --- 그런
데 전달받은 데이터셋, 살펴보니 심상치 않군요! ### 데
이터 안내 데이터를 살펴보니, 학습 과정에서 사용해왔
던 데이터셋과는 다릅니다. - ☒ 여러 사람이, 여러 방식
으로 찍었습니다. 점검 기사들은 저마다 다른 휴대폰으
로, 다른 각도와 햇빛 아래에서 찍었어요. 드론은 자동
으로 수백 장을 쏟아냈고요. 그러다 보니 패널이 화면
구석에 걸리거나, 작업자 손·지붕·하늘이 더 크게 찍힌

사진도 섞였습니다. - 📌 라벨을 붙인 사람도 제각각이
었습니다. "이 정도 먼지면 청소해야 하나?"의 기준은
사람마다 달라요. 누군가는 살짝 뿌연 패널을 Clean으
로, 다른 사람은 Dusty로 표시했습니다. 애매한 사진일
수록 라벨이 엇갈렸죠. - 🔄 같은 사진이 여기저기서 다
시 등장했습니다. 한 패널 사진이 여러 점검 보고서에
들어가고, 압축·리사이즈되어 다시 업로드되면서 거의
똑같은 복제본이 쌓였습니다. - 📁 데이터가 부족하면 웹
에서 긁어모았습니다. 그 과정에서 태양광 제품 카탈로
그 그래픽, 인버터 같은 설비 사진, 심지어 패널과 무관
한 풍경까지 함께 딸려 들어왔습니다. - 📁 그리고 마감
이 닦였습니다. 일일이 검수할 시간 없이, 모인 데이터
는 그대로 하나로 합쳐져서 여러분들에게 전달되었습
니다. 현실의 데이터셋은 이런 방식으로 수집될 가능성
이 높습니다. 여러분은 이 상황을 피할 수 없습니다. 최
대한 데이터를 잘 정제해서 모델의 성능을 높이는 것이
여러분들에게 지금 주어진 목표입니다. ## 2. Kaggle
Competition 소개 이 프로젝트는 2개의 캐글 컴페티션
으로 구성되어 있습니다. ##### Track A - Shine Track 🔄
Track A 컴페티션 참가 링크: <https://www.kaggle.com/t/95a781ec75114e77a34ab9032b44a364> 우리 프로젝트의
진짜 목표입니다. 해당 프로젝트에서는 태양광 패널 이
미지를 Clean(깨끗)/Dusty(먼지)로 분류합니다. 여러분
들은 데이터를 정제해 분류 성능을 높이는 것이 목표입
니다. 여러분은 테스트셋의 이미지가 Dusty일 확률 값
을 제출하시면 됩니다. - dusty_prob: 이미지가 패널일
때 Dusty(먼지)일 확률 (0~1 값) 컴페티션 평가지표는
다음과 같습니다. - ROC-AUC - 이진 분류의 표준 지표입

니다. - 클래스 불균형에 안정적입니다. - 임계값을 정할 필요 없이 모델의 분별력을 체크할 수 있습니다. #####

Track B - Spot Track & Track B 컴페티션 참가 링크: <https://www.kaggle.com/t/e3c9ceb6098b4e6f9af16f1abfbffa>

37 여러분이 데이터를 정제할 때 잘 진행이 되고 있나를 점검할 수 있는 트랙입니다. 데이터에 섞여 있는 아래의 3가지 오염을 구별해 내는 것이 목표입니다. 1. 라벨 오

류 (Label Error) — 이미지는 멀쩡한데 Clean/Dusty 라벨이 반대로 붙어 있는 경우입니다. 틀린 정답지로 공부하게 되어 모델 성능에 악영향을 끼칩니다. 2. 근접 중복 (Near-Duplicate) — 같은 사진이 살짝 변형(크기·자르기·밝기·회전)되어 여러 장 들어가 있는 경우입니다. 학습이 특정 이미지에 편향되고, 같은 이미지가 학습과 평가 양쪽에 걸치면 누수(leakage)가 생깁니다. 3. off-topic

(주제 이탈) — 태양광 패널이 아니거나(그래픽·설비·풍경), 패널이 중심이 아니라 Clean/Dusty를 판단할 수 없는 이미지입니다. 학습에 잡음이 되어서 추론하기 전에 골라내어야 합니다. 각 이미지마다 세가지 의심 점수를 예측해서 제출합니다. - mislabel_score: 라벨이 틀렸을 가능성 - dup_score: 근접 중복일 가능성 - ood_score: 패널이 아닌 이미지(off-topic)일 가능성 컴페티션 평가 지표는 다음과 같습니다. - 세 축(mislabel_score,

dup_score, ood_score)의 Average Precision - AP는 Precision-Recall 곡선의 아래 면적입니다. 오염된 소수의 샘플을 정상 샘플보다 얼마나 위로 잘 끌어올렸는가를 잽니다. - 최종 점수 = 세 AP의 평균 ## 3. 대회 RULE 1. Submission파일에 레이블 생성 후 리더보드에 업로드합니다. - 리더보드의 점수는 모델 성능 확인/학습의 방향성 설정용입니다. - 점수만으로 프로젝트 성취를 판단하지 않습니다. 2. 제출 횟수는 하루 5회로 제한됩니

다. 3. 마지막날 발표를 기준으로 프로젝트 점수를 부여합니다. - 역할 분담, 회고 등의 프로젝트 정보와 프로젝트 진행 과정, 실험 내용, 시각화 등 프로젝트 평가 항목에 맞는 발표자료를 준비해주세요. 4. 프로젝트 평가 항목 - 데이터 EDA와 전처리를 적절히 수행했는가? - 모델 선정 근거가 타당한가? - 모델의 성능/학습 방향을 판단하고 개선을 시도한 기준이 논리적인가? - 결과 도출을 위해 다양한 시도를 했는가? - 도출된 결론에 충분한 설득력이 있는가? - 발표 자료가 청자의 입장에서 잘 정리되어있는가? - 발표가 매끄럽게 진행되었고 발표시간을 준수하였는가? ## 4. DLthon 일정 || Day 1 (6월 30일) | Day 2 (7월 1일) | Day 3 (7월 2일) | Day 4 (7월 3일) | (7월 16일) || --- | --- | --- | --- | --- | --- || 오전 | 팀빌딩 및 프로젝트 안내 | 프로젝트 진행 | 프로젝트 진행 | 카카오 방문 및 커리어 세션 || | 오후 | 프로젝트 진행 | 프로젝트 진행 | 프로젝트 진행 | 발표 자료 제출 마감 | 발표회 | 최종 발표회(19:00~) | 발표 자료는 4일차 오전 12:00까지 제출해주셔야 합니다. - 자료 제출 이후 코드/발표자료 수정 가능 - 단, 주제나 결론이 바뀔 정도의 수정이 아니어야 함 발표는 1팀당 15분씩 진행됩니다. (발표 15분, 질의응답 15분) 4일차 오후 발표를 기준으로 프로젝트 점수가 부여되고, 해당 점수를 기준으로 최종 발표회에 참여하게 될 팀이 선정됩니다. (런케이션 참여하는 전체 기수 중 일부 팀) 최종 발표회에 참여하는 팀에게는 별도 시상도 있을 예정입니다. ## 5. 출결 패널티 - 프로젝트 총점: 10점 - 출결 패널티(회당/개인별) - 결석: - 무단 결석: -3점 - 사전고지 -2점 - 지각/조퇴/외출 - 무단지각/외출/조퇴: -2점 - 사전고지 지각/외출/조퇴: -1점 - 사전고지는 첫날까지 퍼실과 팀 그루에게 반드시 이루어져야 하며, 노선에 기록해주셔야 합니다 ## 6. 팀 편성 || 팀원1 | 팀원2 | 팀원3 | 팀원4 || --- | --- | --- | --- | --- || 1

팀 | 김정민 | 김택훈 | 추병곤 | 김관호 || 2팀 | 김다현 | 김혜원 | 장주휘 ||| 3팀 | 김한울 | 송반디 | 유비 ||| 4팀 | 강성진 | 오용석 | 한승엽 || 온라인 13기 리서치 DLthon (2)

이 DLthon 과제에서는 “오염된 태양광 패널 이미지 데이터셋을 어떻게 정제하고, 그 위에 어떤 모델을 얹어 두 개의 트랙(Shine/Spot)을 잘 풀 것인가”가 핵심입니다.^[1]

아래에서는 실전 대회 참여 관점에서, 3일 안에 발표까지 가야 한다는 일정까지 고려해 전략을 정리해 드리겠습니다.

전체 전략 개요

- Track A(Shine): 패널 이미지 → Dusty 확률 예측 (ROC-AUC 최대화).
- Track B(Spot): 각 이미지에 대해 mislabel / dup / ood 의심 점수 예측 (Average Precision 최대화).
- 데이터 자체가 심하게 오염되어 있으므로, “데이터 클리닝 + 모델링”을 하나의 파이프라인으로 보고 설계하는 것이 유리합니다.^[1]

추천 워크플로우(발표용 구조에도 그대로 사용 가능):

1. EDA로 오염 양상 파악 (라벨 불일치, 중복, off-topic).
2. Self-supervised / pre-trained 비전 모델로 이미지 임베딩 확보.
3. 임베딩 기반 데이터 정제(중복·off-topic 후보 탐지, 오염 스코어 산출 → Track B 베이스라인).
4. 정제된 데이터로 Dusty 분류 모델 학습 (Track A).
5. 두 트랙 성능 상관관계·실험 로그를 정리해 발표.

데이터 EDA 및 전처리 아이디어

구조·라벨 분포 확인

- Clean/Dusty 비율, 촬영 기기(메타데이터가 있다면), 해상도·비율 분포, 라벨별 밝기/색상 분포 등을 기본적으로 확인합니다.^[1]
- Dusty 이미지가 특정 밝기·색상 영역에 치우치는지 확인해서, 단순한 “밝기/콘트라스트” 편향이 있는지 파악합니다.^[1]

실제 발표용으로 좋은 시각화 예:

- 클래스별 샘플 몇 장을 그리드로 보여주고, “이 정도는 애매한데 Clean/Dusty가 섞여 있다”는 사례 제시.
- 해상도/Aspect ratio 히스토그램, 라벨별 평균 밝기·채도 등을 바 플롯/박스플롯으로 보여주기.

기본 전처리

- 리사이즈(예: 256×256 또는 384×384), 중심 혹은 패널 영역 중심 crop, 표준화(normalization)를 통일합니다.^[1]
- 훈련·검증·테스트 split 시, 잠재 중복(파일명과 단순 해시 기준)이라도 최소한으로 분리해 leakage를 줄입니다.^[1]

근접 중복(dup_score) 탐지 접근

데이터셋에 “거의 같은 사진”이 많이 섞여 있으면 모델이 특정 이미지에 과적합되고, train-test leakage가 심각해집니다.^[1]

1단계: 이미지 임베딩

- CLIP, DINOv2, ResNet50(pretrained) 등 pretrained 비전 백본으로 각 이미지를 임베딩 벡터로 변환합니다.^[1]
- 임베딩 차원을 축소(PCA/UMAP)하거나 그대로 사용해 최근접 이웃 탐색을 수행합니다.^[1]

2단계: 근접 이웃 기반 dup_score 산출

- 각 이미지에 대해 k-NN(예: k=10) 거리(또는 코사인 유사도)를 계산합니다.^[1]
- 가장 가까운 이웃들의 평균 거리가 낮을수록 “근접 중복일 가능성 높음”으로 보고 dup_score를 정의합니다.^[1]
 - 예: $\text{dup_score} = 1 - (\text{평균 코사인 거리 정규화})$.
- 이미지 해시(average hash, perceptual hash)를 추가로 사용해, 거의 완전히 같은 이미지 그룹을 따로 잡아 “high-confidence dup” 레이블로 활용할 수 있습니다.^[1]

발표 포인트:

- “임베딩 공간에서 군집이 매우 촘촘한 영역 → 동일 패널/각도 반복 촬영으로 추정”이라는 2D 시각화(UMAP) 슬라이드.
- 이 영역에서 샘플 이미지를 나란히 보여주면 설득력이 큼.

off-topic(ood_score) 탐지 접근

웹 크롤링 과정에서 카탈로그 그래픽·인버터·풍경이 섞여 있다는 설정이므로, 태양광 패널이 아닌 이미지를 잡아내야 합니다.^[1]

아이디어 1: 간단한 이진 OOD 분류기

- 소량의 데이터에 대해 수작업으로 태깅: “패널 중심/판단 가능”, “판단 불가/그래픽/풍경”을 라벨링한 mini-dataset을 만듭니다.^[1]
- pretrained CNN/ViT 위에 작은 classifier를 얹어 패널 vs non-panel 분류기를 학습합니다.^[1]
- 이 모델의 출력 확률을 ood_score로 사용하거나, 불확실도가 높을수록 ood_score 상향하는 방식으로 조정합니다.^[1]

아이디어 2: 임베딩 기반 클러스터링

- 패널 이미지만으로 임베딩 클러스터를 형성한 뒤, 클러스터 중심으로부터의 거리 혹은 밀도를 기반으로 “패널 도메인에서 떨어진 정도”를 `ood_score`로 정의합니다.^[1]
- 카탈로그 그래픽이나 풍경 이미지는 보통 스타일·색상·구도가 달라서 임베딩 공간에서 뚜렷하게 떨어질 가능성이 큼니다.^[1]

라벨 오류(`mislabeled_score`) 탐지 접근

“애매한 Dusty/깨끗” 이미지는 annotator마다 기준이 달라 라벨이 뒤집힌 경우가 있습니다.^[1]

여기서는 “모델 기반 라벨 품질 평가”를 활용하는 것이 실용적입니다.

1단계: 초기 Dusty 분류 모델 학습

- 오염된 라벨을 그대로 사용해 baseline 모델(CNN/ViT + binary classifier)을 학습합니다.^[1]
- 심각한 오염이 있어도, 대다수 샘플이 정상이라면 기본적인 분류 성능은 나옵니다.^[1]

2단계: 모델 예측 vs 기존 라벨 비교

- 각 이미지에 대해 모델이 예측한 Dusty 확률 p 와 원래 라벨 $y \in \{0, 1\}$ 을 비교합니다.^[1]
- 예측과 라벨이 강하게 불일치하는 샘플에 높은 `mislabeled_score`를 부여합니다.^[1]
 - 예: `mislabeled_score = |p - y|` (또는 calibration 후 변형).
- 추가로, 동일·유사 이미지 그룹 내 라벨이 서로 다르면 그 그룹 전체의 `mislabeled_score`를 올립니다.^[1]

발표에서 강조하기 좋은 포인트:

- “모델과 라벨이 크게 충돌하는 샘플을 육안으로 확인했더니, 실제로 애매하거나 잘못 라벨링된 사례가 많았다”는 qualitative 분석.
- 이 분석을 통해 “라벨 품질이 성능 상한을 제한한다”는 메시지.

Track B 제출용 스코어 구성

각 이미지에 대해 다음 세 점수를 출력해야 합니다.^[1]

- `mislabeled_score`: 라벨 오류 의심 정도.
- `dup_score`: 근접 중복 의심 정도.
- `ood_score`: off-topic 의심 정도.

실무적인 구성 예:

- `mislabeled_score`: 초기 Dusty 모델의 예측 확률과 라벨 차이, 유사 이미지 그룹 내 라벨 불일치 여부를 모두 반영한 합성 스코어.^[1]
- `dup_score`: 이미지 임베딩 기반 k-NN 평균 거리 + perceptual hash 중복 여부.^[1]

- ood_score: 패널 vs non-panel 분류기 출력, 임베딩 클러스터 중심과의 거리 또는 밀도 기반 anomaly score.^[1]

모든 스코어를 0~1 범위로 정규화해서 제출하면, Average Precision 평가에 적합합니다.^[1]

Track A: Dusty 분류 모델링 전략

모델 선택

- 데이터 다양성이 크고 오염도 높으므로, 강한 표현력을 가진 pretrained 모델(ResNet, EfficientNet, ConvNeXt, ViT, Swin 등)을 활용하는 것이 유리합니다.^[1]
- Kaggle 환경에서는 GPU 리소스를 고려해, 적당한 크기의 모델을 1~2개 선정해 앙상블까지 고려할 수 있습니다.^[1]

학습 데이터 정제

- Track B에서 얻은 dup_score, ood_score, mislabel_score를 활용해 학습셋 필터링/가중치 조정:
 - dup_score 높은 샘플은 대표 하나만 남기고 나머지를 제거 또는 가중치 감소.
 - ood_score 높은 샘플은 Dusty 분류 학습에서 제외.
 - mislabel_score가 매우 높은 샘플은 제거, 중간값은 가중치를 낮게 설정.^[1]

이렇게 하면 “클린 서브셋”과 “노이즈 서브셋”의 두 가지 설정을 사용해서 비교 실험을 할 수 있고, 발표 시에도 좋은 스토리가 됩니다.^[1]

평가·향상 아이디어

- ROC-AUC가 주요 지표이므로, 클래스 불균형에 크게 신경 쓰지 않고도 모델 discriminative power를 볼 수 있습니다.^[1]
- Threshold 튜닝(실제 운영에서는 Dusty 판정을 어떤 기준으로 할지)도 별도의 슬라이드로 논의하면, “비즈니스 관점”을 강조할 수 있습니다.^[1]

발표 자료 구성 제안

발표 시간 15분을 기준으로, 다음과 같은 구성을 추천합니다.^[1]

1. 문제 정의 및 현실 데이터셋 특징
 - 제주 태양광 패널, 다양한 촬영 조건, 오염된 라벨·중복·off-topic 문제를 사례 이미지로 설명.
2. 데이터 EDA
 - 클래스 분포, 이미지 해상도·밝기 분포, 애매한 이미지 사례.
3. Track B: 데이터 오염 탐지
 - 임베딩 기반 중복 탐지 시각화, off-topic 후보 이미지 예시, mislabel 후보 이미지 예시.
 - 각 스코어 정의 및 AP 결과.
4. Track A: Dusty 분류 모델

- 모델 구조(백본 선택 이유), 데이터 정제 전략(필터링/가중치).
- ROC-AUC 결과, 정제 전/후 성능 변화.

5. 인사이트 및 한계

- 데이터 라벨 품질이 성능 상한을 결정, 현업 적용 시 필요한 추가 개선(라벨링 가이드 정립, active learning 등) 제안.

이 구조대로 슬라이드를 만들면, “데이터 EDA·전처리→모델 선정 근거→시도·실험→결론과 인사이트”라는 평가 항목을 자연스럽게 충족시킬 수 있습니다.^[1]

팀 내 역할 분담 예시

- 데이터/EDA 담당: 이미지 로딩, 기본 통계·시각화, 중복·OOD 탐지 구현.
- 모델링 담당: Dusty 분류 모델 설계·학습, Track B 스코어 산출 로직 정리.
- 실험·로그 담당: 다양한 실험(baseline vs 정제, 모델 비교) 결과를 체계적으로 기록.
- 발표/문서 담당: 실험 결과를 정리해 스토리라인 구성, 슬라이드 제작 및 발표 연습.^[1]

추가로, 팀에서 어떤 수준까지 구현하실 수 있는지(예: CLIP/DINO 사용 가능 여부, 직접 라벨링 가능한 인원·시간) 알려주시면, Kaggle Notebook 구조나 구체적인 코드·실험 플랜까지 더 디테일하게 설계해 드리겠습니다.



1. <https://github.com/greatsong/Hello-Kaggle>
2. <https://www.youtube.com/watch?v=stsef35vxg8>
3. <https://v.daum.net/v/bT19QzyjTB?f=p>
4. <https://www.yna.co.kr/view/AKR20251218070100056>
5. <https://www.headlinejeju.co.kr/news/articleView.html?idxno=575658>
6. https://www.investkorea.org/jj-kr/bbs/i-1150/detail.do?ntt_sn=491681
7. https://energium.kier.re.kr/sub040103/articles/do_print/tableid/news/category/6/page/3/id/6038
8. <https://ocslab.hksecurity.net/Datasets/can-signal-extraction-and-translation-dataset>
9. <https://robotic-vision-lab.github.io/ntrack/>
10. <https://jejurise.kr/pmt/news.htm?page=2&act=view&seq=685>