AIGEN SCIENCES · 참여기업 과제

Benchmark의 Bias 진단

모델의 성능과 데이터셋의 편향을 분리하는 Tool

AIGEN SCIENCES

아이펠 AI 리서처 18기 · 2026-09

Integrated AI System Across Discovery & Development

Built on three multimodal, plug-in AI engines: Insight, ChemTailor, and Clinical Intelligence



Our platform is designed as an integrated Operational Intelligence:

Insight, ChemTailor, and Clinical Intelligence continuously inform each other.

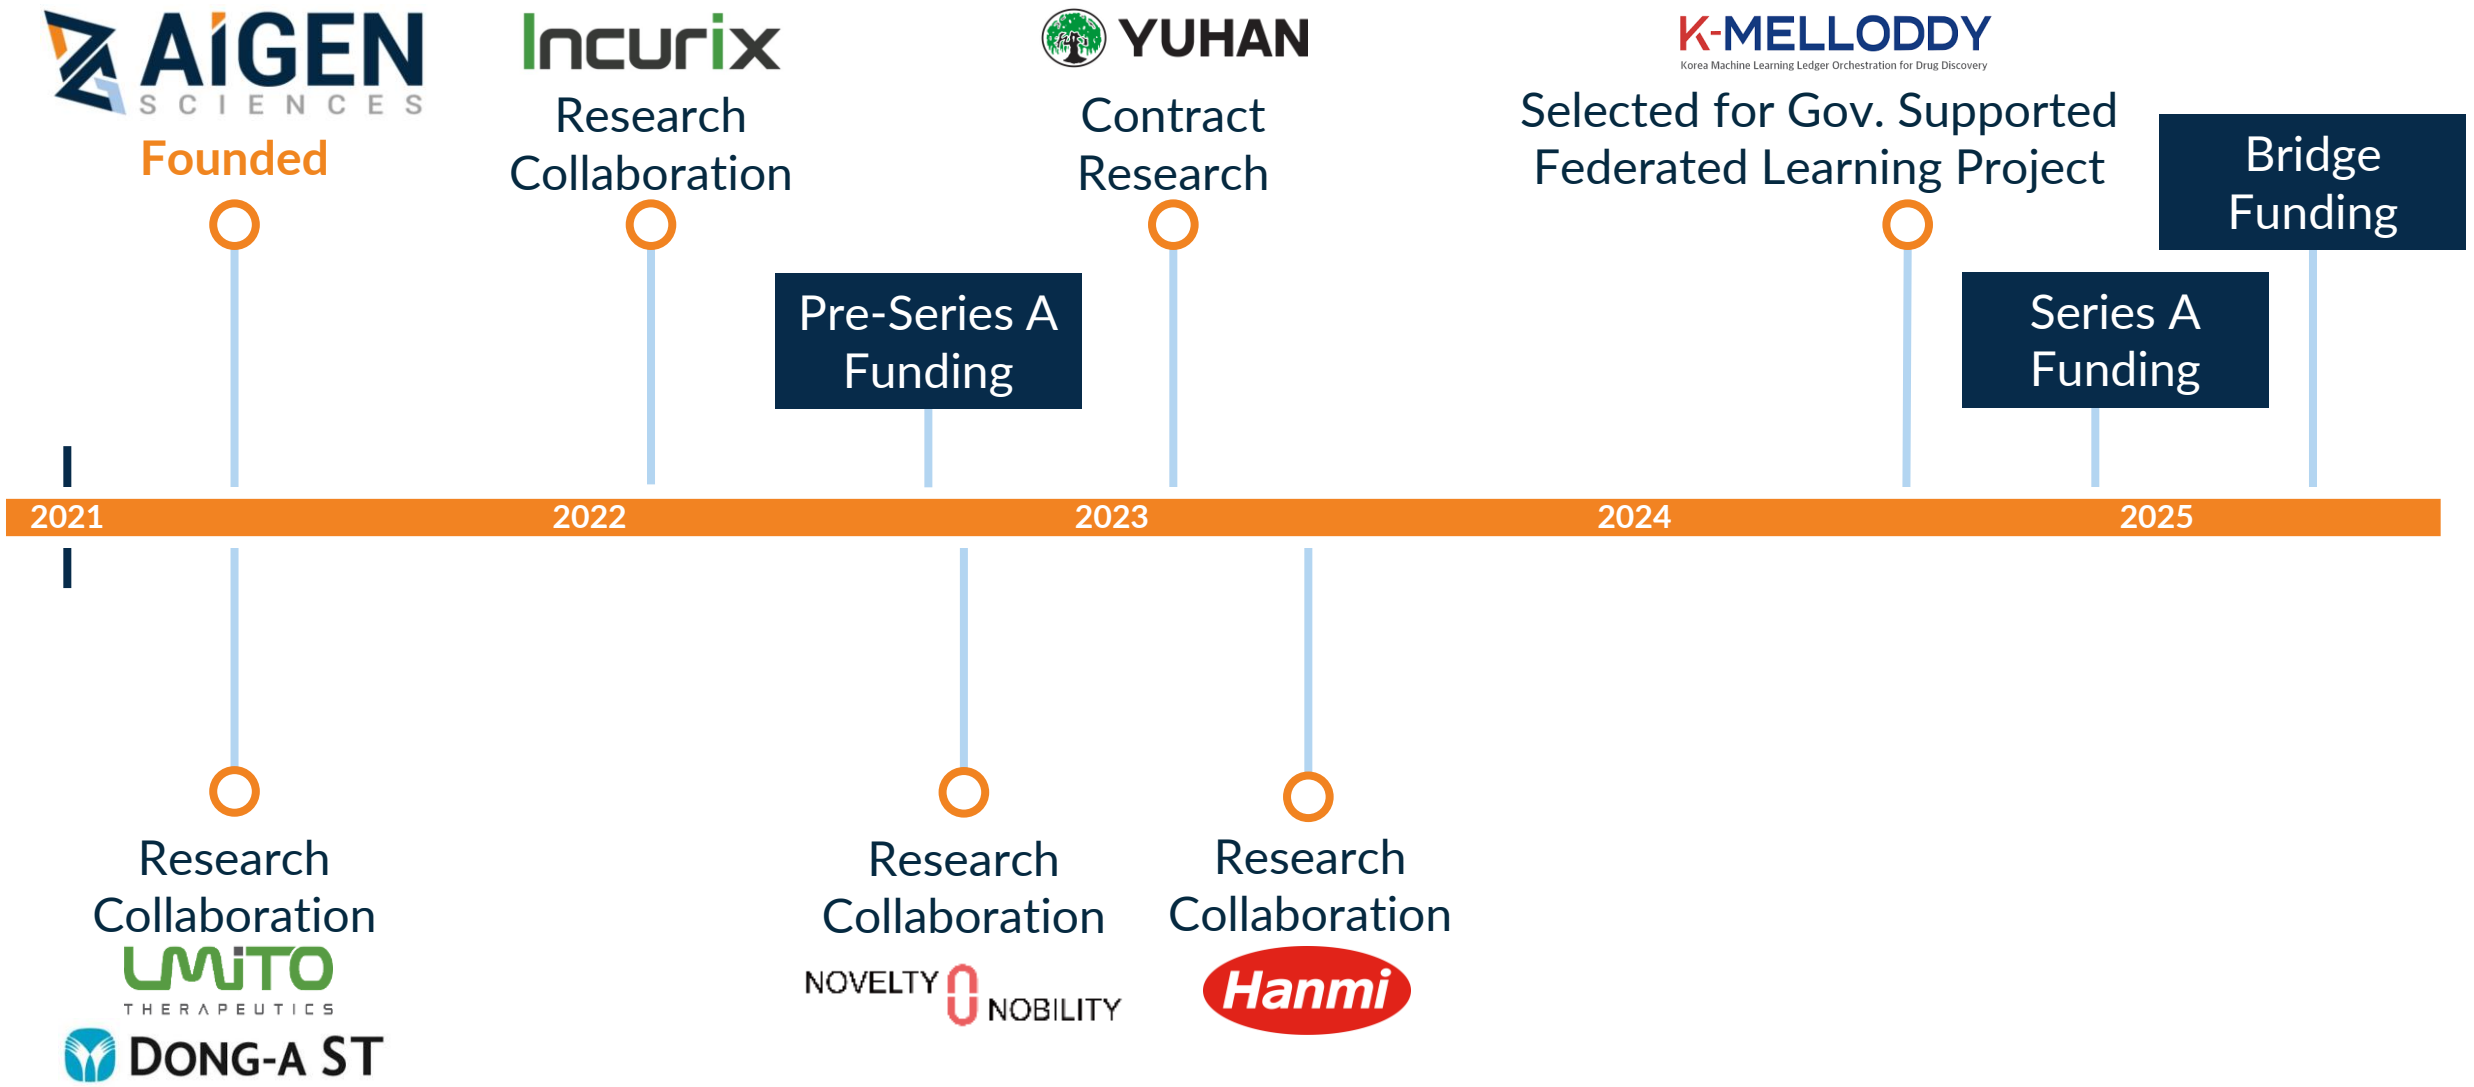
Increasing the information density and efficiency of each iteration.

Topic: Strategy Meeting to Select the Optimal Target for Overcoming PARP Inhibitor Resistance in BRCA1-Mutant Canc

At

각 분야의 전문 에이전트들이 선별된 타깃을 두고 다양한 가설에 대해 토론을 하며,

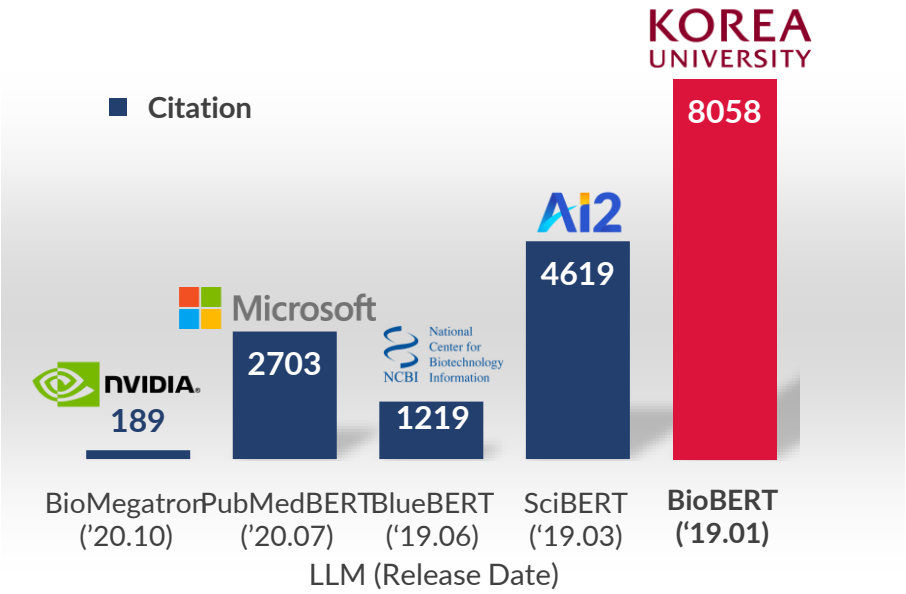
AIGEN Sciences: Milestones



Biomedical AI 역량의 축적

Biomedical language modeling 을 기반한 Domain-specific AI 로의 확장

세계 최초/최다 인용 의생명 특화 LLM `BioBERT`



세계 최초 미국 의사면시험 통과 sLLM `Meerkat`



npj | digital medicine

View all journals | Search | Log in

Explore content | About the journal | Publish with us

nature > npj digital medicine > articles > article

Article | Open access | Published: 02 May 2025

Small language models learn enhanced reasoning skills from medical textbooks

Hyunjae Kim, Hyeon Hwang, Jiwoo Lee, Sihyeon Park, Dain Kim, Taewhoo Lee, Chanwoong Yoon, Jiwoong Sohn, Jungwoo Park, Olga Reykhart, Thomas Fetherston, Donghee Choi, Soo Heon Kwak, Qingyu Chen & Jaewoo Kang

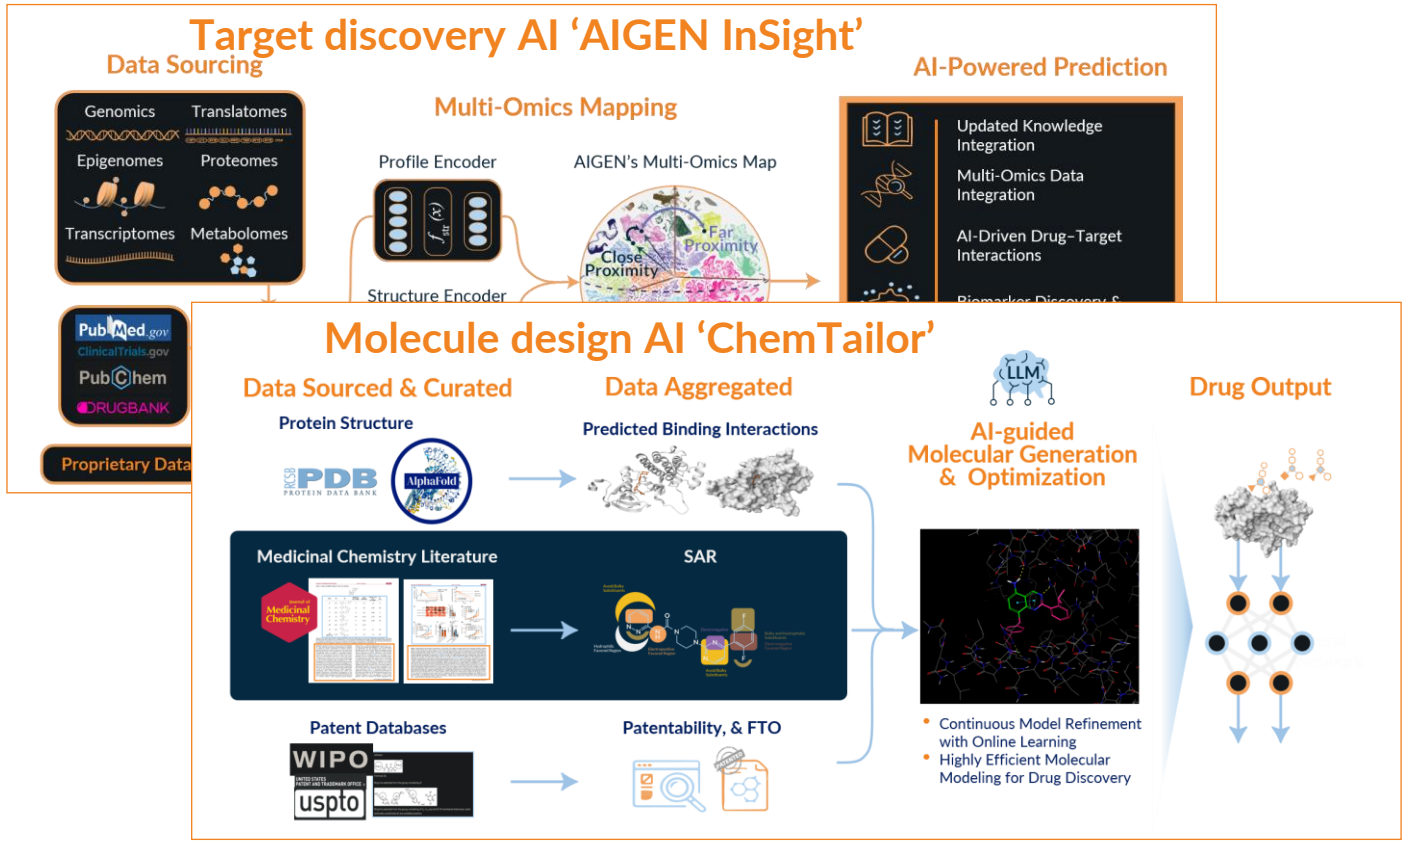
npj Digital Medicine **8**, Article number: 240 (2025) | Cite this article

1218 Accesses | **1** Altmetric | Metrics

초기의 기술적 초점은 생명의학 지식을 AI가 효과적으로 표현하고 활용하는 데 있었음.

예측 모델에서 신약개발 의사 결정으로 확장

개별 AI 모델의 Prediction performance만으로는 신약개발 생산성 향상이 어려움



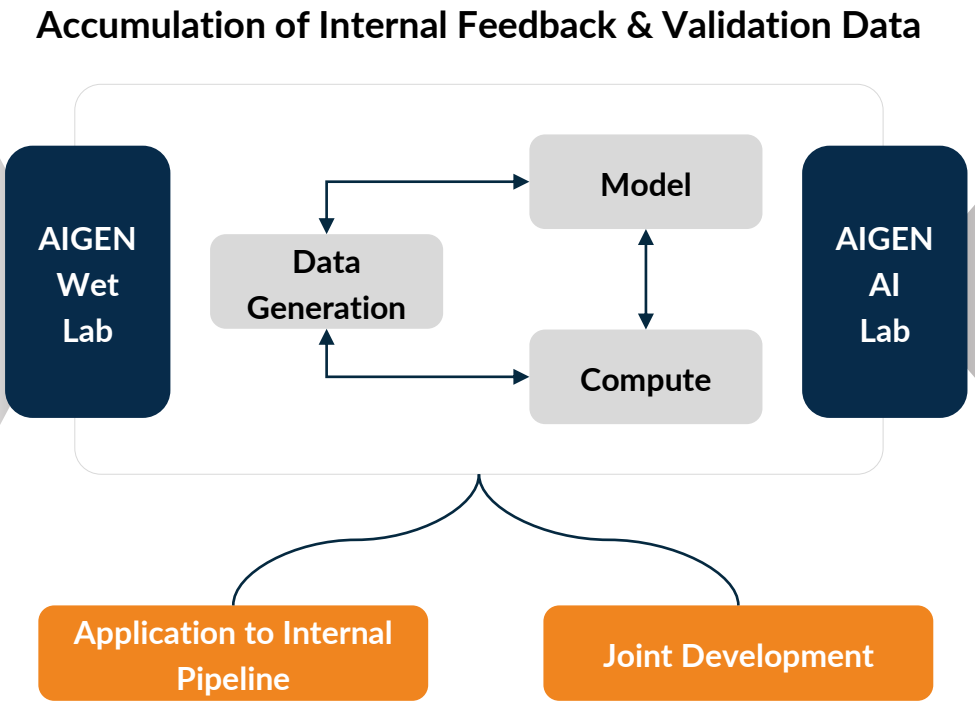
- 어떤 타겟을 우선할 것인가?
- 어떤 물질을 합성할 것인가?
- 어떤 실험을 수행할 것인가?
- 어떤 Pipeline 을 중단/지속할 것인가?

`**AI 예측 정확도**`를 넘어서,
`**의사결정의 Quality**` 로 확장이 필요

Dry-wet lab 간 small closed-loop

AI 모델의 예측 결과와 실험실의 검증 데이터를 실시간으로 피드백하여 모델 고도화





- **128 NVIDIA A100 GPUs:** High-throughput infrastructure optimized for massive parallel processing, operating at **>10×** the scale of typical domestic biopharma compute.
- **Kubernetes-based Orchestration:** Efficient GPU clustering and resource management via Kubernetes (k8s) environments.
- **Multi-node Distributed Computing:** Seamless large-scale parallel processing for complex workloads.

Prospective Validation을 통한 기술 검증

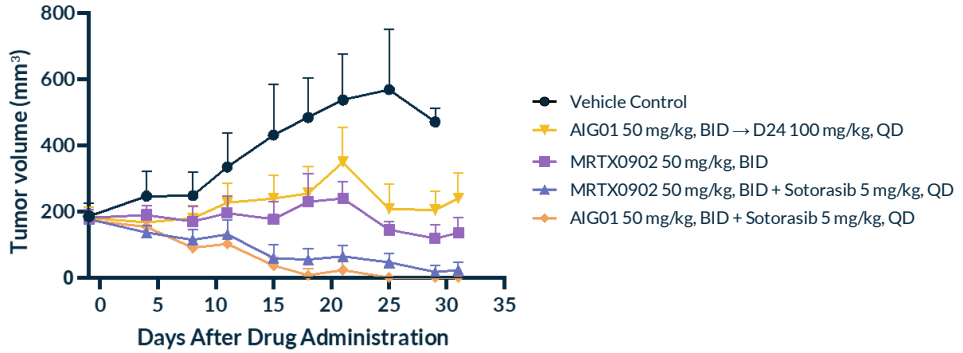
다양한 프로그램들을 통해 예측-결과 사이의 간극을 반복적으로 확인하고 고도화

Challenging target class 와 Experimental validation 성과

Challenge Class	Representative Target	Key Result
PPI (broad, featureless interface)	SOS1-KRAS interaction	~40-45% inhibition at 5 μM
Allosteric modulators	PKM2 tetramer stabilization	All 5 compounds outperformed TEPP-46/DASA-58; HIF-1α, C-Myc, mTOR pathway modulation confirmed
IDPs (transient pockets)	MYC–MAX–DNA ternary complex	IC_{50} 1~10 μM (DNA/reporter); single-digit μM activity across 6 cancer lines (NSCLC, SCLC, AML, T-ALL)
Cryptic pockets	SARM1 NADase	4 hits EC_{50} < 500 nM; 8 distinct scaffolds
Cofactor-context **selectivity**	PRMT5 MTA-cooperative binding	IC_{50} 22 nM (MTAP-del) vs 567 nM (MTAP-WT); 26-fold selectivity
Pan-allele / **multi-mutation coverage**	Pan-KRAS (G12C, G12D, G12V, Q61X)	IC_{50} (KRAS G12C assay) 6.83-7.01 nM vs BI-2865 (12.37 nM); isomer enumeration revealed >10,000-fold activity spread
SAM-competitive **selectivity**	METTL3 m^6A methyltransferase	1.35-1.69% remaining activity @ 0.1 μM; matches STC-15
DUB family **selectivity**	USP1 (HRD synthetic lethality)	IC_{50} 0.065-0.088 μM
Selectivity-critical kinases	CDK2 vs CDK1	Sub-nanomolar CDK2 inhibitor (IC_{50} 0.6 nM) with ~100X selectivity vs. CDK1
Transcription factor modulation	STAT6 inhibitor	IC_{50} 35.6 nM (cell-based reporter assay); >250-fold activity spread vs. internal analogs, and AIG24023 is **4–10X more potent** than reference STAT6 inhibitors

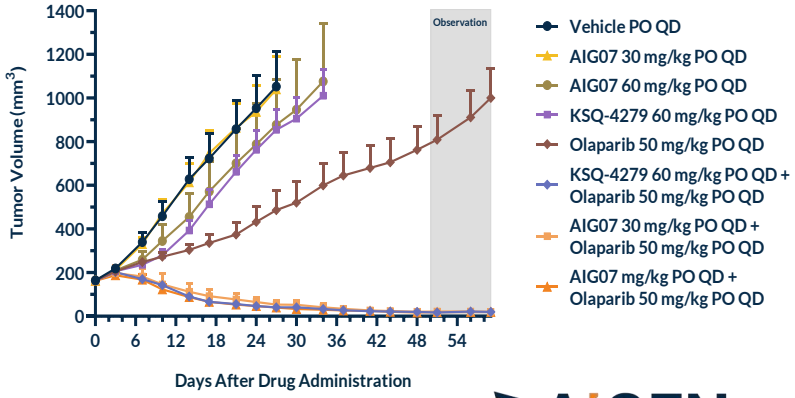
Pancreatic Cancer Xenograft Model(SOS1)

MIA PaCa-2



Breast Cancer Xenograft Model(USP1)

MDA-MB-436

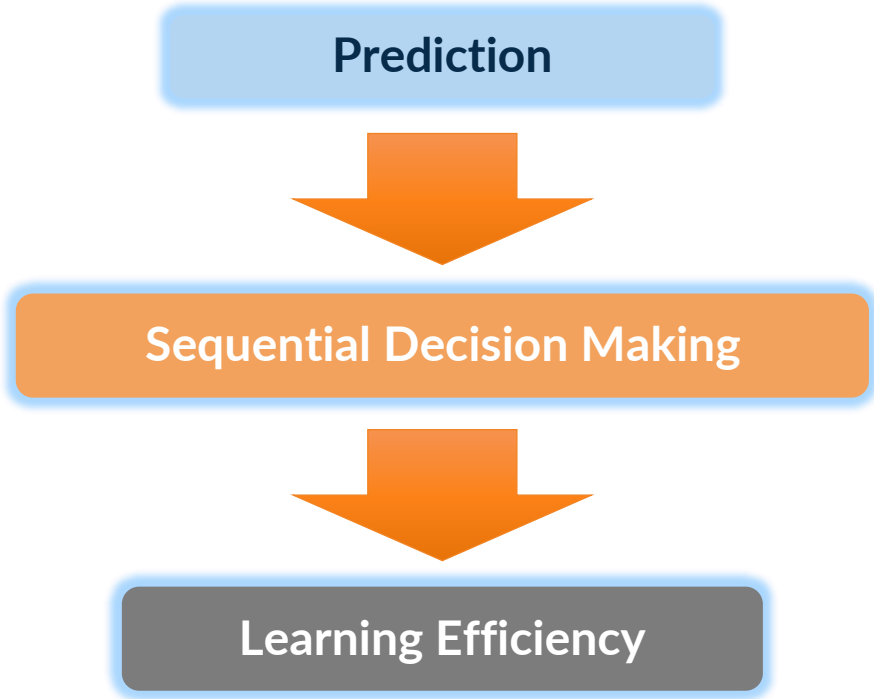


신약개발 AI Bottleneck

한정된 실험, 데이터, 시간, 비용으로 얼마나 빨리 **불확실성을** 줄이고 더 나은 의사결정을 할 수 있는가.

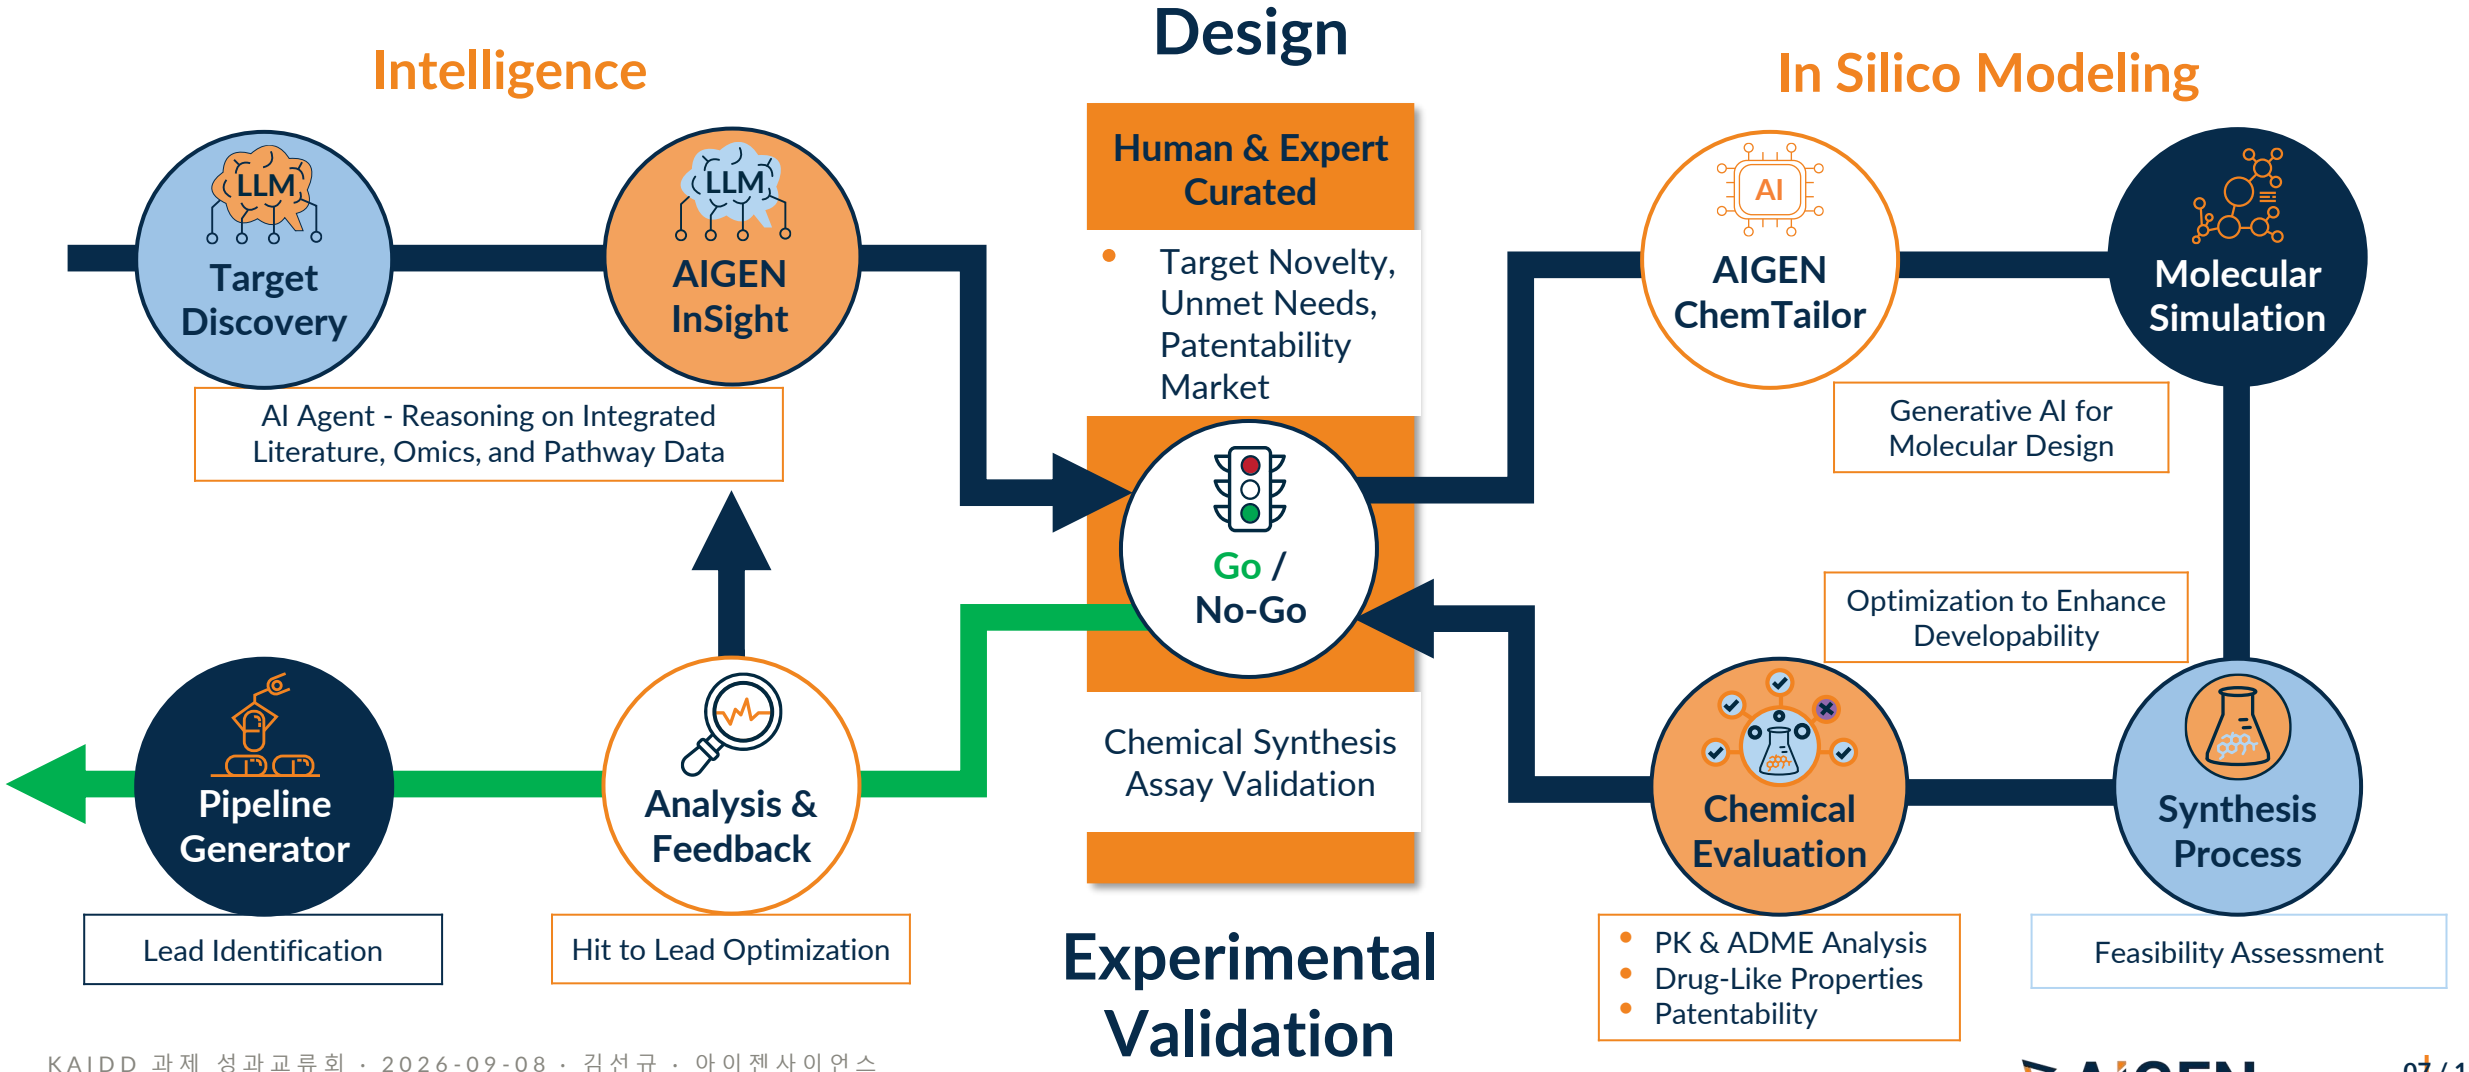
Drug discovery Data characteristics

- Sparse / Biased Data
- Noisy / Heterogeneous assays
- Missing negative data
- Expensive experimental labels
- Proxy endpoint 와 Biological outcome 과의 간극



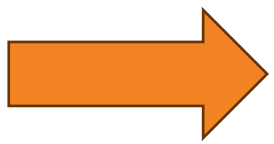
AI–Experimental Decision-making Structure

신규 타겟 발굴, 물질 설계/합성/평가 과정에서 Decision Trace 기록-> Learning 대상



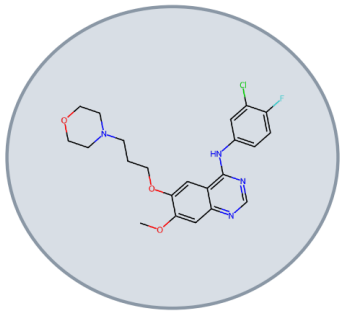
모두의연구소

정직원 4명 채용



AIGEN SCIENCES

단백질을 빼도 점수가 같음

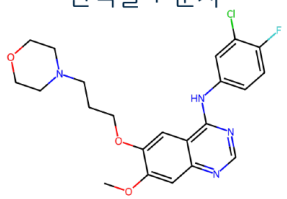


단백질 + 분자

스크리닝 모델

AUC 0.98

=



분자만

스크리닝 모델

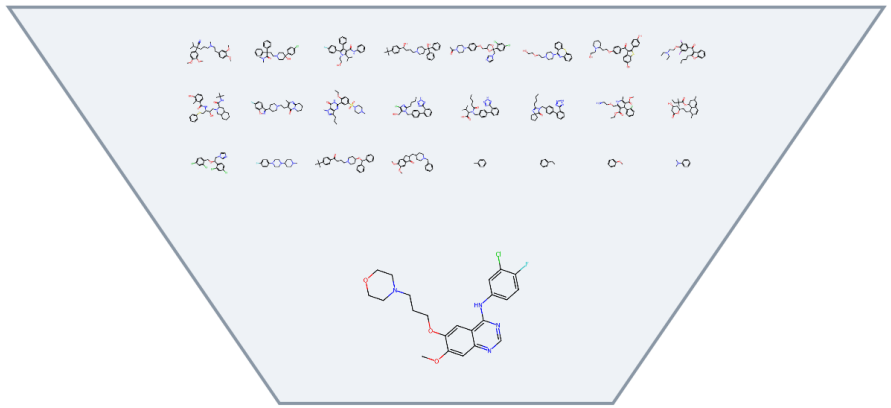
AUC 0.98

차이 없음

그래서 결합을 학습한다고 전제한 모델인데 단백질 쪽 입력을 없애도 성능이 그대로임. 모델이 다른 신호를 읽고 있다는 뜻.

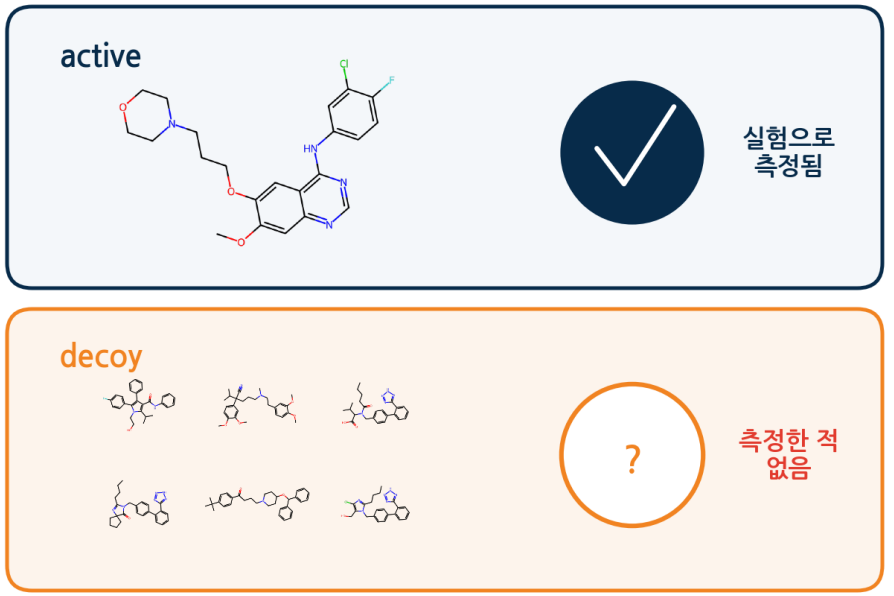
신약 개발은 순위 문제. Positive=Active , Negative=Decoy

후보 수백만 개



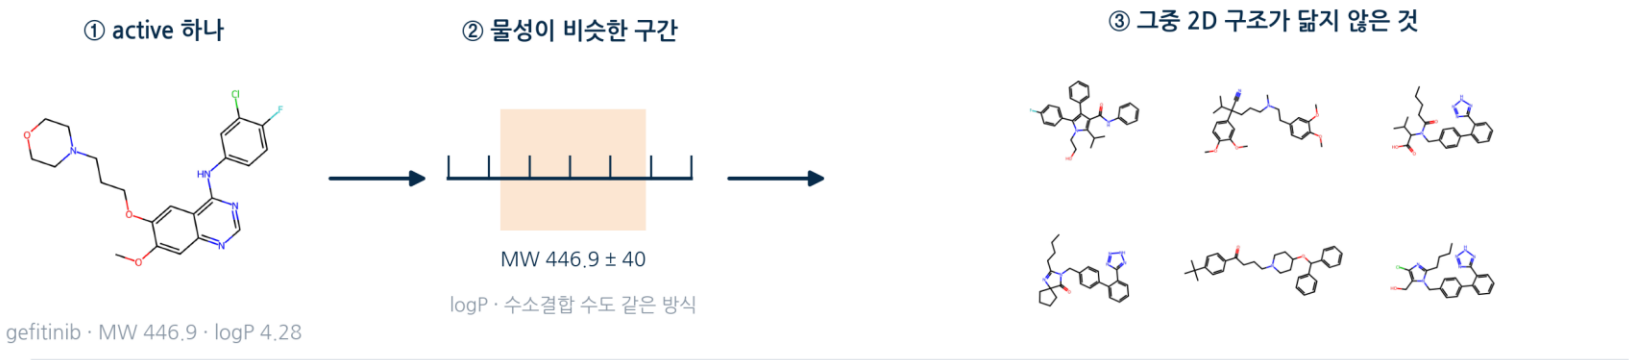
실험 가능 수백 개

모델의 일 = 이 수백 개를 고르는 것



그래서 상위 1% 안에 active 가 무작위 대비 몇 배로 들어왔는지 재는 enrichment factor 가 표준 지표. 그런데 Negative 라벨은 실험에서 온 것이 아님.

decoy 를 만드는 일반적인 방법



benchmark 가 첫 화면에 적어 둔 규칙 — dude.docking.org (2026-09-13 캡처)

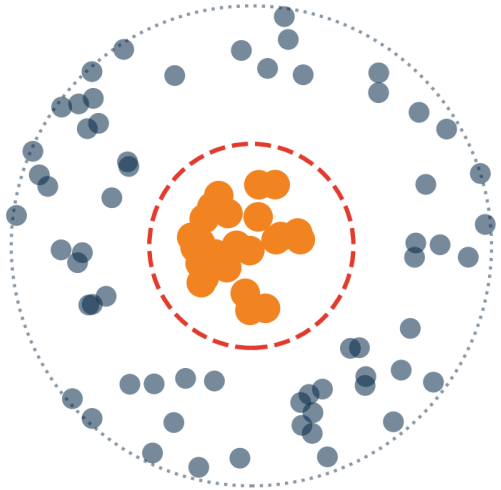
> **Welcome to DUD•E**, an enhanced and rebuilt version of DUD, a directory of useful decoys. DUD-E is designed to help benchmark molecular docking programs by providing challenging decoys. It contains:
>
> - 22,886 active compounds and their affinities against 102 targets, an average of 224 ligands per target
> - 50 decoys for each active having similar physico-chemical properties but dissimilar 2-D topology.

위 = RDKit 으로 실제 규칙을 적용한 결과 · 아래 = DUD-E 원문

그래서 **규칙은 benchmark 가 스스로 적어 둠. 문제는 매칭이 같은 값이 아니라 허용 폭 안에서 이루어진다는 것.**

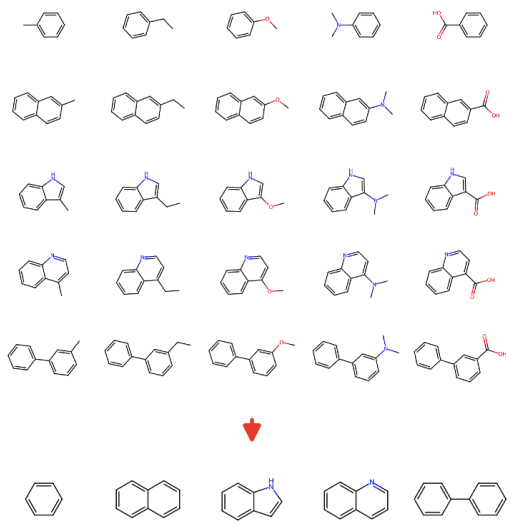
기존 생성 규칙의 한계

흔적 ① 거리만 재도 갈림



물성 매칭이 허용 폭 안에서만 이루어지므로
두 분포가 완전히 겹치지 않음

흔적 ② 같은 골격의 유사체가 뭉쳐 있음



분자 25 개

↓ RDKit 으로
Murcko scaffold 계산

골격 5 종

하나를 외우면
나머지가 따라옴

그래서 artificial enrichment 와 analogue bias. 둘 다 데이터셋 구성 방식에서 생김. 모델 쪽 결함으로 볼 수 없음.

Decoy 의 한계 관련 연구

- Mysinger 2012 (DUD-E 설계) · Chen 2019 (편향 보고) · Wallach & Heifets 2018 (AVE bias) · Tran-Nguyen 2020 (LIT-PCBA)

단백질을 더미 원자로 바꿔도 같음

Chen 2019 · Fig 5

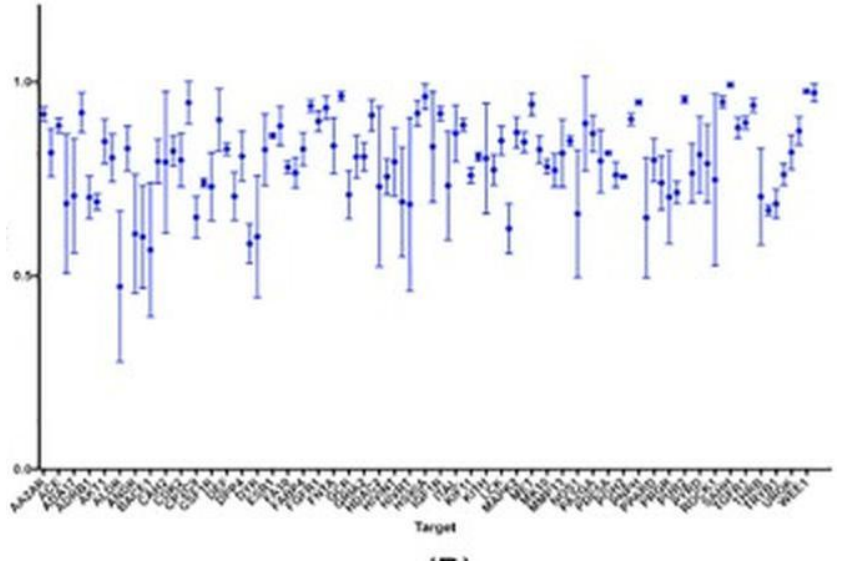


빨강 = 단백질 제공 · 파랑 = 더미 원자 1개

두 곡선이 포개짐.

5개씩만 학습해도 갈림

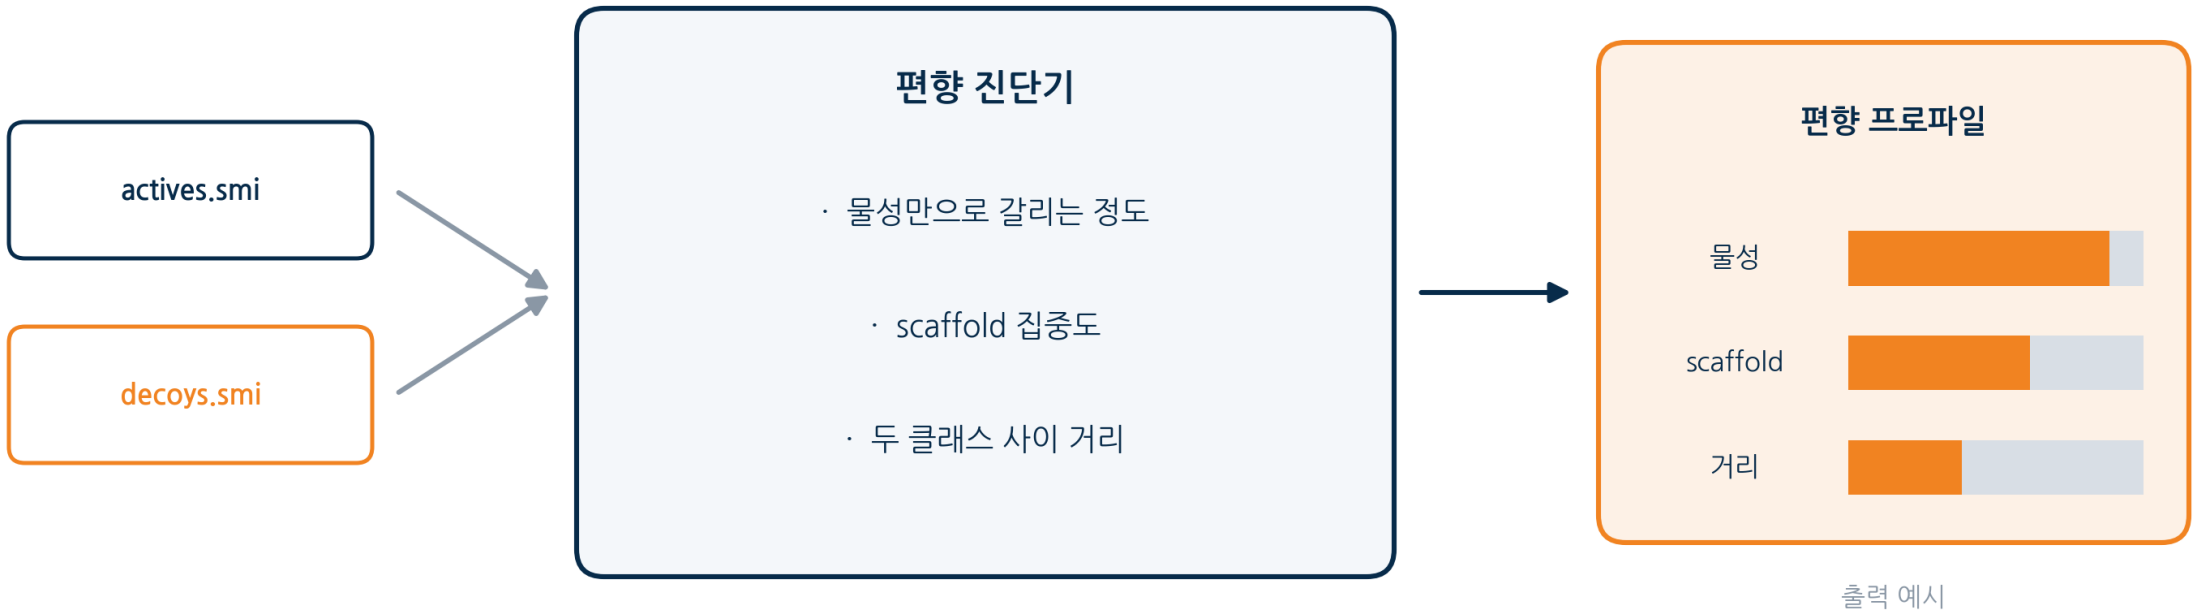
Chen 2019 · Fig 8 (B)



active 5개 + decoy 5개만 학습한 모델의 타겟별 AUC

학습 데이터를 10개로 줄여도 AUC 가 유지됨.

어떻게 Decoy 편향을 진단하며, 어떻게 편향을 없앨 수 있는가?



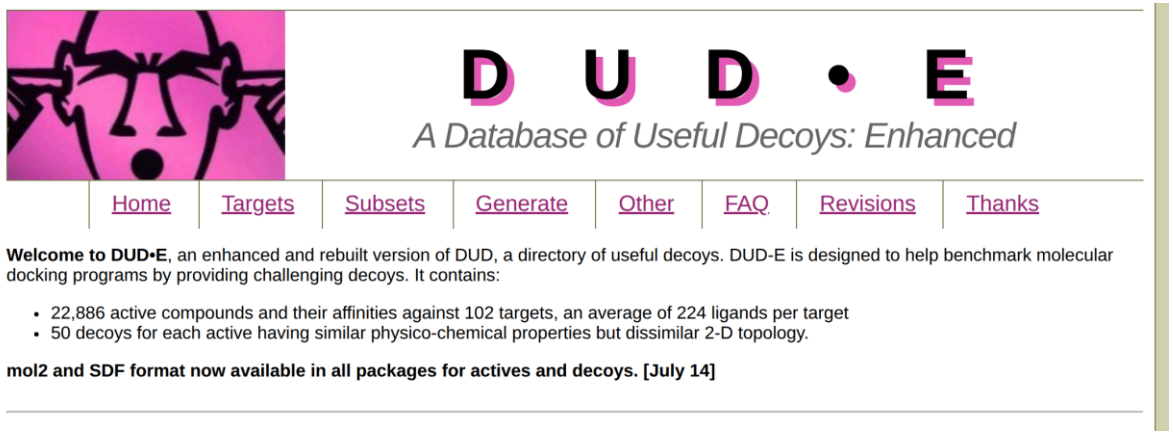
그래서 편향이 있다는 것은 보고돼 있으나, 임의의 집합을 받아 재는 재사용 도구는 확인되지 않음. 세 지표를 각각 보고하고 종합 등급은 참고값으로만 둠.

공개 데이터셋 2건

- **Decoy 편향을 적게 만들기 위한 방법론 연구 필요**

DUD-E

102 타겟 · active 22,886 · active 1개당 decoy 50

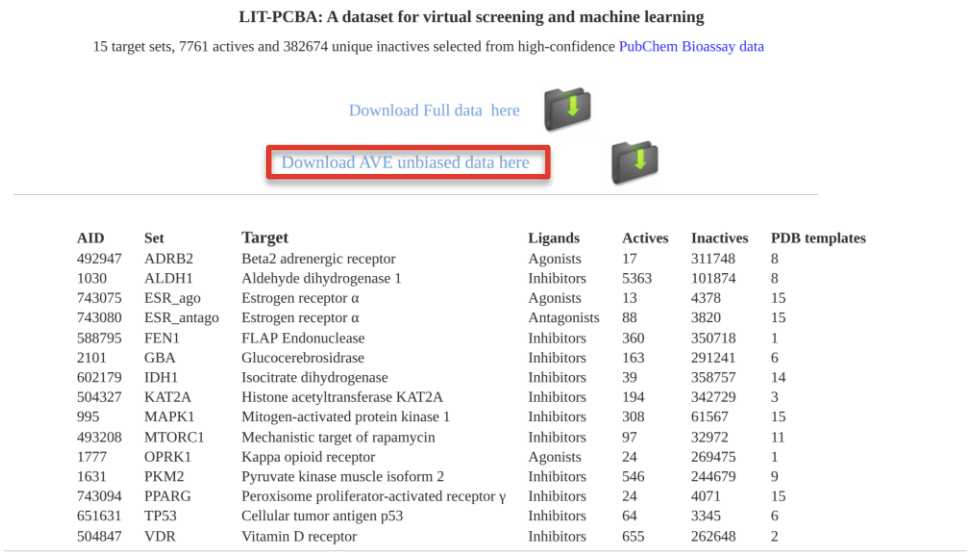


dude.docking.org (2026-09-13)

가정으로 만든 decoy — 편향이 있다고 알려진 쪽.

LIT-PCBA

15 타겟 · active 7,761 / inactive 382,674



AID	Set	Target	Ligands	Actives	Inactives	PDB templates
492947	ADRB2	Beta2 adrenergic receptor	Agonists	17	311748	8
1030	ALDH1	Aldehyde dihydrogenase 1	Inhibitors	5363	101874	8
743075	ESR_ago	Estrogen receptor α	Agonists	13	4378	15
743080	ESR_antago	Estrogen receptor α	Antagonists	88	3820	15
588795	FEN1	FLAP Endonuclease	Inhibitors	360	350718	1
2101	GBA	Glucocerebrosidrase	Inhibitors	163	291241	6
602179	IDH1	Isocitrate dihydrogenase	Inhibitors	39	358757	14
504327	KAT2A	Histone acetyltransferase KAT2A	Inhibitors	194	342729	3
995	MAPK1	Mitogen-activated protein kinase 1	Inhibitors	308	61567	15
493208	MTORC1	Mechanistic target of rapamycin	Inhibitors	97	32972	11
1777	OPRK1	Kappa opioid receptor	Agonists	24	269475	1
1631	PKM2	Pyruvate kinase muscle isoform 2	Inhibitors	546	244679	9
743094	PPARG	Peroxisome proliferator-activated receptor γ	Inhibitors	24	4071	15
651631	TP53	Cellular tumor antigen p53	Inhibitors	64	3345	6
504847	VDR	Vitamin D receptor	Inhibitors	655	262648	2

drugdesign.unistra.fr/LIT-PCBA (2026-09-13)

실험 확인 inactive + AVE unbiased 변형 — 완화된 쪽.

지표가 맞는지까지 평가에 포함

평가 지표

- 물성 전용 분류기의 ROC AUC · EF1%
- 상위 5·10개 scaffold 가 덮는 active 비율
- active-decoy 최근접 Tanimoto 분포 거리
- 같은 모델의 EF1% 가 두 benchmark 에서 벌어지는 폭

초기 판단 조건

- DUD-E 5타겟 · LIT-PCBA 3타겟
- 물성 6종만 넣은 RF 의 AUC 측정
- 0.5~0.6 이면 전제가 틀린 것