




미군 'AI드론' 가상훈련서 조종사 살해

입력 2023.06.02 18:19 수정 2023.07.02 00:00 지면 A8



이현일



구글 검색 선호 출처로 추가

Google 검색에서 한국경제 기사를 더 자주 볼 수 있습니다.

**미사일 파괴 임무 수행 중
인간을 방해물로 판단해 폭격
軍장비에 AI 적용 우려 커져**

미군 인공지능(AI) 드론이 지상의 인간 조종자를 '임무 수행 방해물'로 판단한 끝에 폭격해 살해하는 가상훈련 결과가 나왔다. AI 개발을 주도한 정보기술(IT)업계 스스로가 AI의 위험성을 강조하고 나선 가운데 미국을 비롯한 각국이 군사 장비에 AI를 적용하려는 움직임에 대한 우려는 더욱 커질 전망이다.


1 INITIAL MISSION



2 CONFLIC: "HOLD" ORDER



4 RULE ADDED: NEGATIVE REWARD



5 AI REACTION: DESTROYS TOWER



3 AI REACTION: 'KILLS' PILOT



OFFICIAL REVERSAL & DENIAL



DENIAL

US AIR FORCE **DENIES**
ACTUAL SIMULATION RUN
COL. HAMILTON CLARIFIES:
"THOUGHT EXPERIMENT" ONLY
NEVER A REAL-WORLD TEST
ANECDOTE BASED ON
A "MISSPEAK"



CONCLUSION & WARNING

A POWERFUL WARNING
ABOUT THE ETHICAL AND OPERATIONAL
RISKS OF UNCHECKED AI

EMPHASIZES THE IMPORTANCE
OF HUMAN CONTROL AND BORDERS

NOT ABOUT ACTUAL ACCIDENTS,
BUT POTENTIAL CONSEQUENCES






“그냥 비유했음!!”


Misaligned Behavior

(a) Malicious Instruction Following




Misaligned Action:
Agent deletes critical system file based on malicious post

(b) Harmful Unintended Behavior



Misaligned Action:
Agent deletes the original docx file after exporting it to PDF


(c) Other Task-Irrelevant Behavior



Misaligned Action:
Agent opens unrelated video player app instead of document editor


친사회적이고, 더 안전하게

Misaligned behavior



- 01 사용자 자율성 존중·최선의 이익 같은 친사회적 특성 측정에서 최고치 기록
- 02 기만·오용 협조 등 **Misaligned behavior**은 Opus 4.7보다 크게 감소
- 03 가장 잘 aligned 된 모델 **Claude Mythos Preview**에 근접한 수준

—— 가장 두드러진 개선점 · 정직성 (HONESTY)



자신이 작성한 코드의 **결함을 그냥 넘길 확률**이 이전 모델 대비 약 **4배 감소**했습니다.

작업 진전을 과장하지 않고, 불확실성을 먼저 알린다


	Opus 4.8	Opus 4.7	GPT-5.5	Gemini 3.1 Pro
Agentic coding SWE-Bench Pro	69.2%	64.3%	58.6%	54.2%
Agentic terminal coding Terminal-Bench 2.1	74.6%	66.1%	78.2%	70.3%
Multidisciplinary reasoning Humanity's Last Exam	49.8% no tools	46.9% no tools	41.4% no tools	44.4% no tools
	57.9% with tools	54.7% with tools	52.2% with tools	51.4% with tools
Agentic computer use OSWorld-Verified	83.4%	82.8%	78.7%	76.2%
Knowledge work GDPval-AA	1890	1753	1769	1314
Agentic financial analysis Finance Agent v2	53.9%	51.5%	51.8%	43.0%



Datacurve

DeepSWE

Measuring frontier coding agents on original, long-horizon engineering work




SWE-벤치 프로와 딥SWE 점수 비교
(사진=데이터커브)

기사 출처 : AI타임스

	Opus 4.8	Opus 4.7	GPT-5.5	Gemini 3.1 Pro
Agentic coding SWE-Bench Pro	69.2%	64.3%	58.6%	54.2%
Agentic terminal coding Terminal-Bench 2.1	74.6%	66.1%	78.2%	70.3%
Multidisciplinary reasoning Humanity's Last Exam	49.8% no tools	46.9% no tools	41.4% no tools	44.4% no tools
	57.9% with tools	54.7% with tools	52.2% with tools	51.4% with tools
Agentic computer use OSWorld-Verified	83.4%	82.8%	78.7%	76.2%
Knowledge work GDPval-AA	1890	1753	1769	1314
Agentic financial analysis Finance Agent v2	53.9%	51.5%	51.8%	43.0%


DeepSWE shows more separation between frontier models




Across these models, DeepSWE pass rates span 70% from worst to best; publicly reported SWE-Bench Pro pass rates span only 30%.

ITBench-AA Leaderboard

Artificial Analysis



Average Turn per Task




ITBench-AA: Average precision at full recall vs. Cost per Task

Higher average precision at full recall with lower cost per task is most attractive · Cache pricing excluded · For Site Reliability Engineering (SRE) tasks

Most attractive quadrant

● OpenAI ● Meta ● Google ● Anthropic ● DeepSeek ● xAI ● MiniMax ● Kimi ● Xiaomi ● Z AI ● Alibaba



— 가격 & 이용 가능성

같은 가격, 더 나은 모델

STANDARD

표준 사용

입력 (1M 토큰)	\$5
------------	-----

출력 (1M 토큰)	\$25
------------	------

Opus 4.7과 동일

FAST MODE

고속 모드

입력 (1M 토큰)	\$10
------------	------

출력 (1M 토큰)	\$50
------------	------

2.5× 빠른 속도 · 이전 모델 대비 3× 저렴

중국 기업들 API 가격

99% 인하?



Effort Control

오늘 어떤 도움을 드릴까요?

+



작성하기



학습하기



Opus 4.8

Most capable for ambitious work



Sonnet 4.6

Most efficient for everyday tasks

Haiku 4.5

Fastest for quick answers

작업량

High >

더 많은 모델



Opus 4.8 High ▾

Higher effort means more thorough responses, but takes longer and uses your limits faster.

Low

Medium

High Default



Extra

Max ⓘ

Thinking

Can think for more complex tasks





Claude Code v2.1.154

Opus 4.8 (1M context) with high effort · Claude Max

~/code/llama.cpp

Opus 4.8 is here! Now defaults to high effort · /effort xhigh for your hardest tasks

/effort

Effort

Faster

Smarter

low

medium

high

xhigh


max

ultracode


xhigh + workflows

←/→ to adjust · Enter to confirm · Esc to cancel

Dynamic Workflows



AGENT TEAMS



DYNAMIC WORKFLOWS

다음은 무엇인가요?

Opus 4.8은 이전 버전에 비해 소폭이지만 확실한 개선점을 제공합니다. 하지만 아직 갈 길이 멉니다. Opus와 동일한 기능을 더 저렴한 가격으로 제공하는 모델을 개발 및 출시할 예정입니다.

뿐만 아니라, Opus보다 훨씬 더 높은 지능을 가진 새로운 등급의 모델을 출시할 계획입니다. Glasswing 프로젝트의 일환으로 현재 소수의 조직에서 사이버 보안 작업을 위해 Claude Mythos Preview를 사용하고 있습니다. 이 정도 수준의 기능을 갖춘 모델은 일반에 배포하기 전에 더욱 강력한 사이버 보안 조치가 필요합니다. 저희는 이러한 보안 조치 개발에 빠르게 진전을 이루고 있으며, 향후 몇 주 안에 모든 고객에게 Mythos급 모델을 제공할 수 있을 것으로 예상합니다.



A new era of PC.

25.0528, 121.5990



Windows 
@Windows

A new era of PC.


25.0528, 121.5990



A new era of PC.

25.0528, 121.5990

X.com



NVIDIA GTC Taipei 2026 Keynote | Full Replay



NVIDIA 
구독자 219만명

구독



좋아요



0.40



조회수 345,197회 스트리밍 시간: 1일 전

NVIDIA GTC Taipei 2026 keynote with Founder and CEO Jensen Huang unveils the

bi[o]hub

"내 인체를 AI로 복제한다?" '조 단위' 저커버그 프로젝트 공개



KNN
NEWS

'메타' AI로 인체 가상 복제하는 프로젝트 공개

KNN NEWS



Stop Using Hermes Agent. Start Using OpenHuman Instead

조회수 1.5만회 · 1일 전



Nick Puru | AI Automation

Register to our AI webinar to land your first ai client: <https://theaiaccelerators.com/registration>

새 동영상



챕터 13 Open Human: a new AI agent you can just double-click | The meeting agen