



AfterMap

위성영상 건물 피해 판독 ,
어디까지 믿을 수 있는가

xBD / Siamese U-Net / 3 계층 지표 설계

01 재난이 나면 , 가장 급한 건 판독입니다

72 시간

1 차 피해 규모 보고 마감
자원 배분이 이 숫자로 결정

4,000 장

도시 하나 분량의 위성 타일
담당자가 한 장씩 육안 확인

수일

숙련 분석가 여러 명이
판독에 소요하는 시간

병목은 판독의 정확도가 아니라 판독의 순서입니다 .

" 이 건물이 얼마나 부서졌나 " 보다 " 수천 장 중 어디부터 볼 것인가 " 가 먼저 해결되어야 합니다 .

영상은 무료로 공개됩니다 . 판독만 수작업입니다

이미 해결된 것

- Sentinel-1 (ESA) — 상시 무료 개방
- Vantor Open Data Program — 급성 재난 발생 시 전후 영상 공개
- xBD — 건물 폴리곤 85 만 개 , 피해등급 라벨 완비
- 오픈소스 세그멘테이션 모델 다수 공개

여전히 사람이 하는 것

- 수천 장 타일을 한 장씩 열어보기
- 전후 영상 눈으로 대조하기
- 무너진 건물 세고 좌표 옮겨 적기
- → 예산이 없는 조직일수록 더 늦게 압니다

데이터는 민주화되었지만 , 판독은 민주화되지 않았습니다 .

그래서 저희가 던진 질문은

" 성능을 얼마나 올릴 것인가 " 가 아니라

" 어느 등급까지 실제로 쓸 수 있는가 "

■ 재난 대응에서 자동 판정은 애초에 목표가 아닙니다 . 사람이 검증합니다 .

■ 필요한 건 " 이 출력을 어디까지 신뢰해도 되는가 " 의 경계선입니다 .

■ 그 경계선은 성능 수치 하나가 아니라 , 지표 설계로만 드러납니다 .

03

데이터 : xBD / xView2

라벨이 완비된 공개 벤치마크 — 직접 라벨링 없음 , 성능 비교 가능

850K+

건물 폴리곤

6

재난 유형

45,000

km² 관측 면적

1024²

RGB 타일 (pre/post 쌍)

피해 등급 — 재난 유형 간 비교가 가능하도록 조화된 4 단계 . 한 건물의 모든 픽셀에 동일 등급 부여 .

No Damage

손상 없음

Minor

경미 — 부분 손상

Major

심각 — 구조 손상


Destroyed

전파 — 붕괴

라이선스

xBD 는 CC BY-NC-SA 4.0, Vantor Open Data 는 CC BY-NC 4.0 입니다 . 즉 이 데이터로 학습한 가중치는 상업적 이용이 불가하고 SA 조건을 상속합니다 .
→ 코드는 Apache 2.0, 학습 가중치는 CC BY-NC-SA 4.0 으로 분리 배포합니다 .

04 EDA ① 이 데이터는 아무것도 예측하지 않아도 정확합니다



※ 배치 예시 — 8/18 실측치로 교체

여기서 나오는 결론 두 개

정확도 (accuracy) 는 쓸 수 없다

전부 " 건물 아님 " 으로 찍어도 80% 대가 나옵니다 . 지표로 성립하지 않습니다 .

손실 가중치가 필수다

Minor·Major·Destroyed 는 각각 전체의 2% 미만입니다 .
가중치 없이 학습하면 모델이 소수 등급을 아예 학습하지 않습니다 .

→ 그래서 F1 을 기본 지표로 채택합니다 . 다만 F1 도 충분하지 않다는 걸 뒤에서 보여드리겠습니다 .

05 EDA ② 사람도 Minor 와 Major 를 구분하기 어렵습니다

[pre 영상 타일]

8/18 실제 타일 캡처로 교체

[post 영상 타일 — Minor 라벨]

8/18 실제 타일 캡처로 교체

[post 영상 타일 — Major 라벨]

8/18 실제 타일 캡처로 교체

이건 모델의 문제가 아니라 태스크의 문제입니다

- Minor 와 Major 의 경계는 고해상도 위성영상에서도 육안 판별이 어렵습니다 . 지붕만 보이는 하향 시점에서 벽체 · 구조 손상은 관측되지 않습니다 .
- 라벨 자체에도 애매성이 있습니다 — 겉보기 손상이 없어 보이는 건물이 Minor 로 라벨된 사례가 보고되어 있습니다 .

06 방법론 ① 왜 YOLO 를 쓰지 않았는가

가장 흔한 선택지를 먼저 배제한 근거

	YOLO 계열 (instance seg.)	본 과제의 요구
입력 구조	단일 이미지	pre / post 두 장의 쌍 (bi-temporal)
판단 대상	이미지 안의 객체	두 영상 사이의 변화
출력 형식	박스 + 마스크	픽셀 단위 폴리곤 마스크
평가 방식	박스 IoU 기반 mAP	마스크 대조 F1 (벤치마크 규격)
밀집 도시	인접 건물이 박스로 뭉개짐	건물 단위 분리가 필수

YOLO 는 좋은 모델이지만 이 태스크의 입력 구조와 맞지 않습니다 . 성능 이전에 형식의 문제입니다 .

07 방법론 ② Siamese U-Net, 2 단계 구조

xView2 상위 솔루션이 공통으로 채택한 계열

Stage 1 — 건물 로컬라이제이션


pre 영상만 입력 → ImageNet 사전학습 인코더 (ResNet34) + U-Net 디코더 → 건물 마스크

segmentation_models_pytorch 사용 — 구현 코드 수신킴

Stage 2 — 피해 등급 분류

pre / post 를 가중치 공유 Siamese 브랜치에 통과 → 특징 차분 · 연결 → 디코더 → 4 등급 분류

클래스 가중치 / focal loss 적용



가중치를 공유하는 두 브랜치에 각각 통과

축소 경로 Stage 2 가 시간 내 수렴하지 않으면 Stage 1 + 이진 변화 탐지까지 완주하고 , 4 등급 분류는 " 시도 및 실패 " 로 보고합니다 .

지표 설계 : 3 계층

이 프로젝트의 핵심 — 하나의 숫자로 신뢰구간이 드러나지 않습니다

1. 벤치마크 계층

xView2 공식 점수
= 로컬라이제이션 F1 30% + 피해분류 F1 70% (픽셀 단위)

우리 모델의 객관적 위치를 공개 리더보드 대비로 고정합니다 .

2. 운용 계층

건물 객체 단위 F1
(로컬라이제이션 / 등급별)

픽셀 지표는 큰 건물에 가중됩니다 . 현장에서 세는 단위는 픽셀이 아니라 건물입니다 .

3. 비용 계층


QWK (순서형) + 등급별 Recall
특히 **Destroyed** 누락률

등급은 순서형입니다 . Destroyed 를 Major 로 틀리는 것과 No Damage 로 틀리는 것은 비용이 다릅니다 .

배제한 지표 — 정확도 (불균형으로 무의미) / mAP(모든 오분류를 등가로 취급 , 순서형 무시)

결과 ① 벤치마크 위치

xView2 공식 점수 — 픽셀 단위 가중 F1



※ 배치 예시 — 8/18 실측치로 교체


그런데 이 숫자는 실제 성능을 크게 과대평가하고 있습니다 .

읽는 법

- 상위 5 개 솔루션은 0.73 ~ 0.81 구간입니다 . 대회 참가팀들이 수개월을 투입한 결과입니다 .
- 저희는 5 일 , 단일 모델 , 서브셋 5,000 장 조건입니다 . 순위 경쟁이 목적이 아닙니다 .
- 이 슬라이드의 목적은 하나 — 우리 모델이 논의할 가치가 있는 범위에 있음을 확인하는 것입니다 .

10 결과 ② 픽셀 지표는 성능을 과대평가합니다

xView2 상위 5 개 솔루션을 건물 객체 단위로 재계산한 공개 수치



출처: xFBD, Focused Building Damage Dataset and Analysis (arXiv:2212.13876)

0.78 → 0.44


같은 모델 , 같은 예측입니다 .
지표를 픽셀에서 건물로 바꿨을 뿐입니다 .

픽셀 지표는 면적이 큰 건물에 가중됩니다 . 큰 건물 하나를 맞히면 작은 건물 여럿을 놓쳐도 점수가 유지됩니다 .

우리 모델도 동일한 패턴을 보였습니다 . [수치 기입]

11 결과 ③ 등급별로 뜯어보면 Minor 에서 무너집니다

xView2 상위 5 개 솔루션의 등급별 객체 F1 평균



출처: xFBD (arXiv:2212.13876) 상위 5 개 솔루션 평균 · 개별 솔루션 Minor F1 은 0.16 ~ 0.25 구간

EDA 에서 본 것과 정확히 일치합니다

- Minor 0.21 — 사람도 구분하기 어려웠던 등급에서 모델도 무너집니다 .
- 양 끝단 (No Damage, Destroyed) 은 상대적으로 안정적입니다 . 시각적으로 명확하기 때문입니다 .
- **이건 특정 모델의 결함이 아닙니다 . 상위 5 개 솔루션 전부에서 같은 곡선이 나옵니다 .**

→ 4 등급을 다 맞추는 것은 현 시점에서 열린 문제입니다 . 우리 모델도 예외가 아니었습니다 . [수치 기입]

결과 ④ 학습하지 않은 재난에서는 어떻게 되는가

재난 유형 hold-out — 한 유형을 통째로 제외하고 학습한 뒤 그 유형에서 평가

무작위 분할


같은 재난의 인접 타일이 학습 · 검증에 동시 포함 → 성능이 부풀려짐

재난 유형 hold-out

예 : 산불 전체를 학습에서 제외 → 산불에서만 평가

측정 대상

두 조건의 차이 = 미지의 재난에 대한 일반화 실패의 크기



※ 배치 예시 — 8/18 실측치로 교체

→ 학습에 없던 재난 유형에서는 전 등급이 하락하며 , Minor·Major 의 하락폭이 가장 큼니다 .

결론 — 배포 가능 구간

지금 쓸 수 있는 것

- 이진 판정 — 피해 있음 / 없음
- 판독 우선순위 정렬 (검토 대상 축소)
- Destroyed 등급의 개략적 위치 파악

아직 쓸 수 없는 것

- Minor / Major 구분 — 등급별 F1 이 운용 기준 미달
- 학습에 없던 재난 유형에 대한 무검증 적용
- 사람 검증 없는 자동 피해 집계

저희가 만든 건 판독기가 아니라 분류기 (triage) 입니다 .

성능을 올리는 대신 경계선을 그었습니다 . 이 경계선은 하나의 숫자가 아니라 3 계층 지표로만 드러납니다 . 산출물에는 이 구간을 명시한 모델 카드를 포함합니다 .

다음 단계 — SAR(Sentinel-1) 결합으로 구름 · 야간 대응 · 한국 도시 데이터 재학습 · 시계열 확장으로 복구 진척 추적

코드 Apache 2.0 · 학습 가중치 CC BY-NC-SA 4.0 · 데이터 xBD (CC BY-NC-SA 4.0), Vantor ODP (CC BY-NC 4.0)