

AfterMap 발표 유인물

슬라이드 15장 + 발표 대본 · 발표 15분 / Q&A 15분

시간 배분

01	표지	0:00 – 0:20
02	문제 — 판독 병목	0:20 – 1:20
03	역설 — 영상 vs 판독	1:20 – 2:00
04	질문 전환 ★	2:00 – 2:40
05	데이터 xBD	2:40 – 3:40
06	EDA ① 불균형	3:40 – 4:30
07	EDA ② 육안 판별	4:30 – 5:20
08	방법론 ① 왜 YOLO가 아닌가	5:20 – 6:20
09	방법론 ② Siamese U-Net	6:20 – 7:20
10	지표 설계 3계층 ★★	7:20 – 9:00
11	결과 ① 벤치마크 위치	9:00 – 9:40
12	결과 ② 픽셀 vs 객체 ★★	9:40 – 10:50
13	결과 ③ 등급별 붐피	10:50 – 11:50
14	결과 ④ hold-out	11:50 – 12:50
15	결론 — 배포 가능 구간	12:50 – 14:30

발표 전 플레이스홀더 교체 확인

- ☐ 01 표지 — 팀명 / 발표자 이름
- ☐ 06 EDA① — 클래스 분포 실측 수치 + 빨간 캡션 삭제
- ☐ 07 EDA② — 타일 이미지 3장 + 빨간 캡션 삭제
- ☐ 11 결과① — AfterMap 막대 실측치 + 빨간 캡션 삭제
- ☐ 12 결과② — 우측 하단 [수치 기입]
- ☐ 13 결과③ — 하단 [수치 기입]
- ☐ 14 결과④ — 차트 전체 수치 (미실행 시 슬라이드 삭제)

14분 30초에 끝냅니다. 15분을 넘기면 평가항목 1번에서 감점입니다.
10번 슬라이드(3계층 지표)에 100초를 씁니다. 평가항목 7번의 최대 득점 구간입니다.
12번 슬라이드의 “0.78 → 0.44”를 손으로 가리키며 말합니다. 발표의 클라이맥스입니다.
수치를 모르면 지어내지 말고 자료의 표를 그대로 읽습니다.



AfterMap

위성영상 건물 피해 판독,
어디까지 믿을 수 있는가

xBD / Siamese U-Net / 3 계층 지도 설계

MINI AIFFELETHON · 2026.08.19

[팀명 / 발표자 이름 기입]

대 본

안녕하십니까. 저희 팀 발표를 시작하겠습니다.

주제는 위성영상으로 건물 피해를 판독하는 모델입니다. 다만 저희가 던진 질문은 "성능을 얼마나 올렸는가"가 아니라 "이 모델을 어디까지 믿을 수 있는가"입니다.

왜 그 질문을 골랐는지부터 말씀드리겠습니다.

발표자 메모 — 읽지 않음

- 여기서 절대 서두르지 말 것. 첫 20초의 속도가 15분 전체 속도를 결정한다.
- 제목 슬라이드에서 팀명과 본인 이름을 확인하고 시작.

01 재난이 나면 , 가장 급한 건 판독입니다**72** 시간1 차 피해 규모 보고 마감
자원 배분이 이 숫자로 결정**4,000** 장도시 하나 분량의 위성 타일
담당자가 한 장씩 육안 확인**수일**숙련 분석가 여러 명이
판독에 소요하는 시간**병목은 판독의 정확도가 아니라 판독의 순서입니다 .**

" 이 건물이 얼마나 부서졌나 " 보다 " 수천 장 중 어디부터 볼 것인가 " 가 먼저 해결되어야 합니다 .

대 본

재난이 발생하면 보통 72시간 안에 1차 피해 규모를 보고해야 합니다. 어디에 구조 인력과 자원을 먼저 보낼지가 그 숫자로 결정되기 때문입니다.

그런데 실무는 이렇습니다. 도시 하나를 덮는 위성 타일이 수천 장 나옵니다. 담당자가 이걸 한 장씩 열어서, 전후를 비교하고, 무너진 건물을 눈으로 세고, 좌표를 옮겨 적습니다. 숙련된 분석가 여러 명이 며칠을 씁니다. 골든타임은 그사이에 지나갑니다.

여기서 중요한 건, 병목이 판독의 정확도가 아니라는 점입니다. "이 건물이 얼마나 부서졌나"보다 "수천 장 중에 어디부터 볼 것인가"가 먼저 해결되어야 합니다.

발표자 메모 — 읽지 않음

- 아래 검은 박스 문장은 토박토박. 이 발표의 전제다.

02 영상은 무료로 공개됩니다 . 판독만 수작업입니다**이미 해결된 것**

- Sentinel-1 (ESA) — 상시 무료 개방
- Vantor Open Data Program — 급성 재난 발생 시 전후 영상 공개
- xBD — 건물 폴리곤 85 만 개 , 피해등급 라벨 완비
- 오픈소스 세그멘테이션 모델 다수 공개

여전히 사람이 하는 것

- 수천 장 타일을 한 장씩 열어보기
- 전후 영상 눈으로 대조하기
- 무너진 건물 세고 좌표 옮겨 적기
- → 예산이 없는 조직일수록 더 늦게 압니다

데이터는 민주화되었지만 , 판독은 민주화되지 않았습니다 .

대 본

역설적인 건, 데이터 쪽은 이미 상당 부분 해결되어 있다는 점입니다.

왼쪽을 보시면 — ESA의 Sentinel-1은 상시 무료입니다. Vantor, 예전 Maxar조, 이쪽 Open Data Program은 급성 재난이 발생하면 전후 영상을 공개합니다. xBD라는 데이터셋에는 건물 폴리곤 85만 개에 피해 등급 라벨까지 다 붙어 있습니다. 모델도 오픈소스로 널리 있습니다.

그런데 오른쪽, 판독은 여전히 사람이 합니다. 그리고 이 격차의 비용은 예산이 없는 조직이 가장 크게 치릅니다.

데이터는 민주화되었는데, 판독은 민주화되지 않았습니다.

발표자 메모 — 읽지 않음

- 마지막 한 줄에서 한 박자 쉬고 다음 슬라이드로.

그래서 저희가 던진 질문은

" 성능을 얼마나 올릴 것인가 " 가 아니라

" 어느 등급까지 실제로 쓸 수 있는가 "

■ 재난 대응에서 자동 판정은 애초에 목표가 아닙니다 . 사람이 검증합니다 .

■ 필요한 건 " 이 출력을 어디까지 신뢰해도 되는가 " 의 경계선입니다 .

■ 그 경계선은 성능 수치 하나가 아니라 , 지표 설계로만 드러납니다 .

대 본

그래서 저희가 던진 질문은 "성능을 얼마나 올릴 것인가"가 아닙니다. "어느 등급까지 실제로 쓸 수 있는가"입니다.

이유는 세 가지입니다.

첫째, 재난 대응에서 완전 자동 판정은 애초에 목표가 아닙니다. 피해 기록은 나중에 배상과 복구, 책임 규명의 근거가 되기 때문에 검증되지 않은 자동 판정이 섞이면 기록 전체의 신뢰가 무너집니다. 사람이 반드시 검증합니다.

둘째, 그렇다면 필요한 건 "이 출력을 어디까지 믿어도 되는가"의 경계선입니다.

셋째, 그 경계선은 성능 수치 하나로는 절대 드러나지 않습니다. 지표를 어떻게 설계하느냐로만 드러납니다. 이게 오늘 발표의 핵심입니다.

발표자 메모 — 읽지 않음

- 이 슬라이드가 발표 전체의 전환점. 여기서 청중이 프레임을 잡는다.
- 심사자가 나중에 "왜 성능을 더 안 올렸나"를 물으면 이 슬라이드로 되돌아온다.

03 데이터 : xBD / xView2

라벨이 완비된 공개 벤치마크 — 직접 라벨링 없음, 성능 비교 가능

850K+

건물 폴리곤

6

재난 유형

45,000

km² 관측 면적

1024²

RGB 타일 (pre/post 쌍)

피해 등급 — 재난 유형 간 비교가 가능하도록 조화된 4 단계. 한 건물의 모든 픽셀에 동일 등급 부여.

No Damage

손상 없음

Minor

경미 — 부분 손상

Major

심각 — 구조 손상

Destroyed

전파 — 붕괴

라이선스

xBD는 CC BY-NC-SA 4.0, Vantor Open Data는 CC BY-NC 4.0입니다. 즉 이 데이터로 학습한 가중치는 상업적 이용이 불가하고 SA 조건을 상속합니다. → 코드는 Apache 2.0, 학습 가중치는 CC BY-NC-SA 4.0으로 분리 배포합니다.

대 본

데이터는 xBD, xView2 챌린지 데이터셋을 씁니다.

건물 폴리곤이 85만 개 이상, 6개 재난 유형, 관측 면적 4만 5천 제곱킬로미터입니다. 원본은 1024 곱하기 1024 RGB 타일이고, 재난 전과 후가 쌍으로 제공됩니다.

이 데이터셋을 고른 이유는 두 가지입니다. 첫째, 라벨이 이미 다 붙어 있어서 5일 안에 라벨링에 시간을 쓸 필요가 없습니다. 둘째, xView2라는 공개 챌린지가 있어서 우리 성능의 위치를 객관적으로 비교할 수 있습니다.


피해 등급은 4단계입니다. 중요한 건 이 등급이 재난 유형 간에 비교 가능하도록 조화되어 있다는 점, 그리고 한 건물의 모든 픽셀에 같은 등급이 붙는다는 점입니다. 이 두 번째 특성이 뒤에서 지표 이야기를 할 때 다시 나옵니다.

마지막으로 라이선스입니다. xBD는 CC BY-NC-SA, Vantor 데이터는 CC BY-NC입니다. 비상업 조건이라서, 이 데이터로 학습한 가중치는 상업적으로 못 씁니다. 그래서 저희는 코드는 Apache 2.0으로, 가중치는 CC BY-NC-SA로 분리해서 배포합니다.

발표자 메모 — 읽지 않음

- 라이선스는 빠르게. 다만 반드시 언급할 것. 이걸 짚는 팀이 거의 없어서 점수가 된다.

04 EDA ① 이 데이터는 아무것도 예측하지 않아도 정확합니다



※ 배치 예시 - 8/18 실측치로 교체

여기서 나오는 결론 두 개

정확도 (accuracy) 는 쓸 수 없다
전부 " 건물 아님 " 으로 찍어도 80% 대가 나옵니다 . 지표로 성립하지 않습니다 .

손실 가중치가 필수다
Minor·Major·Destroyed 는 각각 전체의 2% 미만입니다 .
가중치 없이 학습하면 모델이 소수 등급을 아예 학습하지 않습니다 .

→ 그래서 F1 을 기본 지표로 채택합니다 . 다만 F1 도 충분하지 않다는 걸 뒤에서 보여드리겠습니다 .

대 본

EDA에서 가장 먼저 확인한 건 클래스 불균형입니다.

보시면 전체 픽셀의 대부분이 건물이 아닙니다. 건물 픽셀 안에서도 No Damage가 압도적이고, Minor, Major, Destroyed는 각각 전체의 2%도 안 됩니다.

여기서 결론이 두 개 나옵니다.

첫째, 정확도는 지표로 쓸 수 없습니다. 모델이 아무것도 안 하고 전부 "건물 아님"이라고 찍어도 80%대가 나옵니다.

둘째, 손실 가중치가 선택이 아니라 필수입니다. 가중치 없이 학습하면 모델이 소수 등급을 아예 학습하지 않습니다.

그래서 저희는 F1을 기본 지표로 잡았습니다. 그런데 F1도 충분하지 않습니다. 그 이야기를 뒤에서 하겠습니다.

- 발표자 메모 - 읽지 않음**
- ★ 실측 후 수치 교체 필수. 교체 후 좌하단 빨간 캡션 삭제.
 - "F1도 충분하지 않다"는 복선. 여기서 흘리고 09번 슬라이드에서 회수.

05 EDA ② 사람도 Minor 와 Major 를 구분하기 어렵습니다

[pre 영상 타일]

8/18 실제 타일 캡처로 교체

[post 영상 타일 — Minor 라벨]

8/18 실제 타일 캡처로 교체

[post 영상 타일 — Major 라벨]

8/18 실제 타일 캡처로 교체

이건 모델의 문제가 아니라 태스크의 문제입니다

- Minor 와 Major 의 경계는 고해상도 위성영상에서도 육안 판별이 어렵습니다 . 지붕만 보이는 하향 시점에서 벽체 · 구조 손상은 관측되지 않습니다 .
- 라벨 자체에도 애매성이 있습니다 — 겉보기 손상이 없어 보이는 건물이 Minor 로 라벨된 사례가 보고되어 있습니다 .

대 본

두 번째 EDA는 조금 다른 종류입니다. 숫자가 아니라 눈으로 본 겁니다.

가운데와 오른쪽을 비교해 보십시오. 왼쪽이 재난 전, 가운데가 Minor로 라벨된 건물, 오른쪽이 Major로 라벨된 건물입니다.

솔직히 저희는 구분하지 못했습니다.

이유는 구조적입니다. 위성은 하향 시점이라 지붕만 보입니다. 벽체 손상이나 구조적 손상은 애초에 관측되지 않습니다. 그리고 라벨 자체에도 애매성이 있습니다. 겉보기에 멀쩡한 건물이 Minor로 라벨된 사례가 논문에도 보고되어 있습니다.

그래서 이건 모델을 잘 만들면 해결되는 문제가 아닙니다. 태스크 자체의 난이도입니다. 이 관찰이 뒤에 나올 결과를 미리 설명해 줍니다.

발표자 메모 — 읽지 않음

- ★ 이미지 3장 반드시 교체. 플레이스홀더 상태로 나가면 이 슬라이드가 죽는다.
- "저희는 구분하지 못했습니다"는 솔직하게. 웃어도 된다.

06

방법론 ① 왜 YOLO 를 쓰지 않았는가

가장 흔한 선택지를 먼저 배제한 근거

	YOLO 계열 (instance seg.)	본 과제의 요구
입력 구조	단일 이미지	pre / post 두 장의 쌍 (bi-temporal)
판단 대상	이미지 안의 객체	두 영상 사이의 변화
출력 형식	박스 + 마스크	픽셀 단위 폴리곤 마스크
평가 방식	박스 IoU 기반 mAP	마스크 대조 F1 (벤치마크 규격)
밀집 도시	인접 건물이 박스로 뭉개짐	건물 단위 분리가 필수

YOLO 는 좋은 모델이지만 이 태스크의 입력 구조와 맞지 않습니다 . 성능 이전에 형식의 문제입니다 .

대 본

방법론입니다. 먼저 저희가 무엇을 배제했는지부터 말씀드리겠습니다.

객체 탐지 하면 대부분 YOLO를 먼저 떠올립니다. 저희도 그랬습니다. 그런데 배제했습니다. 이유는 성능이 아니라 형식입니다.

표를 보시면, 이 태스크의 입력은 단일 이미지가 아니라 재난 전과 후, 두 장의 쌍입니다. bi-temporal 구조입니다. 그리고 판단해야 하는 건 이미지 안의 객체가 아니라 두 영상 사이의 변화입니다. YOLO 계열은 단일 이미지 instance segmentation 구조라 이 시간축 쌍을 자연스럽게 받지 못합니다.

출력도 안 맞습니다. xBD의 정답은 폴리곤 마스크이고 평가도 마스크 대조로 이뤄집니다. 박스 기반은 평가 체계와 어긋납니다.

마지막으로 밀집 도시에서 인접 건물이 박스로 뭉개집니다. 실제로 로컬라이제이션 오차의 상당수가 건물 밀도 높은 지역에서 발생합니다.

정리하면, YOLO는 좋은 모델이지만 이 태스크와는 형식이 맞지 않습니다.

발표자 메모 — 읽지 않음

- 이 슬라이드는 평가항목 "적절한 방법론을 찾아보고 선정했는가"에 직결.
- 배제 근거를 먼저 말하면 채택 근거가 훨씬 강해 보인다.

07 방법론 ② Siamese U-Net, 2 단계 구조

xView2 상위 솔루션이 공통으로 채택한 계열

Stage 1 — 건물 로컬라이제이션

pre 영상만 입력 → ImageNet 사전학습 인코더 (ResNet34) + U-Net 디코더 → 건물 마스크

`segmentation_models_pytorch` 사용 — 구현 코드 수식 줄

Stage 2 — 피해 등급 분류

pre / post 를 가중치 공유 Siamese 브랜치에 통과 → 특징 차분 · 연결 → 디코더 → 4 등급 분류

클래스 가중치 / focal loss 적용

pre + post 영상

→

공유 인코더

→

특징 차분

→

디코더

→

4 등급 마스크

가중치를 공유하는 두 브랜치에 각각 통과

축소 경고 Stage 2 가 시간 내 수렴하지 않으면 Stage 1 + 이전 변화 탐지까지 완주하고, 4 등급 분류는 " 시도 및 실패 " 로 보고합니다 .

대 본

채택한 구조는 Siamese U-Net, 2단계입니다.

Stage 1은 건물이 어디 있는지 찾는 단계입니다. 재난 전 영상만 입력해서, ImageNet 사전학습 인코더에 U-Net 디코더를 붙여 건물 마스크를 뽑습니다. `segmentation_models_pytorch`를 쓰면 코드 수식 줄입니다.

Stage 2가 본체입니다. 전 영상과 후 영상을 가중치를 공유하는 Siamese 브랜치에 각각 통과시키고, 나온 특징을 차분하고 연결해서 디코더로 보냅니다. 그 결과가 4등급 분류입니다. 아래 흐름도가 그 경로입니다. 클래스 불균형 때문에 여기에 가중치와 focal loss를 적용했습니다.

참고로 xView2 챌린지 1위 솔루션도 Siamese network 계열이었습니다. 저희가 새로운 구조를 제안하는 게 아니라, 검증된 계열을 정확히 구현하는 데 집중했습니다.

마지막 줄은 안전장치입니다. Stage 2가 5일 안에 수렴하지 않을 경우를 대비해서 Stage 1과 이전 변화 탐지까지는 반드시 완주하도록 범위를 설계했습니다.

발표자 메모 — 읽지 않음

- "새로운 구조를 제안하지 않는다"를 부끄러워하지 말 것. 5일 프로젝트에서는 이게 정답이다.

08 지표 설계 : 3 계층

이 프로젝트의 핵심 — 하나의 숫자로는 신뢰구간이 드러나지 않습니다

1. 벤치마크 계층

xView2 공식 점수
= 로컬라이제이션 F1 30% + 피해분류 F1 70% (픽셀 단위)

우리 모델의 객관적 위치를 공개 리더보드 대비로 고정합니다 .

2. 운용 계층

건물 객체 단위 F1
(로컬라이제이션 / 등급별)

픽셀 지표는 큰 건물에 가중됩니다 . 현장에서 세는 단위는 픽셀이 아니라 건물입니다 .

3. 비용 계층

QWK (순서형) + 등급별 Recall
특히 Destroyed 누락률

등급은 순서형입니다 . Destroyed 를 Major 로 틀리는 것과 No Damage 로 틀리는 것은 비용이 다릅니다 .

배제한 지표 — 정확도 (불균형으로 무의미) / mAP (모든 오분류를 등가로 취급 , 순서형 무시)

대 본

여기가 저희 프로젝트의 핵심입니다.

저희는 지표를 세 계층으로 나눴습니다.

첫 번째, 벤치마크 계층입니다. xView2 공식 점수를 그대로 씁니다. 로컬라이제이션 F1에 30%, 피해분류 F1에 70% 가중을 준 픽셀 단위 지표입니다. 이걸 쓰는 이유는 하나입니다. 공개 리더보드와 직접 비교가 되기 때문에 우리 모델의 위치를 객관적으로 고정할 수 있습니다.

두 번째, 운용 계층입니다. 같은 예측을 건물 객체 단위로 다시 계산합니다. 왜냐면 픽셀 지표는 큰 건물에 가중되기 때문입니다. 큰 창고 하나를 맞히면 작은 주택 열 채를 틀려도 점수가 나옵니다. 그런데 현장에서 세는 단위는 픽셀이 아니라 건물입니다.

세 번째, 비용 계층입니다. 피해 등급은 순서형 레이블입니다. No Damage보다 Minor가 크고, Minor보다 Major가 크고, 그다음이 Destroyed입니다. 그런데 일반적인 F1이나 mAP는 모든 오분류를 똑같이 취급합니다. Destroyed를 Major로 틀린 것과 No Damage로 틀린 것이 같은 패널티를 받습니다. 현장에서는 전혀 다릅니다. 후자는 구조대를 안 보내는 결정입니다. 그래서 순서를 반영하는 QWK와, 등급별 Recall, 특히 전파 건물을 놓친 비율을 따로 추적합니다.


아래는 저희가 의도적으로 배제한 지표입니다. 정확도는 불균형 때문에 무의미하고, mAP는 순서형 구조를 무시합니다.

발표자 메모 — 읽지 않음

- ★★ 여기가 발표의 심장. 15분 중 100초를 여기 쓴다.
- 세 계층을 손가락으로 하나씩 짚으면서 말할 것.
- "구조대를 안 보내는 결정"에서 한 박자 쉼.

09 결과 ① 벤치마크 위치

xView2 공식 점수 — 픽셀 단위 가중 F1



※ 배치 예시 — 8/18 실측치로 교체

읽는 법

- 상위 5 개 솔루션은 0.73 ~ 0.81 구간입니다 . 대회 참가팀들이 수개월을 투입한 결과입니다 .
- 저희는 5 일 , 단일 모델 , 서버셋 5,000 장 조건입니다 . 순위 경쟁이 목적이 아닙니다 .
- 이 슬라이드의 목적은 하나 — 우리 모델이 논의할 가치가 있는 범위에 있음을 확인하는 것입니다 .

그런데 이 숫자는 실제 성능을 크게 과대평가하고 있습니다 .

대 본

결과입니다. 먼저 벤치마크 위치부터 보겠습니다.

회색 막대가 xView2 챌린지 상위 5개 솔루션의 공식 점수입니다. 0.73에서 0.81 사이입니다. 대회 참가팀들이 수개월을 투입해서 얻은 결과입니다.

빨간 막대가 저희입니다. 저희는 5일, 단일 모델, 서버셋 5천 장 조건이었습니다. 순위 경쟁이 목적이 아니었습니다.

이 슬라이드의 목적은 하나입니다. 우리 모델이 적어도 논의할 가치가 있는 범위에는 들어와 있다는 걸 확인하는 것.

그런데 여기서 진짜 이야기가 시작됩니다. 이 숫자는 실제 성능을 크게 과대평가하고 있습니다.


발표자 메모 — 읽지 않음

- ★ 빨간 막대 값 교체 필수 (현재 0.62는 임시).
- 마지막 문장이 다음 슬라이드로 넘어가는 다리. 끊지 말고 바로 넘긴다.

10

결과 ② 픽셀 지표는 성능을 과대평가합니다

xView2 상위 5 개 솔루션을 건물 객체 단위로 재계산한 공개 수치



0.78 → 0.44

같은 모델, 같은 예측입니다.
지표를 픽셀에서 건물로 바꿨을 뿐입니다.

픽셀 지표는 면적이 큰 건물에 가중됩니다. 큰 건물 하나를 맞히면 작은 건물 여럿을 놓쳐도 점수가 유지됩니다.

우리 모델도 동일한 패턴을 보였습니다. [수치 기입]

대 본

이 슬라이드가 저희가 가장 하고 싶었던 이야기입니다.

회색이 아까 보신 대회 공식 점수입니다. 0.73에서 0.81. 빨간색은 똑같은 예측을, 건물 객체 단위로 다시 계산한 값입니다. 0.40에서 0.45로 떨어집니다.

1위 솔루션 기준으로 0.78에서 0.44입니다. 모델이 바뀐 게 아닙니다. 예측도 그대로입니다. 지표를 픽셀에서 건물로 바꿨을 뿐입니다.

이유는 단순합니다. 픽셀 지표는 면적이 큰 건물에 가중됩니다. 큰 창고나 아파트 한 동을 맞히면, 작은 주택 여러 채를 놓쳐도 점수가 유지됩니다. 그런데 현장에서 구조 인력을 배분할 때 세는 단위는 건물입니다.

이건 저희가 발견한 게 아니라 xFBD 논문이 지적인 내용이고, 저희 모델에서도 같은 패턴이 재현됐습니다.


발표자 메모 — 읽지 않음

- ★★ 이 슬라이드가 발표의 클라이맥스. 천천히.
- "0.78 → 0.44" 큰 숫자를 손으로 가리키면서 말한다.
- 우측 하단 [수치 기입] 반드시 채울 것.
- 이 데이터는 공개 논문 수치라 실험이 실패해도 슬라이드가 성립한다.

11

결과 ③ 등급별로 뜯어보면 Minor 에서 무너집니다

xView2 상위 5 개 솔루션의 등급별 객체 F1 평균



출처: xFBD (arXiv:2212.13876) 상위 5 개 솔루션 평균 · 개별 솔루션 Minor F1 은 0.16 ~ 0.25 구간

EDA 에서 본 것과 정확히 일치합니다

- Minor 0.21 — 사람도 구분하기 어려웠던 등급에서 모델도 무너집니다 .
- 양 끝단 (No Damage, Destroyed) 은 상대적으로 안정적입니다 . 시각적으로 명확하기 때문입니다 .
- 이건 특정 모델의 결함이 아닙니다 . 상위 5 개 솔루션 전부에서 같은 곡선이 나옵니다 .

→ 4 등급을 다 맞추는 것은 현 시점에서 열린 문제입니다 . 우리 모델도 예외가 아니었습니다 . [수치 기입]

대 본

등급별로 뜯어보면 더 선명해집니다.

No Damage가 0.41, Minor가 0.21, Major가 0.28, Destroyed가 0.37입니다. Minor에서 확 무너집니다. 개별 솔루션으로 보면 0.16까지 내려갑니다.

이게 아까 EDA에서 저희가 눈으로 본 것과 정확히 일치합니다. 사람도 구분하기 어려웠던 그 등급에서 모델도 무너집니다.

반대로 양 끝단, 그러니까 손상이 없는 건물과 완전히 무너진 건물은 상대적으로 안정적입니다. 시각적으로 명확하기 때문입니다.

중요한 건 이게 특정 모델의 결함이 아니라는 점입니다. 상위 5개 솔루션 전부에서 같은 곡선이 나옵니다.

그래서 저희 결론은 이렇습니다. 4등급을 전부 맞추는 것은 현 시점에서 열린 문제입니다. 저희 모델도 예외가 아니었습니다.

발표자 메모 — 읽지 않음

- "우리가 못한 게 아니라 아직 아무도 못 했다"를 데이터로 말하는 슬라이드.
- 방어적으로 들리지 않게, 담담하게 사실만 전달.

12 결과 ④ 학습하지 않은 재난에서는 어떻게 되는가

재난 유형 hold-out — 한 유형을 통째로 제외하고 학습한 뒤 그 유형에서 평가

무작위 분할


같은 재난의 인접 타일이 학습·검증에 동시 포함 → 성능이 부풀려짐

재난 유형 hold-out

예 : 산불 전체를 학습에서 제외 → 산불에서만 평가

측정 대상

두 조건의 차이 = 미지의 재난에 대한 일반화 실패의 크기



※ 배치 예시 — 8/18 실측치로 교체

→ 학습에 없던 재난 유형에서는 전 등급이 하락하며 , Minor·Major 의 하락폭이 가장 큼니다 .

대 본

마지막 실험입니다. 일반화를 봤습니다.

보통은 데이터를 무작위로 나눠서 학습하고 검증합니다. 그런데 이러면 같은 재난 사건의 인접 타일이 학습과 검증에 동시에 들어갑니다. 성능이 부풀려집니다.

그래서 저희는 재난 유형을 통째로 빼는 방식으로 나눴습니다. 예를 들어 산불을 학습에서 완전히 제외하고, 산불에서만 평가합니다. 이 두 조건의 차이가 곧 미지의 재난에 대한 일반화 실패의 크기입니다.

결과를 보시면, 학습에 없던 재난 유형에서는 전 등급이 떨어집니다. 그리고 하락폭이 가장 큰 건 역시 Minor와 Major입니다.

이 실험이 중요한 이유는, 실제 재난은 학습 데이터에 없는 형태로 오기 때문입니다. 무작위 분할 성능만 보고 배포하면 현장에서 그만큼 안 나옵니다.

발표자 메모 — 읽지 않음

- ★ 차트 전체 수치 교체 필수. 현재는 배치 확인용 임시값.
- 만약 hold-out 실험을 못 돌렸다면 이 슬라이드는 통째로 삭제하고
- "다음 단계"로 옮긴다. 안 한 실험을 한 것처럼 두지 말 것.

결론 — 배포 가능 구간

지금 쓸 수 있는 것

- 이진 판정 — 피해 있음 / 없음
- 판독 우선순위 정렬 (검토 대상 축소)
- Destroyed 등급의 개략적 위치 파악

아직 쓸 수 없는 것

- Minor / Major 구분 — 등급별 F1 이 운용 기준 미달
- 학습에 없던 재난 유형에 대한 무검증 적용
- 사람 검증 없는 자동 피해 집계

저희가 만든 건 판독기가 아니라 분류기 (triage) 입니다 .

성능을 올리는 대신 경계선을 그었습니다 . 이 경계선은 하나의 숫자가 아니라 3 계층 지표로만 드러납니다 . 산출물에는 이 구간을 명시한 모델 카드를 포함합니다 .

다음 단계 — SAR(Sentinel-1) 결합으로 구름·야간 대응 · 한국 도시 데이터 재학습 · 시계열 확장으로 복구 진척 추적

코드 Apache 2.0 · 학습 가중치 CC BY-NC-SA 4.0 · 데이터 xBD (CC BY-NC-SA 4.0), Vantor ODP (CC BY-NC 4.0)

대 본

결론입니다.

저희는 이 모델을 "쓸 수 있다" 또는 "쓸 수 없다"로 나누지 않았습니다. 어디까지 쓸 수 있는지 구간을 그었습니다.

왼쪽, 지금 쓸 수 있는 것. 피해가 있는지 없는지 이진 판정, 그리고 그걸로 판독 우선순위를 정렬하는 것. 수천 장 중에 어디부터 볼지 정해주는 용도로는 지금 배포 가능합니다. Destroyed 등급의 개략적인 위치 파악도 가능합니다.

오른쪽, 아직 쓸 수 없는 것. Minor와 Major의 구분은 운용 기준에 미달합니다. 학습에 없던 재난 유형에 검증 없이 적용하는 것도 안 됩니다. 그리고 사람 검증 없는 자동 집계는 어떤 경우에도 안 됩니다.

정리하면, 저희가 만든 건 판독기가 아니라 분류기입니다. 성능을 올리는 대신 경계선을 그었습니다. 그리고 이 경계선은 하나의 숫자로는 절대 드러나지 않습니다. 3계층 지표로만 드러납니다. 그게 이 프로젝트의 기여입니다.

산출물에는 이 구간을 명시한 모델 카드를 함께 포함했습니다.

다음 단계로는 SAR 결합으로 구름과 야간에 대응하는 것, 한국 도시 데이터로 재학습하는 것, 시계열로 확장해서 복구 진척을 추적하는 것을 보고 있습니다.

이상입니다. 감사합니다.

발표자 메모 — 읽지 않음

- 14:30에 끝내고 30초 여유를 남긴다. 15분을 넘기면 평가항목 1번에서 감점.
- 마지막 "감사합니다" 후 바로 Q&A 자세로 전환. 슬라이드는 이 화면에 둔다.