# AIFFEL 최종발표자료

11쪽 전체 문안 + 시각화 구성 + 15분 발표대본 + 심사위원 예상질문 22개

yKa x ARTHÉMIS-Core

Young Korean Artists를 위한 맥락 분리형 AI 아트 큐레이션

본 문서는 업로드된 ARTHÉMIS 통합 마스터, final submission-ready 설계 논문, 다운사이징 실행계획서, 심사 및 최종 준비 로드맵, AIFFEL 포스터 템플릿의 용어와 결과 경계를 맞춘 발표 제작본입니다.

문서 기준일 2026-09-28 | 연구 자료 기준일 2026-09-23

입력 필요: 팀원명, 소속, GitHub/데모 URL, 최종 실측값

사용 안내 및 근거 경계

# 발표자료를 만들 때 가장 먼저 확인할 것

이 PDF는 발표 슬라이드 자체를 대체하는 단순 원고가 아니라, 11쪽 슬라이드 제작자가 그대로 옮겨 넣을 수 있는 문안·도식·발표대본·검증 상태를 한데 묶은 작업본입니다.

| 템플릿 6개 섹션 | 배정 슬라이드 | 핵심 메시지 |
|---|---|---|
| 프로젝트 배경 | 01-02 | 감각 언어, 맥락 오염, 전시 가능성의 3대 단절 |
| 팀 구성 및 역할 | 03 | 데이터-모델-검색-평가-커뮤니케이션의 연결 |
| 수행 절차 및 방법 | 04-07 | 다운사이징 Core, RRF, 계층형 메모리, 2층 grounding |
| 수행 과정 | 08 | 6주 실행과 Evidence 중심의 상태 관리 |
| 예상·실측 결과 | 09-10 | NDCG@10, CR@10, Trec, UCR 및 결과 경계 |
| 느낀 점 & 추후 계획 | 11 | 맞게 기억하는 큐레이션과 다음 검증 단계 |

## 상태 라벨 규칙

- [SOURCE] 업로드된 원자료에서 확인되는 정의·구조·기준.
- [PROPOSED] 계획값·목표값·실행안. 실측 성과로 표현하지 않음.
- [TO-MEASURE] 실험 실행 뒤 입력할 값. 현재는 TBD로 유지.
- [INPUT] 팀원명, 소속, URL, 최종 데이터와 같이 사용자가 채워야 하는 항목.

**발표 전체에서 “향상”, “개선”, “유의한 차이”, “달성”은 실제 결과표가 채워진 뒤에만 사용합니다. 300개 합성 세션, 20명 파일럿, Extraction F1 >= 0.75, CR@10 <= 0.10, p95 <= 6초는 자료에 제시된 계획 또는 초기 목표이며 실측값이 아닙니다.**

SLIDE 01 | 01 프로젝트 배경

# 감각의 언어를, 오늘 갈 수 있는 작품으로 연결하다

## 슬라이드에 넣을 최종 문안

- yKa x ARTHÉMIS-Core
- Young Korean Artists를 위한 맥락 분리형 AI 아트 큐레이션
- 관람객이 말하는 감각과 상황을 이해하고, 서로 다른 관람 맥락을 섞지 않으며, 확인 가능한 전시 정보까지 연결한다.
- 핵심 질문: 장기 미학 메모리와 2층 전시 grounding이 개인화 추천의 유용성과 신뢰성을 함께 높이는가?

## 슬라이드 시각화 구성

- 상단: 프로젝트명과 한 문장 가치제안
- 중앙: 관람객 발화 -> 작품 추천 -> 확인 가능한 전시 정보의 3단 흐름
- 하단: 3개 키워드 카드 - 감각 언어 / 맥락 분리 / 전시 검증
- 이미지는 실제 데이터가 확보된 경우에만 작품 사진을 삽입하고, 없으면 추상적 텍스처 그래픽으로 대체

## 스토리텔링 발표대본

안녕하세요. 저희는 작품을 잘 아는 사람만 검색할 수 있는 미술관 경험을 바꾸고자 했습니다. 관람객은 작가명보다 먼저 오늘의 기분과 상황을 말합니다. ARTHÉMIS는 그 말을 작품 메타데이터와 연결하되, 평일의 혼자 감상과 주말의 가족 관람처럼 서로 다른 맥락이 섞이지 않도록 설계했습니다. 마지막으로 추천이 실제 방문으로 이어지려면 전시 일정이 확인되어야 합니다. 저희의 질문은 이 세 문제를 하나의 감사 가능한 시스템으로 묶을 수 있는가입니다.

## 근거 및 상태

[SOURCE] 문제 정의 및 시스템명. 성능 주장은 하지 않음.

SLIDE 02 | 01 프로젝트 배경

# 세 가지 단절을 하나의 연구문제로 묶었다

## 슬라이드에 넣을 최종 문안

- 단절 1. 감각 언어와 기관 메타데이터의 간극
- 단절 2. 장기 취향을 한 프로필에 누적할 때의 맥락 오염
- 단절 3. 추천 작품과 실제 전시 가능성의 분리
- 연구문제: 감각적 요구를 구조화하고, 시간에 따른 취향 변화와 다중 관람 맥락을 선택적으로 기억하면서, 확인 가능한 전시 정보에 근거한 개인화 추천과 설명을 제공할 수 있는가?

## 슬라이드 시각화 구성

- 왼쪽: 관람객 발화 예시 - '마음이 가라앉는 거친 질감의 추상화'
- 가운데: 번역 레이어 - 정서 / 물질성 / 색채 / 관람 목적
- 오른쪽: 작품층과 전시층을 분리한 문제 지도
- 문제 카드 아래에 연구 질문을 한 줄로 크게 배치

## 스토리텔링 발표대본

문제를 세 가지 단절로 정리했습니다. 첫째, 관람객은 감각과 상황으로 말하지만 아카이브는 작가, 연도, 재료 중심입니다. 둘째, 모든 과거 취향을 한데 합치면 서로 다른 관람 목적이 오염됩니다. 셋째, 알고리즘상 좋은 작품이어도 수장고에 있거나 전시가 끝났다면 방문 추천으로는 불충분합니다. 그래서 저희는 추천 정확도만이 아니라 맥락 분리와 관람 가능성까지 함께 평가하는 연구문제를 세웠습니다.

## 근거 및 상태

[SOURCE] 통합 마스터 및 final submission-ready의 3대 문제. 수치는 없음.

SLIDE 03 | 02 팀 구성 및 역할

# 연구 질문에서 재현 가능한 산출물까지 역할을 연결했다

## 슬라이드에 넣을 최종 문안

- 연구 책임 / PM: 추병곤 [SOURCE] | 팀원: [팀원명 입력]
- Data: yKa 작가·작품·전시 데이터, 라이선스, schema
- Model / Memory: 미학 신호 추출, Session Node, Taste Cluster, Context Router
- Retrieval / Grounding: BM25, text embedding, RRF, 작품층·전시층 검증
- Evaluation / Communication: Golden Set, 지표 코드, 실험 registry, 발표·데모

## 슬라이드 시각화 구성

- 5개 역할을 원형 또는 가로 swimlane으로 배치
- 각 역할의 입력과 산출물을 작은 파일 아이콘으로 표시
- 중앙에 공통 기준: Dataset version / Experiment ID / Commit / Metric / Result
- 실제 팀원 배정 전까지는 이름을 임의로 채우지 말고 [팀원명 입력] 유지

## 스토리텔링 발표대본

역할은 기능별로 나누되, 연구 근거가 끊기지 않도록 연결했습니다. 데이터 담당자는 단순 수집에 그치지 않고 출처와 라이선스까지 남깁니다. 메모리와 검색 담당자는 동일한 데이터 버전과 실험 ID를 공유합니다. 평가 담당자는 결과를 문서보다 먼저 고정합니다. 이 구조를 통해 누가 어떤 코드를 실행했고, 어떤 조건에서 나온 수치인지 추적할 수 있게 합니다. 현재 문서에 없는 팀원명과 소속은 발표 직전에 입력하는 방식으로 관리합니다.

## 근거 및 상태

[SOURCE] 역할 영역과 PM 정보. 팀원명·소속은 [INPUT].

SLIDE 04 | 03 수행 절차 및 방법

# 작게 시작하되, 끝까지 측정 가능한 Core로 동결했다

## 슬라이드에 넣을 최종 문안

- 필수 범위: 작품 코퍼스 1개 + 전시 API 1개 + BM25 + 텍스트 임베딩 1개 + 계층형 메모리 + 단일 LLM API + 2층 grounding
- 후순위 옵션: 이미지 인덱스, cross-encoder, 다기관 코퍼스, 역할별 fine-tuning
- 운영 원칙: 새 기능은 NDCG@10, CR@10, Trec, UCR 중 하나에 기여할 때만 Core에 포함

## 슬라이드 시각화 구성

- 왼쪽: Core와 Option을 색상으로 분리한 범위 동결 보드
- 오른쪽: 데이터 -> 추출 -> 검색 -> 메모리 -> grounding -> 평가 파이프라인
- 하단에 Go / No-Go 4문항: 지표 기여? blocker? 새 모델 없이 해결? fresh clone 재현?

## 스토리텔링 발표대본

이번 프로젝트의 중요한 결정은 더 많이 넣는 것이 아니라, 측정 가능한 범위를 동결한 것입니다. 문서상 이상형에는 여러 기관과 여러 임베딩, 비전 모델이 있지만, 6주 실행에서는 작품 코퍼스 하나와 전시 API 하나로 시작합니다. 이미지 검색과 fine-tuning은 핵심 오류가 확인될 때만 선택합니다. 모든 기능은 네 지표 중 무엇을 바꾸는지 설명할 수 있어야 합니다.

## 근거 및 상태

[SOURCE] 다운사이징 실행계획서. 범위는 계획이며 구현 완료를 의미하지 않음.

SLIDE 05 | 03 수행 절차 및 방법

# 검색은 합치지 않고 분리한 뒤 순위에서 융합한다

## 슬라이드에 넣을 최종 문안

- 입력 예시: 색이 강하지 않고 표면이 거친 그림을 혼자 조용히 보고 싶어요.
- Aesthetic Signal Extractor: 색채, 질감, 분위기, 동반자, 관람 의도와 evidence span을 구조화
- Retrieval: BM25 + text embedding -> RRF rank fusion -> Top-10
- 원칙: 서로 다른 임베딩 공간의 벡터를 직접 더하지 않고, 인덱스를 분리한 뒤 순위 수준에서 결합

## 슬라이드 시각화 구성

- 가로 흐름: 자연어 -> JSON schema -> BM25 / Dense 병렬 -> RRF -> Top-10
- JSON 예시에는 low_saturation, rough, alone, contemplation, evidence_span을 표시
- RRF 옆에 'rank-level fusion'을 명시
- Top-10 아래에 NDCG@10 측정 지점을 표시

## 스토리텔링 발표대본

사용자는 전문 용어 대신 감각적 표현을 사용합니다. 먼저 이 표현을 구조화된 신호와 근거 구간으로 바꿉니다. 그 다음 lexical 검색인 BM25와 텍스트 임베딩 검색을 병렬로 실행하고 순위 수준에서 RRF로 융합합니다. 이때 서로 다른 벡터 공간을 무리하게 더하지 않는 것이 중요합니다. 이 슬라이드의 핵심은 모델의 화려함보다 검색 조건을 분리해 비교 가능하게 만드는 데 있습니다.

## 근거 및 상태

[SOURCE] final submission-ready의 공간 분리 검색. RRF 결과 수치는 [TO-MEASURE].

SLIDE 06 | 03 수행 절차 및 방법

# 기억은 저장, 조직, 선택의 세 층으로 나눈다

## 슬라이드에 넣을 최종 문안

- Session Node: 한 관람 세션에서 발화와 evidence span을 함께 보존
- Taste Cluster: 반복되는 취향 패턴을 묶고 tentative / active / stale / suppressed 상태를 관리
- Context Router: 현재 관람 상황에 맞는 cluster만 선택해 검색에 반영
- 핵심 비교: B1 current turn vs B4 Cluster + Router; B2 full history 및 B3 Session Node는 보조 비교

## 슬라이드 시각화 구성

- 상단: Conversation -> Session Node -> Taste Cluster -> Context Router -> Selected Profile
- 아래 두 사용자 상황을 나란히: 혼자 사유 / 가족 체험
- 각 cluster에 context tag와 상태 badge를 표시
- 오염이 일어나는 잘못된 경로는 회색 점선, 선택 경로는 청록색 실선

## 스토리텔링 발표대본

장기 기억을 하나의 사용자 프로필로 만들지 않았습니다. 한 번의 관람에서 나온 근거는 Session Node로 남기고, 반복적으로 나타나는 경향은 Taste Cluster로 조직합니다. 그리고 현재 사용자가 혼자인지, 가족과 함께인지, 사유를 원하는지 체험을 원하는지에 따라 Context Router가 필요한 클러스터만 선택합니다. 연구적으로는 현재 발화만 보는 B1과 Cluster plus Router인 B4를 비교하고, 전체 이력 B2와 Session Node B3를 보조 조건으로 둡니다.

## 근거 및 상태

[SOURCE] formal B0-B5 ladder 및 다운사이징 핵심 비교. 상태 전이 실측은 [TO-MEASURE].

SLIDE 07 | 03 수행 절차 및 방법

# 작품 추천과 전시 방문 가능성을 두 층으로 검증한다

## 슬라이드에 넣을 최종 문안

- Artwork Layer: 작품 설명, 작가, 제작연도, 재료, 작품 근거
- Exhibition Layer: 전시명, 장소, 기간, 현재성, 출처 snapshot
- 출력 상태: VERIFIED / CACHED / UNVERIFIED
- 확인할 수 없는 일정은 생성하지 않고, 현재 확인 가능한 전시 정보가 없다고 명시

## 슬라이드 시각화 구성

- 두 개의 카드 레이어: Artwork Layer와 Exhibition Layer
- 추천 카드에 근거 span과 전시 상태 badge를 연결
- B4R의 동일 R_10을 고정한 뒤 B5에서 grounding을 추가하는 비교 흐름
- UNVERIFIED는 경고 색으로 표시하되 추천 작품 자체와 분리

## 스토리텔링 발표대본

추천 결과가 그럴듯해 보이는 것만으로는 충분하지 않습니다. 작품을 왜 추천했는지 설명하는 Artwork Layer와, 실제 어디에서 언제 볼 수 있는지를 확인하는 Exhibition Layer를 분리합니다. 전시 API에서 확인한 snapshot만 VERIFIED로 표시하고, 캐시된 정보는 CACHED로, 확인하지 못한 내용은 UNVERIFIED로 표시합니다. 특히 B5는 B4R의 동일한 추천 목록을 유지한 채 grounding을 추가해, 그라운딩이 근거 없는 방문 주장을 줄이는지 분리해 측정합니다.

## 근거 및 상태

[SOURCE] 2층 grounding 및 B4R -> B5 비교. 전시 API·snapshot·UCR 값은 [TO-MEASURE].

SLIDE 08 | 04 수행 과정

# 6주 과정은 데이터보다 평가 가능성을 먼저 쌓는다

## 슬라이드에 넣을 최종 문안

- W1 Data Foundation: yKa 선정 기준, schema, 작품·전시 데이터, Golden Query
- W2 Retrieval Baseline: BM25, Dense, RRF, extractor, 20개 질의 실행
- W3 Memory: Session Node, Taste Cluster, Context Router, CR@10, Trec
- W4 Grounding: 전시 API, snapshot, claim whitelist, UCR
- W5 Controlled Evaluation: B1, B2, B4, B5 및 formal ladder 확장
- W6 Demo and Freeze: Streamlit, GitHub, 발표자료, fresh clone, 최종 평가

## 슬라이드 시각화 구성

- 6주 타임라인을 가로로 표시하고 매주 산출물을 파일 단위로 적기
- 각 주차 아래 Evidence: dataset version, experiment ID, result table
- 실험보다 문서가 앞서는 위험을 빨간 callout으로 표시
- 완료 여부는  대신 Planned / In progress / Measured로 구분

## 스토리텔링 발표대본

실행 순서는 데이터 수집, 모델 연결, 발표자료 제작의 단순한 나열이 아닙니다. 먼저 Golden Query와 평가 코드를 준비하고, baseline을 돌린 뒤 memory와 grounding을 하나씩 추가합니다. 이렇게 해야 어떤 모듈이 어떤 변화와 연결되는지 말할 수 있습니다. 300개 합성 세션과 20명 파일럿은 계획된 평가 규모이지 완료된 실험 표본이 아닙니다. 발표 직전에는 각 항목의 상태를 반드시 Measured 또는 Planned로 갱신합니다.

## 근거 및 상태

[PROPOSED] 6주 로드맵. 계획된 평가 규모: 300 synthetic multi-session, pilot 20명.

SLIDE 09 | 05 예상·실측 결과

# 네 개의 숫자로 연구 질문을 검증한다

## 슬라이드에 넣을 최종 문안

- NDCG@10 ↑: 개인화 추천 순위 품질. 핵심 비교 B1 vs B4
- CR@10 ↓: 다른 관람 맥락의 오염. B2/B3 vs B4
- Trec ↓: 취향 전환 후 새 취향으로 회복하는 데 필요한 턴 또는 세션 수
- UCR ↓: 근거 없는 전시·방문 주장 비율. 동일 추천목록에서 B4R vs B5
- 통계 계획: 동일 사용자, seed, snapshot을 맞춘 paired design; 평균, 95% CI, 오류 사례를 함께 보고

## 슬라이드 시각화 구성

- 4개 metric card를 2x2로 배치하고 방향 화살표만 표시
- 오른쪽에 RQ1-RQ5와 primary metric mapping 표
- 아래 footnote: 결과 입력 전 값은 TBD / [TO-MEASURE]
- 지표 정의 옆에 무엇을 검증하는지 한 줄로 표시

## 스토리텔링 발표대본

결과를 말할 때는 네 개의 숫자만 먼저 봅니다. NDCG는 개인화 순위, CR은 맥락 오염, Trec은 취향 전환 뒤 회복, UCR은 근거 없는 방문 주장입니다. 모든 비교에서 한 번에 바뀌는 모듈을 제한하고, 동일한 사용자와 seed, 전시 snapshot을 사용합니다. 평균만 제시하지 않고 95% 신뢰구간과 오류 사례를 함께 보여주겠습니다. 현재 이 값들은 아직 실험 입력 전이므로 결과 칸은 TBD로 남깁니다.

## 근거 및 상태

[SOURCE] 평가 프로토콜. 모든 성능값 [TO-MEASURE].

SLIDE 10 | 05 예상·실측 결과

# 결과표는 성과를 과장하지 않도록 설계한다

## 슬라이드에 넣을 최종 문안

- 결과 입력 규칙: [SOURCE] 문서 근거 / [PROPOSED] 계획값 / [TO-MEASURE] 실험 대기값
- 목표값 예시 [PROPOSED]: Extraction F1 >= 0.75, CR@10 <= 0.10, p95 <= 6초
- 결과 입력 전 금지 표현: 향상, 개선, 유의한 차이, 달성
- 최종 표에는 조건, 데이터 버전, 표본 수, seed, 평균, 95% CI, 상태 라벨, 오류 사례 링크를 포함

## 슬라이드 시각화 구성

- 왼쪽: 최종 결과표 목업
- 오른쪽: 상태 라벨 legend
- 예시 표: Metric | B1 | B4 | Delta | 95% CI | Status
- 값이 없는 칸에는 TBD를 그대로 표시하고 색상은 중립으로 유지

## 스토리텔링 발표대본

저희가 가장 엄격하게 관리하는 부분은 결과 경계입니다. 설계 문서에는 초기 목표값이 있지만, 그것을 실측 성과처럼 사용하지 않습니다. 예를 들어 Extraction F1 0.75 이상, CR@10 0.10 이하, p95 6초 이하는 계획값으로만 표시합니다. 실험이 끝나면 조건과 표본 수, seed, 데이터 버전을 함께 적고, 그 전에는 향상이나 유의한 차이라는 표현을 사용하지 않습니다. 이 원칙 자체가 연구 재현성과 발표 신뢰도를 지키는 장치입니다.

## 근거 및 상태

[PROPOSED] 목표값은 계획값. 결과 입력 전 모든 값은 TBD / [TO-MEASURE].

SLIDE 11 | 06 느낀 점 & 추후 계획

# 좋은 큐레이션은 더 많이 기억하는 것이 아니라, 맞게 기억하는 것이다

## 슬라이드에 넣을 최종 문안

- 배운 점 1: 기능 수보다 귀속 가능한 실험 설계가 먼저다
- 배운 점 2: 관람객의 말은 취향이 아니라 맥락까지 포함한다
- 배운 점 3: 추천 설명과 방문 정보는 서로 다른 근거 층이 필요하다
- 다음 계획: yKa dataset definition -> Golden Set -> baseline 실측 -> memory ablation -> grounding audit -> 공개 가능한 Demo
- 마지막 메시지: 감각을 존중하고, 맥락을 분리하고, 근거가 없으면 모른다고 말하는 AI 큐레이터

## 슬라이드 시각화 구성

- 왼쪽: Keep / Problem / Try 3단 카드
- 오른쪽: 연구 결과에서 Demo까지 이어지는 next-step ladder
- 하단: '모른다고 말할 수 있는 추천 시스템'을 closing line으로 크게
- QR/GitHub/데모 링크는 실제 공개 URL 확정 후에만 삽입

## 스토리텔링 발표대본

이번 프로젝트를 통해 배운 것은 기능을 많이 붙이는 것이 연구의 진전과 같지 않다는 점입니다. 관람객의 말은 취향 목록이 아니라 특정한 오늘의 맥락입니다. 따라서 좋은 시스템은 모든 기억을 꺼내는 시스템이 아니라 현재 상황에 맞는 기억만 선택하는 시스템입니다. 다음 단계는 데이터셋 정의와 Golden Set을 확정하고, baseline부터 실측한 뒤 memory와 grounding을 차례로 검증하는 것입니다. 마지막으로, 확인할 수 없는 전시 정보를 만들어내지 않는 태도까지 포함해야 큐레이션이 실제 경험으로 이어진다고 생각합니다.

## 근거 및 상태

[SOURCE] 통합 문서의 한계·추후 계획을 발표용으로 정리. 데모 링크는 [INPUT].

부록 A | 평가 조건과 결과 입력 계약

# 정식 비교 조건과 발표용 핵심 비교를 충돌 없이 함께 쓰는 법

문서별 표현 차이는 범위 차이로 정리합니다. 최종 논문·설계 문서의 정식 사다리는 보존하고, AIFFEL 발표에서는 다운사이징 계획이 요구한 최소 비교를 전면에 둡니다.

| 조건 | 정식 의미 | 발표에서의 역할 |
|---|---|---|
| B0 | BM25 baseline | 검색 baseline 및 시작점 |
| B1 | current turn only | B4와 개인화 순위 비교 |
| B2 | full history | 맥락 오염 비교용 상한 조건 |
| B3 | Session Node | 기억 단위 추가의 보조 비교 |
| B4 | Taste Cluster + Context Router | 핵심 memory 조건 |
| B4R | B4 + reranker | grounding 전 동일 추천목록 고정 조건 |
| B5 | grounding | B4R와 UCR·Availability 비교 |

## 추천 결과층과 전시 실행층의 분리

| 층 | 근거 | 상태·출력 |
|---|---|---|
| Artwork Layer | 작품명, 작가, 제작연도, 재료, 작품 설명, evidence span | 왜 추천했는가 |
| Exhibition Layer | 전시명, 장소, 기간, 현재성, API snapshot, freshness | 오늘 방문 가능한가 |

## 네 지표의 발표용 정의

| Metric | 방향 | 발표 문장 |
|---|---|---|
| NDCG@10 | 높을수록 좋음 | 개인화된 작품 순위가 relevant label을 상위에 두는가 |
| CR@10 | 낮을수록 좋음 | 다른 관람 맥락의 추천이 Top-10에 섞이는 비율 |
| Trec | 낮을수록 좋음 | 취향 전환 뒤 새 취향으로 회복하는 턴 또는 세션 수 |
| UCR | 낮을수록 좋음 | 근거 없는 전시·방문 주장의 비율 |

부록 B | 심사위원 예상질문과 모범답변

# Q&A 01-05

### Q01. 기존 미술관 검색과 무엇이 다른가?

기존 검색이 작가명·작품명·재료 같은 전문 필드를 중심으로 한다면, ARTHÉMIS는 관람객의 감각·상황 언어를 구조화해 검색의 진입점을 넓힙니다. 차별점은 자연어 입력 자체보다 맥락 분리 메모리와 전시 수준 grounding까지 하나의 평가 단위로 묶는 데 있습니다.

### Q02. yKa에서 young Korean artists를 어떻게 정의하는가?

발표 시점에 임의로 확정하지 않습니다. Dataset Definition v1.0에서 young, Korean, inclusion, exclusion, 대상 기간, 출처와 라이선스를 먼저 고정해야 합니다. 그 기준이 확정되기 전에는 데이터 규모나 대표성에 대한 주장을 하지 않습니다.

### Q03. 왜 이미지 검색을 Core에서 제외했나?

핵심 질문은 이미지 모델의 우열보다 장기 미학 메모리와 전시 grounding의 효과입니다. 텍스트 Core로 네 지표를 먼저 산출하고, 이미지 인덱스는 별도 ablation으로 추가해야 모듈 귀속이 가능합니다.

### Q04. BM25와 Dense를 함께 쓰는 이유는?

BM25는 정확한 어휘와 메타데이터 일치에 강하고, Dense는 표현이 달라도 의미가 가까운 후보를 찾는 데 유리합니다. 서로 다른 공간의 벡터를 직접 더하지 않고 순위 수준에서 RRF로 융합합니다.

### Q05. RRF가 성능을 보장하는가?

보장하지 않습니다. RRF는 비교 가능한 결합 방법을 제공할 뿐이며, 실제 효과는 NDCG@10과 오류 분석으로 [TO-MEASURE]합니다. 성능이 없으면 그 결과 자체를 보고합니다.

부록 B | 심사위원 예상질문과 모범답변

# Q&A 06-10

### Q06. Session Node는 단순 대화 로그와 무엇이 다른가?

Session Node는 한 관람 세션의 발화, 구조화된 신호, evidence span, 맥락 태그를 함께 보존하는 평가 가능한 단위입니다. 단순 원문 로그보다 무엇을 기억했고 왜 기억했는지 추적할 수 있습니다.

### Q07. Taste Cluster가 편견을 고착하지 않나?

가능한 위험입니다. 그래서 클러스터를 영구 사실로 저장하지 않고 tentative, active, stale, suppressed 상태와 근거를 관리합니다. 취향 전환 후 Trec과 오류 사례를 통해 회복 여부를 확인합니다.

### Q08. Context Router는 어떻게 평가하나?

현재 상황이 바뀐 고정 스크립트를 만들고, 전체 이력·Session Node·Cluster plus Router 조건을 비교합니다. CR@10으로 다른 맥락의 추천이 섞이는 비율을, Trec으로 새 취향으로 회복하는 속도를 봅니다.

### Q09. B1, B2, B4, B5의 관계를 설명해 달라.

정식 사다리는 B0 BM25, B1 current turn, B2 full history, B3 Session Node, B4 Cluster plus Router, B4R reranker, B5 grounding입니다. 발표에서는 핵심 다운사이징 비교인 B1 vs B4, B2/B3 vs B4, B4R vs B5를 전면에 두고 정식 사다리는 부록과 registry에 보존합니다.

### Q10. B5에서 추천 순위가 바뀌면 grounding 효과를 어떻게 분리하나?

B5 비교에서는 우선 B4R의 동일 R_10을 고정한 뒤 전시 정보와 claim 검증만 추가합니다. 선택·필터 효과가 포함된 경우에는 B5-F처럼 별도 조건으로 보고해 섞지 않습니다.

부록 B | 심사위원 예상질문과 모범답변

# Q&A 11-15

### Q11. UCR은 무엇을 세는가?

추천 설명이나 전시 답변에 포함된 외부 검증 가능 주장 중, 제공된 작품 근거·전시 snapshot·허용된 claim whitelist로 뒷받침되지 않는 주장 비율입니다. 작품 설명과 방문 정보를 같은 근거로 처리하지 않습니다.

### Q12. VERIFIED, CACHED, UNVERIFIED는 어떻게 다른가?

VERIFIED는 현재 조회한 근거와 연결된 상태, CACHED는 저장된 snapshot의 유효기간 안에서 재사용하는 상태, UNVERIFIED는 확인하지 못한 상태입니다. UNVERIFIED 정보를 사실처럼 생성하지 않는 것이 원칙입니다.

### Q13. 전시 API가 실패하면 서비스가 멈추나?

작품 추천과 전시 실행 가능성은 분리합니다. API가 실패하면 작품층 결과는 제공할 수 있지만 방문 정보는 확인 불가로 표시합니다. 캐시 snapshot이 있으면 freshness를 표시하고 사용합니다.

### Q14. 300개 합성 세션과 20명 파일럿은 실험 결과인가?

아닙니다. 문서상 계획된 평가 규모입니다. 실제 수행 전에는 계획값이며, 결과표에는 표본 수와 상태 라벨을 함께 입력합니다. 발표에서는 실측값이 채워지기 전까지 성과 표현을 사용하지 않습니다.

### Q15. 왜 fine-tuning을 바로 하지 않았나?

연구 목표가 fine-tuning 자체가 아니기 때문입니다. prompt와 structured output으로 기준선을 만들고, 추출기 오류가 병목인지 F1, evidence-span, schema success rate로 확인한 뒤 필요할 때만 단일 모듈 fine-tuning을 검토합니다.

부록 B | 심사위원 예상질문과 모범답변

# Q&A 16-20

### Q16. LLM 환각을 어떻게 줄이나?

구조화 출력과 schema validation, evidence span, claim whitelist, 작품층·전시층 분리, VERIFIED/CACHED/UNVERIFIED 상태를 함께 사용합니다. 완전 제거를 주장하지 않고 UCR과 오류 감사로 측정합니다.

### Q17. 추천 정확도만 보면 되지 않나?

실제 관람 서비스에서는 정확한 작품 후보뿐 아니라 현재 방문 가능성과 설명의 근거성이 중요합니다. 그래서 NDCG 하나로 통합하지 않고 CR, Trec, UCR을 별도 primary metric으로 둡니다.

### Q18. Golden Set의 품질은 어떻게 보장하나?

질의, 현재 맥락, relevant, irrelevant, contamination label, evidence를 함께 정의하고, 라벨 지침과 불일치 검토 절차를 남깁니다. 표본 규모보다 라벨 계약과 재현 가능한 파일 형식을 먼저 고정합니다.

### Q19. 성능이 baseline보다 낮으면 실패인가?

연구적으로는 유효한 결과입니다. 어떤 모듈이 어떤 조건에서 실패했는지 오류 분류와 함께 보고하면 설계의 한계와 적용 조건을 밝힐 수 있습니다. 결과가 없는데 향상이라고 말하지 않는 것이 더 중요합니다.

### Q20. 개인정보와 취향 프로필의 위험은?

최소 수집, 세션·클러스터 분리, 삭제·억제 상태, 근거 없는 추론 금지, 민감 정보의 별도 취급이 필요합니다. 연구 단계에서는 합성 세션과 익명화된 평가를 우선하고, 실제 서비스 전에는 별도 개인정보 검토가 필요합니다.

부록 B | 심사위원 예상질문과 모범답변

# Q&A 21-22

**Q21. 대표성 편향은 어떻게 다루나?**

yKa 선정 기준과 데이터 출처를 공개하고, 특정 기관·작가군에 치우친 코퍼스임을 한계로 명시합니다. 데이터 확장은 Core 검증 이후 수행하며, 작가·매체·시기별 coverage audit을 추가합니다.

**Q22. 가장 먼저 확인할 실험은 무엇인가?**

20개 Golden Query로 BM25, Dense, RRF가 오류 없이 Top-10을 반환하고 NDCG@10 코드가 실행되는지입니다. 이 통과 조건 전에는 UI나 이미지 모델을 확장하지 않습니다.

부록 C | 발표 직전 점검표

# 제출 전 30분 체크

- 팀원명, 소속, 프로젝트 기간, GitHub/데모 URL이 [INPUT] 상태로 남아 있지 않은가?
- 슬라이드 09-10의 모든 결과값이 TBD 또는 [TO-MEASURE]로 정확히 표시되어 있는가?
- 300개 합성 세션과 20명 파일럿이 계획값이라는 설명이 발표대본에 포함되어 있는가?
- B1/B2/B3/B4/B4R/B5의 정의가 발표와 부록에서 동일한가?
- B5가 동일 R_10을 고정한 비교인지, 선택·필터 효과가 섞이지 않았는가?
- 작품층 설명과 전시층 일정 근거가 시각적으로 분리되어 있는가?
- VERIFIED / CACHED / UNVERIFIED badge의 뜻을 발표자가 말할 수 있는가?
- NDCG@10, CR@10, Trec, UCR의 방향과 의미를 한 문장으로 설명할 수 있는가?
- 실측 전 "향상", "개선", "유의한 차이", "달성" 표현이 제거되어 있는가?
- 데모가 실패할 경우에도 static 결과표와 60초 설명으로 발표를 완주할 수 있는가?

## 권위 문서

- ARTHÉMIS_final_submission_ready.pdf - 문제 정의, 2층 grounding, B0-B5 정식 사다리, 결과 경계
- ARTHÉMIS_Core_다운사이징_실행계획서_2026-09-23.pdf - Core 범위, 6주 실행, 네 지표, 계획값
- ARTHÉMIS_통합_마스터_에디션_2026-09-23.pdf - 시스템·평가·발표·사업 문서의 통합 권위 체계
- ARTHÉMIS 논문 심사 및 최종 준비 로드맵.pdf - API/fine-tuning 선택 조건 및 구현 보조안
- 아이펠톤_포스터_(팀_이름).pdf - AIFFEL 제출 시각 구조의 참고 템플릿