MENTOR REVIEW · SCOPE REDUCTION PLAN

ARTHÉMIS 다운사이징 실행계획서

범위 재설정 · OpenAI API 파인튜닝 계획 · 6주 실행안 — 2026년 9월 23일 제안서 피드백 반영

작성 추병곤 (AIFFEL 리서치 18기, 365챌린지) **작성일** 2026-09-23 **버전** v1.1 (멘토 검토용 · LLM API 확정 반영) **대상 일정** 중간 논문 10/22 · 최종 제출 11/6 16:00 · 발표 11/10

> **문서 상태**
> 이 문서는 실행 계획서입니다. 본문의 모든 수치(표본 규모, F1 목표, 효과크기, 라벨링 시간, 토큰 규모)는 **계획값 또는 가정에 기반한 추정**이며 실측 결과가 아닙니다. 확인되지 않은 항목은 [입력]으로 남깁니다. 외부 서비스 현황은 2026-09-23 기준으로 확인했으며 출처는 부록 B에 있습니다.

0. 요약

9월 23일 제안서 발표에서 멘토님은 원안이 6주 동안 1인이 수행하기에 지나치게 넓다고 판단하셨습니다. 근거는 네 가지였습니다. 이종 데이터셋 통합이 착수되지 않았고, 다수 모델 운용에 자원 제약이 있으며, 평가 지표가 광범위하고, 모든 요소를 2차 가공해 엮어야 하는 구조입니다. 본 계획서는 이 판단을 수용합니다. 원안의 설계 자산은 폐기하지 않고, **하나의 반증 가능한 질문을 끝까지 검증하는 형태**로 범위를 다시 정합니다. 핵심 결정은 다음 다섯 가지입니다.

D1 **연구 질문 5개 → 핵심 질문 1개.** "맥락 분리형 구조화 취향 메모리가 무기억 LLM 및 전체 이력 투입 방식보다 맥락 오염을 줄이고 개인화 순위 품질을 높이는가"만 확증 검정합니다. 확증 가설은 7개에서 2개로 줄입니다.

D2 **비교 조건 10개 → 3개(+선택 1).** B1 무기억, B2 전체 이력 투입, B4 구조화 메모리를 비교하고, 여유가 있으면 B3 세션 요약을 추가합니다. 재순위화, 그라운딩 필터, 설명 절제는 향후 과제로 옮깁니다.

D3 **데이터 원천 다수 → 2종.** 국립현대미술관(MMCA) 소장품 공개 데이터와 문화포털 전시 API 스냅샷 1회만 사용합니다. 감각어–조형어 사전은 Getty AAT 전체가 아니라 큐레이터가 직접 구축하는 100–200개 규모로 줄입니다.

D4 **로컬 인코더 4종 → GPU 비의존 구성.** 텍스트 임베딩 1개, BM25, LLM API로만 구성합니다. 이미지 인덱스(DINOv2, CLIP 계열)는 제외합니다.

D5 **LLM API와 파인튜닝.** LLM은 **OpenAI API Platform**으로 통일하고, 멘토님 제안대로 **에이전트 A의 신호 추출기를 OpenAI SFT로 특화**합니다. 다만 "GPT-4" 원 모델(gpt-4-0613)은 2026-10-23에 API가 종료되어 본실험 기간과 겹칩니다. 그래서 기반 모델은 GPT-4 계열의 **gpt-4o-2024-08-06**(대안 gpt-4.1)로 둡니다. 5월 이후 파인튜닝은 자격이 있는 조직만 가능하므로 **9/25까지 G0 게이트에서 자격을 확인**하고, 불가하면 프롬프팅으로 전환합니다.

항목	원안	축소안	효과
확증 가설	7	2	다중 비교 보정 부담 감소, 검정력 확보
비교 조건	B0–B5, B4a, B5-F, B5-E0, Oracle	B1, B2, B4 (+B3)	실험 실행량 약 1/3
데이터 원천	MMCA·문화포털·Met·Harvard·AAT	MMCA·문화포털	스키마 통합 1회로 종결
검색 인덱스	T·X·V·L + 크로스 인코더	T·L (RRF)	GPU 불필요
시뮬레이션	300세션 (30명×10)	100–150세션 (20–30명×5)	사람 라벨 예산 내 수렴
에이전트 구성	5단계 파이프라인	에이전트 2개 + 오케스트레이터	멘토 제안 구조와 일치
LLM	[미정]	OpenAI API · 추출기 SFT	추출기 특화 효과를 별도 측정

1. 피드백 진단

1.1 지적 사항과 반영 위치

멘토 지적	해석	반영
6–7개 데이터셋의 컬럼이 다르며 통합 데이터셋 구축이 필요하다	데이터 통합이 사실상 첫 번째 연구 과업인데 착수되지 않았다. 원천이 늘수록 통합 비용이 선형 이상으로 늘어난다.	§5 원천 2종, 통합 스키마, G1 게이트
모델 4개를 병렬 운용할 자원이 있는가	실행 자원 가정이 문서에 명시되지 않았다. 원설계의 임베딩은 오프라인에서 순차 계산하는 구조였으나 발표에서 이를 설명하지 못했다. 다만 범위가 과다하다는 판단은 유효하다.	§4.3 GPU 비의존 스택
논문화하려면 명확한 지표화가 필요하다. "그냥 LLM 대비 이만큼 개선"만 보이면 된다	기여를 하나의 비교로 압축하라는 요구이다. 무기억 LLM 기준선(B1)이 반드시 포함되어야 한다.	§3 RQ·H1·H2
GPT-4 파인튜닝으로 특화 에이전트를 만들어 붙여라	OpenAI API 플랫폼의 SFT로 에이전트 A 추출기를 특화한다. 입출력이 명세된 역할 분리, 로컬 자원 부담 제거, 측정 가능한 개선을 함께 얻는다. 계정 자격과 모델 종료 일정을 먼저 확인해야 한다.	§6 OpenAI SFT 계획, G0·G2 게이트
전체적으로 다운사이징하고, LLM이 만든 결과에 끌려가지 말 것	설계 문서는 세 차례 정교화되었지만 데이터와 코드 산출물은 없다. 이 비대칭이 가장 큰 위험이다.	§2 원칙, §8 게이트, §9 거버넌스

1.2 근본 원인

원안의 문제는 설계의 품질이 아니라 **검증 단위의 크기**였습니다. 기여 네 개(메모리, 공간 분리 검색, 2층 그라운딩, 평가 프로토콜)를 한 번의 실험 사다리로 동시에 입증하려 했습니다. 그 결과 조건 수와 가설 수, 라벨링 부담이 곱으로 늘었습니다. 또한 가장 희소한 자원인 **사람 라벨 시간**을 설계 제약으로 두지 않았습니다. 본 계획은 라벨 예산을 먼저 정하고, 그 안에 들어가는 실험만 남기는 방식으로 역산했습니다.

2. 범위 재설정 원칙

원칙	내용	판정 기준
P1 하나의 반증 가능한 질문	확증 검정은 사전 지정된 주 지표 2개로 제한한다. 나머지는 탐색적 결과로 명시한다.	가설마다 비교 쌍과 방향이 하나로 정해짐
P2 GPU 비의존	모든 추론은 API 또는 CPU에서 수행한다. GPU는 조건부 LoRA에만 선택적으로 사용한다.	노트북과 API 키만으로 전 실험 재현 가능
P3 라벨 예산 우선	큐레이터 판정 시간을 먼저 상한으로 정하고 표본 규모를 역산한다.	1차 평가자 약 8–12시간, 2차 평가자 약 2–3시간
P4 부정 결과도 성립	효과가 없거나 반대 방향이어도 해석 가능한 비교만 남긴다.	B4 < B2여도 "구조화의 비용"으로 보고 가능
P5 설계 자산 보존	제외 모듈은 폐기하지 않고 향후 과제와 복귀 조건으로 기록한다.	§4 범위 매트릭스의 복귀 조건

3. 연구 질문과 비교 설계

> **핵심 연구 질문 (RQ)**
>
> 감상 맥락별로 분리·선택되는 구조화 취향 메모리는, 무기억 LLM 및 과거 대화 전체를 투입하는 방식에 비해 **다른 맥락 취향의 혼입(맥락 오염)을 줄이고 개인화 순위 품질을 높이는가?**

가설	비교	주 지표	방향	분석 대상	의미
H1	B2 → B4	CR@10	↓	다중 맥락 사용자 전원	본 연구의 고유 주장이다. 같은 정보를 넣되 구조화하고 선택하는 것이 통째로 넣는 것보다 나은가.
H2	B1 → B4	NDCG@10	↑	전체 사용자	멘토 제안 기준이다. "그냥 LLM" 대비 개인화 개선이 있는가.

표 3-1. 확증 가설. 두 검정에 Holm 보정(양측 $\alpha = 0.05$)을 적용한다. 그 밖의 지표는 보정 없는 신뢰구간과 함께 탐색적 결과로 보고한다.

3.1 비교 조건

세 조건은 **메모리가 질의 구성 단계에 들어가는 방식만** 다르고 나머지는 모두 동일합니다. 원안은 질의 벡터를 $v_t = \mathrm{norm}(\beta q_t + (1-\beta) m_t)$로 혼합했습니다. 축소안은 메모리를 **텍스트 프로필 블록**으로 표현하고, 모든 조건이 공유하는 질의 재작성 프롬프트의 한 슬롯에 넣습니다. 이렇게 하면 B2(원문 이력)와 B4(구조화 프로필)가 같은 채널에서 내용만 다른 조건이 되어, 효과를 메모리 구조에 깨끗하게 귀속할 수 있습니다.

ID	메모리 슬롯 내용	고정 요소	상태
B1	비움 (현재 세션 발화만)	질의 재작성 LLM·프롬프트·temperature·seed, 검색 인덱스(T·L), RRF 설정, 코퍼스·전시 스냅샷, 응답 생성기	필수
B2	과거 세션 전사 전체를 최신순으로 이어붙이고, 모델 입력 한도에서 절단		필수
B3	질의와 유사한 상위 k개 Session Node 요약 (라우팅 없음)		선택
B4	Context Router가 선택한 Taste Cluster 기술문 + 근거 발화 인용		필수

표 3-2. 비교 조건. B3를 수행하면 B2→B3(요약 효과)와 B3→B4(클러스터·라우팅 효과)로 H1을 분해하는 탐색 분석이 가능하다.

3.2 주 지표 정의

맥락 오염률. 사용자 u의 현재 맥락 c에 적합한 작품 집합을 P_c, 다른 맥락에 적합한 작품의 합집합을 P_{c^-}라 하면, 오염률은 다른 맥락에만 적합한 추천의 직접 분율입니다. 두 맥락에 모두 적합한 작품은 오염으로 세지 않습니다.

$$\mathrm{CR@10} = \left| \{ a \in R_{10} : a \in P_{c^-} \setminus P_c \} \right| / 10$$

순위 품질. 큐레이터 등급 $g \in \{0, 1, 2, 3\}$(무관 / 사조·매체 일치 / 조형 또는 정서 일치 / 조형·정서와 현재 맥락까지 일치)으로 NDCG@10을 계산합니다. IDCG는 해당 질의에서 판정된 전체 풀로 계산합니다. 관람 가능성은 등급에 넣지 않습니다.

$$\mathrm{NDCG@10} = (1 / \mathrm{IDCG@10}) \cdot \Sigma_{i=1..10} (2^{g_i} - 1) / \log_2(i + 1)$$

3.3 탐색적 지표

- **추출 micro-F1**(명시·암묵 분리): 에이전트 A의 품질 점검용이며, §6의 파인튜닝 결정 게이트에 사용합니다.
- **회복 턴 수 T_{rec}**: 취향 전환형 사용자에서 전환 이후 CR@10 ≤ 0.10이 연속 2턴 유지되기까지의 턴 수입니다.
- **미검증 방문 주장률 UCR**: 응답의 기간·장소·요금 주장 중 전시 스냅샷 필드로 뒷받침되지 않는 비율입니다. 감사 표본으로 측정합니다.
- **응답 지연 p95**: 데모 운영 지표로만 보고합니다.

4. 범위 매트릭스와 축소 시스템 설계

4.1 원안 대비 범위 매트릭스

구성요소	원안	판정	축소안	향후 복귀 조건
계층형 메모리	Session Node, Taste Cluster(MERGE/BRIDGE/GENESIS, 4상태), Router	유지·단순화	MERGE/GENESIS 2판정, tentative·active·suppressed 3상태, 규칙+유사도 Router	BRIDGE는 판정 로그만 기록하고, 취향 전환 경로 분석 시 복귀
미학 신호 추출	명시·암묵 슬롯 + 근거 span + consent_scope	유지	동일 스키마, JSON 구조화 출력	—
텍스트 검색 T	BGE-M3, 해설문+AAT 태그	유지	다국어 텍스트 임베딩 1종 (API 또는 CPU)	—
어휘 검색 L	BM25	유지	한국어 형태소 토큰화 + BM25	—
텍스트–이미지 X	SigLIP 2 등	제외	—	본실험 종료 후 B4+X 단일 절제
이미지–이미지 V	DINOv2, 조명 강건성 점검	제외	—	이미지 이용 허락 확인 후
크로스 인코더 재순위	B4R, H3	향후	RRF 상위 10 사용	NDCG@5 개선 여지가 관찰될 때
2층 그라운딩	신선도 3상태, 정합도 식, B5/B5-F	데모 수준	스냅샷 1회, 규칙 연결, 확인 필드만 발화, UCR 감사	B5-F 선택 효과 실험
근거 설명 절제	B5-E0 vs B5, H5	향후	근거 인용 설명은 기본 기능으로만 구현	큐레이터 평가자 2인 확보 시
데이터 원천	MMCA, 문화포털, Met, Harvard, AAT	축소	MMCA + 문화포털 스냅샷	해외 소장품 비교 연구
시뮬레이션	페르소나 3유형 × 10변형 × 10세션	축소	다중 맥락형·취향 전환형 × 10–15변형 × 5세션	—
실관람객 파일럿	20명, IRB	조건부	여건 시 5–10명 정성 파일럿	IRB 또는 면제 확인 후

4.2 2-에이전트 구조

멘토님이 제시한 "에이전트 A는 사용자 취향, 에이전트 B는 미술 정보" 분할을 그대로 채택합니다. 원안의 5단계 파이프라인은 이 두 에이전트의 내부 단계로 흡수됩니다.

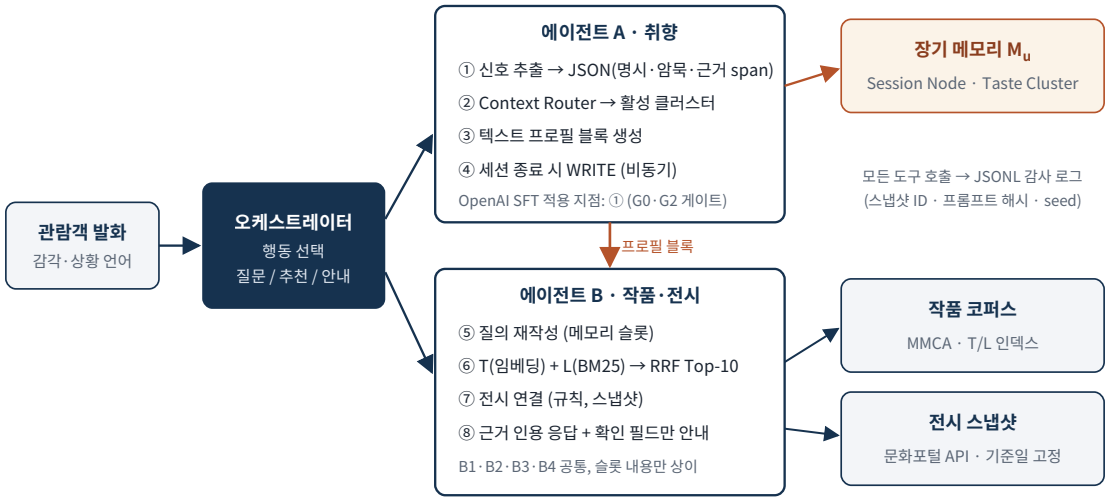


그림 4-1. 축소 시스템 구조. 에이전트 B는 모든 비교 조건에서 동일하며, 조건 간 차이는 에이전트 A가 공급하는 프로필 블록의 내용뿐이다.

4.3 에이전트 A — 과업 계약

구분	명세
입력	현재 발화 x_t, 현재 세션 최근 k턴, 감각어–조형어 사전 후보(사전 매칭 결과)
출력 (JSON 스키마)	**explicit**{artist, medium, region, visit_time, companion} · **implicit**{motive ∈ 사유·회복·학습·체험, formal{color, texture, scale, density}, avoid[], difficulty} · **evidence**[{turn, span}] · **confidence** ∈ [0,1] · **negation**[]
검증	스키마 검증 실패 시 1회 재시도, 이후 해당 필드는 null. 근거 span이 원문에 없으면 해당 신호를 폐기한다.
메모리 쓰기	세션 종료 시 Session Node 생성. 최근접 클러스터 유사도 $\sigma \geq \tau_m$이면 MERGE, 아니면 새 tentative 클러스터를 만든다. 서로 다른 2개 세션에서 재관찰되면 active로 확정하고, 명시적 부정은 suppressed로 둔다. τ_m은 개발 세트에서 보정한다(초기값 0.78).
라우팅	후보 = active ∪ tentative. 점수 = $\eta \cdot \cos(q_t, \mu_k) + \theta \cdot$(맥락 슬롯 일치율). 최대 확률 < ρ이면 확인 질문 1회("누구와 가시나요?")를 우선한다.
프라이버시	정서 원문은 저장하지 않고 목적 수준(예: 회복)으로 추상화한다. 사용자는 프로필을 열람·수정·삭제할 수 있다.

4.4 실행 스택 (GPU 비의존)

층	선택	재현성 고정 항목
LLM (에이전트·재작성·생성)	OpenAI API Platform. 기반 스냅샷 gpt-4o-2024-08-06(대안 gpt-4.1-2025-04-14). 추출기는 G2에서 채택된 SFT 모델 또는 프롬프트	스냅샷명, 파인튜닝 모델 ID, temperature, seed, 프롬프트 해시
시뮬레이터·판정	OpenAI 외 모델 계열 API [입력]	모델명, temperature, seed
텍스트 임베딩	다국어 임베딩 API 또는 CPU 구동 오픈 모델 1종 [입력]. 코퍼스는 1회 오프라인 계산 후 저장	체크포인트, 차원, 정규화
어휘 검색	한국어 형태소 분석기 + BM25	토크나이저 버전, k1·b
벡터 저장소	로컬 FAISS 또는 Chroma	인덱스 파일 체크섬
데모	Streamlit	코드 커밋 해시
로그	JSONL 감사 로그 (도구 입력·출력·오류·근거 span)	스냅샷 ID 연결

5. 데이터 계획

5.1 원천과 이용 조건

원천	용도	W1 확정 항목
MMCA 소장품 공개 데이터	작품 층: 메타데이터와 해설문. T·L 인덱스의 유일한 코퍼스	수집 경로, 이용 조건, 해설문 보유 건수 [입력]
문화포털 공연·전시 API	전시 층: 전시명·기관·기간·소개문. 평가 시작 시 1회 동결	API 키, 스냅샷 기준일·체크섬 [입력]
감각어–조형어 사전 (자체 구축)	감각어를 조형 어휘로 번역. 에이전트 A 입력과 태그 생성	v0 100개 → v1 200개, AAT ID는 가능한 경우만 병기

근현대 작품의 저작권을 고려해 원본 이미지는 저장·재배포하지 않습니다. 축소안은 이미지 인덱스를 쓰지 않으므로 이미지 관련 이용 허락 문제는 본 범위에서 발생하지 않습니다.

5.2 통합 스키마

테이블	필드
artwork	art_id, title_ko, title_en, artist, year, medium, classification, description_ko, sensory_tags[], formal_tags[], source_url, license_note, completeness_score
exhibition	exh_id, title, venue, region, start_date, end_date, description, artists[], tags[], snapshot_id, snapshot_date
link	art_id, exh_id, rule(artist_match | tag_jaccard), score, verified(bool)
lexicon	term_ko, concept_ko, concept_en, aat_id(선택), polarity, example_utterance

G1 게이트(9/29). 해설문을 가진 작품 500건 이상 적재, 필드 완결성 보고서, 중복 제거 로그, 전시 스냅샷 1회, 사전 v0 100개를 갖춰야 합니다. 미달 시에는 해설문 보유 작품만으로 코퍼스를 한정하고 그 사실을 기록합니다.

5.3 라벨 예산과 Golden Set

라벨 예산은 표본 규모를 결정하는 가장 강한 제약입니다. 평가 질의마다 모든 조건의 상위 10개를 합친 풀에 대해 큐레이터가 등급을 매깁니다. 다중 맥락형 사용자에서는 같은 판정에서 "다른 맥락에 적합" 여부도 함께 표시해 CR 계산에 필요한 P_c를 구성합니다.

시나리오	시뮬레이션 사용자	평가 질의	풀 판정 수 (추정)	1차 평가자 시간	검출 가능 d_z (Holm 최엄격)
기본	20 (B형 10 · C형 10)	60	≈ 1,500	≈ 8–12 h	≈ 0.74
확장	30 (15 · 15)	90	≈ 2,250	≈ 12–19 h	≈ 0.59

표 5-1. 가정: 사용자당 평가 체크포인트 3회(세션 4–5), 질의당 고유 풀 약 25건, 판정당 20–30초. 검정력은 짝지은 t 근사, 검정력 0.8, 양측 α = 0.025 기준이다. 모두 계획용 추정치다.

2차 평가자는 판정의 20%를 독립 채점하고 순서 척도 Krippendorff's α를 보고합니다(목표 ≥ 0.67). 확장 시나리오는 W3 말 라벨링 속도를 실측한 뒤 결정합니다. 1차 평가자가 연구자 본인이라는 점은 한계로 명시합니다. 이를 완화하기 위해 판정은 조건 표시 없이 무작위 순서로 수행합니다.

6. LLM API와 파인튜닝 계획 — OpenAI API Platform

> **결정**
>
> LLM은 **OpenAI API Platform**으로 통일하고, 멘토님 제안대로 **에이전트 A(취향)의 신호 추출기를 OpenAI 플랫폼 지도학습 파인튜닝(SFT)으로 특화**합니다. 에이전트 B와 응답 생성기는 모든 비교 조건이 공유하는 고정 요소이므로 파인튜닝하지 않고, 동일한 기반 스냅샷을 프롬프트로 사용합니다.

> **기반 모델 선택: "GPT-4" 원 모델은 사용 불가**
>
> OpenAI 공지에 따르면 **gpt-4 / gpt-4-0613**, **gpt-4o-2024-05-13**, 그리고 파인튜닝 모델 **ft-gpt-4**의 API 제공이 **2026-10-23**에 종료됩니다. 이는 W5 본실험(10/23–10/29) 첫날과 겹쳐 재현성이 깨집니다. 따라서 GPT-4 계열 중 종료 공지가 없는 스냅샷을 기반 모델로 둡니다. 1순위는 **gpt-4o-2024-08-06**, 2순위는 **gpt-4.1-2025-04-14**이며, 조직 대시보드의 파인튜닝 기반 모델 목록에서 확인한 뒤 확정합니다.

6.1 플랫폼 현황 (2026-09-23 확인)

일자	OpenAI 공지 내용	본 과제에 대한 함의
2026-05-07	파인튜닝을 한 번도 실행하지 않은 조직은 파인튜닝 작업을 생성할 수 없다.	새로 만든 개인 계정은 사용할 수 없다.

일자	OpenAI 공지 내용	본 과제에 대한 함의
2026-07-02	최근 60일 안에 파인튜닝 모델로 추론한 이력이 없는 조직은 작업을 생성할 수 없다.	과거 사용 이력만으로는 부족하고, **최근 60일 추론 이력**이 필요하다.
2027-01-06	활성 기존 고객도 신규 작업 생성이 종료된다. 파인튜닝 모델 추론은 기반 모델 폐기 시까지 유지된다.	11/10 발표 이후이므로 일정에는 영향이 없다.
2026-10-23	gpt-4, gpt-4-0613, gpt-4o-2024-05-13, ft-gpt-4 등 종료	기반 모델은 위 경고 상자대로 선택한다.
10/31 · 11/30	OpenAI Evals 플랫폼이 읽기 전용으로 전환된 뒤 종료된다. 재사용 프롬프트 객체도 11/30에 종료된다.	평가는 자체 스크립트로 수행하고, 프롬프트는 코드 저장소에 버전 관리한다.

출처: OpenAI API Deprecations, Pricing 페이지 (부록 B).

6.2 G0 게이트 — 파인튜닝 자격 확인 (9/24–9/25)

자격 여부는 문서로 판단할 수 없고, 실제 작업 생성으로만 확인됩니다. 따라서 W1 초반에 다음 절차를 수행합니다.

1. **조직 API 키 확보.** 본인 조직, AIFFEL 과정 조직, 멘토 소속 조직 중 파인튜닝 이력이 있는 조직의 키를 확보합니다(§ 10 Q1).
2. **최소 작업 생성.** 10개 예제의 JSONL로 기반 스냅샷에 SFT 작업을 생성합니다. 성공하면 자격이 확인된 것입니다. 실패하면 오류 응답을 원문 그대로 보관합니다.
3. **자격 유지.** 생성된 모델로 추론을 1회 이상 실행해 60일 추론 이력 조건을 유지합니다. 이후 W5까지 매주 1회 이상 추론합니다.
4. **분기.** 성공하면 § 6.3–6.6을 진행합니다. 실패하면 § 6.7 폴백으로 즉시 전환하고, 그 사실을 논문의 방법 절에 명시합니다.

6.3 파인튜닝 대상과 범위

구성요소	SFT 여부	근거
A-1 신호 추출기 (발화 → JSON)	대상	입출력이 가장 명확하고, 암묵 신호 추출이 범용 모델의 약점으로 예상되는 지점이다. 멘토님이 말씀하신 "어떤 인풋에 어떤 아웃풋"이 정확히 정의된다.
A-2 세션 구조화 (세션 → Session Node)	선택	A-1이 G2를 통과하고 시간이 남을 때만 진행한다. 학습 데이터는 A-1 라벨을 재사용한다.
B 질의 재작성·응답 생성	제외	B1·B2·B4가 공유하는 통제 변수다. 여기를 바꾸면 H1·H2의 효과가 메모리 구조에 귀속되지 않는다.
시뮬레이터·판정 모델	제외	순환성을 막기 위해 에이전트와 **다른 모델 계열**을 쓴다(OpenAI 외 API [입력]).

6.4 학습 데이터 명세

항목	명세
형식	채팅 형식 JSONL. system = 과업 계약(§ 4.3), user = 현재 발화 + 최근 k턴 + 감각어 사전 후보, assistant = 스키마를 만족하는 JSON
규모	학습 200–300건, 검증 50건, 별도 시험 60건. OpenAI는 수십 개 예제로도 효과가 날 수 있다고 안내하지만, 암묵 슬롯의 분포를 덮기 위해 수백 건을 목표로 한다.
원천	① 연구자가 큐레이터로서 직접 작성한 시드 발화 60–100건 ② 본 평가에서 제외한 페르소나 A(정서 발견형) 스크립트 ③ 다른 모델 계열로 증강한 변형. 모든 예제는 사람이 검수한다.
누수 방지	평가용 시뮬레이션 사용자(B·C형)의 발화는 학습·검증에 절대 포함하지 않는다. 사용자 단위로 분할하고 해시 목록으로 중복을 점검한다.
라벨 비용	약 350건 × 30–40초 ≈ 3–4시간 (가정)
프라이버시	정서 원문은 목적 수준으로 추상화한 뒤 학습에 쓴다. 데이터 공유 할인 옵션은 사용하지 않는다.

6.5 학습 설정과 기록

기반 스냅샷명, 에폭 수(자동 설정으로 시작하고, 필요하면 3으로 고정), seed, 학습·검증 파일 ID, 작업 ID, 결과 모델 ID(ft:<base>:<org>::<id> 형식), 학습·검증 손실 곡선을 실행 기록에 남깁니다. 작업은 1회를 원칙으로 하고, 재학습은 오류 분석에 근거해 최대 1회만 허용합니다. 재학습 사유는 결정 로그에 기록합니다.

6.6 G2 게이트 — 추출기 선택 (10/6)

파인튜닝 모델과 프롬프트 기준선을 같은 시험 세트에서 비교하고, 더 나은 쪽을 본실험 추출기로 동결합니다. 이 비교 자체가 멘토님이 요청한 **"그냥 LLM 대비 특화 에이전트의 개선"**을 보여주는 탐색적 결과가 됩니다.

조건	구성	측정
E-P 프롬프트	동일 기반 스냅샷 + 과업 계약 + few-shot 8–16개 + 구조화 출력	micro-F1(명시·암묵 분리), 근거 span 엄격 F1, JSON 스키마 적합률, 호출당 지연·비용
E-FT 파인튜닝	SFT 모델 + 과업 계약(짧은 지시문), few-shot 없음	

```
채택 규칙 (시험 세트 60건, 사용자 단위 bootstrap 95% CI)
  ΔF1_implicit = F1(E-FT) − F1(E-P)
  if CI 하한 > 0                      → E-FT 채택
  elif CI가 0을 포함하고 E-FT 비용·지연이 낮음 → E-FT 채택 (효율 근거)
  else                                → E-P 채택
  최소 기준: F1_explicit ≥ 0.75, F1_implicit ≥ 0.50 (미달 시 한계로 보고)
채택된 추출기는 W5 본실험 전에 동결하며, 이후 교체하면 B4를 전부 재실행한다.
```

여유가 있으면 탐색 분석으로 **B4(E-FT)**와 **B4(E-P)**의 CR@10을 비교합니다. 파인튜닝이 메모리 품질을 거쳐 최종 추천까지 영향을 주는지 보는 분석이며, 확증 가설에는 포함하지 않습니다.

6.7 폴백 — G0에서 자격이 확인되지 않을 때

순서	방법	비고
1. 과업 계약 프롬프팅	E-P를 그대로 본 추출기로 사용한다. 모델은 OpenAI 기반 스냅샷을 그대로 쓴다.	즉시 가능, GPU 불필요
2. 자체 프롬프트 최적화	개발 세트로 few-shot 예시 조합을 자체 스크립트에서 탐색한다. OpenAI Evals 계열 도구는 종료 예정이므로 쓰지 않는다.	개발 세트 과적합에 주의
3. 소형 오픈 모델 LoRA	1–8B급 오픈 가중치 모델에 LoRA/QLoRA를 적용한다. 추출기에 한정한다.	Colab·과정 GPU 필요, 6.4 데이터 재사용

6.8 비용 산정

항목	산식 (기본 시나리오)	추정 토큰
SFT 학습	300건 × 약 1.5k × 3에폭	≈ 1.4M (학습)
E-P vs E-FT 비교	60건 × 2조건 × 약 2k	≈ 0.2M
시뮬레이션 스크립트 생성 (타 계열)	100세션 × 6턴 × 약 2k	≈ 1.2M
신호 추출 (B4, 채택 추출기)	600턴 × 약 1.5k	≈ 0.9M
메모리 쓰기	100세션 × 약 6k	≈ 0.6M
평가 질의 (재작성+생성)	60질의 × 4조건 × 약 6k	≈ 1.4M
B2 전체 이력 추가분	60질의 × 약 20k	≈ 1.2M

항목	산식 (기본 시나리오)	추정 토큰
합계 (재실행 여유 제외)		**≈ 7M**

표 6-1. 모든 값은 설계용 가정이다. 학습 단가와 파인튜닝 모델 추론 단가는 기반 모델별로 다르므로 조직 대시보드에서 확인한다 [입력]. 예산은 추정치의 2배로 잡는다.

7. 평가 설계

7.1 고정 스크립트 재생 평가

대화형 시뮬레이션을 조건마다 따로 돌리면 시스템 응답에 따라 사용자 발화가 달라집니다. 그러면 조건 간 차이가 메모리 효과인지 대화 경로 차이인지 구분할 수 없습니다. 이를 막기 위해 **페르소나별 다중 세션 대화 스크립트를 한 번 생성해 동결**하고, 모든 조건이 같은 이력으로 메모리를 구축하게 합니다. 이후 동일한 평가 체크포인트에서 검색 결과를 비교합니다. 이 방식은 비교의 인과 귀속을 강화하고 비용을 줄이지만, 적응적 대화 정책(확인 질문의 효과)은 평가하지 못합니다. 이 점은 한계로 명시합니다.

페르소나	시나리오	검증 대상
B 다중 맥락형	평일 혼자 사유형 관람과 주말 자녀 동반 체험형 관람을 세션마다 교차 질의	H1 CR@10, 라우팅
C 취향 전환형	구상 회화 선호에서 3–4번째 세션 이후 미디어·키네틱 설치로 전환	H1(전환 이후 구 취향을 $\bar{c}$로 둠), T_{rec}
A 정서 발견형	사조 어휘 없이 정서·감각어만 사용	본 범위 제외, 추출 개발 세트로만 활용

스크립트는 암묵적 선호 표현이 전체 선호 발화의 40% 이상이 되도록 통제합니다. 스크립트 생성, 에이전트, 판정에는 서로 다른 모델 계열을 배정합니다. 정답 프로필과 맥락 라벨, 전환 시점은 연구자가 큐레이터로서 검수합니다.

7.2 통계 분석 계획

- **분석 단위:** 시뮬레이션 사용자. 지표를 사용자별로 평균한 뒤 조건 간 짝지은 차이를 분석합니다.
- **추정:** 사용자 단위 군집 paired bootstrap(10,000회) 95% 신뢰구간, 짝지은 평균 차이, 효과크기 d_z.
- **검정:** 사용자 단위 부호 뒤집기 순열검정(10,000회), H1·H2에 Holm 보정.
- **해석 원칙:** 표본 규모상 중간 이상 효과만 검출할 수 있으므로, 유의하지 않은 결과를 "효과 없음"으로 해석하지 않고 신뢰구간으로 보고합니다. 음의 결과도 그대로 보고합니다.
- **민감도:** $\tau_m \pm 0.05$, 라우터 $\theta = 0$(맥락 항 제거)에서 H1 방향이 유지되는지 확인합니다.

7.3 사전 등록 성격의 목표 (실측값 아님)

지표	목표	용도
H1: CR@10 짝지은 차이 (B4 − B2)	95% CI 상한 < 0	확증
H2: NDCG@10 짝지은 차이 (B4 − B1)	95% CI 하한 > 0	확증
추출 micro-F1 (명시 / 암묵)	≥ 0.75 / ≥ 0.50	G2 게이트
평가자 간 α	≥ 0.67	라벨 신뢰도
UCR (감사 표본)	0건	탐색·데모 품질

8. 6주 실행 계획과 게이트

주차	산출물	통과 기준 (게이트)	미달 시 조정
W1 9/23–9/29	MMCA 수집·정제, 전시 API 스냅샷, 통합 스키마, 감각어 사전 v0, T·L 인덱스, 추출 시드 발화 작성	**G0**(9/25): 파인튜닝 자격 확인 **G1**: 해설문 보유 작품 ≥ 500, 완결성 보고서, 스냅샷 체크섬	G0 실패 시 §6.7 폴백. G1 미달 시 해설문 보유 작품으로 한정
W2 9/30–10/6	추출 학습·검증·시험 데이터 약 350건, SFT 작업(E-FT), 프롬프트 기준선(E-P), B1 end-to-end	**G2**: E-P vs E-FT 비교 → 추출기 선택·동결 (§6.6)	암묵 슬롯 축소, 한계로 보고
W3 10/7–10/13	메모리 쓰기·라우터, 스크립트 100세션 동결, B2·B4 구현, τ_m 보정, 라벨링 속도 실측	**G3**: B1·B2·B4 전 조건 1회 완주, 감사 로그 정상	라우터를 규칙 기반으로 고정
W4 10/14–10/21	에이전트 B 전시 연결, 개발 세트 예비 결과, 중간 논문 원고	**G4**: 중간 논문 초안 완성	B3 제외 확정
10/22	중간 논문 제출 및 피드백 세션		
W5 10/23–10/29	평가 세트 본실험(동결 구성), 풀 라벨링, 2차 평가자 20%, 통계 분석	**G5**: H1·H2 결과표와 CI 산출	기본 시나리오(20명)로 고정
W6 10/30–11/6	Streamlit 데모, 오류 사례 분석, 최종 논문, GitHub 정리	11/6 16:00 제출	데모 기능 축소

게이트 원칙은 하나입니다. **게이트 미달은 일정 지연이 아니라 범위 축소로 해결합니다.** 중간 논문 이후에는 모듈을 추가하지 않습니다.

9. 리스크 레지스터와 작업 거버넌스

리스크	가능성	영향	대응
MMCA 데이터 접근·이용 조건 지연	중	상	W1 첫 2일 안에 경로를 확정한다. 불가 시 공개된 해설문 보유 건만 사용한다.
암묵 신호 추출 성능 미달	중	중	§6.6 G2 채택 규칙을 따른다. 미달 시 한계로 보고하며 H1·H2는 그대로 수행한다.
라벨링 시간 초과	중	상	W3에 속도를 실측한다. 기본 시나리오로 고정하고 풀 깊이를 10에서 5로 줄인다.
시뮬레이터–정답 순환성	중	중	모델 계열을 분리하고 사람 검수를 거친다. 결과는 상대 비교로만 해석한다.
파인튜닝 자격 없음 (5/7·7/2 정책)	상	중	G0에서 9/25까지 확인한다. 불가하면 즉시 프롬프팅 폴백으로 전환하고, H1·H2는 영향 없이 수행한다.
기반 모델 종료 (gpt-4 계열 10/23)	확정	상	종료 공지가 없는 gpt-4o-2024-08-06을 쓴다. 스냅샷명을 고정하고 응답을 캐시해 재분석이 가능하게 한다.
OpenAI Evals 종료 (10/31·11/30)	확정	하	평가·통계는 자체 Python 스크립트로 수행한다.
유의하지 않은 결과	중	하	P4 원칙에 따라 CI와 오류 사례 중심으로 보고한다.

> **LLM 사용 거버넌스**
>
> 설계 문서의 정교화가 실행을 대체하지 않도록 세 가지 규칙을 둡니다. ① W1–W2에는 논문 원고를 수정하지 않고 데이터와 코드만 산출합니다. ② 모든 설계 변경은 결정 로그에 사유, 근거 데이터, 날짜를 한 줄로 남깁니다. ③ LLM이 제안한 수치나 임계값은 개발 세트로 확인하기 전까지 채택하지 않습니다.

10. 멘토 확인 요청

#	질문	답변에 따른 변경
Q1	OpenAI 정책상 5/7 이후에는 파인튜닝 이력이 있고 최근 60일 안에 파인튜닝 모델 추론 이력이 있는 조직만 작업을 만들 수 있습니다. 과정이나 멘토님 소속 조직에서 이 조건을 만족하는 API 키를 쓸 수 있는지요? 또한 "GPT-4"는 10/23 종료 예정이라 gpt-4o-2024-08-06을 기반으로 하려는데 괜찮을지요?	가능하면 G0 즉시 수행. 불가하면 §6.7 폴백
Q2	핵심 질문 1개와 비교 조건 3개(B1·B2·B4), 확증 가설 2개로 줄인 범위가 적절한지요?	추가 축소 또는 B3 필수화
Q3	본 과제는 연구형 평가표(연구 방법론·통계적 유의성)와 서비스형 평가표(UI/UX·사용자 테스트) 중 어느 쪽으로 평가되는지요?	서비스형이면 데모·사용자 테스트 비중 확대
Q4	이미지 인덱스를 제외하면 "멀티모달"은 제목에서 빼고 향후 과제로 두려 합니다. 동의하시는지요?	제목·기여 문장 수정

부록 A. 연구형 평가표 대응

평가 항목	축소안의 대응
1-1 방법론의 적절성	단일 RQ, 메모리 슬롯만 다른 통제 비교 (§3.1)
1-2 데이터 수집·전처리	원천 2종, 통합 스키마, 완결성 보고서, G1 (§5)
1-3 모델 구현·실험 설계	2-에이전트 과업 계약, 고정 스크립트 재생 평가 (§4, §7.1)
1-4 성능 평가의 적절성	풀링 등급, 평가자 α, 군집 bootstrap (§5.3, §7.2)
1-5 코드 품질·재현성	스냅샷·프롬프트 해시·seed·감사 로그 (§4.4)
2-x 참신성·독창성	예술 도메인의 맥락 분리형 취향 메모리와 큐레이터 구축 감각어 사전
3-2 가설 설정의 타당성 / 3-3 목표 달성도	검증 가능한 가설 2개, 게이트로 달성 가능성 관리 (§8)
4-1 통계적 유의성 / 4-2 개선도	Holm 보정, CI·효과크기, B1·B2 기준선 대비 (§7.2)

부록 B. 외부 현황 출처 (2026-09-23 확인)

- OpenAI API Deprecations — "Update to OpenAI's self-serve fine-tuning"(2026-05-07 · 07-02 · 2027-01-06), 2026-04-22 Legacy GPT model snapshots(10/23 종료: gpt-4-0613, gpt-4o-2024-05-13, ft-gpt-4 등), Evals platform·Reusable prompts 종료 일정: https://developers.openai.com/api/docs/deprecations
- OpenAI API Pricing — Finetuning 항목(단계적 종료, 신규 사용자 접근 불가): https://developers.openai.com/api/docs/pricing
- OpenAI, "Fine-tuning now available for GPT-4o" (기반 스냅샷 gpt-4o-2024-08-06, 수십 개 예제 안내, 2026-05-08 업데이트 공지): https://openai.com/index/gpt-4o-fine-tuning/

본 계획서의 설계 근거 문헌(RecLLM, CSI, A-MEM, AlpsBench, RRF, NDCG, Holm 등)은 중간 논문 참고문헌 목록을 따르며 여기서는 반복하지 않는다.