ARTHÉMIS

원본 vs 수정본 정밀 심사 보고서 및 최종 제출용 통합 문안

대상 문서

원본: ARTHÉMIS_중간논문.pdf, 12쪽, 2026년 9월 초안
수정본: ARTHEMIS_중간논문_수정본_preview.pdf, 8쪽, 2026년 9월 preview

판정 요약

수정본은 원본의 시스템 아이디어를 논문형 방법론으로 진전시켰다. 특히 계층형 메모리, 공간 분리 검색, 2층 전시 그라운딩, B0-B5 절제 사다리, 짝지은 통계 검정을 명시한 점이 실질적 개선이다. 그러나 현재 상태는 제출 가능한 완성 논문이 아니라 설계 및 평가계획을 정교화한 중간 논문이다. 실측 결과, 코퍼스 스냅샷, 라벨 합의도, 모델 버전, API 재현 로그가 비어 있으므로 성능 우월성은 아직 주장할 수 없다.

이 보고서의 원칙

- 문서에서 실제로 확인되는 내용과 본 심사자가 제안하는 보완을 분리한다.
- 수치가 없는 곳에는 임의의 결과를 넣지 않고 [입력], TBD, 산출 필요로 남긴다.
- 외부 문헌은 원문에 인용된 범위를 넘어서 사실을 확정하지 않으며, 서지 검증이 필요한 항목은 별도 표시한다.

검토 기준일: 2026-09-23
문서 성격: 전문 심사 보고서 + 10-15쪽 제출용 통합 문안 + Results/Discussion 입력 템플릿

1. 총괄 심사 의견

종합 판정

수정본은 major revision 후 재심 가능한 수준이다. 아이디어의 독창성보다 중요한 심사 쟁점은 모듈별 효과를 정말 분리해서 측정할 수 있는지, 작품 추천과 전시 관람 가능성의 단위를 일관되게 정의했는지, 그리고 계획값과 실측값을 엄격히 구분했는지이다.

심사 축	현재 판단	근거
문제 중요성	강점	감각 언어, 다중 맥락, 실행 가능성의 단절을 하나의 시스템 문제로 묶음. 원본 p.2-3, 수정본 p.1-2
기술 기여	유망하나 검증 전	Session Node-Taste Cluster-Context Router, T-X-V-L 분리, Artwork-Exhibition 분리
실험 설계	수정본에서 크게 개선	B0-B5와 RQ1-RQ5, paired bootstrap, permutation test, Holm 보정
재현성	미흡	코퍼스 수, API snapshot, 모델 버전, 하이퍼파라미터, 라벨 프로토콜이 미입력
결과 주장	현재 불가	300 sessions와 pilot 20명은 계획/목표이며 실측값이 아님
출판 적합성	major revision	식, 분모, 비교 단위, 표 번호, 서지 상태를 확정해야 함

문서 근거와 보완의 경계

원본은 실험값이 확보되지 않은 항목을 [입력] 또는 TBD로 남긴다는 원칙을 명시한다(p.1-2). 수정본도 실측 결과를 최종 보고서로 유보한다(p.1). 따라서 본 통합 문안의 Results는 빈칸 템플릿으로 제공하며, 목표값을 결과처럼 서술하지 않는다.

가장 중요한 결론

> 논문의 승부처는 기능의 개수나 LLM 사용 여부가 아니다. 동일한 질의·동일 시드·동일 코퍼스 snapshot·동일 후보 집합에서, 한 모듈만 바뀐 비교를 수행하고, 실패가 어느 층에서 발생했는지 재현 가능하게 보여주는 것이다.

2. 원본 vs 수정본: 실제 개선점

수정본의 실질적 진전

항목	원본	수정본의 개선	심사 판단
문제 정의	감각 언어-아카이브 간극, 세션 단절, 실행 불가능 추천을 서술	의미 간극의 언어적 번역과 시각적 번역을 분리하고 세 결함을 명시	문제의 인과 구조가 선명해짐
메모리	Session Node, Taste Cluster, Context Router를 개념적으로 제안	노드 벡터, 가중치, MERGE/BRIDGE/GENESIS, tentative/active/stale/suppressed 상태와 WRITE 알고리즘 제시	구현 가능성이 크게 상승. 임계값 검증 필요
검색	T/X/V/L 인덱스와 RRF를 설명	B1, V 옵션, RRF 식, cross-encoder, 탐색 슬롯, V 강건성 점검을 명시	검색 ablation이 구체화됨
그라운딩	Artwork Layer와 Exhibition Layer의 분리 원칙	VERIFIED/CACHED/UNVERIFIED 상태와 작품-전시 정합도 식 제시	환각 억제 정책이 감사 가능해짐
실험	B0-B5, memory lifecycle, 단계별 지표의 계획	B1-B3-B4-B4R-B5의 비교 조건, RQ별 주 지표, CI/효과크기/Holm 보정 명시	심사자가 요구하는 비교 논리가 보강됨
문헌 연결	RAG, CLIP, DINOv2, A-MEM, MCP 등 흐름을 요약	RecLLM/CSI/AlpsBench/LongMemEval 등 선행 과업과 차이를 연결	related work가 연구 공백과 더 직접 연결됨

원본의 장점도 보존해야 하는 부분

• 원본 p.1-2의 '중간논문' 상태 선언과 목표값/실측값 구분은 수정본의 압축 과정에서 더 전면에 배치할 필요가 있다.

• 원본 p.7-11의 평가 파이프라인, 오류 사례, 윤리적 운영 원칙은 수정본의 수식 중심 서술과 함께 유지하는 편이 안전하다.

• 원본의 12쪽 A4 조판은 읽기 여백이 좋고, 수정본의 8쪽 letter 조판은 정보 밀도가 높다. 최종본은 수정본의 논리와 원본의 가독성을 결합해야 한다.

3. 남은 논리적·방법론적 결함

고위험 결함

우선순위	문제	왜 치명적인가	수정 조치
P0	CR@K 식이 오염률이 아니라 1-오염률에 가까움	수정본 p.3의 식 (3)은 '오염된 항목의 비율'을 정의한다면 1-이 아니라 직접 분율이어야 함. 현재 명칭과 식이 반대일 가능성	CR@K = |R_K ∩ G_cbar| / |R_K| 로 고정하고, purity를 별도 metric으로 분리
P0	B4R-B5에서 후보 순위가 바뀔 수 있음	RQ4가 grounding 효과인지 검색/필터 효과인지 분리되지 않음	B4R의 동일 R_10을 고정해 전시 상태만 부착하고, 별도 운영 실험에서 filtering 효과를 보고
P0	작품 단위와 전시 단위가 혼재	Availability@10이 작품 10개인지 전시 10개인지에 따라 분모와 해석이 달라짐	recommendation card, unique artwork, unique exhibition을 구분해 모두 정의
P0	실측 데이터와 계획 데이터의 경계	300 sessions, 20명, 목표 F1/CI/UCR는 성과가 아니라 계획	초록/결과/결론에 'planned' 또는 'not yet measured'를 반복 명시
P1	B4가 Taste Cluster와 Context Router를 한 번에 추가	세부 기여 귀속이 불완전함	B3->B4a(cluster only)->B4b(router) 또는 주장의 범위를 'memory block'으로 제한
P1	시뮬레이터가 자기 정답 프로필로 평점 생성	메모리와 추천이 같은 정답 신호를 공유하면 순환적 이득이 생김	대화 생성/정답 판정/평가를 분리하고, 독립 검수와 adversarial persona를 추가
P1	implicit signal과 미학 라벨의 주관성	암묵 선호 F1은 라벨 정의·동의·평가자 합의가 없으면 재현 불가	slot ontology, positive/negative/unknown, span 정책, κ 또는 α를 공개

중위험 결함

• T-X-V-L 인덱스의 역할은 명확하지만 B1 본 비교는 T-X-L, V는 별도 옵션이다. 따라서 '멀티모달 검색 전체'의 주장은 V ablation 없이는 제한적으로 써야 한다.

• grounding 식 (8)의 f_T(e), exhibition tag, λ 가중치와 threshold가 정의되지 않았다. 식이 구현 규칙인지 분석용 score인지 구분해야 한다.

• CACHED의 freshness 기준, API 지연 임계값, snapshot 기준일, 장애 시 fallback이 평가 데이터와 운영 데이터에서 동일한지 명시해야 한다.

• 탐색 슬롯은 모든 비교군에 동일하게 적용한다고 했지만, NDCG는 삽입 이전 목록, 사용자 노출 지표는 삽입 이후 목록이다. 두 평가 공간의 명칭을 분리해야 한다.

4. RQ - Baseline - Ablation - Metric 정합성

권고하는 최종 비교 구조

RQ	질문	권고 비교	주 지표	정합성 판단
RQ1	장기 메모리가 현재 발화만 쓰는 방식보다 개인화 순위를 개선하는가?	B1 vs B4; 동일 질의/seed	NDCG@10	가능. 누적 효과임을 명시
RQ2	구조화된 메모리가 전체 이력/단일 요약보다 전환·다중 맥락을 개선하는가?	B2 vs B3 vs B4; B3->B4에 router/cluster 분해 추가	CR@10, T_rec	현재도 가능하나 B4 내부 귀속 보완 필요
RQ3	cross-encoder 재순위가 융합 후보의 top quality를 높이는가?	B4 vs B4R; 후보 50 고정	NDCG@5	높음. reranker 입력과 학습/zero-shot 여부 고정
RQ4	2층 grounding이 관람 가능성과 미검증 주장을 개선하는가?	B4R + 동일 R_10에 grounding metadata 부착 vs B5 output	Availability@10, UCR	현재는 필터 효과 혼입 가능. paired output 필요
RQ5	근거 기반 설명이 자유 생성보다 충실성과 수용도를 높이는가?	B5-E0 vs B5-E1; 검색/grounding 고정	큐레이터 faithfulness	높음. E0/E1 prompt와 evidence visibility 고정

절제 사다리 해석 규칙

• B0는 lexical baseline, B1은 현재 발화 기반 검색, B2는 과거 대화 전체 이어붙이기, B3는 Session Node, B4는 Taste Cluster + Context Router, B4R은 cross-encoder, B5는 exhibition grounding이다.

• B1 -> B3 -> B4 -> B4R -> B5가 '한 모듈씩'이라는 주장은 B4를 하나의 memory block으로 정의할 때만 성립한다. cluster와 router의 개별 효과는 보조 절제로 분리한다.

• V(DINOv2)의 추가 효과는 별도 B1+V 또는 B1+X+V로 보고한다. 본 비교에서 V가 조건별로 켜졌다 꺼지면 전체 ablation의 해석이 흔들린다.

• 각 RQ마다 primary metric 하나만 confirmatory로 두고, Recall@50, MRR, UCR, latency는 exploratory로 표시한다. 수정본의 Holm 보정 계획은 유지한다.

판정

전체적으로 정합성은 수정본에서 유의하게 개선되었으나, RQ2와 RQ4는 현재 정의 그대로면 인과적 귀속을 방어하기 어렵다. 최종본에는 '무엇을 고정하고 무엇을 바꾸었는가'를 한 표 안에서 보여줘야 한다.

5. 수식·표·Figure·References 감사

수식 감사

대상	문서 근거	감사 결과	최종 수정
식 (1)	수정본 p.2	π가 행동·응답을 생성하는 정식화는 적절하나 α, R, G, y의 시간 index와 K가 일관되게 사용되어야 함	정의역과 출력 단위를 한 문단에 모음
식 (2)	수정본 p.3	NDCG 표기는 표준형으로 보이나 g_i 등급의 라벨링과 IDCG가 동일 pool에서 계산되는지 명시 필요	pooling과 relevance grade protocol 추가
식 (3)	수정본 p.3	Contamination Rate 명칭과 1 - wrong fraction이 불일치할 가능성이 큰 핵심 오류	오염 분율로 직접 정의. purity는 별도
식 (4)	수정본 p.4	시간 감쇠와 만족도 가중은 이해 가능. 단, 평점이 추천 반응에서 계산되면 순환성 있음	독립적인 session rating 또는 sensitivity analysis
식 (5)-(7)	수정본 p.5-6	cluster 판정, router, RRF가 제시되어 재현성이 상승. 임계값과 rank missing rule은 미정	개발/검증 분리, rank=∞ 처리, seed 공개
식 (8)	수정본 p.6	artwork-exhibition matching score의 타입과 λ/threshold 미정	분석 score인지 필터 규칙인지 분리하고 가중치 보정 절차 공개

표와 Figure 감사

• 원본 Table 1-3은 문제-대응-지표와 RQ-가설-검정을 잘 연결한다. 수정본 Table 1-4는 persona, ablation, 초기 목표, 일정으로 압축되어 실험 운영성이 좋아졌다.

• 수정본 Figure 1은 파이프라인과 C1/C2 경계를 시각적으로 명확히 한다. 다만 memory write가 세션 종료 또는 핵심 선호 발견 시 비동기 실행된다는 설명과 매 턴 업데이트가 혼재하므로 실행 시점을 하나로 고정해야 한다.

• 원본 Figure 2 평가 파이프라인은 동일 seed/snapshot과 오류 전파를 보여주는 장점이 있으므로 최종본에 복원한다.

• 수정본의 좁은 letter 2단 조판은 수식과 한글이 촘촘하다. 최종 제출본에서는 표가 페이지를 넘기지 않게 하고, 변수 정의가 분리되지 않도록 한다.

References 감사

수정본의 [1]-[28]은 학술 문헌 연결이 원본보다 풍부하다. 다만 이 보고서에서는 각 항목의 출판 상태와 저자/쪽수의 외부 사실을 새로 확정하지 않는다. [22], [24], [27]처럼 2025-2026 arXiv/학회 항목은 최종 제출 전에 DOI 또는 공식 proceedings 페이지로 서지 검증해야 하며, 원본의 내부 자료 [9]-[11]은 외부 출판물과 분리해 'unpublished project materials'로 유지한다.

6. 심사자가 지적할 가능성이 높은 부분

예상 심사 코멘트	답변 및 수정 방향	우선순위
실제 신규 데이터와 실측 결과가 어디에 있는가?	이 문서는 중간 설계 논문임을 초록 첫 문장과 결과 절에 명시하고, 결과가 없는 상태에서는 우월성 표현을 제거	P0
ARTHÉMIS가 기존 CRS/RAG보다 무엇을 더 잘하는지 공정하게 비교했는가?	B0-B5를 동일한 코퍼스와 seed에서 재실행하고, 기능별 baseline과 oracle upper bound를 함께 보고	P0
300 synthetic sessions가 실제 관람객을 대표하는가?	외적 타당성의 한계를 인정하고, simulator-pilot agreement, persona distribution, human pilot의 역할을 제한적으로 기술	P0
Taste Cluster와 Context Router가 각각 필요한가?	B3->B4a->B4b 추가 절제 또는 구성요소별 sensitivity로 분리	P1
전시 단위 API로 작품이 실제 전시 중이라고 어떻게 말하는가?	작품 단위 확인이 없는 경우 exhibition-level availability로만 표현하고 '작품 전시 중' 문구를 금지	P0
근거 기반 설명의 충실성을 어떻게 채점했는가?	evidence span, artwork evidence, exhibition evidence를 각각 claim 단위로 라벨링하고 2인 blind rating 및 α를 보고	P1
서지와 모델 버전이 재현 가능한가?	각 모델의 checkpoint, language, temperature, API date, commit hash, snapshot checksum을 부록에 추가	P1
프라이버시·정서 기억의 위험은?	원문 감정 상태 대신 목적 수준 추상화, consent_scope, read/edit/delete, retention policy와 IRB 상태를 명시	P1

수정 우선순위

P0: CR 식과 grounding 평가 단위 확정, 계획/결과 언어 통일, B5 paired design, 실제 코퍼스/API snapshot 확보. P1: B4 내부 ablation, 라벨 프로토콜, simulator leakage 점검, 모델·하이퍼파라미터·서지 검증. P2: 문장 압축, 영문 초록 다듬기, 표와 수식 조판, 색상/폰트 일관성.

심사 대응 문장

"본 연구는 현 단계에서 시스템의 최종 성능을 주장하지 않는다. 동일한 snapshot과 seed를 공유하는 절제 사다리를 통해 메모리, 검색, 재순위화, 전시 grounding, 설명 근거의 상대적 기여를 분리하는 평가 프로토콜을 제안하며, 실측 결과는 해당 프로토콜을 완료한 뒤 보고한다."

7. 최종 제출용 통합 문안: 제목·초록·기여

권고 제목

ARTHÉMIS: 장기 미학 대화 메모리와 2층 전시 그라운딩을 갖춘 대화형 아트 큐레이션 시스템의 설계 및 단계별 평가

초록 통합본

미술관 아카이브는 작가, 연도, 재료와 같은 전문 메타데이터를 중심으로 구성되지만, 관람객은 감각과 상황의 언어로 작품을 탐색한다. 기존 대화형 추천 시스템은 이 의미 간극을 일부 완화하더라도 세션 간 취향을 보존하지 못하거나 서로 다른 관람 맥락을 혼합할 수 있고, 추천 작품의 실제 전시 가능성을 검증하지 못할 수 있다. 본 연구는 이 문제를 해결하기 위해 근거 발화를 보존하는 Aesthetic Session Node, 반복 성향을 조직하는 Curatorial Taste Cluster, 현재 관람 맥락에 맞는 클러스터를 선택하는 Context Router를 결합한 계층형 미학 메모리를 제안한다. 또한 텍스트, 텍스트-이미지, 이미지-이미지, 어휘 검색을 독립 인덱스로 유지하고 rank-level fusion을 수행하며, 작품 발견과 전시 실행을 Artwork Layer와 Exhibition Layer로 분리한다. 모듈별 기여는 BM25 baseline에서 메모리, 재순위화, 전시 grounding을 단계적으로 추가하는 B0-B5 절제 사다리로 평가한다. 평가는 메모리 생명주기, 검색 순위, 취향 전환 회복, 맥락 오염, 관람 가능성, 근거 기반 설명을 포함한다. 본 중간 논문은 설계와 평가 프로토콜을 보고하며, 300개 합성 다중 세션과 20명 파일럿은 계획된 평가 규모이다. 실측 성능은 실험 완료 후 동일한 프로토콜에 따라 보고한다.

기여점 통합본

- 근거 span을 가진 Session Node와 잠정/활성/감쇠/억제 상태를 가진 Taste Cluster를 이용한 예술 도메인 장기 메모리 설계.
- 서로 다른 임베딩 공간을 벡터 합산하지 않고 독립 검색기와 RRF로 결합하는 공간 분리 멀티모달 검색.
- 작품 설명과 전시 관람 가능성을 분리하고 VERIFIED/CACHED/UNVERIFIED 상태를 기록하는 2층 grounding.
- RQ1-RQ5를 B0-B5와 paired statistical design에 연결한 재현 가능한 단계별 평가 프로토콜.

범위 제한

위 기여는 설계 기여이다. 데이터와 결과가 입력되기 전에는 '개선한다', '높인다' 대신 '검증한다', '측정한다', '목표로 한다'로 표현한다.

8. 최종 제출용 통합 문안: 문제·관련연구·RQ

문제 정의

사용자 u의 세션 열을 S_u=(S_u^(1),...,S_u^(M))라 하고, 작품 코퍼스를 A, 시점 t에 열려 있는 전시 집합을 E(t)라 한다. 시스템은 현재 발화와 대화 이력, 장기 메모리, 작품 코퍼스, 전시 snapshot을 이용해 행동 α_t, 순위화된 작품 목록 R_t, grounding record G_t, 근거 기반 응답 y_t를 생성한다. 여기서 (i) R_t는 현재 맥락과 장기 취향에 정합해야 하고, (ii) 맥락이 바뀌면 이전 취향을 삭제하지 않고 선택적으로 억제해야 하며, (iii) 일정과 장소 주장은 G_t의 확인된 필드에만 근거해야 한다.

연구질문과 가설

RQ	검증 질문	가설	주 결과
RQ1	계층형 장기 메모리가 현재 발화만 사용하는 방식보다 개인화 순위를 높이는가?	B4가 B1보다 NDCG@10이 높다	NDCG@10
RQ2	cluster/router가 전체 이력과 단일 요약보다 전환과 맥락 분리를 개선하는가?	B4가 B2/B3보다 CR@10과 T_rec를 개선한다	CR@10
RQ3	cross-encoder 재순위가 top quality를 개선하는가?	B4R가 B4보다 NDCG@5가 높다	NDCG@5
RQ4	2층 grounding이 관람 가능성과 claim 검증을 개선하는가?	B5가 동일 후보의 ungrounded 조건보다 Availability를 높이고 UCR을 낮춘다	Availability@10
RQ5	근거 기반 설명이 자유 생성보다 충실한가?	E1이 E0보다 faithfulness가 높다	큐레이터 faithfulness

관련 연구의 위치

대화형 추천은 자연어 선호 추론을 제공하고, RAG는 외부 근거를 연결하며, CLIP/DINOv2는 서로 다른 시각-언어 및 시각 표현을 제공한다. 장기 메모리 연구는 추출-갱신-검색-활용을 평가하지만, 예술 감상의 암묵적 선호, 다중 관람 맥락, 전시 실행 가능성을 함께 다루지는 않는다. ARTHÉMIS의 차별점은 새로운 encoder를 제안하는 데 있지 않고, 예술 도메인 메모리와 검색-전시 검증을 하나의 모듈별 평가 단위로 연결하는 데 있다.

9. 최종 제출용 통합 문안: 시스템 방법

계층형 메모리

세션 종료 시 Session Node n_i=(summary_i, intent_i, visit_i, e_i, z_i, s_i, status_i)를 생성한다. e_i는 원 발화의 evidence span이며, z_i는 요약과 AAT 기반 표현의 텍스트 임베딩이다. 노드 가중치는 최신성과 세션 만족도를 사용하되, 만족도가 추천 반응에서 파생되는 경우의 순환성을 피하기 위해 독립 평점과 민감도 분석을 병행한다. 새 노드와 클러스터 중심의 cosine similarity에 따라 MERGE, BRIDGE, GENESIS를 판정하고, tentative cluster는 재관찰 조건을 통과한 경우에만 active로 승격한다. 명시적 부정 선호는 suppressed로 기록하고 삭제와 억제를 구분한다.

공간 분리 멀티모달 검색

T는 BGE-M3 기반 해설문과 AAT 태그 검색, X는 다국어 text-image 검색, V는 기준 작품이 있을 때의 image-image 검색, L은 BM25 기반 고유명사·어휘 검색을 담당한다. 각 인덱스는 자체 순위를 반환하고, RRF score(a)=Σ_r ω_r/(κ+rank_r(a))로 후보를 융합한다. 이후 동일한 후보 50개에 대해 cross-encoder가 활성 프로필·현재 발화·작품 설명을 재순위화해 top 10을 만든다. V의 추가 효과는 별도 ablation으로 보고하며, 탐색 슬롯은 순위 품질 지표와 노출 지표에서 평가 단위를 분리한다.

2층 전시 grounding

Artwork Layer는 작품의 작가, 연도, 재료, 조형 특징 및 설명 근거를 관리한다. Exhibition Layer는 전시명, 기관, 장소, 기간, 확인 시각, 전시 상태를 API snapshot으로 관리한다. 작품 단위 확인이 없으면 '작품이 전시 중'이라고 말하지 않고, '해당 전시에서 관람 가능성이 확인됨'처럼 전시 단위로 표현한다. VERIFIED, 기준일이 표시된 CACHED, UNVERIFIED를 구분하고, 생성기는 VERIFIED 또는 허용된 CACHED 필드만 일정·장소 claim에 사용할 수 있다.

근거 기반 응답

각 추천 카드는 사용자 발화의 연결 span, 작품 조형 근거, 전시 grounding record를 claim 단위로 포함한다. 설명 평가는 작품 근거와 전시 근거를 분리해 blind rating하며, 자유 생성 E0와 근거 인용 E1은 검색 및 grounding 결과를 고정한 직교 절제로 비교한다.

10. 최종 제출용 통합 문안: 실험 설계

데이터와 시뮬레이션

작품 코퍼스는 기관 메타데이터와 해설문을 기본으로 하며, The Met Open Access와 Harvard Art Museums는 비교·시각 인덱스 보강 후보로 기록한다. 실제 사용 조건과 공개 범위는 수집 시점에 명시한다. Golden Set은 natural_query, intent, expected_artwork, expected_context, expected_exhibition, expected_evidence, acceptable_alternatives를 갖는다. 세 persona는 정서적 발견형, 다중 맥락형, 취향 전환형이며, 3 x 10 variants x 10 sessions = 300 sessions는 계획된 합성 평가 규모이다. 파일럿 목표는 20명이며, IRB 또는 면제 확인과 동의가 선행되어야 한다.

평가 지표

층	지표	정의 단위	계획값/상태
Memory	Extraction F1	slot/span의 macro 또는 micro F1을 사전 고정	목표 >= 0.75 명시, >= 0.50 암묵 / 결과 TBD
Memory	Update accuracy	Keep/Add/Revise/Suppress 4범주 행동	목표 >= 0.80 / 결과 TBD
Retrieval	Recall@50, NDCG@10, MRR	pooled candidate와 curator grade	RQ별 주 지표 지정 / 결과 TBD
Context	CR@10, T_rec	다른 맥락 ground-truth의 직접 분율, 전환 후 회복 턴	CR <= 0.10, T_rec <= 3 / 결과 TBD
Grounding	Availability@10, UCR	unique card 또는 artwork/exhibition 단위를 사전 고정	B5 > B4R, audit UCR 0 목표 / 결과 TBD
Explanation	Faithfulness, acceptability	claim-level blind curator rating	alpha >= 0.67 / 결과 TBD
Operations	p95, first token	동일 hardware/API/cache 정책	<= 6s, <= 1.5s / 결과 TBD

통계 계획

모든 조건은 동일 사용자·동일 seed의 paired design으로 평가한다. 주요 비교에는 paired bootstrap 95% CI와 효과크기를 보고하고, 순위 지표에는 permutation test를 보조한다. RQ1 NDCG@10, RQ2 CR@10, RQ3 NDCG@5, RQ4 Availability@10, RQ5 curator faithfulness를 primary metric으로 지정하고 Holm 보정을 적용한다. 그 밖의 metric은 exploratory로 명시한다.

11. Results 입력 템플릿

> 아래 표의 빈칸은 실제 실험을 수행한 뒤에만 채운다. 목표값을 측정값으로 대체하지 않는다.

11.1 데이터·실행 기록

필드	입력
코퍼스/기관/수집 기간	[기관명], [collection date], [snapshot ID/checksum]
작품 수 / 문서 수 / 전시 수	작품 [ ], 문서 [ ], 전시 [ ]
이미지 정책	원본 저장 여부 [ ], 기관 링크 [ ], 임베딩 [model/version]
모델	T [ ], X [ ], V [ ], L/BM25 [ ], CE [ ], LLM [ ]
실행 환경	CPU/GPU [ ], OS [ ], library commit [ ], temperature [ ], seed [ ]
API 및 freshness	API [ ], snapshot 기준일 [ ], VERIFIED window [ ], CACHED rule [ ]
라벨 합의	큐레이터 수 [ ], training/development/test split [ ], alpha/kappa [ ]

11.2 단계별 정량 결과

조건	NDCG@10	CR@10	T_rec	Avail@10	UCR	비고
B1	[ ]	[ ]	n/a	n/a	n/a	current turn
B2	[ ]	[ ]	[ ]	n/a	n/a	full history
B3	[ ]	[ ]	[ ]	n/a	n/a	Session Node
B4	[ ]	[ ]	[ ]	n/a	n/a	Cluster + Router
B4R	[ ]	[ ]	[ ]	[ ]	n/a	reranker
B5	[ ]	[ ]	[ ]	[ ]	[ ]	grounding

11.3 통계 결과 문장 템플릿

> "RQ[ ]에서 [condition A]의 [primary metric]은 [mean/median] = [ ] (95% CI [,])였고, [condition B]는 [ ] (95% CI [,])였다. paired difference는 [ ] (effect size [ ])이며 Holm 보정 후 p = [ ]이다. 따라서 [가설 채택/기각/불확정]으로 판단한다. 이 결과는 [simulated/pilot] 조건에서만 관찰되었으며, [주요 제한]이 있다."

11.4 오류 taxonomy 입력

검색 실패 [ ]건, memory extraction [ ]건, wrong-context retrieval [ ]건, exhibition freshness [ ]건, unsupported claim [ ]건, explanation evidence mismatch [ ]건. 각 사례에는 query_id, stage, expected, observed, root cause, correction을 연결한다.

12. Discussion 입력 템플릿

12.1 결과 해석

RQ1: B4가 B1보다 [ ]만큼 [높음/낮음]을 보였다. 이는 [메모리의 어떤 요소]가 현재 발화만 사용하는 조건과 달리 [현상]을 포착했기 때문으로 해석할 수 있다. 다만 [simulator/pilot] 특성과 [코퍼스 범위] 때문에 일반화는 제한된다.
RQ2: B4의 CR@10은 [ ]이고 T_rec은 [ ]였다. B2/B3 대비 [ ]의 차이는 [cluster/router/Session Node]의 역할과 관련된다. 구성요소별 ablation이 없으면 이 문장은 memory block 전체의 효과로만 제한한다.
RQ3: B4R의 NDCG@5와 MRR 변화는 [ ]이다. 후보 집합을 고정했는지, reranker가 [zero-shot/fine-tuned]인지에 따라 해석을 달리한다.
RQ4: B5의 Availability@10과 UCR은 [ ]이다. 작품-전시 매칭이 아니라 전시 단위 확인을 측정했다면 '작품이 실제 전시 중'이라는 표현은 사용하지 않는다.
RQ5: E1의 faithfulness는 [ ]이다. 이 결과는 evidence visibility와 prompt constraint의 효과이며, 검색 품질 향상으로 해석하지 않는다.

12.2 한계와 위협

- 합성 대화는 상대 비교에는 유용하지만 실제 관람객의 미묘한 감정과 질문 개방성을 완전히 대표하지 않는다.
- 20명 파일럿은 외적 타당성의 방향성 확인에 그치며, 사용성·방문 행동의 일반 효과를 주장하지 않는다.
- Getty AAT와 기관 해설문은 어휘·문화 편향을 가질 수 있다. 한국어 감각어 사전의 구축 절차와 long-tail 노출을 따로 평가한다.
- API availability는 실제 방문의 대리 지표다. 입장, 이동, 운영시간, 현장 폐쇄까지 보장하지 않는다.
- 메모리에는 동의 범위, 보존 기간, 열람·수정·삭제 경로가 필요하며, 원문 정서 상태의 장기 저장을 피한다.

12.3 결론 템플릿

본 연구는 [실험 조건]에서 ARTHÉMIS의 [확인된 효과]를 관찰했다. 그러나 [미확인 범위]에 대해서는 결론을 유보한다. 핵심 기여는 단일 총점이 아니라 memory lifecycle, retrieval, grounding, explanation의 실패 경로를 분리하고 감사 가능한 근거와 함께 보고하는 평가 프레임워크에 있다. 후속 연구에서는 [B4 내부 ablation], [다기관 코퍼스], [실관람 longitudinal study]를 수행한다.

13. 최종 제출 체크리스트와 외부 보완 장부

제출 전 필수 체크리스트

확인	완료 조건
[ ]	초록/결론의 목표값과 실측값을 구분하고, 미측정 항목을 TBD로 표시
[ ]	CR@K 식과 분모 수정; contamination과 purity를 구분
[ ]	B4R-B5 동일 후보 paired grounding 설계 확정
[ ]	작품/전시/recommendation card 평가 단위와 Availability 정의 확정
[ ]	B4 내부 cluster/router ablation 또는 주장의 범위 축소
[ ]	Golden Set 라벨 정책, acceptable alternatives, 평가자 합의도 공개
[ ]	코퍼스·API snapshot·모델 checkpoint·seed·코드 commit 기록
[ ]	UCR claim unit, CACHED freshness, UNVERIFIED 출력 제약 검증
[ ]	참고문헌 [1]-[28]의 DOI/arXiv/proceedings와 본문 인용 일치 검토
[ ]	한글/영문 제목, 저자·소속·이메일 placeholder 제거

외부 보완 장부

구분	현 문서에서 확인	외부/실험으로 보완할 것
문헌	수정본 [1]-[28], 원본 내부자료 [9]-[11]	공식 출판 페이지/DOI/arXiv 상태, 저자·쪽수·연도 확인
데이터	MMCA, 문화포털, The Met, Harvard 후보	사용 승인, 수집일, snapshot checksum, 결측과 중복
평가	300 sessions, pilot 20명은 계획	실제 생성 로그, 참여자 수, IRB/면제, 동의와 철회 기록
모델	BGE-M3, SigLIP 2, DINOv2, BM25, CE 후보	정확한 checkpoint, 언어, tokenizer, hardware, latency
운영	VERIFIED/CACHED/UNVERIFIED 정책	실패·지연·캐시 적중·오류 claim 감사 로그

최종 편집 결론

현재 문서에서 가장 빠르게 심사 통과 가능성을 높이는 작업은 문장을 더 화려하게 만드는 것이 아니라, (1) 식과 평가 단위를 바로잡고, (2) 동일 후보 paired ablation을 고정하고, (3) 실측 결과가 없는 문장을 설계 문장으로 낮추며, (4) 재현성 부록과 서지 검증을 채우는 것이다. 이 네 가지가 완료되면 수정본의 설계적 강점이 실제 연구 기여로 전환된다.

문서 근거 인용 표기: 원본 p.1-12, 수정본 p.1-8. 본 보고서의 수정 권고와 템플릿은 심사자의 방법론적 보완 제안이며, 원문 실험 결과가 아니다.