Arthémis: 장기 미학 대화 메모리와 2층 전시 그라운딩 기반의 대화형 아트 큐레이션 시스템

Memory-Augmented Conversational Art Recommendation with Space-Separated Multimodal Retrieval and Exhibition Grounding

추병곤
모두의연구소 AIFFEL 리서치 18기 · 365챌린지
[email]

[팀원 이름]
[소속]
[email]

Abstract

미술관 아카이브는 작가·연도·재료 같은 전문 메타데이터로 조직되어 있지만, 관람객은 "마음이 가라앉는 거친 질감의 추상화"처럼 감각과 정서의 언어로 말한다. 기존 대화형 추천 시스템(*CRS*)은 이 의미 간극을 부분적으로 해소하나, 세션이 끝나면 취향이 소멸하고, 한 사람 안의 복수 감상 맥락(혼자의 사유형 관람과 가족 체험형 관람)을 구분하지 못하며, 실제로 관람할 수 없는 작품이나 존재하지 않는 전시 일정을 추천한다. 본 연구는 이 세 결함을 동시에 다루는 *Arthémis*를 제안한다. *Arthémis*는 (*i*) 근거 발화를 보존하는 *Aesthetic Session Node*와 이를 편입·연결·창발·감쇠 규칙으로 조직하는 *Curatorial Taste Cluster*, 그리고 질의 시점의 맥락에 맞는 클러스터만 활성화하는 맥락 라우터로 이루어진 계층형 미학 메모리, (*ii*) 서로 다른 임베딩 공간(텍스트·텍스트–이미지·이미지–이미지·어휘)을 합산하지 않고 인덱스를 분리한 뒤 순위를 융합하는 멀티모달 검색, (*iii*) 작품 층(발견)과 전시 층(실행)을 분리하고 공공 전시 *API*로 확인된 정보만 신선도 상태와 함께 안내하는 *2*층 그라운딩으로 구성된다. 각 모듈의 기여를 분리하기 위해, 인접 단계가 정확히 한 모듈만 다른 절제 사다리(*B0*–*B5*)와 *AlpsBench*의 메모리 생명주기(추출→갱신→검색→활용)를 예술 도메인으로 확장한 평가 프로토콜을 설계한다. 본 중간 보고서는 문제 정의, 평가 설계, 기술적 접근을 기술하며, 실험 결과는 최종 보고서에서 보고한다.

1 서론

공공 미술관과 온라인 예술 플랫폼은 방대한 소장품을 공개하고 있지만, 그 접근 인터페이스는 여전히 전문 연구자의 질의 방식에 맞춰져 있다. 검색 가능한 필드는 작가명, 작품명, 제작 연도, 재료, 사조이며, 이는 미술사적 어휘를 이미 갖춘 사용자를 전제한다. 그러나 일반 관람객의 요구는 대개 감각적이고 상황적이다. "요즘 머리가 복잡해서, 색이 요란하지 않고 표면의 물질감이 묵직한 그림 앞에 가만히 있고 싶다"는 발화에는 작가명도 사조명도 없다. 키워드 검색은 이 질의에 대해 결과를 내지 못하거나 누구나 아는 대표작을 나열하고, 그 결과 관람 탐색의 포기와 블록버스터 전시로의 쏠림이 강화된다.

대형 언어 모델(LLM) 기반 CRS [8, 13]는 자연어 대화로 선호를 끌어내어 이 간극을 좁힐 수 있다. 그러나 예술 감상이라는 도메인에서는 세 가지 구조적 결함이 드러난다.

(1) 의미 간극의 이중성. 감각어를 조형 어휘로 옮기는 언어적 번역("거친 질감"→마티에르·임파스토)과, 텍스트로 환원되지 않는 필치·표면·농담을 이미지에서 직접 찾는 시각적 번역이 모두 필요하다. 이미지–텍스트 정렬 모델(CLIP 계열)은 "무엇이 그려졌는가"에 강하지만 국소적 질감에는 약하고, 자기지도 시각 모델(DINOv2)은 그 반대의 성향을 보인다 [15].

(2) 기억의 휘발과 맥락 혼선. 현행 대화 시스템은 세션을 독립 사건으로 취급하여 사용자가 자신의 감상 이력을 매번 재설명하게 한다. 장기 메모리를 도입하더라도 모든 기억을 하나의 프로필로 합치면, 평일 저녁의 명상적 관람 취향이 주말 가족 나들이 추천을 오염시킨다. 나아가 AlpsBench [24]는 메모리 시스템이 페르소나 인식은 높이지만 허구·실제 정보 구분과 정서적 적절성은 오히려 떨어뜨리는 개인화 편향을 보고하였다. 기억은 많을수록 좋은 것이 아니라 선택적으로 쓰여야 한다.

(3) 실행 불가능한 추천. 소장품의 상당수는 상시 전시되지 않으며, 범용 LLM은 전시명·기간·전시실을 그럴듯하게 생성한다. 추천이 실제 관람으로 이어지려면 공공 전시 정보와의 그라운딩이 필요하지만, 공개 전시 API는 일반적으로 전시 단위이며 개별 작품의 현재 전시 여부를 제공하지 않는다.

본 연구의 기여는 다음과 같다.

- **C1. 계층형 미학 메모리.** 근거 발화(evidence span)를 보존하는 Session Node와, 이를 편입·연결·창발(잠정 확정)·감쇠 규칙으로 조직하는 Taste Cluster, 그리고 활성 클러스터를 선택하는 맥락 라우터(§4.3).
- **C2. 공간 분리 멀티모달 검색과 2층 그라운딩.** 서

로 다른 임베딩 공간의 벡터를 합산하지 않고 텍스트(T)·텍스트–이미지(X)·이미지–이미지(V)·어휘(L) 인덱스의 순위를 융합하며(§4.4), 작품 층과 전시 층을 분리해 확인된 정보만 신선도 상태와 함께 안내한다(§4.5).

- **C3. 예술 도메인 메모리 생명주기 평가 프로토콜.** AlpsBench의 4단계 과업을 취향 전환 회복, 맥락 오염, 관람 가능성, 큐레이토리얼 충실성으로 확장하고, 인접 단계가 정확히 한 모듈만 다른 절제 사다리로 모듈별 기여를 귀속한다(§3).

2 관련 연구

LLM 기반 대화형 추천. RecLLM [8]은 단일 LLM이 대화 관리, 대규모 코퍼스 검색, 사용자가 읽고 고칠 수 있는 자연어 프로필, 통제 가능한 사용자 시뮬레이터를 담당하는 구조를 제시했다. CSI [16]는 매 턴 맥락 프로필을 갱신하고 선호 탐색·범주 좁히기·제안·설득을 하나의 행동 공간에서 선택하며, 실제 리뷰 데이터로부터 성격 특성과 구매 이유를 추출한 시뮬레이터(CSUser)를 함께 제안했다. 본 연구는 CSI의 프로필 기반 행동 선택과 선제 질문 구조 [2]를 차용하되, 예산 초과 구매를 유도하는 설득 목표를 제거하고 감상 심화 질문으로 대체한다. 두 연구 모두 단일 대화 내 프로필에 머물며, 다회차 세션에 걸친 취향의 계층 구조와 맥락 분리는 다루지 않는다.

에이전트 메모리. A-MEM [25]은 제텔카스텐 원리에 따라 새 기억이 기존 노트와 링크를 형성하고 기존 노트의 기술을 갱신하는 기억 진화 메커니즘을 제안했다. Mem0 [5] 등은 대화에서 사실을 추출해 지속 저장소로 관리한다. 이들은 범용 사실 기억을 대상으로 하여, 감상 동기·조형 선호·방문 맥락과 같은 예술 도메인 스키마와 맥락별 선택적 활성화를 제공하지 않는다. 본 연구의 Session Node→Taste Cluster는 A-MEM의 노트–링크–진화를 취향 단위로 추상화하고, 여기에 잠정 상태와 라우팅을 추가한 것이다.

개인화 메모리 평가. LoCoMo [17]와 LongMemEval [23]은 장기 대화 기억을 평가하지만 합성 대화에 의존한다. AlpsBench [24]는 실제 사용자–LLM 대화 2,500건과 사람이 검수한 구조화 기억으로 추출·갱신·검색·활용의 4과업을 정의했고, 암묵적 선호의 추출 재현율이 명시적 선호보다 일관되게 낮으며 최고 모델의 추출 F1도 0.67 수준에 머문다고 보고했다. 본 연구는 이 4단계 틀을 채택하되, 예술 도메인에 고유한 취향 전환·맥락 오염·관람 가능성 지표를 추가한다.

예술 이해와 시각 표현. SemArt [9]는 회화와 해설문 사이의 교차 모달 검색을, ArtEmis [1]는 작품에 대한 정서 반응과 그 이유를 기술한 대규모 언어 자료를 제시했다. 이들은 정적 검색·생성 과업이며 대화형 장기 개인화와 실제 관람 연결은 다루지 않는다. 시각 인코더 측면에서 COMM [15]은 CLIP [20]의 얕은 층과 DINOv2 [19]가 국소 형태·질감 정보를 더 많이 담고, 두 인코더의 결합이 세밀 지각을 향상시킴을 MLLM 맥락에서 보였다. 본 연구는 이를 검색 인덱스의 역할 분담 근거로 사용한다. 또한 Event-MLLM [27]은 극단적 밝기 조건(0.05×–20×)에서 비전 인코더 특징의 코사인 유사도가 0.65 수준까지 하락함을 보고했으며, 우리는 이를 작품 사진의 촬영 조건 편차에 대한 강건성 점검의 동기로만 제한적으로 참조한다.

3 문제 정의

3.1 과업 정식화

사용자 u는 시간에 따라 세션 $\mathcal{S}_u = (S^{(1)}, \ldots, S^{(M)})$를 가지며, 각 세션 $S^{(m)}$은 발화 열 $(x_1, y_1, \ldots, x_T, y_T)$로 이루어진다. 작품 코퍼스 $\mathcal{A} = \{a_j\}$의 각 작품은 텍스트 a^{txt}(큐레이토리얼 해설, 정형 메타데이터, AAT 태그)와 이미지 a^{img}(원 기관 링크)를 갖는다. 시점 t에 열려 있는 전시 집합을 $\mathcal{E}(t)$라 한다.

시스템은 세션 간 지속 메모리 $\mathcal{M}_u$를 유지하며, 각 턴에서 다음을 산출한다.

$$\big(\alpha_t,\ R_t,\ G_t,\ y_t\big) = \pi\big(x_{\le t},\ y_{<t},\ \mathcal{M}_u,\ \mathcal{A},\ \mathcal{E}(t)\big), \quad (1)$$

여기서 α_t는 행동(질문·범주 좁히기·작품 제안·전시 안내·감상 심화 질문), $R_t \subset \mathcal{A}$는 순위화된 상위 K개 작품, G_t는 각 추천에 대응하는 전시 그라운딩 레코드와 신선도 상태, y_t는 근거 기반 응답이다. 세션 종료 시 쓰기 함수 $\mathcal{M}_u \leftarrow \textsc{Write}(\mathcal{M}_u, S^{(m)})$가 메모리를 갱신한다.

이 정식화는 세 가지 요구를 동시에 부과한다. (a) R_t는 현재 발화뿐 아니라 현재 맥락에 해당하는 장기 취향과 정합해야 하며 다른 맥락의 취향에 오염되어서는 안 된다. (b) 사용자의 관심이 이동하면 이전 취향을 삭제하지 않고 새 취향으로 빠르게 적응해야 한다. (c) y_t에 포함된 모든 일정·장소 주장은 G_t의 확인된 레코드로 뒷받침되어야 한다.

3.2 데이터

작품·전시 코퍼스. 국립현대미술관 소장품 메타데이터와 해설문을 핵심 코퍼스로 하고, 문화포털 공연·전시 정보 API를 전시 층 그라운딩에 사용한다. 시각 인덱스 보강과 비교군으로 The Met Open Access(CC0 작품)와 Harvard Art Museums API(키 발급·일일 한도)를 사용하며, 감각어–조형어 매핑 사전은 Getty AAT [10]의 계층 시소러스에 한국어 대응어를 자체 구축해 만든다. 기관별 공개 범위와 이용 조건은 1주차에 확정하며, 근현대 작품의 저작권을 고려해 원본 이미지는 저장·재배포하지 않고 임베딩과 원 기관 링크만 보관한다.

대화 데이터. 실제 관람객의 다회차 대화 로그는 공개된 것이 없으므로 통제된 페르소나 시뮬레이션을 주 평가 자원으로 삼는다(표 1). 3개 유형 × 유형별 변형 10개 × 사용자당 10세션으로 총 300세션을 생성한다. AlpsBench가 지적한 합성 대화의 과도한 명시성을 피하기 위해 암묵적 선호 표현 비율을 *40%* 이상으로 통제하고, 대화 생성·신

유형	시나리오	검증 대상
A 정서적 발견형	사조 어휘 없이 정서·감각으로만 질의, 5턴 안에 단색조·물질성 취향으로 수렴	세션 내 수렴, 암묵 신호 추출
B 다중 맥락형	본인 연구(미디어아트)와 자녀 체험형 전시를 교차 질의	라우팅 정확도, 오염률
C 취향 전환형	구상 회화 → 4세션 이후 미디어·키네틱 설치로 전환	회복 턴 수, 구 취향 보존

표 1: 페르소나 설계. 각 유형은 연령·어휘 수준·발화 개방성(CSI의 dialogue openness [16])을 달리한 10개 변형을 갖는다.

ID	구성 (직전 단계 대비 추가 모듈)	RQ
B0	BM25 메타데이터 검색, 메모리 없음	–
B1	멀티모달 검색(T·X·L RRF), 현재 발화만	–
B2	B1 + 과거 대화 전체 이어붙이기	RQ2
B3	B1 + Session Node 요약(클러스터 없음)	RQ2
B4	B3 + Taste Cluster + 맥락 라우터	RQ1, 2
B4R	B4 + Cross-Encoder 재순위화	RQ3
B5	**B4R + 2층 전시 그라운딩 (제안)**	RQ4
B5-E0/E1	B5 고정, 설명 생성: 자유(E0) ↔ 근거 인용(E1)	RQ5
Oracle	정답 프로필 + 정답 관련 작품 집합	–

표 2: 절제 사다리. V(DINOv2) 인덱스의 추가 기여는 B1에 대한 별도 절제로 측정한다.

호 추출·판정에 서로 다른 계열의 모델을 배정한다. 정답 프로필과 전환 시점은 큐레이터 2인이 검수한다. 시뮬레이션 결과의 외적 타당성은 사전 동의·익명화를 거친 실관람객 파일럿(목표 20명)으로 교차 확인한다.

3.3 절제 사다리와 연구 질문

각 모듈의 기여를 인과적으로 귀속하기 위해, 주 사슬 B1 → B3 → B4 → B4R → B5의 인접 단계가 정확히 한 모듈만 다르도록 비교군을 설계한다(표 2). B2는 구조 없는 전체 이력 누적의 대조군이며, 설명 생성 방식은 검색·그라운딩 결과를 고정한 채 교체하는 직교 절제(B5-E0/E1)로 분리한다.

- **RQ1** (장기 메모리) B1 vs B4: 메모리가 개인화 순위 품질을 높이는가.
- **RQ2** (구조화) B2, B3 vs B4: 클러스터와 라우터가 전체 누적·단일 요약보다 전환 적응을 빠르게 하고 맥락 오염을 줄이는가.
- **RQ3** (재순위화) B4 vs B4R: 2단계 재순위화가 상위 순위 품질을 높이는가.
- **RQ4** (그라운딩) B4R vs B5: API 검증이 관람 가능 정밀도를 높이고 미검증 주장을 제거하는가.
- **RQ5** (근거 설명) B5-E0 vs B5-E1: 근거 발화를 인용한 설명이 충실성과 수용도를 높이는가.

3.4 평가 지표

메모리 생명주기. AlpsBench의 과업 정의를 따라 추출은 정답 프로필 대비 의미 매칭 F1을 명시·암묵 신호로 분리해 보고하고, 갱신은 Keep/Add/Revise/Suppress 4범주 분류 정확도로 측정한다.

순위 품질. 큐레이터가 부여한 등급 $g \in \{0,1,2,3\}$(무관 / 사조 일치 / 조형·정서 일치 / 맥락·실행까지 일치)로 NDCG@K [14]를 계산한다.

$$\mathrm{NDCG@}K = \frac{1}{\mathrm{IDCG@}K} \sum_{i=1}^{K} \frac{2^{g_i} - 1}{\log_2(i+1)}. \qquad (2)$$

정답 라벨링은 전 코퍼스가 아닌 풀링 방식으로, 모든 비교군의 상위 10개 합집합에 대해서만 수행한다. 1차 검색의 후보 포착력은 Recall@50, 최상위 적합 작품의 위치는 MRR로 측정한다.

취향 전환과 맥락 오염. 사용자의 맥락 c와 그 밖의 맥락 집합 $\bar{c}$에 대해, 추천 목록 R_K 중 다른 맥락의 정답 집합에만 속하는 작품의 비율을 오염률로 정의한다.

$$\mathrm{CR@}K = \frac{1}{K} \left| \{ a \in R_K : a \in \mathcal{G}_{\bar{c}} \setminus \mathcal{G}_c \} \right|. \qquad (3)$$

페르소나 C의 전환 시점 t_s 이후, 오염률이 0.10 이하로 떨어지고 새 취향의 Recall@10이 Oracle 대비 90%에 도달하기까지의 대화 턴 수를 회복 턴 수 T_{rec}로 정의한다.

그라운딩. Availability@K는 상위 K개 추천 중 확인 시점에 실제 관람 가능한 전시와 연결된 비율이다. 미검증 주장률(UCR)은 응답에 포함된 일정·장소·요금 주장 중 VERIFIED 또는 기준일이 명시된 CACHED 레코드로 뒷받침되지 않는 주장의 비율이며, 감사 표본에서 0건을 목표로 한다.

생성 품질. 외부 큐레이터 2인이 블라인드로 미학적 충실성, 설명 설득력, 접근성 타당성, 세렌디피티를 5점 척도로 평가한다. 순서 척도이므로 평가자 간 신뢰도는 Krippendorff's α [11]로 보고하며($\alpha \geq 0.67$), 본 논문의 저자는 평가자에서 제외한다. LLM 판정 [28]은 후보 순서를 무작위화하고 큐레이터 표본과의 일치율을 먼저 측정한 뒤, 일치율이 낮은 항목은 사람 평가만 인정한다.

시뮬레이터 신뢰도. CSI는 프로필이 단순한 시뮬레이터일수록 수락률은 오르고 실제 목표와의 정합도는 떨어지는, 즉 과도하게 수용적인 시뮬레이터가 됨을 보였다 [16]. 이에 따라 시뮬레이터의 수락/거절 판단과 파일럿 참여자 판단의 일치율을 별도로 보고하고, 시뮬레이션 결과는 비교군 간 상대 비교로만 해석한다.

단계	지표	초기 목표
추출	F1 (명시 / 암묵)	≥ 0.75 / ≥ 0.50
갱신	4범주 정확도	≥ 0.80
검색	NDCG@10: B4 vs B2	95% CI > 0
전환	T_{rec}, CR@10	≤ 3턴, ≤ 0.10
재순위	NDCG@5, MRR: B4R vs B4	95% CI > 0
그라운딩	Availability@10 / UCR	B5 $>$ B4R / 0건
생성	큐레이터 α	≥ 0.67
운영	응답 p95 / 첫 토큰	$\leq$ 6s / $\leq$ 1.5s

표 3: 지표별 초기 목표. 임계값과 목표는 개발 세트에서 보정하며 변경 시 사유를 기록한다.

통계. 모든 비교는 동일 사용자·동일 시드의 짝지은 설계이며, paired bootstrap [7] 95% 신뢰구간과 효과 크기를 보고한다. 순위 지표는 permutation test를 병행하고, 5개 RQ에 걸친 다중 비교는 Holm 보정 [12]한다. 결과는 부정적이더라도 그대로 보고한다.

3.5 기대 결과

표 3는 사전 등록 성격의 초기 목표치이다. 추출 목표는 명시·암묵을 분리한다. AlpsBench의 실대화 벤치마크에서 최고 모델의 추출 F1이 0.674였고 암묵 신호 재현율이 크게 낮았다는 점을 고려하여, 스키마가 고정된 좁은 도메인이라는 이점을 반영하되 암묵 신호 목표는 보수적으로 설정했다.

4 기술적 접근

4.1 개요

그림 1는 Arthémis의 파이프라인이다. 발화가 들어오면 ① 미학 신호 추출기가 명시·암묵 신호와 근거 발화를 분리하고, ② 메모리 엔진의 라우터가 활성 취향 클러스터를 골라 활성 프로필을 구성하며, ③ 공간 분리 검색이 후보 50개를 뽑아 재순위화로 10개를 선택하고, ④ 그라운딩 도구가 전시 층과 연결하며, ⑤ 생성기가 근거를 인용한 설명과 다음 질문을 만든다. 세션 종료 시 대화는 새 Session Node로 기록되어 클러스터 구조에 편입된다. 대화 정책은 ReAct [26] 형식을 따라 매 턴 프로필 갱신→사고→행동 선택을 수행하며, 프로필 불확실성이 높으면 추천보다 큐레이토리얼 질문을 우선한다.

4.2 미학 신호 추출

추출기는 발화로부터 슬롯 구조의 신호를 만든다. 명시 신호는 작가, 매체, 지역, 방문 시간대, 동행 여부이고, 암묵 신호는 감상 동기(사유·회복·학습·체험), 조형 선호(색조, 질감, 여백, 스케일), 기피 조건, 해석 난이도 수용성이다. 각 신호는 근거 발화의 턴 번호와 원문 구간을 반드시 동반하며, 근거가 없는 추론은 신뢰도를 낮추어 `tentative`로만 기록한다. 감각어는 Getty AAT 기반 한–영 매핑 사전으로 조형 어휘 후보에 연결된다 (예: "거친 질감"→*impasto*, *matière*, 텍스처 계열 개념). 정서 상태의 원문(예: "번아웃")은 저장하지 않고 감상 목적 수준(`restoration`)으로 추상화하며, 저장 범위는 `consent_scope` 필드로 관리한다.

4.3 계층형 미학 메모리

Session Node. 세션 종료 시 LLM은 세션을 노드 $n_i = (\text{summary}_i, \text{intent}_i, \text{visit}_i, e_i, z_i, s_i, \text{status}_i)$로 구조화한다. 여기서 e_i는 근거 발화, $z_i = f_T(\text{summary}_i \oplus \text{AAT}_i)$는 텍스트 임베딩(BGE-M3 [4]), $s_i \in [0,1]$는 명시적 만족도이다. 노드의 가중치는 최신성과 만족도로 정한다.

$$w_i = \exp(-\lambda\,\Delta t_i)\,(0.5 + 0.5\,s_i), \qquad \lambda = \ln 2/h, \quad (4)$$

반감기 h의 초기값은 30일이다.

Taste Cluster. 클러스터 k는 멤버 노드 집합 $\mathcal{N}_k$, 가중 중심 $\mu_k = \text{norm}\big(\sum_{i\in\mathcal{N}_k} w_i z_i\big)$, 총 가중치 $W_k = \sum_i w_i$, 확신도 γ_k, LLM이 합성한 기술문, 다른 클러스터로의 다리 관계를 갖는다. 새 노드 z_{new}에 대해 $\sigma_k = \cos(z_{\text{new}}, \mu_k)$와 $k^\dagger = \arg\max_k \sigma_k$를 구하고 다음과 같이 판정한다.

$$\text{판정} = \begin{cases} \textsc{Merge}(k^\dagger) & \sigma_{k^\dagger} \geq \tau_m \\ \textsc{Bridge}(k^\dagger) & \tau_s \leq \sigma_{k^\dagger} < \tau_m \\ \textsc{Genesis} & \sigma_{k^\dagger} < \tau_s \end{cases} \quad (5)$$

초기값은 $\tau_m = 0.78$, $\tau_s = 0.50$이나, 유사도 분포는 임베딩 모델마다 달라 이 값은 이식되지 않는다. 따라서 개발용 페르소나 세션에서 편입/분리 정답을 라벨링해 판정 F1을 최대화하는 값으로 보정하고, 경계 대역 $|\sigma - \tau| < \delta$에서는 A-MEM과 같이 LLM이 링크 여부를 판단한다. 민감도 분석 결과를 함께 보고한다. Bridge로 판정된 노드는 기존 클러스터의 중심을 끌어당기지 않도록 편입하지 않고, 기존 클러스터와 다리 관계로 연결된 잠정 클러스터의 씨앗이 된다. 즉 Bridge와 Genesis는 모두 새 잠정 클러스터를 만들지만, 전자는 인접 취향과의 관계를 보존하여 전환 경로(예: 구상 회화 → 서사적 미디어 설치)를 추적 가능하게 한다.

잠정 확정과 감쇠. Genesis로 생긴 클러스터는 확신도 $\gamma = 0.35$의 `tentative` 상태로 시작하고, 이후 서로 다른 세션에서 2회 이상 Merge될 때 `active`로 확정된다. 이는 일시적 기분 변화와 실제 취향 전환을 구분하기 위한 장치이다. 기존 클러스터는 삭제하지 않고 W_k가 임계값 아래로 떨어지면 `stale`로 전이되며, 사용자가 명시적으로 부정한 선호는 `suppressed`로 표시되어 검색에서 제외된다. 메모리 갱신 행동은 AlpsBench의 Retention/Addition/Modification에 Suppress를 더한 Keep/Add/Revise/Suppress 4범주로 기록되어 갱신 정확도 평가의 단위가 된다(알고리즘 1).

맥락 라우터. 검색 시 모든 클러스터를 평균하지 않는다. 현재 질의 임베딩 q_t와 추출된 맥락 슬롯(동행, 목적, 시간대) $\mathbf{c}_t$로 클러스터 활성 확률을 계산한다.

$$p(k \mid x_t) \propto \exp\big(\eta\,\cos(q_t, \mu_k) + b_k(\mathbf{c}_t)\big), \quad (6)$$

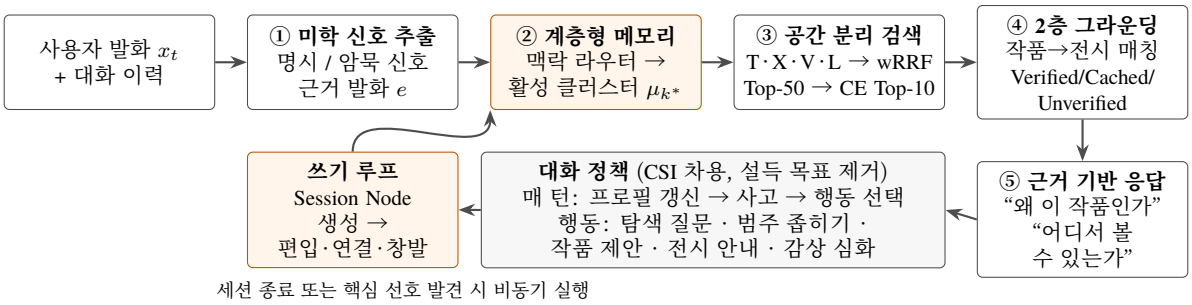


그림 1: ARTHÉMIS 파이프라인. 메모리 관련 구성요소(주황)는 C1, 검색·그라운딩(③④)은 C2에 해당한다.

알고리즘 1 WRITE: 세션 종료 시 메모리 갱신

입력: 메모리 $\mathcal{M}_u$, 세션 S, 임계값 τ_m, τ_s, δ

$n \leftarrow \textsc{Structure}(S)$ ▷ 요약·의도·방문 맥락·근거 발화
$z \leftarrow f_T(n.\text{summary} \oplus n.\text{AAT})$
$k^\dagger \leftarrow \arg\max_k \cos(z, \mu_k)$; $\sigma \leftarrow \cos(z, \mu_{k^\dagger})$
if $|\sigma - \tau_m| < \delta$ **or** $|\sigma - \tau_s| < \delta$ **then**
  op $\leftarrow \text{LLMJudge}(n, k^\dagger)$ ▷ 경계 대역
else
  op $\leftarrow \textsc{Rule}(\sigma; \tau_m, \tau_s)$
end if
if op $=$ MERGE **then**
  $\mathcal{N}_{k^\dagger} \leftarrow \mathcal{N}_{k^\dagger} \cup \{n\}$; 중심·기술문 갱신
  if $k^\dagger$ tentative **and** 재관찰 ≥ 2 **then** active
else if op $=$ BRIDGE **then**
  신규 tentative 클러스터 생성, $k^\dagger$와 다리 관계 기록
else
  신규 클러스터 생성 ($\gamma = 0.35$, tentative)
end if
모든 k: W_k 재계산, $W_k < \epsilon \Rightarrow$ stale
명시적 부정 선호 $\Rightarrow$ suppressed
return $\mathcal{M}_u$, 갱신 행동 로그 (Keep/Add/Revise/Suppress)

b_k는 클러스터에 기록된 방문 맥락과 현재 슬롯의 일치도이다. $\max_k p < \rho$이면 추천 전에 한 번의 확인 질문("누구와 가시나요?")을 수행하고 [2], 그래도 불확실하면 상위 두 클러스터에서 추천 슬롯을 나누어 사용자 반응으로 판정한다. 활성 프로필은 $v_t = \text{norm}(\beta q_t + (1-\beta)\mu_{k^*})$, $\beta = 0.7$이며, 현재 발화의 명시적 요구는 기억보다 우선한다. 이 규칙은 AlpsBench가 보고한 기억 과의존형 개인화 편향을 완화하기 위한 것이다.

4.4 공간 분리 멀티모달 검색

원안의 $E_{\text{art}} = \alpha E_{\text{text}} + (1-\alpha) E_{\text{vis}}$는 서로 다른 학습 목표로 얻은 다른 공간의 벡터를 합산하므로 폐기한다. 대신 네 개의 인덱스를 두고 질의를 각 공간의 인코더로 따로 부호화한다.

- **T** (BGE-M3): 해설문+AAT 태그. 질의는 v_t.
- **X** (다국어 CLIP 계열, 예: SigLIP 2 [22]): 작품 이미지. 질의는 발화와 활성 클러스터 키워드의 텍스트 타워 임베딩.
- **V** (DINOv2 [19]): 작품 이미지. 질의는 대화에서 언급된 기준 작품의 이미지("방금 그 작품과 비슷한 표면").
- **L** (BM25 [21]): 작가·기관·재료 고유명사와 AAT 확장어.

질의 유형 분류기가 {고유명사형, 감각 기술형, 시각 기준형, 혼합형}을 판정하고, 유형별 가중을 둔 가중 RRF [6]로 후보 50개를 만든다.

$$\text{score}(a) = \sum_{r \in \{T,X,V,L\}} \frac{\omega_r(\text{type}(x_t))}{\kappa + \text{rank}_r(a)}, \quad \kappa = 60. \tag{7}$$

V 인덱스는 기준 작품이 있을 때만 활성화된다. 이어서 다국어 크로스 인코더 [18]가 [활성 프로필; x_t; a^{txt}] 쌍을 채점하여 상위 10개를 고른다. 필터버블과 주류 편향을 완화하기 위해 10개 중 2개는 노출 빈도 하위 50% 작가 집합에서 MMR [3]로 선택하는 탐색 슬롯으로 고정하고, 롱테일 노출률을 별도 지표로 기록한다.

시각 인덱스의 정규화와 강건성. 작품 사진은 액자·배경을 크롭하고 색 정규화를 거친다. 촬영 조건 편차에 대한 강건성은 밝기·색온도 변형을 가한 질의 이미지에 대해 V 인덱스의 Recall@10 변화를 측정하는 방식으로 점검한다. 극단적 밝기에서 비전 인코더 특징이 크게 이동한다는 보고 [27]는 주행 영상에서의 결과이므로, 이 점검은 미술관 촬영 조건에 맞춘 완만한 변형 범위에서 수행한다.

4.5 2층 전시 그라운딩

공공 전시 API가 전시 단위라는 제약에 맞추어 약속의 단위를 바꾼다. 작품 층은 취향을 구체화하고 설명하는 데 쓰고, 전시 층은 "이 취향에 맞는 전시가 지금 열려 있다"를 보장한다. 작품 a와 전시 $e \in \mathcal{E}(t)$의 정합도는

$$m(a,e) = \lambda_1 \mathbb{I}[\text{artist}(a) \in e] + \lambda_2 \cos\big(f_T(a), f_T(e)\big) + \lambda_3 J(\text{tag}_a, \text{tag}_e) \tag{8}$$

주차	산출물 / 통과 기준	미달 시 조정
W1 9/23–	코퍼스·API 어댑터, T·L 인덱스 / 500건 수동 점검	MMCA 단일 기관
W2 9/30–	추출기, Session Node, B0·B1 / 추출 F1 목표	암묵 범주 축소
W3 10/7–	클러스터·라우터, 시뮬레이터 300세션 / $T_{\text{rec}} \leq 3$	규칙 기반 고정
W4 10/14–	X(·V) 인덱스, RRF, 재순위, 그라운딩 / 도구 호출 정확도 ≥ 0.90	V 인덱스 옵션화
— 중간 논문 제출 *10/22*, 피드백 세션 이후 —		
W5 10/21–	B0–B5 통제 실험, 큐레이터 평가, 파일럿	결과 그대로 보고
W6 10/28–	데모 (Streamlit)·1분 영상·GitHub·최종 보고서	스트리밍·캐시 강화

표 4: 일정과 통과 기준. 최종 결과물 제출 마감은 11/6 16:00이다.

로 계산하며(J는 AAT 태그의 Jaccard 계수), 사용자의 방문 지역·시간대 제약을 필터로 적용한다. 상설전처럼 작품 단위 확인이 가능한 경우에만 "원작 전시 중"으로 표기한다.

모든 전시 레코드는 세 상태 중 하나를 갖는다. VERIFIED는 24시간 이내 API로 확인된 경우로 기간·장소·요금·예매 링크와 확인 시각을 안내한다. CACHED는 API 지연(>1.5초)·장애 시 직전 스냅샷으로, 기준일과 방문 전 확인 권고를 강제 표기한다. UNVERIFIED는 정합 전시가 없는 경우로, 일정·장소 생성을 금지하고 유사한 조형 언어의 다른 현재 전시로 대체 경로를 제시한다. 생성기는 이 상태 태그가 붙은 필드만 일정·장소 주장에 사용할 수 있도록 제약되며, 이 제약의 준수 여부가 UCR로 측정된다.

4.6 근거 기반 응답 생성

생성기는 추천마다 (i) 사용자의 원 발화를 인용한 연결("말씀하신 '묵직한 물질감'은 이 작품의 두꺼운 마티에르와 저채도 화면에 해당합니다"), (ii) 작품의 조형적 근거, (iii) 그라운딩 레코드에 기반한 관람 정보를 구조화된 필드로 받아 문장화한다. E0 조건은 동일한 검색·그라운딩 결과를 받되 근거 필드를 제거한 자유 생성이다. 사용자는 자연어 프로필을 열람·수정·삭제할 수 있으며 [8], 수정은 다음 세션의 Session Node에 반영된다.

5 구현 계획과 현황

표 4은 6주 일정과 주차별 통과 기준, 미달 시 범위 조정안이다. 연구의 핵심인 메모리(C1)와 평가(C3)를 우선 완성하고, 그라운딩은 단일 API로 시작하며, V 인덱스는 4주차 이후 여유에 따라 확장한다. 본 중간 보고서 시점의 진척은 [**TODO**: W1–W4 산출물, 추출 F1 예비 결과, 임계값 보정 결과를 제출 직전에 기입].

6 한계와 윤리적 고려

첫째, 주 평가가 시뮬레이션에 의존하므로 절대 성능이 아닌 비교군 간 상대 차이로 해석해야 하며, 파일럿 규모(20명)는 외적 타당성의 방향성 확인에 그친다. 둘째, Getty AAT와 기관 해설문은 서구·주류 미술사 중심의 어휘 편향을 가지며, 한국어 조형 어휘의 자체 구축과 롱테일 노출률 관리로 이를 부분적으로만 완화한다. 셋째, 6주 안에 실제 방문 행동을 측정하는 것은 불가능하므로 Availability와 파일럿 방문 의향을 대리 지표로 사용한다. 넷째, 정서 관련 기억은 동의 범위 안에서 추상화해 저장하고 사용자가 언제든 열람·수정·삭제할 수 있게 한다. 마지막으로 원본 작품 이미지는 저장·재배포하지 않으며, 임베딩 계산의 허용 범위는 기관과의 협의가 필요한 사항으로 남아 있다.

참고문헌

[1] Panos Achlioptas, Maks Ovsjanikov, Kilichbek Haydarov, Mohamed Elhoseiny, and Leonidas Guibas. ArtEmis: Affective language for visual art. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021. 2

[2] Mohammad Aliannejadi, Hamed Zamani, Fabio Crestani, and W. Bruce Croft. Asking clarifying questions in open-domain information-seeking conversations. In *Proceedings of the 42nd International ACM SIGIR Conference*, pages 475–484, 2019. 2, 5

[3] Jaime Carbonell and Jade Goldstein. The use of MMR, diversity-based reranking for reordering documents and producing summaries. In *Proceedings of the 21st International ACM SIGIR Conference*, pages 335–336, 1998. 5

[4] Jianlv Chen, Shitao Xiao, Peitian Zhang, Kun Luo, Defu Lian, and Zheng Liu. BGE M3-Embedding: Multilingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*, 2024. 4

[5] Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready AI agents with scalable long-term memory. *arXiv preprint arXiv:2504.19413*, 2025. 2

[6] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference*, pages 758–759, 2009. 5

[7] Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993. 4

[8] Luke Friedman, Sameer Ahuja, David Allen, Zhenning Tan, Hakim Sidahmed, Changbo Long, Jun Xie, Gabriel Schubiner, Ajay Patel, Harsh Lara, et al. Leveraging large language models in conversational recommender systems. *arXiv preprint arXiv:2305.07961*, 2023. 1, 2, 6

[9] Noa Garcia and George Vogiatzis. How to read paintings: Semantic art understanding with multi-modal retrieval. In *Proceedings of the European Conference on Computer Vision (ECCV) Workshops*, 2018. 2

[10] Getty Research Institute. Art & architecture thesaurus (AAT) online. https://www.getty.edu/research/tools/vocabularies/aat/. Linked Open Data, ODC-By. 2

[11] Andrew F. Hayes and Klaus Krippendorff. Answering the call for a standard reliability measure for coding data. *Communication Methods and Measures*, 1(1):77–89, 2007. 3

[12] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979. 4

[13] Dietmar Jannach, Ahtsham Manzoor, Wanling Cai, and Li Chen. A survey on conversational recommender systems. *ACM Computing Surveys*, 54(5):1–36, 2021. 1

[14] Kalervo Järvelin and Jaana Kekäläinen. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4):422–446, 2002. 3

[15] Dongsheng Jiang, Yuchen Liu, Songlin Liu, Jin'e Zhao, Hao Zhang, Zhen Gao, Xiaopeng Zhang, Jin Li, and Hongkai Xiong. From CLIP to DINO: Visual encoders shout in multi-modal large language models. *arXiv preprint arXiv:2310.08825*, 2024. 1, 2

[16] Tongyoung Kim, Jeongeun Lee, Soojin Yoon, Sunghwan Kim, and Dongha Lee. Towards personalized conversational sales agents: Contextual user profiling for strategic action. In *Findings of the Association for Computational Linguistics: EMNLP 2025*, pages 5131–5154, 2025. 2, 3

[17] Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating very long-term conversational memory of LLM agents. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, pages 13851–13870, 2024. 2

[18] Rodrigo Nogueira and Kyunghyun Cho. Passage re-ranking with BERT. *arXiv preprint arXiv:1901.04085*, 2019. 5

[19] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. DINOv2: Learning robust visual features without supervision. *arXiv preprint arXiv:2304.07193*, 2023. 2, 5

[20] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, pages 8748–8763, 2021. 2

[21] Stephen E. Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. 5

[22] Michael Tschannen, Alexey Gritsenko, Xiao Wang, Muhammad Ferjad Naeem, Ibrahim Alabdulmohsin, Nikhil Parthasarathy, Talfan Evans, Lucas Beyer, Ye Xia, Basil Mustafa, et al. SigLIP 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features. *arXiv preprint arXiv:2502.14786*, 2025. 5

[23] Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. LongMemEval: Benchmarking chat assistants on long-term interactive memory. In *International Conference on Learning Representations (ICLR)*, 2025. 2

[24] Jianfei Xiao, Xiang Yu, Chengbing Wang, Wuqiang Zheng, Xinyu Lin, Kaining Liu, Hongxun Ding, Yang Zhang, Wenjie Wang, Fuli Feng, and Xiangnan He. AlpsBench: An LLM personalization benchmark for real-dialogue memorization and preference alignment. In *Proceedings of the 49th International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR)*, 2026. 1, 2

[25] Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, and Yongfeng Zhang. A-MEM: Agentic memory for LLM agents. *arXiv preprint arXiv:2502.12110*, 2025. 2

[26] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct: Synergizing reasoning and acting in language models. In *International Conference on Learning Representations (ICLR)*, 2023. 4

[27] Baoheng Zhang, Jiahui Liu, Gui Zhao, Weizhou Zhang, Yixuan Ma, Jun Jiang, Yingxian Chen, Wilton W. T. Fok, Xiaojuan Qi, and Hayden Kwok-Hay So. Learning to see through illumination extremes with event streaming in multimodal large language models. *arXiv preprint arXiv:2603.27558*, 2026. 2, 5

[28] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric P. Xing, et al. Judging LLM-as-a-judge with MT-Bench and chatbot arena. In *Advances in Neural Information Processing Systems (NeurIPS) Datasets and Benchmarks Track*, 2023. 3