ARTHÉMIS-Core
데모 설계 전문 문서

실제 서비스 구현을 위한 아키텍처·스키마·API·검증 계약

이 문서는 ARTHÉMIS를 한 기관·한 코퍼스·한 전시 API에서 재현 가능한
텍스트 중심 MVP로 구현하기 위한 개발 기준서다.

Engineering Design v1.0 | 작성 기준일 2026년 9월 23일
학술 정본: 중간논문 v3 | 구현 연결: 통합 마스터·로드맵

ARTHÉMIS | 2026-09-23 기준

01 SCOPE

문서 목적과 구현 범위

ARTHÉMIS-Core는 화려한 기능을 먼저 넣는 시스템이 아니라, 동일한 코퍼스·검색기·스크립트에서 기억 표현과 grounding 제약의 효과를 분리해 검증하는 데모다.

구분	Core에 포함	이번 범위에서 제외
데이터	작품 메타데이터·해설문, 전시 snapshot, 감각어-조형어 lexicon	다기관 통합, 무단 크롤링, 원본 이미지 재배포
검색	텍스트 embedding T + 한국어 BM25 L + RRF Top-10	이미지-이미지 검색, cross-encoder reranker
메모리	Session Node, Taste Cluster, Context Router	BRIDGE/stale의 동작화, 생성기 장기기억 튜닝
모델	Extractor prompt/few-shot, 조건부 E-FT 비교	Agent B 생성기 fine-tuning
검증	B1/B2/B3/B4/B4-U, audit log, claim validator	실측 전 성능 숫자, 완성된 사용자 만족도 주장

핵심 계약
조건 간 유일한 차이는 공유 질의 재작성 프롬프트에 들어가는 프로필 블록 Phi다.
검색기·생성기·코퍼스·snapshot·script·seed를 고정해야 memory 효과를 귀속할 수 있다.

02 ARCHITECTURE

전체 아키텍처

입력부터 감사 로그까지 각 단계가 어떤 산출물을 남기는지 고정한다.



단계	입력	출력	실패 시 처리
1. Extract	현재 발화, 최근 k턴, lexicon 후보	고정 JSON, evidence span, confidence	schema 재시도 1회, span 불일치 신호 폐기
2. Write memory	세션 요약과 구조화 신호	Session Node, audit event	감정 원문 장기 저장 금지
3. Route	질의 embedding, companion·motive·time	활성 cluster, router probs, Phi	max prob < rho이면 확인 질문 1회
4. Retrieve	정제 질의, artwork corpus	T/L ranks, RRF Top-10	인덱스·seed·param 고정
5. Ground	R10, exhibition snapshot	grounding record, claim support	VERIFIED@snapshot 또는 CACHED/UNVERIFIED
6. Generate	작품 근거, 확인 필드, 사용자 발화	응답 y, final claims, removed sentences	미지지 방문 문장 제거
7. Audit	모든 중간 산출물	JSONL log, hashes, latency, cost	query_id로 실패 사례 재현

03 DATA CONTRACT

데이터 모델과 JSON 계약

구현팀이 화면이나 프롬프트를 바꾸더라도 아래 구조와 필드 의미는 유지한다.

통합 스키마는 artwork, exhibition, link, lexicon 4개 테이블과 memory/audit 부가 저장소로 구성한다. 모든 외부 데이터는 source_url, collected_at, snapshot_id, checksum을 함께 남긴다.

객체	필수 필드	설명
artwork	artwork_id, title, artist, year, medium, description, tags, source_url	Artwork Layer의 검색 단위. 원본 이미지 저장은 필수 아님
exhibition	exhibition_id, title, institution, venue, start_date, end_date, fee, source_url, checked_at, snapshot_id	Exhibition Layer의 확인 단위
link	artwork_id, exhibition_id, relation, evidence, status	작품 출품 근거가 있을 때만 작품 단위 claim 허용
lexicon	surface, aesthetic_term, aat_term, aliases, examples, version	감각어를 조형 검색어로 연결
session_node	node_id, user_id, summary, intent, visit, evidence, embedding, satisfaction, created_at	감정 원문 대신 감상 목적 수준 저장
taste_cluster	cluster_id, status, context, centroid, description, member_node_ids, weight	tentative/active/suppressed 상태

Agent A 출력 예시

필드	예시	검증 규칙
explicit	artist=[], medium=[], companion=alone	허용 enum과 빈 배열을 구분
implicit	motive=restoration, texture=rough, color=low_saturation	lexicon 후보와 연결
avoid	[vivid_color]	부정 선호도 저장하되 raw emotion은 저장하지 않음
evidence	turn=3, span='표면의 물질감이 묵직한'	원문 substring exact match
confidence	0.0-1.0	범위 밖이면 reject

```json
{
"explicit": {"artist": [], "medium": [], "companion": "alone"},
"implicit": {"motive": "restoration", "formal": {"texture": "rough", "color": "low_saturation"}, "avoid": ["vivid_color"]},
"evidence": [{"turn": 3, "span": "표면의 물질감이 묵직한"}],
"confidence": 0.86
}
```

04 MEMORY AND ROUTING

메모리 알고리즘과 라우팅

학술 정본의 상태 전이와 사업 데모의 사용자 경험을 같은 규칙으로 연결한다.

규칙	조건	동작	로그
MERGE	sigma >= tau_m	최근접 cluster에 node 편입, 중심·기술문 갱신	cluster_id, sigma, threshold
GENESIS	sigma < tau_m 또는 후보 없음	tentative cluster 생성	new_cluster_id, reason
ACTIVATE	서로 다른 n_act=2 세션에서 재관찰	tentative -> active	activation evidence
SUPPRESS	명시적 부정 선호	삭제하지 않고 suppressed 상태로 보존	negation evidence

초기 파라미터는 tau_m=0.78, n_act=2, half-life h=30일, eta=10, theta=2, rho=0.5, kappa=60으로 시작하되 개발 세트 보정값을 로그로 남긴다. 값은 이식 가능한 사실이 아니라 실행 설정이다.

라우터 식: l_k = eta * cos(q_t, mu_k) + theta * match_k(c_t)
프로필 블록: Phi = description(k*) + evidence(k*)
불확실성: max softmax(p_k) < rho이면 추천 전 확인 질문 1회

05 RETRIEVAL AND GROUNDING

검색과 2층 grounding

Artwork Layer는 취향 적합성을, Exhibition Layer는 실제 방문정보를 책임진다.

구성	역할	정책
T index	dense embedding으로 감각어와 해설문 의미 유사성 검색	embedding model·version·checksum 고정
L index	한국어 BM25로 작품명·작가·재료 고유명사 검색	tokenizer·k1·b 기록
RRF	두 rank를 weighted reciprocal rank로 융합	kappa=60, Top-10 R10 유지
Artwork Layer	추천 이유와 조형 근거 제공	source corpus와 evidence span에 근거
Exhibition Layer	기간·장소·요금·상태 확인	snapshot field만 slot template에 채움
Claim validator	최종 문장과 grounding record 대조	미지지 문장 제거, removed_sentences 기록

약속 단위
전시 API가 전시 단위이고 작품 출품이 입증되지 않았다면 '이 작품이 전시 중'이라고 말하지 않는다. '이 취향에 맞는 전시가 열려 있다'로 약속 단위를 낮춘다.

Grounding 상태: 평가에서는 VERIFIED@snapshot으로 고정한다. 데모 운영에서는 최신성에 따라 VERIFIED / CACHED / UNVERIFIED를 표시한다. 두 상태 체계를 섞지 않는다.

06 API AND RUNTIME

API 계약과 서비스 경계

실제 구현 시 Streamlit 화면, OpenAI API, 문화포털 API, 로컬 평가 스크립트를 분리한다.

엔드포인트	입력	출력	실패 처리
POST /extract	utterance, recent_turns, lexicon_version	Extractor JSON	schema retry 1회, fallback 기록
POST /memory/write	session transcript, extractor JSON	node_id, memory_event	raw emotion 미저장
POST /route	query, context slots, clusters	active_cluster_id, probs, Phi	확인 질문 flag
POST /retrieve	rewritten_query, condition, corpus_id	R10, scores, ranks	B1 실패 시 기능 추가 금지
POST /ground	R10, snapshot_id	grounding_record[]	snapshot mismatch -> UNVERIFIED
POST /respond	user_prompt, artwork evidence, grounding	final_text, claims, removed	claim validator 후에만 표시

환경변수 계약: OPENAI_API_KEY는 런타임 secret, CULTURE_API_KEY는 API adapter secret, MODEL_ID와 EMBEDDING_ID는 config에 기록, snapshot_id·prompt_hash·commit은 audit에 기록한다. 실제 모델명과 지원 여부는 G0에서 확인 후 고정한다.

최소 실행 명령
```
python eval/run_retrieval.py --cond B1
python eval/run_extractor_eval.py --arms E-P,E-FT
python eval/run_memory_eval.py --cond B1,B2,B4
python eval/run_grounding_audit.py --cond B4,B4-U
python eval/stats.py --prereg prereg/prereg-v1.yaml
streamlit run app/streamlit_app.py
```

07 AUDIT AND FAILURE TAXONOMY

감사 로그와 실패 분류

데모의 신뢰를 화면에 보여주기 위해 모든 핵심 단계가 query_id로 이어져야 한다.

필드	내용
식별	query_id, user_id, session_id, condition
재현성	snapshot_id, prompt_hash, model_id, extractor_id, seed, commit
추출·메모리	extracted_profile, evidence_spans, active_cluster_id, router_probs
검색·grounding	rewritten_query, retrieval_scores, R10, grounding_record
응답·감사	final_claims, removed_sentences, latency_ms, cost_usd

코드	범주	대표 실패	첫 수정 지점
E1	추출	슬롯 누락, 허위 span	schema·few-shot·lexicon
E2	메모리 쓰기	잘못된 MERGE/GENESIS, SUPPRESS 누락	state transition
E3	라우팅	현재 맥락과 다른 cluster 활성화	threshold·match·clarification
E4	검색	query rewrite drift, 어휘 불일치	T/L index·tokenizer
E5	grounding	미지지 날짜·장소·요금	claim whitelist·slot validator
E6	평가	persona 이탈, 판정 불일치	script freeze·pooling·rater

08 EVALUATION

평가 실행과 통계 계약

성능 결과는 개발 세트와 평가 세트를 분리하고, 실측 전에는 빈칸을 유지한다.

조건	Phi 슬롯	목적
B1	없음, 현재 세션 발화만	무기억 baseline
B2	과거 세션 전사 전체를 최신순 연결	구조 없는 '기억 많이 넣기' baseline
B3	유사 Session Node 상위 k개 요약	요약 효과 분해
B4	Router가 선택한 Taste Cluster 기술문+evidence	제안 방법
B4-U	B4의 동일 R10, grounding 제약 해제	UCR/VCC grounding 감사

분석 단위는 시뮬레이션 사용자다. 사용자별 checkpoint 평균을 만들고 조건 간 paired difference를 계산한다. 사용자 단위 cluster paired bootstrap 10,000회, 95% CI, 효과크기 dz, sign-flip permutation 10,000회, H1/H2 Holm 보정을 사용한다. prereg-v1, 사용자 단위 분할, snapshot·prompt·commit hash가 없으면 전체 결과는 탐색적으로 표기한다.

조건	NDCG@10	CR@10	Srec	UCR	VCC	상태
B1 무기억	[ ]	[ ]	[ ]	[ ]	[ ]	TO-MEASURE
B2 전체 이력	[ ]	[ ]	[ ]	[ ]	[ ]	TO-MEASURE
B3 세션 요약	[ ]	[ ]	[ ]	[ ]	[ ]	TO-MEASURE
B4 구조화 기억	[ ]	[ ]	[ ]	[ ]	[ ]	TO-MEASURE
B4-U 감사	=B4	=B4	-	[ ]	[ ]	동일 R10

09 REPOSITORY AND DEMO

저장소 구조와 60초 데모

개발자가 fresh clone에서 재현하고, 심사자가 화면에서 통제를 확인하는 것을 목표로 한다.

arthemis/
data/{raw,processed,snapshots,lexicon}/
src/{ingest,extract,memory,retrieval,grounding,orchestrator,generation}/
sim/{personas,scripts_frozen}/
ft/{data,jobs}/
eval/{labels,metrics.py,stats.py,run_retrieval.py,run_memory_eval.py,run_grounding_audit.py,run_extractor_eval.py}
app/streamlit_app.py
configs/ audits/ prereg/ tests/ requirements.lock README.md

초	화면	심사 메시지
00:00-00:12	'묵직한 질감의 그림 앞에 혼자' 입력	감각어와 전문어의 간극
00:12-00:27	Agent A JSON, evidence span, active cluster	근거 있는 추출과 맥락 선택
00:27-00:42	Top-10 카드 + grounding record	추천과 방문정보 분리
00:42-00:52	'이번 주말엔 아이와' -> 다른 cluster	context contamination 방지
00:52-01:00	PLAN/MEASURED 라벨과 audit expander	성과 과장 대신 검증 설계

10 SAFETY AND RELEASE

보안·개인정보·운영 체크리스트

서비스 구현의 마지막 기준은 '더 많은 문장을 말하는가'가 아니라 '말해도 되는 근거만 말하는가'다.

- raw emotion과 원문 정서는 장기 memory에 저장하지 않고 회복·사유·학습·체험 등 감상 목적 수준으로 추상화한다.
- 사용자는 기억 cluster를 열람·수정·삭제할 수 있고, 보존기간과 동의 범위를 화면에서 확인한다.
- 기관 데이터 이용조건과 이미지 저작권을 확인하고, 초기 Core는 원본 이미지 저장·재배포를 필수로 하지 않는다.
- 전시정보는 snapshot_id·checked_at·source_url를 남기고, 자유 생성보다 whitelist와 slot template을 우선한다.
- 실행 전 G0에서 실제 모델 지원·파인튜닝 자격·가격·정책을 재확인하고, 실패 시 E-P로 fallback한다.
- Master Gate 전에는 멀티모달, cross-encoder, 다기관 corpus, 생성기 fine-tuning을 복귀시키지 않는다.

구현 완료 정의
B1/B2/B4 E2E 완주 + 실제 결과표/CI + UCR/VCC audit + fresh-clone 재현 + 실패 사례/commit 연결. 하나라도 비면 성능 우월성 문장을 쓰지 않고 설계·프로토콜·탐색 결과로 범위를 낮춘다.

이 문서는 통합 마스터의 구현 청사진을 실제 개발 계약으로 확장한 설계본이다. 성능 결과, 실제 API 응답, 모델 ID, 가격은 실행 시점에 고정하고 이 문서의 빈칸과 상태 라벨을 갱신한다.