ARTHÉMIS-Core

다운사이징 실행계획서

파인튜닝 대안 · 최소 구현 아키텍처 · 핵심 실험 · 6 주 실행 로드맵

프로젝트	ARTHÉMIS - 장기 미학 대화 메모리 기반 대화형 아트 큐레이션
작성 목적	365 Challenge 구현 범위를 실제 완주 가능한 수준으로 동결하고, 실측 결과를 확보하기 위한 실행계획
적용 시점	2026-09-23 이후 중간논문 제출~최종 결과물 제출
문서 상태	실행계획 / 목표치는 실측 성능이 아님

핵심 원칙

"더 추가하기"를 중단한다. ARTHÉMIS-Core 는 NDCG@10, CR@10, Trec, UCR 네 지표를 실제로 산출할 수 있는 최소 시스템을 우선 완성한다. 이미지 정밀검색, 다중 외부 코퍼스, 다중 로컬 모델 상시 구동은 핵심 실험이 통과한 뒤에만 확장한다.

작성 기준: 업로드된 ARTHÉMIS 최종수정본, 정밀심사 통합본, 2026-09-23 365 챌린지 제안서 피드백 원문, 아이펠톤 평가표 및 포스터 양식.

Executive Summary

이 계획서의 결론

현재 ARTHÉMIS 의 위험은 연구 아이디어가 부족한 것이 아니라, 6~7 주 안에 데이터 6~7 종, 다수 임베딩/비전 모델, 장기 메모리, 전시 API, 재순위화, 평가, UI 까지 모두 통합하려는 범위가 과대하다는 점이다. 멘토 피드백도 "주제 의식은 명확하지만 모델·데이터·평가를 최대한 다운사이징해 실현 가능한 상태로 만들라"는 데 집중되어 있다.

> **최종 권고**
>
> ARTHÉMIS-Core 는 텍스트 중심으로 시작한다. 작품 코퍼스 1 개 + 전시 API 1 개 + BM25 + 텍스트 임베딩 1 개 + 계층형 메모리 (Session Node/Taste Cluster/Context Router) + 단일 LLM API + 2 층 그라운딩만을 필수 범위로 동결한다. Cross-encoder 와 이미지 인덱스는 옵션으로 둔다.

이번 다운사이징의 목표는 "기능 수"가 아니라 "귀속 가능한 실측 결과"다. 최소 성공은 아래 네 숫자를 재현 가능하게 출력하는 것이다.

지표	검증 질문	최소 비교	성공 산출물
NDCG@10 ↑	장기 미학 메모리가 현재 발화만 쓰는 검색보다 개인화 순위 품질을 높이는가?	B1 vs B4	조건별 평균, 95% CI, Δ
CR@10 ↓	구조화된 메모리와 라우터가 다른 관람 맥락의 오염을 줄이는가?	B2/B3 vs B4	오염률, 오류 사례
Trec ↓	취향 전환 후 시스템이 새 취향으로 얼마나 빨리 회복하는가?	baseline vs B4	회복 턴/세션 수
UCR ↓	동일 추천목록에서 전시 그라운딩이 미검증 방문 주장을 줄이는가?	B4R vs B5	unsupported claim rate, claim audit

범위 축소 전후

축	기존/이상형 설계	ARTHÉMIS-Core 필수	후속 확장
데이터	국내외 다기관 작품·전시·어휘 데이터	작품 1 개 핵심 코퍼스 + 전시 API 1 개	Met/Harvard/추가 기관
검색	T/X/V/L + reranker	BM25 + text embedding + RRF	CLIP/SigLIP, DINOv2, reranker
LLM	여러 로컬/호스티드 모델 역할 분리	호스티드 LLM 1 종을 프롬프트/스키마로 역할 분리	역할별 SFT/LoRA
메모리	전체 상태기계 + 정교한 라우팅	Session Node + Taste Cluster + Context Router 최소판	감쇠/BRIDGE/민감도 확장
그라운딩	다중 기관/작품 단위 정합	전시 단위 1 개 API + VERIFIED/CACHED/UNVERIFIED	작품 단위 확인, 다중 API
평가	B0~B5 전체 + 파일럿 + 큐레이터	B1/B4/B4R/B5 핵심 + 개발용 B2/B3	전체 ablation/실관람객 파일럿

1. 다운사이징이 필요한 이유

1.1 멘토 피드백의 핵심 해석

현재 계획은 데이터셋 수, 모델 수, 평가 범위가 모두 넓어 7 주 안에 단독 또는 소규모 팀이 통합하기에는 구현 리스크가 높다.

서로 컬럼 구조가 다른 여러 데이터셋을 먼저 2 차 가공하여 통합 데이터셋으로 만들어야 하는데, 발표 시점에는 이 통합 작업이 완료되지 않았다.

여러 비전/임베딩 모델을 동시에 메모리에 상주시켜 병렬 운용하는 방식은 현재 자원에서 현실성이 낮다.

논문화의 핵심은 기능을 많이 만드는 것이 아니라, 명확한 지표로 baseline 대비 개선/차이를 증명하는 것이다.

멘토가 제안한 "파인튜닝된 역할별 에이전트" 아이디어는 하나의 대안이지만, 그 자체가 목표가 아니라 최소한의 입력-출력 과업을 안정화하는 수단으로 해석해야 한다.

> **중요한 해석**
>
> 파인튜닝을 해야만 프로젝트가 성립하는 것이 아니다. 오히려 ARTHÉMIS 의 핵심 연구 질문은 "장기 미학 메모리 구조와 전시 그라운딩이 효과가 있는가"이므로, 먼저 프롬프트·구조화 출력·RAG/메모리로 가설을 검증하고, 파인튜닝은 특정 모듈의 오류가 병목으로 확인될 때만 적용하는 것이 연구 설계상 더 깔끔하다.

1.2 현재 논문 설계에서 이미 반영된 좋은 다운사이징 신호

V(DINOv2) 인덱스는 주 절제 사슬에서 제외되어 별도 선택적 ablation 으로 이동했다.

W1 에서 MMCA 단일 기관으로 축소하는 fallback, W4 에서 V 옵션화, W6 에서 Streamlit·GitHub·영상 완성을 우선하는 일정이 이미 존재한다.

B5 는 B4R 의 동일 R10 을 유지해 그라운딩의 주장 수준 효과를 분리하고, 선택/필터 효과는 B5-F 로 분리하는 형태로 개선되었다.

계획값과 실측값을 분리하고, 중간논문 단계에서는 성능 우위를 주장하지 않는 원칙이 명시되어 있다.

1.3 이번 계획의 범위 동결 원칙

원칙	운영 규칙
P1. 측정 우선	새 기능 제안보다 먼저 "이 기능이 NDCG/CR/Trec/UCR 중 무엇을 바꾸는가"를 확인한다.
P2. 한 번에 한 모듈	비교 조건 사이에서 바뀌는 요소를 1 개로 제한한다.
P3. 데이터 1+1	작품 핵심 코퍼스 1 개, 전시 API 1 개로 시작한다.
P4. 모델 1+1	텍스트 임베딩 모델 1 개 + 생성/추출 LLM 1 개를 기본으로 한다.
P5. 오프라인 전처리	임베딩은 사전 계산·캐시하고 런타임 모델 상주를 최소화한다.
P6. 옵션은 격리	이미지·reranker·추가 기관은 별도 branch/feature flag 로 둔다.
P7. 실패도 결과	성능 향상이 없으면 그대로 보고하고, 오류 분석으로 연구 기여를 전환한다.

2. ARTHÉMIS-Core 최소 구현 아키텍처

2.1 필수 파이프라인

Core Pipeline

사용자 발화 → 미학 신호 추출(JSON) → Session Node 저장 → Taste Cluster 갱신 → Context Router 로 현재 클러스터 선택 → BM25/텍스트 임베딩 검색 → RRF → Top-K → 전시 API grounding → VERIFIED/CACHED/UNVERIFIED → 근거 응답

이 구조에서 중요한 것은 모든 구성요소를 고도화하는 것이 아니라, 각 단계가 실패했을 때 실패 위치를 추적할 수 있도록 로그를 남기는 것이다. 최소 로그 단위는 query_id, user_id, session_id, extracted_profile, active_cluster_id, retrieval_scores, grounding_record, final_claims 이다.

2.2 필수·선택·제외 범위

구분	필수(Core)	선택(시간 여유)	이번 주기 제외/후속
데이터	MMCA 등 단일 핵심 작품 코퍼스, 전시 API 1 개, 소규모 AAT 매핑	추가 기관 1 개	다기관 대규모 통합
검색	BM25 + BGE 계열 text embedding + RRF	cross-encoder	DINOv2 상시 서비스
이미지	없어도 Core 성립	CLIP/SigLIP 단일 이미지 인덱스	CLIP+DINO 동시 병렬 상주
메모리	Session Node, Taste Cluster, Context Router	BRIDGE, decay sensitivity	복잡한 자기진화형 다중에이전트 메모리
LLM	단일 hosted API + 역할별 prompt/schema	extractor 만 SFT/LoRA	여러 대형 로컬 LLM 동시 상주
그라운딩	전시 단위 상태 확인, timestamp	작품 단위 상설전 확인	완전한 작품-전시 실시간 추적
UI	Streamlit 1 화면 데모	기억 편집 UI	상용 수준 프론트엔드

2.3 런타임 자원 구조

CPU/메모리: BM25, metadata filter, JSON validation, evaluation.

GPU/가속기: 가능하면 임베딩 사전 계산에만 사용하고 런타임 상주 모델 수를 최소화한다.

LLM: 로컬 대형 모델 대신 API 호출을 기본값으로 두면 VRAM 병목을 제거할 수 있다.

캐시: 작품 임베딩, 질의 임베딩, API snapshot, 전시 grounding 결과를 캐시한다.

실험 재현: temperature, seed, prompt_version, model_version, snapshot checksum 을 반드시 로그한다.

3. 데이터 다운사이징 계획

3.1 "6~7 개 데이터셋 통합"에서 "두 개의 핵심 테이블"로

멘토가 가장 먼저 확인한 것은 데이터셋 수가 아니라 "서로 다른 컬럼을 어떻게 통합해 실제 학습/검색에 쓰는가"였다. 따라서 첫 산출물은 모델이 아니라 정규화된 두 테이블이어야 한다.

artworks 필드	의미	필수 여부
artwork_id	고유 작품 ID	필수
title / artist	작품명 / 작가	필수
year / medium	제작연도 / 재료	권고

artworks 필드	의미	필수 여부
description	기관 해설문/설명	필수
aat_terms	감각어-조형어 확장 태그	선택→권고
source_url	원기관 근거 링크	필수
image_url	원기관 이미지 링크(저장 대신 링크)	선택

exhibitions 필드	의미	필수 여부
exhibition_id	전시 고유 ID	필수
title / venue	전시명 / 기관	필수
start_date / end_date	전시 기간	필수
artist_terms / theme_terms	작가·주제 연결용 텍스트	권고
source_url	근거 URL	필수
checked_at	확인 시각	필수
status	VERIFIED/CACHED/UNVERIFIED	필수

3.2 데이터 규모 단계화

단계	권고 규모	목적	판정
D0 Smoke	작품 300~500 건 / 전시 수십 건	스키마·검색·grounding 연결 확인	E2E 20 질의 무중단
D1 Core Dev	작품 1,000~3,000 건	임계값·prompt·오류 분석	개발 세트 지표 안정
D2 Core Eval	가능한 전체 단일기관 코퍼스	핵심 지표 산출	B1/B4/B5 재현
D3 Expansion	추가 기관/이미지	외적 확장	Core 결과 확보 후만

※ 위 규모는 프로젝트 관리용 권고 범위이며 논문의 실측 성능이나 사전등록된 표본 수를 의미하지 않는다.

3.3 대화 평가 데이터의 단계화

단계	구성	용도	주의
S0 개발 스모크	3 persona × 3 사용자 × 5 세션 = 45 세션	파이프라인 디버깅	확증 통계에 사용하지 않음
S1 중간 검증	3 persona × 6 사용자 × 5 세션 = 90 세션	CR/Trec 오류 패턴 확인	탐색적 결과로 표기
S2 계획된 평가	3 persona × 10 사용자 × 10 세션 = 300 세션	원 논문 계획과 정합	가능할 때만 확증 분석
S3 실제 파일럿	IRB/면제·동의 확보 후	외적 타당성 방향 확인	규모 작으면 정성/탐색적 해석

중요

45 세션으로 끝까지 구현하는 것은 "다운사이징 성공"이지만, 원 논문에서 300 세션을 전제로 한 검정력·Holm 보정 계획을 그대로 확증 결과로 사용할 수 있다는 뜻은 아니다. 300 세션을 수행하지 못하면 최종 보고서에서 exploratory/pilot 로 명시한다.

4. 모델·컴퓨팅 다운사이징 계획

4.1 모델 수를 줄이는 원칙

기능	기존 후보	Core 권고	이유
텍스트 임베딩	BGE-M3 등	1 개로 고정	검색/메모리 모두 동일 공간을 사용해 구현 복잡도 감소
Lexical	BM25	유지	저비용, 고유명사·작가명에 강함
이미지-텍스트	CLIP/SigLIP	옵션 1 개	Core 성공 전 비활성
이미지-이미지	DINOv2	후속	텍스트 질의 직접 대응 불가, VRAM/전처리 부담
Reranker	cross-encoder	옵션	NDCG 병목일 때만 추가
추출/생성 LLM	다중 모델 역할 분리	호스티드 모델 1 개 + 프롬프트 분리	메모리 상주·MLOps 부담 최소화
판정 LLM	별도 모델	가능하면 규칙+인간 라벨 우선	자기평가 누수 방지

4.2 병렬 상주 대신 오프라인 전처리

작품 텍스트 임베딩은 한 번 계산하여 벡터 DB/파일에 저장한다.

이미지 인덱스를 추가하더라도 배치로 임베딩을 미리 생성한 뒤, 서비스 시에는 벡터만 조회한다.

검색 시 필요한 모델을 순차 호출하고, 동시에 4 개 대형 모델을 GPU 메모리에 올리는 설계를 피한다.

실험 중 model warm-up, cache hit/miss, batch size 를 기록해 p95 지연의 원인을 분리한다.

4.3 권고 실행 프로파일

프로파일	구성	장점	언제 사용
A. 최소	BM25 + text embedding + hosted LLM	가장 빠르게 E2E 완성	즉시
B. 검색 강화	A + cross-encoder	Top-5 품질 개선 가능	NDCG 병목 확인 시
C. 시각 강화	A + CLIP/SigLIP offline index	감각어/시각 매칭 보강	텍스트 Core 통과 후
D. 연구 확장	C + DINOv2 별도 ablation	표면/질감 유사성 연구	최종 이후/후속 연구

5. 파인튜닝 대안 및 의사결정

5.1 결론: "파인튜닝 우선"이 아니라 "병목 확인 후 국소 파인튜닝"

멘토가 제시한 역할별 파인튜닝 에이전트 방식은 구현 대안으로 유효하다. 다만 ARTHÉMIS 의 핵심 가설은 메모리 구조와 그라운딩 효과이므로, 처음부터 여러 파인튜닝 모델을 만드는 것은 비교 변수를 늘리고 시간·비용·재현성 부담을 키운다. 따라서 아래 단계적 전략을 권고한다.

전략	구현	장점	리스크	권고
F0. No FT	prompt + few-shot + JSON schema + retrieval/memory	가장 빠름, 모듈 효과 귀속이 명확	추출 일관성 한계	1 순위
F1. Hosted SFT	지원되는 호스티드 모델에 extraction SFT	인프라 부담 적고 반복 출력 안정화	데이터 제작/비용/벤더 종속	병목 시 2 순위
F2. LoRA/QLoRA	소형 오픈모델 extractor 에 PEFT	저비용 재학습, 로컬 재현 가능	GPU/학습운영 필요	연구 확장
F3. Role-specialized prompts	같은 base LLM, agent A/B 를 prompt/schema 로 분리	파인튜닝 없이 역할 분리	모델 오류 상관	Core 권고
F4. Distillation	강한 teacher 로 라벨/응답 생성→작은 student	추론 비용 절감 가능	추가 연구 프로젝트 수준	이번 주기 제외

5.2 가장 현실적인 대안: 같은 모델, 다른 역할

Agent A - Preference Extractor: 발화 → 고정 JSON 스키마. temperature 낮게, 근거 span 필수.

Agent B - Memory Writer: 세션 종료 후 Session Node 생성 및 Keep/Add/Revise/Suppress 제안.

Agent C - Response Generator: 검색/grounding 결과만 받아 설명. 전시 정보는 tool record 외 추론 금지.

이 세 역할은 반드시 서로 다른 모델일 필요가 없다. 동일 API 모델을 사용하되 system prompt, JSON schema, temperature, 입력 컨텍스트를 분리하면 "다중 모델 상주" 없이도 역할 분리를 구현할 수 있다.

5.3 파인튜닝을 적용할지 결정하는 Gate

Gate	측정	파인튜닝 조건	대안
FT-G1 추출 안정성	명시/암묵 micro-F1, JSON validity	프롬프트/예시 최적화 후에도 반복 오류가 특정 슬롯에 집중	extractor 만 SFT/LoRA
FT-G2 메모리 업데이트	Keep/Add/Revise/Suppress 정확도	규칙+LLM 판정으로 해결되지 않는 일관된 오류	memory writer 국소 SFT
FT-G3 설명	FR/UCR	grounding 제약을 줘도 unsupported claims 가 지속	generator SFT 보다 먼저 constrained decoding/prompt 강화
FT-G4 비용	1 질의당 토큰/지연	API 비용이 최종 데모 규모에서 병목	소형 모델 distill/LoRA 검토

5.4 Hosted SFT 적용 시 권고 과업

파인튜닝이 필요하다면 가장 먼저 "미학 신호 추출기"에 제한한다. 생성기 전체를 파인튜닝하면 메모리 효과와 생성 모델 효과가 섞일 수 있기 때문이다.

항목	권고
입력	사용자 발화 + 최소 대화 맥락

항목	권고
출력	고정 JSON: explicit/implicit preference, avoidance, visit_context, evidence_span, confidence
학습 데이터	사람이 검수한 소수의 고품질 예시부터 시작하고, 개발/평가 사용자 분리
검증	JSON validity, slot micro-F1, evidence span IoU, implicit/explicit 분리
중단 조건	프롬프트 기반 baseline 대비 개선이 작거나 데이터 제작비가 과도하면 즉시 중단
연구 보고	모델 버전, 데이터 크기, epoch/learning setting, 비용, seed, 실패 예시 기록

5.5 LoRA/QLoRA 대안

로컬 GPU 자원이 확보되고, API 비용/재현성이 주요 이슈가 될 때만 고려한다.

3B~8B 급 소형 instruct 모델을 extractor 에 한정해 adapter 학습하는 것이 현실적이다.

메모리/검색/그라운딩은 모델 학습이 아니라 외부 상태·도구 설계로 유지한다.

LoRA 를 도입해도 B1/B4 비교에서는 동일 extractor 를 사용하여 실험 조건을 고정한다.

> **파인튜닝 의사결정 한 줄**
>
> Core 가 프롬프트 기반으로 끝까지 돌아가고 네 지표가 산출되면 파인튜닝은 "필수"가 아니다. 파인튜닝은 지표 병목을 줄이는 선택적 최적화이며, 그 자체가 프로젝트의 기여점이 되어서는 안 된다.

6. 장기 미학 메모리의 최소 구현

6.1 Session Node 최소 스키마

필드	예시	Core 처리
intent	사유/회복/학습/체험	필수
visual_preferences	저채도, 거친 질감, 여백	필수
avoidance	고채도, 과밀 구성	권고
visit_context	혼자/가족, 시간대	필수
evidence_span	원 발화 일부	필수
satisfaction	0~1 또는 없음	선택
status	tentative/active/suppressed	필수 최소

6.2 Taste Cluster 최소 로직

새 Session Node 를 텍스트 임베딩으로 변환한다.

기존 cluster centroid 와 cosine similarity 를 계산한다.

개발 세트에서 정한 임계값 이상이면 MERGE, 아니면 새 tentative cluster 를 만든다.

BRIDGE 는 Core 에서는 로그만 남기거나 후속 기능으로 둔다. 구현 부담이 커지면 생략 가능하다.

사용자가 명시적으로 싫다고 한 취향은 suppressed 로 처리해 라우팅 후보에서 제외한다.

6.3 Context Router 최소 로직

Core router 는 복잡한 학습형 router 가 아니라 “semantic similarity + context match” 점수로 충분하다. 동행/목적/시간대 슬롯이 있으면 가중하고, 불확실하면 확인 질문 1 회만 수행한다.

> **RQ2 를 살리는 최소 기능**
>
> B3 는 Session Node 만 사용하고, B4 는 Taste Cluster + Context Router 를 사용한다. 이 둘의 차이를 CR@10 과 Trec 로 측정하면 ARTHÉMIS 의 핵심 메모리 주장에 직접 답할 수 있다.

7. 검색·그라운딩 최소 구현

7.1 B1 검색 baseline

BM25: 작가명·작품명·재료·고유명사 회수.

Text dense retrieval: 사용자 감각어와 해설문 의미 유사도 회수.

RRF: 두 검색 결과의 순위를 결합한다.

B1 에서는 장기 메모리 벡터를 사용하지 않는다.

7.2 B4 메모리 검색

B4 는 B1 의 검색기와 코퍼스를 그대로 사용한다. 바꾸는 것은 질의 표현에 현재 라우팅된 메모리 정보를 결합하는 것뿐이다. 이렇게 해야 NDCG/CR 변화가 “검색 모델 교체”가 아니라 “메모리 구조” 때문이라고 해석할 수 있다.

7.3 2 층 그라운딩

층	역할	말해도 되는 것	말하면 안 되는 것
Artwork Layer	취향에 맞는 작품 발견/설명	작품의 조형·정서적 근거	현재 전시 중이라고 추정
Exhibition Layer	현재 열려 있는 전시 확인	확인된 기간/장소/상태	작품 단위 확인 없는데 “원작 전시 중”이라고 단정

VERIFIED: 현재 기관/API 근거가 있고 평가 snapshot 과 일치.

CACHED: 과거 확인값이지만 확인시각이 표시됨.

UNVERIFIED: 근거 부족. 방문 정보로 단정하지 않음.

7.4 UCR 실험 통제

B4R 과 B5 는 반드시 동일 추천목록 R10 을 공유한다. B5 에서만 grounding record 를 붙이고 생성 제약을 적용한다. 그러면 UCR 감소를 목록 변경이 아니라 grounding 의 효과로 귀속할 수 있다.

8. 네 핵심 지표의 실측 설계

8.1 NDCG@10

목적: 추천 순위의 개인화 적합도를 측정한다. 작품 적합도는 0~3 의 등급으로 라벨링하고, 관람 가능성은 NDCG 에 섞지 않는다.

비교	고정	변경	보고
B1 vs B4	코퍼스, 검색기, seed, 질의, 후보 생성 방식	메모리 입력/라우팅	평균 NDCG@10, Δ, 95% CI

8.2 CR@10

목적: 가족 관람/혼자 관람 등 다른 맥락의 취향이 섞이는 정도를 측정한다. 현재 맥락에만 부적합하고 다른 맥락에만 적합한 추천의 직접 비율로 정의한다.

대상	비교	핵심 오류 로그
다중 맥락 persona	B2 또는 B3 vs B4	query_id, 현재 context, 활성 cluster, 오염 추천, 원인

8.3 Trec

목적: 취향 전환 후 새 취향 추천으로 회복하는 속도를 측정한다. 원 논문 정의를 유지하려면 CR@10≤0.10 과 새 취향 Recall@10 이 Oracle 대비 90% 이상인 상태가 2 턴 연속 유지되는 최초 시점까지의 턴 수를 기록한다.

8.4 UCR

목적: 기간·장소·요금·운영상태·예매 등 방문 주장에서 근거가 없는 claim 의 비율을 측정한다. 동일 추천 목록에서 B4R 의 자유 방문정보 생성과 B5 의 grounded generation 을 비교한다.

8.5 결과표 템플릿

Metric	Baseline	ARTHÉMIS-Core	Δ	95% CI / Audit	해석
NDCG@10 ↑	[ ]	[ ]	[ ]	[ ]	개인화 순위
CR@10 ↓	[ ]	[ ]	[ ]	[ ]	맥락 오염
Trec ↓	[ ] turns	[ ] turns	[ ]	[ ]	전환 회복
UCR ↓	[ ]	[ ]	[ ]	[ ]	미검증 방문 주장

※ 빈칸은 반드시 실측값으로만 채운다. 목표치나 개발 세트 수치를 최종 성과처럼 사용하지 않는다.

9. 최소 실험 사다리와 재현성

9.1 Core 실험 조건

조건	구성	주 지표	필수 여부
B1	현재 발화 + lexical/dense retrieval, 장기 메모리 없음	NDCG@10	필수
B2	전체 과거 이력을 단순 연결/요약	CR@10 보조	권고
B3	Session Node 기반 메모리	CR/Trec 보조	권고
B4	Taste Cluster + Context Router	NDCG, CR, Trec	필수
B4R	B4 추천목록 고정, grounding 전	UCR baseline	필수
B5	동일 목록 + grounding + claim constraint	UCR	필수
B5-F	관람가능성 필터/재순위	Avail@10	후속
B1+V	이미지 인덱스 추가	Recall/NDCG	후속

9.2 최소 재현성 체크리스트

코퍼스 snapshot ID 와 checksum

전시 API snapshot 기준일과 응답 원본 보관
모델명/버전, embedding dimension, prompt_version
BM25/RRF 파라미터, cluster/router threshold
temperature, seed, batch size
Git commit hash 와 requirements lock
평가 라벨러 수, 사용자 단위 개발/평가 분할
실패 query 의 raw log 를 삭제하지 않고 audit 폴더에 보존

9.3 통계 해석 원칙

동일 사용자·동일 질의·동일 seed·동일 snapshot 의 paired 비교를 유지한다.
300 세션을 수행하면 원 논문의 사용자 단위 bootstrap/Holm 계획을 유지할 수 있다.
45/90 세션 단계는 개발·탐색적 분석으로 명시하고 과도한 유의성 해석을 하지 않는다.
유의하지 않은 결과는 “효과 없음”으로 단정하지 않고 차이와 신뢰구간, 오류 사례를 함께 보고한다.

10. 6 주 실행 로드맵 - 다운사이징 개정안

주차	핵심 목표	필수 산출물	통과 기준(권고)	실패 시 축소
W1	데이터/스냅샷	artworks, exhibitions, schema audit	E2E 데이터 로딩 + 수동 점검	단일 기관·필드 축소
W2	B1 + 추출기	BM25/dense/RRF, JSON extractor	20 질의 무중단, 평가 코드 실행	AAT/암묵 슬롯 일부 축소
W3	메모리	Session Node, Cluster, Router, S0 45 세션	CR/Trec 계산 가능	BRIDGE/decay 생략, rule 고정
W4	grounding	API adapter, status, B4R/B5	동일 R10 에서 UCR audit 가능	전시 API 1 개만, 작품 단위 주장 금지
W5	통제 실험	B1/B2/B3/B4/B5 반복 실행	네 지표 결과표 + CI/오류 로그	cross-encoder/이미지 완전 제외
W6	데모/문서	Streamlit, GitHub, 1 분 영상, 포스터, 최종보고	fresh clone 재실행 + 데모 완료	UI 단순화, 캐시 기반 demo

10.1 매주 금요일 Go/No-Go 회의

질문	Yes	No 일 때
이번 주 기능이 네 지표 중 하나를 산출하는 데 필요한가?	유지	backlog 로 이동
다음 주 실험을 막는 blocker 인가?	우선 해결	후순위
새 모델/데이터 추가 없이 해결 가능한가?	현 구조 유지	추가 전에 비용-효과 검토
현재 branch 가 fresh clone 에서 실행되는가?	merge	문서화보다 재현성 먼저

11. 리스크 관리와 플랜 B/C

리스크	조기 신호	1 차 대응	최종 fallback
데이터 통합 지연	필드 결측/ID 중복이 계속 발생	필수 6 개 필드만 정규화	MMCA 단일 코퍼스만
GPU/메모리 부족	OOM, 모델 로딩 시간 과다	호스티드 LLM + offline embedding	이미지 모델 전부 제거
추출 불안정	JSON 오류/암묵 F1 낮음	schema+few-shot+validator	extractor 만 SFT/LoRA
메모리 오염	CR 이 baseline 보다 나쁨	router context weight 조정	rule-based context routing
취향 전환 실패	Trec 가 관찰기간 내 회복 안 함	tentative cluster 활성화	전환 시 확인 질문 강제
grounding UCR 개선 없음	근거 없는 claim 지속	claim whitelist/structured response	방문정보 템플릿화
API 장애	timeout/응답 형식 변경	snapshot cache	offline snapshot demo
통계 표본 부족	300 세션 미완료	90 세션 exploratory	효과크기+CI+오류사례 중심 보고
UI 지연	백엔드 불안정	캐시/비동기 제거	읽기전용 demo + prerecorded video

11.1 기능 중단 우선순위

삭제 순서	기능	이유
1	DINOv2	Core 연구질문에 필수 아님, 자원 부담 큼

삭제 순서	기능	이유
2	다중 미술관 코퍼스	통합 비용이 높고 baseline 통제가 어려움
3	cross-encoder	B4 까지 결과가 없으면 추가 가치 없음
4	CLIP/SigLIP	텍스트 Core 가 안정된 후 확장 가능
5	복잡한 BRIDGE/decay sensitivity	CR/Trec 최소 실험 후 연구 확장
절대 유지	Session Node/Cluster/Router, B1/B4, grounding, evaluation	ARTHÉMIS 정체성과 네 핵심 지표를 구성

12. 비용·컴퓨팅 자원 전략

12.1 비용의 우선순위

우선순위	비용 항목	원칙
1	데이터 수집/정제 시간	사람 시간을 최우선 병목으로 본다. 자동화보다 스키마 단순화가 먼저.
2	LLM API	prompt caching, batch 평가, 중복 호출 캐시. 실험 ID 별 토큰 사용량 기록.
3	GPU	embedding 일괄 전처리와 선택적 LoRA 에만 사용. 상시 4 모델 운용 금지.
4	평가 인력	최종 relevant/claim label 일부에 집중. 전 항목 인간평가를 피하고 핵심 표본만 이중 라벨.

12.2 파인튜닝 비용 통제

파인튜닝 전 먼저 prompt baseline 의 오류를 유형화한다. "학습으로 해결할 오류"와 "데이터/규칙으로 해결할 오류"를 분리한다.

Hosted SFT 를 사용할 경우 extractor 1 개 과업만 학습하고, 생성기는 grounded prompt 를 유지한다.

LoRA 를 사용할 경우 adapter 만 저장하고 base model/version 을 고정한다.

fine-tune 전/후 비교는 동일 평가 세트에서 수행하고, 비용 대비 F1 개선을 함께 기록한다.

12.3 최소 하드웨어 전략

로컬 환경은 CPU + 16GB 이상 RAM 에서도 Core 검색/메모리 로직을 개발 가능하도록 하고, 임베딩 생성이 느리면 클라우드 GPU 또는 일시적 GPU 세션으로 배치 생성한다. 데모 서버에는 모델 자체를 올리지 않고 이미 계산된 벡터와 호스티드 API 를 사용하면 배포 위험이 크게 줄어든다.

13. GitHub·코드 구조 및 재현 가능한 산출물

13.1 권고 repository 구조

```
arthemis-core/
├── data/
│   ├── raw/              # 배포 제한 원본 제외
│   ├── processed/        # artworks / exhibitions
│   └── snapshots/        # eval snapshot metadata
├── src/
│   ├── ingest/
```

```
|   ├── retrieval/
|   ├── memory/
|   ├── grounding/
|   └── generation/
├── eval/
|   ├── labels/
|   ├── metrics.py
|   ├── run_b1.py
|   ├── run_memory_eval.py
|   └── run_grounding_eval.py
├── app/
|   └── streamlit_app.py
├── configs/
├── audits/
├── tests/
├── requirements.lock
└── README.md
```

13.2 최종 "한 줄 실행" 목표

명령	출력
python eval/run_b1.py	NDCG@10, Recall@50, MRR
python eval/run_memory_eval.py	NDCG@10, CR@10, Trec
python eval/run_grounding_eval.py	UCR, VCC, claim audit
streamlit run app/streamlit_app.py	입력→기억→추천→전시 상태 데모

13.3 README 에서 반드시 보일 것

프로젝트 한 문장 문제 정의
Core 범위와 제외 범위
데이터 출처/라이선스/저작권 처리
환경 설치와 한 줄 실행
네 핵심 지표의 재현 명령
실측 결과표와 결과 생성 commit hash
제한사항: planned vs measured 구분

14. 데모·UI·포스터 전략

14.1 Streamlit 최소 화면

영역	표시 내용	평가 효과
입력	"마음이 가라앉는 거친 질감의 작품…"	사용자 니즈 명확성
기억	현재 활성 Taste Cluster + 근거 발화	메모리 설명가능성
추천	Top-5 작품 + 추천 이유	핵심 기능
전시	VERIFIED/CACHED/UNVERIFIED + 확인시각	grounding 신뢰

영역	표시 내용	평가 효과
편집	기억 삭제/수정(가능하면)	UX/윤리성
로그	응답시간/근거 링크	기술 완성도

14.2 최종 발표의 결정적 결과 슬라이드

슬라이드 제목은 “Does ARTHÉMIS Memory Actually Help?”처럼 질문형으로 두고, 네 지표를 한 표에 배치한다. 성능이 기대와 다르더라도 수치를 그대로 제시하고 실패 원인을 단계별로 설명한다.

Metric	Baseline	ARTHÉMIS	Δ	한 줄 결론
NDCG@10 ↑	[실측]	[실측]	[ ]	개인화 품질
CR@10 ↓	[실측]	[실측]	[ ]	맥락 오염
Trec ↓	[실측]	[실측]	[ ]	취향 전환 적응
UCR ↓	[실측]	[실측]	[ ]	방문정보 신뢰

14.3 평가표 대응

평가 축	Core 증거
기술적 완성도	실행 가능한 repository, E2E demo, 재현 로그, 예외 처리
창의성/혁신성	계층형 미학 메모리 + 2 층 grounding 의 문제 결합
문제 정의/해결	세 가지 gap 을 네 핵심 지표로 연결
연구 결과	B1/B4/B5 paired 실측, CI, 오류 분석
발표/시연	한 화면 demo + 한 장 결과표 + 질문 대응

15. 파인튜닝 대안별 구현 청사진

15.1 대안 A - 파인튜닝 없이 구조화 출력

구성	내용
System prompt	"근거 없는 취향을 만들지 말고 evidence span 이 있는 정보만 JSON 으로 반환"
Schema	intent, preference, avoidance, visit_context, evidence_span, confidence
Few-shot	명시/암묵/부정/불확실 예시를 균형 있게
Validator	JSON schema 검증, 필드 누락 재요청
장점	당일 구현 가능, baseline 명확, 학습 데이터 불필요
적합성	Core 1 차 선택

15.2 대안 B - Extractor 만 Hosted SFT

단계	실행
1. 오류 수집	F0 baseline 에서 실패 사례를 slot 별로 모은다.
2. 라벨 정제	원문 발화와 정답 JSON/evidence span 을 사람 검수한다.
3. 학습/검증 분리	사용자/시나리오 단위로 분리하여 누수를 막는다.
4. SFT	지원되는 모델의 관리형 fine-tuning 기능을 사용한다.
5. 비교	동일 eval set 에서 F0 vs F1 micro-F1/JSON validity/비용 비교.
6. 채택 기준	개선이 실질적이고 전체 일정에 부담이 없을 때만 채택.

15.3 대안 C - LoRA/QLoRA Extractor

항목	권고
모델	소형 instruct 모델 1 개
학습 대상	attention/MLP 일부 adapter
데이터	고품질 구조화 추출 쌍
평가	F0 와 동일 micro-F1/JSON validity
배포	adapter + base model version 고정
주의	GPU 세팅/라이브러리 충돌이 일정 리스크이므로 Core 완성 뒤

15.4 대안 D - 멀티에이전트처럼 보이되 한 모델 사용

멘토가 말한 "Agent A 는 취향, Agent B 는 미술 지식" 구조는 반드시 여러 파인튜닝 모델을 뜻하지 않는다. 아래처럼 동일 LLM 을 역할별 call 로 나눌 수 있다.

Call	입력	출력	실험 영향
A Preference	발화/최근 대화	취향 JSON	메모리 입력
B Art Evidence	query + corpus hits	작품 근거 요약	설명 근거

Call	입력	출력	실험 영향
C Visit Grounding	전시 snapshot	검증된 방문 필드	UCR
D Final Response	A/B/C 구조화 결과	자연어 응답	생성 레이어

추천 조합

이번 365 Challenge 에서는 F0 + Role-specialized prompts 를 기본으로 하고, W2 종료 시 extractor 성능이 병목이면 F1(Hosted SFT) 또는 F2(LoRA)를 선택한다. 생성기 파인튜닝은 UCR 문제를 해결하는 1 차 수단으로 사용하지 않는다.

16. 데이터 거버넌스·윤리·저작권

근현대 작품 원본 이미지는 저장·재배포하지 않고, 필요하면 임베딩과 원기관 링크만 보관한다.

정서 관련 원문은 그대로 장기 기억에 저장하지 않고 "감상 목적" 수준으로 추상화한다.

사용자 기억은 read/edit/delete 가능성을 설계하고, consent_scope 와 보존기간을 기록한다.

전시 정보는 source_url 과 checked_at 를 함께 저장해 감사 가능하게 한다.

실관람객 파일럿은 IRB 심의/면제 확인과 동의 절차가 확보된 경우에만 수행한다.

LLM 판정만으로 최종 실험 라벨을 만들지 말고, 핵심 표본은 사람 평가를 사용한다.

16.1 문서 언어 규칙

금지/주의 표현	대신 사용할 표현
"성능이 향상되었다" (실측 전)	"향상 여부를 검증한다"
"300 세션에서 검증했다" (미완료)	"300 세션을 계획한다 / 실제 수행 규모는 ○○"
"원작이 현재 전시 중" (전시 단위 API 만)	"관련 전시가 확인됨 / 원작 전시 여부는 미확인"
"AI 가 사용자의 취향을 안다"	"동의된 발화 근거에서 취향 신호를 구조화한다"

17. 최종 Go/No-Go 체크리스트

No.	질문	Go 기준
1	작품/전시 데이터가 단일 스키마로 로드되는가?	필수 필드 결측/ID 오류 감사 완료
2	B1 이 1 회 명령으로 실행되는가?	NDCG 계산까지 자동
3	Session Node 가 근거 span 과 함께 저장되는가?	evidence 없는 추론 분리
4	B4 가 B1 과 동일 코퍼스/검색기를 쓰는가?	메모리만 차이
5	CR/Trec 가 자동 계산되는가?	persona B/C 에 대해 재현
6	B4R/B5 가 동일 R10 을 쓰는가?	UCR 귀속 가능
7	전시 claim 마다 source/status/check time 이 있는가?	audit 가능
8	실험 commit 을 fresh clone 에서 재현 가능한가?	README 기준 실행 성공
9	결과표 네 칸이 실측값으로 채워졌는가?	NDCG/CR/Trec/UCR
10	포스터/발표가 기능보다 실측 결과를 먼저 보여주는가?	결과 슬라이드 1 장 완성

프로젝트 종료 조건

최종 제출 시 ARTHÉMIS-Core 가 "작동하는 데모 + 재현 가능한 코드 + 네 실측 지표 + 오류 사례"를 갖추면 성공으로 본다. DINOv2, 다기관 데이터, 고급 UI, 다중 fine-tuned agent 가 없어도 핵심 연구 기여는 성립한다.

부록 A. 근거 문서와 반영 관계

근거 문서	본 계획에 반영한 핵심
ARTHEMIS_중간논문_최종수정본.pdf	B1~B5 절제, CR/Trec/UCR 정의, 300 세션 계획, 6 주 일정, V 옵션화, 재현성 양식
ARTheMIS_원본-수정본_정밀심사_최종통합본.pdf	CR 정의 오류 수정, grounding 목록 고정, B4 내부 귀속, 계획/실측 경계, 재현성·서지 보완
365 챌린지_제안서피드백_2026.09.23_original.txt	다수 데이터셋 통합 부담, 다수 모델 병렬 자원 문제, 범위 축소 권고, 지표화, 파인튜닝/역할별 에이전트 대안
아이펠톤 평가표 이미지	기술 완성도·창의성·문제정의·연구결과·발표/시연 축에 맞춘 산출물 우선순위
아이펠톤 포스터 양식	프로젝트 개요-수행 절차-구조-결과의 4 블록 구성, 결과 영역 중심 전략

부록 B. 핵심 실험 결과 입력 양식

실험 ID	조건 A	조건 B	Primary Metric	A	B	Δ	CI/p	비고
E1	B1	B4	NDCG@10	[ ]	[ ]	[ ]	[ ]	
E2	B3/B2	B4	CR@10	[ ]	[ ]	[ ]	[ ]	
E3	baseline	B4	Trec	[ ]	[ ]	[ ]	[ ]	
E4	B4R	B5	UCR	[ ]	[ ]	[ ]	[ ]	

부록 C. 1 페이지 실행 요약

이번 주 바로 할 일

1) 작품/전시 두 테이블을 만든다. 2) B1 을 먼저 끝까지 실행한다. 3) Session Node→Cluster→Router 최소판을 붙인다. 4) B4 에서 CR/Trec 를 계산한다. 5) 동일 R10 에 grounding 을 붙여 UCR 을 계산한다. 6) 네 숫자가 나온 뒤에만 이미지·reranker·fine-tuning 을 추가한다.

If...	Then...
B1 이 아직 안 돈다	메모리/파인튜닝 금지. 데이터+검색부터 수정
CR 이 높다	router/context logic 우선 수정
Trec 가 길다	tentative cluster 활성화/확인 질문
UCR 이 높다	generator fine-tune 전에 claim whitelist/grounding constraint
NDCG 만 낮다	reranker 또는 이미지 인덱스 검토

If…	Then…
추출 F1 이 병목	extractor SFT/LoRA 검토
네 지표가 안정	그때 확장 기능 시작

최종 메시지

ARTHÉMIS 의 경쟁력은 “모델을 많이 쓰는 프로젝트”가 아니라 “미학적 취향의 장기 기억과 실제 관람 정보의 신뢰성을 분리해서 측정하는 프로젝트”라는 데 있다. 이번 다운사이징은 연구를 축소하는 것이 아니라, 핵심 가설을 실제 데이터와 재현 가능한 코드로 증명하기 위해 변수를 통제하는 과정이다.