ARTHÉMIS: 장기 미학 대화 메모리와 2층 전시 그라운딩을 갖춘 대화형 아트 큐레이션 시스템의 설계 및 단계별 평가

ARTHÉMIS: Design and Stage-wise Evaluation of a Memory-Augmented Conversational Art Curation System with Space-Separated Multimodal Retrieval and Exhibition Grounding

추병곤 외

소속: [AFFILIATION INPUT] | 프로젝트/팀: [PROJECT OR TEAM INPUT]

교신 이메일: [CORRESPONDING EMAIL INPUT] | 문서 버전: 2026-09-23

문서 상태 및 결과 경계

본 문서는 세 원천 PDF를 검토하고 통합한 설계/중간 연구논문이다. 300개 합성 다중 세션, 파일럿 20명, Extraction F1 >= 0.75, CR@10 <= 0.10, p95 <= 6초 등은 계획된 규모 또는 초기 목표이며 실측 결과가 아니다. 실험으로 채워지지 않은 값은 [INPUT] 또는 TBD로 남긴다. 결과가 입력되기 전에는 개선, 향상, 유의한 차이와 같은 성과 표현을 사용하지 않는다.

초록 / Abstract

미술관 아카이브는 작가, 제작연도, 재료와 같은 전문 메타데이터를 중심으로 구성되지만, 관람객은 감각과 상황의 언어로 작품을 탐색한다. 기존 대화형 추천 시스템은 이 의미 간극을 부분적으로 완화하더라도 세션 간 취향을 보존하지 못하거나 서로 다른 관람 맥락을 혼합할 수 있고, 추천 작품의 실제 전시 가능성을 검증하지 못할 수 있다. ARTHÉMIS는 이 문제를 다루기 위해 근거 발화를 보존하는 Aesthetic Session Node, 반복 성향을 조직하는 Curatorial Taste Cluster, 현재 관람 맥락에 맞는 클러스터를 선택하는 Context Router를 결합한 계층형 미학 메모리를 제안한다. 또한 텍스트, 텍스트-이미지, 이미지-이미지, 어휘 검색을 독립 인덱스로 유지하고 rank-level fusion을 수행하며, 작품 발견과 전시 실행을 Artwork Layer와 Exhibition Layer로 분리한다. 모듈별 기여는 BM25 baseline에서 메모리, 재순위화, 전시 grounding을 단계적으로 추가하는 B0-B5 절제 사다리로 평가한다. 평가는 메모리 생명주기, 검색 순위, 취향 전환 회복, 맥락 오염, 관람 가능성, 근거 기반 설명을 포함한다. 본 논문은 설계와 평가 프로토콜을 보고하며, 300개 합성 다중 세션과 20명 파일럿은 계획된 평가 규모이다. 실측 성능은 실험 완료 후 동일한 프로토콜에 따라 보고한다.

Museum archives are organized around professional metadata such as artist, year, and medium, while visitors often search through sensory and situational language. Existing conversational recommender systems may narrow this gap, but can lose preferences across sessions, mix distinct visiting contexts, or recommend works whose current exhibition status is unknown. ARTHÉMIS addresses these risks with a hierarchical aesthetic memory composed of evidence-linked Aesthetic Session Nodes, Curatorial Taste Clusters, and a Context Router. It maintains separate text, text-image, image-image, and lexical indexes and fuses their ranks without adding vectors from incompatible spaces. It also separates artwork discovery from exhibition-level visitability grounding. Contributions are evaluated through a stage-wise B0-B5 ladder from BM25 retrieval to memory, reranking, and grounding, with explicit measures for memory lifecycle, ranking, preference switching, contamination, availability, and evidence-grounded explanation. This interim paper reports a design and evaluation protocol. The planned evaluation includes 300 synthetic multi-session cases and a 20-person pilot;

no measured performance is claimed here.

Keywords: conversational recommender system; long-term memory; multimodal retrieval; art recommendation; personalization; retrieval-augmented generation; tool grounding; museum AI

1. 서론 / Introduction

1.1 배경과 문제 정의

공공 미술관과 온라인 예술 플랫폼은 대규모 소장품을 공개하고 있지만, 검색 인터페이스는 여전히 작가명, 작품명, 제작연도, 재료, 사조와 같은 전문 어휘를 전제로 한다. 반면 관람객의 요구는 '마음이 가라앉는 거친 질감의 추상화'처럼 감각적이고 상황적이다. 이 발화는 정서, 저채도, 물질성, 명상성, 촉각성, 자극 회피, 관람 목적을 동시에 포함하지만 기관 기록의 필드와 직접 대응하지 않는다.

ARTHÉMIS는 세 가지 연결 단절을 연구 대상으로 삼는다. 첫째, 감각어를 조형어로 번역하는 언어적 변환과 텍스트로 환원되지 않는 표면·필치·구성을 이미지에서 찾는 시각적 변환이 함께 필요하다. 둘째, 장기 메모리를 단일 사용자 프로필에 누적하면 평일의 혼자 관람과 주말의 가족 체험처럼 서로 다른 목적이 오염된다. 셋째, 알고리즘적으로 적합한 작품이 수장고에 있거나 전시가 종료되었을 때 추천은 실제 관람 행동으로 이어지지 않는다.

핵심 연구문제

감각 언어로 표현된 미적 요구를 구조화하고, 시간에 따른 취향 변화와 다중 관람 맥락을 선택적으로 기억하면서, 실제로 확인 가능한 전시 정보에 근거한 개인화 추천과 설명을 제공할 수 있는가?

1.2 기여와 범위

기여	통합 설계	검증 범위
C1 계층형 미학 메모리	evidence span을 가진 Session Node, tentative/active/stale/suppressed 상태의 Taste Cluster, Context Router	추출-갱신-검색-활용, 전환 회복, 맥락 오염
C2 공간 분리 검색	T/X/V/L 독립 인덱스와 RRF rank fusion; V는 별도 옵션 ablation	Recall@50, NDCG, MRR, 탐색 슬롯 효과
C3 2층 grounding	Artwork Layer의 설명 근거와 Exhibition Layer의 전시 snapshot을 분리	Availability, UCR, claim-level faithfulness
C4 단계별 평가	동일 사용자·seed·snapshot의 paired design과 RQ별 primary metric	모듈 기여의 귀속 가능성

본 논문의 기여는 새로운 encoder나 실측 성능의 주장보다, 예술 도메인 장기 메모리와 검색-전시 검증을 하나의 감사 가능한 평가 단위로 연결하는 설계에 있다. 데이터와 결과가 입력되기 전에는 '검증한다', '측정한다', '목표로 한다'라는 표현으로 제한한다.

2. 관련 연구 / Related Work

2.1 대화형 추천과 장기 메모리

대화형 추천 연구는 명시적 평점뿐 아니라 대화에서 드러나는 선호, 제약, 의도를 추론하고 후보를 좁히는 방향으로 발전했다. RecLLM과 CSI는 자연어 프로필, 맥락 프로필, 질문 정책, 사용자 시뮬레이터를 결합하는 구조를 제시한다. A-MEM과 Mem0는 새 관찰을 기존 기억과 연결하고 대화에서 사실을 추출해 지속 저장하는 메커니즘을 다룬다. LoCoMo, LongMemEval, AlpsBench는 장기 대화의 추출, 갱신, 검색, 활용을 평가한다. ARTHÉMIS는 이 흐름을 예술 감상의 느린 취향 변화와 다중 관람 맥락에 맞추어 Session Node와 Taste Cluster로 조직하고, Context Router를 통해 선택적으로 활성화한다.

2.2 예술 이해, 멀티모달 검색, RAG

SemArt와 ArtEmis는 작품 이미지와 설명·정서 언어 사이의 연결을 제공하지만 대화형 장기 개인화와 실제 관람 가능성까지 다루지는 않는다. CLIP 계열의 텍스트-이미지 표현과 DINOv2 계열의 시각 표현은 서로 다른 오류 특성을 갖는다. 따라서 ARTHÉMIS는 서로 다른 임베딩 공간의 벡터를 직접 더하지 않고 인덱스를 분리한 후 순위 수준에서 융합한다. RAG는 검색된 외부 근거를 생성 응답에 연결하지만, 본 연구는 작품 근거와 전시 상태 근거를 별도 층으로 관리한다.

2.3 연구 공백

기존 연구는 대화형 개인화, 장기 메모리, 시각 표현, 근거 연결 중 하나 또는 일부를 다룬다. ARTHÉMIS의 공백은 새로운 표현 학습 모델을 제안하는 것이 아니라, 예술 도메인의 암묵 선호와 다중 맥락을 기억하고, 독립 멀티모달 검색과 전시 수준 검증을 동일한 단계별 평가 구조로 묶는 데 있다.

3. 연구질문과 비교 설계 / Research Questions and Comparison Design

3.1 과업 정식화

사용자 u의 세션 열을 S_u = (S_u^(1), ..., S_u^(M))라 하고, 작품 코퍼스를 A, 시점 t에 열려 있는 전시 집합을 E(t)라 하자. 시스템은 현재 발화와 대화 이력, 장기 메모리, 작품 코퍼스, 전시 snapshot을 사용하여 행동 alpha_t, 순위화된 작품 목록 R_t, grounding record G_t, 응답 y_t를 생성한다.

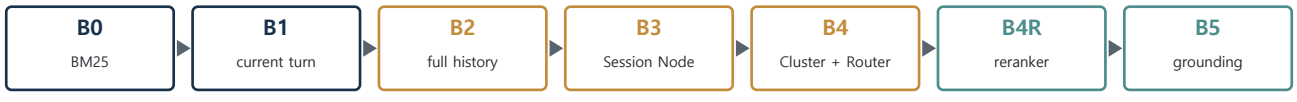
$$(\alpha_t, R_t, G_t, y_t) = \pi(x_{\le t}, y_{<t}, M_u, A, E(t))$$

여기서 R_t는 상위 K개의 작품 목록이며, G_t는 추천 카드에 연결된 전시 grounding record와 freshness 상태이다. 세션 종료 시 메모리는 M_u <- WRITE(M_u, S_u^(m))로 갱신된다. 이 정식화는 현재 맥락과 장기 취향의 정합성, 맥락 전환 시 선택적 억제, 확인된 필드에만 근거한 일정·장소 주장을 요구한다.

3.2 연구질문과 primary metric

RQ	검증 질문	주 비교	Primary metric	결과 상태
RQ1	계층형 장기 메모리가 현재 발화만 사용하는 조건보다 개인화 순위를 높이는가?	B1 vs B4	NDCG@10	TBD
RQ2	Cluster/Router가 전체 이력과 단일 요약보다 전환과 맥락 분리를 개선하는가?	B2/B3 vs B4; B4a/B4b 보조	CR@10	TBD
RQ3	Cross-encoder 재순위가 고정 후보의 상위 품질을 개선하는가?	B4 vs B4R	NDCG@5	TBD
RQ4	2층 grounding이 관람 가능성과 claim 검증을 개선하는가?	동일 R_10, B4R metadata vs B5 grounded output	Availability@10	TBD
RQ5	근거 기반 설명이 자유 생성보다 충실한가?	B5-E0 vs B5-E1; 검색/grounding 고정	Curator faithfulness	TBD

3.3 Ablation ladder



primary comparisons

RQ1: B1 vs B4 RQ2: B2/B3 vs B4 RQ3: B4 vs B4R RQ4: frozen B4R vs grounded B5

RQ5: B5-E0 vs B5-E1 with search and grounding fixed; V is a separate optional ablation.

그림 1. 인접 단계의 차이를 제한하여 모듈 기여를 분리하는 비교 구조. B4는 누적 memory block의 효과를, B4a와 B4b는 Cluster와 Router의 내부 기여를 보조적으로 분해한다. V(DINOv2) 인덱스는 B1+V 또는 B1+X+V의 별도 ablation으로 보고한다.

조건	추가 구성요소	해석
B0	BM25 metadata search; memory 없음	lexical baseline
B1	현재 발화 기반 T/X/L retrieval + RRF	current-turn retrieval
B2	B1 + 과거 대화 전체 이어붙이기	unstructured history
B3	B1 + Session Node 요약	session memory only
B4a	B3 + Taste Cluster	cluster-only support
B4b	B4a + Context Router	router contribution
B4	B4b; primary memory block	RQ1/RQ2 cumulative memory
B4R	B4 + cross-encoder reranker	RQ3
B5	B4R + exhibition grounding	RQ4; candidate rank frozen
B5-E0/E1	B5 fixed; free vs evidence-constrained explanation	RQ5 orthogonal ablation

B4R-B5 인과성 고정

RQ4에서는 B4R이 만든 동일한 candidate set과 순위를 먼저 고정한다. B5는 그 목록에 exhibition metadata와 상태 태그를 부착하고 claim을 제한한다. 전시 상태로 후보를 제거하거나 순위를 바꾸는 filter 효과는 별도 운영 실험으로 보고하며, grounding 효과와 혼합하지 않는다.

4. 제안 시스템 / Proposed System

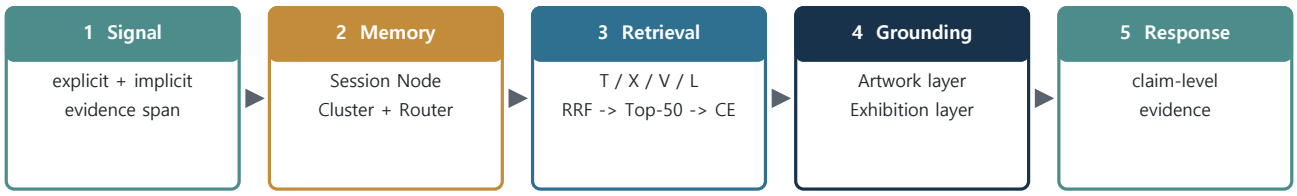


그림 2. ARTHÉMIS 파이프라인. 메모리와 검색, 작품층과 전시층을 분리하고, 같은 seed와 snapshot을 공유하는 paired evaluation으로 각 단계의 실패 경로를 추적한다.

4.1 미학 신호 추출

추출기는 발화에서 명시 신호와 암묵 신호를 분리한다. 명시 신호는 작가, 매체, 지역, 시간대, 동행자와 같은 직접 정보이고, 암묵 신호는 감상 동기, 조형 선호, 기피 조건, 해석 난이도 수용성과 같은 맥락 정보이다. 각 신호는 원 발화의 turn 번호와 evidence span, 불확실도, 시간 범위, consent scope를 함께 저장한다. 감정 상태의 원문은 장기 저장하지 않고 restoration, learning, experience와 같은 목적 수준으로 추상화한다.

4.2 계층형 장기 메모리

세션 종료 시 Session Node n_i = (summary_i, intent_i, visit_i, e_i, z_i, s_i, status_i)를 생성한다. e_i는 근거 발화이고 z_i는 요약과 AAT 기반 표현의 텍스트 임베딩이다. 노드 가중치는 최신성과 독립 평점을 사용하며, 추천 반응으로부터 평점을 만들 경우에는 독립 평점과 민감도 분석을 분리한다.

$$w_i = \exp(-\lambda \cdot \Delta t_i) \cdot (0.5 + 0.5 \cdot s_i), \quad \lambda = \ln(2) / h$$

새 노드와 클러스터 중심의 cosine similarity sigma를 기준으로 MERGE, BRIDGE, GENESIS를 판정한다. 초기값 tau_m = 0.78, tau_s = 0.50은 이식 가능한 상수가 아니라 개발 세트에서 보정할 대상이다. 경계 대역은 독립

검수로 판단하고 민감도 분석을 공개한다. GENESIS로 만든 클러스터는 tentative로 시작하고, 서로 다른 세션에서 재관찰될 때 active로 승격한다. 오래 사용되지 않은 클러스터는 stale, 명시적으로 부정된 선호는 suppressed로 기록하며 삭제와 억제를 구분한다.

판정(sigma) = MERGE if sigma >= tau_m; BRIDGE if tau_s <= sigma < tau_m; GENESIS if sigma < tau_s

Context Router는 모든 클러스터를 평균하지 않는다. 현재 질의 q_t와 맥락 슬롯 c_t에 대해 p(k | x_t) proportional to exp(eta * cos(q_t, mu_k) + b_k(c_t))를 계산한다. 불확실도가 rho 미만이면 추천보다 확인 질문을 우선한다. 현재 발화의 명시 요구는 기억보다 우선하며, 활성 프로필은 현재 질의와 선택 클러스터의 혼합으로 구성한다.

4.3 공간 분리 멀티모달 검색

T 인덱스는 해설문과 AAT 태그, X 인덱스는 다국어 text-image, V 인덱스는 기준 작품이 있을 때의 image-image, L 인덱스는 BM25 기반 고유명사·어휘 검색을 담당한다. 서로 다른 공간의 벡터를 직접 합산하지 않고 각 인덱스에서 순위를 반환한 후 RRF로 결합한다.

RRF(a) = sum over r of omega_r(type(x_t)) / (kappa + rank_r(a)), kappa = 60

RRF 상위 50개를 동일 후보 pool로 고정한 뒤 cross-encoder가 현재 발화, 활성 프로필, 작품 설명을 사용하여 상위 10개를 재순위한다. V 인덱스는 별도 ablation으로 평가한다. 탐색 슬롯은 모든 비교군에 동일하게 적용하되, 순위 품질 지표는 슬롯 삽입 이전 목록에서 계산하고 사용자 노출 지표는 삽입 이후 목록에서 계산한다.

4.4 Artwork-Exhibition 2층 grounding

Artwork Layer는 작가, 제작연도, 재료, 조형 특징, 작품 설명과 evidence span을 관리한다. Exhibition Layer는 전시명, 기관, 장소, 기간, 확인 시각, 전시 상태를 API snapshot으로 관리한다. 작품 단위 확인이 없는 경우 '작품이 전시 중'이라고 말하지 않고 '해당 전시에서 관람 가능성이 확인됨'처럼 전시 단위로 표현한다.

VERIFIED는 기준 freshness window 안에서 API로 확인된 상태, CACHED는 기준일이 명시된 직전 snapshot, UNVERIFIED는 일정·장소 claim을 생성할 수 없는 상태이다. 생성기는 VERIFIED 또는 허용된 CACHED 필드만 일정·장소·요금 claim에 사용할 수 있다.

m(a,e) = lambda_1 * artist_match + lambda_2 * cosine(f_T(a), f_T(e)) + lambda_3 * Jaccard(tags_a, tags_e)

위 정합도는 분석 또는 필터 규칙으로 사용될 수 있으므로, 적용 여부와 lambda, threshold를 사전에 고정하고 별도 운영 실험으로 보고한다. Availability는 추천 card, unique artwork, unique exhibition 중 어느 단위인지 결과표에 명시한다.

4.5 근거 기반 응답

각 추천 카드는 사용자의 연결 span, 작품 조형 근거, 전시 grounding record를 claim 단위로 포함한다. E0는 동일한 검색·grounding 결과를 받되 근거 필드를 제거한 자유 생성이고, E1은 evidence span과 상태 태그를 볼 수 있는 조건이다. 두 조건의 검색과 grounding을 고정하여 explanation faithfulness만 비교한다.

5. 실험 설계 / Experimental Protocol

5.1 데이터와 시뮬레이션

Golden Set은 natural_query, intent, expected_artwork, expected_artist, expected_context, expected_exhibition, expected_evidence, acceptable_alternatives를 가진다. 질의는 Easy, Medium, Hard로 나누고, Hard 사례에는 감각어와 공식 용어의 불일치, 다중 작품 비교, 취향 전환, 전시 실행 조건을 포함한다.

유형	시나리오	검증 대상
A 정서적 발견형	사조 어휘 없이 정서와 감각으로 질의; 5턴 안에 저채도·물질성 취향으로 수렴	암묵 신호 추출, 세션 내 수렴
B 다중 맥락형	본인 연구형 미디어아트와 자녀 체험형 전시를 교차 질의	라우팅 정확도, 맥락 오염
C 취향 전환형	구상 회화에서 4세션 이후 미디어·키네틱 설치로 전환	회복 턴, 구 취향 보존

계획된 합성 평가는 3 personas x 10 variants x 10 sessions = 300 sessions이다. 대화 생성, 신호 추출, 정답 판정은 서로 다른 모델 계열 또는 독립 절차로 분리하고, 정답 프로필과 전환 시점은 큐레이터 2인이 검수한다. 파일럿 목표는 20명이며, IRB 또는 면제 확인, 동의, 철회와 삭제 절차가 선행되어야 한다. 파일럿이 완료되지 않으면 시뮬레이션만 보고하고 외적 타당성의 범위를 제한한다.

5.2 지표 정의

층	지표	정의	계획값 / 실제 상태
Memory	Extraction F1	slot/span macro or micro F1; explicit와 implicit를 분리	>= 0.75 / >= 0.50 목표; 결과 TBD
Memory	Update accuracy	Keep/Add/Revise/Suppress 4범주 행동 정확도	>= 0.80 목표; 결과 TBD
Retrieval	Recall@50, NDCG@10, MRR	pooled candidate와 curator grade; primary는 RQ별 1개	목표/상태 TBD
Context	CR@10, T_rec	다른 맥락 정답만 포함한 직접 분율; 전환 후 회복 턴	<= 0.10 / <= 3 목표; 결과 TBD
Grounding	Availability@10, UCR	사전 고정한 card/artwork/exhibition 단위; claim 감사	B5 > B4R, UCR 0 목표; 결과 TBD
Explanation	Faithfulness, acceptability	claim-level blind curator rating; alpha	alpha >= 0.67 목표; 결과 TBD
Operations	p95, first token	동일 hardware/API/cache 정책에서 측정	<= 6s / <= 1.5s 목표; 결과 TBD

NDCG@K는 g_i in {0,1,2,3} 등급과 동일한 pooled candidate set에서 계산한다. 등급은 무관, 사조 일치, 조형·정서 일치, 맥락·실행까지 일치로 정의한다.

$$NDCG@K = (1 / IDCG@K) * \sum_{i=1}^{K} (2^{g_i} - 1) / \log_2(i + 1)$$

오염률은 purity의 보수가 아니라 오염된 추천 항목의 직접 분율로 정의한다. 현재 맥락을 c, 다른 맥락의 정답 집합을 G_not_c, 현재 맥락의 정답 집합을 G_c라 하면 다음과 같다.

$$CR@K = | R_K \cap (G_{not_c} \setminus G_c) | / |R_K|$$

Purity는 별도 지표로 보고한다. 이 구분은 원천 문서의 식과 명칭 사이의 불일치를 해소한다. T_rec은 전환 시점 이후 CR@10 <= 0.10이고 새 취향 Recall@10이 Oracle 대비 90%에 도달하기까지의 턴 수로 정의하되, Oracle 프로필과 threshold를 결과표에 기록한다.

5.3 통계와 재현성

모든 비교는 동일 사용자, 동일 seed, 동일 corpus/API snapshot의 paired design으로 수행한다. primary metric에 대해 paired bootstrap 95% CI와 효과크기를 보고하고, 순위 지표에는 permutation test를 보조적으로 사용한다. RQ1 NDCG@10, RQ2 CR@10, RQ3 NDCG@5, RQ4 Availability@10, RQ5 curator faithfulness의 5개 검정에 Holm 보정을 적용한다. 나머지 지표는 exploratory로 표시한다. 결과는 음의 방향이거나 불확정이어도 그대로 보고한다.

6. 결과 입력 템플릿 / Results Input Template

결과 보고 원칙

이 절의 빈칸은 실제 실험을 수행한 뒤에만 채운다. 계획값, exit gate, 목표 CI를 측정값으로 대체하지 않는다. 현재 버전은 본문 전체에서 실측 성능을 주장하지 않는다.

필드	입력
Corpus / institution / collection period	[INSTITUTION], [COLLECTION DATE], [SNAPSHOT ID/CHECKSUM]
Counts	artworks [ ], documents [ ], exhibitions [ ]
Models	T [ ], X [ ], V [ ], L/BM25 [ ], CE [ ], LLM [ ]
Runtime	CPU/GPU [ ], OS [ ], library commit [ ], temperature [ ], seed [ ]
API / freshness	API [ ], snapshot date [ ], VERIFIED window [ ], CACHED rule [ ]

필드	입력
Labels	curators [ ], train/dev/test split [ ], alpha/kappa [ ]

Condition	NDCG@10	CR@10	T_rec	Avail@10	UCR	Note
B1	[ ]	[ ]	n/a	n/a	n/a	current turn
B2	[ ]	[ ]	[ ]	n/a	n/a	full history
B3	[ ]	[ ]	[ ]	n/a	n/a	Session Node
B4a	[ ]	[ ]	[ ]	n/a	n/a	Cluster only
B4	[ ]	[ ]	[ ]	n/a	n/a	Cluster + Router
B4R	[ ]	[ ]	[ ]	[ ]	n/a	reranker; candidate fixed
B5	[ ]	[ ]	[ ]	[ ]	[ ]	grounding; rank fixed

통계 문장 템플릿: 'RQ[ ]에서 [condition A]의 [primary metric]은 [mean/median] = [ ] (95% CI [,])였고, [condition B]는 [ ] (95% CI [,])였다. paired difference는 [ ] (effect size [ ])이며 Holm 보정 후 p = [ ]이다. 따라서 [가설 채택/기각/불확정]으로 판단한다. 이 결과는 [simulated/pilot] 조건에서만 관찰되었으며, [주요 제한]이 있다.'

오류 taxonomy는 검색 실패 [ ]건, memory extraction [ ]건, wrong-context retrieval [ ]건, exhibition freshness [ ]건, unsupported claim [ ]건, explanation evidence mismatch [ ]건으로 기록하고, 각 사례에 query_id, stage, expected, observed, root cause, correction을 연결한다.

7. 위협, 윤리, 재현성 / Threats, Ethics, and Reproducibility

합성 대화는 상대 비교에는 유용하지만 실제 관람객의 미묘한 감정과 질문 개방성을 대표하지 않는다. 따라서 시뮬레이션 결과는 절대 성능이 아닌 조건 간 상대 비교로 해석하고, 시뮬레이터의 수락·거절과 파일럿 참여자의 판단 일치율을 별도로 보고한다. 20명 파일럿은 외적 타당성의 방향성 확인에 그치며 방문 행동의 일반 효과를 주장하지 않는다.

Getty AAT와 기관 해설문은 어휘·문화 편향을 가질 수 있다. 한국어 감각어 사전 구축 절차, long-tail 노출, 대안 작품의 문화적 범위를 별도 점검한다. API availability는 실제 방문의 대리 지표이며 입장, 이동, 운영시간, 현장 폐쇄를 보장하지 않는다.

정서 관련 메모리는 consent scope 안에서 목적 수준으로 추상화하고, 사용자의 열람·수정·삭제 경로와 보존기간을 명시한다. 원본 작품 이미지는 저장·재배포하지 않고 기관 링크와 허용된 임베딩만 보관한다. 파일럿은 IRB 심의 또는 면제 확인, 서면 동의, 익명화, 철회와 삭제 요청을 전제로 한다.

재현을 위해 corpus snapshot checksum, API 기준일, 모델 checkpoint, tokenizer, temperature, seed, hardware, latency policy, code commit, label split, inter-rater agreement를 결과와 함께 보존한다. 참고문헌 [1]-[28]의 DOI, proceedings, 저자·쪽수·연도는 최종 제출 전 공식 출판 페이지에서 외부 검증한다.

8. 결론 / Conclusion

ARTHÉMIS는 감각 언어와 기관 아카이브 사이의 의미 간극, 세션 간 취향의 휘발, 다중 맥락의 오염, 실행 불가능한 추천을 하나의 대화형 아트 큐레이션 설계 안에서 다룬다. 핵심 구조는 evidence-linked Session Node, Context Router가 선택하는 Curatorial Taste Cluster, 독립 멀티모달 인덱스의 rank fusion, Artwork-Exhibition 2층 grounding이다.

본 최종 통합본은 CR@K를 오염된 항목의 직접 분율로 교정하고, B4 내부 Cluster/Router 절제를 추가하며, B4R-B5에서 후보 순위를 고정하고, 작품·전시·추천 카드의 평가 단위를 분리했다. 그러나 실험이 완료되지 않은 현재 단계에서 이 설계는 성능 우월성을 주장하지 않는다. 후속 작업은 [B4 내부 ablation], [기관별 corpus와 API snapshot], [큐레이터 blind rating], [실관람 longitudinal study]를 수행하고, 본문의 TBD를 실제 측정값과 CI로 교체하는 것이다.

A. 제출 전 검증 장부 / Pre-submission Validation Ledger

검증 항목	현재 통합본 처리	남은 입력 또는 확인
계획값 vs 실측값	초록, 결과 절, 결론에 TBD와 planned 문구를 명시	실험 완료 후 결과 문장 교체
CR@K	오염 분율로 직접 정의; purity와 분리	정답 집합과 K 단위 확인
RQ4 인과성	B4R 후보·순위 고정 후 B5 metadata/claim 제약 비교	filter 효과 별도 실험
B4 귀속	B4a Cluster-only, B4b Router 보조 절제 추가	실험 budget에 반영
Availability	card/artwork/exhibition 단위를 결과표에 명시	최종 primary unit 선택
UCR	claim-level audit와 VERIFIED/CACHED/UNVERIFIED 규칙 명시	audit sample과 0건 여부 입력
References	세 문서의 [1]-[28] 목록을 통합	DOI/proceedings/metadata 외부 검증
Author metadata	소속·프로젝트·이메일 입력 placeholder 유지	제출 전 실제 값 입력

통합 판단

세 원천 PDF의 설계적 강점은 유지하되, 원본과 수정본 사이의 방법론적 충돌은 보수적으로 해소했다. 이 문서는 실제 결과를 대신하지 않으며, 결과가 입력될 때까지는 제출용 설계 논문으로만 해석되어야 한다.

R. 참고문헌 / References

[1] Achlioptas, P., Ovsjanikov, M., Haydarov, K., Elhoseiny, M., and Guibas, L. ArtEmis: Affective language for visual art. CVPR, 2021.

[2] Aliannejadi, M., Zamani, H., Crestani, F., and Croft, W. B. Asking clarifying questions in open-domain information-seeking conversations. SIGIR, 2019, pp. 475-484.

[3] Carbonell, J. and Goldstein, J. The use of MMR, diversity-based reranking for reordering documents and producing summaries. SIGIR, 1998, pp. 335-336.

[4] Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., and Liu, Z. BGE M3-Embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. arXiv:2402.03216, 2024.

[5] Chhikara, P., Khant, D., Aryan, S., Singh, T., and Yadav, D. Mem0: Building production-ready AI agents with scalable long-term memory. arXiv:2504.19413, 2025.

[6] Cormack, G. V., Clarke, C. L. A., and Buettcher, S. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. SIGIR, 2009, pp. 758-759.

[7] Efron, B. and Tibshirani, R. J. An Introduction to the Bootstrap. Chapman & Hall, 1993.

[8] Friedman, L. et al. Leveraging large language models in conversational recommender systems. arXiv:2305.07961, 2023.

[9] Garcia, N. and Vogiatzis, G. How to read paintings: Semantic art understanding with multi-modal retrieval. ECCV Workshops, 2018.

[10] Getty Research Institute. Art & Architecture Thesaurus (AAT) online. https://www.getty.edu/research/tools/vocabularies/aat/.

[11] Hayes, A. F. and Krippendorff, K. Answering the call for a standard reliability measure for coding data. Communication Methods and Measures, 1(1), 77-89, 2007.

[12] Holm, S. A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2), 65-70, 1979.

[13] Jannach, D., Manzoor, A., Cai, W., and Chen, L. A survey on conversational recommender systems. ACM Computing Surveys, 54(5), 2021.

[14] Jarvelin, K. and Kekalainen, J. Cumulated gain-based evaluation of IR techniques. ACM Transactions on Information Systems, 20(4), 422-446, 2002.

[15] Jiang, D. et al. From CLIP to DINO: Visual encoders in multi-modal large language models. arXiv:2310.08825, 2023.

[16] Kim, T., Lee, J., Yoon, S., Kim, S., and Lee, D. Towards personalized conversational sales agents: Contextual user profiling for strategic action. Findings of EMNLP, 2025, pp. 5131-5154.

[17] Maharana, A. et al. Evaluating very long-term conversational memory of LLM agents. ACL, 2024, pp. 13851-13870.

[18] Nogueira, R. and Cho, K. Passage re-ranking with BERT. arXiv:1901.04085, 2019.

[19] Oquab, M. et al. DINOv2: Learning robust visual features without supervision. arXiv:2304.07193, 2023.

[20] Radford, A. et al. Learning transferable visual models from natural language supervision. ICML, 2021, pp. 8748-8763.

[21] Robertson, S. E. and Zaragoza, H. The probabilistic relevance framework: BM25 and beyond. Foundations and Trends in Information Retrieval, 3(4), 333-389, 2009.

[22] Tschannen, M. et al. SigLIP 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features. arXiv:2502.14786, 2025.

[23] Wu, D. et al. LongMemEval: Benchmarking chat assistants on long-term interactive memory. ICLR, 2025.

[24] Xiao, J. et al. AlpsBench: An LLM personalization benchmark for real-dialogue memorization and preference alignment. SIGIR, 2026; arXiv:2603.26680.

[25] Xu, W. et al. A-MEM: Agentic memory for LLM agents. arXiv:2502.12110, 2025.

[26] Yao, S. et al. ReAct: Synergizing reasoning and acting in language models. ICLR, 2023.

[27] Zhang, B. et al. Learning to see through illumination extremes with event streaming in multimodal large language models. CVPR, 2026, pp. 26198-26208.

[28] Zheng, L. et al. Judging LLM-as-a-judge with MT-Bench and chatbot arena. NeurIPS Datasets and Benchmarks Track, 2023.

Reference note: the bibliography was harmonized from the reviewed source PDFs. DOI, proceedings status, author metadata, page ranges, and the 2025-2026 entries should be checked against official publication pages before final external submission.