ARTHÉMIS

장기 미학 대화 메모리와 멀티모달 전시 그라운딩 기반 대화형 아트 큐레이션 시스템의 설계 및 단계별 평가

Design and Stage-wise Evaluation of a Memory-Augmented Conversational Art Curation System with Multimodal Exhibition Grounding

---

중간논문 / Interim Research Paper
작성자: 추병곤 외
소속: [소속 입력] | 프로젝트: [프로젝트명/팀명 입력]
작성일: 2026년 9월

문서 상태
본 문서는 제공된 ARTHÉMIS 설계 자료와 평가 계획을 통합한 중간논문 초안이다. 실제 실험값이 확보되지 않은 항목은 [입력] 또는 TBD로 남겼으며, 목표값은 실측 결과와 구분하여 표기하였다.

초록 / Abstract

미술관과 공공 문화기관의 디지털 아카이브는 작품명, 작가, 제작연도, 재료와 같은 전문 메타데이터를 중심으로 구축되어 있어, "마음이 가라앉는 거친 질감의 그림"과 같이 감각적·상황적 언어로 작품을 탐색하는 일반 관람객의 요구와 의미론적 간극이 존재한다. 또한 기존 대화형 시스템은 세션 간 선호를 구조적으로 기억하지 못하거나 서로 다른 관람 맥락을 하나의 사용자 프로필에 혼합할 수 있으며, 추천된 작품이 실제로 현재 관람 가능한지 검증하지 못한다. 본 연구는 이러한 문제를 해결하기 위해 Aesthetic Session Node와 Curatorial Taste Cluster 기반의 계층형 장기 메모리, 텍스트·비전 임베딩 공간을 분리한 멀티모달 검색 및 순위 융합, 공공 전시정보 API를 이용한 작품-전시 2층 그라운딩을 결합한 대화형 아트 큐레이션 시스템 ARTHÉMIS를 제안한다. 시스템의 효과를 모듈별로 검증하기 위해 BM25 기반 B0에서 전체 시스템 B5까지 단계적으로 기능을 추가하는 Ablation Ladder를 구성하고, 메모리 추출·갱신·검색·활용, 취향 전환 회복, 맥락 오염, 추천 순위, 관람 가능성 및 근거 기반 설명의 충실성을 독립적으로 평가한다. 중간 단계에서는 세 가지 사용자 유형을 변형한 300개 멀티세션 시뮬레이션과 실관람객 파일럿을 이용한 평가 프로토콜을 구축하고 있으며, 실제 성능값은 실험 완료 후 동일한 평가 틀에 따라 보고할 예정이다. 본 연구는 단순한 예술 추천 성능 향상뿐 아니라, 지각-기억-검색-행동-검증-설명 전 과정을 추적 가능한 형태로 평가하는 공공 문화기관용 개인화 AI 연구 프레임워크를 제시하는 데 목적이 있다.

English Abstract. ARTHÉMIS is a conversational art curation system designed to bridge the gap between affective, context-sensitive visitor language and structured museum records. It combines hierarchical long-term memory, separated multimodal retrieval indexes with rank fusion, and a two-layer grounding architecture that distinguishes artwork discovery from exhibition-level visitability verification. The study proposes a stage-wise evaluation protocol from BM25 retrieval (B0) to the full system (B5), covering memory extraction, update, retrieval, utilization, preference switching, context contamination, ranking quality, availability, and evidence-grounded explanation. The interim paper reports the system design and evaluation plan while explicitly reserving unmeasured results as input fields or TBD. The planned evaluation consists of 300 multi-session simulations and a pilot with real visitors; these are experimental targets rather than completed results.

Keywords: Conversational Recommender System, Long-term Memory, Multimodal Retrieval, Art Recommendation, Personalization, Retrieval-Augmented Generation, Tool Grounding, Museum AI

> 실험값 표기 원칙
> 이 논문에서 300개 세션, 20명 파일럿, Extraction F1 >= 0.75, 오염률 <= 0.10, p95 <= 6초 등은 제안된 실험 규모·초기 목표·exit gate이다. 완료된 실측값으로 해석해서는 안 되며, 결과표의 TBD를 대체할 수 없다.

1. 서론 / Introduction

1.1 연구 배경과 산업적 문제 / Background and Motivation

미술관 디지털 서비스는 검색 가능한 소장품 데이터베이스, 온라인 전시, 모바일 도슨트, 이미지 기반 탐색으로 확장되어 왔다. 그러나 다수의 시스템은 작품명, 작가명, 시대, 재료, 사조 등 전문 메타데이터를 입력하는 방식을 전제로 한다. 이 방식은 이미 찾고 싶은 작품이나 작가를 알고 있는 이용자에게는 효율적이지만, 자신의 정서와 감각을 바탕으로 작품을 발견하려는 관람객에게는 높은 탐색 장벽이 된다.

예를 들어 이용자가 "색이 요란하지 않고 표면의 물질감이 묵직한 그림 앞에 가만히 있고 싶다"고 말했을 때, 발화에는 저채도, 물질성, 명상성, 촉각성, 자극 회피, 관람 목적이라는 복합 신호가 포함된다. 하지만 기관의 기록은 이러한 신호를 그대로 필드로 제공하지 않는다. ARTHÉMIS는 이 불일치를 관람객의 감각 언어와 기관의 아카이브 언어 사이의 semantic gap으로 정의한다.

두 번째 문제는 세션 변동성과 다중 맥락이다. 한 사용자는 평일에는 혼자 조용히 감상할 회화를 찾고, 주말에는 자녀와 함께 체험할 인터랙티브 미디어 전시를 찾을 수 있다. 과거 발화를 하나의 장기 프로필에 단순 누적하면 상이한 목적과 동행자 정보가 섞여 맥락 오염이 발생한다. 따라서 장기 메모리는 많은 내용을 보존하는 기능이 아니라, 현재 상황에 적합한 기억을 선택하고 필요할 때 억제하는 기능이어야 한다.

세 번째 문제는 추천과 실제 관람의 단절이다. 알고리즘적으로 적합한 작품이 수장고에 있거나 전시가 종료되었다면 사용자가 지금 경험할 수 있는 추천이 아니다. 또한 생성형 모델이 전시명, 기간, 전시실, 요금을 확인 없이 생성하면 사용자 신뢰가 직접적으로 훼손된다. 이에 본 연구는 작품을 발견하고 설명하는 Artwork Layer와 공공 전시정보를 이용해 실행 가능성을 검증하는 Exhibition Layer를 분리한다.

> 핵심 문제 정의
> 일상적인 감각 언어로 표현된 관람객의 미적 요구를 구조화하고, 시간에 따른 취향 변화와 다중 관람 맥락을 기억하면서, 실제 관람 가능한 전시 정보에 근거한 개인화 추천과 설명을 제공할 수 있는가?

1.2 연구 목적과 기여 / Objectives and Contributions

본 연구는 장기 메모리, 멀티모달 검색, 도구 기반 사실 검증을 하나의 대화형 미술 추천 파이프라인 안에서 통합하고, 구성요소의 기여를 단계적으로 검증하는 것을 목적으로 한다. 연구의 기여는 다음 세 가지로 정리된다.

- 예술 도메인 특화 계층형 장기 메모리: 세션별 근거 발화를 Aesthetic Session Node로 저장하고, 반복적으로 관찰되는 성향을 Curatorial Taste Cluster로 조직하여 현재 맥락에 맞는 활성 프로필을 선택한다.
- 공간 분리 멀티모달 검색과 2층 그라운딩: 텍스트와 이미지 임베딩을 부적절하게 직접 합산하지 않고 독립 인덱스의 순위를 RRF로 융합하며, 작품 발견과 전시 실행을 분리한다.
- 단계별 평가 프레임워크: 최종 만족도 하나가 아니라 Extraction-Update-Retrieval-Utilization, 취향 전환, 맥락 오염, 관람 가능성, 근거 기반 설명을 독립적으로 측정한다.

Table 1. 연구 문제와 ARTHÉMIS의 대응 구조

연구 문제	기존 방식의 한계	ARTHÉMIS 대응	주요 지표
의미론적 간극	전문 키워드 중심 탐색	감각어-조형어 매핑 + 멀티모달 검색	Recall@K, NDCG@K
세션 단절	세션마다 초기화	Session Node 기반 장기 기억	Extraction F1, Recall
다중 맥락	단일 사용자 프로필	Taste Cluster + Context Router	Contamination Rate
취향 변화	과거 취향 고착 또는 무분별 삭제	잠정 클러스터·감쇠·재활성화	Recovery Turns
실행 불가능 추천	소장품과 전시 상태 혼동	Artwork -> Exhibition 2층 grounding	Availability@K
생성형 환각	일정·장소 자유 생성	API 검증 + freshness 표시	Unverified Claim Rate
설명 불투명	근거 없는 자유 생성	Evidence span 기반 설명	Faithfulness

2. 선행연구 / Related Work

2.1 대화형 추천과 LLM 기반 사용자 프로필 / Conversational Recommendation

대화형 추천시스템은 사용자의 명시적 평점뿐 아니라 대화 과정에서 드러나는 선호, 제약, 의도를 추론하고 후보를 좁히는 방향으로 발전해 왔다. 자연어 사용자 프로필을 검색·추천 과정에 활용하는 접근은 개인화 과정의 해석 가능성을 높인다는 장점이 있다. 그러나 예술 감상은 구매 목적의 단일 선호보다 느리고 가변적이며, 같은 사용자가 서로 다른 관람 맥락을 오간다는 점에서 프로필의 시간성과 맥락성을 명시적으로 다뤄야 한다.

2.2 검색 증강 생성과 재순위화 / Retrieval-Augmented Generation and Reranking

RAG는 생성 모델의 응답을 외부 문서 검색 결과에 연결하여 최신성·근거성 문제를 완화하는 대표적 패러다임이다. ARTHÉMIS는 검색 증강을 단순한 설명 문서 추가가 아니라, 작품 후보와 전시 상태를 별도의 근거 계층으로 분리하는 방식으로 적용한다. BM25와 dense retrieval은 서로 다른 오류 특성을 가지므로, 텍스트(T), cross-modal(X), visual(V), lexical(L) 인덱스를 분리하고 Reciprocal Rank Fusion으로 순위를 결합한다. 상위 후보에 대해서는 재순위화 모델 또는 경량 cross-encoder를 적용하되, 실제 모델과 버전은 실험 시 [입력]으로 기록한다.

2.3 멀티모달 표현학습 / Multimodal Representation Learning

CLIP은 자연어와 이미지 사이의 의미 정렬을 학습하여 텍스트로 시각 개념을 검색하는 데 활용될 수 있다. DINOv2 계열 표현은 이미지의 형태·구성·질감 유사성을 포착하는 시각 표현으로 활용된다. 두 표현공간의 좌표를 직접 더하면 서로 다른 거리 구조를 잘못 결합할 수 있으므로, 본 연구는 각 표현을 독립적인 검색기와 인덱스로 유지하고 ranking-level fusion만 수행한다.

2.4 에이전틱 장기 메모리와 연구 공백 / Agentic Long-term Memory

최근 에이전틱 메모리 연구는 기억을 고정된 요약문이 아니라 새 관찰과 기존 기억의 연결·갱신·진화가 가능한 구조로 다룬다. ARTHÉMIS는 이러한 문제의식을 예술 감상에 맞게 변환한다. 한 번의 감상 대화는 Session Node가 되고, 반복 관찰된 성향은 Taste Cluster가 되며, 라우터는 현재 목적·동행자·시간 맥락에 따라 활성 클러스터를 선택한다. 본 연구의 공백은 장기·다중 맥락의 미학 기억과 실제 전시 가능성 검증을 하나의 추천 시스템에서 함께 평가한다는 점에 있다.

Table 2. 주요 선행연구 흐름과 본 연구의 차별성

연구 흐름	핵심 아이디어	ARTHÉMIS의 차용	확장 또는 한계
대화형 추천	대화에서 선호를 추론하고 후보를 좁힘	자연어 프로필과 질문 정책	예술 감상의 느린 선호 변화 반영
RAG	검색 근거를 생성 모델에 연결	작품·전시 evidence 분리	설명과 실행 정보의 2층 grounding
CLIP	텍스트-이미지 의미 정렬	감각 언어 기반 후보 검색	시각 유사성은 별도 인덱스로 유지
DINOv2	비지도 시각 표현	형태·구성·질감 보조 검색	표현공간 직접 합산을 배제
A-MEM	동적 연결과 기억 진화	Session Node와 Cluster 발상	예술 취향·맥락 라우팅으로 특화
MCP	도구·리소스·프롬프트의 표준 인터페이스	검색·조회·검증·설명 도구화	연구 성능과 인터페이스 계층 분리

3. 연구질문과 가설 / Research Questions and Hypotheses

ARTHÉMIS의 성능을 하나의 총점으로 표현하면 특정 모듈의 실패 원인을 알 수 없다. 따라서 본 연구는 검색·메모리·그라운딩·설명에 관한 연구질문을 분해하여, 동일한 시드와 동일한 평가 사례에서 단계적으로 검증한다.

Table 3. Research Questions, Hypotheses and Tests

RQ	Research Question	Hypothesis	비교 조건	주요 지표
RQ1	계층형 장기 메모리가 현재 발화만 사용하는 방식보다 개인화 추천을 개선하는가?	H1: Memory-On이 No-Memory보다 추천 적합도와 회상률이 높다.	B1 vs B4	NDCG@10, Recall@20
RQ2	Taste Cluster와 Context Router가 전체 대화 누적보다 취향 전환과 다중 맥락을 잘 처리하는가?	H2: B4가 B2/B3보다 전환 후 회복이 빠르고 오염률이 낮다.	B2/B3 vs B4	Recovery Turns, Contamination

RQ	Research Question	Hypothesis	비교 조건	주요 지표
RQ3	독립 인덱스와 재순위화가 단일 검색보다 상위 후보 품질을 개선하는가?	H3: Reranking과 RRF가 NDCG와 MRR을 높인다.	B1/B4 vs B4+R	NDCG@5, MRR
RQ4	전시 그라운딩이 추천의 관람 가능성과 사실성을 개선하는가?	H4: 2층 grounding이 Availability를 높이고 미검증 일정 주장을 줄인다.	B4+R vs B5	Availability@10, UCR
RQ5	근거 기반 설명이 자유 생성보다 신뢰·충실성·수용도를 높이는가?	H5: Evidence span 설명이 blind 평가에서 더 높은 점수를 받는다.	Free vs Evidence	Faithfulness, Acceptability

4. 제안 시스템 / Proposed System

4.1 전체 시스템 아키텍처 / Overall Architecture

ARTHÉMIS는 사용자의 자연어 발화를 미학 신호, 현재 관람 목적, 시간·동행자 맥락으로 해석한 뒤, 기억과 검색을 결합하여 작품 후보를 찾는다. 추천을 확정하기 전에는 작품 자체의 설명 근거와 전시 실행 정보를 서로 다른 계층에서 확인한다. 이 설계는 "이 작품이 지금 걸려 있다"라는 과도한 약속 대신, "이 취향에 맞는 검증된 전시가 지금 열려 있다"라는 더 보수적이고 감사 가능한 약속을 가능하게 한다.

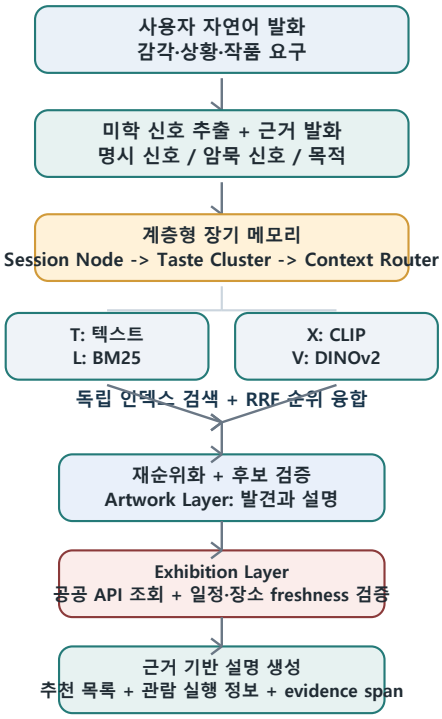


Figure 1. ARTHÉMIS 시스템 아키텍처. 사용자의 감각 언어를 미학 신호로 구조화하고, 계층형 메모리와 독립 멀티모달 인덱스를 거친 뒤 작품층과 전시층을 분리하여 검증한다.

4.2 미학 신호 추출과 근거 발화 / Aesthetic Signal Extraction

추출기는 한 발화에서 명시 신호와 암묵 신호를 분리한다. 명시 신호는 작가, 매체, 지역, 시간, 전시 유형처럼 직접 말해진 정보이며, 암묵 신호는 정서, 감상 목적, 선호 강도, 난이도, 자극 회피, 동행자와 같은 맥락적 정보이다. 각 신호에는 원 발화의 evidence span과 불확실도, 시간 범위, 사용자 동의 상태를 함께 저장한다. 시스템은 정서적 상태를 진단하거나 민감한 정보를 무제한 장기 보존하지 않으며, 저장 필요성이 낮은 정보는 추상화하거나 세션 범위로 제한한다.

4.3 계층형 장기 메모리 / Hierarchical Long-term Memory

Session Node는 한 번의 대화나 관람 세션에서 추출된 선호·비선호·목적·근거 발화를 담는다. Taste Cluster는 여러 Session Node에서 반복 관찰되는 안정적 성향과 서로 충돌하는 성향을 묶는다. Context Router는 현재 질의, 동행자, 방문 목적, 시간적 단서와 과거 cluster의 활성도를 비교하여 한 개 또는 소수의 cluster만 활성화한다. 새 관찰은 Keep, Add, Revise, Suppress 중 하나의 갱신 연산으로 기록하며, 취향 전환이 감지되면 기존 cluster를 삭제하기보다 감쇠시키고 재활성화 가능 상태로 남긴다.

4.4 검색과 순위 융합 / Retrieval and Rank Fusion

검색 계층은 T(text embedding), X(cross-modal embedding), V(visual embedding), L(lexical BM25) 인덱스로 분리된다. 각 인덱스는 서로 다른 근거를 제공하므로, 벡터 자체를 합산하지 않고 후보의 순위를 RRF로 융합한다. 이후 상위 후보에 대해 미학 적합도, 현재 활성 cluster, 작품 설명 가능성, 메타데이터 완결성을 이용하여 재순위화한다. 실제 가중치와 모델 버전은 실험 로그에 고정하고 [입력]으로 기록한다.

4.5 작품층-전시층 2층 그라운딩 / Artwork-Exhibition Two-layer Grounding

Artwork Layer는 작품 이미지, 작가, 제작연도, 재료, 조형적 특징 및 설명의 근거를 다룬다. Exhibition Layer는 공공기관 API 또는 기관 제공 데이터에서 전시명, 장소, 시작·종료일, 확인 시각, 전시 상태를 조회한다. 작품 API가 작품별 현재 전시 여부를 제공하지 않는 경우 작품을 전시 중이라고 단정하지 않고, 전시 단위의 관람 가능성만 보고한다. 상설전처럼 작품 단위 확인이 가능한 경우에만 그 근거와 확인 시각을 함께 표기한다.

4.6 MCP 도구 계층 / MCP Tool Layer

MCP는 본 연구의 성능을 자동으로 보장하는 모델이 아니라, 검색·메타데이터 조회·전시 상태 검증·추천 후보 반환·설명 생성에 필요한 기능을 독립 도구로 노출하는 인터페이스 계층이다. Agent는 도구 호출 전후의 입력, 선택된 후보, API 응답, 오류 및 근거 span을 감사 로그로 남긴다. 이 구조를 통해 시스템 내부의 검색 알고리즘과 외부 클라이언트의 연결을 분리하고, 향후 다른 에이전트나 사용자 인터페이스에서도 동일한 검증된 기능을 재사용할 수 있다.

5. 실험 설계 / Experimental Setup

5.1 평가 데이터와 Golden Set / Evaluation Data and Golden Set

Golden Set은 사용자의 자연어 질의와 정답 후보, 정답 근거, 필수 메타데이터, 전시 검증 상태, 적절한 설명 수준을 함께 보유하는 평가 단위이다. 각 사례는 query_id, natural_query, intent, expected_artwork, expected_artist, expected_context, expected_exhibition, expected_evidence, acceptable_alternatives 필드를 가진다. 질의는 Easy, Medium, Hard로 나누며, Hard 사례에는 감각어와 공식 도메인 용어의 불일치, 다중 작품 비교, 취향 전환, 전시 실행 조건을 포함한다.

중간 단계의 계획된 합성 평가는 세 가지 사용자 유형을 변형하여 3 personas x 10 variants x 10 sessions = 300 sessions로 구성한다. A는 미술사 전문용어가 없고 정서적 발견을 원하는 사용자, B는 본인 연구와 자녀 체험처럼 서로 다른 목적을 교차하는 사용자, C는 구상 회화에서 미디어 설치로 취향이 전환되는 사용자이다. 합성 대화의 명시성을 낮추기 위해 암묵 표현을 전체 대화의 40% 이상 포함하도록 설계하며, 생성·추출·평가 모델을 분리한다. 이 수치는 계획 규모이며, 실제 완료 세션 수는 [입력]이다.

Table 4. Golden Set의 기본 스키마

필드	내용	검증 방식
query_id	질의 식별자 및 난이도	중복·누락 검사
natural_query	사용자 원문과 변형	표현 다양성 검토
intent	탐색·비교·추세·조건부 방문	주석자 합의

필드	내용	검증 방식
expected_artwork	허용 정답 작품 집합	큐레이터 라벨
expected_context	정서·동행자·목적·시간	근거 span 대조
expected_exhibition	전시명·기관·기간·장소	API snapshot 대조
expected_evidence	설명에 인용되어야 하는 근거	evidence precision
acceptable_alternatives	정답과 동등한 후보	사전 정의 및 큐레이터 검토

5.2 구현 환경과 재현성 / Implementation and Reproducibility

데이터 수집 기간, 기관별 API 버전, 작품 이미지 전처리, 임베딩 모델명과 버전, 재순위화 모델, LLM 모델과 temperature, top-k, RRF 상수, 캐시 정책, 하드웨어, 운영체제 및 소프트웨어 버전은 실험 완료 시 부록의 실행 기록에 기입한다. 현 단계의 구현 환경은 다음과 같이 기록한다: 데이터 원천 [입력], 이미지 수 [입력], 텍스트 문서 수 [입력], GPU/CPU [입력], 임베딩 모델 [입력], LLM [입력], API snapshot 기준일 [입력].

재현성 체크포인트
동일한 질의·seed·후보 집합·API snapshot을 사용하지 않으면 메모리와 검색 모듈의 기여를 분리하기 어렵다. 따라서 결과표에는 모델 버전뿐 아니라 평가 snapshot ID와 실행 로그 위치도 함께 기록한다.

6. 베이스라인과 Ablation Ladder / Baselines and Ablation Ladder

단순히 최종 시스템만 평가하면 어떤 구성요소가 효과를 냈는지 알 수 없다. ARTHÉMIS는 BM25 하한선에서 시작하여 한 번에 하나의 모듈을 추가하는 단계적 ladder를 사용한다. 모든 단계는 동일한 질의, 동일한 후보 corpus, 동일한 seed와 동일한 평가 라벨을 사용한다.

Table 5. Baseline / Ablation Ladder

ID	구성	검증하려는 질문	주요 비교
B0	BM25 메타데이터 키워드 검색, 메모리 없음	기존 미술관 웹 검색 수준의 하한선은 무엇인가?	B0 vs B1
B1	멀티모달 dense 검색, 현재 발화만 사용	멀티모달 검색 자체가 기여하는가?	B1 vs B2/B4
B2	B1 + 과거 대화 전체 이어붙이기	구조 없는 기억은 도움인가, 소음인가?	B2 vs B3/B4
B3	B1 + Session Node 요약, cluster 없음	요약 노드만으로 전환을 처리할 수 있는가?	B3 vs B4
B4	B1 + Session Node + Taste Cluster + Context Router	계층형 기억과 맥락 분리가 오염을 줄이는가?	B4 vs B2/B3
B5	B4 + 재순위화 + 전시 grounding + 근거 설명	전체 제안 구조가 실행 가능성과 설명을 개선하는가?	B4+R vs B5
Oracle	정답 프로필과 정답 후보 집합	데이터·모델의 이론적 상한은 무엇인가?	각 단계 ceiling

6.1 통제와 통계 검정 / Controls and Statistical Tests

모든 비교는 동일한 테스트 사례에 대한 paired evaluation으로 수행한다. 결과는 평균 하나만 제시하지 않고 95% bootstrap confidence interval, 효과크기, 사례별 분포를 함께 보고한다. 평가자 순서와 시스템 라벨은 무작위화하며, LLM judge를 사용할 경우 생성 모델, 추출 모델, 평가 모델을 분리한다. 큐레이터 평가의 일치도는 Krippendorff's alpha 또는 사전에 정한 대체 지표로 보고하며, 해당 값은 실측 후 [입력]으로 남긴다.

7. 평가 프로토콜 / Evaluation Protocol

7.1 단계별 평가 지표 / Stage-wise Metrics

평가는 Memory Lifecycle, Retrieval, Grounding, Explanation의 네 층으로 나눈다. Memory Lifecycle에서는 명시·암묵 신호를 구분한 Extraction F1, Keep/Add/Revise/Suppress update accuracy, 활성 cluster retrieval recall, 현재 질의에 맞는 utilization 여부를 측정한다. Retrieval에서는 Recall@K, MRR, NDCG@K를 사용한다. Grounding에서는 Availability@K, verified evidence precision, Unverified Claim Rate를 계산한다. Explanation에서는 근거 충실성, 설득력, 접근성, 세렌디피티를 5점 척도로 평가한다.

핵심 정의는 다음과 같다. Extraction F1은 정답 미학 신호와 추출 신호의 조화 평균이며, Availability@K는 상위 K개 추천 중 평가 시점에 전시층 근거로 관람 가능하다고 확인된 항목의 비율이다. Unverified Claim Rate(UCR)는 응답에 포함된 일정·장소·전시 상태 주장 중 API snapshot 또는 기관 근거로 확인되지 않은 주장의 비율이다. 이 값은 "환각 0%"처럼 시스템 전체를 과장하는 표현 대신, 감사 표본 내 미검증 주장 수와 함께 보고한다.

Table 6. 단계별 평가 지표와 현 단계 상태

평가 층	지표	정의 또는 관찰 대상	현 단계 상태
Memory	Extraction F1	명시/암묵 미학 신호 추출 조화 평균	목표 >= 0.75 / 결과 TBD
Memory	Update Accuracy	Keep/Add/Revise/Suppress 결정 정확도	목표 >= 0.80 / 결과 TBD
Memory	Recovery Turns	취향 전환 후 적합 후보 회복까지 턴 수	목표 <= 3 / 결과 TBD
Retrieval	Recall@50, NDCG@10, MRR	정답 또는 허용 후보의 검색·순위 품질	B4 > B2 검정 / 결과 TBD
Context	Contamination Rate	현재 목적과 무관한 과거 cluster가 추천에 미치는 비율	목표 <= 0.10 / 결과 TBD
Grounding	Availability@10	전시층 근거로 확인된 상위 후보 비율	결과 TBD
Grounding	UCR	검증되지 않은 일정·장소 주장 비율	감사 표본 / 결과 TBD
Explanation	Faithfulness / Acceptability	근거 일치·수용도·접근성·세렌디피티	큐레이터 alpha / 결과 TBD
Operations	p95 / first token	전체 응답시간 / 스트리밍 첫 토큰	목표 <= 6초 / <= 1.5초

7.2 평가 파이프라인 / Evaluation Pipeline

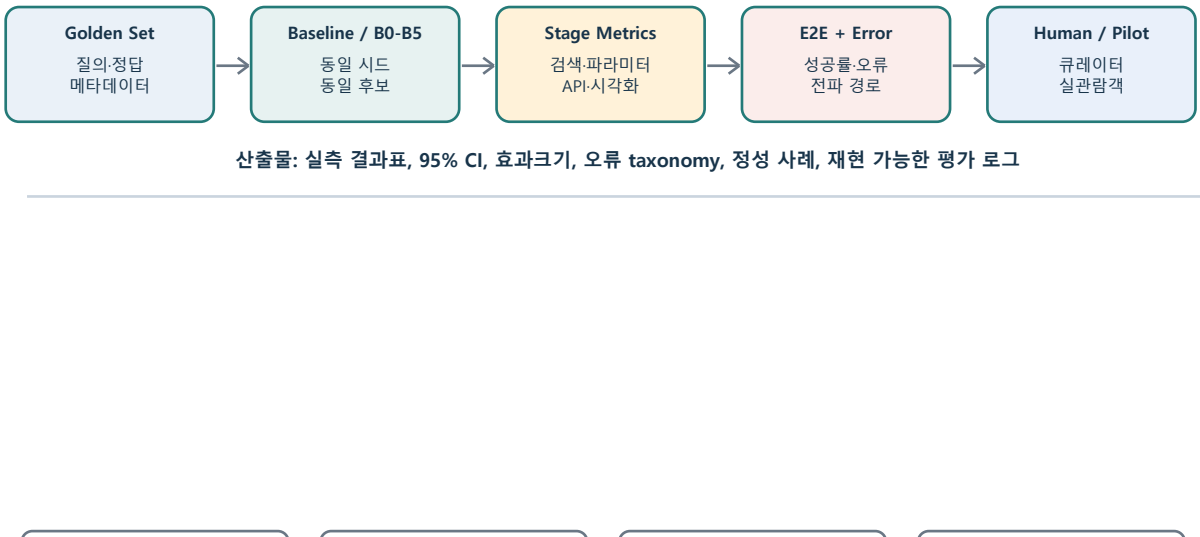


Figure 2. 평가 파이프라인. Golden Set과 동일한 시드·후보·snapshot을 각 baseline에 공급하고, 단계별 지표와 E2E 결과를 분리한 뒤 오류 전파와 사람 평가로 교차 검증한다.

8. 중간 결과 / Interim Results

현재 제공 자료에는 B0-B5의 실제 실험값이 보고되어 있지 않다. 따라서 다음 표는 제출 시 결과를 입력할 수 있는 고정 양식이다. 목표값은 연구 설계상의 exit gate이며, 통계적 유의성 또는 목표 달성을 의미하지 않는다.

Table 7. Interim Results Input Sheet

조건	Recall@50	NDCG@10	MRR	Extraction F1	UCR	p95 (s)
B0 BM25	TBD	TBD	TBD	N/A	N/A	TBD
B1 Dense	TBD	TBD	TBD	TBD	N/A	TBD
B2 Full history	TBD	TBD	TBD	TBD	N/A	TBD
B3 Session Node	TBD	TBD	TBD	TBD	N/A	TBD
B4 Cluster + Router	TBD	TBD	TBD	TBD	TBD	TBD
B5 Proposed	TBD	TBD	TBD	TBD	TBD	TBD
Oracle	TBD	TBD	TBD	N/A	N/A	N/A

결과 입력 지침
실험 완료 후 TBD를 교체할 때에는 평균만 쓰지 말고 표본 수 n, 95% CI, paired bootstrap 또는 사전 등록된 검정, 효과크기, 평가 snapshot ID를 함께 기록한다. 목표를 달성하지 못한 경우에도 값을 삭제하거나 목표값으로 대체하지 않고 그대로 보고한다.

8.1 정성 평가 사례 양식 / Qualitative Case Template

정성 평가는 성공 사례만 선별하지 않고 성공·검색 실패·E2E 실패를 각각 포함한다. 각 사례에는 사용자 발화, 추출된 미학 신호, 활성 cluster, 검색 후보, 선택된 전시 근거, 최종 설명, 오류 단계, 평가자의 판정 근거를 함께 기록한다.

Case A - 성공
감각 표현이 공식 기록과 안정적으로 연결되고, 추천 작품과 전시 실행 정보가 모두 검증되는 사례. 기록할 값: query_id [입력], evidence span [입력], selected artwork [입력], verified exhibition [입력].

Case B - 검색 실패
사용자 표현과 공식 도메인 용어가 다른 사례. 예: "집 같은 따뜻함"이 특정 색채·재료·장르 후보로 이어지지 않는 경우. 검색기별 후보와 실패 원인을 비교한다.

Case C - E2E 실패
작품 검색에는 성공했지만 기간·단위·전시 상태·근거 중 하나가 맞지 않아 최종 응답을 보류하거나 정정하는 사례. 단계별 오류 전파를 설명하는 데 사용한다.

9. 논의 / Discussion

9.1 왜 단계별 평가가 필요한가 / Why Stage-wise Evaluation Matters

통계나 추천 에이전트의 최종 응답만 평가하면 실패 원인이 검색인지, 기억 선택인지, 전시 정보의 freshness인지, 설명 생성인지 구분되지 않는다. ARTHÉMIS는 관람객의 감각 언어를 구조화하는 단계부터 후보 검색, 전시 검증, 설명 생성까지를 개별 상태로 기록한다. 따라서 E2E 실패율이 높을 때에도 어느 모듈의 개선이 전체 성능에 가장 큰 영향을 줄지 판단할 수 있다.

9.2 메모리는 개인화를 높이지만 오염 위험도 높인다 / Memory Improves Personalization but Adds Contamination Risk

장기 메모리는 이전 대화의 설명력을 이어가는 데 유리하지만, 모든 기억을 동일하게 적용하면 현재 관람 목적과 충돌한다. B2는 전체 대화를 이어붙이는 단순한 기억이 도움인지 소음인지 검증하는 조건이며, B4는 cluster와 router를 통해 선택적 기억을 사용하는 조건이다. H2가 지지된다면 개인화는 기억의 양보다 활성화 정책과 억제 정책에 더 크게 의존한다는 해석이 가능하다. 지지되지 않는 경우에도, 계층 구조의 복잡성이 추가 이득을 만들지 못하는 조건을 보고할 수 있다.

9.3 실행 가능성은 작품 정확도와 별개의 품질 축이다 / Actionability is a Separate Quality Axis

작품 검색이 정확해도 전시가 종료되었거나 장소가 불명확하면 관람객의 행동으로 이어지지 않는다. 그러므로 작품 적합도와 전시 실행 가능성은 하나의 점수로 합치기보다 별도 지표로 관리해야 한다. 이 논문은 Availability@K와 UCR을 독립 보고하고, 확인할 수 없는 정보는 "현재 확인되지 않음"으로 표시하는 보수적 응답 정책을 채택한다.

10. 한계와 윤리 / Limitations and Ethics

10.1 연구 한계 / Limitations

- Golden Set의 규모와 범위가 제한되어 특정 미술 장르, 기관, 언어 표현에 편중될 수 있다.
- 합성 대화는 실제 관람객보다 명시적이고 일관된 신호를 포함할 위험이 있으므로, 실관람객 파일럿과 교차 검증해야 한다.
- 미학적 적합도와 세렌디피티는 부분적으로 주관적이며, 큐레이터 라벨의 합의 수준이 결과에 영향을 준다.
- 공공 전시 API의 메타데이터 변화와 지연 때문에 동일한 추천도 조회 시점에 따라 달라질 수 있다.
- 이미지 저작권이 있는 작품은 원본 이미지의 무단 재배포를 피하고, 필요 시 임베딩·링크·기관 허용 범위만 보관한다.
- 정서, 번아웃, 동행자 등 민감할 수 있는 정보는 최소 수집·목적 제한·사용자 열람·수정·삭제권의 대상이 된다.

10.2 윤리적 운영 원칙 / Ethical Operation

ARTHÉMIS는 사용자의 취향을 진단하거나 고정된 정체성으로 규정하지 않는다. 취향 표현은 벡터가 아니라 사용자가 읽고 수정할 수 있는 가설적 프로필과 원 발화 근거로 설명한다. 사용자는 저장되는 메모리의 범위와 보존 기간을 확인하고, 특정 기억을 삭제하거나 해당 세션을 장기 기억에서 제외할 수 있어야 한다. 추천 다양성을 위해 전체 상위 후보를 선호로 채우지 않고 일정 비율의 탐색 슬롯을 둔다는 설계는 필터버블 완화에 도움을 줄 수 있지만, 그 비율과 노출 효과는 실험으로 검증해야 한다. 전시 일정과 장소는 확인 시각을 표시하고, 확인되지 않은 내용을 사실처럼 표현하지 않는다.

11. 향후 연구 / Future Work

향후 작업은 기능 목록이 아니라 연구질문 검증 순서로 진행한다. 첫째, Golden Set v1을 확정하고 큐레이터 라벨의 합의도를 산출한다. 둘째, B0-B4의 Retrieval 및 Memory Lifecycle 결과를 확보하여 메모리 복잡성이 실제 이득을 만드는지 확인한다. 셋째, 재순위화와 전시 grounding을 통합하여 B5의 Availability와 UCR을 측정한다. 넷째, 동일한 사례를 대상으로 근거 기반 설명과 자유 생성 설명의 blind 평가를 수행한다. 마지막으로 MCP 서버를 외부 클라이언트에 연결하고, 도구 호출 실패·API 지연·데이터 갱신에 대한 복원력과 운영 비용을 평가한다.

후속 실험의 우선순위
(1) Retrieval baseline 실측, (2) 메모리 전환·오염 평가, (3) 전시 API snapshot과 freshness 검증, (4) 큐레이터·실관람객 교차 평가, (5) E2E 오류 전파 및 비용 분석

12. 결론 / Conclusion

본 연구는 감각적·상황적 언어로 표현된 관람객의 요구를 작품 데이터와 전시 실행 정보로 연결하는 대화형 아트 큐레이션 시스템 ARTHÉMIS의 설계와 평가 프로토콜을 제안했다. 시스템은 Session Node와 Taste Cluster를 이용한 계층형 장기 메모리, T/X/V/L 독립 인덱스와 RRF 기반 멀티모달 검색, Artwork Layer와 Exhibition Layer를 구분하는 2층 grounding, 그리고 MCP 기반 도구 계층을 결합한다.

중간논문의 핵심은 완성된 추천 성능을 주장하는 데 있지 않다. 자연어 이해, 메모리 갱신, 검색, 재순위화, 관람 가능성 검증, 설명 생성이 서로 다른 실패 지점을 가진다는 사실을 연구 설계에 반영하고, B0-B5의 단계별 비교와 300개 시뮬레이션·20명 파일럿 계획을 통해 각 기여를 검증할 수 있는 틀을 마련한 데 있다. 실제 실험값이 확보되면 본 문서의 TBD 필드를 교체하고, confidence interval·효과크기·오류 사례와 함께 최종 결과를 보고한다.

핵심 결론
예술 추천 에이전트의 신뢰성은 그럴듯한 설명을 생성하는 능력만으로 결정되지 않는다. 사용자의 감각 언어를 근거와 함께 구조화하고, 현재 맥락에 맞는 기억을 선택하며, 실제 전시 가능성을 확인한 뒤, 확인된 근거만으로 설명하는 전체 경로가 추적 가능해야 한다.

참고문헌 / References

[1] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., et al. (2021). Learning Transferable Visual Models From Natural Language Supervision. arXiv:2103.00020.

[2] Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., et al. (2023). DINOv2: Learning Robust Visual Features without Supervision. arXiv:2304.07193.

[3] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems, 33.

[4] Robertson, S., & Zaragoza, H. (2009). The Probabilistic Relevance Framework: BM25 and Beyond. Foundations and Trends in Information Retrieval, 3(4), 333-389.

[5] Cormack, G. V., Clarke, C. L. A., & Buettcher, S. (2009). Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods. Proceedings of SIGIR, 758.

[6] Nogueira, R., & Cho, K. (2019). Passage Re-ranking with BERT. arXiv:1901.04085.

[7] Xu, W., Liang, Z., Mei, K., Gao, H., Tan, J., & Zhang, Y. (2025). A-MEM: Agentic Memory for LLM Agents. arXiv:2502.12110.

[8] Anthropic. (2024-2026). Model Context Protocol Documentation. https://docs.anthropic.com/en/docs/mcp (accessed 2026-09-22).

[9] ARTHÉMIS Project Team. (2026). ARTHÉMIS 최종 제안서·발표대본·Q&A.; Unpublished project materials.

[10] ARTHÉMIS Project Team. (2026). ARTHÉMIS 원안 검토 노트 및 평가 설계. Unpublished project materials.

[11] RAM-CRS Research Notes. (2026). RAM-CRS 통합 분석 보고서. Unpublished methodological report provided with the project materials.

참고문헌 [9]-[11]은 본 프로젝트에서 제공된 내부 자료이며, 외부 학술 출판물로 오인되지 않도록 명시하였다. 본문에서 언급된 목표값과 실험 규모는 해당 내부 설계 자료에서 가져온 계획값이다.