ARTHÉMIS

맥락 분리형 장기 취향 메모리 기반 대화형 AI 아트 큐레이션

통합 마스터 에디션

논문 · 시스템 · 평가 · OpenAI API 구현 · 사업화 · 발표/심사 대응 · 최종 실행 로드맵

기준 문서	arthemis_interim_v3.pdf / ARTHÉMIS 논문 심사 및 최종 준비 로드맵.pdf / ARTHÉMIS SDU Business Competition 제출용 완성본.pdf
통합 원칙	학술 정합성은 중간논문 v3를 기준으로 고정하고, 로드맵의 구현 레시피와 사업계획서의 시장/발표 논리를 연결한다. 실측되지 않은 성능 수치는 성과로 재사용하지 않는다.

작성 기준일 2026-09-23 | 작성자 추병곤 (Byeonggon Choo)

목차

목차 2

0. 통합 원칙과 문서 권위 체계 5

0.1 출처별 역할 . . . 5

0.2 충돌 사항과 정본 결정 . . . 5

0.3 상태 라벨 . . . 5

1. 통합 Executive Summary 6

1.1 세 가지 문제 - 하나의 시스템 . . . 6

1.2 연구와 사업의 연결 . . . 6

1.3 이번 6주의 성공 조건 . . . 6

2. 학술 연구의 정본: 문제 정의, 연구 질문, 기여 7

2.1 연구 문제 . . . 7

2.2 Research Question와 사전 지정 가설 . . . 7

2.3 핵심 기여 . . . 7

2.4 원안 대비 다운사이징의 학술적 의미 . . . 7

3. 비교 조건과 절제 사다리 8

3.1 학술 정본 조건 . . . 8

3.2 사업/발표용 조건명과 논문 조건의 매핑 . . . 8

4. Two-Agent 시스템 설계 8

4.1 전체 흐름 . . . 9

4.2 Agent A - Aesthetic Signal Extractor . . . 9

4.3 Session Node와 Taste Cluster . . . 9

4.4 Context Router . . . 9

4.5 Agent B - Retrieval . . . 10

4.6 Two-layer Exhibition Grounding . . . 10

5. OpenAI API와 조건부 Fine-tuning 10

5.1 기본 원칙 . . . 10

5.2 학습 데이터 계약 . . . 10

5.3 구현 워크플로우 . . . 10

6. 평가 설계와 통계 프로토콜 11

6.1 데이터와 페르소나 . . . 11

6.2 고정 스크립트 재생 . . . 11

6.3 핵심 지표 . . . 11

6.4 라벨링과 신뢰도 . . . 12

6.5 통계 분석 . . . 12
6.6 결과 보고 템플릿 . . . 12
7. 감사 로그, 실패 분류, Go/No-Go 12
7.1 턴 단위 감사 로그 . . . 12
7.2 실패 분류 . . . 12
7.3 Go/No-Go 질문 . . . 13
8. 6주 실행 로드맵과 마일스톤 13
8.1 제출·발표 마일스톤 . . . 13
9. 구현 청사진: 저장소, Streamlit, 데모 14
9.1 저장소 구조 . . . 14
9.2 최소 실행 명령 . . . 14
9.3 Streamlit 프로토타입 화면 . . . 14
9.4 60초 시연 시나리오 - 정본 수정안 . . . 14
10. 사업화 전략: 시장, STP, SWOT, BM 15
10.1 최종 사업 주제 . . . 15
10.2 사업 아이디어 20개 포트폴리오 . . . 16
10.3 시장·경쟁 구도 . . . 16
10.4 STP와 Persona . . . 17
10.5 SWOT . . . 17
11. 비즈니스 모델과 재무 가설 17
11.1 BM Canvas . . . 17
11.2 가격 가설 [PROPOSED] . . . 18
11.3 6주 사업 검증 예산 [PROPOSED] . . . 18
12. 제출용 서사, 12장 피치, 발표 대본 18
12.1 제출용 사업계획서 핵심 문안 . . . 18
사업 개요 . . . 18
문제 인식 . . . 18
AI 활용 . . . 19
실행 . . . 19
위험관리 . . . 19
12.2 12장 발표 구조 . . . 19
12.3 5분 발표 대본 - 정본 버전 . . . 20
13. 심사위원 예상 질문 20개와 답변 21
14. 한계, 윤리, 위험관리 22
14.1 연구 한계 . . . 22
14.2 개인정보·정서·저작권 . . . 22

14.3 제품 위험 레지스터 . . . 22
15. 최종 제출 체크리스트와 Master Decision Gate 22
15.1 학술 제출 체크리스트 . . . 23
15.2 사업/공모전 체크리스트 . . . 23
15.3 Master Gate . . . 23
부록 A. 재현성 기록 양식 23
부록 B. 결과 서술 템플릿 24
부록 C. 용어 사전 24
부록 D. 학술 참고문헌 (중간논문 v3 기준) 24
부록 E. 사업 문서의 웹 근거 목록 25
통합 결론 . . . 25

0. INTEGRATION GOVERNANCE

0. 통합 원칙과 문서 권위 체계

세 문서를 단순 병합하지 않고, 충돌하는 버전과 실측 전 수치를 정리해 하나의 “정본”으로 만든다.

정본의 우선순위	① 학술 설계와 평가는 arthemis_interim_v3.pdf를 최우선으로 사용한다. ② 사업화·시장·STP·BM·발표 구조는 SDU Business Competition 문서를 사용한다. ③ OpenAI API, Streamlit, 파인튜닝, 구현 레시피는 논문 심사 및 최종 준비 로드맵의 아이디어를 참조하되, v3와 충돌하면 v3를 따른다.

0.1 출처별 역할

코드	문서	이 통합본에서의 역할
[A]	arthemis_interim_v3.pdf	학술 정본. 문제 정의, H1/H2, B1/B2/B4(+B3), B4-U, Srec, 통계, 게이트, 감사 로그, 재현성 계약의 기준.
[B]	ARTHÉMIS_SDU_Business_Competition_제출용_완성본.pdf	사업 정본. 시장·경쟁사·STP·SWOT·BM·가격 가설·공모전 제출 문안·5분 피치·Q&A의 기준.
[R]	ARTHÉMIS 논문 심사 및 최종 준비 로드맵.pdf	구현 참고본. OpenAI API 파인튜닝 워크플로우, Streamlit 프로토타입, 인제스천/그라운딩 구현, 심사 공격질문 등의 레시피.

0.2 충돌 사항과 정본 결정

쟁점	기존 표현	정본 근거	통합 결정
성능 수치	[R]에는 100회 실험 결과, NDCG/UCR 성과처럼 쓰인 문장이 존재	[A]는 모든 결과칸을 미측정으로 유지	실측 결과 없음. 이 통합본에서는 [R]의 성과 수치를 삭제하고 TO-MEASURE로 처리.
비교 조건	[B]는 B1-B5, [R]은 B0-B5/M0-M3 등 복수 사다리	[A]는 B1/B2/B4, B3 선택, B4-U 감사	학술 실험은 [A] 사다리. B5는 “grounding 적용 B4”라는 사업 설명용 별칭으로만 사용.
회복 지표	[B]/구버전은 Trec(턴)	[A]는 메모리가 세션 종료 시 갱신됨을 반영해 Srec(세션 시작 체크포인트)	논문/정량평가에는 Srec. 발표에서 Trec를 쓰지 않도록 수정.
검색	[R] 일부는 BGE-M3+SigLIP/DINO/cross-encoder	[A]는 텍스트 임베딩 T + BM25 L의 RRF만 본실험	멀티모달/재순위는 post-study 단일 절제로 유보.
파인튜닝	[R] 일부는 Agent A와 B 모두 FT	[A]는 Extractor만 조건부 SFT, 생성기 FT 금지	Fine-tuning은 E-P vs E-FT 추출기 비교에 한정.
모델 ID/가격	[R]/[B]에 특정 스냅샷·비용 표현	[A]는 G0에서 지원/자격을 실제 작업 생성으로 검증	모델명·가격은 실행 시 재확인. 문서에 고정값을 성과처럼 박지 않음.
grounding 상태	[R] 데모는 VERIFIED/CACHED/UNVERIFIED	[A] 평가는 동결 스냅샷이므로 VERIFIED@snapshot	평가와 데모의 상태 체계를 분리하여 설명.

0.3 상태 라벨

- [SOURCE] 제공 파일이 직접 지지하는 사실 또는 설계.
- [WEB-VERIFIED] 사업계획서가 2026-09-23에 웹 검증했다고 명시한 시장/경쟁 사실. 이 통합본은 그 검증 결과를 재검색하지 않고 출처 상태를 그대로 보존.

- [PROPOSED] 가격, TAM/SAM/SOM, 목표 사용자 수, KPI 등 사업 가설.
- [TO-MEASURE] 실제 실험·파일럿 이후에만 채울 성능값. 결과표에서 공란을 유지.

PART I. EXECUTIVE SYNTHESIS

1. 통합 Executive Summary

ARTHÉMIS의 연구 질문, 제품 가치, 검증 방법, 사업모델을 한 페이지 논리로 연결한다.

한 문장 정의	ARTHÉMIS는 관람객이 미술 용어 대신 감각과 상황으로 말한 선호를 근거와 함께 기억하고, “혼자 보기”와 “가족과 보기” 같은 맥락을 섞지 않은 채 작품을 추천하며, 실제 방문정보는 확인된 전시 레코드의 필드만 말하는 대화형 AI 아트 큐레이터다.

1.1 세 가지 문제 - 하나의 시스템

단절	사용자/기관의 문제	ARTHÉMIS의 대응	측정/통제
의미 단절	관람객은 “묵직한 질감, 조용한 느낌”으로 말하지만 아카이브는 작가·연도·재료 중심.	Aesthetic Signal Extractor + 감각어-조형어 사전 + 질의 재작성	추출 F1, span F1, schema validity
기억 단절	평일 혼자 관람과 주말 가족 관람이 하나의 프로필에 섞임.	Session Node -> Taste Cluster -> Context Router -> 선택 프로필 Phi	CR@10, NDCG@10, Srec
실행 단절	추천된 작품이 실제 전시 중인지, 일정/장소/요금이 맞는지 불확실.	Artwork Layer와 Exhibition Layer 분리, claim whitelist, 검증기	UCR, VCC, 감사 로그

1.2 연구와 사업의 연결

연구 언어	제품 언어	기관 구매 언어
Session Node	회차별 감상 기록	기존 이용자 경험을 세션 단위로 추적
Taste Cluster	반복되는 취향 패턴	재방문/세그먼트 이해를 위한 구조화된 선호
Context Router	오늘 필요한 취향만 선택	동행·목적 변화에 따른 잘못된 개인화 감소
Two-layer grounding	추천 이유와 실제 관람정보 분리	정보 오류/민원 리스크 통제
Audit log + prereg	재현 가능한 평가	품질 리포트·기관 검수·감사 가능성

1.3 이번 6주의 성공 조건

- 작동하는 end-to-end 데모.
- fresh clone에서 재현되는 코드와 고정 설정.
- H1/H2와 탐색 지표의 실제 측정값, 사용자 단위 95% CI.
- 감사 로그에 연결된 실패 사례와 수정 커밋.

절제 원칙	네 조건이 충족되기 전에는 멀티모달 인덱스, cross-encoder, 다기관 코퍼스, 생성기 fine-tuning 같은 확장 모듈을 복귀시키지 않는다. 다운사이징은 기능 포기가 아니라 변수 통제다.

PART II. ACADEMIC CORE

2. 학술 연구의 정본: 문제 정의, 연구 질문, 기여

중간논문 v3의 핵심을 기준으로 RQ-Baseline-Ablation-Metric의 정합성을 고정한다.

2.1 연구 문제

공공 미술관/예술 플랫폼의 메타데이터와 관람객의 감각·상황 언어 사이에는 semantic gap이 있다. LLM 기반 CRS는 이 번역 간극을 줄일 수 있지만, 장기 개인화에서는 "기억을 많이 넣는 것" 자체가 성능을 보장하지 않는다. 핵심 질문은 어떤 기억을 언제 활성화할 것인가이다.

2.2 Research Question와 사전 지정 가설

RQ	감상 맥락별로 분리·선택되는 구조화 취향 메모리는, 무기억 LLM 및 과거 대화 전체를 투입하는 방식에 비해 다른 맥락 취향의 혼입을 줄이고 개인화 순위 품질을 높이는가?

ID	비교	지표	방향	대상/지위
H1	B2 -> B4	CR@10	낮아짐	B형 전체 + C형 전환 후 체크포인트 / 확증
H2	B1 -> B4	NDCG@10	높아짐	전체 사용자 / 확증
G	B2 vs B4	NDCG@10	비열등	B4가 무관 작품으로 CR만 낮추는 퇴화 해 방지 / 가드
E1	B1/B2/B4	Srec	낮아짐	C형 취향 전환 / 탐색
E2	B4-U -> B4	UCR↓, VCC↑	감사	동일 R10에서 발화 제약의 효과 / 탐색
E3	E-P vs E-FT	추출 F1	높아짐	추출 시험 세트 / 탐색
E4	B2 -> B3 -> B4	CR@10	분해	B3 수행 시 요약 효과와 라우팅 효과 분해 / 탐색

2.3 핵심 기여

- C1. 맥락 분리형 계층 취향 메모리: evidence span을 보존하는 Session Node, MERGE/GENESIS/SUPPRESS 규칙의 Taste Cluster, 현재 맥락만 활성화하는 Context Router.
- C2. 귀속 가능한 통제 비교 프로토콜: 검색기·생성기·코퍼스·스냅샷·스크립트를 고정하고, 공유 질의 재작성 프롬프트의 메모리 슬롯 Phi만 조건 간 변경.
- C3. 역할 특화 추출 에이전트: prompt/few-shot 추출기(E-P)와 조건부 OpenAI SFT 추출기(E-FT)를 독립 시험 세트에서 비교하고 본실험 전에 하나를 동결.

2.4 원안 대비 다운사이징의 학술적 의미

초기 원안은 다기관 데이터, 텍스트-이미지/이미지-이미지 인덱스, cross-encoder, 복수 LLM, 사용자 파일럿을 한 주기에 결합했다. v3는 이를 "기능 축소"가 아니라 인과 귀속 가능한 변수 통제로 재정의한다. 본실험에서 T(텍스트 임베딩)와 L(BM25)만 사용하고, 멀티모달과 재순위는 주 실험 이후 단일 절제로 복귀한다.

3. 비교 조건과 절제 사다리

3.1 학술 정본 조건

조건	메모리 슬롯 Phi(Mu, xt)	grounding	해석
B1	없음. 현재 세션 발화만.	적용 필수	무기억 baseline
B2	과거 세션 전사를 최신순으로 연결, Lmax에서 절단.	적용 필수	구조 없는 “기억 많이 넣기” baseline
B3	xt와 유사한 상위 k개 Session Node 요약, 라우팅 없음.	선택	요약 효과 분해용 선택 조건
B4	Router가 선택한 Taste Cluster 기술문 + evidence 인용.	적용 필수	제안 방법
B4-U	B4의 R10을 그대로 동결하고 슬롯/검증기를 해제해 방문정보 자유 생성.	해제	grounding 제약 감사용

3.2 사업/발표용 조건명과 논문 조건의 매핑

사업 문서 표기	정본 해석	사용 규칙
B5	B4에 grounding record + claim constraint를 적용한 상태	논문에서는 별도 실험 조건으로 만들지 않고 B4의 기본 상태로 취급.
B4-U	동일 R10에서 grounding만 해제	UCR/VCC 감사용으로 유지.
M0-M3	구버전 구현/데모 단계	발표 흐름 설명에는 쓸 수 있으나 논문 확증 가설의 조건으로 사용하지 않음.
B0-B5 / B4a/B4b	초기 절제안	부록의 연구 진화 이력으로만 보존. v3의 단순화된 설계가 정본.

중요 동일 추천 목록 R10을 유지한 상태에서 grounding 발화 제약만 바꿔야 UCR 변화의 원인을 그라운딩에 귀속할 수 있다. 추천 목록까지 바꾸면 검색 효과와 그라운딩 효과가 섞인다.

PART III. SYSTEM ARCHITECTURE

4. Two-Agent 시스템 설계

Agent A는 취향과 맥락을 구조화하고, Agent B는 작품 검색과 전시 그라운딩을 수행한다. 조건 간 유일한 차이는 프로필 블록 Phi다.

4.1 전체 흐름

단계	처리	산출물
1. 입력	관람객 발화 xt + 최근 세션 이력	감각·상황 언어
2. Agent A / Extract	고정 JSON schema + evidence span 검사	명시/암묵 선호, motive, companion, avoid
3. Memory / Router	Session Node -> Taste Cluster -> Context Router	활성 클러스터 k*, 프로필 블록 Phi
4. Query rewrite	공유 프롬프트에 Phi를 한 슬롯으로 투입	정제 질의 x-tilde
5. Agent B / Retrieve	T dense + L BM25 -> RRF Top-10	추천 목록 R10
6. Ground	Artwork Layer와 Exhibition snapshot 연결	grounding record Gamma
7. Generate + Validate	확인 필드만 슬롯 템플릿, 미지지 문장 제거	최종 응답 y + removed_sentences
8. Audit	query/model/prompt/snapshot/seed/score 기록	재현 가능한 JSONL 감사 로그

4.2 Agent A - Aesthetic Signal Extractor

추출기는 현재 발화, 최근 k턴, 감각어-조형어 사전 후보를 입력으로 받아 고정 JSON을 출력한다. schema 검증에 실패하면 1회 재시도하며, evidence span이 원문에 없으면 해당 신호를 폐기한다. 정서 원문은 장기 저장하지 않고 회복/사유/학습/체험 같은 감상 목적 수준으로 추상화한다.

```
{ "explicit": {"artist": [], "medium": [], "visit_time": "weekday_eve", "companion": "alone"}, "implicit":
{"motive": "■■", "formal": {"color": "low_saturation", "texture": "rough"}, "avoid": ["vivid_color"]},
"evidence": [{"turn": 3, "span": "■■ ■■■ ■ ■■"}, {"turn": 3, "span": "■■■ ■■■"}], "confidence": 0.0 }
```

4.3 Session Node와 Taste Cluster

세션 종료 시 Session Node n_i = (summary_i, intent_i, visit_i, e_i, z_i, s_i)를 생성한다. e_i는 근거 발화, z_i는 텍스트 임베딩, s_i는 만족도다. 본실험에서는 만족도가 조건 효과와 얽히지 않도록 s_i=0.5로 고정하고 스크립트 만족도 사용은 민감도 분석으로 둔다.

```
■■ ■■■: w_i = exp(-nu * delta_t_i) * (0.5 + 0.5 * s_i), nu = ln(2)/h, ■■ h=30■
```

규칙	조건	동작
MERGE	새 노드와 최근접 클러스터 유사도 sigma >= tau_m	기존 클러스터에 편입하고 중심/기술문 갱신
GENESIS	sigma < tau_m 또는 기존 후보 없음	새 tentative 클러스터 생성
ACTIVATE	서로 다른 n_act=2 세션에서 재관찰	tentative -> active
SUPPRESS	명시적 부정 선호	삭제가 아니라 suppressed 상태로 두어 명시적 거부를 보존

4.4 Context Router

모든 클러스터를 평균하지 않고, active/tentative 후보 중 현재 질의 의미 유사도와 방문 맥락 일치도를 결합해 하나를 선택한다. 라우터 불확실성이 높으면 추천을 강행하지 않고 확인 질문을 최대 1회 트리거한다.

```
router logit: l_k = eta * cos(q_t, mu_k) + theta * match_k(c_t) profile block: Phi = desc(k*) +
evidence(k*) ■■■(■■■■ ■■): eta=10, theta=2, rho=0.5; tau_m ■■ 0.78
```

4.5 Agent B - Retrieval

공유 질의 재작성 프롬프트가 현재 발화, 현재 세션 이력, Phi로부터 정제 질의를 생성한다. 검색은 텍스트 임베딩 T와 한국어 BM25 L을 독립적으로 수행하고 RRF로 융합한다. BM25는 고유명사·작품명·재료를, dense retrieval은 감각 언어와 해설문의 의미 유사도를 보완한다.

```
RRF score(a) = SUM_{r in {T,L}} 1 / (kappa + rank_r(a)), kappa=60; ■■ 10■■ R_t■ ■■
```

4.6 Two-layer Exhibition Grounding

작품 층은 “왜 이 작품인가”를, 전시 층은 “어디서 볼 수 있는가”를 답한다. 평가에서는 동결 snapshot E_eval을 사용하고, 데모에서만 VERIFIED/CACHED/UNVERIFIED의 신선도 상태를 운용한다. 전시 API가 전시 단위이므로 작품 출품이 입증되지 않은 경우 “이 작품이 전시 중”이라고 말하지 않고 “이 취향에 맞는 전시가 열려 있다”로 약속 단위를 낮춘다.

필드	정본 규칙
기간/장소/요금	snapshot field를 채우는 슬롯 템플릿으로만 출력
source_url / checked_at / snapshot_id	grounding record에 항상 보존
자유 서술 중 방문 주장	검증기가 support 여부를 확인하고 미지지 문장을 제거
작품 이미지	초기 Core는 원본 저장/재배포를 필수로 하지 않음
평가 상태	VERIFIED@snapshot으로 고정. 신선도 비교는 데모 운영 기능.

5. OpenAI API와 조건부 Fine-tuning

5.1 기본 원칙

- fine-tuning을 기본값으로 두지 않는다. prompt + few-shot + JSON schema + validator + eval을 먼저 완성한다.
- SFT 대상은 고정 JSON을 내는 Extractor에 한정한다. 생성기 전체를 튜닝하면 메모리 효과와 생성 모델 효과가 섞인다.
- 지원 모델, 조직 자격, deprecation, 가격은 변할 수 있으므로 G0에서 실제 10개 예제로 job 생성 가능 여부를 확인한다.
- E-P와 E-FT는 같은 독립 시험 세트에서 명시/암묵 micro-F1, span F1, schema validity, latency/cost를 비교한다.

5.2 학습 데이터 계약

구성	내용
형식	Chat-style JSONL. system=과업 계약, user=현재 발화+최근 k턴+사전 후보, assistant=고정 schema JSON.
계획 규모	train 200-300, validation 50, test 60. 수치는 계획값이며 실행 후 실제 파일 수 기록.
원천	연구자 시드 발화, 평가에서 제외한 A형 페르소나 스크립트, 다른 모델 계열의 증강 변형.
누수 방지	평가 사용자 발화는 학습에 넣지 않으며, 원천 스크립트 단위로 분할하고 해시 목록으로 검증.
채택 규칙	암묵 F1 차이의 원천 스크립트 군집 bootstrap 95% CI 하한이 0보다 크면 E-FT. 0 포함 시 비용/지연이 낮은 쪽.

5.3 구현 워크플로우

```
1) Prepare train/valid/test JSONL and validate each line 2) G0: create a tiny 10-example job to verify eligibility and supported base model 3) Upload training file with purpose="fine-tune" 4) Create SFT job with BASE_MODEL=<G0 confirmed snapshot> 5) Record job_id, file_id, model_id, epochs, prompt hash 6) Run E-P vs E-FT extractor benchmark 7) Freeze selected extractor before main experiment
```

실행 안전장치	로드맵 문서의 특정 모델명/가격/“수 분” 같은 표현은 당시 구현 참고용이다. 최종 실행 문서에는 G0에서 확인한 실제 snapshot과 job ID만 남긴다.

PART IV. EVALUATION & STATISTICS

6. 평가 설계와 통계 프로토콜

성능 수치보다 먼저 “무엇을 고정하고 무엇만 바꿀지”를 명확히 한다.

6.1 데이터와 페르소나

항목	정본
작품 층	MMCA 공개 데이터의 메타데이터와 해설문. 수집 경로/이용조건/작품수/해설문수/체크섬을 기록.
전시 층	문화포털 공연·전시 API를 평가 시작 시점에 1회 동결한 snapshot E_eval. 기준일/전시수/체크섬 기록.
통합 스키마	artwork, exhibition, link, lexicon 4개 테이블.
B형	평일 혼자 사유형 관람과 주말 자녀 동반 체험형 관람을 세션마다 교차.
C형	구상 회화 선호에서 3번째 세션 도중 미디어/키네틱 설치 선호로 전환.
A형	사조 어휘 없이 정서/감각어만 사용. 추출기 개발 전용, 본 평가 제외.
분할	개발 6-12명, 평가 20-30명 계획. 사용자 단위 분할. 평가 스크립트는 시스템 실행 전에 동결.

6.2 고정 스크립트 재생

조건마다 대화형 시뮬레이션을 새로 돌리면 시스템 응답에 따라 사용자 발화가 달라져 메모리 효과와 대화 경로 효과가 섞인다. 따라서 페르소나별 다중 세션 스크립트를 한 번 생성·검수·동결하고, 모든 조건이 같은 이력과 같은 체크포인트에서 검색 결과를 비교한다. 체크포인트는 세션의 첫 추천 턴으로 둔다.

6.3 핵심 지표

지표	정의	해석
CR@10	Top-10 중 현재 맥락 Pc에는 속하지 않고 다른 맥락 Pc_bar에만 적합한 작품의 직접 분율.	다른 맥락 취향의 오염. 낮을수록 좋음.
NDCG@10	큐레이터 등급 g=0/1/2/3에 기반한 순위 품질. 모든 조건 Top-10 교차 풀링 판정.	맞는 작품을 위에 배치하는가. 높을수록 좋음.
Srec	전환 후 세션 시작 체크포인트에서 CR<=0.10과 P@10_new>=pi0를 연속 두 번 만족하는 최초 세션 index.	취향 전환을 몇 세션 만에 따라잡는가. 낮을수록 좋음.
UCR	방문 주장 중 grounding record가 지지하지 않는 주장 비율.	일정/장소/요금 등 환각. 낮을수록 좋음.
VCC	grounding에 값이 있는 검증 가능 field 대비 실제로 지지된 주장 비율.	침묵만으로 UCR을 낮추는 회피를 감시. 높을수록 좋음.
Extractor F1	명시/암묵 micro-F1 + evidence span F1 + schema validity.	E-P vs E-FT 비교용 탐색 지표.

```
CR@K = (1/K) * |{a in R_K : a in P_cbar \ P_c}|, K=10
```

```
UCR = unsupported_visit_claims / all_visit_claims VCC = supported_claims / verifiable_grounding_fields
```

6.4 라벨링과 신뢰도

- 각 평가 질의에서 모든 조건의 Top-10을 합쳐 무작위 순서로 판정한다.
- 평가자는 persona card와 현재 체크포인트까지의 스크립트를 보고 g 등급과 “다른 맥락 적합” 여부를 함께 기록한다.
- 2차 평가자가 20%를 독립 채점하고 순서 척도 Krippendorff alpha를 보고한다. 목표 >=0.67은 계획값.
- LLM 판정은 사전 분류/불일치 탐지 보조로만 사용하고 최종 정답으로 쓰지 않는다.

6.5 통계 분석

분석 단위는 시뮬레이션 사용자다. 사용자별 체크포인트 평균을 구한 뒤 조건 간 paired difference를 계산하고, 사용자 단위 cluster paired bootstrap 10,000회 95% CI, 평균 차이, 효과크기 dz, sign-flip permutation 10,000회를 보고한다. H1과 H2에만 Holm 보정을 적용한다.

확증 해석 전제	평가 사용자 >=20, 사용자 단위 개발/평가 분할, 본실험 전 prereg-v1 태그로 가설·지표·임계값·분석 script hash 동결, 재현성 기록 완비. 하나라도 어기면 결과 전체를 “탐색적”으로 표기.

6.6 결과 보고 템플릿

조건	NDCG@10	CR@10	Srec	UCR	VCC	상태
B1 무기억	[ ]	[ ]	[ ]	[ ]	[ ]	TO-MEASURE
B2 전체 이력	[ ]	[ ]	[ ]	[ ]	[ ]	TO-MEASURE
B3 세션 요약(선택)	[ ]	[ ]	[ ]	[ ]	[ ]	TO-MEASURE
B4 구조화 메모리	[ ]	[ ]	[ ]	[ ]	[ ]	TO-MEASURE
B4-U 감사	=B4	=B4	-	[ ]	[ ]	R10 동결

```
H1: Delta(B2->B4, CR@10)=[ ], 95% CI=[ ], dz=[ ], p_Holm=[ ] H2: Delta(B1->B4, NDCG@10)=[ ], 95% CI=[ ], dz=[ ], p_Holm=[ ] Guard: lower95CI(B4-B2 NDCG@10) > -delta ? [ ]
```

7. 감사 로그, 실패 분류, Go/No-Go

7.1 턴 단위 감사 로그

```
{ "query_id":"C07-s4-t1", "user_id":"C07", "session_id":4, "condition":"B4", "snapshot_id":"...",
"prompt_hash":"...", "model_id":"...", "extractor_id":"...", "seed":0, "extracted_profile":{...},
"evidence_spans":[...], "active_cluster_id":"k3", "router_probs":{...}, "rewritten_query":"...",
"retrieval_scores":[...], "R10":[...], "grounding_record":[...], "final_claims":[...],
"removed_sentences":[...], "latency_ms":0, "cost_usd":0.0 }
```

7.2 실패 분류

코드	범주	대표 실패
E1	추출 오류	슬롯 누락, 허위 span
E2	메모리 쓰기 오류	잘못된 MERGE/GENESIS, SUPPRESS 누락
E3	라우팅 오류	현재 맥락과 다른 클러스터 활성화
E4	검색 오류	질의 재작성 표류, 어휘 불일치
E5	그라운딩/주장 오류	전시 연결 실패, 미지지 날짜·장소·요금
E6	평가 인공물	스크립트 persona 이탈, 판정 불일치

7.3 Go/No-Go 질문

- 이 기능이 CR@10, NDCG@10, Srec, UCR 중 무엇을 바꾸는가?
- 다음 주 실험을 막는 blocker인가?
- 새 모델·새 데이터 없이 해결할 수 있는가?

세 질문에 답하지 못하는 기능은 본실험 전에 추가하지 않는다.

증상	먼저 수정	금지/유보
B1 미작동	데이터 적재, 인덱스, RRF	메모리/FT 추가
CR@10 높음	Router의 threshold/match 정의	reranker 도입
Srec 김	tentative 승격 규칙, 확인 질문	decay부터 튜닝
UCR 높음	claim whitelist, slot template, validator	생성기 FT
추출 F1 미달	schema, few-shot -> G0 통과 시 E-FT	생성기 FT
NDCG만 낮음	사전/토크나이저 확장	본실험 중 이미지 인덱스/재순위 추가

PART V. EXECUTION ROADMAP

8. 6주 실행 로드맵과 마일스톤

일정 지연을 기능 추가로 메우지 않고, 게이트 미달 시 범위를 축소한다.

주차	목표	필수 산출물	Go 기준	실패 시 축소
W1 9/23-9/29	데이터·snapshot·FT 자격	artwork/exhibition/link/lexicon, schema audit, lexicon v0, 10-example FT job	G0: job 생성 자격; G1: 해설문 보유 작품·snapshot checksum	필드 축소, E-P 확정
W2 9/30-10/6	B1 + Extractor	T/L index, RRF, JSON extractor+validator, E-P/E-FT 비교	G2: 20질의 무중단, NDCG 코드 실행, extractor 동결	암묵 슬롯 일부 축소, E-P
W3 10/7-10/13	Memory	Session Node, Cluster, Router, B2/B4 E2E, 개발 스크립트	G3: B1/B2/B4 1회 완주, CR/Srec 자동 계산	theta=0 대안, B3 제외
W4 10/14-10/21	Grounding + 예비 결과	전시 adapter, slot+validator, B4-U audit, labeling pilot	G4: 개발 세트 예비 결과, 동일 R10 UCR audit	작품 단위 주장 금지, 감사 표본 축소
W5 10/22-10/29	본실험	평가 세트 replay, pooling, labels, stats	prereg-v1 동결 후 결과표+CI+오류 로그	평가 사용자 20명 고정
W6 10/30-11/6	데모·문서	Streamlit, fresh-clone run, 1분 영상, 최종 논문/발표	fresh clone + demo 완주, 제출	캐시 기반 read-only demo

8.1 제출·발표 마일스톤

- 10/22: 중간 논문 제출 및 prereg-v1 동결.
- 10/23-10/29: 본실험. 동결 이후 평가 세트를 보며 수정 금지.
- 11/06 16:00: 최종 제출 목표(원문 일정 기준).
- 11/10: 발표/시연 목표(원문 일정 기준).

일정 해석	현재 실제 일정이 변경되었을 경우 날짜만 갱신하되, “G0-G4 -> prereg freeze -> main experiment -> fresh-clone reproduction -> final submission”의 순서는 유지한다.

9. 구현 청사진: 저장소, Streamlit, 데모

9.1 저장소 구조

```
arthemis/ data/{raw,processed,snapshots,lexicon}/
src/{ingest,extract,memory,retrieval,grounding,orchestrator,generation}/ sim/{personas,scripts_frozen}/
ft/{data,jobs}/ eval/{labels,metrics.py,stats.py,run_retrieval.py,run_memory_eval.py,run_grounding_audit.p
y,run_extractor_eval.py} app/streamlit_app.py configs/ audits/ prereg/ tests/ requirements.lock README.md
```

9.2 최소 실행 명령

```
python eval/run_retrieval.py --cond B1 python eval/run_extractor_eval.py --arms E-P,E-FT python
eval/run_memory_eval.py --cond B1,B2,B4 python eval/run_grounding_audit.py --cond B4,B4-U python
eval/stats.py --prereg prereg/prereg-v1.yaml streamlit run app/streamlit_app.py
```

9.3 Streamlit 프로토타입 화면

영역	화면 요소	연구/사업 기능
Sidebar	snapshot/model/prompt hash, API key, force refresh	재현성/운영 설정
Chat	사용자 질의와 확인 질문	감각·상황 자연어 UX
Agent A debug	intent/context/extracted slots/active cluster	데모에서 맥락 분리 가시화
Recommendation card	작품 제목/작가/재료/추천 이유	Artwork Layer
Grounding badge	VERIFIED/CACHED/UNVERIFIED + checked_at/source	Exhibition Layer 신뢰 표시
Audit expander	RRF score, claim support, removed sentence	심사자에게 “AI 통제”를 증명

9.4 60초 시연 시나리오 - 정본 수정안

시간	화면/발화	핵심 메시지
00:00-00:12	“머리가 복잡해서 묵직한 질감의 그림 앞에 혼자 있고 싶어요.”	감각어-전문 메타데이터의 간극 제시
00:12-00:27	Agent A JSON과 evidence span, active cluster 표시	근거 있는 미학 신호 추출과 맥락 선택
00:27-00:42	Top-10 중 1-2개 카드 + grounding record	추천과 방문정보를 분리
00:42-00:52	“이번 주말에는 아이와 가요.” -> 다른 cluster 활성화	혼자 보기와 가족 보기의 context contamination 방지
00:52-01:00	“실측 결과는 본실험 후 기입” 라벨과 audit log	성과를 과장하지 않고 검증 설계를 강점으로 제시

삭제해야 할 구버전 문구

“100회 실험 결과 CR 8%, UCR 0건 달성”, “NDCG 0.842 완벽히 보존” 등 [R]의 성과형 문장은 v3와 충돌하므로 최종 영상/발표에서 사용하지 않는다. 실제 측정값으로 교체되기 전까지 TO-MEASURE.

PART VI. BUSINESS & COMPETITION

10. 사업화 전략: 시장, STP, SWOT, BM

연구의 구조를 “기관이 사는 경험 레이어”로 번역한다. 시장 사실과 사업 가설은 분리해서 표기한다.

10.1 최종 사업 주제

제품명	ARTHÉMIS: 나의 감상 맥락을 기억하는 AI 아트 큐레이터

항목	내용
고객 문제	관람객은 작품명/사조보다 “오늘은 조용한 질감”, “아이와 함께 쉽게 이해할 작품”처럼 말한다. 기존 검색은 이 말을 잘 받지 못하고, 장기 기억도 맥락을 섞을 수 있다.
핵심 고객	관람객 경험·교육·디지털 전환을 개선하려는 미술관·박물관·문화기관. 최종 사용자는 미술 초보, 혼자 감상하는 직장인, 가족 관람객, 재방문 관람객.
가치 제안	말로 설명하기 어려운 취향을 작품 언어로 번역하고, 현재 맥락에 맞는 작품을 추천하며, 방문정보는 확인된 사실만 안내.
서비스 형태	기관 브랜드를 반영한 웹/모바일 대화형 큐레이터 + 기관용 콘텐츠/메모리/근거 관리 콘솔 + 품질/감사 대시보드.
차별화 한 줄	“추천을 많이 하는 AI”가 아니라 “감상 맥락을 섞지 않고, 추천과 방문정보를 따로 검증하는 AI”.

10.2 사업 아이디어 20개 포트폴리오

No	아이디어	핵심 가치	점수/25	판정
1	ARTHÉMIS 개인화 미술관 큐레이터	감각·상황 발화 기반 작품/전시 추천	23	최종 후보
2	가족 관람 모드 AI 도슨트	동행자·연령·시간 반영 가족 관람 루트	21	확장
3	회복형 문화처방 큐레이터	휴식·사유·회복 목적 예술 탐색	20	윤리 검토
4	전시 전 10분 프리뷰	예약 전 취향 확인과 예상 동선	20	B2C
5	지역 미술관 재방문 엔진	지역별 재방문·숨은 작품 발견	19	기관형
6	AI 미술관 교육 튜터	학생 질문에 작품 근거로 답변	19	교육형
7	감각어-미술어 번역 사전	거친 느낌과 재료·기법 연결	18	기술자산
8	전시 정보 신뢰 레이어	기간·장소·요금·상태의 근거 확인	18	API형
9	큐레이터 업무 보조	해설문 태깅·메타데이터 정규화	18	B2B
10	나의 미술 감상 여권	세션·작품·취향 변화 기록	17	커뮤니티
11	장애 감상 보조	텍스트·음성·촉각 설명 변환	17	접근성
12	전시 동선 혼잡 회피 추천	시간대·동반자 기반 동선 제안	17	센서 연계
13	작가·작품 관계 그래프	작가·시대·재료·정서 연결	17	탐색형
14	미술관 멤버십 리텐션 AI	회원 취향 기반 재방문 캠페인	16	CRM
15	기업 문화복지 큐레이터	직원 맞춤 전시·문화활동 추천	16	B2B2E
16	전시 리뷰 감정·맥락 분석	리뷰를 운영 인사이트로 변환	16	분석형
17	미술 초보 4주 학습 코스	작품·용어·질문 단계형 추천	16	교육형
18	전시 후 대화 카드	동행자별 감상 대화 촉진	15	콘텐츠형
19	공공문화 데이터 자연어 탐색	전시·공연을 상황어로 검색	15	플랫폼형
20	작품 라이선스·출처 도우미	기관용 이미지·텍스트 권리 확인	15	운영형

1번이 최종 후보인 이유는 연구 자산을 가장 직접적으로 재사용하면서 기관 구매자와 최종 관람객을 동시에 설명할 수 있고, 6주 안에 텍스트 중심 MVP와 통제평가를 보여줄 수 있기 때문이다. 나머지는 후속 모듈/파트너 패키지로 둔다.

10.3 시장·경쟁 구도

근거/경쟁자	사업 문서가 2026-09-23 기준 확인한 내용	ARTHÉMIS의 해석
문화예술활동조사	문화예술 관람률 63.0%, 전년 대비 4.4%p 상승 [WEB-VERIFIED]	관람 수요의 존재. 미술관 전용 수요와 지불의사는 별도 검증.
문화포털	문화공공데이터 Open API, 전시정보 통합 API 설명 [WEB-VERIFIED]	전국 확대 전 snapshot 1개 + 코퍼스 1개로 시작 가능.
Google Arts & Culture	2,000개 이상 문화기관 온라인 컬렉션 경험 [WEB-VERIFIED]	규모 경쟁 대신 한국어 감각대화/기관용 기억/claim 통제.
Smartify	접근성·번역·브랜딩·오프라인·개인화 등 기관 기능 [WEB-VERIFIED]	오디오/콘텐츠 플랫폼과 달리 맥락 분리 추천·통제평가에 집중.
Artsy	대규모 작품·갤러리·개인화·거래 [WEB-VERIFIED]	상업 거래가 아닌 실제 기관 전시/비상업적 감상 맥락.
Artivive / DailyArt	AR 레이어 / 일일 콘텐츠 습관 [WEB-VERIFIED]	AR/콘텐츠 빈도보다 대화·기억·grounding이 핵심.

10.4 STP와 Persona

세그먼트	정의	획득 메시지
S1 기관 디지털 담당	관람객 경험·교육·CRM·전시 콘텐츠와 브랜딩/분석을 관리	“기존 전시 정보를 버리지 않고 개인화 경험 레이어를 추가하세요.”
S2 미술 초보	색·분위기·상황으로 작품을 선택	“미술 용어를 몰라도 원하는 감상을 말할 수 있어요.”
S3 가족 관람객	동행자에 따라 난이도/설명 길이/동선이 바뀜	“같은 전시도 혼자와 아이 동반을 다르게 안내합니다.”
S4 재방문 관람객	과거 취향과 이번 목적이 달라 기억 선택이 중요	“지난번 취향을 기억하되, 오늘의 맥락을 우선합니다.”

초기 타깃: 디지털 전환과 관람객 경험 개선을 동시에 추진하는 중소 규모 미술관·박물관. 포지셔닝: “대규모 문화 플랫폼”이 아니라 “기관 데이터에 붙는 맥락 분리형 AI 큐레이터”.

10.5 SWOT

Strength	Weakness	Opportunity	Threat
연구 구조가 기능·지표·로그로 연결; 감각 언어 스키마; 작품/전시 분리	초기 코퍼스 작음; 실제 사용자/기관 데이터 부족; API 정책 변화	문화예술 관람 수요; 공공문화 Open API; 기관 디지털 경험 수요	글로벌 플랫폼 규모; 환각·저작권·개인정보; 기관 구매 주기

전략: SO=감각어 UX와 Core 지표 공개, WO=한 코퍼스·한 API로 시작, ST=규모 대신 한국어 맥락/기관 브랜딩/감사 로그, WT=grounding·최소수집·저작권 보수·Go/No-Go를 제품 설계에 내장.

11. 비즈니스 모델과 재무 가설

11.1 BM Canvas

블록	설계
고객	미술관·박물관·문화재단·복합문화공간 / 미술 초보·가족·재방문 관람객
가치	맥락을 섞지 않는 개인화, 감각어 검색, 확인된 전시 정보, 기관 데이터 활용도 상승
채널	기관 파일럿, 문화데이터/미술관 네트워크, 공모전 데모, 교육·문화행사 파트너
관계	온보딩 워크숍, 큐레이터 검수 콘솔, 월간 품질 리포트, 기억 수정 UI
수익	초기 구축비, 월 구독, 다국어/오프라인/고급 분석 add-on, 공동 프로젝트
핵심자원	Core 코드, 감각어-조형어 사전, 기관 메타데이터, Golden Set, audit log
핵심활동	데이터 정규화, 검색/메모리 품질관리, 기관 설정, 안전/저작권 검수
파트너	미술관·박물관, 문화포털 API, 미술교육자/큐레이터, AI API/클라우드
비용	LLM/API·임베딩, 데이터 정제, 기관 온보딩, 서버/모니터링, 큐레이터 검수

11.2 가격 가설 [PROPOSED]

패키지	범위	초기 제안가	검증 조건
Pilot 6주	코퍼스 1개, 전시 API 1개, 기관 브랜딩, 대시보드, 평가 리포트	구축 500만원 내외	구매예산·온보딩 공수 인터뷰
Starter	월 1,000 세션, 기본 분석, 1개 채널	월 49만원	사용량/API 원가와 고객가치
Growth	월 5,000 세션, 다국어, 고급 분석, 검수 workflow	월 149만원	3개월 후 재계약 의향
Enterprise	다기관·SSO·SLA·전용 데이터 공간·컨설팅	별도 견적	보안·조달·법무 검토

주의 가격, TAM/SAM/SOM, 12개월 유료 파일럿 3곳/구독 2곳은 실적이 아니라 검증 가능한 사업 가설이다. 인터뷰·LOI·유료 파일럿 이후 업데이트한다.

11.3 6주 사업 검증 예산 [PROPOSED]

항목	금액	설명
LLM·임베딩·검색 API	120만원	개발·평가 호출량 상한, cache/batch
데이터 정제·큐레이터 검수	100만원	작품·전시 필드 표준화, 감각어 사전 검수
데모·호스팅·도메인	50만원	웹 데모와 로그 저장
사용자·기관 인터뷰 인센티브	80만원	기관 담당자·관람객 인터뷰
예비비	50만원	정책·데이터·추가 호출 변동
합계	400만원	실제 비용은 실행 시 확정

PART VII. SUBMISSION & DEFENSE

12. 제출용 서사, 12장 피치, 발표 대본

학술 정합성을 훼손하지 않으면서도 비전공 심사위원이 30초 안에 이해할 수 있게 번역한다.

12.1 제출용 사업계획서 핵심 문안

사업 개요

ARTHÉMIS는 관람객의 감각·상황 언어를 이해하고, 개인의 감상 맥락을 장기적으로 기억하는 대화형 AI 아트 큐레이터다. 사용자의 발화를 미학 신호와 근거로 구조화하고 세션별 취향을 클러스터로 관리한 뒤, 현재 동행·목적에 맞는 취향만 선택해 작품을 추천한다. 방문정보는 별도 snapshot에서 확인된 필드만 안내한다.

문제 인식

미술관 검색은 전문 메타데이터에 의존하지만 일반 관람객은 감각과 상황으로 말한다. 장기 기억도 복수 맥락을 하나의 프로필로 섞으면 개인화가 오히려 부정확해지고, LLM이 존재하지 않는 전시 일정·장소·요금을 생성하면 추천은 실제 관람으로 이어지지 않는다.

AI 활용

AI는 감각·상황 발화를 고정 JSON으로 추출하고, Session Node/Cluster 기술문을 만들고, 질의를 재작성하며 추천 이유를 설명한다. schema validator, evidence span, snapshot ID, source_url, claim validator를 함께 사용한다. fine-tuning은 반복 오류와 목표 미달 시 Extractor에만 조건부 적용한다.

실행

W1 데이터/snapshot, W2 B1+Extractor, W3 memory/router, W4 grounding audit, W5 controlled evaluation, W6 Streamlit+fresh-clone+1분 영상. 각 주차는 Go/No-Go 게이트로 연결한다.

위험관리

추천 부정확성, 전시정보 오류, 개인정보·정서정보 과다 저장, 저작권, API 정책 변화, 기관 구매주기를 주요 위험으로 보고 claim whitelist, 최소수집, 원본 이미지 비저장, snapshot/commit 고정, pilot KPI 합의로 대응한다.

12.2 12장 발표 구조

#	제목	핵심 메시지	화면
1	제목	“나의 감상 맥락을 기억하는 AI 아트 큐레이터”	혼자 보기 vs 아이와 보기 장면
2	문제	미술관은 전문어로 검색, 사람은 감각/상황으로 말함	“거친 질감, 조용한 그림”
3	왜 지금	문화예술 수요 + 공공 전시 데이터 + 대화형 AI	시장 근거 1장
4	고객	기관 담당자와 최종 관람객 JTBD	누가 돈을 내고 누가 쓰는가
5	해결책	Session Node -> Cluster -> Router	기억하되 오늘의 맥락만 선택
6	데모	발화 -> JSON -> 추천 -> 검증 전시	1개 사용자 여정
7	차별화	규모가 아니라 맥락 분리와 근거 통제	경쟁 matrix
8	AI 설계	Extractor, RRF, grounding, audit	AI가 빠지면 사라지는 기능
9	검증	NDCG, CR, Srec, UCR/VCC	B1/B2/B4와 B4-U 통제
10	BM	Pilot -> subscription -> multi-institution	가격은 PROPOSED 표시
11	실행	6주 Core + gates + 범위 축소	무엇을 하지 않을지까지
12	결론/요청	“AI가 감상을 대신하지 않고 다음 감상을 더 잘 만나게 한다”	pilot 기관/사용자 협력 요청

12.3 5분 발표 대본 - 정본 버전

시간	대본
0:00-0:25	안녕하세요. ARTHÉMIS는 나의 감상 맥락을 기억하는 AI 아트 큐레이터입니다. 작품을 대신 감상하는 AI가 아니라, 사람이 다음 작품을 더 잘 만나도록 돕는 AI를 만들고 있습니다.
0:25-0:55	문제는 검색 언어에 있습니다. 미술관은 작가·사조로 정리하지만 관람객은 “색이 요란하지 않고 표면이 묵직한 그림”처럼 말합니다. 또 혼자 보고 싶은 취향과 아이와 체험하고 싶은 취향이 한 기억에 섞이면 추천이 틀어집니다.
0:55-1:35	ARTHÉMIS는 발화에서 감각·상황 신호와 근거 span을 추출해 Session Node를 만듭니다. 반복되는 취향은 Taste Cluster로 묶고 Context Router가 오늘의 동행과 목적에 맞는 클러스터만 선택합니다.
1:35-2:15	선택된 취향은 BM25와 dense retrieval의 RRF 검색에 들어갑니다. “왜 이 작품인가”는 Artwork Layer, “어디서 볼 수 있는가”는 Exhibition Layer가 맡습니다. 확인되지 않은 기간·장소·요금은 말하지 않습니다.
2:15-2:55	글로벌 서비스는 규모와 콘텐츠에 강합니다. ARTHÉMIS는 한국어 감각대화, 맥락 분리형 장기 기억, 감사 가능한 전시 claim 통제라는 좁고 측정 가능한 문제를 해결합니다.
2:55-3:35	첫 고객은 관람객 경험을 개선하려는 미술관과 박물관입니다. 한 기관 6주 파일럿으로 시작하고, 기관 브랜딩·분석·검수 콘솔을 월 구독으로 확장합니다.
3:35-4:25	검증에서는 검색기·코퍼스·snapshot·seed를 고정하고 메모리 슬롯만 바꿉니다. H1은 B2 대비 B4의 CR@10 감소, H2는 B1 대비 B4의 NDCG@10 증가입니다. 취향 전환은 Srec, 전시정보는 동일 R10의 UCR/VCC로 감사합니다.
4:25-4:50	실측 전 숫자를 성과처럼 말하지 않습니다. 본실험 조건과 preregistration을 충족한 값만 확증 결과로 보고하고, 실패 사례도 audit log와 함께 공개합니다.
4:50-5:00	ARTHÉMIS의 경쟁력은 AI가 더 많이 아는 데 있지 않습니다. 관람객의 말에 근거를 남기고, 서로 다른 감상 맥락을 섞지 않으며, 실제 방문정보에는 확인의 선을 긋는 데 있습니다. 감사합니다.

13. 심사위원 예상 질문 20개와 답변

ID	질문	답변
Q1	Google Arts & Culture와 무엇이 다른가?	글로벌 규모와 아카이브 탐색보다 기관 코퍼스에 붙는 한국어 감각·상황 대화, 맥락 분리 기억, 전시 claim 검증을 핵심으로 한다.
Q2	Smartify와 겹치지 않나?	Smartify는 오디오·번역·접근성·브랜딩에 강하다. ARTHÉMIS는 long-term taste routing과 controlled evaluation이 중심이며 향후 연동 파트너가 될 수 있다.
Q3	AI가 틀리면?	작품 추천은 source corpus와 근거를, 방문정보는 snapshot field만 사용한다. 미지지 claim을 제거하고 UCR로 감사한다.
Q4	장기 기억은 개인정보 침해 아닌가?	정서 원문을 장기 저장하지 않고 감상 목적 수준으로 추상화하며, 열람/수정/삭제/보존기간 UI를 둔다.
Q5	데이터는 어디서 오나?	기관이 허용한 메타데이터·해설문과 문화포털 전시 API가 초기 core. corpus와 snapshot의 수/날짜/checksum을 기록한다.
Q6	왜 fine-tuning을 바로 하지 않나?	문제 원인을 분리하기 위해 prompt+schema+validator+eval을 먼저 만들고, 반복 오류가 남을 때 Extractor에만 SFT한다.
Q7	실사용자가 적은데 NDCG는?	동결한 persona script와 사람이 라벨링한 pooled Golden Set으로 조건 간 상대 차이를 먼저 평가하고, 실제 pilot은 외적 타당성 보완용이다.
Q8	기관이 왜 돈을 내나?	기존 데이터 재사용, 관람 전환/교육 참여, 콘텐츠 제작 공수, 정보 오류 리스크를 pilot KPI로 합의하고 품질 리포트/브랜딩/분석을 유료화한다.
Q9	연구를 어떻게 사업으로 바꿨나?	Session Node=기록, Taste Cluster=패턴, Router=오늘의 선택으로 번역하고, 연구 지표를 제품의 품질 계약으로 사용한다.
Q10	가장 큰 실패 가능성?	기관 데이터 정제와 구매주기. 그래서 한 기관·한 코퍼스·한 API로 6주 pilot을 제한하고 B1이 안 되면 확장하지 않는다.
Q11	멀티모달을 뺀 이유?	한 주기에서 여러 모델/인덱스를 결합하면 자원과 변수 수가 늘어 메모리 효과 귀속이 어렵다. 텍스트 baseline을 검증한 뒤 단일 절제로 추가한다.
Q12	왜 B2가 중요한 baseline인가?	“기억을 구조화하지 않고 그냥 많이 넣는” 강한 baseline이기 때문에 B4의 고유 주장인 selection/routing 효과를 직접 검증할 수 있다.
Q13	CR만 낮추려고 무관 작품을 추천할 수 있지 않나?	그래서 NDCG 비열등 guard를 같이 보고, CR 감소가 순위 품질 붕괴를 동반하지 않는지 확인한다.
Q14	왜 Trec가 아니라 Srec인가?	메모리가 세션 종료 시에만 갱신되므로 턴 단위 회복은 현재 세션 발화 효과와 섞인다. 다음 세션 시작 체크포인트가 장기 메모리 효과에 더 맞는다.
Q15	Grounding이 추천 자체를 바꾸나?	주 감사에서는 R10을 동결한다. 그래야 UCR/VCC 차이를 검색이 아니라 claim constraint에 귀속할 수 있다.
Q16	전시 API가 작품 단위가 아닌데 “전시 중”이라고 할 수 있나?	입증되지 않으면 그렇게 말하지 않는다. “이 취향에 맞는 전시”로 약속 단위를 낮추고, 작품 출품 증거가 있을 때만 작품 단위 주장을 허용한다.
Q17	합성 persona의 외적 타당성은?	절대 사용자 만족을 주장하지 않고 조건 간 통제 비교로 제한한다. 실제 pilot은 IRB/동의 후 정성적 외적 타당성 보완 단계다.
Q18	파인튜닝 효과와 메모리 효과가 섞이지 않나?	본실험 전에 extractor를 하나로 동결하고 모든 B조건에서 동일 extractor를 사용한다. E-P/E-FT 비교는 별도 탐색 결과다.
Q19	재현성은 어떻게 보장?	snapshot ID, prompt hash, model ID, seed, commit, requirements.lock, persona/script hash를 감사 로그와 부록에 기록하고 fresh clone으로 재실행한다.
Q20	최종적으로 무엇을 증명하려는가?	큰 모델의 우월성이 아니라 “같은 정보를 구조화·선택해 쓰는 장기 기억이 통째로 넣는 것보다 맥락 오염을 줄이며 개인화 품질을 유지/개선할 수 있는가”를 검증한다.

PART VIII. ETHICS, RISK & QUALITY

14. 한계, 윤리, 위험관리

논문과 제품 모두 “잘 말하는 AI”보다 “말해도 되는 범위”를 먼저 설계한다.

14.1 연구 한계

- 주 평가는 시뮬레이션 사용자에 의존하므로 절대 성능이 아니라 조건 간 상대 차이로만 해석.
- 고정 script replay는 인과 귀속을 강화하지만 적응적 확인 질문 정책 자체의 효과는 직접 측정하지 못함.
- 평가 사용자 20-30명 계획 규모는 작은 효과를 검출하기 어렵고, 유의하지 않음을 “효과 없음”으로 해석하지 않음.
- 1차 평가자가 연구자 본인이라는 한계와 감각어 사전/기관 해설문의 문화·어휘 편향.
- 단일 기관 corpus와 전시 단위 API는 외적 타당성을 제한하고, 전시 연결은 실제 방문 가능성의 대리 지표.

14.2 개인정보·정서·저작권

위험	원칙
정서 정보	“번아웃” 같은 원문을 장기 저장하지 않고 회복/사유 등 감상 목적 수준으로 추상화.
사용자 통제	memory를 열람·수정·삭제할 수 있고 동의 범위와 보존기간을 표시.
치료 오인	정신건강 진단/치료를 표방하지 않으며 “문화처방” 확장 아이디어는 별도 윤리 검토.
저작권	초기 core는 메타데이터·해설문·source link 중심. 원본 이미지 저장/재배포를 필수로 하지 않음.
실관람객 연구	수행 시 IRB 심의 또는 면제 확인과 동의를 거친 소규모 정성 연구로 분리.

14.3 제품 위험 레지스터

위험	신호	완화책	중단 조건
추천 부정확	NDCG 하락	사전/토크나이저/라벨 검토	B1도 기준선 미달이면 memory 확장 중단
맥락 오염	CR 상승	Router/match/clarification 수정	B4가 B2보다 악화되면 release 보류
방문정보 환각	UCR 상승	claim whitelist/validator/snapshot	DATE/VENUE/FEE 미지지 반복 시 자유생성 금지
침묵 회피	VCC 하락	지원되는 필드는 템플릿으로 적극 활용	UCR만 낮고 VCC 급락 시 실패
개인정보	raw emotion 저장 발견	schema 제거/retention cleanup	동의 없는 raw text 장기 저장 즉시 중단
API/모델 변화	G0 job 실패/deprecation	E-P fallback, snapshot 재확인	본실험 직전 모델 교체 금지

PART IX. FINAL DELIVERY CONTROL

15. 최종 제출 체크리스트와 Master Decision Gate

논문, 코드, 데모, 사업계획서, 발표가 서로 다른 숫자와 조건을 말하지 않도록 마지막에 하나로 잠근다.

15.1 학술 제출 체크리스트

- □ 모든 [ ] 자리표시를 실측/확정값으로 교체했거나 “미측정”으로 명시.
- □ 표 결과 제목에 “개발 세트·탐색적” 또는 “평가 세트·확증”을 실제 경로대로 표시.
- □ E3 서술은 G0/G2 실제 경로 하나만 남김.
- □ G0-G4 결과와 범위 축소 내역을 구현 현황에 기록.
- □ corpus/snapshot checksum, model ID, prompt hash, commit이 재현성 표와 일치.
- □ fresh clone에서 최소 실행 명령이 오류 없이 실행.
- □ 감정 관련 raw text가 장기 memory/audit figure에 남지 않음.
- □ 참고문헌과 OpenAI 문서의 확인일/지원모델을 제출 직전 재확인.

15.2 사업/공모전 체크리스트

- □ 공모전 확정 공지에서 접수기간, 분량, 파일명, 제출양식, 평가표 재확인.
- □ [PROPOSED] 가격·시장규모·12개월 목표를 인터뷰/LOI/계약 근거로 업데이트.
- □ [TO-MEASURE] 지표의 실제 값, CI, 표본수, snapshot 기준일, commit을 기입.
- □ 실측 전 목표값을 결과처럼 쓰지 않고, 데모 화면에도 PLAN vs MEASURED를 분리.
- □ 기관 데이터 이용조건, 이미지 저작권, 개인정보 보존기간/동의 문구 확인.
- □ 경쟁사 비방 대신 각 서비스의 강점과 ARTHÉMIS가 해결하는 빈틈을 설명.
- □ 최종 PDF 외에 1분 데모 영상, 1페이지 요약, 발표자 노트, fresh-clone README 준비.

15.3 Master Gate

GO	B1/B2/B4 E2E 완주 + 실제 결과표/CI + UCR/VCC audit + fresh-clone 재현 + 실패 사례 /commit 연결이 모두 완료되면 최종 성능 서술과 사업 pitch에 실측치를 반영.
NO-GO	한 항목이라도 비면 성능 우월성 문장을 쓰지 않는다. 대신 설계·프로토콜·예비/탐색 결과로 범위를 낮추고, 실측되지 않은 숫자는 삭제한다.

APPENDICES

부록 A. 재현성 기록 양식

이 표가 채워지지 않으면 통제 실험 결과를 확증 결과로 보고하지 않는다.

항목	기록
코퍼스	MMCA 수집 경로 [ ], 수집일 [ ], 작품/해설문 수 [ ]/[ ], 중복·결측 처리 [ ], checksum [ ]
전시 snapshot	E_eval ID [ ], 기준일 [ ], checksum [ ], 전시 수 [ ]
LLM/SFT	base snapshot [ ], job ID [ ], final model ID [ ], epochs [ ], train/valid file ID [ ]
기타 모델	text embedding [ ], BM25 tokenizer/k1/b [ ], simulator [ ], auxiliary judge [ ]
hyperparameters	tau_m, n_act, h, eta, theta, rho, kappa, tau_g, pi0, delta, Lmax의 보정값/로그 [ ]
실행환경	OS [ ], requirements.lock hash [ ], commit [ ], temperature [ ], seed [ ], prompt hash [ ], fresh clone 확인일 [ ]
prereg	prereg-v1 commit [ ], freeze date [ ], analysis script hash [ ]
simulation	persona version [ ], frozen script hash list [ ], dev/eval users [ ]/[ ]

항목	기록
labeling	raters [ ], pool size [ ], judgments [ ], Krippendorff alpha [ ], second-rating ratio [ ]
ethics	pilot 여부 [ ], IRB/면제 [ ], retention period [ ]

부록 B. 결과 서술 템플릿

- 확증 H1/H2: “H[ ]에서 [A]->[B]의 [지표] paired difference는 [ ] (95% CI [[ ], [ ]], dz=[ ])이며 Holm 보정 p=[ ]이다. 이 결과는 시뮬레이션 조건에서만 관찰되었다.”
- Guard: “B4-B2 NDCG@10 차이의 95% CI 하한은 [ ]로 비열등 여유 -delta보다 [크다/작다].”
- E1: “C형 사용자 중 B4는 [ ]%가 전환 후 첫 세션, [ ]%가 두 번째 세션에서 회복했고 [ ]%가 중도절단되었다.”
- E2: “동일 R10에서 B4-U와 B4의 UCR은 [ ]/[ ], VCC는 [ ]/[ ]였다. 미지지 claim은 [DATE/VENUE/FEE/STATUS/작품 단위]에 집중되었다.”
- E3: “G0 자격 미확인으로 E-P를 채택했다.” 또는 “E-FT의 암묵 F1 차이는 [ ] (95% CI [ ])로 [채택/비채택]되었다.”
- 오류 사례: “query_id [ ]에서 [stage] 기대값은 [ ], 관찰값은 [ ]. root cause [ ], commit [ ]에서 [수정].”

부록 C. 용어 사전

용어	정의
Aesthetic Signal	사용자의 감각·상황 언어에서 추출한 색·질감·매체·목적·동행·회피 등 구조화 신호
Session Node	한 세션 종료 시 생성되는 요약/목적/맥락/evidence/embedding 단위
Taste Cluster	반복 관찰된 Session Node를 묶은 장기 취향 구조. tentative/active/suppressed 상태
Context Router	현재 질의와 방문 맥락에 맞는 cluster만 선택하는 규칙 기반 router
Phi	비교 조건에서 공유 query-rewrite prompt에 들어가는 memory profile slot
Context Contamination	현재 맥락이 아닌 과거/타맥락 취향이 추천 목록에 섞이는 현상
Two-layer grounding	작품 적합성(Artwork)과 실제 전시/방문정보(Exhibition)를 분리하는 설계
UCR	grounding이 지지하지 않는 visit claim 비율
VCC	말할 수 있는 verified field 중 실제로 지지된 claim으로 사용한 비율
Srec	취향 전환 후 장기 memory가 새 취향으로 안정적으로 회복하는 데 필요한 세션 시작 checkpoint 수

부록 D. 학술 참고문헌 (중간논문 v3 기준)

[1] Achlioptas et al. ArtEmis: Affective language for visual art. CVPR, 2021.

[2] Aliannejadi et al. Asking clarifying questions in open-domain information-seeking conversations. SIGIR, 2019.

[3] Buckley & Voorhees. Retrieval evaluation with incomplete information. SIGIR, 2004.

[4] Chhikara et al. Mem0: Building production-ready AI agents with scalable long-term memory. arXiv:2504.19413, 2025.

[5] Cormack, Clarke & Büttcher. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. SIGIR, 2009.

[6] Efron & Tibshirani. An Introduction to the Bootstrap. Chapman & Hall, 1993.

[7] Friedman et al. Leveraging large language models in conversational recommender systems. arXiv:2305.07961, 2023.

[8] Garcia & Vogiatzis. How to read paintings: Semantic art understanding with multi-modal retrieval. ECCV Workshops, 2018.

[9] Getty Research Institute. Art & Architecture Thesaurus (AAT) Online.

[10] Hayes & Krippendorff. Answering the call for a standard reliability measure for coding data. Communication Methods and Measures, 2007.

[11] Holm. A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 1979.
[12] Jannach et al. A survey on conversational recommender systems. ACM Computing Surveys, 2021.
[13] Järvelin & Kekäläinen. Cumulated gain-based evaluation of IR techniques. ACM TOIS, 2002.
[14] Kim et al. Towards personalized conversational sales agents: Contextual user profiling for strategic action. Findings of EMNLP, 2025.
[15] Lewis et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. NeurIPS, 2020.
[16] Maharana et al. Evaluating very long-term conversational memory of LLM agents. ACL, 2024.
[17] OpenAI. Fine-tuning now available for GPT-4o. Accessed 2026-09-23 (source document citation).
[18] OpenAI. API deprecations: self-serve fine-tuning; legacy GPT snapshots. Accessed 2026-09-23 (source document citation).
[19] OpenAI. Supervised fine-tuning guide. Accessed 2026-09-23 (source document citation).
[20] Robertson & Zaragoza. The probabilistic relevance framework: BM25 and beyond. FnT IR, 2009.
[21] Wang et al. Rethinking the evaluation for conversational recommendation in the era of LLMs. EMNLP, 2023.
[22] Wu et al. LongMemEval: Benchmarking chat assistants on long-term interactive memory. ICLR, 2025.
[23] Xiao et al. AlpsBench: An LLM personalization benchmark for real-dialogue memorization and preference alignment. arXiv:2603.26680, 2026.
[24] Xu et al. A-MEM: Agentic memory for LLM agents. arXiv:2502.12110, 2025.
[25] Yao et al. ReAct: Synergizing reasoning and acting in language models. ICLR, 2023.
[26] Zhong et al. MemoryBank: Enhancing large language models with long-term memory. AAAI, 2024.

부록 E. 사업 문서의 웹 근거 목록

아래는 SDU Business Competition 문서가 2026-09-23 기준으로 [WEB-VERIFIED]라고 표시한 자료의 목록이다. 본 통합본은 해당 웹 사실을 재검증하지 않고 원문 상태를 보존한다. 제출 직전 공식 페이지에서 다시 확인하는 것이 전제다.

- 문화체육관광부 2024 국민문화예술활동조사 결과 - 문화예술 관람률 63.0% 근거.
- 문화포털 / 문화공공데이터광장 - Open API 및 전시정보 통합 API 설명.
- Google Arts & Culture About/Experience - 참여 문화기관 규모 설명.
- Smartify Platform Features - 접근성/번역/브랜딩/오프라인/개인화 기능.
- Artsy About - 사용자/작품/파트너/개인화/거래 정보.
- Artivive About - 작품용 AR 디지털 레이어 플랫폼.
- DailyArt App Store - 작품/작가/미술관 콘텐츠 및 다국어 정보.
- OpenAI Supervised fine-tuning guide - eval을 먼저 설정하고 SFT 개선효과를 검증하는 원칙.

통합 결론

ARTHÉMIS의 강점은 “AI가 더 많이 아는 것”에 있지 않다. 관람객의 말에서 근거를 남기고, 서로 다른 감상 맥락을 섞지 않으며, 실제 방문정보에는 검증 가능한 경계를 두는 데 있다. 연구에서는 이 주장을 B1/B2/B4의 통제 비교로 검증하고, 제품에서는 기관이 신뢰할 수 있는 audit layer로 번역한다. 최종 제출본의 품질은 화려한 기능 수가 아니라 정본의 일관성, 실측값과 계획값의 분리, fresh-clone 재현성, 실패 사례의 투명성에서 결정된다.

END OF MASTER EDITION