ARTHÉMIS: 맥락 분리형 장기 취향 메모리를 갖춘 대화형 아트 큐레이션 에이전트 — 설계와 통제 평가 프로토콜

Context-Separated Long-Term Taste Memory for Conversational Art Curation:

Design and a Controlled Evaluation Protocol

추병곤 (Byeonggon Choo)
모두의연구소 AIFFEL Research 18기 · 365 Challenge
[email]

문서 상태 — 중간 논문 통합본 v3 (2026-09-23 빌드, 10/22 제출 예정). v2(맥락 분리형 장기 취향 메모리)를 본체로 하고, ARTHÉMIS-Core 뼈대의 운영 장치(성공 조건, Go/No-Go 규칙, 감사 로그, 실패 분류, 저장소 구조, 실행 명령, 결과 입력 규칙)를 통합했다. 표기: [빨강] 실측 후 기입, [주황] 실행 전 확정, [작성: 보라]. 본문의 모든 수치 목표는 계획값이며 실측 결과가 아니다. 원안 대비 변경은 부록 A.

초록

미술관 아카이브는 작가·연도·재료 같은 전문 메타데이터로 조직되지만, 관람객은 "마음이 가라앉는 거친 질감의 그림"처럼 감각과 상황의 언어로 말한다. 대형 언어 모델(LLM) 기반 대화형 추천은 이 번역 간극을 좁힐 수 있으나, 장기 개인화에서는 다른 실패가 드러난다. 세션이 끝나면 취향이 사라지고, 기억을 도입하더라도 한 사람 안의 서로 다른 감상 맥락—평일 혼자의 사유형 관람과 주말 자녀 동반 체험형 관람—이 하나의 프로필로 섞인다. 본 연구는 이 **맥락 오염**(context contamination)을 핵심 문제로 두고 ARTHÉMIS를 제안한다. 취향 에이전트는 근거 구간을 동반한 미학 신호를 추출하여 세션 요약(Session Node)을 취향 클러스터(Taste Cluster)로 조직하고, 질의 시점의 맥락에 맞는 클러스터만 선택(Context Router)해 텍스트 프로필로 공급한다. 작품·전시 에이전트는 이 프로필로 작품을 검색하고, 동결된 전시 스냅샷에서 확인된 필드만 슬롯 템플릿으로 안내한다. 평가는 메모리가 공유 질의 재작성 프롬프트의 한 슬롯에 들어가는 방식만 다른 세 조건(무기억 B1, 전체 이력 B2, 구조화 메모리 B4)을 고정 스크립트 재생으로 비교한다. 확증 가설은 두 개이다. B4가 B2보다 맥락 오염률(CR@10)을 낮추는가(H1), B1보다 개인화 순위 품질(NDCG@10)을 높이는가(H2). 분석 단위는 시뮬레이션 사용자이며, 사용자 단위 군집 짝지은 bootstrap과 Holm 보정을 사용한다. 취향 전환 후 회복 세션 수, 미검증 방문 주장률(UCR), OpenAI 지도학습 파인튜닝 추출기와 프롬프트 추출기의 비교는 탐색적 결과로 보고한다. 본 중간 논문은 문제 정의, 설계, 사전 지정 평가 프로토콜, 재현성 계약과 6주 실행 계획을 제시하며 성능 우위를 주장하지 않는다.

1. 서론

공공 미술관과 온라인 예술 플랫폼은 방대한 소장품을 공개하지만, 검색 가능한 필드는 작가명·작품명·제작연도·재료·사조처럼 미술사 어휘를 이미 갖춘 사용자를 전제한다. 일반 관람객의 요구는 감각적이고 상황적이다. "요즘 머리가 복잡해서, 색이 요란하지 않고 표면의 물질감이 묵직한 그림 앞에 가만히 있고 싶다"는 발화에는 작가명도 사조명도 없다. LLM 기반 대화형 추천 시스템(CRS) [7, 12]은 이런 발화를 조형 어휘로 번역하여 이 간극을 좁힐 수 있다.

본 연구는 예술 감상 개인화가 부딪히는 단절을 세 층으로 본다. (i) **의미 단절**: 감각어를 해설문과 조형 속성에 연결해야 한다. (ii) **기억 단절**: 세션 간 선호를 보존하되, 서로 다른 관람 맥락이 서로를 오염시키지 않아야 한다. (iii) **실행 단절**: 추천이 실제 관람으로 이어지려면 일정·장소 같은 방문 주장이 검증 가능한 근거에 묶여야 한다. 현행 대화 시스템은 세션을 독립 사건으로 다뤄 사용자가 감상 이력을 매번 다시 설명하게 하고, 장기 메모리를 도입하더라도 모든 기억을 하나의 프로필로 합치면 평일 저녁의 명상적 관람 취향이 주말 가족 나들이 추천에 섞인다. AlpsBench [23]는 명시적 메모리가 회상은 높이지만 선호 정렬을 자동으로 보장하지 않음을 보고했다. 기억은 많을수록 좋은 것이 아니라 선택적으로 쓰여야 한다. 본 연구는 (ii)의 이 양상—맥락 오염—을 핵심 질문으로 삼고, (iii)은 확인된 필드만 안내하는 설계 제약으로 다룬다.

다운사이징은 변수 통제이다. 초기 설계는 다기관 코퍼스, 텍스트·텍스트-이미지·이미지-이미지 인덱스, 크로스 인코더 재순위, 복수 LLM, 사용자 파일럿을 한 주기에 결합했다. 2026-09-23 제안서 검토는 범위 과다, 데이터 통합 미착수, 다수 모델 운용의 자원 제약을 지적했다. 본 원고는 이를 기

능 축소가 아니라 **변수 통제**로 재정의한다. 검색기·생성기·코퍼스·전시 스냅샷·대화 스크립트를 모두 고정하고 메모리가 공급하는 텍스트 슬롯 하나만 조건 간에 바꾼다. 그래야 관측된 차이를 메모리 구조에 귀속할 수 있다.

최종 제출 성공 조건. (a) 작동하는 end-to-end 데모, (b) fresh clone에서 재현되는 코드와 고정 설정, (c) H1·H2 주 지표와 탐색 지표의 실측값 및 사용자 단위 95% 신뢰구간, (d) 감사 로그에 연결된 실패 사례. 네 조건이 충족되기 전에는 부록 A의 제외 모듈을 복귀하지 않는다.

기여.

- **C1. 맥락 분리형 계층 취향 메모리.** 근거 발화를 보존하는 Session Node, 이를 편입(MERGE)·창발(GENESIS)·억제 규칙으로 조직하는 Taste Cluster, 질의 맥락에 맞는 클러스터만 활성화하는 Context Router(§4.3).
- **C2. 귀속 가능한 통제 비교 프로토콜.** 메모리가 공유 프롬프트의 한 슬롯에 들어가는 방식만 다른 조건, 고정 스크립트 재생, 사용자 단위 짝지은 통계, 그리고 감사 로그·Go/No-Go 규칙·결과 입력 규칙으로 이루어진 재현성 계약(§3, §6, §7).
- **C3. 역할 특화 추출 에이전트.** 큐레이터가 구축한 감각어–조형어 사전과, OpenAI 플랫폼 지도학습 파인튜닝 추출기와 프롬프트 추출기의 사전 지정 비교(§5).

멀티모달 검색, 크로스 인코더 재순위, 전시 신선도 필터, 설명 충실도 절제는 이번 범위에서 제외하고 복귀 조건과 함께 향후 과제로 둔다. 본문에서 "개선한다"는 표현은 검정할 가설을 뜻한다.

2. 관련 연구

LLM 기반 대화형 추천. RecLLM [7]은 대화 관리, 코퍼스 검색, 사용자가 읽고 고칠 수 있는 자연어 프로필, 사용자 시뮬레이터를 LLM으로 구성했다. CSI [14]는 매 턴 맥락 프로필을 갱신하며 선호 탐색과 제안 행동을 선택한다. 본 연구는 자연어 프로필과 선제적 명료화 질문 [2]을 차용하되, 두 연구가 단일 대화 안의 프로필을 다룬다면 본 연구는 다회차 세션에 걸친 취향 구조와 맥락별 분리를 다룬다는 점에서 다르다.

에이전트 메모리. MemoryBank [26]는 망각 곡선에 기반한 장기 기억 갱신을, A-MEM [24]은 새 기억이 기존 노트와 링크를 형성하며 진화하는 구조를, Mem0 [4]는 대화에서 사실을 추출해 지속 저장하는 방식을 제안했다. 이들은 범용 사실 기억을 대상으로 하며, 감상 동기·조형 선호·방문 맥락 같은 도메인 스키마와 맥락별 선택적 활성화는 제공하지 않는다. 본 연구는 기억을 삭제하지 않고 억제(suppressed)하는 상태를 두어, 명시적 거부와 일시적 비활성을 구분한다.

개인화 메모리 평가. LoCoMo [16]와 LongMemEval [22]은 장기 대화 기억의 회상을, AlpsBench [23]는 실대화 기반의 추출·갱신·검색·활용을 평가한다. 이들은 주로 기억 내용의 정확성을 묻는 반면, 본 연구는 기억이 추천 목록 수준에서 얼마나 다른 맥락을 끌어들이는가를 직접 재는 맥락 오염 지표를 더한다.

근거 기반 생성과 평가 방법론. 검색 증강 생성 [15]은 외부 근거로 환각을 줄이지만, 방문 정보처럼 사실 오류의 비용이 큰 필드는 생성 후 검증보다 출력 채널 자체를 제한하는 편이 안전하다. 본 연구는 기간·장소·요금을 스냅샷 필드로만 채우는 슬롯 템플릿을 택한다. LLM 시대의 CRS 평가는 사용자 시뮬레이터에 크게 의존하며 [21], 조건마다 시뮬레이션을 따로 돌리면 대화 경로 차이가 조건 효과와 섞인다. 본 연구는 스크립트를 한 번 생성해 동결하는 재생 방식과 조건 교차 풀링 판정 [3]으로 이 문제를 줄인다.

예술 이해. SemArt [8]와 ArtEmis [1]는 작품과 해설문·정서 언어의 연결을 다루지만 대화형 장기 개인화는 다루지 않는다. 본 연구의 감각어–조형어 사전은 이 연결을 검색 가능한 질의 어휘로 번역하는 경량 장치이다.

3. 문제 정의와 연구 질문

3.1. 과업 정식화

사용자 u는 세션 열 $\mathcal{S}_u = (S^{(1)}, \ldots, S^{(M)})$을 가지며, 각 세션은 발화 열 $(x_1, y_1, \ldots, x_{T_m}, y_{T_m})$이다. 작품 코퍼스 $\mathcal{A} = \{a_j\}$의 각 작품은 텍스트 a^{txt}(해설문, 메타데이터, 감각·조형 태그)를 갖고, 평가 시점에 동결한 전시 스냅샷을 $\mathcal{E}_{\text{eval}}$라 한다. 시스템은 장기 메모리 $\mathcal{M}_u$를 유지하며 각 턴에서

$$(d_t, R_t, \Gamma_t, y_t) = \pi\big(x_{\le t}, y_{<t}, \Phi(\mathcal{M}_u, x_t), \mathcal{A}, \mathcal{E}_{\text{eval}}\big) \quad (1)$$

를 산출한다. d_t는 대화 행동(질문·추천·전시 안내), $R_t \in \mathcal{A}^{10}$은 순위화된 추천 목록, Γ_t는 그라운딩 레코드, y_t는 응답이다. Φ는 메모리를 텍스트 프로필 블록으로 바꾸는 함수이며, **비교 조건은 오직 Φ만 다르다**(§3.3). 장기 메모리는 세션 종료 시에만 $\mathcal{M}_u \leftarrow \textsc{Write}(\mathcal{M}_u, S^{(m)})$로 갱신된다.

3.2. 연구 질문과 가설

RQ. 감상 맥락별로 분리·선택되는 구조화 취향 메모리는, 무기억 LLM 및 과거 대화 전체를 투입하는 방식에 비해 다른 맥락 취향의 혼입을 줄이고 개인화 순위 품질을 높이는가?

H1의 분석 대상은 두 유형을 합친다(표 4). 다중 맥락형(B)에서는 현재 관람 맥락 외의 맥락이, 취향 전환형(C)에서는 전환 이전 취향이 $\bar{c}$가 된다. 두 경우 모두 "현재 요구와 무관하지만 기억 속에 실재하는 취향"의 혼입이라는 같은 현상이며, 합산은 검정력을 확보한다. 유형별 층화 결과와 B형 단독 민감도 분석을 사전 지정한다(§6.6).

ID	비교	지표	방향	대상 / 지위
H1	B2→B4	CR@10	↓	B형 전체 + C형 전환 후 체크포인트 / **확증**
H2	B1→B4	NDCG@10	↑	전체 사용자 / **확증**
G	B2 vs B4	NDCG@10	—	비열등 동반 보고(여유 δ) / 가드
E1	B1·B2·B4	S_{rec}	↓	C형 / 탐색
E2	B4-U→B4	UCR, VCC	↓,↑	감사 표본 / 탐색
E3	E-P vs E-FT	추출 F1	↑	추출 시험 세트 / 탐색
E4	B2→B3→B4	CR@10	—	B3 수행 시 H1 분해 / 탐색

표 1. 사전 지정 가설. H1·H2에만 Holm 보정(가족 단위 양측 $\alpha = 0.05$)을 적용한다. H1은 본 연구의 고유 주장(같은 정보를 구조화·선택하는 것이 통째로 넣는 것보다 나은가), H2는 무기억 LLM 대비 개인화 효과이다. G는 B4가 무관한 작품을 채워 CR만 낮추는 퇴화 해를 배제하기 위한 동반 보고이다.

ID	메모리 슬롯 $\Phi(\mathcal{M}_u, x_t)$	그라운딩	상태
B1	$\varnothing$ (현재 세션 발화만)	적용	필수
B2	과거 세션 전사 전체를 최신순으로 이어붙여 입력 한도 [$L_{\max}$ 토큰]에서 절단	적용	필수
B3	x_t와 유사한 상위 k개 Session Node 요약 (라우팅 없음)	적용	선택
B4	Router가 선택한 Taste Cluster 기술문 + 근거 발화 인용	적용	필수
B4-U	B4의 R_{10} 동결, 방문 정보 자유 생성(슬롯·검증기 해제)	해제	감사

표 2. 비교 조건. **고정 요소**: 질의 재작성·응답 생성 LLM과 프롬프트, temperature, seed, 검색 인덱스(T, L), RRF 설정, 코퍼스·전시 스냅샷, 대화 스크립트, 추출기(동결본). B3를 수행하면 B2→B3(요약 효과)와 B3→B4(클러스터·라우팅 효과)로 H1을 분해할 수 있다. Core 뼈대의 B5는 본 원고의 B4(기본 그라운딩)와 같다.

3.3. 비교 조건

원안은 질의 벡터를 $\mathbf{v}_t = \text{norm}(\beta \mathbf{q}_t + (1-\beta)\mathbf{m}_t)$로 혼합했다. 이 방식은 B2(원문 이력)를 같은 벡터 공간에 넣기 어렵고, β 선택이 조건 효과와 얽힌다. 통합본은 모든 조건이 공유하는 질의 재작성 프롬프트의 한 슬롯에 텍스트 프로필 Φ를 넣는다(표 2). 이렇게 하면 B2와 B4가 같은 채널에서 내용만 다른 조건이 되어, 효과를 메모리 구조에 귀속할 수 있다. 그라운딩 제약은 모든 조건에 동일하게 적용되며, 그 효과는 동일 추천 목록에서 제약만 해제한 감사 조건 B4-U로 따로 잰다(E2).

4. 시스템 설계

4.1. 개요

그림 1는 제안서 피드백의 "취향 에이전트 / 미술 정보 에이전트" 분할을 채택한 구조이다. 원안의 5단계 파이프라인(신호 추출, 메모리, 검색, 그라운딩, 응답)은 두 에이전트의 내부 단계로 흡수된다. 오케스트레이터는 ReAct [25] 형식으로 매 턴 행동을 고르며, 라우팅 불확실성이 높으면 추천보다 확인 질문을 우선한다. 턴 단위 처리 순서는 알고리즘 2에 정리했다. 모든 LLM은 단일 호스팅 계열로 통일하고 텍스트 임베딩은 사전 계산하여, 로컬 GPU에 여러 대형 모델을 상주시키지 않는다.

4.2. 에이전트 A: 미학 신호 추출

추출기는 현재 발화 x_t, 현재 세션의 최근 k턴, 감각어–조형어 사전의 매칭 후보를 입력으로 받아 고정 스키마의 JSON을 출력한다(그림 2). 스키마 검증에 실패하면 1회 재시도하고, 근거 span이 원문에 없으면 해당 신호를 폐기한다. 근거 없는 추론은 장기 메모리에 쓰지 않는다. 감각어는 큐레이터가 구축한 사전(v0 100항목 → v1 200항목)으로 조형 개념에 연결된다(예: "거친 질감"→마티에르·임파스토). 정서 상태의 원문(예: "번아웃")은 저장하지 않고 감상 목적 수준(회복)으로 추상화한다. 추출기의 구현(파인튜닝 또는 프롬프트)은 §5의 G2 게이트에서 결정하고 본실험 전에 동결한다.

4.3. 에이전트 A: 계층형 취향 메모리

Session Node. 세션 종료 시 LLM은 세션을 다음 튜플로 구조화한다.

$$n_i = (\text{summary}_i,\ \text{intent}_i,\ \text{visit}_i,\ e_i,\ z_i,\ s_i)$$

e_i는 근거 발화, $z_i = f_T(\text{summary}_i)$는 텍스트 임베딩, $s_i \in [0,1]$은 세션 만족도이다. 노드 가중치는

$$w_i = \exp(-\nu\,\Delta t_i)\,(0.5 + 0.5\,s_i), \qquad \nu = \ln 2 / h \quad (2)$$

이며 반감기 h의 초기값은 30일이다. 시뮬레이션 스크립트는 세션마다 타임스탬프를 가지며, 본실험에서는 만족도가 조건 효과와 얽히지 않도록 $s_i = 0.5$로 고정한다(스크립트 만족도 사용은 민감도 분석).

Taste Cluster. 클러스터 k는 멤버 노드 집합 N_k, 가중 중심 $\mu_k = \text{norm}\big(\sum_{i \in N_k} w_i z_i\big)$, 세 상태(`tentative`, `active`, `suppressed`) 중 하나, 그리고 LLM이 합성한 기술문을 갖는다. 새 노드와 최근접 클러스터의 유사도 σ가 τ_m 이상이면 MERGE, 아니면 새 `tentative` 클러스터를 만든다(GENESIS). 서로 다른 $n_{\text{act}} = 2$개 세션에서 재관찰되면 `active`로 확정하는데, 이는 일시적 기분과 실제 취향 전환을 구분하기 위한 장치이다. 명시적 부정 선호에 대응하는 클러스터는 `suppressed`로 두어 삭제와 억제를 구분한다(알고리즘 1). τ_m의 초기값 0.78은 임베딩 모델 간에 이식되지 않으므로 개발 세트의 편입/분리 라벨로 보정한다. 원안의 BRIDGE와 stale 상태는 판정 로그만 남기고 이번 범위에서 동작에 쓰지 않는다.

Context Router. 검색 시 모든 클러스터를 평균하지 않는다. 후보 K_r은 `active`와 `tentative` 클러스터이며, 질의 임

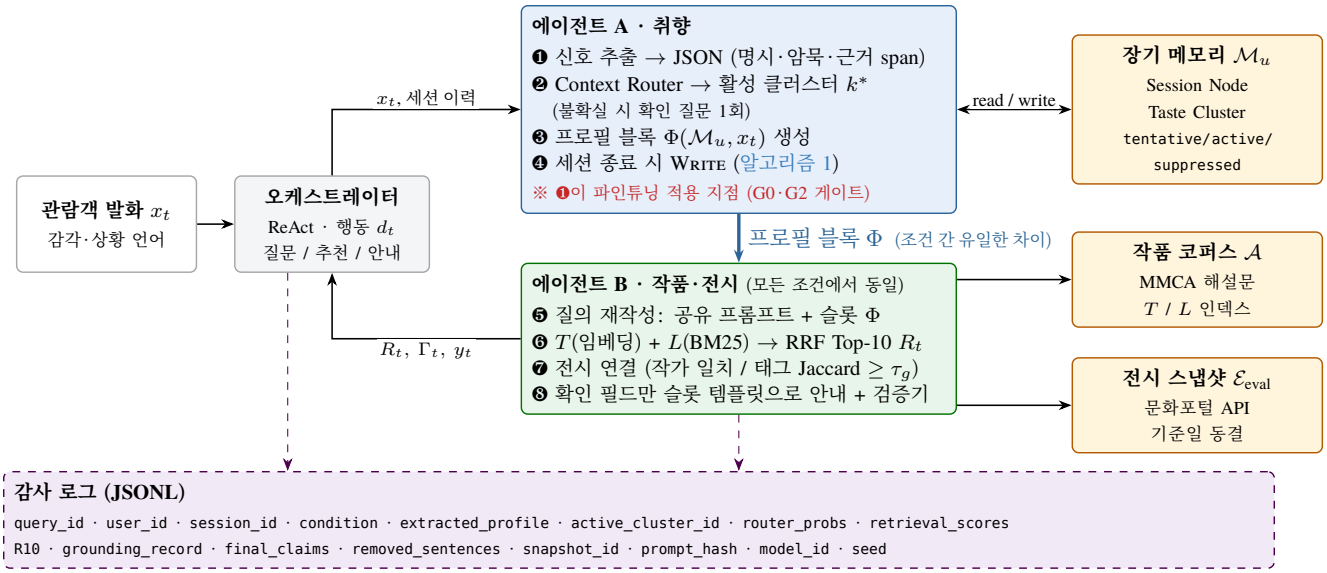


그림 1. 통합본 시스템 구조. 에이전트 B는 모든 비교 조건(B1–B4)에서 동일하며, 조건 간 차이는 에이전트 A가 공급하는 프로필 블록 Φ의 내용뿐이다. 모든 도구 호출은 스냅샷 ID·프롬프트 해시·모델 ID·seed와 함께 JSONL 감사 로그로 남는다(부록 B).

```
{"explicit": {"artist": [], "medium": [],
   "region": null, "visit_time": "weekday_eve",
   "companion": "alone"},
 "implicit": {"motive": "회복",
   "formal": {"color": "low_saturation",
     "texture": "rough", "scale": null,
     "density": "sparse"},
   "avoid": ["vivid_color"], "difficulty": "low"},
 "evidence": [{"turn": 3, "span": "색이 요란한 건 싫고"},
              {"turn": 3, "span": "표면이 묵직한"}],
 "negation": [], "confidence": 0.0}
```

그림 2. 추출기 출력 스키마(형식 예시, 값은 실측 아님). `motive`∈{사유, 회복, 학습, 체험}.

베딩 $\mathbf{q}_t = f_T(x_t)$와 추출된 맥락 슬롯(동행, 목적, 시간대) c_t로

$$p(k \mid x_t, c_t) = \text{softmax}_{k \in K_r}\ \ell_k, \qquad \ell_k = \eta \cos(\mathbf{q}_t, \mu_k) + \theta\, \text{match}_k(c_t) \tag{3}$$

를 계산한다. $\text{match}_k(c_t)$는 채워진 슬롯 중 클러스터 k의 최빈 방문 맥락과 일치하는 비율이다. $\max_k p < \rho$이면 추천 전에 확인 질문("누구와 가시나요?")을 1회 수행한다 [2]. B4의 프로필 블록은 $\Phi = \text{desc}(k^*) \oplus e_{k^*}$, $k^* = \arg\max_k p$이다. 초기값은 $\eta = 10$, $\theta = 2$, $\rho = 0.5$이며 개발 세트에서 보정한다. 라우터는 학습형 모델이 아니므로 개발 세트 20–30개 라벨만으로 보정이 가능하다.

4.4. 에이전트 B: 검색

공유 프롬프트가 x_t, 현재 세션 이력, 슬롯 Φ로부터 재작성 질의 $\tilde{x}_t$를 만든다. 검색은 해설문·태그의 텍스트 임베딩 인덱스 T와 한국어 형태소 기반 BM25 [20] 인덱스 L을 RRF [5]

알고리즘 1 WRITE: 세션 종료 시 장기 메모리 갱신

Require: 메모리 $\mathcal{M}_u$, 세션 S, 임계값 τ_m, 확정 횟수 n_{act}
Ensure: 갱신된 $\mathcal{M}_u$, 갱신 로그 $\mathcal{L}$

$n \leftarrow \text{STRUCTURE}(S)$; $z \leftarrow f_T(n.\text{summary})$; $\mathcal{L} \leftarrow \varnothing$
$K \leftarrow \{k \in \mathcal{M}_u : \text{status}_k \neq \texttt{suppressed}\}$
if $K \neq \varnothing$ **then**
  $k^\dagger \leftarrow \arg\max_{k \in K} \cos(z, \mu_k)$; $\sigma \leftarrow \cos(z, \mu_{k^\dagger})$
  if $K \neq \varnothing \wedge \sigma \geq \tau_m$ **then** ▷ MERGE
    $N_{k^\dagger} \leftarrow N_{k^\dagger} \cup \{n\}$; $\mu_{k^\dagger}$ ·기술문 갱신
    $\mathcal{L} \leftarrow \mathcal{L} \cup \{\text{KEEP/REVISE}\}$
    if #세션$(N_{k^\dagger}) \geq n_{\text{act}}$ **then**
      $\text{status}_{k^\dagger} \leftarrow \texttt{active}$
  else ▷ GENESIS
    새 클러스터 k': $N_{k'} = \{n\}$, `tentative`
    $\mathcal{L} \leftarrow \mathcal{L} \cup \{\text{ADD}\}$
for all 부정 선호 $q \in n.\text{neg}$와 $\text{MATCHES}(q, k)$인 k **do**
  $\text{status}_k \leftarrow \texttt{suppressed}$; $\mathcal{L} \leftarrow \mathcal{L} \cup \{\text{SUPPRESS}\}$
return $\mathcal{M}_u$, $\mathcal{L}$

로 융합한다. BM25는 작품명·작가명·재료 같은 고유 어휘를, 임베딩은 감각 언어와 해설문의 의미 유사도를 회수한다.

$$\text{score}(a) = \sum_{r \in \{T, L\}} \frac{1}{\kappa + \text{rank}_r(a)}, \qquad \kappa = 60 \tag{4}$$

$\text{rank}_r(a)$는 인덱스 r의 상위 200개 안의 순위이며, 없으면 해당 항은 0이다. 상위 10개가 R_t이다.

알고리즘 2 턴 단위 처리 (조건 $c \in \{\text{B1}, \text{B2}, \text{B3}, \text{B4}\}$)

Require: x_t, 세션 이력 $h_{<t}$, $\mathcal{M}_u$, 사전 $\mathcal{D}$, $\mathcal{E}_{\text{eval}}$
$\hat{e}_t \leftarrow \textsc{Extract}(x_t, h_{<t}, \mathcal{D})$ ▷ 스키마·span 검증
$\Phi \leftarrow \textsc{Slot}_c(\mathcal{M}_u, x_t, \hat{e}_t)$ ▷ 표 2
if $c = \text{B4} \wedge \max_k p < \rho \wedge$ 세션 내 미질문 **then**
  확인 질문 발화 ▷ 재생 시 기록만
$\tilde{x}_t \leftarrow \textsc{Rewrite}(x_t, h_{<t}, \Phi)$ ▷ 공유 프롬프트
$R_t \leftarrow \text{Top}_{10}\,\text{RRF}\big(T(\tilde{x}_t), L(\tilde{x}_t)\big)$
$\Gamma_t \leftarrow \textsc{Link}(R_t, \mathcal{E}_{\text{eval}})$
$y_t \leftarrow \textsc{Validate}\big(\textsc{Generate}(x_t, R_t, \Gamma_t), \Gamma_t\big)$
$\textsc{Audit}(x_t, \hat{e}_t, \Phi, p, \tilde{x}_t, R_t, \Gamma_t, y_t)$
return $(d_t, R_t, \Gamma_t, y_t)$

4.5. 에이전트 B: 전시 연결과 발화 제약

작품 층은 "왜 이 작품인가"를, 전시 층은 "어디서 볼 수 있는가"를 답한다. 작품 a는 스냅샷 $\mathcal{E}_{\text{eval}}$의 전시 e와 작가가 일치하거나 태그 Jaccard 계수가 τ_g 이상일 때 연결된다. 그라운딩 레코드 Γ_t의 각 항목은 `exhibition_id`, 상태(`VERIFIED/CACHED/UNVERIFIED`), `checked_at`, `source_url`, 기간·장소·요금 필드를 갖는다. 평가에서는 모든 레코드가 동결 스냅샷에서 오므로 상태는 `VERIFIED@snapshot`이며, 세 상태의 구분은 실시간 API를 쓰는 데모에서만 작동한다. 전시 API는 전시 단위이므로 "작품이 전시 중"이라고 말하지 않고 "이 취향에 맞는 전시가 열려 있다"로 표현한다. 기간·장소·요금은 스냅샷 필드를 채우는 슬롯 템플릿으로만 출력하며, 자유 서술에 이런 표현이 나타나면 검증기가 해당 문장을 제거하고 제거 내역을 로그에 남긴다. 근현대 작품의 저작권을 고려하여 원본 이미지는 저장·재배포하지 않는다.

4.6. 구현 스택과 감사 로그

LLM은 OpenAI API Platform으로 통일한다. 질의 재작성·응답 생성 기반 스냅샷은 [gpt-4.1-2025-04-14 / gpt-4o-2024-08-06 중 G0에서 확정]이고, 추출기는 G2에서 채택된 모델을 쓴다. 시뮬레이터와 보조 판정 모델은 순환성을 막기 위해 [OpenAI 외 모델 계열]을 쓴다. 텍스트 임베딩은 [모델 ID], BM25 토크나이저는 [Kiwi / MeCab-ko], 벡터 저장소는 로컬 FAISS, 데모는 Streamlit이다. 전 과정은 GPU 없이 API와 CPU로 실행된다. 프롬프트는 코드 저장소에서 버전 관리하며 해시로 참조한다. 모든 턴은 부록 B의 스키마로 `audits/`에 JSONL로 기록되고, 실패 사례는 같은 `query_id`로 수정 커밋과 연결된다.

5. 추출 에이전트의 특화: 파인튜닝과 프롬프트 기준선

5.1. 플랫폼 제약

OpenAI 공지 [18](확인일 2026-09-23)에 따르면 셀프서브 파인튜닝은 2026년 5월 7일부터 파인튜닝 이력이 없는 조직에서 작업을 만들 수 없고, 7월 2일부터는 최근 60일 안에 파인튜닝 모델로 추론한 이력이 없는 조직도 작업을 만들 수 없다. 또한 `gpt-4-0613`, `gpt-4o-2024-05-13`, `ft-gpt-4`는 2026년 10월 23일에 API가 종료되며, 이는 본실험 기간(10/23–10/29)과 겹친다. 따라서 종료 공지가 없는 스냅샷을 기반 모델로 쓴다. 지도학습 파인튜닝 가이드 [19]는 GPT-4.1 계열 스냅샷(`gpt-4.1-2025-04-14`, `gpt-4.1-mini-2025-04-14`, `gpt-4.1-nano-2025-04-14`)을 예시로 들고, GPT-4o 파인튜닝 공지 [17]는 `gpt-4o-2024-08-06`을 대상으로 한다. 지원 모델은 바뀔 수 있으므로 문서 확인만으로 결정하지 않고, **G0 게이트(9/25)**에서 10개 예제로 실제 작업을 생성해 자격과 모델 지원을 검증한다: [G0 결과 — 성공/실패, 조직, 기반 스냅샷, 작업 ID].

추출기	$\text{F1}_{\text{명시}}$	$\text{F1}_{\text{암묵}}$	span F1	적합률	지연/비용
E-P	[ ]	[ ]	[ ]	[ ]	[ ]
E-FT	[ ]	[ ]	[ ]	[ ]	[ ]
목표(계획)	≥ 0.75	≥ 0.50	—	≥ 0.98	—

표 3. G2 추출기 비교(시험 세트 n =[ ], 개발 단계 결과). 목표는 계획값이며 실측값이 아니다.

5.2. 학습 데이터

채팅 형식 JSONL로 구성한다. `system`은 과업 계약(스키마와 폐기 규칙), `user`는 현재 발화·최근 k턴·사전 후보, `assistant`는 스키마를 만족하는 JSON이다. 학습 [200–300]건, 검증 [50]건, 시험 [60]건이며, 원천은 연구자가 큐레이터로서 작성한 시드 발화, 본 평가에서 제외한 페르소나 A(정서 발견형) 스크립트, 다른 모델 계열로 증강한 변형이다. 모든 예제는 사람이 검수한다. 평가용 시뮬레이션 사용자의 발화는 학습에 포함하지 않으며, 원천 스크립트 단위 분할과 해시 목록으로 누수를 점검한다. 증강 변형은 반드시 원본과 같은 분할에 둔다.

5.3. 비교와 채택 규칙 (G2, 10/6)

E-P(동일 기반 스냅샷 + 과업 계약 + few-shot 8–16개 + 구조화 출력)와 E-FT(파인튜닝 모델 + 짧은 지시문)를 같은 시험 세트에서 비교한다(표 3). 측정은 명시·암묵 신호별 micro-F1, 근거 span 엄격 F1(토큰 IoU ≥ 0.5), 스키마 적합률과 필수 필드 성공률, 호출당 지연·비용이다. 시험 예제는 원천 스크립트에 군집되므로, **원천 스크립트 단위 군집 bootstrap**으로 암묵 F1 차이의 95% CI를 구한다. CI 하한이 0보다 크면 E-FT를, CI가 0을 포함하면 비용·지연이 낮은 쪽을 채택한다. G0에서 자격이 확인되지 않으면 E-P를 채택하고, E-P가 목표에 미달하며 오류가 특정 슬롯에 반복 집중될 때에 한해 소형 오픈 모델의 LoRA를 추출기에만 검토한다. 파인튜닝 대상은 고정 JSON을 내는 추출기로 한정한다. 응답 생성기 전체를 튜닝하면 메모리 효과와 생성 모델 효과가 섞이기 때문이다. 이 비교는 확증 가설에 포함하지 않는 탐색적 결과이다.

유형	시나리오	세션	역할
B 다중 맥락형	평일 혼자 사유형 관람과 주말 자녀 동반 체험형 관람을 세션마다 교차	5	H1, H2
C 취향 전환형	구상 회화 → 3번째 세션 도중 미디어·키네틱 설치로 전환	6	H1($\bar{c}$=전환 전 취향), H2, E1
A 정서 발견형	사조 어휘 없이 정서·감각어만 사용	—	추출기 개발 전용

표 4. 페르소나 설계. B·C형은 각각 [10–15]개 변형(시뮬레이션 사용자)을 둔다. 암묵적 선호 표현은 선호 발화의 40% 이상으로 통제한다. 평가 체크포인트는 B형 세션 3·4·5, C형 세션 4·5·6의 첫 추천 턴이다.

6. 평가 설계

6.1. 데이터

작품 층은 국립현대미술관(MMCA) 소장품 공개 데이터의 메타데이터와 해설문만 사용한다(수집 경로·이용 조건 [ ], 해설문 보유 작품 [ ]건). 전시 층은 문화포털 공연·전시 API를 평가 개시 시점에 한 번 동결한 스냅샷 $\mathcal{E}_{\text{eval}}$(기준일 [ ], 체크섬 [ ])이다. 두 원천은 `artwork`, `exhibition`, `link`, `lexicon` 네 테이블의 통합 스키마로 정리한다(`artwork`: id, title, artist, description, source_url 필수, year·medium 권고, AAT 선택; `exhibition`: id, title, venue, start/end date, fee, source_url, checked_at, status). 감각어–조형어 사전은 Getty AAT [9] 식별자를 가능한 경우에만 병기한다. 단일 기관 코퍼스는 외적 타당성을 제한하지만 데이터 통합 변수를 통제한다.

6.2. 페르소나와 분할

표 4의 두 유형을 평가에, 한 유형을 추출기 개발에 쓴다. C형은 전환 뒤 세 번의 세션 시작 체크포인트를 확보하기 위해 6세션으로 둔다. 시뮬레이션 사용자는 **개발 세트**([6–12]명; 하이퍼파라미터 보정·파이프라인 디버깅)와 **평가 세트**([20–30]명)로 사용자 단위 분할하며, 평가 세트 스크립트는 시스템을 한 번도 실행하기 전에 생성·검수·동결한다.

6.3. 고정 스크립트 재생과 체크포인트

대화형 시뮬레이션을 조건마다 따로 돌리면 시스템 응답에 따라 사용자 발화가 달라져, 조건 간 차이가 메모리 효과인지 대화 경로 차이인지 구분할 수 없다. 따라서 페르소나별 다중 세션 스크립트를 한 번 생성해 동결하고, 모든 조건이 같은 이력으로 메모리를 구축한 뒤 같은 체크포인트에서 검색 결과를 비교한다. 체크포인트는 세션의 첫 추천 턴으로 둔다. 세션 내 선호 발화가 가장 적은 지점이므로 장기 메모리의 기여가 가장 직접 드러나며, 첫 발화에는 맥락 단서("이번 주말엔 아이랑")가 명시 또는 암묵적으로 들어가도록 스크립트를 통제한다. 사용자당 3개 체크포인트이므로 평가 질의는 20명 기준 60개, 30명 기준 90개이다. 이 방식은 확인 질문

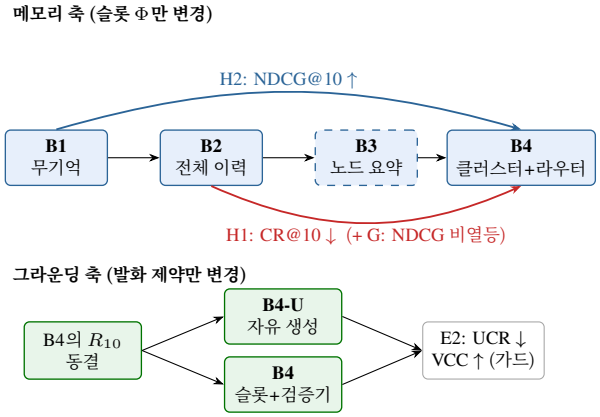


그림 3. 평가 경로. 메모리 축에서는 검색기·생성기를 고정하고 Φ만, 그라운딩 축에서는 추천 목록을 고정하고 발화 제약만 바꾼다. 점선 B3는 선택 조건이다.

같은 적응적 대화 정책의 효과를 평가하지 못한다. 재생 중 확인 질문 조건이 충족되면 발화하지 않고 로그에 기록한 뒤 k^*로 진행하며, 그 빈도를 탐색적으로 보고한다.

6.4. 지표

맥락 오염률 (H1). 현재 맥락 c에 적합한 작품 집합을 P_c, 다른 맥락에 적합한 작품의 합집합을 $P_{\bar{c}}$라 할 때, 다른 맥락에만 적합한 추천의 직접 분율이다. 두 맥락 모두에 적합한 작품은 오염으로 세지 않는다.

$$\text{CR@}K = \frac{1}{K}\left|\{a \in R_K : a \in P_{\bar{c}} \setminus P_c\}\right|, \quad K = 10 \tag{5}$$

순위 품질 (H2). 큐레이터 등급 $g \in \{0,1,2,3\}$(무관 / 사조·매체 일치 / 조형 또는 정서 일치 / 조형·정서와 현재 맥락까지 일치)으로 NDCG@10 [13]을 계산한다. 관람 가능성은 등급에 넣지 않고 별도 축(E2)으로 유지한다.

$$\text{NDCG@10} = \frac{1}{\text{IDCG@10}} \sum_{i=1}^{10} \frac{2^{g_i} - 1}{\log_2(i+1)} \tag{6}$$

모든 조건의 상위 10개를 풀링해 판정하므로 어느 조건의 상위 10개에도 미판정 작품이 없다. IDCG는 해당 질의의 판정 풀 전체로 계산하며, 풀 밖의 이상적 작품은 반영하지 못하나 조건 간에 같은 방향으로 작용한다.

회복 세션 수 (E1). 원 계획의 턴 단위 회복 지표 T_{rec}는 장기 메모리가 세션 종료 시에만 갱신된다는 점과 어긋난다. 전환 세션 안의 회복은 주로 현재 세션 발화가 주도하므로, 메모리 구조의 효과는 다음 세션의 시작에서 드러난다. 따라서 전환 이후 세션 시작 체크포인트 $j = 1, 2, 3$(C형 세션 4·5·6)에서

$$\text{ok}_j = \mathbb{I}\left[\text{CR@10}_j \le 0.10 \ \wedge \ \text{P@10}_j^{\text{new}} \ge \pi_0\right] \tag{7}$$

을 정의하고, $S_{\text{rec}} = \min\{j : \text{ok}_j = \text{ok}_{j+1} = 1\}$로 둔다. P@10^{new}는 새 취향 적합 작품의 정밀도이며 π_0는 개발 세트에서 [보정]한다. 관찰 기간 안에 회복하지 못하면 중도절단($S_{\text{rec}} > 2$)으로 기록하고, 회복 분포와 중도절단률을 함께 보고한다. 전환 세션 내부의 턴별 CR 궤적은 기술 통계로만 제시한다. 이 정의는 Core 뼈대의 Oracle Recall 기준을 대체한다. Core 조건표에는 Oracle 조건이 없어 해당 기준이 계산되지 않기 때문이다.

미검증 방문 주장률과 검증 주장 포괄률 (E2). 응답의 방문 주장 집합을 C_{visit}, 레코드 Γ_t가 주장 ℓ을 지지하는지를 $\text{supp}(\ell, \Gamma_t)$라 하면

$$\text{UCR} = \frac{|\{\ell \in C_{\text{visit}} : \neg\, \text{supp}(\ell, \Gamma_t)\}|}{|C_{\text{visit}}|}. \tag{8}$$

주장을 아예 하지 않아 UCR을 낮추는 회피를 막기 위해, Γ_t에 값이 있는 검증 가능 필드 집합 F_t 대비 지지된 주장의 비율인 VCC$= |\{\ell : \text{supp}(\ell, \Gamma_t)\}|/|F_t|$를 함께 보고한다. B4는 슬롯 템플릿과 검증기로 방문 주장을 구조적으로 제한하므로 B4-U 대비 UCR 감소는 상당 부분 설계에서 기인한다. 따라서 이 비교는 효과 검정이 아니라 제약이 의도대로 작동하는지의 감사로 해석하며, 미지지 주장은 DATE/VENUE/FEE/STATUS/작품 단위 전시 주장으로 분류한다.

기타 탐색 지표. 추출 F1(표 3), 확인 질문 트리거 빈도, 응답 지연 p95, 호출당 비용.

6.5. 라벨링

평가 질의마다 모든 조건의 상위 10개를 합친 풀을 조건 표시 없이 무작위 순서로 판정한다 [3]. 평가자는 사용자의 페르소나 카드(모든 맥락 포함)와 현재 체크포인트까지의 스크립트를 보고, 등급 g와 "다른 맥락에 적합" 여부를 함께 표시해 $P_c, P_{\bar{c}}$를 구성한다. C형은 "전환 전 취향에 적합"을 같은 방식으로 표시한다. 2차 평가자가 판정의 20%를 독립 채점하고 순서 척도 Krippendorff's α [10]를 보고한다(목표 ≥ 0.67). LLM 판정은 사전 분류와 불일치 탐지에만 쓰고 최종 정답으로 쓰지 않으며, LLM–사람 일치도는 탐색적으로 보고한다. 1차 평가자가 연구자 본인이라는 점은 한계로 명시한다. 예상 판정 수는 평가 세트 20명(질의 60개)에서 약 1,500건, 30명에서 약 2,250건이며 1차 평가자 8–18시간이다(계획값).

6.6. 통계 분석

분석 단위는 시뮬레이션 사용자이다. 체크포인트별 지표를 사용자별로 평균한 뒤 조건 간 짝지은 차이를 구하고, 사용자 단위 군집 paired bootstrap [6](10,000회) 95% CI, 평균 차이, 효과크기 d_z를 보고하며 부호 뒤집기 순열검정(10,000회)을 병행한다. H1·H2에 Holm 보정 [11]을 적용한다. 짝지은 t 근사에서 검정력 0.8로 검출 가능한 최소 효과는 $n = 20$일 때 $d_z \approx 0.74$, $n = 30$일 때 $d_z \approx 0.59$(양측 0.025 기준)이다. 따라서 유의하지 않은 결과를 "효과 없음"으로 해석하지 않고 신뢰구간으로 보고한다. G(가드)는 B4−B2의 NDCG@10 차이의 95% CI 하한이 $-\delta([\delta = 0.05])$보다 큰지로 판단한다.

확증 해석의 전제. 다음 네 조건이 모두 충족될 때만 H1·H2를 확증 결과로 보고하고, 하나라도 어기면 모든 결과를 탐색적으로 표기한다. (i) 평가 세트 사용자 ≥ 20명, (ii) 사용자 단위 개발/평가 분할, (iii) 10/22 본실험 전 가설·지표·임계값·분석 스크립트 해시를 저장소 태그 `prereg-v1`로 동결, (iv) 부록 C의 재현성 기록 완비. 개발 세트 결과는 규모와 무관하게 탐색적이다.

민감도 분석. $\tau_m \pm 0.05$, $\theta = 0$(맥락 항 제거), s_i를 스크립트 만족도로 대체, B형 단독 H1, 유형별 층화에서 H1의 방향이 유지되는지 확인한다.

7. 실행 계획과 운영 규칙

7.1. 6주 로드맵과 게이트

그림 4와 표 5은 Core 뼈대의 주차 계획을 v2의 날짜 게이트에 맞춘 것이다. 미달한 게이트는 일정 지연이 아니라 **범위 축소**로 해결하며, 조정 내용을 결과와 함께 기록한다.

7.2. Go/No-Go 규칙

새 기능을 추가하기 전에 세 가지를 묻는다. "이 기능이 CR@10·NDCG@10·S_{rec}·UCR 중 무엇을 바꾸는가?", "다음 주 실험을 막는 blocker인가?", "새 모델·데이터 없이 해결 가능한가?" 세 질문에 답하지 못하는 기능은 추가하지 않는다. 증상별 우선 조치는 표 6와 같다.

7.3. 오류 분석과 감사 연결

각 실패는 `query_id`, 단계, 기대값, 관찰값, 근본 원인, 수정 내용, 커밋으로 감사 로그와 연결한다. 범주는 여섯 가지이다: (1) 추출 오류(슬롯 누락·허위 span), (2) 메모리 쓰기 오류(잘못된 MERGE/GENESIS·억제 누락), (3) 라우팅 오류(맥락 오선택), (4) 검색 오류(재작성 질의 표류·어휘 불일치), (5) 그라운딩·주장 오류(연결 실패·미지지 주장), (6) 평가 인공물(스크립트 페르소나 이탈·판정 불일치). 범주 (6)은 시스템 결함과 섞이지 않도록 따로 집계한다. 최종 원고는 범주별 빈도와 대표 사례 2–3건을 로그 발췌와 함께 제시한다.

7.4. 결과 입력 규칙

결과표의 빈칸은 실제 실행 결과로만 채운다. 목표치, 개발 세트 수치, 예시 숫자를 최종 결과처럼 쓰지 않는다. 부록 C의 재현성 항목이 모두 채워진 경우에만 통제 실험 결과표를 보고한다. 값마다 산출 스크립트, 커밋, 스냅샷 ID를 추적할 수 있어야 한다.

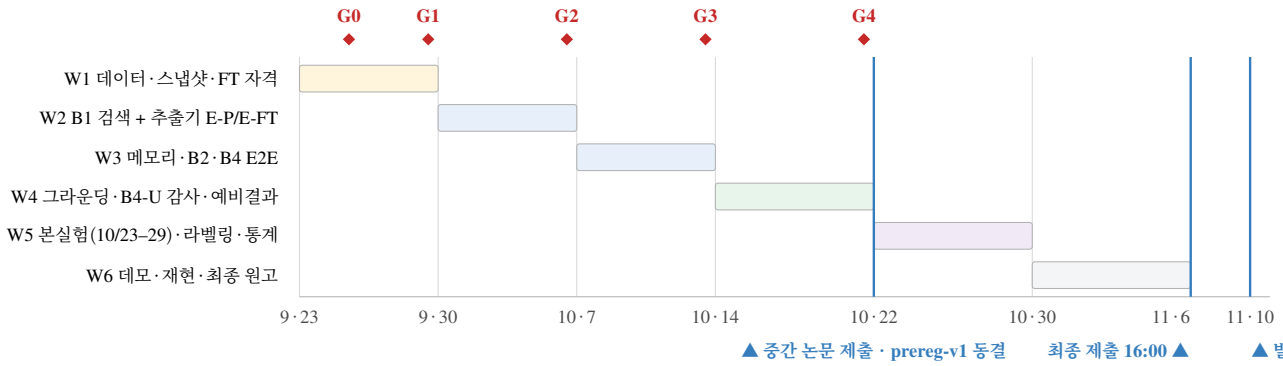


그림 4. 9/23–11/10 실행 일정. 빨간 마름모는 게이트, 파란 세로선은 제출·발표 마일스톤이다. 본실험(10/23–10/29)은 사전등록 태그 동결 이후에만 시작한다.

주차 (기간)	목표	필수 산출물	게이트 / Go 기준	실패 시 축소
W1 (9/23–9/29)	데이터·스냅샷·FT 자격	`artwork·exhibition·link·lexicon` 테이블, 스키마 감사, 사전 v0(100항목), FT 10예제 작업	**G0 (9/25)** FT 작업 생성 가능 여부; **G1 (9/29)** 해설문 보유 작품 ≥ 500, 스냅샷 체크섬	필드 축소, E-P 경로 확정
W2 (9/30–10/6)	B1 + 추출기	T/L 인덱스, RRF, JSON 추출기+검증기, 학습 200–300건	**G2 (10/6)** 20질의 무중단·NDCG 코드 실행, E-P vs E-FT 비교, 추출기 동결	암묵 슬롯 일부 축소, E-P 채택
W3 (10/7–10/13)	메모리	Session Node·Cluster·Router, 개발 세트 스크립트, B2 슬롯	**G3 (10/13)** B1·B2·B4 end-to-end 1회 완주, CR·S_{rec} 자동 계산	$\theta = 0$ 대안 유지, B3 제외
W4 (10/14–10/21)	그라운딩·예비 결과	전시 어댑터, 슬롯 템플릿·검증기, B4-U 감사, 라벨링 파일럿, 원고	**G4 (10/21)** 개발 세트 예비 결과, 동일 R_{10}에서 UCR 감사	작품 단위 주장 금지, 감사 표본 축소
W5 (10/22–10/29)	본실험	평가 세트 재생, 풀링 판정, 통계 스크립트 실행	결과표 모든 칸 + CI + 오류 로그; 10/22 `prereg-v1` 태그	평가 사용자 20명 고정
W6 (10/30–11/6)	데모·문서	Streamlit, GitHub, 1분 영상, 최종 논문·발표자료	fresh clone 실행 + 데모 완주; 11/6 16:00 제출	캐시 기반 읽기 전용 데모

표 5. 6주 실행 계획과 게이트. 게이트 결과란은 §8에 실측으로 기입한다.

증상	먼저 수정할 것	금지
B1 미작동	데이터 적재·인덱스·RRF	메모리·FT 추가
CR@10 높음	Router(θ, ρ, match 정의)	재순위 도입
S_{rec} 김	tentative 승격(n_{act}), 확인 질문	반감기 튜닝부터
UCR 높음	주장 화이트리스트·슬롯·검증기	생성기 FT
추출 F1 미달	스키마·few-shot → E-FT(G0 통과 시)	생성기 FT
NDCG만 낮음	사전 확장·토크나이저 → (본실험 후) 재순위·이미지 인덱스 단일 절제	본실험 중 추가

표 6. Go/No-Go 결정표. 본실험 동결 이후에는 어떤 수정도 평가 세트 결과를 보고 하지 않는다.

8. 구현 현황과 예비 결과 (제출 직전 기입)

코퍼스. 작품 [ ]건, 해설문 [ ]건, 전시 [ ]건, 스냅샷 기준일 [ ].

게이트. G0 [ ], G1 [ ], G2 [ ], G3 [ ], G4 [ ]. 조정 사항: [미달 게이트와 축소 내용].

개발 세트 예비 결과. 추출 F1(명시/암묵) [ ]/[ ]; 보정값 τ_m =[ ], η, θ, ρ =[ ], π_0 =[ ]; 라벨링 속도 [ ]건/시간. 표 7의 값은 개발 세트에서 얻은 것으로 확증 검정 결과가 아니다.

[작성: 10/21까지 위 문단과 표 7를 실측값으로 채우고, 오류 사례 2–3건을 감사 로그와 함께 서술]

9. 한계와 윤리적 고려

첫째, 주 평가는 시뮬레이션에 의존하므로 절대 성능이 아닌 조건 간 상대 차이로만 해석한다. 둘째, 고정 스크립트 재생은 인과 귀속을 강화하지만 확인 질문 같은 적응적 대화 정책의 효과는 측정하지 못한다. 셋째, 표본 규모상 중간 이상의 효과만 검출할 수 있다. 넷째, 1차 평가자가 연구자 본인이며, 감각어 사전과 기관 해설문은 어휘·문화 편향을 가질 수 있다. 다섯째, 단일 기관 코퍼스와 전시 단위 API

조건	NDCG@10 ↑	CR@10 ↓	S_{rec} (회복/중도절단)	UCR ↓	VCC ↑	비고
B1 무기억	[ ]	[ ]	[ ]	[ ]	[ ]	
B2 전체 이력	[ ]	[ ]	[ ]	[ ]	[ ]	
B3 세션 요약 (선택)	[ ]	[ ]	[ ]	[ ]	[ ]	
B4 구조화 메모리	[ ]	[ ]	[ ]	[ ]	[ ]	
B4-U (감사)	=B4	=B4	—	[ ]	[ ]	R_{10} 동결

확증 H1 (B2→B4, CR@10): Δ =[ ], 95% CI [ ], d_z =[ ], p_{Holm} =[ ]
확증 H2 (B1→B4, NDCG@10): Δ =[ ], 95% CI [ ], d_z =[ ], p_{Holm} =[ ]
가드 G (B4−B2, NDCG@10): 95% CI 하한 [ ] $> -\delta$ 여부 [ ]

표 7. 결과 보고 양식. 각 칸은 사용자 평균과 95% 군집 bootstrap 신뢰구간을 기록한다. 개발 세트 값을 기입할 때는 표 제목에 "개발 세트·탐색적"을 명시한다.

는 외적 타당성을 제한하며, 전시 연결은 실제 방문 가능성을 보장하지 않는 대리 지표이다. 여섯째, 정서 관련 기억은 목적 수준으로 추상화해 저장하고, 동의 범위와 보존 기간을 두며 사용자가 열람·수정·삭제할 수 있게 한다. 근현대 작품 이미지는 기관 이용조건을 따르고 원본을 저장·재배포하지 않는다. 실관람객 파일럿은 IRB 심의 또는 면제 확인과 동의 뒤, 여건이 될 때만 소규모 정성 연구로 수행한다.

10. 결론

본 중간 논문은 예술 감상의 다중 맥락 개인화를 위해 맥락 분리형 취향 메모리를 설계하고, 메모리 구조의 효과만 분리해 측정하는 통제 비교 프로토콜을 제시했다. 핵심은 모델의 수가 아니라 귀속 가능성이다. 동일 검색기에서 메모리 슬롯만 바꾸어 CR@10과 NDCG@10을 측정하고, 동일 추천 목록에서 발화 제약만 바꾸어 UCR을 감사하며, 파인튜닝은 추출기에 국소적으로 적용한다. 원안의 멀티모달 검색, 재순위, 신선도 필터는 걷어내고 하나의 질문을 끝까지 검증하는 범위로 줄였다. [작성: 개발 세트 예비 결과 한 문장]. 최종 보고서에서는 H1·H2의 결과를 효과크기, 신뢰구간, 오류 사례와 함께 보고한다.

참고문헌

[1] Panos Achlioptas, Maks Ovsjanikov, Kilichbek Haydarov, Mohamed Elhoseiny, and Leonidas J. Guibas. ArtEmis: Affective language for visual art. In *CVPR*, 2021. 2

[2] Mohammad Aliannejadi, Hamed Zamani, Fabio Crestani, and W. Bruce Croft. Asking clarifying questions in open-domain information-seeking conversations. In *SIGIR*, pages 475–484, 2019. 2, 4

[3] Chris Buckley and Ellen M. Voorhees. Retrieval evaluation with incomplete information. In *SIGIR*, pages 25–32, 2004. 2, 7

[4] Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready AI agents with scalable long-term memory. *arXiv preprint arXiv:2504.19413*, 2025. 2

[5] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Büttcher. Reciprocal rank fusion outperforms Condorcet and individual rank learning methods. In *SIGIR*, pages 758–759, 2009. 4

[6] Bradley Efron and Robert J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993. 7

[7] Luke Friedman, Sameer Ahuja, David Allen, Zhenning Tan, Hakim Sidahmed, Changbo Long, Jun Xie, Gabriel Schubiner, Ajay Patel, Harsh Lara, et al. Leveraging large language models in conversational recommender systems. *arXiv preprint arXiv:2305.07961*, 2023. 1, 2

[8] Noa Garcia and George Vogiatzis. How to read paintings: Semantic art understanding with multi-modal retrieval. In *ECCV Workshops*, 2018. 2

[9] Getty Research Institute. Art & architecture thesaurus (AAT) online. https://www.getty.edu/research/tools/vocabularies/aat/. 6

[10] Andrew F. Hayes and Klaus Krippendorff. Answering the call for a standard reliability measure for coding data. *Communication Methods and Measures*, 1(1):77–89, 2007. 7

[11] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979. 7

[12] Dietmar Jannach, Ahtsham Manzoor, Wanling Cai, and Li Chen. A survey on conversational recommender systems. *ACM Computing Surveys*, 54(5):1–36, 2021. 1

[13] Kalervo Järvelin and Jaana Kekäläinen. Cumulated gain-based evaluation of IR techniques. *ACM Transactions on Information Systems*, 20(4):422–446, 2002. 6

[14] Tongyoung Kim, Jeongeun Lee, Soojin Yoon, Sunghwan Kim, and Dongha Lee. Towards personalized conversational sales agents: Contextual user profiling for strategic action. In *Findings of EMNLP*, pages 5131–5154, 2025. 2

[15] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *NeurIPS*, 2020. 2

[16] Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating very long-term conversational memory of LLM agents. In *ACL*, pages 13851–13870, 2024. 2

[17] OpenAI. Fine-tuning now available for GPT-4o. https://openai.com/index/gpt-4o-fine-tuning/, . Accessed 2026-09-23. 5

[18] OpenAI. API deprecations: Update to OpenAI's self-serve fine-tuning; legacy GPT model snapshots. https://developers.openai.com/api/docs/deprecations, . Accessed 2026-09-23. 5

[19] OpenAI. Supervised fine-tuning. https://developers.openai.com/api/docs/guides/supervised-fine-tuning, . Accessed 2026-09-23. 5

[20] Stephen E. Robertson and Hugo Zaragoza. The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. 4

[21] Xiaolei Wang, Xinyu Tang, Wayne Xin Zhao, Jingyuan Wang, and Ji-Rong Wen. Rethinking the evaluation for conversational recommendation in the era of large language models. In *EMNLP*, 2023. 2

[22] Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. LongMemEval: Benchmarking chat assistants on long-term interactive memory. In *ICLR*, 2025. 2

[23] Jianfei Xiao, Xiang Yu, Chengbing Wang, Wuqiang Zheng, Xinyu Lin, Kaining Liu, Hongxun Ding, Yang Zhang, Wenjie Wang, Fuli Feng, and Xiangnan He. AlpsBench: An LLM personalization benchmark for real-dialogue memorization and preference alignment. *arXiv preprint arXiv:2603.26680*, 2026. 1, 2

[24] Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, and Yongfeng Zhang. A-MEM: Agentic memory for LLM agents. *arXiv preprint arXiv:2502.12110*, 2025. 2

[25] Shunyu Yao, Jeffrey Zhao, Dian Yu, Nan Du, Izhak Shafran, Karthik Narasimhan, and Yuan Cao. ReAct: Synergizing reasoning and acting in language models. In *ICLR*, 2023. 3

[26] Wanjun Zhong, Lianghong Guo, Qiqi Gao, He Ye, and Yanlin Wang. MemoryBank: Enhancing large language models with long-term memory. In *AAAI*, 2024. 2

부록

A. 원안 대비 변경 내역

2026-09-23 제안서 피드백(범위 과다, 데이터 통합 미착수, 다수 모델 운용의 자원 제약, 지표화 요구, 파인튜닝 에이전트 제안)을 반영한 변경이다. 제외된 모듈은 폐기하지 않고 복귀 조건과 함께 향후 과제로 둔다.

항목	v1 원안 (9월 초)	Core 뼈대 (9/23)	v2 다운사이징 (9/23)	**v3 통합본 (본 원고)**
제목	장기 미학 메모리 + 2층 전시 그라운딩 + 멀티모달 검색	경량 CRS + 2층 전시 그라운딩	맥락 분리형 장기 취향 메모리	v2 유지
확증 가설	H1–H5 (7개 검정)	4개 지표 모두 primary	H1·H2 (2개 검정)	H1·H2 + NDCG 비열등 가드, 나머지 탐색
비교 조건	B0–B5, B4a, B4R, B5-F, B5-E0, Oracle	B1/B3/B4/B4-U/B5 (B2 선택)	B1/B2/B4 (+B3)	B1/B2/B4 (+B3) + 감사용 B4-U
메모리 투입	벡터 혼합 $\mathbf{v}_t$	질의 표현 결합(미정의)	공유 프롬프트 슬롯 Φ	v2 유지
메모리 규칙	MERGE/BRIDGE/GENESIS, 4상태, 경계 대역 LLM 판정	BRIDGE/decay 비필수	MERGE/GENESIS, 3상태	v2 유지; BRIDGE는 로그만
검색	$T \cdot X \cdot V \cdot L$ 가중 RRF + 크로스 인코더	BM25 + dense RRF	$T \cdot L$ RRF	유지; 재순위·이미지 인덱스는 본실험 후 단일 절제
그라운딩	신선도 3상태, 정합도 식, B5/B5-F	RQ3 primary (B4-U vs B5)	설계 제약(확인 필드만 발화)	설계 제약 + UCR·VCC 감사 (E2)
회복 지표	T_{rec} (턴)	T_{rec} (턴, Oracle Recall 90%)	T_{rec} (턴)	S_{rec} (세션 시작 체크포인트) + 턴 궤적 기술
평가 규모	3유형×10변형×10세션 (300)	S0 45 → S1 90 → S2 300	B·C형×10–15변형×5세션, 고정 스크립트 재생	개발 6–12명 / 평가 20–30명, C형 6세션
파인튜닝	미정	조건부 (W2 미달 시)	G0 자격 → G2 비교	G0·G2 유지, 원천 스크립트 단위 bootstrap
H1 대상	—	—	다중 맥락 사용자 (표 간 불일치)	B형 + C형 전환 후, 층화·B형 단독 민감도
운영 장치	—	성공 조건, Go/No-Go, 감사 로그, 저장소, 실행 명령	날짜 게이트 G0–G4	게이트 + Core 운영 장치 전부 + 사전등록 태그
데이터	MMCA, 문화포털, Met, Harvard, Getty AAT	코퍼스 1개 + 전시 API 1개	MMCA, 문화포털 스냅샷, 자체 사전	v2 유지
파일럿	20명	S3 (IRB 후)	IRB 여건 시 5–10명 정성	v2 유지

B. 감사 로그 스키마, 저장소 구조, 실행 명령

턴 레코드. 한 줄이 한 턴이며 모든 조건에서 같은 필드를 쓴다.

```
{"query_id": "C07-s4-t1", "user_id": "C07", "session_id": 4, "turn": 1, "condition": "B4",
 "snapshot_id": "...", "prompt_hash": "...", "model_id": "...", "extractor_id": "...", "seed": 0,
 "extracted_profile": {...}, "evidence_spans": [...],
 "active_cluster_id": "k3", "router_probs": {"k1": 0.0, "k3": 0.0}, "clarification_triggered": false,
 "rewritten_query": "...", "retrieval_scores": [{"artwork_id": "...", "T": 0, "L": 0, "rrf": 0.0}],
 "R10": ["..."], "grounding_record": [{"exhibition_id": "...", "status": "VERIFIED@snapshot",
 "checked_at": "...", "source_url": "..."}], "final_claims": [...], "removed_sentences": [...],
 "latency_ms": 0, "cost_usd": 0.0}
```

실패 레코드. `query_id`, `stage` (extract / write / route / retrieve / ground / eval-artifact), `expected`, `observed`, `root_cause`, `fix`, `commit`.

저장소 구조.

```
arthemis/
  data/{raw,processed,snapshots,lexicon}/      # 스냅샷은 체크섬과 함께 보존
  src/{ingest,extract,memory,retrieval,grounding,orchestrator,generation}/
  sim/{personas,scripts_frozen}/               # 평가 스크립트는 생성 즉시 해시 기록
```

```
ft/{data,jobs}/                              # 학습/검증/시험 JSONL, 작업 ID 기록
eval/{labels,metrics.py,stats.py,run_retrieval.py,run_memory_eval.py,
      run_grounding_audit.py,run_extractor_eval.py}
app/streamlit_app.py
configs/  audits/  prereg/  tests/
requirements.lock  README.md
```

최소 실행 명령.

```
python eval/run_retrieval.py        --cond B1          # -> NDCG@10, Recall@50, MRR
python eval/run_extractor_eval.py   --arms E-P,E-FT    # -> micro-F1, span F1, schema validity, latency/cost
python eval/run_memory_eval.py      --cond B1,B2,B4    # -> NDCG@10, CR@10, S_rec (+ audit JSONL)
python eval/run_grounding_audit.py  --cond B4,B4-U     # -> UCR, VCC, claim audit
python eval/stats.py --prereg prereg/prereg-v1.yaml    # -> cluster bootstrap CI, d_z, permutation p, Holm
streamlit run app/streamlit_app.py                     # input -> memory -> recommendation -> exhibition status
```

C. 재현성 기록 양식

통제 실험의 결과표는 아래 항목이 모두 채워진 경우에만 보고한다. 목표값을 측정값으로 대체하지 않는다.

항목	기록
코퍼스	MMCA 수집 경로 [ ], 수집일 [ ], 작품/해설문 수 [ ]/[ ], 중복·결측 처리 [ ], 체크섬 [ ]
전시 스냅샷	$\mathcal{E}_{\text{eval}}$ ID [ ], 기준일 [ ], 체크섬 [ ], 전시 수 [ ]
LLM	기반 스냅샷 [ ], 파인튜닝 작업 ID [ ], 결과 모델 ID [ ], 에폭 [ ], 학습/검증 파일 ID [ ]
기타 모델	텍스트 임베딩 [ ], BM25 토크나이저·k_1·b [ ], 시뮬레이터 LLM [ ], 보조 판정 LLM [ ]
하이퍼파라미터	$\tau_m, n_{\text{act}}, h, \eta, \theta, \rho, \kappa, \tau_g, \pi_0, \delta, L_{\max}$ 보정값 [ ] 및 보정 로그 위치 [ ]
실행 환경	OS [ ], `requirements.lock` 해시 [ ], 코드 커밋 [ ], temperature [ ], seed [ ], 프롬프트 해시 [ ], fresh clone 재현 확인일 [ ]
사전등록	`prereg-v1` 태그 커밋 [ ], 동결일 [ ], 분석 스크립트 해시 [ ]
시뮬레이션	페르소나 카드 버전 [ ], 평가 스크립트 해시 목록 [ ], 개발/평가 사용자 수 [ ]/[ ]
라벨링	평가자 수 [ ], 풀 크기 [ ], 판정 수 [ ], 등급 α [ ], 2차 채점 비율 [ ]
윤리	파일럿 수행 여부 [ ], IRB 심의/면제 [ ], 보존 기간 [ ]

D. 결과 서술 템플릿

확증 가설. "H[ ]에서 [조건 A]→[조건 B]의 [주 지표] 짝지은 차이는 [ ] (95% CI [[ ], [ ]], d_z =[ ])이며, Holm 보정 후 p =[ ]이다. 이 결과는 시뮬레이션 조건에서만 관찰되었다."

가드. "B4−B2의 NDCG@10 차이의 95% CI 하한은 [ ]로, 비열등 여유 $-\delta$보다 [크다/작다]."

E1. "C형 사용자 중 B4는 [ ]%가 전환 후 첫 세션에서, [ ]%가 두 번째 세션에서 회복했고 [ ]%가 중도절단되었다 (B2: [ ]/[ ]/[ ]%)."

E2. "동일 R_{10}에서 B4-U와 B4의 UCR은 각각 [ ], [ ]였고 VCC는 [ ], [ ]였다. 미지지 주장은 [DATE/VENUE/FEE/STATUS/작품 단위]에 집중되었다."

E3 (둘 중 실제 경로 하나만 남김). "G0에서 자격이 확인되지 않아 E-P를 채택했다." / "E-FT의 암묵 F1은 E-P 대비 [ ] (원천 단위 95% CI [[ ], [ ]])로 [채택/비채택]되었다."

오류 사례. "`query_id` [ ]에서 [단계]의 기대값은 [ ], 관찰값은 [ ]였다. 근본 원인은 [ ]이며 커밋 [ ]에서 [수정]했다."

E. 제출 직전 점검표

☐ 모든 [ ]와 [ ] 자리표시를 실측·확정값으로 교체했거나, 남은 항목을 "미측정"으로 명시했다.
☐ 표 7 제목에 "개발 세트·탐색적" 또는 "평가 세트·확증"을 실제 경로대로 표기했다.
☐ E3 서술에서 실제 경로 하나만 남겼다.
☐ 게이트 G0–G4 결과와 범위 축소 내역을 §8에 기록했다.
☐ 모든 참고문헌을 공식 페이지에서 확인했다(특히 arXiv 2026 문헌과 OpenAI 문서의 확인일).

□ 코퍼스·스냅샷 체크섬, 모델 ID, 프롬프트 해시, 커밋이 부록 C와 일치한다.
□ fresh clone에서 부록 B의 명령이 오류 없이 실행된다.
□ 감정 관련 원문이 저장소·로그·그림에 남아 있지 않다.