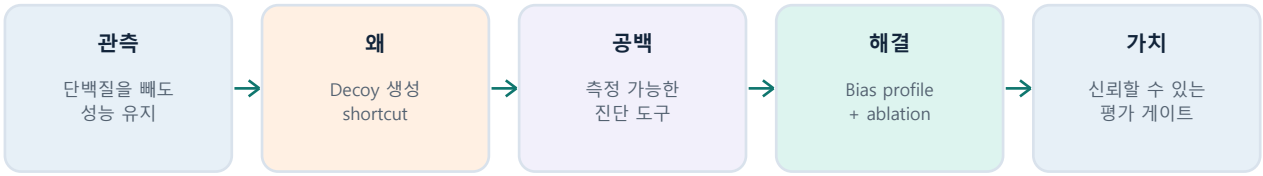
AIGEN SCIENCES · 참여기업 과제

신약개발 Benchmark의 Bias 진단

모델 성능과 데이터셋 편향을 분리 진단하는 도구



보고서 목적

발표자료 19쪽의 표현과 사실관계를 우선해 10-15분 발표 스크립트, 전문 검토, 예상 질의응답, 연구제안서, 스토리텔링 개선안, 구현 아키텍처와 WBS, Baseline 실험계획을 하나의 제출용 문서로 정리했다. 원자료에 없는 내용은 '보완 제안'으로 명확히 구분했다.

기준일 2026-09-15 | 원자료: 20260914_모두연_decoy편향진단_발표자료_final.pdf

0. Executive Summary

이 보고서는 '높은 benchmark score가 실제 biological interaction 학습을 의미하는가?'라는 질문에서 출발한다. 원자료는 단백질 입력을 제거해도 성능이 유지되는 관측을 제시하고, 이를 Decoy 생성 규칙에서 유래한 ligand-side shortcut 가능성과 연결한다.

> 핵심 결론
> 프로젝트의 산출물은 새로운 screening 모델이 아니라, active/decoy 집합을 입력받아 property bias, scaffold bias, similarity bias를 분리 측정하고 protein-aware와 ligand-only 성능 차이까지 함께 보여주는 재사용 가능한 진단 pipeline이어야 한다.

축	원자료에서 확인되는 내용	보고서에서의 적용
문제	Decoy가 실험 inactive가 아니라 생성 규칙에 의해 구성될 수 있음	데이터셋 artifact와 모델 성능을 분리 진단하는 문제로 정식화
관측	단백질을 빼도 점수가 같음	'단백질을 사용하지 않는다'가 아니라 shortcut 가능성의 경고로 표현
비교	DUD-E와 LIT-PCBA를 공개 benchmark로 비교	DUD-E는 편향 가능성이 알려진 쪽, LIT-PCBA는 상대적 완화 기준
지표	물성 전용 ROC-AUC, EF1%, scaffold coverage, NN Tanimoto 분포 거리	개별 profile 우선, 종합 등급은 참고값
PoC	DUD-E 5 타겟, LIT-PCBA 3 타겟, 물성 6종 RF AUC	6주 WBS와 falsification 조건으로 구체화

독자가 이 보고서에서 얻는 것

- 바로 읽어 말할 수 있는 12분 30초 발표 대본과 15분 확장 지점
- 19개 슬라이드의 메시지, 논리 리스크, 수정 권고
- 기업 심사위원의 반론을 선제적으로 다루는 Q&A 20개
- 연구질문, 가설, 실험, 지표, 통계와 실패 기준이 연결된 연구제안서
- 제품화 가능한 모듈 구조, 데이터 계약, WBS, Baseline 비교표

1. 원자료 사실관계와 해석 원칙

원자료는 19쪽 발표자료이며, 1쪽의 제목과 12-19쪽의 본론이 핵심이다. 2-10쪽은 AIGEN Sciences의 통합 AI, 의생명 AI 역량, dry-wet small closed-loop, prospective validation, AI-Experimental Decision-making Structure를 설명한다.

항목	원자료 기반 사실	보고서 해석 원칙
중심 관측	슬라이드 12: 단백질 쪽 입력을 없애도 성능이 그대로였다는 관측	원인 확정이 아닌 ligand-side shortcut 가능성으로 해석
Decoy 배경	슬라이드 13-15: positive는 active, negative는 decoy이며, decoy 생성 규칙과 허용 폭이 흔적을 남길 수 있음	dataset construction artifact라는 표현 사용
관련 연구	Mysinger 2012, Chen 2019, Wallach & Heifets 2018, Tran-Nguyen 2020이 슬라이드 16에 기재	정확한 서지사항은 제출 전 원문 대조 필요
DUD-E	102 타겟, active 22,886, active 1개당 decoy 50, dude.docking.org, 2026-09-13 표기	수치는 버전·정제 규칙과 함께 보고
LIT-PCBA	15 타겟, active 7,761, inactive 382,674, drugdesign.unistra.fr/LIT-PCBA, 2026-09-13 표기	완전한 무편향이 아니라 상대적 완화 기준으로 표현
초기 평가	DUD-E 5 타겟, LIT-PCBA 3 타겟, 물성 6종만 넣은 RF AUC	PoC의 시작 조건이며 전체 benchmark 일반화의 증거와 구분

보완 제안 표기 규칙

원자료에 직접 적힌 내용은 '원자료 기반'으로, 구현 후보나 추가 통계 설계는 '보완 제안'으로 표기한다. 두 층위를 섞지 않으면 심사위원 질문에 답할 때 사실, 가설, 계획을 명확히 분리할 수 있다.

표현을 반드시 정교하게 바꿀 세 문장

위험한 표현	권장 표현	이유
단백질을 안 쓴다	단백질 입력을 제거해도 높은 성능이 가능하므로 ligand-side shortcut이 존재할 가능성이 있다	ablation만으로 모델의 내부 사용 여부를 확정할 수 없음
DUD-E는 biased, LIT-PCBA는 unbiased	DUD-E는 편향 가능성이 알려진 비교군이고 LIT-PCBA는 상대적으로 완화된 기준군이다	LIT-PCBA도 완전한 무편향을 보장하지 않음
물성 AUC 0.5-0.6이면 전제가 틀렸다	사전 정의한 불확실성 구간에서 물성 AUC가 낮고 다른 지표도 차이가 없으면 가설을 수정한다	단일 AUC와 작은 PoC만으로 전제를 폐기하면 과잉해석 위험

2. 10-15분 발표용 상세 스크립트

아래 대본은 약 12분 30초를 기준으로 한다. 15분 발표가 주어지면 슬라이드 16의 선행연구, 17의 진단 개념, 19의 falsification criterion에 각각 30-40초를 추가한다. 11쪽은 채용 정보로 발표 논리와 직접 연결되지 않으므로 본문에서는 5초 이내로 처리하거나 삭제한다.

구간	쪽	시간	역할
Hook	1	0:00-0:25	문제의식을 질문으로 제시
기업 맥락	2-10	0:25-3:10	AIGEN의 의사결정·closed-loop와 평가 품질 연결
본론	12-16	3:10-7:40	관측 -> Decoy 메커니즘 -> 기존 증거
해결안	17-19	7:40-11:20	문제정의 -> 데이터 -> 평가와 falsification
결론	-	11:20-12:30	bias profile과 evaluation gate의 가치

슬라이드별 발표 대본

슬라이드 1 | 0:00-0:25 - Benchmark의 Bias 진단

안녕하세요. 저희가 다루려는 문제는 모델의 성능을 더 높이는 문제가 아닙니다. 먼저 '지금 보고 있는 높은 성능이 정말 모델의 능력일까?'를 묻는 문제입니다. benchmark 자체가 active와 decoy를 쉽게 구분하는 흔적을 가지고 있다면, 높은 점수는 생물학적 추론이 아니라 데이터셋 구조를 읽은 결과일 수 있습니다. 저희는 모델 성능과 데이터셋 편향을 분리 진단하는 도구를 제안합니다.

슬라이드 2 | 0:25-0:42 - 통합 AI 구조

AIGEN Sciences는 Insight, ChemTailor, Clinical Intelligence라는 세 가지 multimodal plug-in AI engine을 연결해 discovery와 development 전반의 Operational Intelligence를 지향합니다. 이 회사 맥락은 본 프로젝트가 실제 의사결정의 신뢰성을 높이는 평가 계층이라는 점을 보여주기 위한 배경입니다.

슬라이드 3 | 0:42-0:52 - 기업 플랫폼의 방향

이 슬라이드는 통합 플랫폼이 개별 모델의 섬처럼 존재하는 것이 아니라 서로 정보를 주고받는 구조라는 점을 보여줍니다. 여기서 중요한 키워드는 반복되는 iteration의 정보 밀도와 효율입니다. 반복이 제대로 작동하려면 평가 데이터도 신뢰할 수 있어야 합니다.

슬라이드 4 | 0:52-1:02 - AIGEN의 milestones

회사의 설립, 연구협력, 투자와 과제 수행의 흐름을 간단히 확인합니다. 이 부분은 발표의 증거라기보다 프로젝트가 실제 연구개발 환경과 연결되어 있음을 보여주는 맥락이므로 길게 설명하지 않겠습니다.

슬라이드 5 | 1:02-1:15 - Biomedical AI 역량

원자료는 biomedical language modeling에서 domain-specific AI로 확장해 온 역량을 제시합니다. 즉 이 프로젝트는 일반적인 데이터 분석이 아니라 의생명 지식과 분자 설계가 연결된 환경에서 평가 품질을 점검하는 과제입니다.

슬라이드 6 | 1:15-1:45 - Prediction performance에서 의사결정으로

신약개발에서는 어떤 타겟을 우선할지, 어떤 물질을 합성할지, 어떤 실험을 수행할지, 어느 pipeline을 중단하거나 지속할지를 결정해야 합니다. 따라서 개별 모델의 prediction performance만으로 생산성 향상을 보장하기 어렵고, AI 예측 정확도를 넘어 의사결정의 quality로 확장해야 합니다. 저희는 그 decision quality의 선행조건으로 evaluation quality를 점검합니다.

슬라이드 7 | 1:45-2:10 - Dry-wet lab small closed-loop

AI 모델의 예측 결과와 실험실의 검증 데이터가 실시간으로 피드백되는 closed-loop는 학습 효율을 높입니다. 하지만 출발 benchmark가 편향되어 있으면 모델 선택과 실험 우선순위부터 잘못될 수 있습니다. 좋은 closed-loop의 시작점은 좋은 benchmark입니다.

슬라이드 8 | 2:10-2:30 - Prospective validation

원자료는 다양한 challenging target class에서 예측과 실험 결과 사이의 간극을 반복적으로 확인하고 고도화한 사례를 보여줍니다. 이 슬라이드의 메시지는 '예측 결과는 실험으로 검증되어야 한다'는 것입니다. 저희는 그 앞 단계에서 benchmark 평가가 공정한지도 점검하려 합니다.

슬라이드 9 | 2:30-2:45 - 신약개발 AI bottleneck

신약개발은 제한된 실험, 데이터, 시간, 비용 안에서 불확실성을 얼마나 빨리 줄이는가의 문제입니다. sparse 또는 biased data, noisy assay, missing negative data, 비싼 실험 label과 proxy endpoint의 한계가 있습니다. Decoy bias는 이 중 'negative data가 어떻게 만들어졌는가'와 직접 연결됩니다.

슬라이드 10 | 2:45-3:05 - AI-Experimental Decision-making Structure

타겟 발굴, 물질 설계·합성·평가 과정의 decision trace가 다시 learning 대상이 되는 구조입니다. 이 구조에서 benchmark가 잘못된 신호를 주면 모델이 그 신호를 반복적으로 강화할 수 있습니다. 따라서 이 발표에서 제안하는 진단기를 평가 게이트로 넣는 것이 실무적 의미를 가집니다.

슬라이드 11 | 3:05-3:10 - 채용 정보

이 슬라이드는 프로젝트의 기술적 논리와 직접 연결되지 않으므로 본문 발표에서는 생략하거나 '조직 확장 맥락'으로 한 문장만 언급하고 넘어가겠습니다.

슬라이드 12 | 3:10-4:20 - 관측: 단백질을 빼도 점수가 같음

이 프로젝트는 하나의 이상한 관측에서 시작합니다. protein-ligand interaction을 학습한다고 생각한 screening model에서 protein 입력을 제거했는데도 AUC가 거의 달라지지 않았습니다. 이 사실만으로 모델이 단백질을 전혀 사용하지 않는다고 단정할 수는 없습니다. 다만 benchmark 내부에 ligand만으로 active와 decoy를 가르는 shortcut이 있을 가능성을 강하게 경고합니다. 그래서 저희의 첫 가설은 모델 성능의 일부가 target-specific biological interaction이 아니라 dataset construction artifact로 설명될 수 있다는 것입니다.

> 발표 안전문장
> 단백질 제거 후 성능 유지 = 모델이 단백질을 전혀 사용하지 않는다는 증명은 아니다. 동일 split의 ablation에서 ligand-side shortcut 가능성이 관측되었다는 뜻이다.

슬라이드 13 | 4:20-5:10 - 배경: Positive는 Active, Negative는 Decoy

Virtual screening은 분류 자체보다 순위가 중요합니다. 수많은 물질 중 실제 active를 얼마나 위에 올리는지가 핵심이므로 상위 1%에 active가 무작위 대비 몇 배 농축되는지를 보는 EF1%가 중요합니다. 그런데 원자료가 강조하듯 negative 라벨은 실험에서 확인된 inactive가 아니라 decoy일 수 있습니다. 따라서 active와 decoy를 잘 나누는 것이 곧 biological binding 예측을 잘한다는 뜻은 아닙니다.

슬라이드 14 | 5:10-6:00 - 메커니즘: decoy 생성 규칙

DUD-E 계열의 아이디어는 active와 물리화학적 성질은 비슷하게 만들되 구조적으로는 다른 decoy를 고르는 것입니다. 하지만 매칭이 같은 값을 정확히 맞추는 것이 아니라 허용 폭 안에서 이루어지면, 생성 과정에서 반복 가능한 잔여 차이가 남을 수 있습니다. 그러면 모델이 '이 ligand가 이 protein과 결합하는가?'가 아니라 '이 molecule이 active 생성과정에서 왔는가, decoy 생성과정에서 왔는가?'를 풀게 될 수 있습니다.

슬라이드 15 | 6:00-6:45 - 흔적: artificial enrichment와 analogue bias

artificial enrichment는 active와 decoy 사이의 물성 차이가 systematic하게 남아 물성만으로도 분류가 쉬워지는 현상입니다. analogue bias는 active가 특정 scaffold 또는 chemical series에 집중되어 구조적 유사성만으로도 높은 점수가 가능한 현상입니다. 두 현상 모두 모델 architecture의 결함으로만 볼 수 없고 데이터셋 구성

방식에서 생길 수 있다는 점이 핵심입니다.

슬라이드 16 | 6:45-7:40 - 증거와 관련 연구

원자료는 Mysinger 2012의 DUD-E 설계, Chen 2019의 편향 보고, Wallach와 Heifets 2018의 AVE bias, Tran-Nguyen 2020의 LIT-PCBA를 연결합니다. 특히 protein을 dummy atom으로 바꾸어도 두 곡선이 겹치고, active 5개와 decoy 5개만 학습해도 타겟별 AUC가 유지되는 사례를 제시합니다. 문제는 알려져 있지만 실무자가 자신의 dataset을 넣어 위험도를 빠르게 측정하는 재사용 도구가 부족하다는 것이 저희가 겨냥하는 gap입니다.

슬라이드 17 | 7:40-8:45 - 문제정의: 어떻게 진단하고 없앨 것인가

저희의 질문은 임의의 active/decoy 집합을 받아 decoy 편향을 정량적으로 진단할 수 있는가입니다. 세 질문을 분리합니다. 단순 물성만으로 두 집단이 구분되는가, active가 소수 scaffold에 집중되어 있는가, active와 decoy의 chemical similarity 구조가 비정상적으로 분리되는가입니다. 개별 지표를 먼저 보여주고, 종합 등급은 참고값으로만 두어 원인을 숨기지 않겠습니다.

슬라이드 18 | 8:45-9:35 - 데이터: DUD-E와 LIT-PCBA

DUD-E는 원자료 기준 102 타겟, active 22,886, active 1개당 decoy 50인 비교군입니다. LIT-PCBA는 15 타겟, active 7,761, inactive 382,674이며 실험 확인 inactive와 AVE bias 완화 변형을 포함하는 상대적 기준군입니다. 목표는 'DUD-E는 나쁘고 LIT-PCBA는 완벽하다'를 증명하는 것이 아니라, 두 구성의 차이가 진단 profile에 반영되는지 확인하는 것입니다.

슬라이드 19 | 9:35-11:20 - 평가: 지표가 맞는지까지 검증

첫째, 물성 전용 classifier의 ROC-AUC로 단순 물성 shortcut을 봅니다. 둘째, 상위 5·10개 scaffold가 전체 active를 덮는 비율을 봅니다. 셋째, active와 decoy 최근접 Tanimoto의 분포 거리를 봅니다. 넷째, 같은 screening model의 EF1%가 두 benchmark에서 얼마나 벌어지는지 비교합니다. 초기 PoC는 DUD-E 5 타겟과 LIT-PCBA 3 타겟으로 시작합니다. 물성 6종 RF AUC가 0.5-0.6 수준이고 다른 지표도 차이가 없다면, 결과를 억지로 성공으로 포장하지 않고 가설을 수정하겠습니다.

결론 멘트 | 11:20-12:30

정리하겠습니다. 저희가 해결하려는 문제는 모델을 하나 더 만드는 것이 아니라 모델의 높은 benchmark score를 믿어도 되는지 검사하는 도구를 만드는 것입니다. 입력은 active와 decoy dataset이고, 출력은 property bias, scaffold bias, similarity bias를 보여주는 bias profile입니다. 그리고 protein-aware와 ligand-only 모델의 차이를 함께 보아 성능 중 shortcut으로 설명될 가능성을 점검합니다. '이 모델의 성능이 좋은가?'라는 질문 앞에 '이 benchmark는 모델 성능을 평가하기에 충분히 공정한가?'라는 질문을 하나 추가하는 것이 목표입니다. 감사합니다.

3. 슬라이드별 전문 검토·논리 오류·보완점

아래 표는 발표자료 19쪽을 슬라이드 단위로 검토한 결과다. '논리 리스크'는 심사위원이 반론을 제기할 수 있는 지점이며, '보완 제안'은 원자료에 직접 적히지 않은 편집·실험 설계 제안이다.

쪽	현재 역할	강점	논리 리스크	보완 제안
1	제목 / 문제 선언	질문이 선명함	Tool의 입력·출력이 아직 보이지 않음	부제에 active/decoy -> bias profile을 추가
2	통합 AI 시스템	기업 맥락 제공	프로젝트 문제와 거리가 있음	20초 이내, 평가 품질로 연결
3	플랫폼 방향	통합 iteration 강조	슬라이드만 보면 핵심 주장 불명확	'반복 학습의 출발점은 공정한 평가' 한 줄 추가
4	회사 milestones	신뢰 맥락	본문 흐름 단절	Appendix 이동 또는 10초 처리
5	Biomedical AI 역량	기업 전문성 근거	인용 수치의 의미 설명 부족	domain-specific AI와 본 과제 연결 문장 추가
6	Prediction -> decision	과제 연결성 높음	평가 품질로 넘어가는 다리가 짧음	Evaluation gate 개념 삽입
7	Dry-wet loop	실제 활용 맥락	benchmark bias와 인과 연결이 암묵적	Bad benchmark -> bad model selection 화살표
8	Prospective validation	실험 검증을 강조	사례가 많아 메시지 분산	대표 2개 사례만 남기고 본 과제 연결
9	AI bottleneck	sparse/biased data가 명시됨	Decoy와 missing negative 관계 미설명	negative data 생성 문제를 강조
10	Decision structure	실무적 가치	진단기가 들어갈 위치가 없음	모델 평가 전 QC gate 표시
11	채용	조직 확장 맥락	연구 논리 단절	본문 삭제 또는 Appendix
12	핵심 관측	가장 강력한 Hook	단백질을 전혀 안 쓴다고 과해석 가능	shortcut 가능성, 동일 split ablation 명시
13	Active / Decoy 배경	EF1%와 라벨 문제 연결	decoy가 왜 위험한지 다음 장으로 분리 필요	active/inactive/decoy 라벨 도식
14	Decoy 생성 메커니즘	허용 폭이라는 원인 제시	허용 폭 -> 잔여 차이의 실증이 약함	예시 property residual 또는 toy diagram 추가
15	두 bias	개념 구분이 좋음	정량 지표가 바로 매핑되지 않음	각 bias 옆에 metric 연결
16	선행연구	문제의 학술적 근거	서지정보와 주장 범위가 제한됨	최종 제출 전 원문·DOI·그림 출처 확인
17	문제정의	세 지표와 종합등급 원칙	'편향을 없애는가'와 '진단하는가' 혼재	PoC 목표를 진단으로 한정, 제거는 후속
18	비교 데이터	known contrast 설계	DUD-E biased / LIT-PCBA unbiased 이분법 위험	상대적 완화 기준군으로 표현
19	평가 계획	falsification 의지	물성 6종, threshold, 표본 수 정의 부족	descriptor 목록 후보, CI, seed, target 선정 기준 추가

핵심 슬라이드의 수정 우선순위

우선순위	대상	수정 내용	기대 효과
P0	12-19	관측 -> 메커니즘 -> 연구 gap -> 진단 지표 -> 실험을 한 방향으로 재배열	발표의 논리적 spine 확보
P0	12	'모델이 다른 신호를 읽는다'를 'shortcut 가능성'으로 완화	과잉 주장 방지

우선순위	대상	수정 내용	기대 효과
P1	14-15	두 bias를 property AUC, scaffold coverage, NN Tanimoto로 연결	개념과 측정의 일치
P1	18-19	비교군의 성격과 작은 PoC의 한계를 명시	일반화 과장 방지
P2	2-11	기업 소개 1-2장으로 압축	본론에 시간 확보

4. 기업 심사위원 예상 질문 20개와 모범답변

Q1. 이미 Decoy bias 연구가 있는데 새로울 것이 무엇인가요?

새로운 현상을 최초로 발견한다고 주장하지 않습니다. 기존 연구의 artificial enrichment, analogue bias, AVE bias를 임의의 active/decoy dataset에 반복 적용할 수 있는 diagnostic workflow로 도구화하고, bias profile과 downstream EF1%를 연결해 실무 의사결정에 쓰도록 만드는 것이 신규성입니다.

Q2. DUD-E만 분석하면 충분하지 않나요?

한 benchmark에서 높은 bias score가 나온 것만으로는 metric이 작동하는지 알기 어렵습니다. 원자료에 제시된 LIT-PCBA를 상대 비교군으로 사용해 알려진 구성 차이가 진단 결과에 반영되는지 검증합니다.

Q3. LIT-PCBA를 unbiased라고 가정하나요?

아닙니다. 실험 확인 inactive를 포함하고 AVE bias 완화를 고려한 상대적 기준군으로 사용합니다. 완전한 무편향의 ground truth라고 주장하지 않습니다.

Q4. 왜 ROC-AUC인가요?

property-only classifier의 목적은 screening 모델의 최종 성능이 아니라 단순 물성만으로 class separability가 생기는지를 진단하는 것입니다. 따라서 ROC-AUC를 쓰고, 실제 랭킹은 EF1%로 별도 평가합니다.

Q5. AUC가 높으면 무조건 bias인가요?

아닙니다. 특정 assay나 타겟의 실제 화학적 차이일 수도 있습니다. property AUC, scaffold concentration, similarity 분포와 ablation 결과를 함께 보고 원인을 분리합니다.

Q6. 왜 Random Forest인가요?

설명 가능하고 계산 비용이 낮으며 소수의 tabular descriptor에서 강력한 baseline이기 때문입니다. 보완 제안으로 Logistic Regression을 함께 두어 비선형 모델 의존성을 점검합니다.

Q7. 모델 종류에 따라 결과가 달라지지 않나요?

맞습니다. 핵심은 특정 모델의 최고점이 아니라 낮은 복잡도의 모델에서도 separability가 재현되는지입니다. seed와 stratified CV를 고정하고 LR/RF 간 방향성을 비교합니다.

Q8. scaffold bias는 어떻게 정의하나요?

Bemis-Murcko scaffold로 active를 그룹화한 뒤 상위 5개와 10개 scaffold가 전체 active를 덮는 비율을 봅니다. 높은 concentration은 analogue memorization 위험의 신호로 해석하되, 단독 판정은 하지 않습니다.

Q9. Tanimoto에는 어떤 fingerprint를 쓰나요?

PoC에서는 RDKit Morgan fingerprint를 기본 후보로 두고 radius와 bit size를 고정합니다. fingerprint 선택에 민감한지는 보조 분석으로 확인합니다. 이는 원자료 외의 구현 보완 제안입니다.

Q10. Tanimoto 분포 거리는 정확히 무엇인가요?

각 molecule에서 반대 class의 nearest-neighbor Tanimoto를 계산해 분포를 만든 뒤, 중앙값과 Wasserstein distance 또는 KS statistic으로 두 benchmark의 분포 차이를 수치화하는 방안을 검토합니다.

Q11. 단백질을 빼도 성능이 유지되면 정말 dataset bias인가요?

그 사실만으로 확정할 수 없습니다. split leakage나 architecture artifact도 가능하므로 protein-aware, masked, ligand-only 조건을 동일 split과 seed로 비교해야 합니다.

Q12. 성능과 데이터 bias를 어떻게 '분리'하나요?

완전한 인과분리는 어렵습니다. model-independent dataset diagnostics와 model ablation을 결합해 성능 중 shortcut으로 설명될 가능성을 추정합니다. 발표에서도 '분리 진단'이라고 표현합니다.

Q13. 왜 EF1%인가요?

virtual screening에서는 극초기 상위 순위의 품질이 중요하기 때문입니다. 원자료도 상위 1% active enrichment를 핵심 평가 축으로 제시합니다.

Q14. 작은 target에서 EF1%가 불안정하지 않나요?

그렇습니다. target별 active 수를 같이 보고하고 bootstrap confidence interval과 반복 sampling을 적용하는 것이 보완 제안입니다. 필요하면 PR-AUC나 BEDROC를 보조지표로 둡니다.

Q15. 성공 기준은 무엇인가요?

DUD-E와 LIT-PCBA의 bias profile이 일관되게 구분되고, 그 차이가 ligand-only 또는 protein-ablated model의 EF1%와 방향성 있게 연결되는 것이 최소 성공조건입니다.

Q16. 예상과 달리 차이가 안 나면 실패인가요?

연구적으로는 중요한 결과입니다. 원자료도 물성 6종 RF AUC가 0.5-0.6 수준이면 전제를 재검토하는 조건을 제시합니다. 다만 단일 metric이 아니라 불확실성과 다른 지표까지 확인한 뒤 판단합니다.

Q17. 실무에서는 어떻게 사용합니까?

새 benchmark나 사내 screening dataset을 모델 훈련 전에 QC gate로 넣습니다. 결과는 property, scaffold, similarity의 개별 profile과 해석 가능한 주의사항으로 제공하고, 이후 모델 평가 결과와 함께 보게 합니다.

Q18. 수백만 compound면 계산량이 너무 크지 않나요?

full pairwise Tanimoto는 $O(N^2)$ 문제가 있습니다. 대규모 mode에서는 fingerprint indexing, approximate nearest neighbor, stratified sampling을 적용하는 확장 설계를 둡니다.

Q19. 종합 bias score를 만들 건가요?

핵심 output으로 두지 않습니다. 서로 다른 편향을 하나의 점수로 압축하면 원인이 사라집니다. 종합 등급은 traffic-light 참고값으로만 두고 개별 지표를 우선합니다.

Q20. 기업 입장에서 최종 산출물은 무엇인가요?

재현 가능한 진단 pipeline, target별 bias report, 그리고 JSON/CSV/PDF로 내보낼 수 있는 결과물입니다. 이후에는 사내 QC gate 또는 dashboard로 연결할 수 있습니다.

5. 연구제안서 재구성

연구제목
신약개발 Virtual Screening Benchmark의 Decoy 편향 진단도구 개발 - 모델 성능과 데이터셋 Artifact의 분리 평가

5.1 문제정의

Virtual screening benchmark에서 높은 ROC-AUC 또는 EF1%가 관찰되더라도, 그 성능이 실제 protein-ligand interaction 학습의 결과인지 active/decoy 생성 방식에서 발생한 shortcut의 결과인지 구분하기 어렵다. 원자료는 protein 입력을 제거했는데도 성능이 유지되는 관측을 문제의 출발점으로 제시한다.

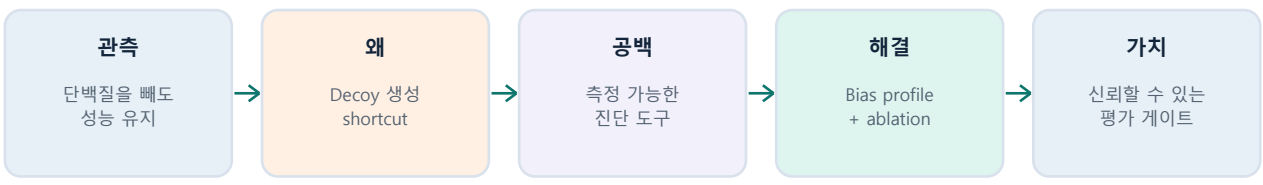
범위의 한계
이 연구의 1차 목표는 bias를 '없애는 것'이 아니라, 데이터셋마다 어떤 shortcut 위험이 어느 정도 존재하는지 진단하는 것이다. decoy 재생성이나 benchmark 재설계는 후속 단계로 분리한다.

5.2 연구목표

- G1. Active-decoy의 physicochemical separability를 정량화한다.
- G2. Active set의 scaffold concentration을 측정한다.
- G3. Active-decoy chemical similarity 구조의 분리를 정량화한다.
- G4. bias 지표와 실제 virtual screening 성능의 관계를 검증한다.
- G5. 결과를 재사용 가능한 diagnostic tool과 보고서로 구현한다.

5.3 연구질문과 가설

연구질문	검증 가설
RQ1. 단순 physicochemical properties만으로 active와 decoy를 구분할 수 있는가?	H1. DUD-E에서 property-only classifier가 chance보다 유의하게 높은 AUC를 보일 것이다.
RQ2. active molecule이 소수 scaffold에 과도하게 집중되는가?	H2. DUD-E의 active set은 LIT-PCBA보다 일부 타겟에서 더 높은 SC@5/SC@10을 보일 것이다.
RQ3. 두 집단의 structural similarity distribution에 systematic separation이 있는가?	H3. DUD-E에서 opposite-class nearest-neighbor similarity 분리도가 더 크게 나타날 것이다.
RQ4. metric은 두 benchmark를 구분하는가?	H4. 세 지표를 함께 본 bias profile이 DUD-E와 LIT-PCBA의 known contrast를 반영할 것이다.
RQ5. bias가 클수록 ligand-only model 성능도 높아지는가?	H5. bias가 높은 타겟일수록 protein-aware와 ligand-only의 EF1% 격차가 작을 것이다.



5.4 개념적 인과 구조

Decoy 생성 규칙과 dataset composition은 property residual, scaffold concentration, similarity separation이라는 관측 가능한 흔적을 만든다. 이 흔적은 ligand-only 모델의 성능을 높일 수 있으며, 최종적으로 protein-aware 모델과의 성능 차이를 축소할 수 있다. 단, 이 구조는 관측 기반의 가설 모델이며 인과효과를 확정하는 분석은 아니다.

5.5 실험설계

실험	입력 / 처리	주요 출력	판정 포인트
A. Physicochemical shortcut	물성 descriptor만 사용, LR/RF, stratified CV	ROC-AUC, PR-AUC, bootstrap CI	단순 물성만으로 class separability가 생기는가
B. Scaffold concentration	Bemis-Murcko scaffold 그룹화	SC@5, SC@10, Gini/entropy 보조	상위 소수 scaffold에 active가 집중되는가
C. Structural separation	Morgan FP, 반대 class nearest neighbor	median NN Tanimoto, Wasserstein/KS	구조적 분리도가 benchmark마다 다른가
D. Model ablation	protein-aware, masked, ligand-only 동일 split	ROC-AUC, EF1%, Delta EF	protein 정보의 incremental value가 남는가
E. Cross-benchmark	DUD-E 5 타겟 + LIT-PCBA 3 타겟 PoC	target-level profile, effect direction	known contrast가 재현되는가

5.6 평가지표와 수식

지표	정의	해석
EF1%	EF1% = (상위 1% 내 active 비율) / (전체 active 비율)	초기 screening 순위의 enrichment
SC@K	SC@K = (상위 K개 scaffold가 포함하는 active 수) / (전체 active 수)	analogue/scaffold concentration
NN Tanimoto	S_i = max Tanimoto(i, j), j는 반대 class	각 분자가 반대 class와 얼마나 가까운가
Property AUC	물성 6종만으로 active/decoy 분류 시 ROC-AUC	물성 shortcut separability
Delta EF	Delta EF = EF1%(protein-aware) - EF1%(ligand-only)	protein 정보의 incremental ranking value

보완 제안: 물성 6종

원자료는 '물성 6종'이라고만 제시한다. 구현 후보는 MW, cLogP, TPSA, HBD, HBA, Rotatable Bonds이며, 실제 항목은 데이터 추출·결측·중복 처리 규칙과 함께 사전 고정해야 한다.

5.7 통계 및 재현성 계획

- 동일 target split, 동일 seed, 동일 전처리로 ablation 비교
- target별 결과를 먼저 보고한 뒤 benchmark-level 요약은 평균과 중앙값을 함께 제시
- AUC와 EF1%에 bootstrap confidence interval을 부여
- 표본 수가 작은 target은 상위 1%의 절대 compound 수와 함께 해석
- dataset 버전, 다운로드 날짜, canonicalization, salt/duplicate 제거 규칙, descriptor 설정을 manifest로 저장

6. 대상 수상 수준의 스토리텔링 구조 개선안

현재 자료는 기업 소개가 길고 본론이 후반부에 배치되어 있다. 심사 발표에서는 회사 맥락을 유지하되, 12쪽의 관측을 앞쪽으로 끌어와 '이상한 결과 -> 왜 그런가 -> 무엇이 비어 있는가 -> 어떻게 검증하는가 -> 기업에 어떤 gate가 생기는가'의 흐름으로 재배열하는 것이 좋다.

6.1 한 문장 메시지

높은 benchmark score가 biological interaction을 반영하는지 확인하기 위해, active/decoy dataset의 shortcut을 bias profile과 model ablation으로 진단하는 도구를 만든다.

6.2 권장 11장 구성

새 순서	제목	한 문장 메시지	시각 장치
1	높은 점수는 정말 실력인가?	benchmark도 모델처럼 shortcut을 제공할 수 있다	질문형 Hook
2	AIGEN의 의사결정 문제	prediction이 decision quality로 이어져야 한다	decision loop
3	이상한 관측	단백질 입력을 제거해도 성능이 유지됐다	동일 곡선 비교
4	왜 Decoy가 문제인가	negative가 실험 inactive가 아니라 생성 규칙의 결과일 수 있다	active/decoy 라벨 도식
5	shortcut의 생성 메커니즘	허용 폭과 구성 규칙이 흔적을 남긴다	property residual toy example
6	이미 알려진 증거와 연구 gap	문제는 알려졌지만 재사용 진단 도구가 부족하다	선행연구 타임라인
7	우리의 문제정의	임의의 dataset을 받아 위험도를 수치화한다	입력 -> profile
8	세 가지 bias profile	property, scaffold, similarity를 각각 본다	3축 radar 대신 3개 카드
9	Known contrast 검증	DUD-E와 LIT-PCBA의 차이가 지표에 반영되는가	benchmark 비교표
10	Ablation과 falsification	protein 정보의 incremental value와 실패 기준을 함께 본다	모델 3조건 + 판정표
11	기업 가치	모델 평가 전 benchmark QC gate를 만든다	운영 workflow / next step

6.3 수상 발표용 편집 원칙

- 첫 30초 안에 관측을 보여주고, 회사 소개는 관측의 중요성을 설명하는 범위로 제한
- 한 슬라이드 한 주장: 정의, 원인, 증거, 해결안을 섞지 않기
- 'biased/unbiased'의 이분법 대신 상대적 위험과 불확실성 사용
- 진단 지표를 설명할 때 반드시 '그래서 의사결정이 어떻게 달라지는가'를 한 문장으로 연결
- 마지막에는 모델 정확도보다 evaluation gate가 먼저라는 운영 메시지로 닫기

6.4 현재 구조와 권장 구조의 대비

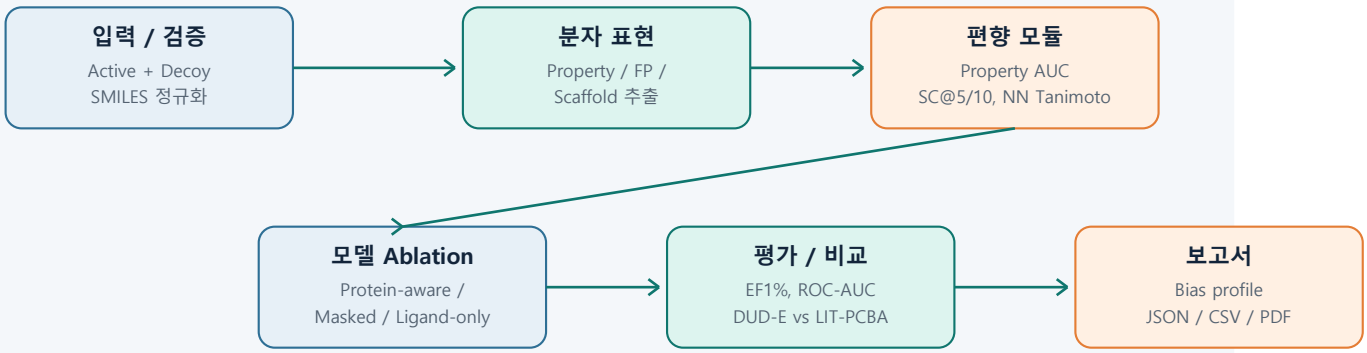
현재 흐름	권장 흐름
기업 소개 -> 역량 -> 사례 -> bottleneck -> 관측 -> 배경 -> mechanism -> 연구 gap -> 데이터 -> 평가	질문형 Hook -> 의사결정 맥락 -> 관측 -> Decoy mechanism -> 선행 증거 -> gap -> tool -> known contrast -> ablation -> 기업 가치

현재 흐름	권장 흐름
장점: 회사 신뢰도와 기술 배경이 풍부함	장점: 심사위원이 '왜 이 도구가 필요한가'를 2-3분 안에 이해함
리스크: 본론 진입이 늦고 채용 슬라이드가 흐름을 끊음	리스크: 회사 소개가 축약되므로 2쪽과 6쪽의 연결 문장 필요

7. Decoy bias 진단도구 구현 아키텍처

도구는 입력 검증, 분자 표현, 세 편향 모듈, 모델 ablation, benchmark 비교, 보고서 생성의 6층으로 구성한다. 계산 결과뿐 아니라 데이터 버전과 설정을 함께 저장해야 재현 가능한 QC gate가 된다.

재사용 가능한 Decoy bias 진단 파이프라인



핵심 원칙: 개별 지표를 우선 보고하고, 종합 등급은 참고값으로만 제시

7.1 모듈별 책임과 인터페이스

모듈	책임	입력	출력
Data Validator	SMILES canonicalization, invalid, salt, duplicate, label 검사	active/decoy CSV 또는 SMI	validated molecule table + log
Property Engine	descriptor 계산과 결측·범위 기록	validated molecule table	property matrix + descriptor manifest
Fingerprint Engine	Morgan FP 또는 고정된 대체 fingerprint 생성	canonical SMILES	bit vector/index
Scaffold Engine	Bemis-Murcko scaffold 그룹화	canonical SMILES	scaffold counts, SC@5/10
Bias Metrics	AUC, PR-AUC, NN similarity, 분포 거리	properties/FP/scaffold	target-level bias profile
Model Ablation	protein-aware, masked, ligand-only의 동일 split 평가	모델 입력 + split manifest	ROC-AUC, EF1%, Delta EF
Report Generator	시각화와 해석 문장, provenance 출력	metrics + metadata	JSON, CSV, PDF report

7.2 권장 결과 스키마

필드	예시 형식	필수 여부
dataset	DUD-E_target_X	필수

필드	예시 형식	필수 여부
provenance	source, version/date, checksum, preprocessing	필수
property_bias	lr_auc, rf_auc, ci_low, ci_high	필수
scaffold_bias	top5_coverage, top10_coverage	필수
similarity_bias	median_nn_tanimoto, distance, method	필수
model_ablation	protein_ef1, masked_ef1, ligand_ef1, delta_ef	PoC 필수
diagnosis	risk band, evidence list, caveat	해석층

종합 등급의 원칙

risk=high 같은 threshold를 처음부터 임의로 고정하지 않는다. 초기에는 개별 지표와 confidence interval을 우선 제공하고, DUD-E/LIT-PCBA와 downstream 성능의 empirical distribution을 본 뒤 calibration한다.

7.3 확장성과 운영

- PoC: target별 batch 실행과 PDF/CSV 출력
- 운영형: CLI와 API를 동일한 config로 연결하고 결과 manifest를 저장
- 대규모 similarity: full pairwise 대신 fingerprint index, ANN, stratified sampling
- 실패도 기록: invalid SMILES, descriptor 계산 실패, scaffold 미추출 건수를 결과에 포함
- 보안·재현성: 사내 데이터는 원문 대신 hash와 요약 통계를 보고서에 남기는 옵션 제공

8. WBS와 Baseline 실험계획

8.1 6주 PoC WBS

주차	목표	작업	산출물	완료 기준
1	데이터 파이프라인	DUD-E/LIT-PCBA 소스 확인, target 선정, 정제 규칙 고정	cleaned tables, manifest	재실행 시 동일 row count
2	Bias metric prototype	property/scaffold/fingerprint 모듈 구현	metric notebook/module	샘플 target 수기 검증
3	Baseline	Random, property LR/RF, fingerprint baseline	baseline report	seed별 결과와 CI
4	Ablation	protein-aware/masked/ligand-only 동일 split 비교	ablation report	Delta EF와 오류 로그
5	Cross-benchmark	DUD-E 5 + LIT-PCBA 3 target 확장, profile 비교	comparison report	target-level table 완성
6	제품화·발표	JSON/CSV/PDF 출력, 한계·falsification 정리	PoC package, demo PDF	타인이 config만으로 재실행

8.2 Baseline 비교군

ID	입력	모델	목적
B0 Random	없음	chance	우연 수준
B1 Property LR	물성 6종 후보	Logistic Regression	선형 property shortcut
B2 Property RF	물성 6종 후보	Random Forest	비선형 property shortcut
B3 Fingerprint	ligand FP	LR/RF	구조적 shortcut
B4 Ligand-only	ligand representation	screening model	protein 없는 실전 성능
B5 Protein-masked	ligand + dummy/masked protein	동일 architecture	protein 입력 ablation
P Proposed	protein + ligand	정상 모델	생물학적 interaction 조건

가장 중요한 비교

P Proposed의 EF1%가 가장 높다는 사실보다, P와 B4의 EF1% 차이가 얼마나 되는지가 중요하다. 예를 들어 Proposed 22, ligand-only 21이면 protein 정보의 incremental value가 1에 불과하다는 점이 핵심 결과다.

8.3 PoC 판정표

관측	해석	다음 조치
Property AUC 높음 + SC@K 높음 + Delta EF 작음	ligand-side shortcut 가능성 강함	benchmark 사용 주의, split/decoy 재검토
Property AUC 낮음 + scaffold concentration 높음	물성보다 analogue bias 가능성	scaffold split과 similarity 분석 강화
모든 지표가 비슷하고 Delta EF 큼	이번 비교에서 shortcut 증거 제한적	타겟 수 확대, metric 민감도 점검
Property AUC 0.5-0.6 + 다른 지표 차이 없음	초기 가설 약화 또는 구현 오류 가능성	전처리·label·split 검증 후 가설 수정

8.4 위험과 대응

위험	영향	대응
데이터 버전/정제 규칙 차이	결과 재현 불가	manifest, checksum, row count 저장
작은 target 수	일반화 과장	PoC와 전체 결론 분리, target 확대
metric 단독 해석	실제 원인 오판	세 지표와 ablation을 함께 보고
EF1% 불안정	랭킹 결론 왜곡	bootstrap, active count, 보조지표
Tanimoto O(N^2)	대규모 실행 불가	index/ANN/sampling mode

9. 발표자료 전체용 멘트와 시간 배분 빠른 참조

실제 발표 직전에는 아래 표만 출력해 큐시트로 사용할 수 있다. 12분 30초 버전과 15분 확장 포인트를 함께 제시한다.

쪽	12:30 버전	멘트 키워드	15분 확장
1	25초	높은 score가 진짜 능력인가	질문 후 1초 pause
2-5	50초	세 AI engine, milestones, biomedical 역량	회사 맥락 10초 추가
6	30초	prediction -> decision quality	사례 질문 추가
7-10	80초	closed-loop, validation, bottleneck, decision trace	evaluation gate 삽입
11	5초	삭제 또는 한 문장	삭제 권장
12	70초	protein 제거 후 유지	ablation 한계 설명
13	50초	EF1%, decoy label	ranking 직관 추가
14-15	95초	허용 폭, artificial / analogue bias	toy example + metric 매핑
16	55초	기존 증거와 gap	연구별 기여 10초
17	65초	세 질문, profile	종합등급 원칙
18	50초	DUD-E vs LIT-PCBA	수치와 기준일
19	105초	평가와 falsification	통계 계획 + 한계
결론	70초	benchmark QC gate	기업 적용 장면

운영 모드	편집 지침
10분	2-5쪽을 합치고 3-4쪽은 넘김. 8쪽은 실험 검증 한 문장, 11쪽은 삭제, 16쪽은 연구명만, 19쪽은 지표 4개와 falsification만 남긴다.
15분	12쪽 ablation, 14쪽 residual difference toy example, 18쪽 라벨 구성과 기준일, 19쪽 CI·target aggregation·실패 시 다음 실험을 확장한다.

10. 부록: 제출 전 체크리스트와 참고 메모

A. 발표 전 사실관계 체크리스트

체크	항목	상태
[ ]	원자료의 DUD-E/LIT-PCBA 수치와 기준일을 실제 다운로드 버전과 대조	필수
[ ]	Mysinger 2012, Chen 2019, Wallach & Heifets 2018, Tran-Nguyen 2020의 정확한 서지정보와 그림 출처 확인	필수
[ ]	단백질 제거 관측의 split, seed, architecture, metric을 기록	필수
[ ]	'물성 6종'의 정확한 descriptor 목록과 계산 도구 버전 확정	필수
[ ]	DUD-E 5 타겟과 LIT-PCBA 3 타겟의 선정 기준을 사전 정의	권장
[ ]	EF1%의 active count, top 1% tie 처리, bootstrap 방법 확정	권장
[ ]	종합 risk band threshold를 데이터 보기 전에 고정하지 않도록 명시	권장

B. 최종 한계와 정직한 결론

이 보고서가 제안하는 진단기는 benchmark가 공정한지에 대한 절대 판정기가 아니다. 관측 가능한 dataset artifact와 모델 ablation 결과를 묶어 '어떤 shortcut 위험이 보이는지'를 정량화하는 QC 도구다. 특히 DUD-E와 LIT-PCBA의 비교는 known contrast validation이지, 두 데이터셋의 모든 과학적 차이를 통제한 무작위 실험이 아니다. 따라서 결론은 target-level profile, 불확실성, 데이터 버전과 함께 제시해야 한다.

> 제출용 결론 문장
> 이 연구의 성과는 높은 점수를 만드는 또 하나의 모델이 아니라, 그 점수를 믿기 전에 benchmark의 신뢰성을 검사하는 평가 계층을 제안했다는 데 있다. 결과가 가설을 지지하든 약화하든, 재현 가능한 profile과 falsification 기준을 남기는 것이 기업 연구개발 환경에서의 가치다.

C. 원자료에 기재된 참고 연구 메모

발표자료 16쪽에 다음 연구명이 기재되어 있다: Mysinger 2012 (DUD-E 설계), Chen 2019 (편향 보고), Wallach & Heifets 2018 (AVE bias), Tran-Nguyen 2020 (LIT-PCBA). 본 보고서는 원자료의 맥락을 보존하기 위해 이 목록을 사용했으며, 최종 학술 제출본에서는 각 논문의 정확한 제목, 저널, DOI, 인용 그림의 라이선스와 재현 조건을 별도로 확인해야 한다.

D. 보고서 작성 범위

원자료 기반 사실: 발표자료 19쪽의 문구, 데이터셋 수치, 연구명, 평가 지표, 초기 PoC 조건. 보완 제안: descriptor 후보, Logistic Regression 보조 baseline, Morgan fingerprint 설정, Wasserstein/KS, bootstrap CI, JSON schema, architecture, 6주 WBS, risk band calibration, 운영형 QC gate. 보완 제안은 사실 주장으로 사용하지 않고 연구·구현 계획으로 표시한다.