

DLthon2 프로젝트 제안서

프로젝트명 K-VALUE-Lite — 검열(Censoring)을 고려한 멀티모달 미술품 가치 추정 모델 제안자 추병곤 (AIFEL 18기) 작성일 2026.07.29 | 버전 v0.1

※ 본 제안서의 일정은 DLthon2 공식 기간(D-1 ~ D-10) 기준 상대적으로 표기했습니다. 확정 일자에 맞춰 치환하시면 됩니다.

0. 개요

0-1. 아이템 소개

K-VALUE-Lite는 미술품의 이미지와 메타데이터를 입력받아 **가격 구간(point estimate가 아닌 interval)** 과 **그 판단의 근거**를 함께 출력하는 멀티모달 딥러닝 모델입니다.

핵심 기능은 세 가지입니다.

- 4-레이어 특징 추출 (K-ART-4L)** — 작품을 도상(iconography), 기법(technique), 물성(materiality), 색채(color) 네 층위로 분해해 각각 독립적인 임베딩을 생성합니다.
- LQA (Layer-Query Attention) 융합** — 메타데이터를 query로, 4개 레이어 임베딩을 key/value로 하는 cross-attention을 수행합니다. 이때 산출되는 attention weight가 곧 **“이 추정에 어느 층위가 얼마나 기여했는가”**에 대한 답이 됩니다.
- Tobit 회귀 헤드** — 낙찰된 작품(관측값)과 유찰된 작품(검열된 관측)을 **하나의 우도함수 안에서 함께 학습**합니다. 유찰작을 결측으로 버리지 않고 **“가격이 유보가 아래에 있다”**는 부등호 정보로 활용합니다.

목적은 가격을 정확히 맞추는 것이 아니라, **감정평가 실무자가 근거로 인용할 수 있는 형태의 추정치**를 만드는 것입니다.


0-2. 아이템의 특징 및 차별성

구분	기존 접근	K-VALUE-Lite
학습 데이터	낙찰된 작품만 사용, 유찰작은 필터링해서 제거	유찰작을 검열 관측으로 함께 학습
특징 추출	단일 CNN 임베딩 + 테이블 피쳐	도상/기법/물성/색채 4개 층위 분리
출력	단일 예측 가격	가격 구간 + 신뢰수준 + 레이어별 기여도
설명가능성	사후 SHAP/PDP (post-hoc)	구조 자체가 설명을 산출 (attention weight)
평가 지표	RMSE/MAE 중심	RMSE/MAE + PICP(구간 포함률) + 선택편향 크기

가장 큰 차별점은 **유찰 데이터를 버리지 않는다**는 점 하나입니다. 뒤(1-2)에서 확인하겠지만, 선행 연구들은 유찰작을 명시적으로 제거하고 시작합니다. 그 순간 모델은 “팔린 것들의 세계”만 학습하게 되고, 실제 시장에 적용하면 체계적으로 가격을 과대추정합니다. 이 편향을 **모델링 대상으로 삼는 것**이 본 프로젝트의 정체성입니다.

0-3. 이미지 (설계도)

[그림 1] K-VALUE-Lite 모델 아키텍처 → 첨부 파일: `kvalue_lite_architecture.svg` (PDF판에는 본문에 직접 삽입)



[그림 2~4] 제출 시 추가 삽입 예정 - 그림 2: MOG(시장 관측 격차) 개념도 — 전체 출품작 중 관측 가능한 낙찰가의 비율 - 그림 3: 4-레이어 특징의 실제 시각화 예시 (동일 작품에 대한 네 층위 출력) - 그림 4: Ablation 결과 그래프 (Tobit 적용 유무에 따른 잔차 분포)

1. 문제인식

1-1. 프로젝트 목표 및 목적

목표(Goal) 멀티모달 입력으로부터 미술품 가격을 추정하되, **표본선택 편향을 명시적으로 보정**하고 **추정 근거를 구조적으로 산출**하는 딥러닝 모델을 DLthon2 기간 내에 구현·검증한다.

세부 목적(Objectives)

#	목적	측정 방법
O1	4-레이어 특징이 단일 임베딩보다 유효함을 보인다	레이어 조합별 ablation, MAE 비교
O2	Tobit 헤드가 선택편향을 줄임을 보인다	합성 검열 실험 + 실데이터 잔차 편향 비교
O3	신뢰할 수 있는 구간을 출력한다	PICP(90% 목표 구간의 실제 포함률)
O4	LQA attention이 해석 가능함을 보인다	매체별 물성 레이어 가중치 정성 분석

의의(Why it matters) 미술품 가격 추정은 전형적인 **불확실성 하의 회귀** 문제입니다. 정답이 하나로 존재하지 않고, 관측 자체가 편향되어 있으며, 사용자는 숫자보다 근거를 원합니다. 이 세 조건은 의료 예후 예측, 부동산 감정, 보험 손해액 산정 등과 구조적으로 동일합니다. 즉 본 프로젝트는 **“관측이 편향된 도메인에서의 설명가능한 회귀”**라는 일반적 문제에 대한 사례 연구이기도 합니다.

1-2. 아이템의 독창성

(1) 유사 프로젝트 조사 결과

미술품 가격 예측은 이미 여러 차례 시도된 주제입니다. 확인된 선행 사례는 다음과 같습니다.

- **Stony Brook 대학 프로젝트 (Team 4, “Predicting the Price of Art at Auction”)** — Sotheby’s 데이터를 사용해 가격을 예측. 데이터셋에는 유찰작과 최저 기준가 미달 작품이 포함되어 있었으나, **연구진은 이를 명시적으로 필터링해 제거**했고 1만 달러 미만 저가작도 제외했습니다. 본 제안의 문제의식이 실재함을 보여주는 직접적 근거입니다.
- **Painting2Auction (Stanford CS230)** — Siamese CNN + LSTM 구조로 작가 유사도 기반 가격 예측. 이미지-작가 데이터셋과 가격 데이터셋을 분리 사용.
- **Applied Sciences (2024), “Tabular Data Models for Predicting Art Auction Results”** — 프린트/에디션 작품 대상으로 XGBoost, CatBoost, LightGBM, SAINT 등 13개 모델을 비교. 결론은 **모든 경우에 일관되게 높은 정확도를 내는 단일 접근이 없다**는 것이었습니다.
- **Kaggle “The Price of Art” 대회 / art-price-dataset** — 가격, 작가, 제목, 제작연도, 서명 여부, 상태, 시대, 사조 속성 보유.

(2) 차별성

선행 연구 대비 본 프로젝트의 위치는 명확합니다.

선행 연구의 공통 한계	K-VALUE-Lite의 대응
유찰·저가작을 제거 하고 시작 → 표본선택 편향 내재	Tobit 우도로 검열 관측을 포함 해 학습
이미지를 단일 CNN 임베딩으로 압축 → 무엇이 가격을 견인했는지 불명	4-레이어 분리 + LQA로 기여도 분해
단일 점추정 출력 → 실무 활용 불가	μ 와 σ 를 동시 추정해 구간 + 신뢰수준 출력
정확도 지표만 보고 → 과신 위험	PICP와 편향 크기 를 주 지표로 병행

Tobit 손실을 신경망에 적용하는 접근 자체는 이미 문헌이 존재합니다(Danaila 외의 PyTorch 구현, Zhang 외 “Deep Tobit networks”, Neural Networks 144, 2021). **본 프로젝트의 독창성은 새 손실함수를 발명하는 데 있지 않고, 이 기법을 유찰이 구조적으로 발생하는 미술시장 도메인에 처음으로 결합하고, 그 효과를 정량 검증하는 데 있습니다.**

2. 개발 및 연구 내용

2-1. 구현 내용 상세

(1) 문제 정식화

- **입력**: 이미지 I (1~3장), 메타데이터 x (작가, 제작연도, 재료, 규격, 경매사, 판매 시점)
- **출력**: $\log(\text{price})$ 의 조건부 정규분포 — 평균 $\mu(l, x)$ 와 표준편차 $\sigma(l, x)$ 를 동시에 추정
- 관측 유형:
 - 낙찰 → 정확한 값 y 를 관측
 - 유찰 → $y < c$ (유보가 c 이하라는 사실)만 관측 = **좌측 검열(left-censored)**

(2) 손실함수

$$\begin{aligned} \text{낙찰 (정확한 값 관측)} &: - \sum_{i \in \text{sold}} [\log \phi((y_i - \mu_i) / \sigma_i) - \log \sigma_i] \\ \text{유찰 (검열된 관측)} &: - \sum_{j \in \text{unsold}} [\log \Phi((c_j - \mu_j) / \sigma_j)] \\ L &= \text{위 두 항의 합} \\ \phi &: \text{표준정규 확률밀도 (PDF)} & \Phi &: \text{표준정규 누적분포 (CDF)} \\ y &: \text{관측된 로그 낙찰가} & c &: \text{유보가(reserve price)} \end{aligned}$$

첫 항은 통상적인 가우시안 NLL, 둘째 항이 검열 관측의 누적확률 항입니다. 유찰 데이터를 버리는 대신 이 부등호 정보로 학습에 참여시킵니다.

(3) 모듈별 구성

모듈	구현 방식	비고
도상 레이어	CLIP ViT-B/32 image encoder (frozen)	의미론적 내용
기법 레이어	VGG19 중간층 Gram matrix → 차원 축소	스타일/붓질 통계
물성 레이어	매체 분류 헤드 (oil/acrylic/bronze/print/mixed) + 표면 통계	소량 fine-tune
색채 레이어	HSV 히스토그램 + k-means 팔레트 + 색 엔트로피	학습 불필요, 결정론적
메타 인코더	범주형 임베딩 + 수치 정규화 → MLP	query 생성
LQA	Multi-head cross-attention (head=4)	attention weight 저장
출력 헤드	2-head MLP → $\mu, \log \sigma$	σ 는 softplus로 양수 보장

이미지 인코더는 **frozen 상태로** 시작합니다. DLthon 기간에 대형 백본을 처음부터 학습하는 것은 비현실적이고, 본 프로젝트의 기여는 백본이 아니라 융합·손실 설계에 있기 때문입니다.

(4) 데이터

1순위 (가격 라벨 보유) - Kaggle [flkuhm/art-price-dataset](#) — price, artist, title, yearCreation, signed, condition, period, movement
- Kaggle [The Price of Art](#) 대회 데이터 - Kaggle [art-market-dataset-selling-paintings-prediction](#)

2순위 (이미지 보장) - WikiArt 계열 이미지·작가 데이터셋 - 국내: 공공데이터포털 국립현대미술관 미술은행 작품 기본정보, 문화공공데이터광장 공공미술작품 API ([api.kcisa.kr](#))

검열 데이터 확보 전략 — 여기가 최대 리스크입니다. 공개 데이터셋 대부분은 낙찰작만 담고 있어 유찰 레코드가 없습니다. 따라서 2단계로 갑니다.

- **Plan A**: 유찰 정보가 포함된 데이터셋을 확보 → 실데이터로 직접 검증 (D-2까지 판정)
- **Plan B (기본 전제): 합성 검열 실험** — 낙찰 데이터에서 하위 $q\%$ 를 인위적으로 검열 처리해 정답(비검열 원본)을 알고 있는 상태로 만든 뒤, Tobit 헤드가 원래 분포를 얼마나 복원하는지 측정. Plan A가 무산돼도 O2 검증이 가능하며, **오히려 인과관계를 더 깨끗하게 보일 수 있습니다.**

Plan B를 백업이 아니라 **주 실험**으로 설계한 것이 본 계획의 안전장치입니다.

(5) 실험 설계 (Ablation)

실험 ID	구성	확인하려는 것
E0	메타데이터만 + MSE (baseline)	하한선
E1	단일 CNN 임베딩 + 메타 + MSE	통상적 멀티모달
E2	4-레이어 + 단순 concat + MSE	레이어 분리의 효과
E3	4-레이어 + LQA + MSE	융합 방식의 효과
E4	4-레이어 + LQA + Tobit	최종 모델
E5	E4에서 레이어 1개씩 제거 ($\times 4$)	레이어별 기여

핵심 비교는 E3 vs E4입니다. 여기서 유의한 차이가 나오지 않으면 본 프로젝트의 주장은 성립하지 않으며, 발표에서 그 사실을 그대로 보고합니다.

(6) 평가 지표

- **MAE / RMSE** on log-price (정확도)
- **PICP** (Prediction Interval Coverage Probability) — 90% 구간이 실제로 90%를 담는가
- **평균 부호 잔차** $\text{mean}(\hat{y} - y)$ — 0에서 얼마나 벗어나는가 = **선택편향의 직접 측정치**
- **Attention entropy** — 특정 레이어에 쏠리는지, 고르게 분산되는지

2-2. 개발 아이템 기대효과

직접 활용 - 공공 미술관·지자체의 **보험평가 및 수집심의 근거자료** 생성. 소장품 일괄 처리로 담당자의 반복 업무를 줄입니다. - 갤러리·경매사의 **시가감정 사전 스크리닝**. 유사 사례 조사 시간을 단축합니다. - 미술품 담보대출·조각투자 플랫폼의 **담보가액 산정 근거 문서화**.

파생 효과 - **저평가 영역의 가시화** — 거래 이력이 없는 지역 작가·신진 작가 작품에 대해서도 속성 기반 추정 구간을 제공. 시장 관측 격차 자체를 좁히는 방향으로 작동합니다. - **아카이브 메타데이터 자동 보강** — 4-레이어 출력(매체 분류, 색채 팔레트, 스타일 통계)은 가격과 무관하게 소장품 DB의 검색 필드로 재 활용 가능합니다. - **도메인 이전** — Tobit + attention 융합 구조는 부동산 감정, 중고 자산 평가, 보험 손해액 등 검열이 발생하는 다른 회귀 문제로 그대로 이식됩니다.

한계에 대한 명시적 인식 본 모델은 **진위감정을 수행하지 않으며**, 출력은 법적 효력을 갖는 감정평가액이 아닙니다. 서비스화 시 이 경계를 UI와 약관에 고정 명시하는 것을 전제로 합니다.

3. 실행 계획

3-1. 프로젝트 완성을 위한 전략

전략 1 — 데이터 리스크를 1일차에 소진한다. 가장 큰 불확실성은 “쓸 만한 데이터가 있는가”입니다. D-1에 3개 팀원이 동시에 서로 다른 데이터 소스를 병렬로 확인하고, **D-2 오전에 데이터셋을 확정**합니다. 이 시점 이후에는 데이터를 바꾸지 않습니다.

전략 2 — Baseline을 먼저, 그것도 아주 빨리 만든다. D-3까지 E0(메타데이터 + MSE)를 완성해 제출 가능한 상태를 만듭니다. 이후 모든 작업은 “이미 굴러가는 것”에 얹는 방식이 되므로, 어느 시점에 멈춰도 결과물이 남습니다.

전략 3 — 4개 레이어를 병렬로 만든다. 레이어들은 서로 의존하지 않습니다. 각 팀원이 하나씩 맡아 동일한 출력 인터페이스((B, D) 텐서)로 맞추면 통합 비용이 거의 0입니다.

전략 4 — 발표 자료를 D-7부터 쓴다. 결과가 다 나온 뒤 슬라이드를 만들면 반드시 시간이 모자랍니다. D-7에 빈 슬라이드에 **결과가 들어갈 자리를 먼저 뚫어두고**, 실험이 끝나는 대로 채웁니다.

전략 5 — 실패도 결과로 보고한다. E3 vs E4에서 차이가 없으면 그것을 그대로 발표합니다. 부정 결과를 숨기고 억지 해석을 붙이는 것이 가장 나쁜 선택지입니다.

3-2. DLthon2 기간 내 마일스톤

단계	기간	Task	상세 내용	산출물
M0. 킥오프	D-1	문제 정의 확정, 데이터 소스 병렬 조사	후보 데이터셋 3종 동시 다운로드·검토. 유찰 레코드 유무 판정	데이터 후보 비교표
M1. 데이터 확정 & EDA	D-2	데이터셋 확정, EDA, 전처리 파이프라인	가격 분포(로그 변환 필요성), 결측 패턴, 작가별 표본 수, 이미지 해상도 분포. Plan A/B 최종 판정	EDA 노트북, 전처리 스크립트
M2. Baseline	D-3	E0/E1 구현 및 학습	메타데이터 MLP → MSE. 이미지 단일 임베딩 추가	Baseline 성능 기록
M3. 4-레이어 구현	D-4 ~ D-5	도상/기법/물성/색채 인코더 병렬 개발	각자 담당 레이어 구현, 공통 인터페이스 준수, 단위 테스트	레이어 4종 모듈
M4. LQA 융합	D-6	cross-attention 융합 + E2/E3 학습	attention weight 추출·저장 로직 포함	융합 모델 v1
M5. Tobit 헤드	D-7	검열 손실 구현 + E4 학습	합성 검열 실험 세팅 동시 진행. PT 골격 착수	최종 모델 v1, 발표 골격
M6. Ablation & 평가	D-8	E0~E5 전체 비교, 지표 산출	MAE/RMSE/PICP/편향 표 작성, attention 정성 분석	결과 표·그래프
M7. 해석 & 시각화	D-9	레이어 기여도 시각화, 케이스 스터디	잘 맞춘 사례 2건 + 크게 틀린 사례 2건 심층 분석	시각화 자료
M8. 발표 준비	D-10	PT 완성, 리허설 2회, 코드 정리	README, 재현 스크립트, 데모	발표자료, 최종 리포지토리

버퍼 정책: M3와 M6에 각 만나절의 여유를 내장했습니다. 지연이 발생하면 **M7의 케이스 스터디를 4건에서 2건으로 줄이는 것**이 첫 번째 축소 대상이며, M2 Baseline과 M8 발표 준비는 어떤 경우에도 축소하지 않습니다.

3-3. 팀장 및 팀원의 역할분배 (5인 가정)

역할	담당자	주요 업무	연결 마일스톤
팀장 / PM·도메인	A (추병곤)	문제 정의, 도메인 검증(감정 실무 관점), 일정 관리, 발표 총괄, 결과 해석	M0, M7, M8 전체
데이터 엔지니어	B	데이터 수집·정제, EDA, 전처리 파이프라인, 데이터로더, 합성 검열 세팅	M1, M5
비전 모델러	C	도상·기법 레이어 (CLIP, Gram matrix) 구현 및 튜닝	M3
멀티모달 모델러	D	물성·색채 레이어 + 메타 인코더 + LQA 융합 구현	M3, M4
평가·통계 담당	E	Tobit 손실 구현, Ablation 설계·실행, 지표 산출, 시각화	M5, M6, M7

협업 규칙 - 매일 15분 스탠드업 — 어제 한 것 / 오늘 할 것 / 막힌 것 세 문장만. - 브랜치 전략: `main` 보호, 기능별 브랜치 + PR 리뷰 1인 이상. - 실험 기록은 W&B 또는 공유 스프레드시트에 **모든 런을 예외 없이** 기록. 사후에 “그때 그 설정이 뭐였더라”가 가장 큰 시간 낭비입니다. - 담당 영역이 막히면 **2시간 룰** — 2시간 이상 혼자 붙잡지 않고 즉시 공유합니다.

4. 레퍼런스

4-1. 선행 연구 및 유사 프로젝트

1. Stony Brook University, Predicting the Price of Art at Auction (Team 4 Final Report). Sotheby's 데이터 기반 가격 예측. **유찰작 및 저가작을 명시적으로 제외한 전처리를 수행** — 본 제안의 문제의식에 대한 직접 근거.
https://www3.cs.stonybrook.edu/~skiena/591/final_projects/art_acution/Team4_Final_Report.pdf
2. Worth, T., Painting2Auction: Art Price Prediction with a Siamese CNN and LSTM, Stanford CS230, 2020.
http://cs230.stanford.edu/projects_fall_2020/reports/55539436.pdf
3. Tabular Data Models for Predicting Art Auction Results, Applied Sciences 14(23), 11006, 2024. 13종 모델 비교 결과 **모든 시나리오에서 일관되게 우수한 단일 접근은 없음**을 보고. <https://www.mdpi.com/2076-3417/14/23/11006>
4. Idanlau, Art Price Prediction Model (GitHub). 수치 모델 + CNN 가중평균 앙상블 구조.
https://github.com/Idanlau/Art_Price_Prediction_Model
5. jasonshi10, art_auction_valuation (GitHub). 37,638점 웹스크래핑 데이터. 작품 높이와 고유 색상 비율이 가격과 양의 상관, 코너 비율은 음의 상관으로 보고. https://github.com/jasonshi10/art_auction_valuation

4-2. 방법론 근거 (검열 회귀 / Tobit)

6. Danaila, V., A deep learning approach to censored regression. 신경망 학습을 위한 세 가지 검열 손실함수(tobit likelihood, censored MSE, censored MAE)를 제안. σ 를 고정값·재매개변수화·별도 신경망 추정의 세 방식으로 실험한 결과 **tobit likelihood가 최선**. 구현: https://github.com/vlad-danaila/deep_learning_censored_regression
7. Zhang, J., Li, Z., Song, X., Ning, H., Deep Tobit networks: A novel machine learning approach to microeconometrics, Neural Networks 144, 279–296, 2021. 전통 Tobit의 선형·정규성 가정 한계를 지적하고 deep Tobit-I / Tobit-II 네트워크를 제안.
<https://doi.org/10.1016/j.neunet.2021.09.003>
8. Eggensperger, K. et al., Neural Model-based Optimization with Right-Censored Observations, arXiv:2009.13828, 2020. 검열 관측을 단순 제거하면 안 되는 이유와 Tobit 기반 손실 + 앙상블 사후분포 모델링. <https://arxiv.org/abs/2009.13828>
9. Jia, Y., Jeong, J.-H., Deep Learning for Quantile Regression under Right Censoring: DeepQuantreg, arXiv:2007.07056, 2021. 구간 추정 관점의 대안 접근 — 비교 baseline 후보. <https://arxiv.org/pdf/2007.07056>
10. Deep Tobit model: an integrated framework for high-dimensional censored regression with variable selection, Lifetime Data Analysis, 2026. 음의 Tobit 로그우도를 손실로 사용하는 통합 프레임워크 및 2단계 변수 선택.
<https://link.springer.com/article/10.1007/s10985-026-09690-5>

4-3. 데이터 소스

11. Kaggle, Art Price Dataset (flkuhm). price / artist / title / yearCreation / signed / condition / period / movement.
<https://www.kaggle.com/datasets/flkuhm/art-price-dataset>
12. Kaggle, The Price of Art (competition). <https://www.kaggle.com/competitions/the-price-of-art/data>
13. Kaggle, Art Market Dataset: Selling Paintings Prediction (jijagallery).
<https://www.kaggle.com/datasets/jijagallery/art-market-dataset-selling-paintings-prediction>
14. 공공데이터포털 — 문화체육관광부 국립현대미술관 데이터셋 목록 (미술은행 작품 기본정보 등). <https://www.data.go.kr>
15. 문화공공데이터광장 — 공공미술작품 조회 오픈API. <https://www.culture.go.kr/data/openapi/openapiInfo.do> 엔드포인트 예:
<https://api.kcisa.kr/openapi/service/rest/convergence2018/conver9>

4-4. 도메인 기준

16. USPAP (Uniform Standards of Professional Appraisal Practice) — 평가 목적·전제·범위·한계의 명시 요건. 출력 리포트 서식 설계의 근거. [원문 확인 필요]
17. 예술경영지원센터, 『한국 미술시장 실태조사』 연간 보고서 — 국내 미술시장 규모 및 유통 경로별 비중. [최신판 수치 확인 필요]

부록. 제안서 자체 점검

심사자가 가장 먼저 물을 질문 3개와 답

1. “기간 내에 되나요?” → M2 Baseline이 D-3에 완성되므로, 이후 어느 시점에 멈춰도 제출물이 존재합니다. 4개 레이어는 병렬이라 인원 수만큼 시간이 나뉩니다.
2. “유찰 데이터가 없으면 핵심 주장이 무너지지 않나요?” → 그래서 합성 검열 실험(Plan B)을 백업이 아닌 **주 실험**으로 설계했습니다. 정답을 알고 있는 상태에서 복원력을 측정하므로 인과 검증이 더 깨끗합니다.
3. “Tobit 손실은 이미 있는 기법 아닌가요?” → 맞습니다. 기여는 손실함수 발명이 아니라 **도메인 결합과 정량 검증**에 있으며, 제안서에 그렇게 명시했습니다. 없는 독창성을 주장하지 않는 것이 더 안전합니다.

아직 비어 있는 칸 - [] DLthon2 실제 일정으로 D-day 치환 - [] 데이터셋 라이선스 조항 확인 (특히 이미지 재배포 가능 여부) - [] 그림 2~4 실제 생성 - [] 예술경영지원센터 시장 규모 수치 확보