

2026 NAIS AI Hackathon 제출용 기획서

FALSIFY-AI

틀릴 가능성을 먼저 찾는 AI 과학자

성명	_____	팀명	_____
소속	_____	연락처/이메일	_____

1. 주제 요약 (300자 이내)

제출 문안

생성형 AI는 연구가설을 빠르게 만들지만, 반증 가능성·인용 신뢰성·재현성을 검증하지 못하면 연구 오류를 증폭시킬 수 있다. FALSIFY-AI는 Claim Decomposer, Evidence, Skeptic, Reproducibility, Statistics, Experiment, Judge Agent가 협업해 가설을 세부 주장으로 분해하고 지지·반박 문헌을 탐색하며 실제 데이터를 재분석한다. 최종적으로 근거·불확실성·재현성·다음 실험을 한 장의 Research Reliability Card로 제시해, 연구자가 AI의 답을 믿기 전에 틀릴 가능성을 먼저 확인하도록 한다.

2. 연구문제 및 제안배경

연구현장에서는 '관련 논문을 찾아 요약하는 AI'보다 '이 주장이 어디서 틀릴 수 있는가'를 빠르게 확인하는 AI가 더 시급하다. 인용 범위가 원문과 어긋나거나, 반대 결과가 누락되거나, 논문의 통계·코드·데이터가 재현되지 않으면 AI의 속도가 오히려 오류 전파 속도가 된다. 최근 Co-Scientist와 Robin은 과학 에이전트가 문헌·도구·실험 설계에 참여할 수 있음을 보여주었다. FALSIFY-AI는 이 흐름의 다음 병목인 신뢰성·반증·재현성을 별도 계층으로 해결한다.

3. 핵심 아이디어 및 차별성

기존 AI Scientist	FALSIFY-AI
지지 문헌 중심 검색	지지·중립·반박 evidence를 의도적으로 균형 검색
문장 단위 요약	claim-level 원문 passage와 관계 라벨
LLM 답변의 자기평가	실행 가능한 코드·통계 audit·재현성 trace
가설 또는 결론 제시	상태, 불확실성, 승인 상태, 다음 반증실험 제시

한 문장 가치제안

우리는 연구를 대신하는 AI가 아니라, AI가 만든 연구를 믿어도 되는지 검증하는 과학적 신뢰성 계층을 만든다.

4. 주요 내용 및 AI Agent 역할

순서	Agent	핵심 역할	출력
1	Claim Decomposer	가설 -> 변수·조건·결과·반증조건	검증 가능한 claim 목록
2	Evidence Agent	논문·특허·데이터에서 지지 근거 탐색	직접/간접 evidence
3	Skeptic Agent	반례·음성 결과·경계조건·대안 설명 탐색	contradiction set
4	Repro + Statistics	CSV/코드 재실행, 효과크기·CI·power 점검	분석 trace와 audit
5	Experiment Designer	경쟁가설을 가장 잘 구별할 후속실험 순위화	정보가치 기반 실험
6	Scientific Judge	모든 근거를 종합하되 인간 승인을 요구	Research Reliability Card

5. 구현방안 및 본선 MVP

입력: 연구가설 + 논문 PDF/URL 3-5개 + CSV 1개. 처리: 구조화 출력 기반 Orchestrator가 검색·반증·재현·통계 도구를 연결하고, 읽기 전용 sandbox에서 분석 코드를 실행한다. 출력: claim별 근거, 반증 증거, 재현성 상태, 통계 audit, 핵심 불확실성, 다음 실험, provenance를 한 화면에 제시한다.

본선 시간	우선 구현	시연 장면
0-7시간	입력 schema, claim/evidence/skeptic	지지 논문만 찾던 질문에 반증 논문이 함께 표시
7-12시간	CSV 재분석과 통계 audit	논문 수치와 재현 결과의 차이, 원인 표시
12-16시간	실험 설계와 Judge	'왜 확신도가 낮은가?'를 근거로 설명
16-19시간	UI/README/발표	Reliability Card와 GitHub 재실행

6. 실현가능성

본선에서는 모든 과학 분야를 지원하지 않고, 공개 문헌·단일 CSV·하나의 도메인 사례에 범위를 고정한다. 멀티에이전트의 핵심은 대화 연출이 아니라 각각의 도구 호출과 출력 schema를 분리하는 데 둔다. 모든 단계는 실패해도 다음 단계가 중단되지 않도록 fallback을 제공하며, 분석 결과가 없으면 '검증 불가'로 표시한다.

7. AI 윤리·신뢰성·안전 설계

위험	대응
환각·잘못된 인용	원문 passage와 DOI/URL 없이는 지지 판정 금지. 불확실한 문장은 Unresolved.
확증 편향	Skeptic Agent가 별도 검색 경로로 반례·음성 결과를 우선 탐색.
코드·데이터 오남용	읽기 전용 sandbox, 패키지 allowlist, 실행시간·메모리 제한.
통계 과신	p-value만 제시하지 않고 effect size, CI, sample size, power, missingness를 함께 표시.
개인정보·연구 IP	최소 수집·비식별화·접근권한·라이선스·데이터 보존 정책 적용.
자동화 과신	연구자 승인 전 결론 확정·실험 실행·외부 시스템 변경을 차단.

8. 심사기준 대응

기준	제안서에서의 대응	시연 증거
혁신성	생성 중심에서 반증 중심으로 전환. 과학적 Trust Layer라는 새로운 포지셔닝.	반증 증거와 Reliability Card
활용성	연구자가 바로 쓰는 문헌·데이터·통계·다음 실험 workflow.	입력 3종 -> 한 화면 결과
실행가능성	도메인·데이터·기능을 MVP로 제한하고 19시간 구현 계획을 사전 정의.	작동하는 업로드·분석·카드
확장성	도메인 adapter, 공개 benchmark, 기존 AI Scientist 위에 붙는 플랫폼.	provenance schema와 모듈 구조
AI 윤리·신뢰성	근거 필수, sandbox, human approval, 불확실성 공개.	source/code/statistics trace

9. 기대효과 및 후속 R&D;

- 연구 오류를 실행 전에 발견하고, 반증 가능한 다음 실험으로 연구비·시간 낭비를 줄인다.
- 연구 결과를 claim-source-data-code-model의 provenance로 남겨 재현·감사·협업을 돕는다.
- 바이오·소재·에너지·환경·문화유산 보존 등 도메인별 데이터·시뮬레이션 도구를 연결한다.
- 해커톤 이후 전문가 라벨 데이터와 공개 benchmark를 구축해 논문과 국가 R&D; 플랫폼으로 확장한다.

최종 메시지

AI가 답을 말하는 시대에는 '무엇이 맞는가'만큼 '무엇이 틀릴 수 있는가'를 보여주는 시스템이 필요하다. FALSIFY-AI는 그 질문을 연구 workflow의 기본 단계로 만든다.

서명: _____ 제출일: 2026년 ____월 ____일

참고: 행사 및 공고 조건은 AI4Sci Korea 2026 공식 페이지와 참조 대화에서 확인된 신청서 요구요소를 반영함. 개인·팀 정보는 사용자가 직접 입력.