

AI Native R&D; / 2026 NAIS AI Hackathon

# FALSIFY-AI

근거기반 과학적 반증, 재현성 검증, 후속실험 설계를 위한 멀티에이전트 연구 신뢰성 계층

핵심 포지셔닝

연구를 대신하는 AI가 아니라, AI가 만든 연구 주장을 신뢰 가능한 증거와 재현 가능한 분석으로 통과시키는 Trust Layer for AI-Native R&D;

제출자 정보

| 구분        | 입력란 |
|-----------|-----|
| 성명        |     |
| 팀명        |     |
| 소속        |     |
| 연락처 / 이메일 |     |

본 문서는 사용자가 제공하지 않은 개인·팀 정보 및 서명을 임의로 생성하지 않고, 입력용 빈칸으로 남겼습니다.

## 초록

생성형 AI와 과학 에이전트는 문헌 탐색, 가설 생성, 실험 제안의 속도를 높이고 있다. 그러나 과학적 의사결정의 병목은 새로운 문장을 만드는 데 있지 않고, 해당 주장이 어떤 조건에서 틀릴 수 있는지, 인용이 원문을 실제로 지지하는지, 데이터 분석이 재현되는지, 다음 실험이 경쟁가설을 얼마나 잘 구별하는지를 검증하는 데 있다. 본 연구는 생성 중심 AI Scientist에 반증 중심의 신뢰성 계층을 결합한 FALSIFY-AI를 제안한다. 시스템은 Claim Decomposer, Evidence Agent, Skeptic Agent, Reproducibility Agent, Statistics Agent, Experiment Designer, Scientific Judge가 협력하는 구조로 설계된다. 각 판단은 문헌의 주장 단위 인용, 실행 가능한 분석 코드, 통계량과 불확실성, 반증 가능성, 인간 승인 상태를 함께 기록한다. 연구질문은 반대 증거 탐색, 인용 검증, 재현성 및 통계 검증, 정보가치 기반 후속실험 추천이 단일 RAG 또는 일반 LLM 대비 유의미한 개선을 만드는지 검증하는 것이다. 해커톤 본선에서는 연구가설, 논문 3-5편, CSV 1개를 입력받아 Research Reliability Card를 출력하는 MVP를 구현하고, 이후 다분야 벤치마크와 전문가 평가로 확장한다.

핵심어: AI for Science, scientific agents, falsification, reproducibility, provenance, trustworthy AI, human-in-the-loop

## 1. 연구 배경 및 문제 정의

과학 연구는 관찰, 가설, 실험 설계, 데이터 분석, 가설 수정이 반복되는 과정이다. 최근에는 Co-Scientist와 Robin처럼 멀티에이전트가 문헌 검색과 전문 도구를 결합해 가설과 실험을 제안하는 시스템이 등장했다. 이는 AI가 연구 전주기에 참여할 수 있음을 보여주지만, 동시에 연구자의 검증 부담을 줄이려면 생성 결과가 아니라 검증 경로를 먼저 설계해야 한다는 과제를 남긴다.

본 연구가 겨냥하는 핵심 문제는 다음과 같다.

- 확증 편향: 질문과 일치하는 지지 문헌은 찾지만 반례, 음성 결과, 적용 조건의 경계는 놓치기 쉽다.
- 인용 불일치: 생성 문장과 원문 주장의 범위·조건·결론이 어긋날 수 있다.
- 재현성 공백: 논문에 제시된 데이터·코드·파라미터를 다시 실행하지 않고 결과를 단정한다.
- 통계적 과신: p-value만으로 결론을 내리고 효과크기, 신뢰구간, 검정력, 표본수와 결측을 충분히 점검하지 않는다.
- 다음 행동 부재: 불확실성이 남아도 가장 정보가치가 높은 추가 실험으로 연결되지 않는다.

### 연구의 중심 전환

Hypothesis Generation -> Evidence-Grounded Falsification -> Reproducible Verification -> Information-Gain Experiment -> Human Decision

## 2. 연구 목적 및 독창성

목적은 연구자의 판단을 자동 대체하는 것이 아니라, AI가 제안한 과학적 주장을 반증 가능한 구조로 바꾸고, 근거와 실행 흔적을 붙여 인간이 빠르게 감사할 수 있게 하는 것이다. FALSIFY-AI는 기존 문헌 요약형 RAG와 다음 네 가지 차별성을 갖는다.

| 차원    | 기존 생성형 연구 보조 | FALSIFY-AI                       |
|-------|--------------|----------------------------------|
| 질문 방향 | 무엇이 관련 있는가?  | 어떤 조건에서 틀리는가?                    |
| 근거    | 문서 단위 요약     | 주장 단위 지지·반박 그래프                  |
| 검증    | 언어적 자기평가     | 실행 코드·통계·재현성 검사                  |
| 결과    | 답변 또는 가설     | Research Reliability Card와 승인 상태 |
| 다음 행동 | 일반적 실험 제안    | 경쟁가설을 구별하는 정보가치 기반 실험            |

## 3. 관련 연구와 연구 공백

Co-Scientist는 Generation, Reflection, Ranking, Evolution, Proximity, Meta-review 등 전문 에이전트와 도구 사용을 통해 가설 생성과 자기비판을 수행한다. Robin은 문헌 검색 에이전트와 데이터 분석 에이전트를 결합해

가설-실험-해석의 순환을 구현했다. 이러한 연구는 멀티에이전트 과학 추론의 가능성을 보여주는 반면, AI의 결론이 실제 근거와 분석 실행에 의해 얼마나 지지되는지를 별도 평가 계층으로 구조화한 연구는 여전히 필요하다.

ScienceAgentBench는 데이터 기반 과학 과제에서 코드 생성과 분석을 엄격하게 평가할 필요를 제기한다. 따라서 본 연구는 과학 에이전트의 생성 능력을 확장하기보다, 반증·재현·통계·provenance를 묶은 검증 계층을 제안하고 독립적인 정량 평가를 설계한다.


## 4. 연구 질문과 검증 가설

| 연구질문                                | 검증 가설                                                                        | 핵심 지표                                                      |
|-------------------------------------|------------------------------------------------------------------------------|------------------------------------------------------------|
| RQ1. Skeptic Agent가 반대 증거를 더 잘 찾는가? | 멀티에이전트 반증 탐색은 일반 RAG보다 Contradiction Recall과 Evidence Precision을 높인다.        | Contradiction Recall, Evidence Precision, expert agreement |
| RQ2. 주장-근거-실행 trace가 판정 품질을 높이는가?   | 근거 그래프와 실행 trace를 함께 제시하면 Citation Verification Accuracy와 calibration이 개선된다. | citation accuracy, Brier score, ECE                        |
| RQ3. 재현성과 통계 검증이 과신을 줄이는가?          | Repro + Statistics Agent는 unsupported claim과 과도한 확신을 줄이고 재현성 오류를 더 잘 탐지한다.   | reproduction error, error detection F1                     |
| RQ4. 정보가치 기반 실험이 효율적인가?             | 경쟁가설을 최대한 구별하는 실험 추천은 일반적 LLM 추천보다 예상 정보이득/비용이 높다.                           | expected information gain, cost-normalized utility         |

## 5. 시스템 설계

입력은 연구 질문 또는 가설, 관련 논문 PDF/URL, 선택적 CSV와 실험 제약조건이다. Orchestrator는 주장을 원자 단위 claim으로 분해하고 각 에이전트의 작업을 병렬 또는 순차로 배치한다. Scientific Judge는 다른 에이전트의 말투를 투표하지 않고, claim-level evidence, source passage, 실행 결과, 통계 검증 결과, uncertainty를 입력으로 받아 판정한다.

### FALSIFY-AI evidence-to-decision pipeline



Every output carries claim-level evidence, executable analysis trace, uncertainty, and human approval state.

그림 1. 연구자 질문에서 근거 기반 판단까지의 실행 구조

| 에이전트                  | 역할                                           | 산출물                                  | 통제 장치                                  |
|-----------------------|----------------------------------------------|--------------------------------------|----------------------------------------|
| Claim Decomposer      | 가설을 변수·조건·결과·반증조건으로 구조화                      | Claim schema, competing hypotheses   | 원문 보존, 사용자 수정                          |
| Evidence Agent        | 지지·중립·반박 문헌을 검색하고 원문 passage 연결              | Evidence graph                       | 출처·검색시점·라이선스 기록                        |
| Skeptic Agent         | 반례, 경계조건, 음성 결과, 대안 설명을 의도적 탐색               | Contradiction set                    | 검색 쿼리와 누락 사유 공개                        |
| Reproducibility Agent | 제공 데이터·코드·표의 분석 재실행                          | Executable notebook, discrepancy log | Sandbox, resource limit, no write-back |
| Statistics Agent      | 효과크기, CI, sample size, power, missingness 점검 | Statistical audit                    | 도메인 전문가 승인                             |

| 에이전트                | 역할                    | 산출물                  | 통제 장치                 |
|---------------------|-----------------------|----------------------|-----------------------|
| Experiment Designer | 경쟁가설을 구별하는 후보 실험 순위화  | Next-experiment card | 비용·위험·윤리 constraint   |
| Scientific Judge    | 증거·실행·불확실성을 종합한 상태 판정 | Reliability Card     | 인간 승인 없이는 확정·실험 실행 금지 |

6. 데이터, 도구, provenance 설계

문헌은 DOI, PubMed, Crossref 또는 사용자가 제공한 합법적 PDF 등 출처가 확인되는 자료를 우선한다. 외부 검색 결과는 원문 passage와 함께 저장하며, 검색 결과 자체를 증거로 간주하지 않는다. CSV는 컬럼 설명, 단위, 결측, 표본수, 라이선스와 함께 등록한다. 분석 실행은 읽기 전용 샌드박스에서 수행하고 실행 ID, 코드 해시, 환경, 입력 파일 해시, 출력 통계량을 기록한다.

관장 기술 스택: Python, pandas, scipy/statsmodels, Jupyter 또는 실행 가능한 notebook, 벡터 검색/RAG, 구조화 출력(JSON Schema), tool calling, SQLite 또는 문서형 provenance store, Streamlit 기반 대시보드. 본선에서는 모델 제공자와 데이터베이스의 실제 사용 가능 여부에 따라 대체 가능한 모듈 구조를 유지한다.

7. Research Reliability Card

| 항목       | 예시 출력                                          | 판정 근거                        |
|----------|------------------------------------------------|------------------------------|
| 주장 상태    | Tentative / Supported / Unresolved / Falsified | claim-level evidence와 반증 조건  |
| 지지·반증 증거 | 직접 6, 간접 11, 반증 4                              | 검색된 원문 passage와 관계 라벨        |
| 재현성      | High / Moderate / Low                          | 코드 실행 성공, discrepancy, 누락 변수 |
| 통계 건전성   | effect size, 95% CI, power, missingness        | 실행된 계산 결과                    |
| 핵심 불확실성  | 온도 조건, 표본수, 측정 편향                              | Skeptic-Statistics audit     |
| 다음 실험    | 조건 A/B를 구별하는 최소 실험                             | 정보이득/비용/시간/위험                |
| 감사 추적    | source, code, model, prompt, timestamp         | provenance log와 승인 기록        |

8. 평가 설계

평가는 시스템 성능, 과학적 품질, 안전성, 사용성의 네 층으로 구성한다. 한 분야의 단일 사례만으로 일반화를 주장하지 않고, 공개된 재현 가능 데이터와 전문가가 판정한 claim set을 함께 사용한다.

| 평가 층           | 비교군                    | 측정 방법                      | 성공 기준(목표)                                    |
|----------------|------------------------|----------------------------|----------------------------------------------|
| 문헌 근거          | LLM direct, single RAG | 전문가 라벨 기반 precision/recall | 반증 recall +20%p 이상, citation accuracy 90% 이상 |
| 분석 재현          | LLM code generation    | 동일 입력 재실행과 논문 수치 비교        | 코드 실행 성공률 80% 이상, discrepancy 원인 설명          |
| 판정 calibration | 단일 Judge               | 정답 claim set, Brier/ECE    | 확신도 과신 감소, calibration 개선                    |
| 실험 추천          | 일반적 실험 제안              | 전문가 블라인드 평가와 정보이득/비용       | Top-1 유용성 4/5 이상                             |
| 사용성            | 기존 연구자 workflow        | time-to-decision, SUS형 설문  | 의사결정 시간 30% 이상 단축                            |

재현 가능한 실험 프로토콜

- 사전등록된 claim set과 평가 기준을 먼저 고정하고, 시스템 구성과 프롬프트를 버전 관리한다.
- 동일한 입력을 최소 3회 반복해 확률적 변동을 보고한다.
- 검색·실행·판정의 각 단계에 실패 원인과 누락된 증거를 별도 기록한다.
- Ablation: Skeptic 제거, Repro 제거, provenance 제거, 단일 Judge 비교를 수행한다.

9. 본선 MVP 구현 계획

본선 시연은 하나의 도메인에 고정해 기능 완성도를 확보한다. 예시 입력은 'A 물질의 첨가가 배터리 수명을 증가시킨다'와 같이 사용자가 제공한 가설, 논문 3-5편, CSV 1개로 제한한다. 시스템이 모든 과학 분야를 해결한다고 주장하지 않고, 핵심 검증 루프를 한 번 완주하는 것을 성공 기준으로 둔다.

| 시간      | 구현 목표                                     | 검증 가능한 결과            |
|---------|-------------------------------------------|----------------------|
| 0-3시간   | 입력 schema, 파일 업로드, claim decomposition    | claim 목록과 반증 조건      |
| 3-7시간   | Evidence/Skeptic 검색 및 citation passage 연결 | 지지·반증 evidence graph |
| 7-12시간  | CSV 분석 notebook 실행, 통계 audit              | 수치·그래프 실행 trace      |
| 12-16시간 | Experiment/Judge 및 Reliability Card       | 상태·불확실성·다음 실험        |
| 16-19시간 | UI, 오류 처리, 시연 시나리오, README/GitHub         | 재현 가능한 데모와 5분 발표     |

## 10. AI 윤리, 신뢰성, 안전 설계

본 설계는 NIST AI RMF의 Govern, Map, Measure, Manage 관점과 NIH의 rigor and reproducibility 원칙을 적용한다. 특히 과학적 결론을 자동 확정하지 않고, 근거 수준과 불확실성을 표시하며, 인간 승인 이전에는 실험 실행·외부 시스템 변경·고위험 의사결정을 차단한다.

| 위험       | 대응 설계                                   | 잔여 위험과 운영 원칙                |
|----------|-----------------------------------------|-----------------------------|
| 환각·인용 조작 | 원문 passage 필수, DOI/URL 검증, 미확인 문장 표시    | 근거 없는 주장은 'Unresolved'로만 출력 |
| 확증 편향    | Skeptic Agent를 독립 검색 경로로 분리, 반증 우선 UI   | 검색 누락을 정답으로 해석하지 않음         |
| 코드 실행 위험 | 읽기 전용 sandbox, 패키지 allowlist, 시간·메모리 제한 | 분석 결과는 참고용, 인간 검토 필수        |
| 통계 오용    | 효과크기·CI·power-missingness 함께 표시         | 도메인 통계 전문가 sign-off         |
| 민감정보·IP  | 비식별화, 접근권한, 최소 수집, 원문 라이선스 기록           | 사용자 데이터 외부 학습 전용 금지         |
| 자동화 과신   | 신뢰 점수 대신 상태·근거·불확실성 카드                  | 모든 최종 결정은 연구자 승인            |

## 11. 기대성과 및 확장성

- 학술적 성과: 반증 중심 scientific agent의 구조와 평가 지표를 제안하고, claim-level evidence와 reproducibility를 결합한 실험 결과를 논문화한다.
- 현장 성과: 연구자가 읽어야 할 문헌과 다시 확인해야 할 분석을 우선순위화해 time-to-decision을 줄인다.
- 국가 R&D; 확장: 바이오, 소재, 에너지, 환경, 문화유산 보존 등 도메인별 evidence adapter와 통계·시뮬레이션 도구를 연결한다.
- 플랫폼 확장: 기존 AI Scientist 또는 연구 보조 서비스 위에 붙는 독립 Trust Layer로 배포하고, provenance를 감사·재현·협업의 공통 포맷으로 제공한다.
- 데이터 자산: 공개 benchmark, failure cases, expert-labeled contradiction set을 축적해 과학 에이전트 평가 인프라로 발전시킨다.

## 12. 결론

FALSIFY-AI는 AI가 더 많은 가설을 말하게 하는 프로젝트가 아니라, 그 가설이 왜 믿을 만한지 또는 왜 아직 믿으면 안 되는지를 검증 가능하게 만드는 프로젝트다. 본선에서는 작은 범위의 완주 가능한 MVP로 차별성을 증명하고, 연구 질문과 사전 정의된 지표를 통해 해커톤 결과를 재현 가능한 논문 연구로 확장한다. 핵심 성공 기준은 화려한 자율성보다 '근거가 보이고, 분석이 다시 실행되며, 반증 가능성이 드러나고, 인간이 승인할 수 있는가'이다.

참가자 입력란: 연구자/팀 정보, 도메인 사례, 실제 데이터셋, 사용 가능한 API 및 모델은 제출 전 기입한다.

## 참고문헌 및 공식 근거

[1] AI4Sci Korea 2026, '2026 NAIS AI Hackathon: AI Native R&D;, Powered by Agents', 공식 행사 페이지, <https://ai4scikorea.org/> (accessed 2026-08-15).

[2] Gottweis, J. et al., 'Accelerating scientific discovery with Co-Scientist', Nature, 2026. DOI: 10.1038/s41586-026-10644-y.

[3] Ghareeb, A. E. et al., 'A multi-agent system for automating scientific discovery', Nature 655, 497-505, 2026. DOI: 10.1038/s41586-026-10652-y.

[4] Huang, K. et al., 'ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery', arXiv:2410.05080, 2024.

[5] Autio, C. et al., NIST AI 600-1, 'Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile', NIST, 2024. DOI: 10.6028/NIST.AI.600-1.

[6] NIH, 'Guidance: Rigor and Reproducibility in Grant Applications', National Institutes of Health, updated guidance page, <https://www.grants.nih.gov/policy-and-compliance/policy-topics/reproducibility/guidance>.

[7] 'Multi-agent AI systems need transparency', Nature Machine Intelligence 8, 1, 2026. DOI: 10.1038/s42256-026-01183-2.

**공고·신청서 반영 메모**

참조 대화에서 확인된 제출 조건인 3쪽 이내 기획서, 300자 이내 주제요약, 연구문제·제안배경·주요내용·구현방안·AI 윤리 및 안전·기대효과·확장성 항목과 혁신성·활용성·실현가능성·확장성 중심의 심사 대응을 제출용 PDF에 반영했다. 개인·팀 정보와 서명은 빈칸으로 남겼다.