

## K-ART-4L 파일럿 코퍼스 구축 계획서

공개 데이터 소스 조사 및 수집·주석 실행 계획 (v1.0) 작성: 2026. 07. | 목표: 파일럿 1,000점 → 워크숍 논문 실험용 코퍼스

### 1. 공개 데이터 소스 조사 결과 총괄표

| # | 소스                                   | 운영기관     | 규모·특성                                                            | 접근 방식                                                          | 라이선스                             | 4-레이어 적합성                                | 파일럿 우선순위           |
|---|--------------------------------------|----------|------------------------------------------------------------------|----------------------------------------------------------------|----------------------------------|------------------------------------------|--------------------|
| 1 | e뮤지엄 (emuseum.go.kr)                 | 국립중앙박물관  | 354개 협력 박물관 통합, 약 250만 건 유물정보. 국립 27 개관 + 공립 141 + 사립 82 + 학교 23 | 공공데이터포털 오픈 API(자동승인, 개발계정 일 1,000 건). 소장품 목록·상세 조회, 이미지 URL 포함 | 공공누리(자료별 유형상이 — 필드 확인 필수)        | 도상 ★★★ 기법★★ 물성★★ 색채★★★ (민화·불화·풍속화·공예 풍부) | 1순위 — 주력           |
| 2 | 국립중앙박물관 고화질 이미지 (museum.go.kr 소장품검색) | 국립중앙박물관  | 고화질(최대 1,500만 화소급) 소장유물 이미지. 국보·보물 포함, 상업적 이용 보장 방침              | 누리집 소장품 검색 다운로드 + e뮤지엄 API 연계                                  | 공공누리 1유형 중심(개별 확인)               | 물성 ★★★ (고해상도 → 텍스트처·발목 분석 가능)            | 1순위 — 고해상도 서브셋     |
| 3 | 국가유산포털 (heritage.go.kr)              | 국가유산청    | 국가지정유산, 기록유산 원문, 궁궐·왕릉, 유네스코 등재유산 통합                             | 오픈 API(XML만 제공, 클라이언트 직접 호출 불가 → 서버사이드 수집 필요)                  | 공공누리 — 일부 4유형 (변경금지) 주의          | 도상 ★★★ (불화·탱화·단청·궁중문양)                   | 2순위                |
| 4 | 국가유산 디지털 서비스 (digital.khs.go.kr)     | 국가유산청    | 3D 콘텐츠·테마 자료 등 디지털 특화 자료                                         | 웹 다운로드                                                         | 자료별 확인                           | 물성★★ (3D·질감 참조)                          | 3순위                |
| 5 | 공유마당 (gongu.copyright.or.kr)         | 한국저작권위원회 | 만료저작물 + 기증저작물 + 공공콘텐츠. 미술·사진 이미지 필터, CCL/공공누리 유형별 검색 지원          | 웹 검색·다운로드 (CCL 필터: 만료/기증/공공누리)                                 | 저작권 만료분 = 가장 자유로운 이용 (생성 실험에 최적) | 기법 ★★★ (근대기 한국화 만료작 — 필법·발목 라벨링에 적합)     | 1순위 — 생성성 (T3) 실험용 |
| 6 |                                      |          |                                                                  | 오픈 API                                                         |                                  |                                          | 3순위                |

| # | 소스                                                     | 운영기관     | 규모·특성                                                                             | 접근 방식                      | 라이선스        | 4-레이어 적합성                  | 파일럿 우선순위      |
|---|--------------------------------------------------------|----------|-----------------------------------------------------------------------------------|----------------------------|-------------|----------------------------|---------------|
|   | 문화공공데이터광장<br>(culture.go.kr/data)                      | 문화체육부    | 문화 분야 공공데이터 통합(전시·소장품·문화시설 메타데이터)                                                 |                            | 공공누리        | 메타데이터 보장용                  |               |
| 7 | 해외 오픈엑세스 한국미술 컬렉션 — MET·클리블랜드미술관·시카고미술관·스미소니언 국립아시아미술관 | 각 기관     | 한국 회화·도자·공예 소장품. CC0(퍼블릭 도메인) 선언 + 공개 API(MET Collection API, Cleveland OA API 등) | REST API, 고해상도 이미지 직접 다운로드 | CC0 — 제약 없음 | 도상·색채 ★★★ + 국제 벤치마크 비교군 역할 | 2순위 — 차별화 포인트 |
| 8 | 위키미디어 공용<br>(commons.wikimedia.org)                    | 위키미디어 재단 | 김홍도·신윤복 등 조선 회화 퍼블릭 도메인 도판 다수                                                     | API·덤프                     | PD/CC       | 보조·중복 검증용                  | 보조            |

유사 선행 사례(중복 회피·Related Work 반영): 경희대 나형민 교수팀의 한국 전통 미술(수묵화·채색화·민화) 데이터 구축 및 한국화 생성형 AI 개발 사례가 존재한다. 다만 해당 데이터는 공개 벤치마크 형태가 아니므로, K-ART-4L의 차별점은 '공개(open) + 4-레이어 전문가 주석 + 표준 평가 프로토콜'로 명확히 설정한다. AI허브에는 한국 미술 전용 데이터셋이 부재함을 확인 — 논문의 연구 공백(gap) 주장을 뒷받침하는 실증 근거.

## 2. 파일럿 코퍼스 설계 (목표 1,000점)

'small-but-deep' 원칙에 따라, 4-레이어 주석 밀도가 높은 장르를 우선한다.

| 블록          | 장르·내용                       | 목표 수량 | 주 소스                        | 선정 기준                             |
|-------------|-----------------------------|-------|-----------------------------|-----------------------------------|
| A. 민화       | 작호도(까치호랑이)·책가도·십장생도·문자도·화조도 | 300   | e뮤지엄(국립민속박물관·국립관 소장분), 공유마당 | 도상 레이어 계층 라벨의 밀도 최대 장르            |
| B. 풍속화·인물화  | 김홍도·신윤복 계열 및 무악관 풍속화        | 200   | e뮤지엄, 위키미디어, 해외 CC0         | 도상(생활사)·색채                        |
| C. 불화·종교 미술 | 탱화·괘불·사경변상도 (지정유산 도판)       | 150   | 국가유산포털, e뮤지엄                | 색채(오방색 온톨로지)·도상 — 생성 비용 제외 플래그 적용 |
| D. 궁중·장식 미술 | 일월오봉도·궁중문양·단청·의궤 도설         | 150   | 국가유산포털, 국립고궁박물관(e뮤지엄 경우)    | 색채·문양 도상                          |
|             | 저작권 만료 근대기 수묵·채색화           | 150   | 공유마당 만료저작물                  |                                   |

| 블록                 | 장르·내용                            | 목표<br>수량 | 주 소스                             | 선정 기준                              |
|--------------------|----------------------------------|----------|----------------------------------|------------------------------------|
| E. 근대 한국<br>화(만료작) |                                  |          |                                  | 기법 레이어(필법·발목) + T3 생<br>성 실험 전용 블록 |
| F. 물성 참조           | 한지·비단·안료 접사, 고해상도<br>부분 확대(crop) | 50       | 국립중앙박물관 고화질 이미<br>지에서 상세 crop 생성 | 물성 레이어 보조 학습                       |

설계 원칙 세 가지: 1. **생성 실험(T3)**은 블록 E(만료저작물)에서만 수행 — 저작권·변경금지 리스크를 원천 차단. 2. 블록 C(종교미술)는 인식(T1·T2) 전용 — 문화 전유·종교적 민감성 거버넌스 반영. 3. **해외 CC0 소장분**을 10~15% 혼입 — 국내외 디지털화 품질·메타데이터 격차 자체를 분석 대상으로 삼아 논문의 국제적 시사점 확보.

### 3. 수집 파이프라인 (4주 실행 계획)

#### 1주차 — 접근권 확보 및 스키마 설계

- 공공데이터포털에서 'e뮤지엄 유물정보'·'전국 박물관 유물정보' API 활용신청(자동승인, 즉일 발급).
- 국가유산포털 오픈 API 키 신청(XML 파서 준비 — 서버사이드 수집 스크립트 필요).
- 해외 기관 API(MET·클리블랜드)는 키 없이 즉시 사용 가능 — 'Korea' 필터 쿼리 테스트.
- 통합 메타데이터 스키마 v0.1 확정: 아래 매핑 테이블 기준.

| K-ART-4L 필드          | e뮤지엄 원천 필드  | 국가유산포털  | 해외 CC0 API          |
|----------------------|-------------|---------|---------------------|
| title_ko / title_en  | 유물명(국문/한자)  | 국가유산명   | title               |
| period               | 국적/시대       | 시대      | period/dynasty      |
| material_raw → L3 시드 | 재질          | 재질·구조   | medium              |
| subject_raw → L1 시드  | 주제/용도·기능 분류 | 분류      | classification/tags |
| image_url + 해상도      | 이미지 경로      | 사진 URL  | primaryImage        |
| license              | 공공누리 유형 필드  | 공공누리 유형 | CC0 고정              |
| provenance           | 소장처·유물번호    | 관리번호    | objectID·accession  |

핵심 설계 포인트: 원천 메타데이터(재질·주제 분류)를 4-레이어 주석의 '시드(seed) 라벨'로 자동 매핑한 뒤 전문가가 검수·세분화하는 2단계 구조 → 주석 비용을 크게 절감하면서 논문에는 'metadata-bootstrapped annotation'이라는 방법론적 기여로 기술 가능.

#### 2주차 — 크롤링·필터링

- API 일 1,000건 트래픽 한도 내 배치 수집(장르 키워드: 민화, 호랑이, 책가도, 십장생, 풍속, 탕화, 오봉도 등).
- 자동 필터: (a) 이미지 해상도  $\geq 1,024\text{px}$  장변, (b) 공공누리 1·2유형만 통과(3·4유형 '변경금지'는 별도 격리 폴더 — 인식 실험만 허용), (c) 중복 제거(pHash 기반).
- 산출물: raw\_corpus.parquet (전체 메타데이터) + 이미지 저장소.

### 3주차 — 시드 라벨 자동 부여 및 검수 세트 구성

- 원천 분류 → 4-레이어 시드 라벨 규칙 기반 매핑(예: 재질 '지본채색' → L3: 한지+채색안료).
- CLIP 제로샷으로 예비 태깅 후 신뢰도 낮은 샘플을 검수 우선순위로 정렬(active learning 방식).
- 전문가 검수 파일럿: 200점 × 4레이어 (본인 + 검수자 1인 → 일치도  $\kappa$  예비 측정. 이 수치가 워크숍 논문의 핵심 표가 됨).

### 4주차 — 제로샷 진단 실험 및 데이터시트 작성

- CLIP/SigLIP 제로샷 T1 실험 → '문화 표현 격차' 진단 수치 확보(논문 5.2절 플레이스홀더 대체).
- Datasheets for Datasets 양식의 데이터시트 v0.1 작성 — 소스·라이선스·필터링 기준 전부 기록.

## 4. 라이선스·거버넌스 체크리스트

- [ ] 공공누리 유형을 **이미지 단위**로 기록했는가 (기관 단위 가정 금지 — 동일 기관 내에서도 자료별 유형이 다름)
- [ ] 3·4유형('변경금지') 자료를 생성 실험 파이프라인에서 물리적으로 격리했는가
- [ ] 생성 실험(T3)은 저작권 만료분(공유마당 블록 E)으로만 수행하는가
- [ ] 종교미술(블록 C)에 생성 비용 제외 플래그를 적용했는가
- [ ] 출처표시 문자열(기관명·유물번호·공공누리 유형)을 메타데이터에 포함해 재배포 시 자동 표기되는가
- [ ] 근현대 작가(박서보 등 저작권 존속 작가) 작품은 파일럿에서 **제외**하고, 본 데이터셋 단계에서 기관 협약(라이선스 tier-b)으로만 다루는가
- [ ] 데이터셋 공개 시 이미지 원본 재배포 대신 'URL + 메타데이터 + 주석' 배포 방식(WebDataset 관행)을 검토했는가

특히 마지막 항목은 중요하다. 이미지 원본을 직접 재배포하지 않고 원천 기관 URL을 참조하는 방식은 LAION 등 대형 데이터셋의 표준 관행으로, 공공누리 조건과의 충돌을 최소화하면서 재현성을 유지한다.

## 5. 리스크와 대응

| 리스크                         | 발생 가능성 | 대응                                               |
|-----------------------------|--------|--------------------------------------------------|
| API 트래픽 한도(일 1,000건)로 수집 지연 | 중      | 활용사례 등록 시 트래픽 증량 신청 가능. 파일럿 1,000점 규모는 한도 내 충분   |
| 국가유산포털 XML 파싱·직접 호출 제한      | 중      | 서버사이드 수집 스크립트로 우회(공식 허용 방식). 필요 시 공공데이터 포털 경유    |
| 저해상도 이미지 비중 과다              | 중      | 국립중앙박물관 고화질 서비스분을 물성 서브셋으로 별도 확보                 |
| 원천 메타데이터의 분류 불일치(기관별 상이)    | 높음     | 크로스워크 매핑 테이블 작성 — 이 자체가 논문 부록 기여물이 됨             |
| 근대 작가 저작권 만료 여부 판단 오류       | 중      | 공유마당 '만료' 필터만 신뢰. 사망연도 +70년 규칙 개별 검증. 판단 곤란 시 제외 |

## 6. 다음 단계 제안

1. **즉시 실행 가능:** 공공데이터포털 API 활용신청(무료·자동승인) → 첫 100건 샘플 수집으로 메타데이터 품질 실측.
2. **2주 내:** 시드 라벨 매핑 규칙 초안 + 주석 지침서(codebook) 목차 작성 — 이 문서가 학예 전문성을 논문 기여로 변환하는 핵심 산출물.
3. **협업 타진:** 국립민속박물관(민화 최대 소장처)·국립고궁박물관에 연구 목적 고해상도 협조 공문 — 소속 대학원 명의로 발송하면 본 데이터셋(v1.0) 단계의 tier-b 협약 기반이 된다.

---

### 참고 소스 (조사 시점: 2026. 07.)

- e뮤지엄: [emuseum.go.kr](http://emuseum.go.kr) / 오픈 API: [data.go.kr](http://data.go.kr) (문화체육관광부\_국립중앙박물관 전국 박물관 유물정보, 데이터셋 번호 3036708 및 e뮤지엄 유물정보 15104964)
- 국립중앙박물관 고화질 이미지 공개: [museum.go.kr](http://museum.go.kr) 소장품 검색·보도자료
- 국가유산청 국가유산포털: [heritage.go.kr](http://heritage.go.kr) / 오픈 API 개방목록: [khs.go.kr](http://khs.go.kr) / 디지털 서비스: [digital.khs.go.kr](http://digital.khs.go.kr)
- 공유마당: [gongu.copyright.or.kr](http://gongu.copyright.or.kr) (한국저작권위원회)
- 문화공공데이터광장: [culture.go.kr/data](http://culture.go.kr/data)
- 해외: MET Collection API, Cleveland Museum of Art Open Access API, Art Institute of Chicago API, Smithsonian Open Access