

발표 현장 낭독용 최종본

K-ART LENS

한국 미술 작품 4-Layer 자동 해석 및 유사작 검색 엔진

최종 15분 실전 발표대본 + 대상 수상 수준 압박질문 30선

구성: 표지, 15분 발표대본, 압박질문 30개와 모범답변, 금지 답변 7가지
답변 공식, 발표 직전 암기 7문장, 마지막 20초 엔딩

I. 최종 15분 실전 발표대본

권장 실제 발표시간: 14분 20초~14분 40초

남은 20~40초는 슬라이드 전환, 호흡, 돌발상황을 위한 버퍼입니다.

[멈춤], [강조], [화면 지시]는 실제 발표 동작입니다.

Slide 1. K-ART LENS

0:00~1:05

핵심 메시지: “우리는 AI에게 작품을 맞춰 보라고 한 것이 아닙니다.”

안녕하세요.

K-ART LENS, 한국 미술 작품 4-Layer 자동 해석 및 유사작 검색 엔진을 발표할 추병곤입니다.

[1초 멈춤]

발표를 시작하기 전에 한 장면을 떠올려 보겠습니다.

미술관에 새로운 작품 한 점이 들어왔습니다.

누군가는 작품 정보를 확인해야 하고,

누군가는 무엇이 그려져 있는지 기록해야 하며,

누군가는 재료와 기법을 정리해야 합니다.

그리고 기존 소장품 가운데 어떤 작품과 연결되는지도 찾아야 합니다.

현재 이런 상세 페이지와 소장품 DB 메타데이터 작성은 작품 한 점당 상당한 수작업을 요구합니다.

그런데 더 중요한 문제는 시간만이 아닙니다.

같은 작품도 사람마다 다른 용어로 기록할 수 있다는 것.

바로 이 지점에서 질문을 바꿨습니다.

[조금 천천히]

“AI가 이 작품을 맞힐 수 있는가?”가 아니라,

“AI가 사람이 작품을 이해하는 방식을 구조화할 수 있는가?”

이 질문에서 K-ART LENS가 시작됐습니다.

그리고 오늘 발표 전체를 관통하는 원칙도 하나입니다.

[강조]

근거 없는 성능값은 만들지 않는다.

Slide 2. 문제는 검색이 아니라 해석 단위다

1:05~2:10

처음에는 저도 단순한 유사 이미지 검색 문제라고 생각했습니다.

이미지를 넣고, 가장 비슷한 작품을 찾아주면 된다고 생각했습니다.

그런데 미술관의 실제 질문은 달랐습니다.

“왜 비슷한가?”

도상이 비슷한 것인가?

기법이 비슷한가?

재료가 비슷한가?

색채가 비슷한가?

단일 이미지 임베딩은 “비슷하다”는 결과는 잘 만들 수 있습니다.

하지만 그 유사성을 실무자가 원하는 의미 단위로 설명하기에는 한계가 있습니다.

특히 한국화는 더 어렵습니다.

장지, 한지, 먹, 분채, 석채, 혼합재료와 같이 이미지만으로 단정하기 어려운 물성이 존재하기 때문입니다.

그래서 이 프로젝트의 첫 번째 결론은 이것이었습니다.

[강조]

문제는 검색 알고리즘보다 먼저, 작품을 어떤 단위로 해석할 것인가에 있다.

그래서 작품을 하나의 이미지가 아니라 **네 개의 렌즈로 나누었습니다.**

Slide 3. 시스템은 작품을 네 개의 층위로 나눈다

2:10~3:25

첫 번째 렌즈는 **도상, Iconography**입니다.

질문은 간단합니다.

“무엇이 그려져 있는가?”

여기에는 CLIP 또는 SigLIP 계열의 의미 임베딩을 활용합니다.

두 번째는 **기법, Technique**입니다.

“어떻게 만들어졌는가?”

VGG 중간층의 Gram 통계를 활용해 표면적 스타일과 제작 특성을 표현합니다.

세 번째는 **물성, Materiality**입니다.

“무엇으로 만들어졌는가?”

한국화 재료 vocabulary와 rule-based fallback을 결합했습니다.

마지막은 **색채, Color**입니다.

HSV histogram과 k-means를 활용해 작품의 주요 색채 구조를 표현합니다.

[화면 네 영역을 차례로 가리킴]

도상.

기법.

물성.

색채.

이 구조의 핵심은 특징을 네 개 더 만든 것이 아닙니다.

질문할 수 있는 관점을 네 개로 만든 것입니다.

이제 사용자는 “비슷한 작품을 찾아주세요”가 아니라,

“물성이 비슷한 작품을 찾아주세요.”

“도상은 다르지만 색채가 유사한 작품을 보여주세요.”

라고 질문할 수 있습니다.

[강조]

우리는 검색 결과의 개수를 늘린 것이 아니라, 검색할 수 있는 질문의 종류를 늘렸습니다.

Slide 4. 파이프라인은 로그가 남는 단위로 설계된다

3:25~4:30

이제 시스템 내부를 보겠습니다.

첫째, 작품 이미지를 입력하고 정규화합니다.

장변 384픽셀 기준으로 정규화하고 pHash를 이용해 중복을 관리합니다.

둘째, 네 개 Layer의 특징을 각각 추출합니다.

셋째, VLM이 자유롭게 긴 문장을 생성하게 두지 않고 **고정된 JSON schema** 안에서 결과를 생성하도록 제한합니다.

필요하면 validation, retry, fallback을 적용합니다.

넷째, FAISS를 이용해 Layer별 또는 가중 방식으로 Top-5 유사작을 검색합니다.

마지막으로 4-Layer JSON, 한국어 해설, 유사작 Top-5, CSV 출력으로 연결합니다.

그런데 이 슬라이드에서 제가 가장 강조하고 싶은 것은 결과 화면이 아닙니다.

[1초 멈춤]

각 단계가 기록될 수 있다는 점입니다.

왜냐하면

[강조]

평가 가능성은 예쁜 결과 화면이 아니라 로그 구조에서 나오기 때문입니다.

Slide 5. 평가는 실무 사용 가능성을 기준으로 다섯 축을 본다

4:30~5:40

그렇다면 이 시스템을 어떻게 평가해야 할까요?

Accuracy 하나만 높으면 좋은 미술관 AI라고 할 수 있을까요?

저는 아니라고 판단했습니다.

그래서 다섯 가지 질문을 만들었습니다.

첫째, **Accuracy.**

4-Layer 결과가 큐레이터의 Gold Label과 얼마나 일치하는가?

둘째, **Reliability**.

실제 사용자가 기다릴 수 있는 시간 안에 결과가 나오는가?

셋째, **Structure**.

첫 번째 JSON 출력이 schema를 안정적으로 통과하는가?

넷째, **Retrieval**.

AI가 추천한 Top-5를 실제 큐레이터도 관련 있다고 판단하는가?

다섯째, **Usability**.

실무자가 이 결과를 실제 업무에서 사용할 의향이 있는가?

한 문장으로 줄이면 이렇습니다.

[박자를 두고]

정확한가.

빠른가.

안정적인가.

잘 찾아오는가.

그리고 사람이 실제로 쓰고 싶은가.

K-ART LENS는 이 다섯 축을 함께 보도록 설계했습니다.

Slide 6. 성공 기준은 사전에 고정했다

5:40~6:50

그리고 중요한 원칙 하나를 더 세웠습니다.

결과를 본 뒤 성공 기준을 바꾸지 않는다.

그래서 사전에 목표치를 정의했습니다.

색채 일치율은 **90% 이상**.

물성 **80% 이상**.

기법 **65% 이상**.

도상 **55% 이상**.

P95 End-to-End 처리시간은 **15초 이하**.

JSON first-pass 통과율 **95% 이상**.

Top-5 명확 관련성 **60% 이상**.

실무자 평가는 **5점 만점에 3.5 이상**입니다.

레이어마다 목표가 다른 이유는 문제의 난도가 다르기 때문입니다.

색채처럼 비교적 직접적으로 계산할 수 있는 특징과,

추상·반추상 작품에서 해석의 모호성이 큰 도상을

같은 난이도로 취급하는 것은 오히려 현실을 왜곡할 수 있습니다.

여기서 중요한 것은 목표 숫자 자체보다

[강조]

결과를 보기 전에 성공과 실패의 경계를 먼저 정했다는 점입니다.

Slide 7. 확정 가능한 것과 보류해야 하는 것을 분리했다

6:50~8:00

이제 이번 프로젝트에서 가장 중요한 판단을 말씀드리겠습니다.

현재 자료에는 세 종류의 정보가 존재합니다.

첫째, 확정 가능한 설계 정보입니다.

4-Layer 구조,

평가 산식,

KPI,

필요한 데이터 구조입니다.

둘째는 계산 구조를 설명하기 위한 **예시 수치**입니다.

92%.

12.8초.

96%.

68%.

3.8점.

그리고 셋째는 현재 확정하면 안 되는 것입니다.

바로 최종 PASS와 FAIL입니다.

왜냐하면 현재 제출 자료에는 이 숫자를 독립적으로 다시 계산할 수 있는 원시 로그 전체가 최종 증빙 패키지 형태로 갖춰져 있지 않기 때문입니다.

따라서 오늘 저는 이 숫자들을 실제 최종 성능이라고 주장하지 않겠습니다.

[1초 멈춤]

발표에서 숫자를 많이 보여주는 것은 어렵지 않습니다.

하지만 연구자가 더 어려운 선택을 해야 할 때가 있습니다.

[천천히]

“어디까지 알고 있고, 어디부터 아직 모르는지 정확히 말하는 것.”

저는 그것도 AI 연구의 성능이라고 생각했습니다.

Slide 8. 예시 수치는 결과가 아니라 산식 검증값이다

8:00~8:50

예를 들어 보겠습니다.

100점 가운데 92점의 색채 라벨이 일치한다면 Accuracy는 92%입니다.

100번의 JSON 생성 가운데 96번이 첫 시도에서 schema를 통과했다면 96%입니다.

Top-5 평가 항목 가운데 68개를 큐레이터가 “명확히 관련 있음”으로 판단했다면 68%입니다.

이렇게 산식은 검증할 수 있습니다.

그러나 현재 자료에서 92%, 12.8초, 96%, 68%, 3.8점은 **최종 실측 성과가 아니라 계산 예시**입니다.

따라서 이번 발표의 질문은 “우리가 몇 퍼센트를 달성했는가?”에서 끝나지 않습니다.

더 중요한 질문은

[강조]

“그 숫자를 어떻게 다시 계산할 수 있는가?”

입니다.

Slide 9. 성능 숫자는 Evidence Chain으로 역산 가능해야 한다

8:50~10:05

그래서 성능 숫자 뒤에 **Evidence Chain**, 증거사슬을 설계했습니다.

[화면 따라가며]

Artwork.

Gold Label.

Prediction.

Log.

Metric.

Threshold.

그리고 마지막에 PASS 또는 FAIL.

이 과정을 증명하려면 여섯 종류의 원시 파일이 필요합니다.

`gold_labels.csv`.

큐레이터의 정답입니다.

`predictions.jsonl`.

모델의 4-Layer 출력입니다.

`latency_log.csv`.

단계별 처리시간입니다.

`schema_validation_log.csv`.

JSON 유효성 기록입니다.

`top5_relevance_eval.csv`.

큐레이터가 Top-5 결과를 평가한 기록입니다.

마지막으로 `practitioner_survey.csv`.

실무자 평가입니다.

이 여섯 개 파일이 완성되면 누군가 제 발표를 믿지 않아도 됩니다.

[1초 멈춤]

직접 다시 계산하면 되기 때문입니다.

“저를 믿어주세요”가 아니라,

[강조]

“데이터를 확인해 주세요.”

저는 이것이 데모와 실증 시스템을 나누는 중요한 차이라고 생각합니다.

Slide 10. 실패를 숨기지 않고 오류의 이름을 붙였다

10:05~11:25

연구 과정에서 가장 흥미로운 것은 잘 맞힌 작품보다 **틀린 작품**이었습니다.

특히 한국화에서 중요한 문제가 있었습니다.

장지, 한지, 분채와 같은 재료를 acrylic이나 oil 계열로 잘못 판단할 수 있는 **Material Hallucination**입니다.

그래서 한국화와 전통 재료군의 제한 vocabulary를 활용해 자유생성 문제를 가능한 범위에서 분류 문제로 축소하고,

필요할 경우 rule fallback을 적용하는 방향을 설계했습니다.

그리고 오류 자체도 여섯 가지로 나눴습니다.

Material Hallucination.

Iconographic Ambiguity.

Technique-Material Confusion.

Color Simplification.

Schema Error.

Retrieval Mismatch.

중요한 것은 “우리 AI는 틀리지 않습니다”라고 말하는 것이 아닙니다.

오히려 반대입니다.

[강조]

“우리 AI는 어떤 방식으로 틀리는가?”를 설명할 수 있어야 합니다.

오류에 이름을 붙일 수 있으면 실패는 막연한 문제가 아니라 측정하고 개선할 수 있는 연구 대상이 됩니다.

그래서 물성도 Baseline, Vocabulary, Rule Fallback, Final의 ablation 구조로 비교할 수 있도록 설계했습니다.

Slide 11. 최종 수행평가

11:25~12:35

현재 K-ART LENS를 네 가지로 구분해서 평가했습니다.

첫째, 기술 구현.

완료입니다.

4-Layer 추출,

JSON 구조화,

fallback,

FAISS 검색,

CSV 출력까지 MVP 구조를 정의했습니다.

둘째, 평가방법론.

완료입니다.

Accuracy,

Latency,

JSON validity,

Retrieval relevance,

Practitioner acceptance를 함께 평가합니다.

셋째, 성공 기준.

완료입니다.

각 KPI에 사전 threshold를 설정했습니다.

마지막으로

Raw Data 기반 최종 실측 검증.

이 부분은 검증 대기입니다.

이유는 명확합니다.

6종 Raw Data Package가 현재 최종 증빙 형태로 완비되지 않았기 때문입니다.

따라서 지금의 가장 정확한 종합판정은

[천천히]

“MVP 구현 및 평가체계 완료. 실측 증빙 패키지 검증 대기.”

입니다.

저는 이것을 미완성의 문장이라기보다 다음 연구 단계가 정확히 정의된 문장이라고 생각합니다.

Slide 12. 결론

12:35~14:35

“데모에서 실증 시스템으로”

마지막으로 처음의 작품 한 점으로 돌아가 보겠습니다.

미술관에 들어온 한 점의 작품.

사람은 작품 앞에서 질문합니다.

무엇이 그려졌는가.

어떻게 만들어졌는가.

무엇으로 만들어졌는가.

어떤 색채를 가지고 있는가.

K-ART LENS가 하려는 일은 그 사람을 없애는 것이 아닙니다.

[강조]

사람이 작품을 바라볼 때 사용하는 질문을 AI 시스템 안에 구조로 남기는 것.

그것이 이 프로젝트의 출발점이었습니다.

도상.

기법.

물성.

색채.

그리고 이 프로젝트를 진행하면서 한 가지를 더 배웠습니다.

AI에게 필요한 것은 더 많은 정답만이 아니었습니다.

그 답을 다시 확인할 수 있는 구조가 필요했습니다.

그래서 K-ART LENS의 핵심 성과를 특정 모델 하나의 높은 숫자로 정의하고 싶지 않습니다.

한국 미술을 설명 가능한 네 개의 Layer로 분해하고,

이를 유사작 검색과 연결하고,

결과를 다섯 개의 실무 지표로 평가하며,

그 성능 숫자를 다시 계산할 수 있는 Evidence Chain을 설계한 것.

저는 그것이 이번 프로젝트의 핵심이라고 생각합니다.

그리고 다음 단계는 더 그럴듯한 숫자를 만드는 일이 아닙니다.

[1초 멈춤]

모든 숫자를 다시 계산할 수 있는 증거를 남기는 일입니다.

Raw Data Package를 확보하고,

동일 로그로 독립 재계산하고,

오류분석과 신뢰구간까지 검증한 뒤,

그때 최종 PASS와 FAIL을 선언하겠습니다.

왜냐하면

[가장 천천히]

좋은 AI는 답을 잘하는 AI일 수 있습니다.

하지만

신뢰할 수 있는 AI는 그 답의 근거를 다시 추적할 수 있는 AI입니다.

그리고 미술관에서는 그 차이가 더욱 중요합니다.

우리가 기록하는 것은 단순한 이미지 파일이 아니라,

한 시대의 작품을 다음 세대로 전달하는 **기억의 구조**이기 때문입니다.

[심사위원을 바라보며]

K-ART LENS는 작품을 대신 보는 AI가 아닙니다.

사람이 작품을 더 깊이 보고, 더 정확하게 기록하고, 그 판단의 근거까지 다음 세대에 남길 수 있도록 돕는 네 개의 렌즈입니다.

이상으로 발표를 마치겠습니다.

감사합니다.

[2초 멈춤 - 고개 숙여 인사]

II. 대상 수상 수준 압박질문 30개와 모범답변

Q1. "결국 성능 측정을 한 겁니까, 안 한 겁니까?"

모범답변

두 가지를 분리해서 말씀드리겠습니다.

평가 방법과 측정 프로토콜은 설계되어 있습니다. 그러나 현재 제출 자료만으로 최종 실측 성능을 독립 검증할 수 있는 Raw Data Package가 완비되어 있지는 않습니다.

따라서 저는 92%, 12.8초 등의 값을 최종 실측 성능이라고 주장하지 않습니다.

현재 단계의 정확한 표현은

"측정 체계는 구축됐고, 최종 실증 판정은 원시 증빙 확보 후 확정한다."

입니다.

연구자로서는 숫자를 채우는 것보다 실측과 예시를 구분하는 것이 더 중요하다고 판단했습니다.

Q2. "그렇다면 결과가 없는 프로젝트 아닌가요?"

모범답변

그렇게 보실 수 있는 지점이 있다는 것을 인정합니다.

다만 이 프로젝트의 완료 범위를 구분할 필요가 있습니다.

현재 완료된 것은

기능적 MVP, 4-Layer 구조, 검색 파이프라인, 평가 프로토콜, KPI, Raw Data schema와 Evidence Chain입니다.

반면 최종 실측 성능의 PASS/FAIL은 검증 대기입니다.

따라서 "결과가 없다"기보다

"기술적 결과와 평가체계는 존재하지만, 최종 성능 주장에 필요한 증빙 단계가 남아 있다"

라고 표현하는 것이 가장 정확합니다.

Q3. "92%, 12.8초 같은 숫자를 왜 자료에 넣었습니까? 오해를 유도할 수 있지 않나요?"

모범답변

맞습니다. 그래서 가장 주의한 부분입니다.

해당 값은 **성과값이 아니라 계산 예시**입니다.

어떤 numerator와 denominator가 들어가면 어떤 방식으로 KPI가 계산되는지를 보여주기 위한 값입니다.

그래서 최종 자료에서는

Example Value와 Verified Result를 명확히 분리하고, 원자료 확보 전에는 PASS/FAIL을 확정하지 않는 원칙을 적용했습니다.

오히려 이 구분을 명시함으로써 수치 오해 가능성을 줄이고자 했습니다.

Q4. "4-Layer라는 구분은 학술적으로 검증된 표준입니까?"

모범답변

현재 자료만으로 4-Layer가 미술사 또는 박물관학의 보편적 표준이라고 주장하지는 않습니다.

K-ART LENS의 4-Layer는

도상, 기법, 물성, 색채라는 실무적으로 설명 가능한 검색·기록 축을 시스템 설계 관점에서 분리한 구조입니다.

따라서 현재 단계에서는 "보편적 미술분류 표준"이라기보다

AI 아카이빙과 검색을 위한 operational framework라고 정의하는 것이 정확합니다.

향후 실제 기관 적용 단계에서는 기존 미술관 metadata ontology와의 mapping 검증이 필요합니다.

Q5. "왜 하필 네 개입니까? 다섯 개나 여섯 개가 더 좋을 수도 있지 않습니까?"

모범답변

그 가능성을 열어두고 있습니다.

네 개가 영원한 최적값이라고 주장하지 않습니다.

현재 네 축은

무엇이 그려졌는가,

어떻게 만들어졌는가,

무엇으로 만들어졌는가,

어떤 색채 구조인가라는

서로 다른 실무 질문을 분리하기 위한 MVP 구성입니다.

향후 작가, 시대, 공간, 형태, 주제 등의 축을 추가할 수 있습니다.

따라서 4-Layer는 **단한 분류체계가 아니라 확장 가능한 기본 구조**입니다.

Q6. "CLIP 하나로 검색하면 되는데 시스템이 지나치게 복잡해진 것 아닙니까?"

모범답변

단순 검색 정확도만 목표라면 CLIP 기반 단일 임베딩이 훨씬 간결할 수 있습니다.

하지만 K-ART LENS의 목표는 nearest image 하나를 찾는 것이 아니라

"왜 유사한가"를 검색축 단위로 설명하는 것입니다.

예를 들어 전체 이미지는 덜 비슷하더라도 색채만 매우 유사하거나,

도상은 다르지만 물성이 유사할 수 있습니다.

따라서 추가 복잡성의 대가는 **검색 설명 가능성과 실무 질문 대응력**으로 얻는 구조입니다.

다만 최종적으로는 반드시 단일 임베딩 baseline과 비교실험을 해야 합니다.

Q7. "단일 임베딩 baseline보다 실제로 성능이 좋다는 증거가 있습니까?"

모범답변

현재 제출 자료만으로는 그 비교우위를 실측 결과로 주장할 수 없습니다.

따라서 "4-Layer가 더 정확하다"고 말하지 않겠습니다.

현재 주장할 수 있는 차별점은

정확도 우위가 아니라 검색속 분리와 오류분석 가능성입니다.

다음 검증에서는

단일 CLIP baseline과

4-Layer 독립 검색,

4-Layer weighted fusion을

동일 데이터셋에서 비교하는 ablation이 필요합니다.

Q8. "도상·기법·물성·색채가 정말 독립적인 Layer입니까?"

모범답변

완전히 독립적이라고 보기는 어렵습니다.

예를 들어 재료는 기법에 영향을 주고, 기법은 색채 표현에 영향을 줄 수 있습니다.

따라서 여기서 Layer라는 표현은 존재론적으로 완전한 독립을 의미한다기보다

분석과 검색을 위해 기능적으로 분리한 축을 의미합니다.

오히려 Technique-Material confusion을 오류 유형으로 별도 관리한 것도 이 두 영역의 경계가 실제로 어렵기 때문입니다.

Q9. "이미지만 보고 장치와 한지, 분채를 판별한다는 게 가능한가요?"

모범답변

완전한 확정 판별은 어렵습니다.

그래서 K-ART LENS의 Materiality 결과는 보존과학적 진단이나 감정 결과를 대체하는 것이 아닙니다.

현재 단계에서는

이미지 기반의 구조화된 1차 추정으로 보는 것이 정확합니다.

향후 정확도를 높이려면 작품 metadata, 작가 제작기록, 고해상도 촬영, 보존과학 분석정보와의 multimodal 결합이 필요합니다.

Q10. "그렇다면 Materiality라는 이름 자체가 과장된 것 아닌가요?"

모범답변

좋은 지적입니다.

그래서 실무 배포 시에는 confidence 또는 uncertainty를 함께 표시하는 것이 필요합니다.

현재 Materiality Layer는 “재료를 확정한다”기보다

시각정보에 근거해 재료 후보를 구조화하는 Layer입니다.

향후에는 predicted_material, confidence, evidence_source, needs_expert_review 같은 필드를 추가하는 것이 더 안전합니다.

Q11. “Gold Label은 누가 정답이라고 결정합니까?”

모범답변

현재 설계에서는 큐레이터가 모델 prediction을 보지 않은 상태에서 blind 방식으로 Gold Label을 작성하고,

artwork_id를 기준으로 prediction과 매칭합니다.

하지만 전문가 한 명의 판단을 절대적 진리로 간주해서는 안 됩니다.

따라서 향후에는 복수 전문가 labeling을 도입하고 전문가 간 일치도를 함께 평가해야 합니다.

도상처럼 해석적 요소가 큰 경우에는 **정답률과 함께 전문가 합의 수준 자체가 하나의 지표**가 될 수 있습니다.

Q12. “Cohen’s kappa 같은 일치도 측정을 실제로 했습니까?”

모범답변

현재 제출 자료에는 복수 전문가의 독립 labeling 결과와 kappa 통계가 포함돼 있지 않습니다.

따라서 수행했다고 주장하지 않습니다.

다음 평가 단계에서는 두 명이면 Cohen’s kappa,

세 명 이상이면 Fleiss’ kappa 등을 활용해

Gold Label 자체의 신뢰도부터 먼저 검증하는 것이 필요합니다.

Q13. “왜 평가 데이터가 100점입니까? 충분합니까?”

모범답변

현재 자료에서 100점은 평가 규모로 제시된 값이지만, 실제 gold_labels.csv가 첨부되지 않았기 때문에 최종 실측 표본으로 확정해 주장하지 않습니다.

그리고 100점이 모든 한국 미술을 대표한다고도 볼 수 없습니다.

향후에는 시대, 장르, 재료, 구상·추상, 작가군 등을 층화해

stratified test set으로 확대하는 것이 필요합니다.

Q14. “표본이 100개라면 92%라는 숫자도 신뢰구간이 꽤 넓지 않습니까?”

모범답변

맞습니다.

그래서 단일 point estimate만 제시해서는 안 됩니다.

최종 실측이 이루어지면 Accuracy와 함께 95% confidence interval을 병기하는 것이 필요합니다.

현재 보고서에서도 예시 수치에 대한 Wilson interval은 설명할 수 있지만,
그 역시 실제 원시 데이터가 확보되기 전에는 최종 성능 신뢰구간으로 주장해서는 안 됩니다.

Q15. "목표치 90%, 80%, 65%, 55%는 어떤 근거로 정한 겁니까?"

모범답변

현재 자료에서는 이 값들이 사전에 정의된 성공 기준이라는 점은 확인되지만,
외부 benchmark를 통해 통계적으로 도출된 최적 threshold라고까지 주장할 근거는 없습니다.
따라서 현재 단계에서는

프로젝트 운영을 위한 design target으로 보는 것이 정확합니다.

향후 충분한 baseline과 전문가 평가 데이터가 축적되면 이 threshold 역시 재검증되어야 합니다.

Q16. "도상 55%면 너무 낮은 것 아닙니까?"

모범답변

절대적인 수치만 보면 그렇게 느낄 수 있습니다.

하지만 도상은 특히 추상·반추상에서 정답 정의 자체가 어려운 영역입니다.

다만 55%가 충분히 좋은 기준이라고 제가 단정하지는 않습니다.

중요한 것은

첫째, Layer별 난도를 분리했다는 점,

둘째, threshold를 결과 이후 조정하지 않았다는 점입니다.

장기적으로는 exact match뿐 아니라 hierarchical label이나 semantic similarity를 병행할 필요가 있습니다.

Q17. "왜 exact match를 주지표로 사용합니까? 너무 엄격하지 않나요?"

모범답변

맞습니다. 그래서 strict exact match를 주지표로 두되 필요할 경우 Jaccard similarity 같은 보조지표를 병기하도록 설계했습니다.

Strict match의 장점은

결과 해석이 명확하고 과대평가 가능성이 낮다는 것입니다.

반면 다중 라벨이나 동의어가 많은 미술 metadata에서는 semantic similarity 또는 ontology-aware 평가를 보조적으로 사용할 필요가 있습니다.

Q18. "Top-5를 왜 0, 1, 2점으로 평가합니까?"

모범답변

Cosine similarity 값만으로는 실제 큐레이터 관점의 의미 있는 관련성을 보장할 수 없기 때문입니다.

그래서

0점 무관,

1점 약한 관련,
 2점 명확한 관련으로 평가하고,
 가장 보수적으로는 2점만 relevant로 계산합니다.
 즉

모델의 수학적 유사성과 전문가가 느끼는 실질적 관련성을 분리한 것입니다.

Q19. "Top-5 60%라는 기준도 자의적이지 않습니까?"

모범답변

현재 자료 기준으로는 운영 목표치라고 보는 것이 정확합니다.
 외부 benchmark를 통해 최적화된 보편적 기준이라고 주장하지 않습니다.
 향후에는 Precision@K, nDCG, MRR, 큐레이터 relevance score 등을 함께 사용해 검색 품질을 다면적으로 평가하는 것이 바람직합니다.

Q20. "왜 평균 latency가 아니라 P95입니까?"

모범답변

실제 서비스에서는 평균보다 느린 요청의 사용자 경험이 중요하기 때문입니다.
 평균이 5초여도 일부 사용자가 30초를 기다린다면 실무성이 떨어집니다.
 그래서 업로드부터 카드 렌더링 완료까지 End-to-End latency를 측정하고,
 95%의 요청이 어느 시간 안에 완료되는지를 보는 P95를 주지표로 선택했습니다.

Q21. "15초도 실제 서비스에서는 너무 느리지 않습니까?"

모범답변

그럴 수 있습니다.
 현재 15초는 프로젝트 단계의 성공 기준입니다.
 실제 상용 서비스 수준에서는 사용 시나리오에 따라 더 낮은 latency가 요구될 수 있습니다.
 중요한 것은 현재 시스템이
모델 inference만이 아니라 전체 사용자 경험을 End-to-End로 측정하도록 설계했다는 점입니다.
 향후 cache, batching, 모델 경량화, feature precomputation 등으로 최적화할 수 있습니다.

Q22. "JSON schema 통과율이 왜 중요한가요?"

모범답변

미술관 DB에서는 좋은 문장을 만드는 것보다 **정해진 필드에 안정적으로 적재되는 것이 더 중요할 수 있습니다.**
 필드 하나가 누락되거나 enum 외의 값이 들어오면 자동화 pipeline이 깨질 수 있습니다.
 그래서 first-pass schema pass rate를 별도 KPI로 둔 것입니다.

생성 AI를 실제 정보시스템으로 연결할 때 구조 안정성은 accuracy와 별개의 성능이라고 판단했습니다.

Q23. "Retry나 fallback을 사용하면 결국 모델 성능을 감추는 것 아닙니까?"

모범답변

그래서 first-pass와 final validity를 분리해야 합니다.

첫 출력이 바로 통과한 비율은 모델과 prompt 구조의 안정성을 보여주고,

retry 이후 final validity는 실제 서비스 복구력을 보여줍니다.

또한 fallback rate 자체도 기록해야 합니다.

즉 fallback을 숨기는 것이 아니라

fallback이 얼마나 자주 필요한지까지 성능지표로 남기는 구조입니다.

Q24. "가장 치명적인 오류는 무엇이라고 봅니까?"

모범답변

현재 설계상 가장 주의해야 할 것은 **Material Hallucination**이라고 판단합니다.

이유는 재료 정보가 미술사 연구, 보존, 소장품 관리와 연결될 경우 잘못된 단정이 실무적으로 큰 영향을 줄 수 있기 때문입니다.

그래서 Materiality는 제한 vocabulary와 fallback뿐 아니라 향후 uncertainty 표시와 human verification이 반드시 필요합니다.

Q25. "AI hallucination을 완전히 제거할 수 있습니까?"

모범답변

완전히 제거한다고 약속하는 것은 현실적이지 않습니다.

K-ART LENS의 접근은 hallucination을 없다고 주장하는 것이 아니라,

발생 위치와 유형을 기록하고 통제 가능한 상태로 만드는 것입니다.

JSON schema, 제한 vocabulary, fallback, error taxonomy, human review가 그 장치들입니다.

Q26. "이 시스템이 큐레이터를 대체할 가능성은 없습니까?"

모범답변

현재 설계는 대체보다는 **Human-in-the-Loop 지원 도구**에 가깝습니다.

Gold Label도 사람이 만들고,

검색 결과 relevance도 사람이 평가하며,

최종 DB 반영 역시 전문가 검수가 필요합니다.

AI는 반복적인 초안 생성과 후보 탐색을 빠르게 하고,

큐레이터는 해석과 검증에 집중하는 구조가 더 현실적이라고 생각합니다.

Q27. "그렇다면 실제 업무시간이 얼마나 줄어드니까?"

모범답변

현재 자료에는 실제 before/after 업무시간을 독립 검증할 수 있는 실측 결과가 없습니다.

따라서 몇 퍼센트 절감된다고 주장하지 않겠습니다.

향후 현장평가에서는 수작업 기준 소요시간과 K-ART LENS + 큐레이터 검수 시간을 동일 작품군에서 비교해

time saving과 correction burden을 함께 측정해야 합니다.

Q28. "기존 상용 VLM을 조합한 것이라면 연구적 새로움이 부족한 것 아닌가요?"

모범답변

모델 자체의 새로운 architecture를 제안한 연구는 아닙니다.

따라서 foundation model 수준의 novelty를 주장하지 않습니다.

이 프로젝트의 기여는

한국 미술 아카이빙 문제를 4-Layer로 재정의하고, Layer별 검색과 생성 결과를 실무형 평가체계 및 Evidence Chain으로 연결한 시스템 설계에 있습니다.

즉 model novelty보다 **problem formulation과 evaluation architecture**에 무게가 있습니다.

Q29. "이 프로젝트의 가장 큰 약점을 하나만 말한다면 무엇입니까?"

모범답변

가장 큰 약점은 명확합니다.

최종 성능을 독립 검증할 Raw Data Package가 아직 완비되지 않았다는 점입니다.

그래서 그 약점을 숨기지 않고 최종 수행평가 자체에 "검증 대기"로 명시했습니다.

그리고 그 약점이 다음 연구과제를 아주 분명하게 만들었습니다.

원시 데이터를 고정하고,

동일 결과를 제3자가 재계산할 수 있게 하는 것.

그 단계가 완료되어야 성능에 대한 강한 주장을 할 수 있습니다.

Q30. "그래서 이 프로젝트가 왜 대상을 받아야 합니까?"

모범답변

저는 단순히 높은 숫자를 보여주었기 때문에 이 프로젝트가 좋은 평가를 받아야 한다고 생각하지 않습니다.

K-ART LENS가 보여준 것은 세 가지입니다.

첫째,

한국 미술 작품 검색의 문제를 단일 유사도에서 **설명 가능한 4-Layer 질문 구조**로 바꿨습니다.

둘째,

Accuracy 하나가 아니라 Reliability, Structure, Retrieval, Usability까지 **실무형 AI 평가체계**로 확장했습니다.

셋째,

성과 숫자를 보여주는 데서 멈추지 않고 그 숫자를 다시 계산할 수 있는 **Evidence Chain**과 **재현성 구조**를 설계했습니다.

그리고 무엇보다 확인되지 않은 숫자는 확인됐다고 말하지 않았습니다.

저는 AI 연구에서 이것도 중요한 경쟁력이라고 생각합니다.

[마지막 한 문장]

“잘 작동해 보이는 AI”를 만드는 데서 멈추지 않고, “왜 믿어도 되는지 검증할 수 있는 AI”로 가는 경로를 설계했다는 것.

그것이 K-ART LENS의 가장 중요한 가치라고 생각합니다.

Ⅲ. 심사위원에게 절대 하지 말아야 할 답변 7가지

1. “아마 그 정도 나올 겁니다.”

금지.

대신:

“현재 자료로는 실측 확정할 수 없습니다.”

2. “AI니까 알아서 판단합니다.”

금지.

대신:

“해당 판단은 특정 Layer의 feature와 schema 제약 안에서 수행됩니다.”

3. “정확도는 거의 90% 이상입니다.”

원자료가 없다면 금지.

대신:

“90%는 목표값이며 최종 실측값과 구분하고 있습니다.”

4. “기존 방식보다 무조건 좋습니다.”

비교실험 없으면 금지.

대신:

“현재 확인된 차별점은 정확도 우위보다 설명 가능한 검색축입니다.”

5. “큐레이터 업무를 대체할 수 있습니다.”

금지.

대신:

“현재 목표는 Human-in-the-Loop 기반 업무지원입니다.”

6. 질문을 들은 뒤 바로 길게 설명하기

금지.

항상 먼저 한 문장으로 답합니다.

예:

“네. 현재 가장 큰 한계가 바로 그 부분입니다.”

그 뒤 근거를 설명합니다.

7. 모르는 것을 억지로 방어하기

가장 위험.

대신:

“현재 자료에서는 그 부분까지 검증되지 않았습니다. 다만 다음 실험에서는 이렇게 검증하겠습니다.”

이 답변은 감점용 답변이 아니라 연구자의 경계 설정 능력을 보여주는 답변입니다.

IV. 답변 공식 - 모든 압박질문을 버티는 4단계

심사위원이 어떤 질문을 하더라도 다음 순서를 유지합니다.

① 결론부터

“네. 현재 가장 큰 한계가 그 부분입니다.”

② 현재 증거

“현재 자료에서 확인할 수 있는 것은 ○○까지입니다.”

③ 주장 경계

“따라서 △△까지는 주장하지 않습니다.”

④ 다음 검증

“다음 단계에서는 □□ 방식으로 검증하겠습니다.”

이를 공식처럼 기억하십시오.

결론 - 근거 - 경계 - 다음 실험

V. 발표 직전 반드시 외울 7문장

1. “문제는 검색이 아니라 해석 단위였습니다.”
2. “4-Layer는 네 개의 특징이 아니라 네 개의 질문입니다.”
3. “우리는 검색 결과를 늘린 것이 아니라 검색할 수 있는 질문의 종류를 늘렸습니다.”
4. “평가 가능성은 결과 화면이 아니라 로그 구조에서 나옵니다.”
5. “저를 믿어달라는 시스템이 아니라 데이터를 다시 계산할 수 있는 시스템을 만들려고 했습니다.”
6. “현재의 가장 정확한 판정은 MVP와 평가체계 완료, 실측 증빙 검증 대기입니다.”
7. “좋은 AI는 답을 잘할 수 있지만, 신뢰할 수 있는 AI는 그 답의 근거를 다시 추적할 수 있어야 합니다.”

VI. 마지막 20초 - 반드시 이렇게 끝낼 것

[속도를 낮추고 심사위원을 바라본다.]

K-ART LENS는 작품을 대신 보는 AI가 아닙니다.

사람이 작품을 더 깊이 보고, 더 정확하게 기록하고, 그 판단의 근거까지 다음 세대에 남길 수 있도록 돕는 네 개의 렌즈입니다.

그리고 저는 AI가 문화의 기억을 다루기 위해서는

정확성뿐 아니라 검증 가능성과 책임성까지 설계되어야 한다고 생각합니다.

감사합니다.

[2초 정지 후 인사]