

K-ART LENS 최종 발표 스크립트

발표 15 분 + 질의응답 15 분 · 스토리텔링 구성판

발표자: 추병곤 (AIFTEL 18 기 온라인 리서처) 대응 보고서: K-ART_LENS_최종발표보고서_v2.0 (A4 49 쪽)

0. 이 스크립트를 쓰기 전에

0.1 이 발표의 전략

이 발표에는 다른 팀에 없는 약점이 하나 있다. **성능 수치가 없다.**

이걸 숨기려 하면 발표 전체가 방어적으로 변하고, 질의응답에서 반드시 무너진다. 그래서 이 스크립트는 정반대 전략을 쓴다. **약점을 발표의 클라이맥스로 만든다.**

구조는 이렇다.

구간	시간	청중의 상태
1 막 — 현장	0:00-4:00	“이 사람은 이 문제를 진짜 겪었구나”
2 막 — 해법	4:00-8:00	“구조가 영리하네”
3 막 — 전환	8:00-9:00	“어? 숫자가 없네?”
4 막 — 고백과 반전	9:00-13:30	“...아, 그래서 없는 거구나”
5 막 — 착지	13:30-15:00	“이 사람 신뢰할 수 있다”

핵심은 **3 막의 침묵**이다. 청중이 “숫자가 없다”는 걸 스스로 눈치채게 두고, 그 다음에 직접 말한다. 발표자가 먼저 변명하면 약점이 되고, 청중이 먼저 알아차린 뒤 발표자가 인정하면 **정직함**이 된다.

0.2 표기 규칙

기호	의미
[사이]	1~2 초 정지. 반드시 지킬 것. 이 발표의 설득력 절반은 침묵에 있다
[긴 사이]	3 초. 총 2 회만 등장한다. 남용하면 힘이 빠진다
[슬라이드 N]	슬라이드 전환 지점
굵게	문장의 무게중심. 여기서 속도를 늦춘다
〈개인 경험 슬롯〉	본인의 실제 경험으로 교체할 것. 지어낸 일화는 질의응답에서

0.3 리허설 3 원칙

1. **빠르게 말하지 않는다.** 15 분에 이 분량이면 분당 약 330 음절, 또박또박 읽는 속도다. 긴장하면 저절로 빨라지니 **의식적으로 느리게** 시작한다.
2. **4 막을 외운다.** 1~2 막은 슬라이드를 보며 해도 되지만, 4 막의 고백 부분은 **청중 눈을 보고** 해야 한다. 원고를 읽으면 진정성이 절반으로 준다.
3. **숫자는 딱 네 개만 외운다.** 20~40 분, 92%, 85.0~95.9, 100 건 중 100 건. 나머지는 슬라이드에 있다.

1 막 — 현장 (0:00 - 4:00)

[슬라이드 1 — 제목]

안녕하십니까. K-ART LENS 를 만든 추병곤입니다.

[사이]

오늘 발표를 작품 한 점을 등록하는 시간 이야기로 시작하겠습니다.

미술관에서 작품 한 점을 소장품 데이터베이스에 올리는 데 **20 분에서 40 분**이 걸립니다.

[사이]

이건 제가 어디서 인용한 통계가 아닙니다. **제 손이 기억하고 있는 시간**입니다.

[슬라이드 2 — 문제 정의]

저는 큐레이터입니다. 부산, 경남, 제주, 강원 의 지역 미술관과 문화재단에서 8 년쯤 일했습니다.

전시 하나를 올리면 작품이 서른 점, 많으면 여든 점입니다. 그 작품들을 한 점씩 열어서, 재료를 적고, 기법을 적고, 크기를 적고, 색을 적습니다. 순수하게 옮겨 적는 데만 열 시간에서 쉰 시간이 듭니다.

[사이]

그런데 시간보다 무서운 게 있습니다.

미술관의 기록은 틀려도 아무도 즉시 알려주지 않는다는 것입니다.

〈개인 경험 슬롯 — 예: “제가 몇 해 전에 입력한 재료 표기 하나가, 몇 년 뒤 다른 기관의 도록에 그대로 실린 걸 본 적이 있습니다.”〉

[사이]

잘못 들어간 메타데이터는 조용히 살아남습니다. 검색 결과로 남고, 도록으로 남고, 논문 각주로 남고, 나중에는 가격 산정의 근거로까지 씁니다. **처음 오기록을 만든 사람은 이미 그 미술관을 떠난 뒤인데도요.**

[슬라이드 3 — 기존 도구의 한계]

그래서 저도 다들 하시는 걸 해봤습니다. 범용 AI에 작품 사진을 넣어봤습니다.
결과는 두 가지였습니다.

첫째, **장지에 분채로 그린 한국화를 아크릴이라고 답합니다.** 서양 미술 데이터로 배운 모델에게는 그게 가장 그럴듯한 답이니까요.

둘째, 물어볼 때마다 **형식이 다릅니다.** 어떤 날은 문단으로, 어떤 날은 목록으로 답합니다. 데이터베이스 컬럼에는 한 글자도 못 넣습니다.

[사이]

그리고 이게 제일 답답한 지점인데요.

[슬라이드 4 — 검색축의 부재]

큐레이터가 실제로 하는 질문은 이런 겁니다.

“이 작품이랑 물성이 비슷한 소장품 좀 찾아줘.”

[사이]

이 질문에 답할 수 있는 검색 시스템이 지금 국내에 없습니다.

왜냐하면 메타데이터가 ‘지본채색’, ‘목조’ 같은 **글자 한 덩어리**로만 저장돼 있기 때문입니다. 데이터가 부족한 게 아닙니다. **데이터를 가를 축이 없는** 겁니다.

그래서 저는 AI를 배우러 왔습니다.

2 막 — 해법 (4:00 - 8:00)

[슬라이드 5 — 4-Layer 분해]

K-ART LENS의 발상은 단순합니다.

작품 하나를 벡터 하나로 뭉개지 않고, **작품이 만들어지는 미학적 조건 그대로 네 겹으로 쪼갭니다.**

[사이 — 손가락 네 개를 펴며]

도상 — 무엇이 그려져 있는가. **기법** — 어떻게 그려졌는가. **물성** — 무엇으로 만들어졌는가. **색채** — 어떤 색으로 이루어져 있는가.

미술사에서 작품을 읽는 순서를 그대로 가져온 겁니다. 제가 8년 동안 손으로 하던 일을, 축으로 만든 것뿐입니다.

[슬라이드 6 — 기술 구성]

층위마다 다른 방법을 씁니다.

도상은 CLIP 계열 임베딩으로, 기법은 VGG 중간층의 Gram 행렬 통계로, 색채는 HSV 히스토그램과 k-means로 뽑습니다.

그리고 여기서 **설계 하나를 강조하고** 싶습니다.

[사이]

색채와 물성 — 틀리면 가장 치명적인 두 층위에는 규칙 기반 알고리즘을 같이 물려놨습니다.

왜냐하면 미술관 입력 도구에서 **틀린 값보다 나쁜 건, 값이 없어서 공정이 멈추는 것**이기 때문입니다. 모델이 통째로 죽어도 출력이 0 이 되지는 않게 만들었습니다.

해설을 생성할 때는 JSON 스키마와 한국화 재료 목록을 프롬프트에 강제로 밀어 넣습니다. 자유롭게 쓰라고 하지 않고, **주어진 목록 안에서 고르게** 만드는 겁니다. 생성 문제를 분류 문제로 끌어내리는 거죠.

【슬라이드 7 — 시연】

시연을 보시겠습니다.

[화면 전환 — 이미지 업로드]

작품 이미지를 올립니다. 오른쪽 위에 처리 시간 타이머가 돕니다. 15 초 안에 도상·기법·물성·색채 네 장의 카드가 뜹니다.

[사이]

이제 이 발표에서 **제일 보여드리고 싶었던 화면**입니다.

['물성 유사' 토글을 켜다]

같은 작품입니다. 토글 하나 켜을 뿐인데, 추천되는 유사작 다섯 점이 통째로 바뀝니다.

[사이]

이미지가 비슷한 작품과, 물성이 비슷한 작품은 **큐레이터에게 완전히 다른 질문**입니다. 구글 렌즈는 이 둘을 구분하지 못합니다. 구분할 축 자체가 없으니까요.

마지막으로 CSV 내보내기를 누르면, 미술관 소장품 DB 컬럼 헤더와 정확히 같은 형식으로 파일이 떨어집니다. **사람이 다시 옮겨 적는 공정이 사라집니다.**

3 막 — 전환 (8:00 - 9:00)

[슬라이드 8 로 넘긴다]

자, 이제 성능을 말씀드릴 차례입니다.

[긴 사이 — 3 초. 슬라이드를 청중이 충분히 읽게 둔다]

【슬라이드 8 — 평가 결과 요약표 · 실측 칸 전부 공란】

보시는 대로입니다.

[사이]

여덟 칸이 전부 비어 있습니다.

[사이]

실수가 아닙니다. 파일이 잘못 올라간 것도 아닙니다.

저는 오늘 성능 수치를 하나도 가져오지 않았습니다.

지금부터 5 분 동안, 왜 그랬는지 말씀드리겠습니다.

4 막 — 고백과 반전 (9:00 - 13:30)

[여기서부터 원고를 보지 않는다. 청중을 본다.]

4-1. 제가 쓸 수 있었던 문장 (9:00 - 10:00)

지난주에 저는 이런 문장을 쓸 수 있었습니다.

[슬라이드 9 — 문장 하나만 크게]

“큐레이터 골드셋 100 점 기준, 색채 일치율 92%를 달성했습니다.”

[사이]

이 문장을 썼다면 오늘 이 자리는 훨씬 편했을 겁니다. 아무도 검증하지 않았을 거고요. 슬라이드에 92 라는 숫자가 있으면, 사람은 그걸 읽고 넘어갑니다.

[사이]

그런데 저는 이 문장을 지웠습니다. 이유가 두 가지입니다.

4-2. 첫 번째 이유 — 로그가 없었다 (10:00 - 10:40)

첫째, 그 92%를 뒷받침할 원본 파일이 제 컴퓨터에 없었습니다.

골드셋 원본도, 모델 출력 로그도, 처리시간 로그도 없었습니다. 제가 기억하는 감각과, 몇 번 돌려본 인상이 있었을 뿐입니다.

[사이]

산업 현장에서 성능 수치는 감사 대상입니다. 감사에 통과하지 못하는 숫자는 자산이 아니라 부채입니다.

그리고 앞서 말씀드렸듯이, 미술관은 잘못된 기록의 회수 비용이 비대칭적으로 큰 도메인입니다. 저는 그 기록을 만드는 도구를 만들고 있습니다. 그렇다면 이 도구의 성능을 말하는 방식도, 그 기록만큼 오래 견뎌야 한다고 생각했습니다.

4-3. 두 번째 이유 — 92%는 애초에 달성이 아니었다 (10:40 - 12:00)

그런데 두 번째 이유가 더 중요합니다.

[사이]

제가 그 92%를 정직하게 로그까지 갖춰서 측정했다고 가정해 보겠습니다. 목표는 90%였습니다. 92 는 90 보다 큼니다. 그러니 달성이겠죠.

[사이]

아닙니다.

[슬라이드 10 — 92/100 의 신뢰구간]

100 건 중 92 건이 맞았을 때, 이 비율의 95% 신뢰구간은 **85.0%에서 95.9%**입니다.

목표치 90%가 이 구간 안에 들어 있습니다.

[사이]

무슨 뜻이냐면, 표본을 다시 뽑으면 87%가 나올 수도, 94%가 나올 수도 있다는 겁니다. 92 라는 숫자는 **참값이 90** 을 넘는지 아닌지를 판정할 힘이 없습니다.

정직한 판정은 '달성'이 아니라 '**보류**' 입니다.

[사이]

그래서 저는 계산을 해봤습니다. 표본 150 점에서 색채 지표를 '달성'이라고 말하려면 몇 퍼센트가 나와야 하는가.

95.3%입니다. 목표는 90%인데, 합격선은 95.3%입니다.

[사이]

목표 기준과 합격선은 다른 숫자입니다. 저는 이걸 모른 채 발표장에 설 뻔했습니다.

4-4. 결정타 — 만점을 받아도 주장할 수 없는 지표 (12:00 - 12:40)

하나만 더 말씀드리겠습니다.

[슬라이드 11 — JSON 지표]

JSON 스키마 1 차 통과율. 목표는 95%였습니다. 표본 100 건으로 재기로 했었습니다.

[사이]

계산해 보니 **100 건 중 100 건이 전부 통과해도 '달성'이라고 말할 수 없습니다.**

[긴 사이 — 3 초]

만점을 받아도 주장할 수 없는 지표를, 저는 8 개 지표 중 하나로 넣어두고 있었던 겁니다.

100%로 주장하려면 표본이 109 건, 99%면 200 건, 98%면 350 건이 필요합니다.

[사이]

그런데 여기서 **좋은 소식**이 하나 있습니다. 스키마 검증하고 처리시간 재는 건 **큐레이터 인건비가 한 푼도 안 듭니다.** 배치로 돌려놓으면 되니까요.

그래서 원칙을 세웠습니다. **비싼 지표는 표본을 아끼고, 공짜인 지표는 표본을 키운다.** 이 두 로그의 목표 표본을 300 건으로 올렸습니다.

4-5. 제가 삭제한 문장 (12:40 - 13:30)

마지막으로, 제가 지운 문장을 하나 더 공개하겠습니다.

[슬라이드 12 — 삭제선 그은 문장]

“제한 어휘를 적용해 물성 정확도를 10%p 이상 끌어올렸습니다.”

[사이]

이건 제 프로젝트에서 **가장 듣기 좋은 문장**이었습니다. 문제를 발견하고, 개입하고, 개선했다는 서사가 완결되니까요.

[사이]

그런데 인과를 주장하려면 대조군이 필요합니다. **저에게는 적용 전 로그가 없었습니다.** 그러니까 저 문장은, 제가 그랬으면 좋겠다고 믿은 것이지 측정한 게 아니었습니다.

지웠습니다. 그리고 그 자리에 **적용 전후 A/B 절제 실험 설계**를 넣었습니다. 같은 골드셋에 두 번 돌려서, 대응표본 검정으로 개선폭의 신뢰구간을 냅니다.

[사이]

개선했다는 이야기 대신, 개선을 증명하는 방법을 가져왔습니다.

5 막 — 착지 (13:30 - 15:00)

[슬라이드 13 — 무엇을 만들었는가]

그래서 저는 지난 2 주 동안 두 가지를 만들었습니다.

하나는 **동작하는 파이프라인**입니다. 방금 보신 그 화면입니다.

다른 하나는 **평가 프로토콜**입니다. 지표 여덟 개의 측정식, 표본 수 산정 근거, 채점 규칙, 판정 규칙, 원시 로그 아홉 종의 규격을 전부 사전에 못 박았습니다.

[사이]

그리고 여기에 하나를 더 붙였습니다.

[슬라이드 14 — `compute_metrics.py`]

판정 규칙을 코드로 고정한 채점 스크립트를 함께 제출합니다.

자체 검증 21 항목을 통과했고, 외부 라이브러리 없이 파이썬만 있으면 돌아갑니다.

[사이]

이 스크립트의 제일 중요한 사양은 성능이 아닙니다.

데이터가 없으면, 오류를 내지도 않고 **0**을 출력하지도 않고, 빈칸을 그대로 출력한다는 겁니다.

[사이]

다시 말해, 지금 이걸 실행하면 여러분이 조금 전에 보신 그 빈칸 표가 그대로 나옵니다.

그 여덟 개의 빈칸은 제가 겸손해서 비워둔 게 아닙니다. 도구가 산출한 결과입니다.

[슬라이드 15 — 다음 단계]

앞으로 14 일, 약 95 시간짜리 계획을 세워렸습니다. 그중 30 시간이 골드셋 라벨링입니다. 가장 비싸고, 가장 미룰 수 없는 작업입니다.

그게 끝나면 저 여덟 칸이 채워지고, 이 보고서는 v3.0 이 됩니다.

그다음은 K-VALUE 입니다. 여기서 만든 4-Layer 태그를 입력 피처로 써서, 유찰 데이터의 관측 편향을 보정하는 미술품 가치평가 모델로 갑니다.

[사이]

그래서 지금 신뢰구간을 고집하는 게 결벽이 아닙니다. 여기서 **젠 측정 오차가 그대로 가격 추정의 편향으로 넘어가기 때문**입니다. 층위별 오차를 알아야, 다음 모델에서 그걸 사전 정보로 넣을 수 있습니다.

[슬라이드 16 — 마무리]

마무리하겠습니다.

[사이]

저는 오늘 성능을 가져오지 못했습니다.

대신 **성능을 주장할 자격**을 가져왔습니다.

[긴 사이]

미술관의 기록은 한번 잘못 들어가면 사람보다 오래 남습니다.

저는 그 기록을 만드는 도구를 만들고 있습니다.

그렇다면 그 도구의 성능을 말하는 방식도, 사람보다 오래 견딜 만큼 정확해야 한다고 생각했습니다.

[사이]

감사합니다.

발표 구간별 시간 점검표

구간	누적	슬라이드	이 구간에서 반드시 전달할 것
1 막 현장	4:00	1-4	이 사람은 이 문제의 당사자 다
2 막 해법	8:00	5-7	4 축 분해는 미술사의 방법을 그대로 옮긴 것
3 막 전환	9:00	8	여덟 칸이 비어 있다 (침묵으로 전달)
4 막 고백	13:30	9-12	92%는 달성이 아니다 / 만점도 부족하다 / 나는 내 최고의 문장을 지웠다
5 막 착지	15:00	13-16	빈칸은 도구의 산출물이다

초과 시 잘라낼 순서: ① 2 막의 기술 구성 세부(슬라이드 6 후반) → ② 5 막의 K-VALUE 문단 → ③ 1 막의 개인 경험 슬롯. **4 막은 어떤 경우에도 줄이지 않는다.** 이 발표의 존재 이유다.

분량 설계 근거 — 왜 15 분을 꼭 채우지 않았는가

이 스크립트의 순수 대사량은 약 **3,100 음절**, 분당 **330 음절** 기준 **9~10** 분이다. 여기에 다음이 더해진다.

항목	소요
대사	9:30
[사이] 25 회 + [긴 사이] 2 회	0:50
시연 실연 (업로드 → 카드 렌더링 → 토글 → CSV)	1:30
슬라이드 전환·호흡·청중 반응	1:00
합계	약 12:50

15 분 슬롯에 **2 분** 남기는 설계다. 의도적이다.

발표자는 예외 없이 초과한다. 긴장하면 말이 빨라지지만, 동시에 계획에 없던 부연을 붙이게 되고 시연은 반드시 예상보다 오래 걸린다. **여유 2 분이 없으면 5 막이 잘리는데, 5 막이 잘리면 이 발표는 “숫자 없는 발표”로 끝난다.**

반대로 시간이 남으면 4 막의 92% 대목에서 한 박자 더 쉬면 된다. 남는 시간은 침묵에 쓴다.

질의응답 15 분 대응

Q0. 질의응답의 기본 자세

발표에서 약점을 먼저 공개했기 때문에, 질의응답의 성격이 달라진다. 보통은 **약점을 찾는 시간**인데, 이 발표 뒤에는 **약점을 이미 아는 사람이 그 판단을 시험하는 시간**이 된다. 훨씬 유리한 위치다. 단, 세 가지를 지켜야 유지된다.

원칙 1 — 먼저 인정하고, 그다음에 설명한다. “맞습니다. 그건 아직 안 했습니다. 대신…” 순서를 지킨다. 설명을 앞세우면 변명으로 들린다.

원칙 2 — 모르는 건 모른다고 한다. 오늘 발표의 자산은 정직함 하나다. 질의응답에서 한 번만 얼버무려도 15 분 동안 쌓은 걸 다 잃는다. **“측정하지 않아서 모릅니다”**는 이 발표에서 가장 강한 대답이다.

원칙 3 — 추측 수치를 절대 말하지 않는다. “대략 몇 % 정도 나올 것 같아요?”는 이 발표에 대한 가장 치명적인 함정이다. 여기서 숫자를 말하는 순간, 발표 전체가 무너진다. 대응은 Q11 참조.

답변 길이: 기본 30~45 초. 세 문장 구조로 간다. **결론 → 근거 → 다음 행동.** 길게 말할수록 불안해 보인다.

A. 정면 공격형 질문

Q1. “결국 성능 수치가 하나도 없다는 거죠? 그럼 이 프로젝트는 실패 아닌가요?”

성능 검증은 아직 실패도 성공도 아닙니다. **시작하지 않았습니니다.**

제가 2 주 동안 완료한 건 두 가지입니다. 동작하는 파이프라인과, 성능을 판정할 프로토콜입니다. 수치가 없는 건 세 번째 단계를 아직 안 했기 때문이고, 그 단계는 95 시간짜리 계획으로 산정해 뒀습니다.

다만 이걸 말씀드리고 싶습니다. 수치는 있는데 로그가 없는 상태가, 수치가 없는 상태보다 나쁩니다. 재현 불가능한 숫자 하나는 재현 가능한 빈칸 여덟 개보다 프로젝트 신뢰도를 훨씬 크게 깎습니다.

Q2. “다른 팀은 다 숫자를 냈는데요.”

알고 있습니다. 그리고 그 선택이 틀렸다고 말할 생각은 없습니다.

[사이]

다만 제가 만드는 게 미술관 소장품 DB에 들어가는 데이터라, 저는 그 숫자를 나중에 감사받는 쪽에 서게 됩니다. 제가 그 자리에서 로그를 못 내놓으면 그건 제 책임입니다. 저는 오늘 좋은 발표보다 나중에 방어 가능한 발표를 택했습니다.

Q3. “2 주 안에 골드셋 150 점을 못 만든 건 그냥 시간 관리 실패 아닌가요?”

절반은 맞습니다. 라벨링 공수를 처음에 과소평가했습니다.

나머지 절반은 다릅니다. 초기 계획의 '골드셋 100 점'은 근거 없이 정한 숫자였습니다. 정밀도를 역산해 보니 도상 지표는 $N=100$ 에서 신뢰구간 반폭이 $\pm 10\%p$ 라 판정 자체가 안 됩니다.

그러니까 제가 만약 100 점으로 밀어붙였어도 판정 불가능한 결과가 나왔을 겁니다. 표본 설계를 먼저 했기 때문에 지금 150이라는 숫자를 말할 수 있는 겁니다.

Q4. “그냥 있는 걸로 대충 돌려서 숫자 내면 되잖아요.”

돌릴 수는 있습니다. 그런데 그 숫자가 무엇에 대한 숫자인지를 제가 설명할 수 없습니다.

'일치'의 정의가 없으면 같은 로그로 전혀 다른 수치가 나옵니다. 예를 들어 골드라벨이 '장치에 분채'이고 모델이 '장치에 분채, 부분 금박'이라고 답했을 때, 이걸 일치로 볼지 말지에 따라 물성 정확도가 10%p 넘게 움직입니다.

채점 규칙을 먼저 못 박지 않으면, 나중에 결과를 보고 규칙을 고르게 됩니다. 그건 측정이 아니라 조정입니다.

B. 방법론 검증형 질문

Q5. “MVP 인데 Wilson 신뢰구간에 Bonferroni 보정까지, 과한 것 아닌가요?”

과해 보일 수 있는데, 실제로 계산해 보니 과하지 않았습니다.

지표가 8 개입니다. 각각을 유의수준 5%로 보면, 아무 성능이 없어도 최소 하나가 우연히 통과할 확률이 34%입니다. 세 번에 한 번은 운으로 성공 발표가 나온다는 뜻입니다.

그래서 1 차 종점 3 개만 남기고 보정했습니다. 모든 걸 주장하려다 아무것도 주장 못 하게 되는 걸 막으려는 겁니다.

Q6. “골드셋을 본인이 만들면 자기평가 아닌가요?”

정확한 지적이고, 제 프로젝트의 가장 큰 구조적 약점입니다.

제가 개발자이면서 큐레이터라, 제가 만든 정답으로 제 모델을 채점하게 됩니다.

그래서 세 가지를 걸었습니다. 라벨러를 **2 인 이상**으로 하고, 전체의 **30%를 이중 라벨링**하고, **Krippendorff 알파**를 반드시 **함께** 보고합니다. 알파가 0.667 아래면 지침을 고쳐서 다시 라벨링합니다.

그리고 결과표에 모델 정확도 옆에 **인간 라벨러끼리의 일치율**을 나란히 씁니다. 도상에서 모델이 55%인데 인간끼리도 60%라면, 그건 모델이 못하는 게 아니라 그 **충위가 원래 어려운 것**입니다. 해석이 완전히 달라집니다.

Q7. “N=150 도 부족하다면서 왜 150 으로 정했나요?”

타협점입니다. 그리고 타협했다는 사실을 보고서에 적어뒀습니다.

$\pm 5\%p$ 정밀도를 원하면 도상 지표에만 381 점이 필요합니다. 라벨링 공수로 환산하면 2 주짜리 프로젝트에서 불가능합니다.

150 은 도상 반폭이 $\pm 8\%p$ 로 떨어지는 지점이고, 30 시간이면 가능한 규모입니다. **부족한 걸 알면서 고른 숫자라, 결과표에 그 한계를 같이 적을 겁니다.**

Q8. “4 개 레이어로 나눈 게 정말 효과가 있다는 근거는요?”

지금은 구조적 근거만 있고 실측 근거는 없습니다.

구조적으로는 명확합니다. 단일 임베딩은 왜 비슷하다고 판단했는지 분해할 수 없어서, 틀렸을 때 개선 방향이 안 나옵니다. 4 층은 어느 층에서 틀렸는지 귀속됩니다.

실측 근거는 절제 실험으로 만듭니다. **단일 통합 임베딩 대비 4 층 분리의 검색 품질을 같은 질의로 비교**하도록 설계해 뒀습니다. 그 결과가 나오기 전까지는 “구조가 다르다”까지만 말하고 “더 낫다”고는 말하지 않습니다.

Q9. “실무자 5 명 설문은 왜 넣었나요? 판정도 안 한다면서요.”

판정에는 쓸 수 없습니다. $n=5$ 의 95% 신뢰구간이 약 ± 1.0 점이라, 평균 3.8 이 나와도 참값은 2.8 에서 4.8 사이입니다. 3.5 기준을 못 가릅니다.

그래도 남겨둔 건 **평균이 아니라 코멘트 때문**입니다. “이건 쓸 만한데 저건 못 쓰겠다”는 문장 하나가 다음 개선 항목을 정해줍니다.

그래서 평균 대신 **개별 점수 5 개와 코멘트 원문을 전부 공개**하는 방식으로 바꿨습니다. 정량 지표에서 정성 신호로 성격을 바꾼 겁니다.

C. 실무·확장형 질문

Q10. “GPT-4V 같은 모델에 프롬프트만 잘 쓰면 되는 것 아닌가요?”

그게 정확히 제 베이스라인입니다. 그리고 아직 비교 측정을 안 했으니 우위를 주장하지 않겠습니다.

다만 제가 겪은 두 가지 문제는 프롬프트로 해결이 안 났습니다. 하나는 한국 재료를 서양 재료로 답하는 것, 다른 하나는 **호출할 때마다 형식이 달라져서 DB 에 못 넣는 것**입니다.

그래서 스키마와 제한 어휘를 강제하고, 실패하면 규칙 기반으로 떨어지게 만들었습니다. **정확도보다 출력 분산을 잡는 게 목적**이었습니다.

비교는 절제 실험 A1(자유 생성) 대 A3(스키마+제한 어휘)로 설계해 뒀습니다.

Q11. ★합정 질문★ “그래서 대충 몇 퍼센트 정도 나올 것 같으세요?”

[웃으며] 그 질문에는 답하지 않겠습니다.

[사이]

제가 여기서 숫자를 말하면, 그게 회의록에 남고 기대치가 됩니다. 그리고 나중에 실측이 그보다 낮게 나오면 저는 두 가지 유혹을 받게 됩니다. **채점 규칙을 느슨하게 바꾸거나, 표본을 골라 담거나.**

오늘 제 발표의 요지가 정확히 그 유혹을 차단하는 거였습니다. 그래서 답을 드리지 않는 게 답입니다.

다만 계산으로 말씀드릴 수 있는 건 있습니다. 색채가 '달성'으로 판정되려면 **95.3% 이상**이 나와야 합니다. 그 선이 어디인지는 이미 정해졌습니다.

Q12. “이거 실제로 언제 미술관에서 쓸 수 있나요?”

지금은 **초안 생성기**로만 쓸 수 있습니다. 사람이 검수하는 걸 전제로요.

검수 없이 자동 적재하려면 물성 정확도가 판정 기준을 통과해야 하는데, 그건 14 일 뒤에 답이 나옵니다.

그리고 하나 덧붙이면, **전 계열에서 통과해도 전체 자동화는 권하지 않을 겁니다.** 서브그룹 분석에서 특정 재료 계열 성능이 떨어지면, 그 계열은 검수 필수로 남기는 식의 부분 자동화가 맞다고 봅니다.

Q13. “K-VALUE 도 데이터 없으면 결국 같은 문제 아닌가요?”

같은 문제가 맞고, 그게 제가 지금 이걸 하는 이유입니다.

K-VALUE 는 4-Layer 태그를 입력 피쳐로 씁니다. 그러면 이 단계의 **측정 오차가 그대로 가격 추정 편향으로 전파**됩니다. 태그가 얼마나 부정확한지 모르는 채로 가격 모델을 세우면, 그 모델의 불확실성을 아예 계산할 수 없습니다.

층위별 신뢰구간을 지금 확보해 두면, 다음 단계에서 그걸 **피쳐 노이즈의 사전 정보**로 넣을 수 있습니다. 지금 신뢰구간을 고집하는 실용적인 이유가 여기 있습니다.

Q14. “폴백이 있으면 항상 결과가 나온다는 건가요?”

그렇게 의도했지만, 아직 검증하지 않았습니다.

장애 주입 시험을 안 했습니다. 5 개 장애 유형에 각 20 회씩 넣어서 폴백 진입률을 보는 계획을 세워졌습니다.

그 전까지는 “차단했다”가 아니라 “**차단하도록 설계했다**” 로 말합니다. 오늘 발표 내내 지킨 규칙과 같습니다.

Q15. “공수가 부족하면 뭘 먼저 포기하실 건가요?”

우선순위표를 만들어 뒀습니다. 원칙은 **비용 대비 주장 가치가 낮은 것부터 버린다**입니다.

절대 안 버리는 게 세 개입니다. 골드셋 100 점 이상, 처리시간 로그, 스키마 로그. 뒤의 둘은 인건비가 0 이라 버릴 이유가 없습니다.

가장 먼저 버릴 건 **실무자 설문**입니다. 공수는 드는데 판정 기여가 없습니다.

그리고 절제 실험을 못 하면, **물성 개선 주장을 아예 삭제**합니다. 축소가 아니라 삭제입니다.

답변 중 절대 하지 말 것

금지	이유	대체
추측 수치 말하기 (“한 90% 정도는…”)	발표 전체 논지가 무너진다	“측정하지 않아서 모릅니다”
“그건 시간이 없어서요”로 끝내기	변명으로 들린다	“못 했습니다. 대신 이걸 했고, 언제까지 합니다”
질문자 지적을 부정하기	이 발표의 자산은 정직함뿐이다	“맞습니다. 그건 제 약점입니다”
보고서 쪽수로 도망가기	답을 못 하는 걸로 보인다	한 문장으로 답하고 “자세한 건 §4.6에 있습니다”
다른 팀과 비교해 방어하기	옹졸해 보인다	내 기준만 설명한다
길게 말하기	불안해 보인다	세 문장 안에 끝낸다

외워둘 숫자 여섯 개

숫자	맥락
20~40 분	작품 1 점 수기 등록 시간
92% → 85.0~95.9	그렇듯한 점추정의 신뢰구간
95.3%	N=150에서 색채 '달성'의 실제 합격선
100 건 중 100 건	JSON 지표가 만점으로도 판정 불가한 사실
34%	8 개 지표 무보정 시 우연 통과 확률
95 시간 / 30 시간	전체 잔여 공수 / 그중 골드셋 라벨링

최후의 한 문장

질의응답이 어떻게 흘러가든, 마지막에 한 번은 이 말을 꼭아 넣는다.

“저는 오늘 성능 대신, 성능을 주장할 자격을 가져왔습니다.”

발표 직전 체크리스트

- 슬라이드 8(빈칸 표)에서 **3 초 침묵** — 이것만은 반드시
- 4 막은 원고 안 보고 청중 보며 진행

- ☐ 〈개인 경험 슬롯〉을 **실제 경험**으로 교체 완료
- ☐ 시연 영상/화면 사전 테스트 (라이브 실패 대비 녹화본 준비)
- ☐ 발표 첫 2 분 의식적으로 느리게
- ☐ 숫자 여섯 개 암기 확인
- ☐ `compute_metrics.py --selftest` 화면 캡처 준비 (Q1·Q4 대비 실물 증거)