

K-ART LENS 최종 발표 보고서 v2.0

한국 미술 작품 4-Layer 자동 해설 및 유사작 검색 엔진 — 평가 프로토콜 확정본

항목	내용
프로젝트명	K-ART LENS (Korean ART Layered ENgine for Search)
작성자	추병곤 (AIFFEEL 18 기 온라인 리서처)
문서 판본	v2.0 — 평가 프로토콜 확정 / 실측값 미기입
선행 판본	v1.0 K-ART_LENS_최종발표자료.pdf, v1.5 K-ART_LENS_최종발표보고서_보완본.pdf
감수 관점	AI/Data Senior Researcher (평가 방법론·주장 강도·재현성 감수)
문서 상태	E1 (설계 확정) — 실측 데이터 미확보
작성일	2026-08-19

목차

0. 문서 요약 (Executive Summary)

- 0.1 한 문단 요약
- 0.2 v1.0 → v2.0 변경 요지
- 0.3 심사자를 위한 안내 — 이 보고서가 숫자를 비워둔 이유
- 0.4 판본 관리 및 승급 조건

1. 주장 강도 관리 원칙 (Claim Strength Policy)

- 1.1 증거 등급 정의
- 1.2 등급별 서술어 사전 — 발표 대본에도 동일 적용
- 1.3 전체 문서 주장 감사표 (Claim Audit)
- 1.4 발표 시 금지 표현 목록

2. 문제 정의 및 개발 배경

- 2.1 현장 병목의 구조
- 2.2 베이스라인 수치의 근거 상태 — 감사 항목 #1
- 2.3 기존 범용 AI 대비 결손 지점
- 2.4 설계 목표(Design Goal)와 비목표(Non-goal)

3. 시스템 아키텍처 및 계층 설계

- 3.1 4-Layer 분해의 근거
- 3.2 레이어별 기술 사양

- 3.3 Fail-safe 설계와 검증 방법 — 감사 항목 #8
- 3.4 구조화 출력 제어
- 3.5 검색 계층 — 4-Index 가중합
- 3.6 파이프라인 및 계측 지점 (Instrumentation Point)
- 3.7 재현성 고정 항목 (Reproducibility Lock)

4. 평가 설계 (Evaluation Protocol)

- 4.1 평가 철학
- 4.2 구성 타당도 매핑 (Construct Validity)
- 4.3 1차 / 2차 종점 사전 지정
- 4.4 골드셋 설계
- 4.5 채점 규칙 (Matching Rule) — “일치”의 정의
- 4.6 판정 규칙 (Decision Rule) — 달성 / 미달 / 보류의 통계적 정의
- 4.7 지연시간 측정 프로토콜
- 4.8 JSON 스키마 안정성 프로토콜
- 4.9 검색 품질 평가 프로토콜
- 4.10 실무 수용성 평가 프로토콜
- 4.11 서브그룹 및 편향 분석
- 4.12 절제 실험 (Ablation) — 감사 항목 #7 검증 설계
- 4.13 오류 분석 분류 체계
- 4.14 사전등록 및 데이터 잠금 절차

5. [발표용 슬라이드 삽입 1] 평가 결과 요약

- 5.1 결과표 (실측값 미기입 — 원시 데이터 확보 후 입력)
- 5.2 함께 제시할 인간 상한 대조표
- 5.3 발표 멘트 (슬라이드 1)

6. [발표용 슬라이드 삽입 2] 측정식 및 결과 입력 형식

- 6.1 주 산식
- 6.2 보조 산식 (판정·불확실성용)
- 6.3 Top-5 관련도 척도 및 산출 기준
- 6.4 수치 표기 규칙

7. 원시 데이터 및 로그 스키마 (Data Contract)

- 7.1 파일 목록 및 책임
- 7.2 gold_labels.csv
- 7.3 predictions.jsonl
- 7.4 latency_log.csv
- 7.5 schema_validation_log.csv
- 7.6 top5_relevance_eval.csv
- 7.7 practitioner_survey.csv
- 7.8 추가 파일 3 종
- 7.9 저장소 구조 및 무결성
- 7.10 데이터 거버넌스

8. 기존 문구 수정 대조표 (전면판)

- 8.1 평가 방법 관련 (보완안 반영)
- 8.2 추가 발견 항목 (본 보고서에서 신규 지적)

9. 차별점 및 비교 평가 설계

- 9.1 4 축 분리의 구조적 이점

9.2 공정 비교 조건 (현재 미 실시)

10. 한계 및 타당도 위협 (Threats to Validity)

10.1 구성 타당도 (Construct Validity)

10.2 내적 타당도 (Internal Validity)

10.3 외적 타당도 (External Validity)

10.4 통계적 결론 타당도 (Statistical Conclusion Validity)

10.5 인정하는 한계 (발표에서 먼저 말할 것)

11. 회고(KPT) 및 향후 계획

11.1 KPT — 주장 강도 조정판

11.2 Future Work

12. 실행 계획 — 데이터 확보 스프린트 (D+0 ~ D+14)

12.1 공수 부족 시 축소 우선순위

13. 최종 결론 문구 템플릿

부록

부록 A. 4-Layer JSON 스키마 초안 (v0.1)

부록 B. 물성 제약 어휘 — 초안 및 확정 절차

부록 C. 라벨링 지침 요약

부록 D. 채점 스크립트 (compute_metrics.py) — 본 보고서와 함께 제출

부록 E. 예상 질의응답 10 선

부록 F. 제출 전 체크리스트

부록 G. 용어 정리

부록 H. 참고 자료

0. 문서 요약 (Executive Summary)

0.1 한 문단 요약

K-ART LENS는 한국 미술 작품 이미지 1 장을 입력받아 **도상(Iconography) · 기법(Technique) · 물성(Materiality) · 색채(Color)** 4 개 층위로 구조화된 메타데이터와 한국어 해설, 유사작 Top-5 를 15 초 이내에 산출하는 것을 목표로 설계된 MVP 다. 본 v2.0 판본은 **모델 성능을 주장하는 문서가 아니라, 성능을 주장할 자격을 갖추기 위한 평가 프로토콜을 확정하는 문서다**. 4-Layer 라벨 일치율, P95 처리시간, JSON 스키마 1 차 통과율, 유사작 검색 품질, 실무 수용성 — 5 개 축 8 개 지표에 대해 측정식·표본 설계·채점 규칙·판정 규칙·원시 로그 스키마를 사전 확정했으며, 실측값 칸은 **의도적으로 공란으로 남겨 두었다**.

0.2 v1.0 → v2.0 변경 요지

구분	v1.0 (기존 발표자료)	v2.0 (본 판본)
결과 서술	“측정했습니다”, “검증했습니다” (완료형 단정)	“측정하도록 설계했습니다” (설계 확정형)
표본 수	“골드셋 100 점” (근거 미제시)	목표 정밀도 역산으로 N 산정, N=100 의 한계 명시

구분	v1.0 (기존 발표자료)	v2.0 (본 판본)
판정 기준	점추정 vs 목표치 단순 비교	Wilson 95% 신뢰구간 기반 3 분 판정(달성/미달/보류)
지표 위계	8 개 지표 동일 취급	1 차 종점 3 개 / 2 차 종점 5 개 분리, 다중비교 보정 명시
일치의 정의	미정의	정규화 규칙·동의어 사전·부분점수·micro/macro 명시
물성 +10%p 주장	근거 없이 서술	절제 실험(Ablation) 설계로 이관 , 현재는 미검증 표기
20~40 분 베이스라인	사실처럼 서술	출처 미확보 항목으로 분류, 검증 설계 제시
원시 데이터	언급 없음	9 종 데이터 계약 (Data Contract) + 재현성 패키지 규정
실무자 n=5	“검증했습니다”	통계적 판정 불가임을 명시, 기술통계·정성코딩으로 한정
결과 산출 방식	수기 계산·수기 기입	실행 가능한 채점 스크립트 compute_metrics.py 동봉 (자체 검증 21 항목 통과, 외부 의존성 없음)
합격선	목표치만 제시	목표치와 별도로 ‘달성’ 판정 최소 관측 건수를 표본 규모별로 사전 산출(\$4.6.1)

0.3 심사자를 위한 안내 — 이 보고서가 숫자를 비워둔 이유

발표 심사에서 가장 먼저 나올 질문은 “왜 성능 수치가 없는가”일 것이다. 답은 다음과 같다.

1. 수치는 있으나 근거 로그가 없는 상태가 가장 위험하다. 재현 불가능한 수치 1 개는 재현 가능한 공란 8 개보다 프로젝트 신뢰도를 크게 훼손한다. 산업 현장에서 성능 수치는 감사(audit) 대상이며, 감사에 통과하지 못하는 수치는 자산이 아니라 부채다.
2. 본 프로젝트의 도메인(미술관 소장품 DB)은 오기록의 회복 비용이 비대칭적으로 크다. 잘못 적재된 메타데이터는 이후 모든 검색·전시기획·가치평가 파이프라인에 전파된다. 따라서 “정확도가 높다”보다 “정확도를 어떻게 잴 것인가”를 먼저 고정하는 것이 도메인 합리적이다.

3. 평가 설계의 사전 확정(pre-registration)은 그 자체가 방법론적 기여다. 데이터를 본 뒤에 기준을 정하면 결과에 맞춰 기준이 이동한다. 본 보고서는 기준을 먼저 못 박고 데이터를 나중에 채우는 순서를 택했다.

0.4 판본 관리 및 승급 조건

판본	상태	승급 조건
v2.0 (현재)	평가 프로토콜 확정	—
v2.1	파일럿 결과 반영	골드셋 20 점 이중 라벨링 완료, 라벨러 간 신뢰도 α 산출 (채점 스크립트 검증은 v2.0 에서 완료 — 부록 D)
v3.0	본 실험 결과 반영	골드셋 $N \geq 150$ 확정·동결, 9 종 로그 전량 확보, 판정 규칙 적용 완료
v3.1	외부 검증 반영	제 3 자 재현 실행 1 회 이상, 서브그룹 분석 포함

1. 주장 강도 관리 원칙 (Claim Strength Policy)

본 절은 이 보고서 전체에 우선하는 최상위 규칙이다. 이후 모든 서술은 이 등급 체계를 따른다.

1.1 증거 등급 정의

등급	명칭	정의	허용되는 표현
E0	미근거	출처·로그·실험 없음. 통념 또는 추정	“추정합니다”, “가정합니다”, “확인이 필요합니다”
E1	설계 확정	측정 방법·기준·절차가 문서로 고정됨. 실측 없음	“설계했습니다”, “기준으로 설정했습니다”, “측정하도록 규정했습니다”
E2	파일럿 근거	소표본($N < 30$) 실측 존재. 신뢰구간 넓음	“예비 관측에서는 ~로 나타났습니다 ($N = __$, 잠정)”
E3	본실험 근거	사전등록 표본 실측 + 로그 +	“측정 결과 ~ 였습니다(95%)”

등급	명칭	정의	허용되는 표현
		신뢰구간 확보	CI ~)", “ 검증했습니다”

본 v2.0 문서에서 E3 등급 주장은 0 건이다. 모든 성능 관련 서술은 E1 로 하향 조정되었다.

1.2 등급별 서술어 사전 — 발표 대본에도 동일 적용

금지 표현 (v1.0 에서 사용됨)	대체 표현 (v2.0)	사유
측정했습니다	측정하도록 설계했습니다	측정 로그 부재
검증했습니다	검증 절차를 규정했습니다	검증 결과 부재
달성했습니다	목표 기준으로 설정했습니다	달성 여부 미판정
끌어올렸습니다	개선 효과를 절제 실험으로 확인할 예정입니다	대조군 부재
차단했습니다	차단하도록 설계했습니다	장애 주입 시험 미 실시
정확히 일치합니다	매핑 표에 따라 일치시키도록 설계했습니다	대상 스키마 미고정
15 초 이내로 단축합니다	15 초를 상한 목표로 설정했습니다	P95 로그 부재

1.3 전체 문서 주장 감사표 (Claim Audit)

v1.0 발표자료 및 v1.5 보완본에 포함된 모든 수치·단정 서술을 감사한 결과다. 보완안이 지적한 8 개 평가 지표 외에도 5 건의 미검증 단정이 추가로 발견되었다.

#	원문 주장	위치	현재 등급	위험도	수정 후 문장	필요 증거
1	“작품 한 점당 20 분에서 40 분”	문제 정의	E0	상	“현장 인터뷰 기준 20~40 분으로 추정되 며, 실측 타임스 터디는 미 실시 입니다”	실무자 3 인 이상 작업 시간 측정 기록

#	원문 주장	위치	현재 등급	위험도	수정 후 문장	필요 증거
2	“골드셋 100 점을 기준으 로 일치율 을 측정했 습니다”	평가 방법	E1	상	“ 큐레이 터 골드셋 기준 필드 단위 일치율 을 측정하 도록 설계했 습니다”	gold_la bels.csv , predicti ons.json l
3	“P95 15 초 이내인 지를 안정성 지표로 사용했 습니다”	평가 방법	E1	상	“P95 처리시 간을 안정성 지표로 사용하 며 상한 목표를 15 초로 설정했 습니다”	latency _log.csv
4	“JSON 1 차 통과율 95% 이상”	평가 방법	E1	중	“JSON 스키마 1 차 통과율 95%를 목표 기준으 로 설정했 습니다”	schema _validat ion_log. csv
5	“관련성 60% 이상을 달성했 는지 측정했 습니다”	평가 방법	E1	중	“3 점 척도 관련도 로 채점하 며 60% 를 목표 기준으	top5_rel evance_ eval.csv

#	원문 주장	위치	현재 등급	위험도	수정 후 문장	필요 증거
6	“실무 수용성 (목표 3.5 이상)을 검증했 습니다”	평가 방법	E1	상	로 설정했 습니다” “실무자 5인 리커트 평균으 로 측정하 되, n=5 는 통계적 판정 대상이 아닙니 다”	practitio ner_sur vey.csv
7	“물성 정확도 를 10%p 이상 끌어올 렸습니 다”	KPT / Try	E0	최상	“제약 어휘 주입의 개선 효과는 절제 실험으 로 측정할 예정입 니다”	개선 전/ 후 동일 골드셋 대조 실행 로그
8	“출력이 0 이 되는 상황을 구조적 으로 차단했 습니다”	아키텍 처	E0	상	“폴백 경로로 차단하 도록 설계했 으며, 장애 주입 시험으 로 확인할 예정입 니다”	fault_inj ection_l og.csv
9	“ DB 컬럼	데모	E0	중	“대상	대상

#	원문 주장	위치	현재 등급	위험도	수정 후 문장	필요 증거
	헤더와 정확히 일치하 는 형식”	시나리 오			기관 스키마 매핑표 에 따라 정합하 도록 설계했 습니다”	기관 컬럼 정의서 + 매핑표
10	“15 초 이내로 단축하 고”	문제 정의	E1	중	“15 초를 서비스 수준 목표 (SLO)로 설정했 습니다”	latency _log.csv
11	“수기 입력의 편차를 없애며”	문제 정의	E0	중	“입력 편차를 축소하 는 것을 목표로 합니다”	동일 작품 다인 입력 분산 비교
12	“한국화 재료군 20 종 제한 리스트”	아키텍 처	E1	하	유지 (단, 리스트 원본을 부록에 첨부)	실제 운용 어휘 목록 파일

감사 결론: 7 번과 8 번은 v1.0 에서 가장 위험한 서술이다. 7 번은 “개선 효과가 있었다”는 인과 주장을 대조군 없이 수치까지 붙여 제시했고, 8 번은 신뢰성 공학의 핵심 주장을 장애 주입 시험 없이 단정했다. 두 항목 모두 심사자가 근거를 요구했을 때 즉시 방어 불가능한 지점이므로 최우선 수정 대상이다.

1.4 발표 시 금지 표현 목록

발표 대본에서 다음 표현은 실측 로그 확보 전까지 사용하지 않는다.

- “정확도가 높습니다”, “성능이 좋습니다” (비교 대상·기준 부재)
- “기존 대비 우수합니다” (공정 비교 조건 미설정)
- “실무에서 바로 쓸 수 있습니다” (수용성 실측 부재)
- “안정적으로 동작합니다” (안정성 로그 부재)

- 소수점이 붙은 모든 수치 (예: “92.3%”) — 출처가 로그 파일이 아닌 수치는 발표 자료에 기재하지 않는다.

2. 문제 정의 및 개발 배경

2.1 현장 병목의 구조

중소 갤러리와 공립미술관의 소장품 메타데이터 입력 공정은 다음 세 가지 병목을 동시에 갖는다.

(1) 시간 병목. 작품 한 점당 상세페이지·소장품 메타데이터 수기 작성에 20~40 분이 소요되는 것으로 현장에서 보고된다. 100 점 규모 신규 수집이면 33~66 시간, 즉 실무자 1인의 1~2 주 업무량이 순수 입력 공정에 소모된다.

(2) 형식 병목. 챗 GPT 등 범용 생성 AI 를 활용하려 해도 산출물이 매번 다른 서술 형식으로 나오기 때문에 DB 컬럼에 그대로 적재할 수 없다. 결과적으로 “AI 가 쓴 글을 사람이 다시 표 형식으로 옮기는” 이중 공정이 발생하여 순 절감 효과가 상쇄된다.

(3) 검색 병목 — 가장 근본적인 문제. 현행 메타데이터는 ‘지본채색’, ‘목조’ 같은 단일 문자열 토큰에 갇혀 있다. 큐레이터가 “물성이 비슷한 작품”, “이 작가의 필치와 유사한 붓질”, “이 전시장 조명에서 색이 부딪히지 않을 작품”을 찾고자 해도 **질의를 표현할 축 자체가 DB 에 존재하지 않는다.** 이것은 검색 알고리즘의 문제가 아니라 스키마의 문제다.

2.2 베이스라인 수치의 근거 상태 — 감사 항목 #1

“20~40 분” 및 “수기 입력의 편차”는 본 프로젝트의 가치 명제를 지탱하는 기준선이지만, **현재 실측 타임스터디 기록이 없다.** 개선율은 기준선의 함수이므로, 기준선이 흔들리면 개선 주장 전체가 흔들린다. 따라서 다음 측정을 병행 설계한다.

항목	측정 설계	산출물
수기 소요시간	실무자 3 인 × 작품 5 점 × 스톱워치 계측, 작업 유형(신규/보완) 구분	baseline_timestudy.csv
입력 편차	동일 작품 5 점을 3 인이 독립 입력 → 필드별 문자열 불일치율 산출	baseline_variance.csv
절감 효과	절감률 = (수기 중앙값 - K-ART LENS P50) / 수기 중앙값 × 100	v3.0 결과표에 반영

발표 시에는 “현장 인터뷰 기준 20~40 분으로 파악되며, 정식 타임스터디는 후속 과제로 설계했습니다”로 서술한다.

2.3 기존 범용 AI 대비 결손 지점

결손	구체적 현상	K-ART LENS 의 대응
도메인 어휘 결손	장지에 분채로 그린 한국화를 '아크릴'로 오인식	제약 어휘(controlled vocabulary) 강제 주입
형식 불안정	동일 프롬프트에도 서술 구조가 매회 변동	고정 JSON 스키마 + 검증 실패 시 재시도·폴백
축 미분리	색채가 비슷해서 유사하다고 판단했는지, 도상이 비슷해서인지 추적 불가	4 축 독립 인덱스 + 축별 가중 검색
전면 실패 위험	모델 장애 시 출력 0	규칙 기반 색채·물성 폴백 경로

2.4 설계 목표(Design Goal)와 비목표(Non-goal)

평가 지표의 범위를 확정하기 위해 **하지 않기로 한 것**을 먼저 명시한다.

설계 목표

- G1. 작품 이미지 1 장 → 4-Layer 구조화 JSON 을 P95 15 초 이내 산출
- G2. 산출 JSON 이 스키마 검증을 1 차에 통과 (목표 95%)
- G3. 큐레이터 골드셋 대비 층위별 차등 일치율 확보 (색채 90 / 물성 80 / 기법 65 / 도상 55)
- G4. 4 축 분리 검색으로 축별 유사작 Top-5 제공
- G5. 실무 DB 적재 가능한 CSV 내보내기

비목표 (본 MVP에서 측정도 주장도 하지 않음)

- N1. 작가 **등정(attribution)** — 위작 판별·작가 추정은 범위 밖이다. 오픈의 법적·시장적 파급이 크므로 MVP에서 다루지 않는다.
- N2. 가격·가치 평가 — 후속 K-VALUE 과제로 분리한다.
- N3. 진위·연대 판정 — 과학적 재료 분석 없이는 불가하다.
- N4. 최종 확정 메타데이터 생성 — 본 시스템의 산출물은 **초안(draft)**이며, 큐레이터 검수를 전제한다. 이 전제는 실무 수용성 설문 문항에도 그대로 반영한다.

비목표를 명시하는 것은 방어적 조치가 아니라 평가 설계의 필수 요건이다. 측정하지 않을 것을 정해야 측정할 것의 표본과 지표가 확정된다.

3. 시스템 아키텍처 및 계층 설계

3.1 4-Layer 분해의 근거

미술품을 단일 임베딩으로 압축하면 유사도가 무엇에서 비롯되었는지 분해할 수 없다. 본 시스템은 작품이 성립하는 미학적 조건에 대응하여 4 개 층위로 특징을 분해한다.

층위	미학적 질문	실무 질의 예시
도상 (Iconography)	무엇이 그려졌는가	“산수 도상 작품만”
기법 (Technique)	어떻게 그려졌는가	“이 필치와 유사한 붓질”
물성 (Materiality)	무엇으로 만들어졌는가	“장지·분채 계열 작품”
색채 (Color)	어떤 색으로 구성되었는가	“이 전시실 벽색과 충돌하지 않는 작품”

3.2 레이어별 기술 사양

층위	주 추출기	보조/풀백	출력 형태	주요 실패 모드	실패 시 치명도
도상	CLIP / SigLIP 임베딩	VLM 텍스트 태깅	임베딩 + 태그 집합	한국 도상 어휘 부재	중
기법	VGG 중간층 Gram 행렬 통계	—	스타일 벡터 + 태그	스캔 품질 · 조명 편차 민감	중
물성	VLM (제약 어휘 강제)	규칙 기반 분류	단일/다중 라벨	서양화 재료 편향 오인식	상
색채	HSV 히스토그램 + k-means	규칙 기반 색군 매핑	대표색 팔레트 + 색군 라벨	액자·배경 혼입	상

치명도가 상인 층위(물성·색채)에만 규칙 기반 풀백을 두는 설계 근거: 이 두 층위는 (a) 결정론적 신호(픽셀 통계, 재료 어휘)로 상당 부분 복원 가능하고, (b) 오류 시 DB 적재 후 하류 전파 비용이 가장 크다. 반면 도상·기법은 규칙 기반 대체가 사실상 불가능하므로, 실패 시 값을 지어내지 않고 null + low_confidence 플래그를 반환한다.

설계 원칙: 모르는 것을 채워 넣는 것보다 모른다고 표시하는 것이 미술관 DB에서는 항상 낫다. 이 원칙은 abstention(판단 유보) 필드로 스키마에 명시된다.

3.3 Fail-safe 설계와 검증 방법 — 감사 항목 #8

v1.0 의 “출력이 0 이 되는 상황을 구조적으로 차단했습니다”는 장애 주입 시험 없이는 성립하지 않는 주장이다. 다음 시험을 설계한다.

주입 장애 유형	주입 방법	기대 동작	합격 기준
VLM 타임아웃	응답 지연 강제 (>T_max)	규칙 기반 폴백 경로 진입	색채·물성 필드 non-null 100%
VLM 5xx 오류	오류 응답 주입	1 회 재시도 후 폴백	파이프라인 미중단 100%
스키마 위반 JSON	잘못된 키/타입 반환	재시도 1 회 → 폴백	최종 스키마 유효 100%
손상 이미지	잘린 파일·0 바이트	전처리 단계 거부 + 오류코드	error_code 기록 100%
인덱스 미로드	FAISS 인덱스 부재	검색만 실패, 4-Layer JSON 은 반환	부분 성공 응답 100%

산출 로그: fault_injection_log.csv (주입 유형, 시행 횟수, 폴백 진입 여부, 최종 출력 유효성)

시행 규모 권고: 유형당 20 회 이상. 20 회 전량 성공 시 실패율의 95% 신뢰 상한은 약 14%이며, 50 회 전량 성공 시 약 6%로 내려간다. “100% 차단”이라는 표현은 어떤 표본 크기로도 성립하지 않으므로, 발표에서는 **“주입 시험 __회에서 폴백 진입 실패 0 건”**의 형태로 서술한다.

3.4 구조화 출력 제어

VLM 해설 생성 단계는 **자유 생성이 아니라 제약된 분류**로 축퇴시킨다.

1. 고정 JSON 스키마를 프롬프트에 주입 (부록 A)
2. 물성 필드는 제약 어휘 20 종 중에서만 선택 허용 (부록 B)
3. 온도 0 고정, 최대 토큰 상한 지정
4. 산출 JSON 을 스키마 검증 → 실패 시 오류 메시지 첨부 재시도 1 회 → 재실패 시 규칙 기반 폴백
5. 프롬프트·스키마·모델 버전을 predictions.jsonl 에 전량 기록

지표 간 상충 주의: JSON 1 차 통과율은 스키마를 느슨하게 할수록 올라간다. 따라서 스키마 버전을 평가 시작 전에 동결하고, 통과율과 스키마 버전을 항상 함께 보고한다. 스키마 버전 없이 보고된 통과율은 무의미하다.

3.5 검색 계층 — 4-Index 가중합

4 개 층위의 임베딩을 각각 독립 FAISS 인덱스로 구축하고, 검색 시 가중합한다.

$$\begin{aligned} \text{score}(q, d) = & w_{\text{ico}} \cdot \text{sim}_{\text{ico}}(q, d) \\ & + w_{\text{tec}} \cdot \text{sim}_{\text{tec}}(q, d) \\ & + w_{\text{mat}} \cdot \text{sim}_{\text{mat}}(q, d) \\ & + w_{\text{col}} \cdot \text{sim}_{\text{col}}(q, d) \end{aligned}$$

제약: $w_{\text{ico}} + w_{\text{tec}} + w_{\text{mat}} + w_{\text{col}} = 1$, $w_* \geq 0$

축별 프리셋 (평가 시작 전 동결 필요)

프리셋	w_ico	w_tec	w_mat	w_col	용도
균형 (default)	0.40	0.20	0.20	0.20	일반 유사작 탐색
도상 단일	1.00	0.00	0.00	0.00	주제 기준 검색
물성 가중	0.15	0.15	0.55	0.15	재료 기준 검색 (데모 핵심 기능)
색채 가중	0.15	0.15	0.15	0.55	전시 공간 색 조율

동결 대상 파라미터: 인덱스 타입(Flat/IVF/HNSW), 유사도(코사인/내적), 정규화 여부, nlist/efSearch, 가중치 프리셋 값, 코퍼스 스냅샷 해시. 이 중 하나라도 평가 중에 변경되면 그 이전 로그는 폐기하고 재실행한다.

주의: 가중치를 평가 결과를 본 뒤에 조정하면 그 시점부터 골드셋은 검증셋이 아니라 **개발셋**이 된다. 튜닝이 필요하면 별도 개발셋(dev set)을 분리하고, 최종 판정은 한 번도 보지 않은 홀드아웃에서만 수행한다.

3.6 파이프라인 및 계측 지점 (Instrumentation Point)

지연시간 로그의 컬럼은 임의로 정한 것이 아니라, 아래 각 단계의 종료 시점에 대응한다.

순서	단계	처리 내용	계측 타임스탬프
0	업로드 수신	이미지 수신, 요청 ID 발급	upload_started_at
1	정규화	장변 384px 리사이즈, pHash 중복 제거, EXIF 제거	image_normalized_at
2	병렬 추출	4-Layer 특징 독립 추출	feature_extracted_at
3	해설·검증	VLM 해설 생성 → 스키마 검증 → (재시도/ 폴백)	schema_validated_at
4	검색	4-Index 가중합 Top-5 산출	search_completed_at
5	렌더	화면 카드 4 장 렌더링 완료	card_render_done_at
6	내보내기	4-Layer JSON, 한국어 해설,	(별도 계측)

순서	단계	처리 내용	계측 타임스탬프
		Top-5, CSV	

총 처리시간 정의: $\text{total} = \text{card_render_done_at} - \text{upload_started_at}$. 단계별 소요는 인접 타임스탬프 차분으로 얻으며, 병목 구간 식별에 사용한다. 모든 시각은 **단조 시계(monotonic clock)** 기준으로 기록하고 밀리초 단위로 저장한다.

3.7 재현성 고정 항목 (Reproducibility Lock)

평가 실행 전 다음을 run_config.yaml에 고정하고 해시를 기록한다.

범주	고정 항목
모델	VLM 모델명·버전, CLIP/SigLIP 체크포인트, VGG 가중치 출처
생성	temperature=0, top_p, max_tokens, 재시도 횟수(=1)
프롬프트	prompt_version, 제약 어휘 목록 파일 해시
전처리	리사이즈 규격(장변 384px), 보간법, pHash 임계값, 색공간
검색	인덱스 타입·파라미터, 가중치 프리셋, 코퍼스 스냅샷 해시
실행 환경	OS, Python·라이브러리 버전, GPU/CPU 사양, 배치 크기, 동시 요청 수
난수	전역 시드, k-means 시드

> 재현성 패키지가 없으면 성능 수치는 “그날 그 노트북에서 그랬다”는 일화에 머문다. 본 프로젝트가 후속 **K-VALUE**의 입력 피쳐 공급원이 될 예정이라는 점에서, 재현성은 선택이 아니라 전제다.

4. 평가 설계 (Evaluation Protocol)

본 절이 v2.0 보고서의 핵심이다. v1.0에서 “평가 방법”은 한 페이지 표였으나, 그 표만으로는 어떤 결과가 나와도 사후에 해석을 바꿀 수 있었다. 아래 설계는 **결과가 나오기 전에 해석을 고정**하기 위한 것이다.

4.1 평가 철학

단일 정확도 하나로 시스템을 요약하지 않는다. 이유는 두 가지다.

첫째, 총위별 난이도가 다르다. 색채는 픽셀 통계에서 거의 결정론적으로 얻어지지만 도상은 문화적 해석이 개입한다. 이를 평균 내면 **색채의 높은 점수가 도상의 실패를 은폐한다**. 그래서 목표 기준을 색채 90 / 물성 80 / 기법 65 / 도상 55로 차등화하고, 평균 지표를 만들지 않는다.

둘째, 정확도가 높아도 쓰이지 않는 시스템이 있다. 15 초 안에 안 나오면, JSON 이 깨지면, 유사작 추천이 엉뚱하면, 큐레이터는 정확도와 무관하게 사용을 중단한다. 그래서 **유용성(정확도)·안정성(지연·스키마)·수용성(사람 판단)** 세 축을 분리해 각각 판정한다.

4.2 구성 타당도 매핑 (Construct Validity)

각 지표가 실제로 무엇을 대리하는지, 그리고 그 대리에 어떤 한계가 있는지를 명시한다.

실무 질문	지표	대리 관계의 한계
이 라벨을 그대로 DB에 넣어도 되는가	4-Layer 필드 단위 일치율	골드셋 작성자 1 인의 판단이 곧 정답이라는 가정. 라벨러 간 신뢰도로 보완
실무 흐름을 끊지 않는가	P95 처리시간	체감 지연은 P95 외에 분산·예측 가능성에도 좌우됨. P50/P99 병기
DB에 자동 적재 가능한가	JSON 1 차 통과율	스키마 통과 ≠ 내용 정확. 일치율과 반드시 함께 읽어야 함
추천이 쓸 만한가	Top-5 관련성	관련성 ≠ 유용성. 이미 아는 작품만 추천되면 관련성은 높아도 무용
실제로 쓸 것인가	리커트 평균	의향 ≠ 행동. n=5 는 통계적 판정 불가

경고: JSON 1 차 통과율이 높고 일치율이 낮은 상태는 “형식은 완벽한데 내용이 틀린 데이터를 대량 생산하는 시스템”을 의미한다. 이는 아무것도 생산하지 않는 것보다 위험하다. 두 지표는 항상 쌍으로 보고한다.

4.3 1 차 / 2 차 종점 사전 지정

8 개 지표를 동시에 유의수준 5%로 판정하면 최소 1 개가 우연히 통과할 확률(FWER)은 $1 - 0.95^8 \approx 33.7\%$ 다. 따라서 종점을 위계화한다.

구분	지표	판정 유의수준	지정 사유
1 차 종점	물성 일치율	Bonferroni 보정 $\alpha = 0.05/3 \approx 0.0167$	본 시스템의 핵심 차별점이자 KPT에서 확인된 최대 약점
1 차 종점	P95 처리시간	동일	사용자와의 명시적 서비스 약속
1 차 종점	JSON 1 차 통과율	동일	DB 적재 가능성의

구분	지표	판정 유의수준	지정 사유
			필요조건
2 차 종점	색채·기법·도상 일치율	보정 없이 CI 만 보고	탐색적 지표. 단독 성패 주장 금지
2 차 종점	Top-5 관련성	동일	탐색적
2 차 종점	실무자 리커트	판정 없음	n=5, 기술통계만

1 차 종점을 3 개로 좁히는 것은 겸손이 아니라 정밀도의 문제다. 모든 것을 주장하면 아무것도 주장하지 못한다.

4.4 골드셋 설계

4.4.1 표본 프레임 및 층화

무작위 추출이 아니라 **층화 추출(stratified sampling)**을 사용한다. 4-Layer 중 물성·기법의 난이도가 재료 계열에 따라 급격히 달라지기 때문이다.

층화 변수	구간	최소 배분
재료 계열	지본(장지·순지· 화선지) / 견본 / 유화· 아크릴 / 입체(목·석· 금속) / 사진·판화	각 15% 이상
제작 시기	근대(~1945) / 현대 (1945~2000) / 동시대(2000~)	각 20% 이상
색채 특성	저채도 수묵 계열 / 고채도 채색 계열	각 30% 이상
도상 유형	구상 / 반추상 / 추상	각 20% 이상

층화의 실무적 이유: 무작위 추출 시 데이터 가용성이 높은 유화·현대·구상 작품에 표본이 쏠리고, 정작 이 시스템의 존재 이유인 한국화 재료 계열이 과소 표집된다. 그 상태의 물성 일치율 80%는 “한국화를 잘 맞힌다”는 근거가 되지 못한다.

4.4.2 표본 수 N 산정 — v1.0 의 “100 점”은 충분한가

정규 근사 기준 필요 표본 수는 $n = z^2 \cdot p(1-p) / e^2$ ($z=1.96$)이며, 역으로 주어진 N에서의 신뢰구간 반폭은 $e = 1.96 \cdot \sqrt{p(1-p)/N}$ 이다.

목표 기준별 필요 표본 수 (95% 신뢰, 반폭 e)

목표 p	$e=\pm 10\%p$	$e=\pm 8\%p$	$e=\pm 7\%p$	$e=\pm 5\%p$
색채 0.90	35	55	71	139
물성 0.80	62	97	126	246
기법 0.65	88	137	179	350

목표 p	e=±10%p	e=±8%p	e=±7%p	e=±5%p
도상 0.55	96	149	195	381

(표본 수는 항상 올림 처리. 계산 검증은 `compute_metrics.py --selftest` 로 재현 가능)

주어진 N에서의 신뢰구간 반폭

N	색채(0.90)	물성(0.80)	기법(0.65)	도상(0.55)
100 (v1.0 주장)	±5.9%p	±7.8%p	±9.4%p	±9.8%p
150 (권고)	±4.8%p	±6.4%p	±7.6%p	±8.0%p
200 (충분)	±4.2%p	±5.5%p	±6.6%p	±6.9%p

핵심 지적: N=100에서 도상 일치율의 신뢰구간 반폭은 약 ±10%p다. 즉 관측값이 55%로 나와도 참값은 45~65% 어디든 가능하며, **목표 55% 달성 여부를 판정할 수 없다.** v1.0이 “골드셋 100 점으로 측정했다”고 서술한 것은 표본 설계 없이 정한 수치일 가능성이 높다.

최종 권고: - 본 실험 **N = 150** (MVP 공수 대비 현실적 상한, 도상 반폭 ±8%p) - 총화 배분: 재료 계열 5 구간 × 30 점 - 파일럿 N = 20 (본 실험 골드셋과 **중복 없이** 별도 구성, 채점 스크립트·라벨 지침 검증용) - 예산 제약으로 **N < 100** 이 불가피하면, 결과표에 “**판정 불가(표본 부족)**”를 명시하고 점추정만 참고치로 제시한다.

4.4.3 라벨링 프로토콜 및 라벨러 간 신뢰도

골드셋의 품질이 곧 평가의 상한이다. 라벨러가 서로 다른 답을 내는 필드에서는 모델이 아무리 잘해도 일치율이 오르지 않는다.

절차	내용
라벨러	큐레이터 자격 보유자 2 인 (curator_id 기록)
라벨 지침	총위별 정의·허용 어휘·경계 사례 문서화 후 배포 (부록 C)
이중 라벨링	전체의 30% 이상(N=150 이면 45 점)을 두 라벨러가 독립 라벨링
신뢰도 산출	총위별 Krippendorff α (다중 라벨 대응) 및 Cohen κ 병기
합격 기준	$\alpha \geq 0.80$ 수용, $0.667 \leq \alpha < 0.80$ 잠정, $\alpha < 0.667$ 지침 개정 후 재라벨링
불일치 조정	제 3 자 조정(adjudication) 또는 합의 회의로 최종 골드 라벨 확정, 조정 이력 기록
블라인드	라벨러는 모델 출력을 보지 않은 상태에서 라벨링 (앵커링 차단)

필수 보고 항목: 각 층위의 모델 일치율 옆에 반드시 **인간 라벨러 간 일치율**을 병기한다. 도상 일치율 모델 55% / 인간 60%라면 이는 “모델이 못한다”가 아니라 “그 층위는 원래 어렵다”는 뜻이며, 해석이 완전히 달라진다. 인간 상한(human ceiling) 없이 보고된 모델 정확도는 평가되지 않은 수치다.

4.4.4 데이터 누수 차단

누수 경로	차단 조치
골드셋 작품이 검색 인덱스에 포함	골드셋 artwork_id 를 인덱스 코퍼스에서 제외, 또는 검색 시 자기 자신 제외 규칙 명시
동일 작품의 다른 촬영본 중복	pHash 임계값 기반 근사 중복 제거를 골드셋 구성 단계에서 선행
프롬프트 예시로 골드셋 작품 사용	few-shot 예시는 골드셋 밖에서만 선정
튜닝 중 골드셋 반복 참조	개발셋 분리, 골드셋은 최종 1 회만 실행 (실행 횟수 로그 기록)

4.5 채점 규칙 (Matching Rule) — “일치”의 정의

v1.0 은 “필드 단위 일치율”이라고만 했으나, 무엇을 일치로 볼 것인지가 정의되지 않으면 같은 로그로 전혀 다른 수치가 나온다. 다음을 사전 확정한다.

4.5.1 정규화 규칙 (모든 층위 공통)

1. 유니코드 NFC 정규화, 좌우 공백 제거
2. 대소문자 통일, 중복 공백 축약
3. 괄호 주석 제거 (예: 장지에 분채(부분 금박) → 장지에 분채)
4. 조사·접미 표현 제거 (~계열, ~풍, ~로 추정)
5. 동의어 사전 적용 (한지 = 장지 = 순지 여부는 사전에서 **명시적으로 결정**하고 그 결정을 문서화)

동의어 사전은 평가 전에 동결한다. 결과를 본 뒤 동의어를 추가하는 것은 점수를 조작하는 것과 구별되지 않는다. 사전 파일: synonym_map.csv (해시 기록).

4.5.2 층위별 채점 방식

층위	라벨 구조	채점 방식	부분 점수
색채	다중 라벨 (대표 색군 3 개)	집합 일치 — Jaccard ≥ 0.5 를 일치로 판정	있음 (보조 지표로 micro-F1 병기)
물성	단일 주라벨 + 보조 라벨	주라벨 완전 일치만 일치로 인정	없음 (보수적 채점)
기법	다중 라벨	상위 1 개 라벨 일치 여부	보조로 micro-F1
도상	다중 라벨 (주제)	골드 태그 중 1	보조로 micro-

층위	라벨 구조	채점 방식	부분 점수
	태그)	개 이상 포함 시 일치	F1

주 지표는 위 정의에 따른 이진 일치율(binary match rate)로 고정한다. micro-F1·Jaccard 는 보조 지표로만 보고하며, 주 지표를 대체하지 않는다.

4.5.3 집계 방식

- **micro (기본):** 전체 평가 건수 기준 일치 비율. 결과표의 주 수치.
- **macro (병기):** 층화 구간별 일치율의 단순 평균. 소수 계열(예: 견본, 입체)의 성능 저하를 드러낸다.
- micro 와 macro 의 격차가 10%p 이상이면 특정 계열에 성능이 쏠려 있다는 신호이며, 반드시 서브그룹 표를 함께 제시한다.

4.5.4 판단 유보(abstention)의 처리

모델이 null + low_confidence 를 반환한 건은 **불일치로 계산한다(보수적 처리)**. 동시에 유보율 = 유보 건수 / 전체 건수를 별도 보고한다. 유보율이 높는데 일치율도 높다면 이는 “쉬운 것만 답하는” 전략일 수 있으므로, **커버리지-정확도 곡선**을 부록에 첨부한다.

4.6 판정 규칙 (Decision Rule) — 달성 / 미달 / 보류의 통계적 정의

보완안이 도입한 달성/미달/보류 3 분 판정은 방향은 옳으나 기준이 없다. 다음과 같이 **Wilson 점수 구간**으로 정의한다. (Wilson 구간은 소표본·극단 비율에서 정규 근사보다 안정적이며, 90%대 목표치를 다루는 본 과제에 적합하다.)

비율 지표 (일치율, JSON 통과율, Top-5 관련성)

Wilson 95% 신뢰구간:

$$\text{center} = (\hat{p} + z^2/2n) / (1 + z^2/n)$$

$$\text{half} = z \cdot \sqrt{(\hat{p}(1-\hat{p})/n + z^2/4n^2) / (1 + z^2/n)}$$

$$\text{CI} = [\text{center} - \text{half}, \text{center} + \text{half}], \quad z = 1.96 \text{ (1 차 종점은 } z = 2.394, \text{ Bonferroni)}$$

판정:

달성 $\leftarrow$ CI 하한 $\geq$ 목표치

미달 $\leftarrow$ CI 상한 $<$ 목표치

보류 $\leftarrow$ 그 외 (구간이 목표치를 포함)

지연시간 지표 (P95)

P95 추정: 정렬 후 선행보간 백분위수

불확실성: 부트스트랩 2,000 회 재표본 $\rightarrow$ P95 의 95% 백분위 구간

판정:

달성 $\leftarrow$ 부트스트랩 CI 상한 $\leq$ 15 초

미달 $\leftarrow$ 부트스트랩 CI 하한 $>$ 15 초

보류 $\leftarrow$ 그 외

리커트 지표 (n=5)

판정하지 않는다. 평균·중앙값·최솟값·개별 점수·정성 코멘트를 전량 제시한다.

사유: $s=0.8$ 가정 시 $n=5$ 의 표준오차는 약 0.36, 95% CI는 약 ± 0.99 .

즉 평균 3.8 이 나와도 참값은 2.8~4.8 구간이며 3.5 기준을 가를 수 없다.

이 판정 규칙이 v1.0 대비 갖는 의미: 점추정만으로 판정하면 물성 79%는 “미달”, 81%는 “달성”이 된다. 그러나 $N=150$ 에서 두 값의 신뢰구간은 거의 완전히 겹친다. 신뢰구간 기반 판정은 “아직 모른다”를 정직하게 말할 수 있는 언어를 제공하며, 이것이 본 보고서 전체의 태도와 일치한다.

4.6.1 판정 임계 카운트 — 데이터를 보기 전에 확정하는 합격선

판정 규칙을 산식으로만 남기면, 실측값이 나온 뒤 “이 정도면 달성 아니냐”는 사후 협상이 반드시 발생한다. 이를 원천 차단하기 위해 각 지표가 ‘달성’으로 판정되기 위한 최소 관측 건수를 데이터 수집 전에 계산해 고정한다.

표본 N 별 ‘달성’ 판정 최소 관측 건수 (Wilson 하한 $\geq$ 목표치)

지표	종점	목표	N=100	N=150 (권고)	N=200
색채 일치율	2 차	90%	96 (96.0%)	143 (95.3%)	189 (94.5%)
물성 일치율	1 차	80%	90 (90.0%)	132 (88.0%)	174 (87.0%)
기법 일치율	2 차	65%	75 (75.0%)	109 (72.7%)	144 (72.0%)
도상 일치율	2 차	55%	65 (65.0%)	95 (63.3%)	124 (62.0%)
JSON 1 차 통과율	1 차	95%	판정 불가	149 (99.3%)	198 (99.0%)
Top-5 관련성	2 차	60%	70 (70.0%)	102 (68.0%)	134 (67.0%)

1 차 종점은 Bonferroni 보정 $z=2.394$, 2 차 종점은 $z=1.96$ 적용.

이 표에서 세 가지 사실이 즉시 드러난다.

(1) 목표 기준과 합격선은 다르다. 색채 목표는 90%지만, $N=150$ 에서 실제로 ‘달성’을 선언하려면 관측 일치율이 **95.3%** 여야 한다. 92%가 나오면 판정은 ‘보류’다. 이 간극을 사전에 인지하지 못하면, 발표 당일 “92%로 목표 90%를 상회했습니다”라는 통계적으로 잘못된 문장이 나온다.

(2) JSON 1차 통과율 95% 목표는 $N=100$ 에서 원리적으로 판정할 수 없다. 100 건 전부가 통과해도 Bonferroni 보정 하의 Wilson 하한이 95%에 미치지 못한다. 목표치가 표본 규모의 정밀도 한계에 걸려 있기 때문이다.

관측 1 차 통과율	‘달성’ 판정에 필요한 최소 N
100%	109
99%	200

관측 1 차 통과율	‘달성’ 판정에 필요한 최소 N
98%	350
97%	700

실행 권고: 스키마 검증과 지연시간 측정은 큐레이터 인건비가 전혀 들지 않는 완전 자동 로그다. 골드셋 라벨링은 30 시간이 들지만, 이 두 로그는 배치 실행만 걸어도 N=300~500 을 사실상 무비용으로 확보할 수 있다. **비싼 지표는 N 을 아끼고, 싼 지표는 N 을 키운다** — 이것이 제한된 공수에서 판정 가능한 주장을 최대화하는 유일한 방법이다. 따라서 schema_validation_log.csv 와 latency_log.csv 의 목표 표본은 **N ≥ 300** 으로 상향한다.

(3) 도상 55%는 N=100 에서 65% 이상이어야 달성이다. 목표치가 0.5 근처일수록 이항 분산 $p(1-p)$ 가 최대가 되어 구간이 가장 넓어진다. 목표를 낮게 잡는 것이 판정을 쉽게 만들지 않는다는 점을 유의해야 한다.

판정 임계값의 동결: 위 표는 데이터 수집 개시 전에 protocol_v2.0.md 에 포함하여 해시를 기록한다. 실측 후 임계값을 조정하는 것은 사전등록 위반으로 간주하고, 조정이 불가피할 경우 조정 사실·사유·조정 전후 값을 결과표에 명시한다.

4.7 지연시간 측정 프로토콜

항목	규정
표본 수	성공 실행 N ≥ 300 (최소선 100). 인건비가 들지 않는 자동 로그이므로 표본을 아낄 이유가 없다 (§4.6.1)
위밍업	최초 5 회 실행은 콜드 스타트로 간주하여 제외하고, 제외 사실을 명시
실패 처리	실패 실행은 P95 계산에서 제외하되 실패율을 별도 보고 (실패를 빼서 지연이 좋아 보이는 착시 차단)
동시성	단일 요청(concurrency=1) 조건을 기본으로 하고, 동시 3·5 조건을 부가 측정
보고 항목	P50 / P90 / P95 / P99 / 최댓값 / 실패율 / 단계별 소요 분해
환경 명시	하드웨어, 네트워크 조건, 이미지 평균 용량, 측정 일시

표본 수의 통계적 근거: 모든 표본이 참 P95 미만일 확률은 0.95^n 이다. $n=59$ 에서 이 값이 5% 아래로 내려가므로, **$n ≥ 59$ 는 P95 추정의 최소선**이고 안정적 추정에는 100 이상이 필요하다. N=20 수준의 로그로 산출한 P95 는 보고하지 않는다.

4.8 JSON 스키마 안정성 프로토콜

항목	규정
표본 수	N ≥ 300 필수. 목표 95%는 N=100에서 만점이어도 판정 불가하다(§4.6.1). 자동 배치 실행으로 확보
1 차 통과	재시도·폴백을 적용하기 전 최초 생성물이 스키마 검증을 통과한 경우만 인정
최종 통과	재시도·폴백 후 최종 유효 여부. 별도 컬럼(final_valid)으로 기록
병기 필수	1 차 통과율 · 최종 통과율 · 폴백 사용률 3 개를 항상 함께 보고
실패 분류	필수 필드 누락 / 타입 불일치 / 허용값 위반 / 파싱 실패 로 구분 기록
스키마 버전	통과율 수치 옆에 schema_version 을 반드시 병기

1 차 통과율 95%와 폴백 사용률 40%가 동시에 성립할 수 없음에 유의한다. 두 수치의 정합성 검사는 채점 스크립트에 자동 검증으로 포함한다.

4.9 검색 품질 평가 프로토콜

항목	규정
쿼리 수	측당 30 개 이상 (정보검색 평가 관례: 25~50 토픽)
평가 축	MVP 는 도상 단일 / 물성 가중 2 개 축을 필수, 균형·색채 축은 선택
판정 규모	30 쿼리 × 2 축 × Top-5 = 300 건
척도	0 = 무관 / 1 = 약한 관련 / 2 = 명확히 관련
주 지표	보수적 관련성 = (2 점 건수) / (전체 판정 건수) × 100
보조 지표	완화 관련성(1 점 이상), P@5, nDCG@5
이중 평가	전체의 30%를 2 인 평가하여 α 산출
블라인드	평가자에게 검색 축·순위를 숨기고 결과를 무작위 배열하여 제시

보고 규칙: 관련성 비율을 제시할 때는 표 하단에 판정 기준을 반드시 명시한다. “관련 판정 기준: 2 점만” 또는 “1 점 이상”. 기준을 밝히지 않은 관련성 수치는 비교 불가능하다.

nDCG@5 산식 (보조)

$$DCG@5 = \sum_{i=1..5} (2^{rel_i} - 1) / \log_2(i + 1)$$
$$IDCG@5 = \text{판정 풀을 관련도 내림차순 정렬했을 때의 DCG@5}$$
$$nDCG@5 = DCG@5 / IDCG@5$$

nDCG 를 보조로 두는 이유: 관련성 비율은 순위를 무시한다. 1 위가 무관이고 5 위가 관련인 경우와 그 반대가 같은 점수를 받는데, 실무에서는 전혀 다른 경험이다.

4.10 실무 수용성 평가 프로토콜

항목	규정
응답자	미술관·갤러리 실무자 5 인 (소속·경력 구간 기록, 개인식별정보 비수집)
블라인드 조건	AI 산출물임을 밝히지 않고 제시. blind_condition 컬럼에 조건 코드 기록
대조 제시	가능하면 수기 초안과 AI 초안을 무작위 순서로 병렬 제시(A/B)
핵심 문항	“이 초안을 검수해서 실무에 사용할 의향이 있는가” (1~5)
보조 문항	신뢰도, 수정 소요 예상시간, 가장 신뢰 못 할 층위(선택형)
보고 방식	평균 + 중앙값 + 개별 5 개 점수 전량 + 정성 코멘트 주제 코딩
금지	n=5 로 “검증했다”·“달성했다”고 말하지 않는다

핵심 문항 설계의 주의점: “검수해서”라는 단어를 반드시 포함해야 한다. 이 단어가 빠지면 응답자는 ‘완성본으로 쓸 것인가’를 묻는 것으로 이해하고 점수가 구조적으로 낮아진다. 본 시스템의 비목표 N4(초안 생성)와 문항이 일치해야 한다.

4.11 서브그룹 및 편향 분석

전체 평균은 특정 집단에서의 실패를 은폐한다. 다음 분해를 필수 산출물로 규정한다.

분해 축	보고 지표	확인 목적
재료 계열 (5 구간)	층위별 일치율 + N + CI	한국화 재료에서의 성능 하락 여부 (KPT Problem 검증)
제작 시기 (3 구간)	동일	근대 작품 상태(변색·손상)의 영향
색채 특성 (2 구간)	색채·물성 일치율	저채도 수묵

분해 축	보고 지표	확인 목적
		계열에서의 색군 오분류
이미지 품질	일치율	스캔·촬영 품질이 성능에 미치는 영향

최악 그룹 성능(worst-group accuracy)을 별도 보고한다. 전체 물성 일치율 80%인데 견본 계열만 45%라면, 그 시스템은 견본 소장 기관에서는 쓸 수 없다. 서브그룹 N이 20 미만이면 CI가 매우 넓으므로 **참고치로만 제시**하고 판정하지 않는다.

4.12 절제 실험 (Ablation) — 감사 항목 #7 검증 설계

v1.0의 “제약 어휘 주입으로 물성 정확도를 10%p 이상 끌어올렸다”는 인과 주장이다. 인과 주장에는 대조군이 필요하다.

조건	프롬프트	그 외 조건
A (대조)	제약 어휘 없음 , 자유 생성	동일 골드셋, 동일 모델·시드·전처리
B (처치)	제약 어휘 20 종 주입	동일

개선폭 Δ = 물성 일치율(B) - 물성 일치율(A) [단위: %p]

불확실성: 동일 표본에 대한 대응 비교이므로 McNemar 검정 또는
쌍대 부트스트랩(2,000 회)으로 Δ 의 95% CI를 산출한다.

판정: CI 하한 > 0 → 개선 효과 확인
CI가 0을 포함 → “개선 방향이 관측되었으나 유의하지 않음”

보고 형식 (예시): $\Delta = +_\%p$ (95% CI $_\sim_\$, N= $_\$, McNemar p= $_\$)

절제 실험 없이 “+10%p”를 발표에 넣는 것은 본 보고서의 가장 큰 잠재 실점
요인이다. 심사자가 “그 10%p는 어떻게 됐습니까”라고 물으면 답할 수 없다. 현
판본에서는 해당 수치를 **삭제**하고, 위 설계를 제시하는 것으로 대체한다.

4.13 오류 분석 분류 체계

정량 지표만으로는 다음 개선 방향이 나오지 않는다. 불일치 건 전량에 오류 유형을 부여한다.

코드	오류 유형	예시	대응 방향
E-MAT-01	서양화 재료 편향	장지·분채 → ‘ 아크릴’	제약 어휘 강화
E-MAT-02	지종 세분 실패	장지/순지/ 화선지 미구분	동의어 사전 정책 결정
E-COL-01	액자·배경 혼입	액자색이 대표색에 포함	크롭· 세그멘테이션 전처리
E-COL-02	저채도 색군	수묵 담채 → ‘	색군 경계

코드	오류 유형	예시	대응 방향
E-TEC-01	오분류	무채색'	재정의
	촬영 조건 민감	조명 반사로 필치 왜곡	정규화 강화
E-ICO-01	한국 도상 어휘 부재	십장생·문자도 미인식	도상 어휘집 구축
E-SYS-01	스키마 위반	허용값 밖 문자열	프롬프트·검증 강화
E-SYS-02	폴백 오작동	폴백 진입 실패	장애 처리 로직 수정

산출물: error_taxonomy.csv — 유형별 건수 상위 3 개를 발표에서 언급하고, 각각에 대응하는 다음 스크린트 액션을 1:1 로 붙인다.

4.14 사전등록 및 데이터 잠금 절차

순서	절차	산출물
1	본 v2.0 문서를 평가 프로토콜로 확정, 해시 기록	protocol_v2.0.md.sha 256
2	골드셋 라벨링 완료 후 파일 동결 , 이후 수정 금지	gold_labels.csv + 해시
3	채점 스크립트를 골드셋 실행 전에 작성 ·검증 (더미 데이터로)	compute_metrics.py
4	run_config.yaml 고정 후 본 실행 1 회	predictions.jsonl 등 로그 9 종
5	채점 스크립트 실행, 결과 자동 산출 (수기 계산 금지)	results_v3.0.md
6	결과를 본 뒤 기준· 가중치·사전을 수정하지 않는다	변경 시 사유·일시 기록 필수

> 3 번이 가장 중요하다. 데이터를 보기 전에 분석 코드를 완성하는 것이 사후 기준 이동을 막는 가장 확실한 장치다. 본 보고서와 함께 채점 스크립트 초안을 첨부하는 이유가 여기에 있다.

5. [발표용 슬라이드 삽입 1] 평가 결과 요약

5.1 결과표 (실측값 미가입 — 원시 데이터 확보 후 입력)

본 프로젝트는 K-ART LENS 가 실제 미술관·갤러리 DB 입력 업무에 사용 가능한지를 확인하기 위해, **4-Layer 라벨 일치율 · 처리시간 · JSON 안정성 · 유사작 검색 품질 · 실무 수용성**을 분리해 평가하도록 설계했다. 아래 표에서 확인 가능한 것은 **측정 방법과 목표 기준**이며, 실측 결과값 산출에 필요한 골드셋·실행 로그·관련도 채점표·설문 원자료는 현재 확보되지 않았다. 근거 없는 수치는 임의로 기입하지 않는다.

표 A — 판정표 (발표 슬라이드에 그대로 삽입)

지표	종점	목표 기준	실측 결과	95% CI	판정
색채 일치율	2 차	90% 이상	$\frac{__}{__} = __\%$	[_, _]	달성/미달/ 보류
물성 일치율	1 차	80% 이상	$\frac{__}{__} = __\%$	[_, _]	달성/미달/ 보류
기법 일치율	2 차	65% 이상	$\frac{__}{__} = __\%$	[_, _]	달성/미달/ 보류
도상 일치율	2 차	55% 이상	$\frac{__}{__} = __\%$	[_, _]	달성/미달/ 보류
P95 처리시간	1 차	15 초 이내	$__ \text{초}$	[_, _]	달성/미달/ 보류
JSON 1 차 통과율	1 차	95% 이상	$\frac{__}{__} = __\%$	[_, _]	달성/미달/ 보류
유사작 Top-5 관련성	2 차	60% 이상	$\frac{__}{__} = __\%$	[_, _]	달성/미달/ 보류
실무자 리커트 평균	참고	3.5 점 이상	평균 $\frac{__}{5.0}$, n=5	산출 안 함	판정 없음

표 B — 지표별 근거 데이터 추적 (감사용, 슬라이드에는 생략 가능)

지표	평가 구분	근거 원시 데이터
색채·물성·기법·도상 일치율	4-Layer 라벨 정확도	gold_labels.csv, predictions.jsonl, synonym_map.csv
P95 처리시간	시스템 안정성	latency_log.csv
JSON 1 차 통과율	시스템 안정성	schema_validation_lo

지표	평가 구분	근거 원시 데이터
유사작 Top-5 관련성	검색 품질	g.csv top5_relevance_eval.csv
실무자 리커트 평균	실무 수용성	practitioner_survey.csv
(전 지표 공통)	재현성	run_manifest.json

표 하단 필수 주기 (발표 자료에 그대로 삽입)

- 골드셋 N = __, 라벨러 __인, 층위별 라벨러 간 신뢰도 α = __
- Top-5 관련 판정 기준: 2점만 / 1점 이상 중 택일 명시
- 지연시간 표본 N = __ (골드 스타트 __회 제외), 실패율 __%
- 스키마 버전 __, 프롬프트 버전 __, 모델 버전 __
- 실무자 리커트는 n=5로 통계적 판정 대상이 아니며 기술통계로만 제시

5.2 함께 제시할 인간 상한 대조표

층위	모델 일치율	인간 라벨러 간 일치율	격차	해석
색채	__%	__%	__%p	
물성	__%	__%	__%p	
기법	__%	__%	__%p	
도상	__%	__%	__%p	

5.3 발표 멘트 (슬라이드 1)

“평가 항목은 실제 사용 가능성을 기준으로 설계했습니다. 4-Layer 라벨은 큐레이터 골드셋과의 필드 단위 일치율로 보고, 시스템 안정성은 P95 처리시간과 JSON 스키마 1차 통과율로 판단합니다. 검색 품질은 유사작 Top-5의 관련도 평가로, 현장 적용 가능성은 실무자 5명의 리커트 평가로 확인합니다.

여기서 한 가지를 분명히 말씀드리겠습니다. **이 표의 실측 칸이 비어 있는 것은 실수가 아니라 의도입니다.** 현재 제출 자료에는 골드셋 원본, 모델 출력 로그, 처리시간 로그, 관련도 채점표, 설문 원자료가 포함되어 있지 않습니다. 근거 로그 없이 산출된 수치는 감사에 통과하지 못하고, 미술관 소장품 DB처럼 오기록이 하류로 전파되는 도메인에서는 그 자체가 위험 자산이 됩니다.

대신 저는 **판정 규칙까지 미리 확정**했습니다. 8개 지표 중 1차 종점 3개를 지정했고, 신뢰구간 하한이 목표치를 넘을 때만 달성으로 판정합니다. 구간이 목표치를 걸치면 '보류'입니다. 데이터가 채워지는 순간 해석의 여지 없이 결론이 나오도록 설계했습니다.”

6. [발표용 슬라이드 삽입 2] 측정식 및 결과 입력 형식

6.1 주 산식

지표	측정식	결과 입력 형식 예시
색채/물성/기법/도상 일치율	일치율(layer) = 일치 건수 / 평가 대상 건수 × 100	색채: 92 / 100 = 92.0%
P95 처리시간	P95 = percentile_95(card_re nder_done_at – upload_started_at)	P95 처리시간: 12.8 초
JSON 스키마 1 차 통과율	1 차 통과율 = 1 차 생성 JSON 중 스키마 유효 건수 / 전체 생성 건수 × 100	96 / 100 = 96.0%
Top-5 관련성	관련성 = 관련 판정 항목 수 / 전체 Top-5 평가 항목 수 × 100	68 / 100 = 68.0%
실무 수용성	평균점수 = 리커트 점수 합 / 응답자 수	평균 3.8 / 5.0, n=5
물성 개선 효과	Δ = 제약어휘 적용 후 일치율 - 적용 전 일치율	+__%p (95% CI __ ~ __)

6.2 보조 산식 (판정·불확실성용)

용도	산식
비율의 95% 신뢰구간 (Wilson)	center = $(\hat{p} + z^2/2n)/(1 + z^2/n)$, half = $z \cdot \sqrt{(\hat{p}(1-\hat{p})/n + z^2/4n^2)/(1 + z^2/n)}$
필요 표본 수	$n = z^2 \cdot p(1-p)/e^2$
P95 불확실성	부트스트랩 2,000 회 재표본 → P95 분포의 2.5 / 97.5 백분위
라벨러 간 신뢰도	Krippendorff $\alpha = 1 - D_o/D_e$ (관측 불일치 / 기대 불일치)
검색 순위 품질	$nDCG@5 = DCG@5 / IDCG@5$, $DCG@5 = \sum (2^{rel_i} - 1) / \log_2(i+1)$
개선 효과 검정	대응 표본 McNemar 검정 또는 쌍대 부트스트랩
시간 절감률	절감률 = (수기 중앙값 - 시스템 P50) / 수기 중앙값 × 100

6.3 Top-5 관련도 척도 및 산출 기준

점수	정의	판정 예시
0	무관	재료·주제·시대 어느 측에서도 연결점 없음

점수	정의	판정 예시
1	약한 관련	한 축에서만 유사, 실무에서 함께 제시하기 어려움
2	명확히 관련	큐레이터가 실제로 나란히 검토할 만함

산출 기준: 발표용 관련성 비율은 보수적으로 2점 항목 수 / 전체 평가 항목 수 × 100 으로 산출한다. 1 점까지 관련으로 포함하려면 표 하단에 “**관련 판정 기준: 1 점 이상**”을 반드시 명시한다. 두 기준의 수치를 모두 산출해 병기하는 것을 권장한다 (엄격 __% / 완화 __%).

6.4 수치 표기 규칙

항목	규칙
유효숫자	비율은 소수점 첫째 자리까지 (92.0%), 시간은 소수점 첫째 자리까지 (12.8 초)
분자·분모 병기	모든 비율은 분자 / 분모 = 비율 형태로 표기. 비율 단독 표기 금지
표본 수 병기	모든 지표에 N=__ 병기
반올림	은행가 반올림 사용 금지, 일반 반올림
계산 주체	모든 수치는 compute_metrics.py 출력에서 복사. 수기 계산·수기 입력 금지

7. 원시 데이터 및 로그 스키마 (Data Contract)

향후 성과 증빙 시 누락을 방지하기 위해 다음 데이터 확보를 파이프라인의 **필수 요건**으로 규정한다. 보완안의 6 종에 3 종을 추가하여 총 9 종으로 확정한다.

7.1 파일 목록 및 책임

#	파일	생성 주체	시점	필수
1	gold_labels.csv	큐레이터	실행 전 (동결)	필수
2	predictions.jsonl	시스템	실행 중	필수
3	latency_log.csv	시스템	실행 중	필수
4	schema_validation_log.csv	시스템	실행 중	필수
5	top5_relevance_eval.csv	큐레이터	실행 후	필수

#	파일	생성 주체	시점	필수
	v			
6	practitioner_survey.csv	실무자	실행 후	필수
7	annotator_agreement.csv	채점 스크립트	라벨링 후	추가
8	fault_injection_log.csv	시스템	별도 시험	추가
9	run_config.yaml	실행자	실행 전 (동결)	추가

7.2 gold_labels.csv

컬럼명	타입	필수	설명
artwork_id	string	O	평가 대상 작품 ID (전 파일 조인 키)
image_path	string	O	작품 이미지 경로
image_sha256	string	O	이미지 무결성 해시 (추가 권고)
curator_id	string	O	골드 라벨 작성자 ID
label_round	int	O	1 차/2 차 라벨링 회차 (이중 라벨링 식별, 추가 권고)
stratum_material	string	O	층화 구간: 재료 계열 (추가 권고)
stratum_period	string	O	층화 구간: 제작 시기 (추가 권고)
iconography_gold	string	O	도상 골드 라벨 (다중 시 ; 구분)
technique_gold	string	O	기법 골드 라벨
materiality_gold	string	O	물성 골드 라벨 (주라벨 우선 기재)
color_gold	string	O	색채 골드 라벨
label_confidence	int	△	라벨러 자신감 1~3 (추가)

컬럼명	타입	필수	설명
adjudicated	bool	△	권고) 불일치 조정 거친 건 여부 (추가 권고)

7.3 predictions.jsonl

필드명	타입	필수	설명
run_id	string	O	실행 ID
artwork_id	string	O	평가 대상 작품 ID
iconography_pred	string/array	O	모델 도상 예측
technique_pred	string/array	O	모델 기법 예측
materiality_pred	string	O	모델 물성 예측 (주라벨)
color_pred	string/array	O	모델 색채 예측
fallback_used	bool	O	규칙 기반 폴백 사용 여부
abstained_layers	array	△	판단 유보한 층위 목록 (추가 권고)
confidence	object	△	층위별 신뢰도 점수 (추가 권고)
prompt_version	string	O	프롬프트 버전
model_version	string	O	모델 버전
schema_version	string	O	스키마 버전 (추가 권고)
raw_response	string	△	모델 원문 응답 (오류 분석용, 추가 권고)

7.4 latency_log.csv

컬럼명	타입	필수	설명
run_id	string	O	실행 ID
artwork_id	string	O	작품 ID
upload_started_at	timestamp(ms)	O	업로드 시작 시각
image_normalised_at	timestamp(ms)	O	이미지 정규화 완료

컬럼명	타입	필수	설명
feature_extracted_at	timestamp(ms)	O	4-Layer 추출 완료
schema_validated_at	timestamp(ms)	O	JSON 검증 완료
search_completed_at	timestamp(ms)	O	FAISS 검색 완료
card_render_done_at	timestamp(ms)	O	화면 카드 렌더링 완료
status	enum	O	success / fail
error_code	string	△	실패 시 오류 코드
is_warmup	bool	△	콜드 스타트 제외 대상 여부 (추가 권고)
concurrency	int	△	동시 요청 수 (추가 권고)

7.5 schema_validation_log.csv

컬럼명	타입	필수	설명
run_id	string	O	실행 ID
artwork_id	string	O	작품 ID
schema_version	string	O	검증에 사용한 스키마 버전 (추가 권고)
first_pass_valid	bool	O	1 차 JSON 스키마 통과 여부
retry_count	int	O	재시도 횟수
final_valid	bool	O	최종 스키마 통과 여부
validation_error	string	△	실패 사유 원문
error_class	enum	△	필드누락/ 타입불일치/ 허용값위반/ 파싱실패 (추가 권고)

7.6 top5_relevance_eval.csv

컬럼명	타입	필수	설명
query_artwork_id	string	O	검색 기준 작품

컬럼명	타입	필수	설명
			ID
search_axis	enum	O	도상 / 기법 / 물성 / 색채 / 가중
rank	int	O	검색 결과 순위 (1~5)
result_artwork_id	string	O	추천 유사작 ID
curator_score_0_2	int	O	큐레이터 관련도 점수 (0/1/2)
curator_id	string	△	평가자 ID (이중 평가 식별, 추가 권고)
curator_comment	string	△	평가 메모

7.7 practitioner_survey.csv

컬럼명	타입	필수	설명
reviewer_id	string	O	실무자 ID (익명 코드)
org_type	enum	△	공립미술관 / 사립미술관 / 갤러리 (추가 권고)
career_band	enum	△	경력 구간 (추가 권고)
blind_condition	string	O	블라인드 조건 코드
likert_score_1_5	int	O	실무 사용 의향 점수
trust_score_1_5	int	△	산출물 신뢰도 (추가 권고)
expected_edit_min	int	△	예상 수정 소요 시간(분) (추가 권고)
least_trusted_lay er	enum	△	가장 신뢰 못 할 층위 (추가 권고)
comment	string	△	정성 코멘트

7.8 추가 파일 3 종

annotator_agreement.csv — layer, n_double_labeled, krippendorff_alpha, cohen_kappa, n_adjudicated

fault_injection_log.csv — injection_type, trial_id, fallback_entered, output_nonnull, pipeline_completed, error_code

run_config.yaml — 3.7 절 재현성 고정 항목 전체 + 각 파일 SHA-256

7.9 저장소 구조 및 무결성

```
kart-lens-eval/
├── protocol/
│   ├── protocol_v2.0.md      # 본 문서 (해시 고정)
│   ├── labeling_guide.md     # 라벨링 지침
│   ├── synonym_map.csv       # 동의어 사전 (동결)
│   └── kart_lens_4layer.schema.json
├── data/
│   ├── gold_labels.csv       # 동결 후 수정 금지
│   ├── predictions.jsonl
│   ├── latency_log.csv
│   ├── schema_validation_log.csv
│   ├── top5_relevance_eval.csv
│   ├── practitioner_survey.csv
│   ├── annotator_agreement.csv
│   └── fault_injection_log.csv
├── config/
│   └── run_config.yaml
├── scripts/
│   └── compute_metrics.py     # 데이터 확보 이전에 작성 완료
├── results/
│   ├── results_v3.0.md       # 자동 생성
│   └── error_taxonomy.csv
└── MANIFEST.sha256           # 전 파일 해시
```

7.10 데이터 거버넌스

항목	원칙
개인정보	실무자·라벨러는 익명 코드로만 기록. 실명·소속 상세 비수집
이미지 저작권	해외 CC0 데이터(Met·AIC·Rijksmuseum)와 국내 OpenAPI 데이터의 이용 조건은 동일하지 않다 . e 뮤지엄·국가문화유산포털 데이터의 재배포·상업적 이용 조건을 별도 확인하고 그 결과를 LICENSE_NOTES.md에 기록한다
이미지 저장	골드셋은 원본 대신 해시와 경로만 저장소에 포함, 원본은 별도 관리
로그 보존	실행 로그는 발표 후 최소 12개월 보존
EXIF	전처리 단계에서 위치정보 등 EXIF 전량 제거

8. 기존 문구 수정 대조표 (전면판)

8.1 평가 방법 관련 (보완안 반영)

[1] 골드셋 일치율

- 기존: “큐레이터가 직접 4-Layer 라벨을 작성한 골드셋 100 점을 기준으로 필드 단위 일치율을 측정했습니다.”
- 수정: “큐레이터가 직접 작성한 4-Layer 골드셋을 기준으로 필드 단위 일치율을 측정하도록 설계했습니다. 실측 결과는 골드셋과 모델 출력 로그를 매칭해 산출하며, 색채 90%, 물성 80%, 기법 65%, 도상 55%를 목표 기준으로 설정했습니다. 표본 수는 도상 지표의 신뢰구간 반폭을 $\pm 8\%p$ 이내로 확보하기 위해 $N=150$ 을 권고합니다.”

[2] 시스템 안정성

- 기존: “P95 처리 시간이 15 초 이내인지, JSON 스키마 1 차 통과율이 95% 이상인지를 시스템 안정성 지표로 사용했습니다.”
- 수정: “시스템 안정성은 업로드 시작부터 카드 렌더링 완료까지의 P95 처리시간과 JSON 스키마 1 차 통과율로 측정합니다. 목표 기준은 P95 15 초 이내, JSON 1 차 통과율 95% 이상이며, P95 는 성공 실행 100 건 이상에서 콜드 스타트를 제외하고 산출합니다.”

[3] 실무 수용성

- 기존: “실무 수용성(목표 3.5 이상)을 검증했습니다.”
- 수정: “실무 수용성은 실무자 5 명의 5 점 리커트 평균으로 측정합니다. 목표 기준은 3.5 점 이상이나, $n=5$ 는 통계적 판정이 불가능한 규모이므로 평균·중앙값·개별 점수·코멘트를 원자료 그대로 제시하고 참고 신호로만 활용합니다.”

[4] 검색 품질

- 기존: “관련성 60% 이상을 달성했는지 측정했습니다.”
- 수정: “검색된 유사작 Top-5 를 큐레이터가 3 점 척도로 채점하고, 보수적 기준(2 점만 관련 인정)으로 관련성 비율을 산출하도록 설계했습니다. 목표 기준은 60% 이상이며, 판정 기준을 표에 명시합니다.”

8.2 추가 발견 항목 (본 보고서에서 신규 지적)

[5] 물성 개선폭 — 최우선 수정

- 기존: “물성 정확도를 10%p 이상 끌어올리는 개선을 시도했습니다.”
- 수정: “프롬프트에 한국화·전통 재료군 20 종을 제한 리스트로 주입하여 자유 생성을 분류 문제로 축퇴시키는 개선을 적용했습니다. 개선 효과의 크기는 제약 어휘 적용 전/후 대조 실험으로 측정할 예정이며, 현 시점에서 수치는 제시하지 않습니다.”

[6] Fail-safe

- 기존: “출력이 0 이 되는 상황을 구조적으로 차단했습니다.”
- 수정: “치명도가 높은 색채·물성 충돌에 규칙 기반 폴백 경로를 두어 출력 공백을 차단하도록 설계했습니다. 실효성은 장애 주입 시험으로 확인할 예정입니다.”

[7] 베이스라인

- 기존: “작품 한 점당 20 분에서 40 분의 시간을 들여”
- 수정: “현장 인터뷰 기준 작품 한 점당 20~40 분이 소요되는 것으로 파악되며, 정식 타임스터디는 후속 과제로 설계했습니다.”

[8] CSV 정합성

- 기존: “미술관 소장품 DB 컬럼 헤더와 정확히 일치하는 형식으로 데이터가 다운로드되어”
- 수정: “대상 기관 소장품 DB 의 컬럼 정의서를 기준으로 매핑표를 작성하고, 그 매핑에 따라 CSV 를 내보내도록 설계했습니다. 현재 매핑 대상 기관은 __이며 매핑표는 부록에 첨부합니다.”

[9] 처리시간 약속

- 기존: “이 과정을 15 초 이내로 단축하고”
 - 수정: “이 과정의 서비스 수준 목표(SLO)를 P95 15 초로 설정했습니다.”
-

9. 차별점 및 비교 평가 설계

9.1 4 축 분리의 구조적 이점

구글 렌즈 등 기존의 단일 임베딩 검색은 결과가 틀렸을 때 무엇이 틀렸는지 추적할 수 없다. 유사도 점수 하나만 남기 때문에 색채가 비슷해서 뽑힌 것인지, 도상이 비슷해서인지 분해할 수 없고, 따라서 개선 방향도 도출되지 않는다.

K-ART LENS 는 검색 축을 4 개로 분리함으로써 다음을 얻는다.

이점	설명
복합 질의 대응	‘도상 단일 검색’, ‘물성 가중 검색’ 등 실무의 실제 질의 형태에 직접 대응
오류 귀인 가능	추천 실패 시 어느 축의 임베딩이 문제인지 축별 관련성 점수로 분해
점진적 개선	축별로 독립 개선 가능. 한 축의 교체가 다른 축을 훼손하지 않음
설명 가능성	큐레이터에게 “이 작품이 추천된 이유는 물성 유사도”라고 제시 가능
하류 재사용	4 축 태그가 그대로 후속 K-VALUE 모델의 입력 피처가 됨

9.2 공정 비교 조건 (현재 미실시)

“기존 대비 우수하다”는 주장은 비교 조건을 명시하지 않으면 성립하지 않는다. 본 MVP 는 아직 비교 실험을 수행하지 않았으며, 다음을 설계로만 제시한다.

비교 대상	비교 조건	측정 지표
범용 VLM 단독 (제약 없음)	동일 이미지·동일 골드셋	4-Layer 일치율, JSON 1 차 통과율
단일 임베딩 검색 (CLIP only)	동일 코퍼스·동일 쿼리	Top-5 관련성, nDCG@5
수기 입력	동일 작품 5 점, 실무자 3 인	소요시간, 입력 편차

> 발표 시 유의: 슬라이드에 구글 렌즈를 비교 대상으로 표기할 경우, 실측 비교를 하지 않았다면 “구조적 차이”라고만 서술하고 성능 우위를 주장하지 않는다.

10. 한계 및 타당도 위협 (Threats to Validity)

성능이 좋게 나왔을 때 그 결과를 무효화할 수 있는 요인들을 결과가 나오기 전에 열거한다.

10.1 구성 타당도 (Construct Validity)

위협	설명	완화 조치
골드셋이 정답이라는 가정	큐레이터 1 인의 판단이 유일한 정답은 아님	이중 라벨링, α 보고, 인간 상한 병기
일치율 $\neq$ 유용성	형식적으로 일치해도 실무에 무용할 수 있음	실무 수용성 설문 병행, 수정 소요시간 문항 추가
관련성 $\neq$ 발견 가치	이미 아는 작품만 추천되면 관련성은 높아도 무용	코멘트 정성 코딩에 ‘새로운 발견’ 항목 포함
리커트 의향 $\neq$ 실사용	의향과 행동의 괴리	후속 단계에서 실제 사용 로그 측정

10.2 내적 타당도 (Internal Validity)

위협	설명	완화 조치
데이터 누수	골드셋이 인덱스·프롬프트 예시에 포함	4.4.4 절 차단 조치, 코퍼스 해시 대조
사후 기준 이동	결과를 본 뒤 동의어·가중치·기준 조정	사전등록, 파일 동결, 채점 스크립트 선작성
반복 실행 선택	여러 번 돌려 좋은 결과만 채택	실행 횟수 로그 기록, 최종 실행 1 회 지정
평가자 앵커링	라벨러가 모델 출력을 먼저 봄	블라인드 라벨링, 결과 무작위 배열

10.3 외적 타당도 (External Validity)

위험	설명	완화 조치
코퍼스 편향	오픈 데이터 중심이라 실제 소장품 분포와 불일치	총화 추출로 재료 계열 최소 배분 강제
촬영 조건 편향	미술관 공식 촬영본 위주, 현장 스냅 부재	이미지 품질 서브그룹 분석
기관 일반화	특정 기관 스키마에 맞춘 결과일 수 있음	매핑표 다기관 확장, 기관 무관 필드 우선
실무자 5 인의 대표성	표본이 작고 선택 편향 가능	소속 유형·경력 구간 기록, 판정 미 실시

10.4 통계적 결론 타당도 (Statistical Conclusion Validity)

위험	설명	완화 조치
검정력 부족	N=150 에서 도상 반폭 ±8%p	판정 규칙에 ‘보류’ 범주 명시적 포함
다중 비교	8 개 지표 동시 판정 시 FWER 33.7%	1 차 종점 3 개 지정 + Bonferroni
P95 의 불안정성	소표본에서 극단값에 민감	N≥100, 부트스트랩 CI, P50/P90/P99 병기
서브그룹 과소표집	계열별 N 이 30 내외	서브그룹은 참고치로만, 판정 안 함

10.5 인정하는 한계 (발표에서 먼저 말할 것)

- 1. 본 MVP 는 초안 생성기이며 확정 메타데이터 생성기가 아니다. 큐레이터 검수를 반드시 전제한다.
- 2. 작가 동정·진위·가격 판단은 범위 밖이며, 산출물이 그 용도로 오용되지 않도록 UI 에 명시할 필요가 있다.
- 3. 현 단계에서 성능에 대한 어떠한 정량 주장도 하지 않는다.
- 4. 2 주 개발 기간의 제약상 코퍼스 규모·다양성이 실제 기관 소장품 분포를 대표하지 못한다.

한계를 먼저 말하는 것은 방어가 아니라 신뢰의 확보다. 심사자가 먼저 지적하는 한계와 발표자가 먼저 밝히는 한계는 청중에게 전혀 다르게 들린다.

11. 회고(KPT) 및 향후 계획

11.1 KPT — 주장 강도 조정판

Keep (유지할 점)

신규 모델을 처음부터 학습시키는 대신, 사전학습 모델의 조합과 **도메인 스키마 설계**에 자원을 집중하여 2 주라는 기간 안에 파이프라인을 멈춤 없이 완주시킨 전략을 유지한다. 특히 “모델을 바꾸는 것보다 출력 형식을 강제하는 것이 실무 적용에 더 큰 영향을 준다”는 판단은 유효했다.

Problem (문제점)

초기에 VLM 이 장치에 분채로 그려진 한국화를 아크릴로 오인식하는 등, **물성 층위에서 서양 미술 편향**이 확인되었다. 더 근본적인 문제는, 이 편향을 발견했음에도 **개선 효과를 측정할 대조군 설계를 사전에 마련하지 않았**다는 점이다. 그 결과 개선을 적용하고도 그 효과를 정량화할 수 없는 상태가 되었다. 이것이 본 프로젝트의 가장 큰 방법론적 실책이다.

Try (시도할 점)

- 프롬프트에 한국화·전통 재료군 20 종을 제한 리스트로 강제 주입하여 자유 생성을 분류 문제로 축퇴시켰다. **효과 크기는 4.12 점 절제 실험으로 측정한다.**
- 개선을 적용하기 **전에** 대조군 실험 로그를 먼저 남기는 것을 표준 절차로 삼는다.
- 해외 오픈 액세스(CC0) 데이터를 보강하되, 그것이 오히려 서양화 편향을 강화할 수 있음을 인지하고 **국내 재료 계열 데이터 확보를 우선한다.**

11.2 Future Work

단계	내용	선행 조건
즉시	골드셋 구축 및 9 종 로그 확보, v3.0 결과 확정	12 점 스프린트 실행
단기	도상 어휘집(십장생·문자도·산수 등) 구축, 도상 층위 성능 개선	오류 분석 E-ICO-01 결과
단기	대상 기관 DB 컬럼 매핑표 작성, 실제 적재 파일럿	협력 기관 1 곳 확보
중기	4-Layer 태그를 입력 피처로 하는 K-VALUE 가치평가 모델	4-Layer 태그 신뢰도 확보
중기	유찰 데이터의 관측 편향 통계 보정(선택 편향 보정)	K-VALUE 설계

K-VALUE 연계 시 반드시 유의할 점: 본 MVP 의 4-Layer 태그가 후속 가치평가 모델의 입력 피처가 된다는 것은, **4-Layer 의 측정 오차가 가치평가 모델의 편향으로 전파**된다는 뜻이다. 층위별 일치율과 신뢰구간은 K-VALUE 단계에서 피처 노이즈 수준의 사전 정보로 사용되어야 하며, 태그를 오차 없는 관측치로 취급해서는 안 된다. 이것이 본 보고서가 신뢰구간을 고집하는 실질적 이유다.

12. 실행 계획 — 데이터 확보 스프린트 (D+0 ~ D+14)

일차	작업	산출물	예상 공수
D+0	프로토콜 v2.0 확정, 해시 기록	protocol_v2.0. md	2h
D+0~1	라벨링 지침· 동의어 사전 작성 및 동결	labeling_guide. md, synonym_map. csv	6h
D+1	채점 스크립트 작성 및 더미 데이터 검증	compute_metri cs.py	6h
D+2~3	파일럿 골드셋 20 점 이중 라벨링	파일럿 라벨	8h
D+3	파일럿 α 산출, 지침 개정 여부 판단	annotator_agre ement.csv (파일럿)	2h
D+4~7	본 골드셋 150 점 라벨링 (30% 이중)	gold_labels.csv (동결)	30h
D+8	run_config.yaml 고정, 본 실행 1 회	predictions.json 1 외 3 종	4h
D+8	지연시간 측정 200 회 실행	latency_log.csv	3h
D+9	장애 주입 시험 (5 유형 × 20 회)	fault_injection_l og.csv	4h
D+9	절제 실험 A/B 실행	대조군 로그	3h
D+10~11	Top-5 관련도 채점 300 건	top5_relevance _eval.csv	10h
D+12	실무자 5 인 블라인드 설문	practitioner_sur vey.csv	5h
D+13	채점 스크립트 실행, 결과 자동 산출	results_v3.0.md	2h
D+13	오류 분류 및 서브그룹 분석	error_taxonomy .csv	4h
D+14	v3.0 보고서· 발표자료 갱신	최종본	6h

총 예상 공수 약 **95 시간**. 그중 골드셋 라벨링이 30 시간으로 최대 비중이다.

12.1 공수 부족 시 축소 우선순위

우선순위	항목	축소 시 영향
1 (사수)	골드셋 $N \geq 100$ + 이중 라벨링 30%	이것이 없으면 어떤 정확도 주장도 불가
2 (사수)	latency_log.csv $N \geq 100$	P95 는 로그만 있으면 저비용으로 확보 가능
3 (사수)	schema_validation_lo g.csv	자동 생성 가능, 비용 거의 없음
4	절제 실험	축소 시 물성 개선 주장을 전면 삭제
5	Top-5 관련도 300 건 → 150 건	축소 시 CI 폭 확대, 판정 '보류' 가능성 증가
6	실무자 설문	축소 시 해당 행을 표에서 제거 (판정 없음)이므로 손실 적음)

축소 판단의 원칙: 비용 대비 주장 가치가 가장 낮은 것부터 버린다. 지연·스키마 로그는 사실상 공짜이므로 절대 빠뜨리지 않는다. 반대로 실무자 설문은 공수 대비 판정 기여가 없으므로 가장 먼저 축소 대상이다.

13. 최종 결론 문구 템플릿

아래 문구는 **9 종 원시 데이터가 확보되고 compute_metrics.py 로 수치가 산출된 이후** 최종 발표 결론에서 사용한다.

“측정 결과, K-ART LENS 는 4-Layer 중 __개 / 4 개 지표에서 목표 기준을 충족했습니다. 특히 가장 높은 지표명은 __% (95% CI __~__)로 목표 __%를 상회했으며, 가장 낮은 지표명은 __% (95% CI __~__)로 추가 개선이 필요했습니다. 참고로 동일 층위의 인간 라벨러 간 일치율은 __%였습니다.

시스템 안정성 측면에서는 P95 처리시간 __초 (부트스트랩 CI __~__), JSON 스키마 1 차 통과율 __%를 기록해 각각 달성/미달/보류로 판정했습니다. 유사작 Top-5 관련성은 보수적 기준으로 __%였습니다. 실무 수용성은 평균 __ / 5.0 (n=5)이며, 표본이 작아 판정은 하지 않고 참고 신호로만 제시합니다.

사전에 지정한 1 차 종점 3 개 중 __개가 달성으로 판정되었으므로, 본 MVP 는 제한적 실무 적용 가능 / 추가 검증 필요 / 목표 충족으로 판단됩니다. 다만 __ 계열에서 최악 그룹 성능이 __%로 나타나 해당 계열 기관에는 아직 권장하지 않습니다.”

결론 서술 시 금지 사항

- 1 차 종점 판정 없이 2 차 종점만으로 “목표 충족” 선언

- 신뢰구간 없이 점추정만 제시
 - '보류' 판정을 '달성'으로 반올림
 - 최악 그룹 성능을 생략한 채 전체 평균만 제시
-

부록

부록 A. 4-Layer JSON 스키마 초안 (v0.1)

```
{
  "$schema": "https://json-schema.org/draft/2020-12/schema",
  "title": "K-ART LENS 4-Layer Artwork Record",
  "type": "object",
  "required": ["artwork_id", "iconography", "technique", "materiality", "color", "meta"],
  "properties": {
    "artwork_id": { "type": "string" },
    "iconography": {
      "type": "object",
      "required": ["tags", "abstained"],
      "properties": {
        "tags": { "type": "array", "items": { "type": "string" }, "maxItems": 5 },
        "confidence": { "type": "number", "minimum": 0, "maximum": 1 },
        "abstained": { "type": "boolean" }
      }
    },
    "technique": {
      "type": "object",
      "required": ["primary", "abstained"],
      "properties": {
        "primary": { "type": ["string", "null"] },
        "secondary": { "type": "array", "items": { "type": "string" }, "maxItems": 3 },
        "confidence": { "type": "number", "minimum": 0, "maximum": 1 },
        "abstained": { "type": "boolean" }
      }
    },
    "materiality": {
      "type": "object",
      "required": ["primary", "abstained"],
      "properties": {
        "primary": {
          "type": ["string", "null"],
          "description": "부록 B 제약 어휘에서만 선택",
          "enum": ["장지에 분채", "장지에 수간채색", "순지에 수묵", "화선지에 수묵담채",
            "견본채색", "마본채색", "저본채색", "지본수묵", "지본담채", "지본채색",
            "캔버스에 유채", "캔버스에 아크릴", "패널에 혼합재료", "종이에 콜라주",
            "목조", "석조", "금속", "도자", "옷칠·나전", "사진·판화", null]
        },
        "support": { "type": ["string", "null"], "description": "바탕재" },
        "medium": { "type": ["string", "null"], "description": "채색재" },
        "confidence": { "type": "number", "minimum": 0, "maximum": 1 },
        "abstained": { "type": "boolean" }
      }
    },
    "color": {
```

```

    "type": "object",
    "required": ["palette", "groups", "abstained"],
    "properties": {
      "palette": { "type": "array", "items": { "type": "string", "pattern": "^[0-9A-Fa-f]{6}$" }, "maxItems": 5 },
      "groups": { "type": "array", "items": { "type": "string" }, "maxItems": 3 },
      "saturation_band": { "type": "string", "enum": ["저채도", "중채도", "고채도"] },
      "abstained": { "type": "boolean" }
    }
  },
  "caption_ko": { "type": "string", "maxLength": 500 },
  "meta": {
    "type": "object",
    "required": ["run_id", "model_version", "prompt_version", "schema_version", "fallback_used"],
    "properties": {
      "run_id": { "type": "string" },
      "model_version": { "type": "string" },
      "prompt_version": { "type": "string" },
      "schema_version": { "type": "string" },
      "fallback_used": { "type": "boolean" }
    }
  }
},
"additionalProperties": false
}

```

주의: 위 enum 목록은 초안이다. 실제 운용 중인 제약 어휘 20 종 원본 파일로 교체해야 하며, 교체 시 schema_version 을 올리고 그 이전 통과율 로그와 분리 보관한다.

부록 B. 물성 제약 어휘 — 초안 및 확정 절차

초안 20 종 (지본·견본 계열 우선)

구분	어휘
지본	장지에 분채, 장지에 수간채색, 순지에 수묵, 화선지에 수묵담채, 지본수묵, 지본담채, 지본채색
직물본	견본채색, 마본채색, 저본채색
서양화	캔버스에 유채, 캔버스에 아크릴, 패널에 혼합재료, 종이에 콜라주
입체·기타	목조, 석조, 금속, 도자, 옷칠·나전, 사진·판화

확정 절차: (1) 대상 기관 소장품 DB 의 실제 재료 필드 값 분포를 빈도순으로 추출 → (2) 상위 누적 90%를 커버하는 어휘로 목록 재구성 → (3) 큐레이터 2 인 검토 → (4) 파일 해시 기록 후 동결. 어휘가 실제 분포를 커버하지 못하면 물성 일치율은 어휘 설계 실패로 인해 구조적으로 낮게 나온다.

부록 C. 라벨링 지침 요약

층위	라벨 규칙	경계 사례 처리
도상	화면에서 식별 가능한 주제 태그 최대 3 개, 중요도 순	추상 작품은 추상 단일 태그, 억지 해석 금지
기법	주 기법 1 개 필수, 보조 최대 2 개	혼합 기법은 화면 점유 면적이 큰 쪽을 주 기법으로
물성	제약 어휘에서 주라벨 1 개 선택 필수	육안 판별 불가 시 판단 유보 선택. 추측 금지
색채	대표 색군 최대 3 개, 면적 순	액자·배경·매트는 제외. 화면 영역만 판단

공통 규칙

- 작품 정보(작가·제목·연도)를 보지 않고 **이미지만으로** 라벨링한다.
- 확신이 없으면 label_confidence 를 1 로 기록하고 넘어간다. 억지로 채우지 않는다.
- 라벨링 중 지침의 모호함을 발견하면 즉시 기록하고, 지침 개정은 파일럿 단계에서만 허용한다.

부록 D. 채점 스크립트 (compute_metrics.py) — 본 보고서와 함께 제출

본 보고서는 산식을 문장으로만 남기지 않는다. **판정 규칙을 코드로 고정한 실행 가능한 스크립트를 함께 제출**하며, 자체 검증(--selftest) 21 개 항목이 전부 통과한 상태다. 실측 데이터가 확보되면 이 스크립트를 실행하는 것만으로 본 보고서 5 장의 결과표가 생성된다.

D.1 실행 방법

```
python3 compute_metrics.py --selftest # 통계 함수 자체 검증 (21 항목)
python3 compute_metrics.py --data ./raw --out ./results
```

Python 3.8 이상, **외부 의존성 없음**(표준 라이브러리만 사용). 별도 환경 구축 없이 실무자 PC 에서 바로 재현 가능하도록 의도한 설계다.

D.2 기능 구성

기능	입력	출력	구현 방식
층위별 일치율 + Wilson CI	gold_labels.csv, predictions.json , synonym_map.csv	일치율, CI, 판정	층위별 채점 규칙(\$4.5.2) 코드 고정
라벨 정규화	동일	정규화 라벨	NFC → 괄호 주석 제거 → 접미 제거 → 동의어 사전
이중 라벨 중복	gold_labels.csv	작품당 최종	adjudicated

기능	입력	출력	구현 방식
제거		골드 1 행	우선, 미지정 시 최초 행
P95 + 부트스트랩 CI	latency_log.csv	P50/P90/P95/ P99/최댓값, CI, 실패율	선형보간 백분위 + 2,000 회 재표본
JSON 통과율	schema_validation_log.csv	1 차·최종 통과율, 재시도율, 실패 유형 분포	Bonferroni z=2.394 적용
Top-5 관련성	top5_relevance_eval.csv	엄격·완화 관련성, 축별 분해	질의 단위 클러스터 부트스트랩
라벨러 간 신뢰도	gold_labels.csv (이중 라벨분)	쌍별 일치율, Krippendorff α	명목 척도 α 구현
리커트 기술통계	practitioner_survey.csv	평균·중앙값· 최소·최대· 표준편차·개별 점수	판정 수행하지 않음
개선 효과 검정	절제 실험 로그	McNemar 정확검정 p 값	대응표본 이항 정확검정
결과표 자동 생성	전체	results_summary.csv, results_table.m d, results_detail.js on	본 보고서 5 장 표 형식과 동일

D.3 데이터가 없을 때의 동작 — 가장 중요한 사항

원시 데이터가 없으면 스크립트는 오류를 내거나 **0** 을 출력하지 않고, 해당 행을 미측정으로 유지한 채 공란 표를 그대로 출력한다.

| 시스템 안정성 | JSON 스키마 1 차 통과율 | 1 차 | 95% 이상 | `\_\_ / \_\_ = \_\_%` | `[\_\_, \_\_]` | 미측정 |
원시 데이터 없음 |

[경고] 미측정 지표가 있습니다: 색채 일치율, 물성 일치율, ...
해당 항목은 발표 자료에서 공란으로 유지하십시오.

즉 **현 시점에 이 스크립트를 실행하면 본 보고서 5 장의 표가 그대로 재현된다**. 5 장의 공란은 작성자의 서술 선택이 아니라 **도구가 산출한 결과**이며, 이것이 “근거 없는 수치는 기입하지 않는다”는 원칙의 기계적 보증이다.

D.4 자체 검증에 포함된 항목

Wilson 구간(92/100 → [85.0%, 95.9%]), 판정 임계 카운트(\$4.6.1 전 항목), 필요 표본 수 (\$4.4.2 전 항목), 선형보간 백분위, McNemar 정확검정, Krippendorff α , 층위별 채점 규칙 5 종, 3 분 판정 규칙 5 종. 본 보고서에 인쇄된 모든 수치는 이 검증을 통과한 함수로 산출되었다.

D.5 설계 원칙

스크립트는 판정까지 자동 수행한다. 사람이 개입해 판정을 바꿀 수 있는 지점을 남기지 않는 것이 사후 기준 이동을 막는 마지막 방어선이다. 판정 파라미터(Z_PRIMARY, Z_SECONDARY, TARGETS, MATCH_RULE)는 파일 상단에 상수로 모아 두었으며, 이 값의 변경은 곧 프로토콜 개정이므로 변경 시 해시를 재기록하고 결과표에 변경 이력을 명시한다.

부록 E. 예상 질의응답 10 선

Q1. 왜 성능 수치가 하나도 없습니까? > 근거 로그 없이 산출된 수치를 발표 자료에 올리지 않기로 원칙을 세웠기 때문입니다. 대신 측정식·표본 설계·판정 규칙을 모두 확정해 두었고, 로그가 확보되면 해석의 여지 없이 결론이 나옵니다. 소요 공수는 약 95 시간으로 산정했습니다.

Q2. 골드셋 100 점이면 충분하지 않나요? > 색채(목표 90%)에는 충분하지만 도상(목표 55%)에는 부족합니다. N=100 에서 도상 일치율의 신뢰구간 반폭이 약 $\pm 10\%p$ 여서, 55%가 나와도 목표 달성 여부를 판정할 수 없습니다. N=150 을 권고합니다.

Q3. 목표 기준을 층위별로 다르게 잡은 근거는? > 층위별 난이도가 다르고, 평균을 내면 색채의 높은 점수가 도상의 실패를 은폐하기 때문입니다. 평균 지표를 아예 만들지 않은 것도 같은 이유입니다.

Q4. 물성 정확도가 10%p 올랐다는 건 어떻게 됐습니까? > 정확히 그 지적 때문에 해당 수치를 이번 판본에서 삭제했습니다. 인과 주장에는 대조군이 필요한데 없었습니다. 제약 어휘 적용 전/후 A/B 절제 실험을 설계해 두었고, McNemar 검정으로 개선폭의 신뢰구간을 산출할 예정입니다.

Q5. 실무자 5 명이면 표본이 너무 적지 않나요? > 맞습니다. 그래서 이 지표는 판정 대상에서 제외했습니다. n=5 의 95% 신뢰구간은 약 ± 1.0 점이라 3.5 기준을 가를 수 없습니다. 평균 대신 개별 점수 5 개와 코멘트를 원자료로 제시합니다.

Q6. 15 초 목표는 어떻게 정했습니까? > 실무 흐름이 끊기지 않는 체감 상한을 기준으로 설정한 서비스 수준 목표입니다. 다만 P95 만으로는 체감 지연을 다 설명하지 못해서 P50·P90·P99 를 함께 보고하도록 했습니다.

Q7. 구글 렌즈보다 나은 겁니까? > 실측 비교를 하지 않았으므로 성능 우위는 주장하지 않습니다. 구조적 차이는 명확합니다. 단일 임베딩은 무엇 때문에 유사하다고 판단했는지 분해할 수 없고, 그래서 개선 방향도 나오지 않습니다.

Q8. JSON 통과율 95%면 실무에 바로 쓸 수 있는 건가요? > 아닙니다. 스키마 통과는 형식 유효성일 뿐 내용 정확성이 아닙니다. 통과율이 높으면 일치율이 낮으면 형식만 완벽하고 내용은 틀린 데이터를 대량 생산하는 상태이며, 이는 아무것도 만들지 않는 것보다 위험합니다. 두 지표는 반드시 함께 봅니다.

Q9. 폴백이 있으면 항상 결과가 나온다는 뜻인가요? > 설계상 그렇게 의도했지만 아직 장애 주입 시험을 하지 않았습니다. 5 개 장애 유형에 각 20 회씩 주입해 폴백 진입률을 확인할 계획이며, 그 전까지는 “차단했다”가 아니라 “차단하도록 설계했다”로 말합니다.

Q10. 이 결과가 K-VALUE 로 어떻게 이어집니까? > 4-Layer 태그가 가치평가 모델의 입력 피처가 됩니다. 그래서 태그의 측정 오차가 그대로 가치평가 편향으로 전파됩니다. 층위별 신뢰구간을 확보해 두어야 후속 단계에서 피처 노이즈를 사전 정보로 반영할 수 있습니다. 신뢰구간을 고집하는 실질적 이유가 여기 있습니다.

부록 F. 제출 전 체크리스트

문서

- ☐ 완료형 동사(“측정했다/검증했다/달성했다”)가 남아 있지 않은가
- ☐ 로그 근거 없는 수치(소수점 포함)가 남아 있지 않은가
- ☐ 모든 비율에 분자/분모 및 N 이 병기되었는가
- ☐ Top-5 관련 판정 기준이 표 하단에 명시되었는가
- ☐ 스키마·프롬프트·모델 버전이 결과표에 병기되었는가
- ☐ 비교 우위 주장이 실측 없이 들어가 있지 않은가

데이터

- ☐ 9 종 파일이 모두 존재하고 MANIFEST.sha256 이 갱신되었는가
- ☐ gold_labels.csv 가 동결되었고 실행 후 수정 이력이 없는가
- ☐ 골드셋 artwork_id 가 검색 인덱스에서 제외되었는가
- ☐ 이중 라벨링 비율이 30% 이상이고 α 가 산출되었는가
- ☐ latency_log.csv 의 콜드 스타트 제외 건수가 명시되었는가
- ☐ 실패 실행이 P95 에서 제외되었고 실패율이 별도 보고되었는가

분석

- ☐ 모든 수치가 compute_metrics.py 출력에서 복사되었는가 (수기 계산 0 건)
- ☐ 1 차 종점 3 개에 Bonferroni 보정이 적용되었는가
- ☐ 판정이 Wilson CI 규칙에 따라 자동 산출되었는가
- ☐ 서브그룹 표와 최악 그룹 성능이 포함되었는가
- ☐ 인간 라벨러 간 일치율이 모델 일치율과 나란히 제시되었는가

부록 G. 용어 정리

용어	정의
골드셋 (Gold set)	정답으로 간주하는 인간 라벨 집합. 본 과제에서는 큐레이터 작성 4-Layer 라벨
인간 상한 (Human ceiling)	동일 과제에서 인간 라벨러들끼리 일치하는 비율. 모델 성능 해석의 기준선
Wilson 신뢰구간	이항 비율의 신뢰구간 추정법.

용어	정의
P95	소표본·극단 비율에서 정규 근사보다 안정적 상위 5%를 제외한 최댓값. 꼬리 지연을 보는 지표
1 차 종점 (Primary endpoint)	성패 판정의 근거가 되는 사전 지정 지표
FWER	다중 비교 시 최소 1 개 이상 거짓 양성이 나올 확률
Bonferroni 보정	유의수준을 비교 횟수로 나누어 FWER 을 통제하는 방법
Krippendorff α	다중 라벨·결측을 허용하는 평가자 간 신뢰도 계수
절제 실험 (Ablation)	구성 요소를 제거·추가한 대조 실험으로 기여도를 분리하는 방법
판단 유보 (Abstention)	신뢰도가 낮을 때 값을 생성하지 않고 유보를 반환하는 전략
사전등록 (Pre-registration)	데이터 수집 전에 가설·지표·분석 방법을 고정 공개하는 절차
데이터 누수 (Leakage)	평가 대상 정보가 학습·인덱스·프롬프트에 유입되어 성능이 부풀려지는 현상
SLO	서비스 수준 목표. 본 과제에서는 P95 15 초

부록 H. 참고 자료

- e 뮤지엄, 국가문화유산포털 OpenAPI
- The Metropolitan Museum of Art / Art Institute of Chicago / Rijksmuseum Open Access (CC0) Data
- 선행 판본: K-ART_LENS_최종발표자료.pdf (v1.0), K-ART_LENS_최종발표보고서_보완본.pdf (v1.5)

문서 종료. 본 보고서 v2.0 은 평가 프로토콜 확정본이며, 실측값이 채워진 v3.0 으로 대체될 때까지 성능에 관한 정량 주장의 근거로 인용될 수 없다.