

K-ART LENS 최종수행 발표보고서

한국 미술 작품 4-Layer 자동 해석 및 유사작 검색 엔진

시스템 구현, 실험 설계, 성능평가, 수치증빙, 재현성 검증 통합본

항목	내용
작성자	추병곤
과정	AIFEL 18기 온라인 리서처
작성 기준일	2026. 8. 19.
프로젝트 단계	MVP 최종 수행평가
평가 원칙	Accuracy, Reliability, Retrieval Quality, Practical Usability, Reproducibility
근거 자료	[S1] K-ART_LENS_최종발표자료.pdf, [S2] K-ART_LENS_평가결과_슬라이드_보완안.pdf, [S3] K-ART_LENS_최종발표보고서.pdf, [S4] K-ART_LENS_최종발표보고서_보완본.pdf

연구윤리 및 수치 사용 원칙

본 제출본은 원본 PDF 4개와 사용자 제공 원고를 근거로 재구성하되, 원시 로그가 없는 값을 실측 성능으로 확정하지 않는다. 92.0%, 12.8초, 96.0%, 68.0%, 3.8/5.0은 산식 설명용 예시로 분리하고, 최종 PASS/FAIL은 Raw Data Package 확보 후에만 확정한다.

목차

1. Executive Summary
 2. 검토 원자료와 증거 수준
 3. 시스템 개요와 4-Layer 파이프라인
 4. 연구목표와 성공판정 기준
 5. 실험 데이터셋 및 평가 단위
 6. 실험 실행 프로토콜
 7. 정량 및 정성 평가 방법
 8. 수치증빙 결과표와 예시수치 검증
 9. 물성 성능 개선 실험과 오류분석
 10. Raw Data Package와 재현성
 11. 최종 수행평가와 발표 문안
- 부록 A. 최종 실측치 확정표
- 부록 B. 필수 데이터 파일 스키마
- 부록 C. 검토 원자료 목록

1. Executive Summary

K-ART LENS는 한국 미술 작품 이미지를 하나의 통합 이미지 임베딩으로만 처리하는 접근에서 벗어나, 작품의 특성을 도상(Iconography), 기법(Technique), 물성(Materiality), 색채(Color)의 네 개 층위로 분해해 구조화 메타데이터, 작품 해설, 유사작 검색 결과를 생성하는 AI 기반 미술 아카이빙 시스템이다.

시스템은 도상 영역에 CLIP/SigLIP 계열 임베딩, 기법 영역에 VGG 중간층 Gram 통계, 색채 영역에 HSV histogram 및 k-means를 활용하고, 실무 오류 영향이 큰 물성 영역에는 한국화 재료 vocabulary와 rule-based fallback을 결합한다. VLM 출력은 고정 JSON schema로 제한해 자유서술형 생성보다 DB 적재 가능한 구조화 출력을 지향한다. [S3 p.3, S1 p.2]

최종 판정 요약

기능적 MVP와 평가 프레임워크는 완료 상태로 볼 수 있다. 다만 현재 제출 PDF에 gold label, prediction log, latency log, schema validation log, Top-5 채점표, practitioner survey 원자료가 포함되어 있지 않으므로 실제 성능 수치의 최종 판정은 보류한다.

본 최종평가는 단일 accuracy가 아니라 다음 5개 축으로 구성된다.

- 4-Layer 라벨 정확성
- End-to-End 시스템 지연시간
- JSON 구조 안정성
- 유사작 검색 적합성
- 실무자 수용성

2. 검토 원자료와 증거 수준

자료 ID	파일명	본 보고서에서 사용한 근거
S1	K-ART_LENS_최종발표자료.pdf	프로젝트 문제정의, 기능 흐름, 평가 방법, 물성 오류와 개선 방향
S2	K-ART_LENS_평가결과_슬라이드_보완안.pdf	실측 원자료 부재, KPI 목표, 예시수치, 필요 로그 스키마, 문구 수정안
S3	K-ART_LENS_최종발표보고서.pdf	보완 원칙, 평가 기준표, 산식, 결과 입력 템플릿, 품질관리 절차
S4	K-ART_LENS_최종발표보고서_보완본.pdf	통합 보완본의 논리 구조와 제출본 구성 방향

증거 수준	정의	본 보고서 처리
Level A - Raw-data verified	CSV, JSONL, 실행 로그에서 재산출 가능한 값	현재 PDF에는 원자료가 없으므로 최종 성능값은 보류
Level B - Calculation example	산식 설명을 위해 문서에 들어간 예시값	92.0%, 12.8초, 96.0%, 68.0%, 3.8/5.0은 예시로만 사용
Level C - Target / design value	사전에 설정된 목표치 또는 설계 기준	성공 기준으로 유지하되 달성 판정은 하지 않음

3. 시스템 개요와 4-Layer 파이프라인

K-ART LENS의 설계 목표는 큐레이터와 미술관 실무자가 작품 한 점마다 수작업으로 작성하던 상세 페이지, 소장품 DB 메타데이터, 검색 태그를 더 빠르고 일관된 구조로 생성하는 것이다. 원 발표자료는 작품당 20-40분 수준의 수기 작성 부담과 작성자별 용어 불일치 문제를 제시한다. [S3 p.3]

핵심 차별점은 단일 유사 이미지 검색이 아니라 검색축 자체를 4개로 분리한다는 점이다. 따라서 사용자는 '도상이 유사한 작품', '물성이 유사한 작품', '색채가 유사한 작품'처럼 실무 질문에 가까운 검색을 수행할 수 있다. [S1 p.3]

파이프라인 단계	내용	중빙 포인트
1. 입력 및 정규화	작품 이미지 업로드, 장변 384px 정규화, pHash 중복 제거	평가 표본 고정과 중복 제거의 전제
2. 4-Layer 특징 추출	도상, 기법, 물성, 색채를 독립 특징으로 추출	단일 임베딩 대비 설명가능 검색 구조
3. JSON 해석 생성	제한 JSON schema 기반 VLM 해석, 실패 시 retry/fallback	DB 적재 안정성과 재현성
4. FAISS 검색	4개 독립 index 또는 가중 검색으로 Top-5 유사작 도출	검색축별 relevance 평가 가능
5. 최종 출력	4-Layer JSON, 한국어 해설, 유사작 Top-5, CSV 내보내기	미술관 DB 업무 연결

4. 연구목표와 성공판정 기준

성공 기준은 결과를 본 뒤 사후적으로 조정하는 값이 아니라, 원 발표자료와 보완안에서 확인되는 사전 목표치로 유지한다. 단, 목표치가 존재한다는 사실과 목표를 달성했다는 판정은 분리한다.

평가영역	핵심지표	목표	현재 판정
4-Layer	색채 일치율	>= 90%	실측 원자료 미첨부 - 보류
4-Layer	물성 일치율	>= 80%	실측 원자료 미첨부 - 보류
4-Layer	기법 일치율	>= 65%	실측 원자료 미첨부 - 보류
4-Layer	도상 일치율	>= 55%	실측 원자료 미첨부 - 보류
시스템 안정성	P95 End-to-End latency	<= 15 sec	latency_log.csv 미첨부 - 보류
시스템 안정성	JSON 1차 schema pass rate	>= 95%	schema_validation_log.csv 미첨부 - 보류
검색 품질	Top-5 명확 관련성	>= 60%	top5_relevance_eval.csv 미첨부 - 보류
현장 적용성	실무자 Likert 평균	>= 3.5 / 5.0	practitioner_survey.csv 미첨부 - 보류

5. 실험 데이터셋 및 평가 단위

원 발표자료는 큐레이터가 직접 4-Layer 라벨을 작성한 작품 100점 규모의 gold set을 평가 기준으로 설명한다. 그러나 현재 확보된 PDF에는 100개 artwork_id 목록과 gold_labels.csv 자체가 첨부되어 있지 않다. 따라서 N=100은 명목 평가규모 또는 예시 산식의 분모로만 다루며, 실측 분모로 확정하지 않는다. [S2 p.1]

구분	필수 필드	역할
Gold label	artwork_id, iconography_gold, technique_gold, materiality_gold, color_gold	큐레이터 정답
Prediction	artwork_id, iconography_pred, technique_pred, materiality_pred, color_pred	모델 출력
Matching key	artwork_id	정답과 예측의 primary key
Version metadata	dataset_version, model_version, prompt_version, schema_version	재현성과 audit trail

6. 실험 실행 프로토콜

최종 측정은 sample lock 이후 같은 작품 목록에 대해 gold label, prediction, latency, schema, retrieval, practitioner survey를 독립 저장하는 방식으로 수행한다.

Step	절차	품질관리 목적
1	평가표본 고정	모델 개선 이후 테스트 작품 교체 방지
2	Curator gold label 생성	모델 출력을 보지 않은 blind 정답 구축
3	모델 추론 및 로그 저장	predictions.jsonl, latency_log.csv, schema_validation_log.csv 확보
4	Gold-Prediction matching	artwork_id 기준 결합
5	4-Layer accuracy 계산	층위별 일치 건수와 평가 가능 건수 산출
6	Latency 계산	upload_started_at에서 card_render_done_at까지 P95 산출
7	JSON 안정성 계산	first_pass_valid 기준 schema pass rate 산출
8	Retrieval evaluation	Top-5 결과를 0, 1, 2점으로 큐레이터 평가
9	Practitioner evaluation	실무자 5명 blind Likert 평가
10	결과 동결	모델, prompt, schema, FAISS index version 고정

7. 정량 및 정성 평가 방법

7.1 4-Layer 라벨 정확성

각 작품 i 에 대해 prediction과 gold label을 정규화한 뒤, 단일 라벨은 $\text{normalize}(\text{pred}_i) == \text{normalize}(\text{gold}_i)$, 다중 라벨은 $\text{set}(\text{pred}_i) == \text{set}(\text{gold}_i)$ 를 기본 판정식으로 사용한다. 발표용 주지표는 strict exact match이며, 필요한 경우 Jaccard similarity를 보조지표로 병기한다. [S3 p.5]

$$\text{Accuracy}(\text{layer}) = \text{일치 작품 수} / \text{평가 가능 작품 수} \times 100$$

7.2 시스템 안정성

실무 시스템은 평균 처리시간보다 tail latency가 중요하므로 upload_started_at에서 card_render_done_at까지의 경과시간을 정렬해 P95를 산출한다. JSON 안정성은 첫 번째 VLM 출력이 schema를 통과했는지 first_pass_valid로 계산한다.

지표	산식	목표	근거 로그
P95 latency	$\text{percentile}_{95}(\text{card_render_done_at} - \text{upload_started_at})$	$\leq 15 \text{ sec}$	latency_log.csv
JSON first-pass	$\text{first_pass_valid 수} / \text{최초 생성 JSON 수} \times 100$	$\geq 95\%$	schema_validation_log.csv
Final validity	$\text{final_valid 수} / \text{전체 실행 수} \times 100$	운영 보조지표	schema_validation_log.csv
Fallback rate	$\text{fallback_used 수} / \text{전체 실행 수} \times 100$	운영 보조지표	predictions.jsonl

7.3 검색 품질 및 실무 수용성

유사작 Top-5는 cosine similarity만으로 성능을 주장하지 않고, 큐레이터가 0점(무관), 1점(약한 관련), 2점(명확한 관련)으로 평가한다. 본 보고서는 보수적으로 2점만 relevant로 계산한다. 실무 수용성은 실무자 5명의 5점 Likert 평균으로 측정한다. [S2 p.2]

정성 지표	주지표	목표	주의
Top-5 relevance	$2\text{점 판정 수} / \text{전체 Top-5 평가 항목 수} \times 100$	$\geq 60\%$	1점을 관련으로 포함할 경우 기준을 명시해야 함
Practitioner acceptance	Likert 점수 합 / 응답자 수	$\geq 3.5 / 5.0$	mean, sd, median, min, max 병기 권장

8. 수치증빙 결과표와 예시수치 검증

중요

아래 표의 Result는 현재 제출용 확정값이 아니다. 원시 로그가 없으므로 실제 성능은 보류한다. 예시 숫자는 산식 설명용 Level B로만 사용한다.

KPI	Target	Current Evidence	Final
Color accuracy	$\geq 90\%$	Raw data 없음	보류
Materiality accuracy	$\geq 80\%$	Raw data 없음	보류
Technique accuracy	$\geq 65\%$	Raw data 없음	보류
Iconography accuracy	$\geq 55\%$	Raw data 없음	보류
P95 latency	≤ 15 sec	Raw log 없음	보류
JSON first-pass	$\geq 95\%$	Raw log 없음	보류
Top-5 relevance	$\geq 60\%$	채점 원본 없음	보류
Practitioner score	≥ 3.5	설문 원본 없음	보류

8.1 계산 예시의 지위

지표	계산 예시	결과	해석
색채	92 / 100	92.0%	실측값 아님 - 산식 입력 예시
P95 latency	percentile95(log)	12.8 sec	실측 로그 미첨부 - 산식 예시
JSON first-pass	96 / 100	96.0%	실측값 아님 - 산식 입력 예시
Top-5 relevance	68 / 100	68.0%	실측값 아님 - 산식 입력 예시
실무 수용성	n=5	3.8 / 5.0	설문 원자료 미첨부 - 산식 예시

8.2 예시 비율의 통계적 보조분석

N=100이라고 가정하면 Wilson 95% confidence interval은 색채 92/100 -> 약 85.0-95.9%, JSON 96/100 -> 약 90.2-98.4%, Top-5 68/100 -> 약 58.3-76.3%이다. 이 분석 역시 예시 수치에 대한 보조 해석이며, 실제 표본과 원시 데이터가 확보되기 전에는 최종 성능 CI가 아니다.

9. 물성 성능 개선 실험과 오류분석

초기 오류 사례 중 중요한 유형은 한국화의 장지, 분채 계열을 acrylic/oil 계열로 오인하는 물성 오류였다. 원 발표자료는 한국화 및 전통 재료군 20종을 제한 vocabulary로 prompt에 주입해 자유 생성을 분류 문제로 축소하는 개선을 시도했다고 설명한다. 단, before/after raw accuracy는 현재 첨부되어 있지 않다. [S1 p.4]

Ablation 단계	측정값	필요 증거
Baseline	__%	vocabulary 적용 전 predictions.jsonl
+ Material Vocabulary	__%	동일 작품군에 대한 vocabulary 적용 후 로그
+ Rule Fallback	__%	fallback_used 및 final_valid 기록
Final	__%	gold_labels.csv와 최종 predictions.jsonl 매칭

Materiality 개선폭 = Accuracy(proposed) - Accuracy(baseline)

9.1 오류분석 Taxonomy

Error code	정의	대표 개선방향
E1. Material hallucination	장지, 한지, 분채를 acrylic/oil 계열로 예측	한국화 재료 vocabulary 강화
E2. Iconographic ambiguity	추상, 반추상 작품의 도상 의미를 과도하게 단정	uncertainty label 추가
E3. Technique-Material confusion	제작기법과 재료를 동일 개념으로 취급	ontology 분리
E4. Color simplification	다색 작품을 dominant color 하나로 축약	multi-color label
E5. Schema error	필드 누락, enum 외 값, JSON syntax 오류	constrained decoding
E6. Retrieval mismatch	전체 이미지 유사성은 높으나 선택 검색축에서는 관련성이 낮음	layer weight 조정

10. Raw Data Package와 재현성

최종 성능 수치는 다음 여섯 종류의 원시 파일에서 독립적으로 역산 가능해야 한다. 이 파일들이 확보되기 전에는 결과표의 PASS/FAIL을 확정하지 않는다. [S2 p.2-3, S3 p.7]

파일	증빙 내용	핵심 컬럼
gold_labels.csv	큐레이터 정답	artwork_id, iconography_gold, technique_gold, materiality_gold, color_gold
predictions.jsonl	모델 4-Layer 출력과 version	run_id, artwork_id, *_pred, fallback_used, prompt_version, model_version
latency_log.csv	단계별 처리시간	upload_started_at, feature_extracted_at, schema_validated_at, search_completed_at, card_render_done_at
schema_validation_log.csv	1차 및 최종 JSON 유효성	first_pass_valid, retry_count, final_valid, validation_error
top5_relevance_eval.csv	Top-5 큐레이터 관련도 평가	query_artwork_id, search_axis, rank, result_artwork_id, curator_score_0_2
practitioner_survey.csv	실무자 5인 평가	reviewer_id, blind_condition, likert_score_1_5, comment

10.1 Reproducibility checklist

- 평가 전에 sample과 artwork_id를 고정했는가
- pHash 중복 제거와 실패 run 처리 기준을 기록했는가
- gold label 작성자가 prediction을 보지 않았는가
- 동의어 normalization rule이 사전에 정의되었는가
- model, prompt, schema, FAISS index version을 남겼는가
- 동일 raw log로 동일 결과를 재계산할 수 있는가

11. 최종 수행평가와 발표 문안

평가 항목	판정	근거
기술 구현	완료	4-Layer 특징 추출, JSON 구조화, fallback, FAISS 검색, CSV 출력까지 MVP 구조 정의
평가방법론	완료	accuracy, latency, JSON validity, retrieval relevance, practitioner acceptance의 다중 평가체계
평가 threshold	완료	모든 주지표에 사전 성공 기준 존재
Raw-data 기반 실측 검증	검증 대기	6종 Raw Data Package 미첨부
종합판정	MVP 구현 및 평가체계 완료, 실측 증빙 패키지 검증 대기	근거 없는 성능값을 생성하지 않음

최종 연구자 판단

K-ART LENS의 다음 단계는 더 그럴듯한 성능 수치를 만드는 것이 아니라, 모든 성능 수치를 다시 계산할 수 있는 증거를 남기는 것이다. 이 검증 구조가 완성되는 순간 K-ART LENS는 데모에서 실증 시스템으로 전환된다.

11.1 최종 발표용 90초 스크립트

평가에서는 단일 정확도 하나로 시스템을 설명하지 않았습니다. 큐레이터 골드셋과 모델 결과를 작품 ID 기준으로 매칭해 도상, 기법, 물성, 색채 네 개 레이어를 각각 평가하도록 설계했습니다. 목표는 색채 90%, 물성 80%, 기법 65%, 도상 55%입니다.

둘째, 실제 사용자 경험을 확인하기 위해 업로드부터 카드 렌더링 완료까지의 P95 처리시간을 측정하며 목표를 15초 이내로 정의했습니다. 셋째, DB 적재 안정성을 평가하기 위해 첫 번째 모델 출력이 JSON schema를 바로 통과하는 비율을 측정하고 95% 이상을 목표로 설정했습니다.

넷째, 유사작 검색은 cosine similarity만으로 평가하지 않고 큐레이터가 Top-5를 0점부터 2점까지 블라인드 평가하도록 했습니다. 특히 가장 보수적으로 2점, 즉 명확히 관련 있음만 relevant로 계산합니다.

마지막으로 실제 실무자 5명이 결과를 검수해서 업무에 사용할 의향이 있는지를 5점 척도로 평가하도록 했습니다. 이번 평가 보완의 핵심은 결과 숫자와 그 숫자를 증명하는 원시 데이터를 하나의 evidence chain으로 묶은 것입니다.

따라서 gold label, prediction, latency, schema validation, Top-5 evaluation, practitioner survey의 여섯 종류 로그를 보관하면 모든 발표 숫자를 다시 계산할 수 있습니다. 이것이 K-ART LENS가 단순한 AI 데모를 넘어 검증 가능하고 재현 가능한 미술관 AI 시스템으로 발전하기 위한 핵심입니다.

부록 A. 최종 실측치 확정표

KPI	Numerator	Denominator	Result	Target	Final
Color	—	—	__%	>= 90%	PASS / FAIL / 보류
Materiality	—	—	__%	>= 80%	PASS / FAIL / 보류
Technique	—	—	__%	>= 65%	PASS / FAIL / 보류
Iconography	—	—	__%	>= 55%	PASS / FAIL / 보류
P95 Latency	-	-	__ sec	<= 15 sec	PASS / FAIL / 보류
JSON First-pass	—	—	__%	>= 95%	PASS / FAIL / 보류
Top-5 Relevant	—	—	__%	>= 60%	PASS / FAIL / 보류
Practitioner	score sum	5	__ / 5.0	>= 3.5	PASS / FAIL / 보류

부록 B. 필수 데이터 파일 스키마

파일	필수 컬럼
gold_labels.csv	artwork_id, image_path, curator_id, iconography_gold, technique_gold, materiality_gold, color_gold
predictions.jsonl	run_id, artwork_id, iconography_pred, technique_pred, materiality_pred, color_pred, fallback_used, prompt_version, model_version
latency_log.csv	run_id, artwork_id, upload_started_at, image_normalized_at, feature_extracted_at, schema_validated_at, search_completed_at, card_render_done_at, status, error_code
schema_validation_log.csv	run_id, artwork_id, first_pass_valid, retry_count, final_valid, validation_error
top5_relevance_eval.csv	query_artwork_id, search_axis, rank, result_artwork_id, curator_score_0_2, curator_comment
practitioner_survey.csv	reviewer_id, blind_condition, likert_score_1_5, comment

부록 C. 검토 원자료 목록

본 제출본 작성에는 아래 원자료와 사용자 제공 통합 원고를 함께 사용했다. PDF 원문에서 확인 가능한 내용은 페이지 단위로 본문에 [S# p.#] 형식으로 표기했다.

ID	파일명	확인한 핵심 내용
S1	K-ART_LENS_최종발표자료.pdf	기능 흐름, 평가 방법, 기존 서비스 대비 차별점, 물성 오류와 개선 시도
S2	K-ART_LENS_평가결과_슬라이드_보완안.pdf	실측 원자료 부재, 예시수치, 원시 데이터 스키마, 문구 수정 권장안
S3	K-ART_LENS_최종발표보고서.pdf	보완 원칙, KPI table, 산식, 품질관리, 결과 입력 템플릿
S4	K-ART_LENS_최종발표보고서_보완본.pdf	최종 보고서형 구성과 재현성 중심 서술

최종 성능 확정 조건
위 부록 A의 모든 숫자가 해당 raw-data 파일에서 독립적으로 재산출 가능할 것. 이 조건이 충족될 때에만 발표자료의 Result와 Final 열을 PASS/FAIL로 확정한다.