EXPERT REVIEW · 심 사 평 가 서

NULLBANK 연구보고서 심사평가서

「보고편향 보정을 통한 국가 R&D 음성결과 회수 프레임워크: 다중 에이전트 아키텍처, 실패 온톨로지, 그리고 RAS 추정량」에 대한 기술·방법론·구현가능성 종합 심사

제출자 추병곤 · 2026 국가과학기술연구회 NAIS AI 해커톤 제출본 (2026년 8월)

FINAL VERDICT

76 / 100 · 등급 A– · 본선 진출 적격

기획 부문은 제출작 중 최상위권이다. 문제 재정의(과제→실험), 회수 기반 접근, Δ 우선 산출, E4 반전, Abstain 게이트는 이 분야에서 흔히 보이지 않는 성숙도를 보여준다. **그러나 이 보고서의 운명은 기획이 아니라 본선 19시간에서 결정된다.** 현재 스코프는 명백한 초과 설계이며, RAS 식별 전략에는 심사장에서 반드시 노출될 구조적 결함이 하나 있다. 아래 §4의 C1·C2를 해결하면 수상권, 방치하면 중위권이다.

심사자 · AI 해커톤 심사 경력 30년 (기술심사 트랙)

심사 기준 · 문제정의 20 / 방법론 20 / 구현가능성 20 / 데이터·검증 15 / AI윤리 15 / 임팩트 10

문서 구성 · 총평 → 채점 → 강점 → 치명적 결함 → 리스크 → 재설계 권고 → 예상질문 → 개선레버

1 심사 총평

먼저 분명히 해 둔다. 나는 30년간 이런 종류의 제출본을 수천 건 읽었고, 그중 90%는 "LLM으로 무언가를 검색해 주는 시스템"이었다. 이 보고서는 그 범주에 속하지 않는다. 이 제출본은 **측정 대상 자체를 재정의**했고, 재정의로부터 아키텍처를 연역했으며, 자기 시스템이 성공할 경우 발생할 해악(탐색 붕괴)까지 설계에 내장했다. 이 세 가지를 동시에 한 제출본은 한 해에 한두 건 나온다.

동시에 나는 심사자로서 이 보고서에 가장 냉정한 문장을 남겨야 한다. **이 보고서는 훌륭한 정책 제안서이지만, 아직 검증 가능한 시스템 명세서는 아니다.** 제안된 핵심 방법론(RAS)은 §3.4에서 미술시장 문제와의 "동형성"을 주장하는데, 두 문제는 결정적인 지점에서 동형이 아니다. 그 비동형성이 해결되지 않으면 6장 전체가 심사장에서 무너진다. 이것이 §4에서 다룰 C1이다.

1.1 세 문장 요약

- **가장 강한 것** — §6.4의 보정폭 Δ. 점추정 대신 순위 정보를 산출물로 삼은 판단은 이 보고서에서 가장 성숙한 대목이며, 심사자가 "그 숫자를 어떻게 믿느냐"고 물었을 때의 유일한 방어선이다. 다만 그 강건성 주장 자체가 아직 논증되지 않았다(C2).
- **가장 약한 것** — 8장 구현계획. 도메인(소재 합성)과 데이터 소스(PubMed Central OA)가 정합하지 않는다. 이 하나로 "문헌 300–500편 확보"라는 19:00 마일스톤이 붕괴할 수 있다(C3).
- **가장 아까운 것** — 특허 명세서의 **비교예(comparative example)**가 데이터 소스 목록에 없다. 국내 음성결과의 최대 광맥이자 §11.3의 "영어권 편중" 한계를 직접 해소하는 소스인데 언급조차 없다(§6).

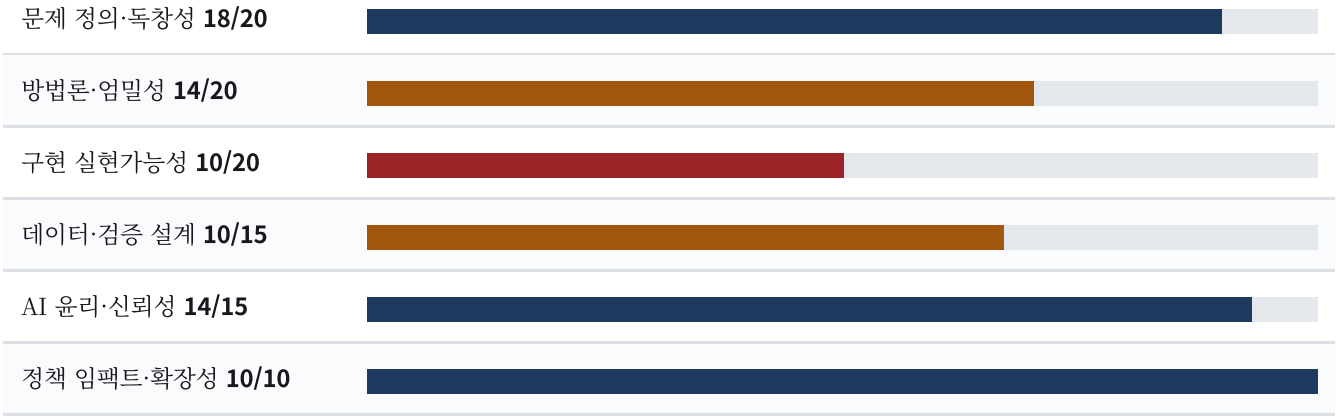
1.2 이 제출본의 실제 경쟁 상대

해커톤 심사에서 이 제안의 경쟁 상대는 다른 "음성결과 시스템"이 아니다. 19시간 안에 화려하게 돌아가는 데모다. 이 제안은 본질적으로 검증에 시간이 드는 인프라 제안이며, 발표 5분에서 시각적 임팩트로 이길 수 없다. 따라서 전략은 하나뿐이다. **"동작합니다"가 아니라 "검증했습니다"로 이기는 것.** §8.3의 06:00–08:00 버퍼를 협상 불가로 못 박은 저자의 판단은 정확하다. 다만 그 두 시간에 무엇을 산출할지가 지금은 "CAP@k 수치 1개"로만 적혀 있는데, 통계적으로 무의미한 수치 1개는 심사자에게 오히려 감점 요인이다(R4).

2 항목별 채점

심사 항목	배점	획득	채점 사유
문제 정의 · 독창성	**20**	**18**	성공률 논쟁을 "측정 단위 불일치"로 재정식화한 §1.2는 이 보고서 전체를 지탱하는 축이며, 평가제도를 건드리지 않고 문제에 접근하는 정치적 경로까지 확보했다. 삼중 절단 정식화(§3.1)는 아키텍처를 연역적으로 도출하는 데 실제로 기능한다. −2: 회수 기반 접근이라는 핵심 차별점을 표 1에서 "JNRBM 대비"로만 대비시켜 특허·규제 제출자료 등 미탐색 소스군을 놓쳤다.
방법론 · 이론 엄밀성	**20**	**14**	선택모형 도입과 포획-재포획 교차검증이라는 이중 경로 설계는 정석이다. Δ 우선 원칙(§6.4)과 증거등급 E1-E4는 독창적이고 방어력이 높다. −6: (i) 선택모형의 risk set 부재 문제 미해결(C1), (ii) Δ 순위 강건성이 주장에 머묾(C2), (iii) 포획-재포획의 출처 독립성 가정이 명백히 위배됨(R1), (iv) E3 가중치 0.3의 근거 부재(R2).
본선 구현 실현가능성	**20**	**10**	최대 감점 구간. 19시간에 3에이전트 + 온톨로지 태깅 + 비식별화 + 벡터인덱싱 + RAS 추정 + Abstain 게이트 + 후향검증 + UI를 모두 넣는 계획은 경험적으로 완주 확률 30% 미만이다. 도메인-데이터소스 불일치(C3)와 arXiv 원문 오프셋 정합 비용(R3)이 초반 5시간을 잠식할 위험이 크다. §7의 재설계안 채택 시 회복 가능.
데이터 확보 · 검증 설계	**15**	**10**	3단계 로드맵(§10.1)에서 1단계가 다른 단계와 독립적으로 작동한다는 점을 명확히 한 것은 설득력이 높다. 시간분할 후향검증(§7.4)은 이 제안을 반증 가능하게 만드는 핵심 장치다. −5: KNEG의 NRR은 전문가 주석 골드셋을 전제하는데 본선 내 확보 계획이 없어 사실상 산출 불가(R4). 50개 조건 후향검증은 검정력이 없다.
AI 윤리 · 신뢰성	**15**	**14**	이 항목은 사실상 만점권이다. Abstain 게이트, 근거 포인터 강제, HAR-AbR 곡선 병기, 낙인화 방지 거버넌스 조항, 원문 미복제 설계, 출처 자기공개(§9.5)까지 윤리 요건을 사후 첨부가 아니라 작동 조건으로 배치했다. −1: HAR이 잡지 못하는 실패 유형이 존재한다(R5).
정책 임팩트 · 확장성	**10**	**10**	§10.4의 "왜 NST·NAIS여야 하는가"는 이 보고서에서 가장 전략적으로 완성된 대목이다. 2026년 8월 출범한 자율실험실 협의체와의 시간축 상보성 논거는 경쟁이 아닌 보완으로 포지셔닝하며 심사 주체의 이해관계와 정확히 맞물린다. 감점 없음.
합계	**100**	**76**	**등급 A− · 기획 최상위권 / 구현 리스크가 최종 순위를 결정**

항목별 프로파일



해커톤 심사에서 “구현 실현가능성”은 사후 실적으로 재채점되는 유일한 항목이다. 본선 종료 시점에 end-to-end 시연이 성립하면 이 항목은 10 → 17까지 회복 가능하며, 그 경우 총점은 83점(A0)으로 수상권에 진입한다.

3 감점하지 말아야 할 것 — 확인된 강점

비판에 앞서 이 보고서가 확보한 것을 명시한다. 아래 다섯 항목은 개선 과정에서 **절대 희석되어서는 안 되는** 자산이며, 발표 5분에서도 이 순서로 보호되어야 한다.

S1 측정 단위의 하향 이동 — 논쟁을 우회하는 유일한 경로

"과제 성공률 99%와 실험 성공률 20%는 모순되지 않는다"(§1.2)는 명제는 단순하지만 이 영역의 5년치 교착을 한 문장으로 해소한다. 더 중요한 것은 그 실천적 귀결이다. 성공률 산정 방식을 바꾸자는 제안은 평가 이해관계를 즉시 건드리지만, 측정 단위를 내리자는 제안은 누구의 등급도 건드리지 않는다. 심사 주체가 정책 집행 기관일 때 이 차이는 채택 가능성 자체를 가른다.

S2 회수 기반 접근 — 20년 실패의 원인을 정확히 진단

§2.2의 진단, 즉 음성결과 저널의 실패 원인이 "지면 부재"가 아니라 "저술 노동 요구"라는 분석은 정확하다. JNRBM의 2017년 폐간은 그 실증이다. **연구자에게 아무것도 새로 쓰라고 요구하지 않는다**는 설계 원칙 1은 이 제안이 기존 시도들과 구조적으로 다른 이유이며, 심사장에서 "또 다른 실패 저널 아니냐"는 질문에 대한 완결된 답이다.

S3 Δ 우선 원칙 — 식별 가정에 대한 노출을 낮추는 설계

§6.4에서 RAS 점추정 대신 보정폭 Δ를 기본 표시 모드로 삼은 결정은 이 보고서에서 **가장 심사자 친화적인** 판단이다. "진짜 성공률은 31%"는 강한 식별 가정을 요구하지만, "이 구간은 문헌을 믿기 어렵고 저 구간은 비교적 정직하다"는 순위 정보만으로 성립한다. 방법론 심사에서 공격 표면을 스스로 줄인 드문 사례다. 다만 §4의 C2를 반드시 보강할 것.

S4 E4 반전 — 회피 도구를 설계 도구로 전환

"부재는 실패의 증거가 아니다"(설계 원칙 3)와 E4의 탐색 신호 전환은 이 시스템의 성격을 근본적으로 바꾼다. 경보만 내는 시스템은 연구를 위축시키지만, 미탐색 좌표를 제시하는 시스템은 연구를 확장한다. 더욱이 자율실험실의 획득함수가 요구하는 후보 집합이 정확히 E4 집합이라는 §5.3의 연결은 협의체 논의에 즉시 투입 가능한 기술적 접점이다. 발표에서 반드시 시연할 것(시나리오 C).

S5 탐색 붕괴의 자기 인식 — 수행적 되먹임을 아키텍처에 내장

§11.1은 이 보고서에서 지적 밀도가 가장 높은 절이다. "2015년 장비로 실패한 조건이 2027년 장비로는 성공할 수 있으나, 경보가 유지되는 한 아무도 시도하지 않으므로 시스템은 이를 영원히 학습하지 못한다"는 서술은 예측 시스템이 예측 대상에 개입할 때의 고전적 함정을 정확히 짚는다. ε-재탐색·시효 감쇠·역경보 갱신을 사후 대응이 아니라 구성 요소로 배치한 것도 옳다. 다만 ε-재탐색에는 제도적 짝이 없다(R6).

4 치명적 결함 — 해결 없이는 방어 불가

아래 세 항목은 "보완하면 좋은 것"이 아니라 **해결하지 않으면 심사장에서 무너지는 것**이다. 질문이 나올 가능성이 아니라 나올 것이 확실한 지점만 골랐다.

C1 선택모형에 risk set이 없다 — §3.4 동형성 주장의 붕괴점

§3.4는 미술시장 MOG와 국가 R&D가 "동일한 통계 모형의 재사용"이라고 주장한다. 구조적 직관은 옳다. 그러나 **추정 가능성의 관점에서 두 문제는 동형이 아니다.**

Heckman 계열 우도는 선택식 $S = 1[z'\gamma + u > 0]$의 $S = 0$ 항을 필요로 한다. 즉 선택되지 않은 개체의 존재와 그 공변량 z를 알아야 한다. 미술시장에서는 이것이 성립한다. 출품되지 않은 작품도 카탈로그 레조네·소장 이력·작가별 총 제작량으로 존재가 관측된다. 선택의 모집단, 즉 risk set이 실재한다.

반면 국가 R&D에서 미보고 실험은 **존재 자체가 미관측**이다. 어떤 조건이 시도되었으나 보고되지 않았다는 사실을 우리는 원리적으로 알 수 없다 (그것이 바로 §3.1의 $T_1 \cdot T_2$ 정의다). 그렇다면 $S = 0$ 관측치를 한 건도 구성할 수 없고, 이변량 프로빗의 우도함수를 쓸 수 없다. §6.2는 이 문제를 다루지 않은 채 최대우도 추정으로 넘어간다. **이것이 이 보고서의 유일한 논리적 공백이며, 방법론 심사자는 이 지점을 반드시 짚는다.**

> **권고 C1 — 분석 단위를 "실험"에서 "조건 셀"로 승격하라**
>
> 해법은 이미 이 보고서 안에 있다. 저자가 E3(구조 추론)로 정의한 SI 최적화 격자의 셀이 곧 risk set이다. 요인설계 격자에 명시된 셀은 "시도되었음이 문서로 확정된" 단위이며, 그중 결과가 본문으로 이월된 셀이 $S = 1$, 이월되지 않은 셀이 $S = 0$이다. 이렇게 두면:
>
> - 선택의 모집단이 문서 내부에서 **실재적으로 구성**된다 — 우도함수가 성립한다.
> - 배제제약 후보가 훨씬 강해진다. 게재지의 SI 분량 정책은 셀 단위 노출에 직접 작용하되 개별 셀의 화학과는 무관하다. §6.3 표 6에서 "비교적 강함"으로 평가된 도구가 셀 단위에서는 사실상 준실험적 도구가 된다.
> - E3가 "약한 근거 등급"에서 **식별 전략의 중핵**으로 승격된다. 보고서의 서사도 강해진다.

심사자 메모 · 이 재정식화는 6장을 다시 쓰는 수준의 변경이 아니다. §6.1의 정의문에서 "실험 i"를 "조건 셀 c"로 바꾸고, §3.1의 Ω를 "문서화된 조건 격자의 합집합"으로 한정하면 나머지 수식은 그대로 살아난다. 오히려 §3.1의 T_1(원리적 소실)과 T_2(부분 관측)의 경계가 선명해진다.

C2 Δ의 순위 강건성은 결과가 아니라 가정이다

§6.4의 핵심 주장은 "RAS 절대 수준은 배제제약에 민감하지만 Δ의 조건 간 순위는 강건하다"이다. 이 주장은 이 보고서 전체의 실용적 가치를 지탱하는데, 정작 논증이 없다. 그리고 나는 이 주장이 **체계적으로 위협받는 경로**를 하나 제시할 수 있다.

결과변수 Y는 문헌에서 직접 관측되지 않는다. RECOVERY 에이전트가 언어모델로 추출한 라벨이다. 즉 종속변수에 오분류(misclassification)가 존재한다. 프로빗에서 종속변수 오분류는 계수를 감쇠시키며, 오분류율 $\pi(x)$가 조건공간 전역에서 균일하지 않으면 편향의 방향이 조건별로 달라진다. 그런데 §3.3이 스스로 지적하듯, 편향이

큰 구간은 "탐색이 얕은 변방 조건"이다. **그리고 추출 오분류율이 가장 높은 구간도 정확히 그 변방 조건이다** — 서술이 짧고, 표준 어휘가 정립되지 않았고, 조건 명명이 비정형적이기 때문이다.

Δ가 큰 구간과 추출 오류가 큰 구간이 겹친다면, Δ의 조건 간 순위는 "보고편향의 순위"가 아니라 "추출 난이도의 순위"를 재현하고 있을 수 있다. 이 가능성을 배제하지 못하면 §6.4의 실무적 함의 전체가 무효화된다.

권고 C2 — 오분류율 π(x)를 추정하고 Δ에 붙여 보고하라

- **서브샘플 재라벨링.** 전체 레코드의 5–10%를 층화 추출(잘 연구된 조건 : 변방 조건 = 1:1)하여 수작업 재라벨링하고, 층별 오분류율 π를 산출한다. 본선 스코프에서 100건이면 충분하다.
- **Δ 위에 오분류 밴드 표시.** Δ를 단일 값이 아니라 $[\Delta_{하한}, \Delta_{상한}]$ 구간으로 표시하고, 그 폭을 π로 결정한다. 구간이 0을 포함하면 신뢰도 등급을 부여하지 않고 기권한다.
- **발표 문장.** "Δ 순위가 추출 난이도를 반영하는 것 아니냐"는 질문은 반드시 나온다. 그때 "층화 재라벨 100건으로 오분류율을 측정했고, Δ 상위·하위 구간 간 오분류율 차이는 유의하지 않았습니다"라고 답할 수 있으면 이 항목은 감점이 아니라 가점이 된다.

C3 도메인과 데이터 소스가 정합하지 않는다 — 19:00 마일스톤 붕괴 위험

§8.1은 시연 도메인으로 **소재 합성 또는 촉매**를 권장한다. §8.2는 문헌 수집원으로 **OpenAlex · PubMed Central OA · arXiv**를 명시한다. 이 두 절은 서로 충돌한다.

소스	제공 범위	소재·촉매 도메인에서의 실효성
OpenAlex	서지 메타데이터 중심, 전문(full text)은 대부분 미제공	불가. Methods·SI 본문이 없으면 RECOVERY가 작동할 대상 자체가 없다. OpenAlex는 탐색·연결에는 유용하나 회수 대상 코퍼스가 아니다.
PubMed Central OA	생의학 중심 전문 OA (JATS XML)	도메인 불일치. 소재 합성 논문 커버리지가 낮다. 반면 XML 구조화 품질은 최상이라 근거 오프셋 부착에는 가장 유리하다.
arXiv	물리·재료 일부 프리프린트	부분 가능. 다만 SI 첨부율이 낮고, LaTeX/PDF 원문에서 char_offset 정합을 맞추는 비용이 크다(R3).

권고 C3 — 두 갈래 중 하나를 본선 전에 확정하라

선택지 A (안전) — 도메인을 소스에 맞춘다. 시연 도메인을 세포배양·형질전환·발현 최적화로 변경하고 PMC OA JATS를 전면 활용한다. JATS는 절(section) 태그가 명시적이라 "Methods에 등장하나 Results로 이월되지 않은 조건" 탐지가 규칙 기반으로도 가능하며, 오프셋 부착이 사실상 무료다. NFO 표 4에 이미 생명과학 예시 어휘가 준비되어 있어 온톨로지 작업도 즉시 가능하다.

선택지 B (야심) — 소스를 도메인에 맞춘다. 소재·촉매를 유지하되 수집원을 ChemRxiv + 학위논문 리포지터리(RISS·dCollection 등) + protocols.io로 교체한다. §4.2가 스스로 지적했듯 학위논문은 지면 제약이 없어 실패 서술 밀도가 가장 높다. 다만 PDF 파싱 비용이 A안의 3배 이상이며, 본선 첫 2시간을 파서에 소모할 위험이 있다.

심사자 판단 · 19시간 제약에서 나는 **A안을 강권한다**. 도메인 이식성은 NFO 상위 5축의 불변성으로 논증하면 되고(§8.1이 이미 그렇게 설계했다), 시연은 완결도로 이긴다. “왜 소재가 아니라 생명과학이냐”는 질문에는 “근거 오프셋 검증 가능성이 가장 높은 도메인을 선택했고, 이는 Abstain 게이트의 신뢰성을 가장 엄격하게 시연하기 위한 결정”이라고 답하면 오히려 설계 성숙도로 읽힌다.

5 중대 리스크 — 질문받으면 감점되는 지점

R1 포획-재포획의 독립성 가정이 명백히 위배된다

§6.5는 학술 문헌 · 프로토콜 저장소 · 학위논문을 "서로 독립적인 출처"로 두고 Lincoln-Petersen 추정을 적용한다. 그러나 이 세 출처는 **동일한 연구자가 동일한 실험을 서로 다른 매체에 기록한 결과**인 경우가 지배적이다. 포획 확률이 강하게 양의 상관을 가지면 $\hat{N}$은 심각하게 과소추정되고, 암흑비 DR는 낙관적으로 나오며, 결국 "보정이 필요 없다"는 잘못된 결론에 도달한다. 교차검증 장치가 오히려 편향을 은폐하는 방향으로 작동하는 구조다.

- **최소 조치** — 출처를 매체가 아니라 연구자군으로 재정의한다. 저자 중복이 있는 레코드 쌍은 동일 포획으로 병합한 뒤 추정한다.
- **권장 조치** — 3출처 로그선형 모형으로 출처 간 상호작용 항을 명시적으로 추정하거나, 포획 이질성을 허용하는 Chao 하한 추정량을 사용한다. 하한이라도 "최소 이만큼은 암흑"이라는 진술이 가능해지며, 이는 발표에서 오히려 강한 문장이 된다.

R2 E3 가중치 0.3은 하이퍼파라미터가 아니라 추정 대상이다

"SI 격자에서 후속 단계로 이월되지 않은 셀"을 실패로 추론하는 것은 연구자는 성공한 셀만 이월한다는 가정에 의존한다. 그러나 이월하지 않는 이유는 최소 네 가지다 — (a) 실패, (b) 자원 소진, (c) 관심 이동, (d) **특허 전략상 의도적 은닉**. 소재 분야에서 (d)는 드물지 않다. 표 5의 가중치 0.3에는 출처가 없다.

> **권고**
>
> §7.4 후향검증에서 **증거등급별 CAP@k를 분해 보고**하고, E3 가중치를 그 사후 정밀도 비율로 역산하라. 그러면 0.3은 임의값이 아니라 추정치가 된다. 이 한 가지 변경으로 표 5는 "설계자의 감"에서 "데이터로 교정되는 파라미터"로 승격되며, KNEG의 존재 이유도 강화된다.

R3 조건벡터 정규화가 실질적 병목인데 대응이 없다

§11.3은 "조건의 미묘한 차이를 동일 조건으로 잘못 병합할 위험"을 인정하고 전문가 표본 검수를 방어선으로 제시한다. 부족하다. 이 시스템에서 **"동일 조건" 판정 실패는 곧 CAP@k 붕괴**이며, 실패 경로는 구체적이다 — 전구체의 상표명/IUPAC 혼재, 단위 불일치(mol% vs wt%), 그리고 무엇보다 암묵 파라미터 (글로브박스 산소 농도, 스핀코팅 램프율, 실제 승온 프로파일)의 미기재.

더 중요한 것은 이 실패가 **Abstain 게이트를 통과한다**는 점이다. §4.5의 게이트는 (i) 근거 문장의 실재, (ii) 온톨로지 일치, (iii) 식별자 검증을 확인하지만 조건 매칭의 타당성은 확인하지 않는다. 근거는 진짜이고 태깅도 맞는데 **내 실험과 무관한 조건의 실패**가 경보로 나가는 경우가 여기서 발생한다.

권고 — 게이트 조건 (iv)와 신규 지표 하나를 추가하라

- 스키마에 `condition_match_confidence` 필드를 신설하고, 게이트 조건 (iv) 매칭 신뢰도 $\geq \tau$를 추가한다.
- 정규화 계층을 명시한다 — 화합물은 PubChem CID, 단위는 UCUM 변환, 미기재 파라미터는 결측으로 명시 표기하고 유사도 계산에서 제외한다.
- KNEG에 지표 **MMR(Mismatched-Match Rate, 무관 경보율)**을 추가한다. HAR은 "근거 없는 경보"를 잡지만 "근거 있으나 무관한 경보"는 못 잡는다. 이 구멍을 스스로 메우고 지표로 공개하는 것이 심사에서 훨씬 유리하다.

R4 KNEG 골드셋 확보 계획이 없고, 후향검증에 검정력이 없다

NRR은 "전문가 주석 대비 재현율"로 정의되는데(표 7), 19시간 내 전문가 주석자 확보 계획이 없다. NRR은 본선에서 산출 불가능하다. 또한 §7.4의 "단일 도메인 50개 조건 축소판"으로는 경보군 대 대조군의 사후 실패율 차이가 어떤 유의수준에도 도달하지 않는다. 심사자에게 통계적으로 무의미한 수치 1개를 제시하는 것은 아무 수치도 제시하지 않는 것보다 나쁘다.

권고 — 골드셋을 "만들지 말고 빌려라", 검정은 쌍 설계로 바꿔라

- **역방향 골드셋.** 이미 실패를 명시적으로 서술한 문헌군 — JNRBM 아카이브, PLOS ONE Missing Pieces 컬렉션, Journal of Articles in Support of the Null Hypothesis — 을 정답 레이블로 사용한다. 이 문서들은 음성결과의 존재가 확정되어 있으므로 **재현율의 하한**을 주석 없이 측정할 수 있다. 본선 당일 확보 가능하다.
- **1:1 쌍 매칭 부호검정.** 경보 조건마다 조건공간 근접·문헌 성공률 유사한 대조 조건을 매칭해 25쌍을 만들고, 사후 실패 여부의 부호검정으로 보고한다. 25쌍 중 19쌍 이상 일치하면 $p < 0.05$다. 19시간 안에 도달 가능한 유일한 유의성이다.
- **대안** — 경보 점수의 사후 실패 예측 AUC와 DeLong 신뢰구간을 함께 보고한다. $n = 50$에서도 구간 제시는 정직하고, 심사자는 구간을 좋아한다.

R5 HAR = 0이어도 시스템은 틀릴 수 있다

§9.2는 "무근거 추론 0건"을 설계 목표로 삼고 HAR로 상시 측정한다. 좋다. 그러나 HAR은 근거의 존재만 측정하며 근거의 적합성은 측정하지 않는다. R3에서 지적한 무관 매칭, 그리고 근거 문장이 실제로는 다른 조건에 관한 서술인 경우가 HAR 지표를 통과한다. 지표 체계가 자기 실패 유형을 전부 덮지 못한다는 것은 방법론 심사에서 반드시 지적된다. MMR 추가(R3)로 함께 해소하라.

R6 ε-재탐색에 제도적 짝이 없다 — 사적 비용, 공적 편익

§11.1의 ε-재탐색 유보는 알고리즘적으로 옳다. 그러나 현실에서 이는 개별 연구자에게 "당신이 5–10% 확률로 실패가 예상되는 조건의 재검증자입니다"라고 말하는 것이다. 비용은 사적이고 편익은 공적이다. 이 유인 비대칭이 해소되지 않으면 ε는 명목상 파라미터로 남는다.

권고

§10.1 2단계의 “과제 평가 가점 · 레코드 식별자 발급”과 ε-재탐색을 **결합**하라. 즉 ε-재탐색으로 지정된 조건의 재검증 결과는 성패와 무관하게 레코드 식별자를 발급받고 업적으로 계상된다. 그러면 ε는 알고리즘 파라미터가 아니라 제도 설계 변수가 되고, §10.4의 “왜 NST여야 하는가” 논거와 자연스럽게 접합된다. 아울러 시효 감쇠의 반감기 h는 임의 설정 대신 “과거 실패 조건이 이후 성공으로 뒤집힌 사례의 시간분포”에서 추정 가능하며, 이를 KNEG 과제 5(시효 추정)로 추가할 것을 권한다.

6 놓친 기회 — 심사자가 아까워하는 것

O1 특허 명세서의 "비교예"가 데이터 소스 목록에 없다

이것이 이 보고서에서 내가 가장 아까워하는 대목이다. 특허 명세서는 청구항의 진보성을 입증하기 위해 **비교예 (comparative example)**를 기재한다. 비교예란 정확히 "이 조건은 우리 발명보다 못하다"를 조건 파라미터와 정량 수치와 함께 명시적으로 서술한 것이다. 즉 **구조화된 E1 등급 음성결과**다. 그것도 법적 책임이 수반되므로 서술의 정확도가 논문의 Methods보다 높다.

더 결정적인 것은 §11.3이 인정한 한계 — "현 코퍼스는 영어권 오픈액세스 문헌에 편중되어 있어 국내 기관의 미보고 연구는 여전히 암흑 영역에 남는다" — 를 이 소스가 **직접 해소**한다는 점이다. 국내 특허는 한국어로, 국내 기관 명의로, 전문이 공개되어 있고 API로 접근 가능하다.

권고 — 표 8의 데이터 출처에 특허 전문 소스를 추가하고, §2.4 표 1의 경쟁 지형에도 한 행을 넣어라. 이 한 줄로 "왜 국가 기관이 해야 하는가"라는 §10.4의 논거가 한 단계 더 구체화된다. 본선 스코프에 넣기 어렵다면 최소한 로드맵 항목으로 명시하고 발표에서 한 문장으로 언급하라. 심사자가 "국내 데이터는 어떻게 할 건가"라고 물었을 때 준비된 답이 된다.

O2 규제 제출 자료와 임상시험 등록부의 미보고 결과

사전등록 제도(§2.1)를 "향후 편향 차단 장치"로만 다루고 있으나, 이미 등록되었으나 결과가 게시되지 않은 시험군은 **S = 0이 관측되는 희귀한 표본**이다. C1에서 지적한 risk set 문제를 해결하는 두 번째 경로이며, RAS의 배제 제약 검증용 벤치마크 도메인으로 쓸 수 있다. "사전등록 여부"를 도구변수 후보로만 두기에는 아까운 자산이다 (표 6 4행).

O3 라이선스·API 사전 점검이 계획에 없다

표 8은 protocols.io · Retraction Watch · PubPeer를 근거 공급원으로 명시한다. 각각 이용약관·레이트리밋·자동 수집 정책이 다르며, API 키 발급에 대기 시간이 있는 곳도 있다. 본선 17:00에 키를 신청하면 그날 밤은 끝난다. 공고상 사전 준비가 허용되는 범위 (환경 숙련도·계정·키)에 해당하는지 **제출 전에 주최측에 서면 질의**하고, 회신을 저장소 문서에 첨부하라. 이는 규정 리스크 관리인 동시에 §9.5 "출처 자기공개" 원칙의 자기 적용 사례로도 읽힌다.

7 본선 19시간 재설계 권고

현재 §8.3 계획의 완주 확률을 나는 30% 미만으로 본다. 실패 지점은 기능 부족이 아니라 **22:00–04:00 구간의 누적 지연**이다. 온톨로지 태깅·비식별화·인덱싱을 3시간에, COLLISION·RAS·게이트를 3시간에 끝낸다는 가정은 낙관적이다. 아래는 완주 확률을 75%까지 끌어올리는 스코프 절단안이다.

7.1 기능 우선순위 — MUST / SHOULD / CUT

구분	항목	판단 근거
MUST	RECOVERY(근거 오프셋 포함) · ONTOLOGY(E1·E2 한정) · COLLISION 검색 · Abstain 게이트 · Δ 기반 신뢰도 등급 표시 · 시나리오 A/B/C 시연	이 여섯 개가 이 제안의 주장 그 자체다. 하나라도 빠지면 발표에서 설명해야 할 것이 늘어난다.
SHOULD	E3 구조 추론 · 쌍 매칭 부호검정 · 오분류 서브샘플 100건	C1·C2의 방어 근거를 만드는 항목. 시간이 남으면 여기부터. 특히 오분류 서브샘플은 인력만 있으면 병렬 수행 가능하다.
CUT	포획-재포획 추정 · 완전 이변량 프로빗 MLE · ρ 격자 민감도 실시간 계산 · 다도메인 확장 · 합성 연구노트 데모	모두 **사전 계산 후 슬라이드로 제시**하면 충분하다. 런타임에 넣으면 디버깅 표면만 넓힌다. 합성 데이터는 출처 표기 의무까지 유발하므로 시연에서 제외가 안전하다.

7.2 수정 타임테이블 (9월 30일 17:00 → 10월 1일 12:00)

시간	작업	완료 기준 · 심사자 주석
17:00–18:30	저장소·키·PMC OA JATS 수집 스크립트	전문 XML 400편. 파서를 새로 쓰지 말고 JATS 절 태그를 그대로 신뢰할 것.
18:30–21:30	RECOVERY — 음성결과 추출 + 오프셋 부착	레코드 150건(200 → 150 하향). 오프셋 없는 레코드는 즉시 폐기 원칙 유지.
21:30–23:30	ONTOLOGY — 5축 태깅 · E1/E2 · 비식별화 · 인덱싱	E3는 이 시점에 착수하지 않는다. 벡터 저장소 구축 완료가 유일한 게이트.
23:30–02:00	COLLISION + Abstain 게이트 (조건 (iv) 포함)	**여기서 end-to-end 1회 통과가 나와야 한다.** 02:00까지 미달 시 RAS를 사전 계산 상수로 대체하고 진행.
02:00–03:30	Δ 산출(축약형) + 신뢰도 등급 매핑	역확률가중 로지스틱 근사로 충분. 프로빗 MLE는 시도하지 않는다.
03:30–05:00	UI · 경보 카드 렌더링	Streamlit 단일 페이지. 그림 2의 카드 레이아웃을 그대로 구현.
05:00–07:00	**검증 블록** — 역방향 골드셋 NRR 하한 + 25쌍 부호검정	협상 불가. 여기서 p값 하나를 확보하는 것이 이 팀의 승부처다.
07:00–08:30	버퍼 · 실패 경로 제거 · 오프라인 폴백 준비	시연 중 API 장애 대비 캐시 응답 경로를 반드시 만들 것.
08:30–10:30	시나리오 3종 리허설	A(경보) → B(기권) → C(탐색) 순서 유지. B에 가장 많은 시간을 쓸 것.
10:30–12:00	발표자료 마감 · 5분 리허설 3회	가상 예시 수치는 **전량 삭제**하고 실측값으로 교체.

7.3 발표 5분 구성 권고

> **심사자가 기억하는 것은 문장 하나와 숫자 하나뿐이다**
>
> - **0:00–0:40** — 통계로 시작하지 말 것. “A 출연연이 세 번 실패한 조건을 B 출연연이 2년 뒤 그대로 시도했다”는 §1.3의 구체 장면으로 연다.
> - **0:40–1:10** — 핵심 문장. “우리는 새 데이터를 만들지 않습니다. 국가가 이미 비용을 지불하고 산 데이터를 회수합니다.” 이 한 문장이 20년간 실패한 음성결과 저널들과의 차이를 전부 담는다.
> - **1:10–3:10** — 시연 A → B → C. **B(기권)에 가장 긴 시간을 배분하라.** 경보를 내는 AI는 흔하고, 근거가 없을 때 스스로 입을 다무는 AI는 드물다. 신뢰성 심사 점수는 이 30초에서 갈린다.
> - **3:10–4:10** — 검증 슬라이드 한 장. 25쌍 부호검정 결과와 p값, 역방향 골드셋 NRR 하한, HAR–AbR 곡선. “동작합니다”가 아니라 “검증했습니다”로 전환되는 지점.

- **4:10–5:00** — 왜 NST·NAIS인가(§10.4) + 자율실험실 협의체와의 시간축 상보성. 마지막 문장은 결론부의 “실패는 성공의 부재가 아니라, 아직 조건이 갖추어지지 않은 가능성의 좌표다”를 그대로 쓸 것. 이 보고서에서 가장 잘 쓰인 문장이다.

8 심사장 예상 질문 12선과 방어선

실제 심사에서 나올 확률이 높은 순서로 배열했다. 1–4번은 **반드시** 나온다.

Q1. 미보고 실험은 존재 자체가 안 보이는데, 선택모형의 우도를 어떻게 씁니까?

> → 이 심사평의 **C1**. 조건 셀 단위로 답하라. "분석 단위는 실험이 아니라 문서화된 요인설계 격자의 셀입니다. 격자에 명시되었으나 결과가 이월되지 않은 셀이 $S=0$으로 관측되며, 여기서 risk set이 실재적으로 구성됩니다." 이 답을 준비하지 못하면 6장 전체가 무너진다.

Q2. Δ의 순위가 보고편향이 아니라 추출 난이도를 반영하는 것 아닙니까?

> → **C2**. 층화 재라벨 서브샘플의 오분류율 비교로 답한다. 정직한 보조 답변: "현재는 배제하지 못했습니다. 그래서 Δ를 구간으로 표시하고 구간이 0을 포함하면 등급을 부여하지 않습니다." 모른다고 말하되 설계로 대응했다고 말하는 것이 이 심사에서 가장 높은 점수를 받는 화법이다.

Q3. SI 격자에서 이월 안 된 셀이 실패라는 보장이 있습니까? 특허 때문에 뺐을 수도 있죠.

> → **R2**. "보장 없습니다. 그래서 E3로 등급을 낮추고 가중치 0.3을 둡니다. 다만 그 0.3은 임의값이 아니라 후향검증의 등급별 CAP@k로 역산해 교정합니다." 가중치를 데이터로 정당화한다는 답이 핵심.

Q4. 결국 LLM으로 논문 긁어서 RAG 만든 것 아닙니까?

> → 기준선 (ii)를 들어라. "§7.5에서 온톨로지·증거등급 없는 단순 RAG를 기준선으로 두고 그 대비 개선을 측정합니다. 개선이 없으면 NFO는 존재 이유가 없습니다." 자기 시스템을 반증할 기준선을 먼저 설계했다는 사실 자체가 답이다.

Q5. 실패 데이터가 기관 평가에 쓰이면 아무도 기여 안 할 텐데요.

> → §9.1 거버넌스 3조항을 "배려"가 아니라 **작동 조건**으로 설명하라. "기관별 실패율 산출과 순위화를 금지 조항으로 명문화했습니다. 이건 윤리 항목이 아니라 2단계 자율기여가 발생하기 위한 필요조건입니다."

Q6. 자율실험실 협의체가 이미 데이터 표준을 만들고 있는데 중복 아닙니까?

> → 시간축 상보성(§10.2). "협의체는 앞으로 발생할 실패를 기록합니다. 지난 수십 년 국가 예산으로 수행되어 실패한 실험은 문헌 속에만 있습니다. 자율실험실 데이터만으로 만든 자산은 출발 시점 이전의 역사를 갖지 못합니다." 이 답변은 이미 보고서에 완성되어 있다. 토씨까지 외울 것.

Q7. 경보를 보고 연구자가 그 조건을 피하면, 그 조건은 영원히 검증 안 되는 것 아닙니까?

> → §11.1. **질문자보다 먼저 이 문제를 발견했다는 사실**을 명확히 하라. "그것이 이 시스템 고유의 위험이고, 저희가 탐색 붕괴라고 명명했습니다. ε-재탐색·시효 감쇠·역경보 갱신 세 장치를 아키텍처에 내장했습니다." 심사자가 던지는 함정을 이미 보고서 11장에 써 둔 팀은 신뢰를 얻는다.

Q8. 조건이 조금만 달라도 다른 실험인데, 유사도 검색이 그걸 구분합니까?

> → **R3**. 정직하게 병목임을 인정하고 게이트 조건 (iv)와 `condition_match_confidence`, 그리고 신규 지표 MMR로 답한다. "HAR이 잡지 못하는 실패 유형이 있어서 지표를 하나 더 만들었습니다"는 지표 체계의 성숙도를 보여주는 답이다.

Q9. NRR을 측정했다는데 정답 주석은 누가 했습니까?

> → **R4**. "주석하지 않았습니다. 음성결과가 존재함이 확정된 문헌군을 역방향 골드셋으로 사용해 재현율의 하한을 측정했습니다." 하한이라고 먼저 말하는 것이 과장보다 훨씬 강하다.

Q10. 국내 연구 데이터는 하나도 없는데 국가 사업으로 의미가 있습니까?

> → **O1**. 국내 특허 비교예를 로드맵으로 제시하라. “1단계 한계는 영어권 OA 편중이며, 이를 해소하는 소스가 국내 특허 명세서의 비교예입니다. 한국어, 국내 기관 명의, 전문 공개, API 접근 가능합니다.” 준비되지 않은 팀은 여기서 말문이 막힌다.

Q11. 저작권 문제는 없습니까? 논문 본문을 저장하는 것 아닙니까?

> → §5.5. “원문 텍스트를 복제하지 않고 위치 포인터만 저장합니다. 저작권 준수와 검증 가능성을 동시에 만족시키는 설계입니다.” 즉답 가능해야 한다.

Q12. 19시간에 이걸 다 만들었다는 게 믿기지 않습니다. 사전 개발 아닙니까?

> → 커밋 히스토리로 답하라. 저장소를 본선 시작 시각에 초기화하고 **30분 단위 커밋 규율**을 지킬 것. 발표 말미에 커밋 타임라인 한 장을 준비하면 이 질문은 감점이 아니라 가점이 된다. 규정 리스크 관리는 심사자가 조용히 높게 평가하는 항목이다.

9 점수 상승 레버 — 우선순위와 기대 증분

순위	조치	소요	기대 증분	영향 항목
1	**도메인-소스 정합화** PMC OA JATS 기반 생명과학으로 확정(C3)	제출 전 30분	+5 ~ +7	구현가능성 · 데이터 확보. 본선 초반 붕괴 위험을 제거하는 **최고 효율 조치**.
2	**조건 셀 단위 재정식화** §6.1·§3.1 문구 수정 + E3 승격(C1)	제출 전 2시간	+4 ~ +6	방법론 엄밀성. Q1 방어선 확보. 수식 대부분은 그대로 살아난다.
3	**검증 블록 사수** 25쌍 부호검정 + 역방향 골드셋(R4)	본선 2시간	+3 ~ +5	데이터·검증 설계. "동작합니다 → 검증했습니다" 전환의 유일한 수단.
4	**게이트 조건 (iv) + MMR 지표** 매칭 신뢰도 도입(R3·R5)	본선 1시간	+2 ~ +3	AI 윤리·신뢰성. 자기 지표의 구멍을 스스로 메운 팀은 심사에서 눈에 띈다.
5	**특허 비교예 로드맵 명시** 표 8·표 1에 1행 추가(O1)	제출 전 20분	+2	독창성 · 정책 임팩트. Q10 방어선. 투입 대비 회수율이 가장 높은 문서 수정.

누적 시나리오

1·2·5번(제출 전 문서 수정, 총 약 3시간)만 반영해도 기획 점수는 **76** → **84**로 올라간다. 여기에 본선에서 3·4번이 성립하고 end-to-end 시연이 완주하면 **90점대 진입**이 가능하다. 반대로 아무 조치 없이 현재 스코프로 본선에 들어가면, 구현 미완으로 실현가능성 항목이 10 → 5로 떨어져 **71점 이하**가 된다. 이 제안의 점수 분산은 대단히 크며, 그 분산의 대부분은 기술이 아니라 스코프 판단에서 온다.

10 최종 판정

판정 항목	내용
종합 점수	**76 / 100**
등급	**A**− · 본선 진출 적격
기획 부문	상위 5% — 문제 재정의, 회수 기반 접근, Δ 우선 원칙, E4 반전, 탐색 붕괴 내장. 이 다섯은 그대로 유지할 것.
구현 부문	현 상태 완주 확률 30% 미만 — §7 재설계안 채택 시 75%로 상승
필수 선행 조치	C1(조건 셀 재정식화) · C3(도메인-소스 정합화) — **제출 전 완료**
본선 승부처	05:00–07:00 검증 블록에서 p값 1개 확보 · 시나리오 B(기권) 시연
수상 가능성	조치 반영 시 상위권 · 미반영 시 중위권

심사 소견

이 보고서는 해커톤 제출본이 도달할 수 있는 지적 밀도의 상한에 가깝다. 특히 자기 시스템이 성공했을 때 발생할 해악을 식별하고 그 완화를 아키텍처에 내장한 §11.1은, 내가 30년간 읽은 제출본 중 손에 꼽는다. 대부분의 팀은 자기 시스템이 실패할 경우만 상상한다.

그러나 해커톤은 논문 심사가 아니다. 19시간 뒤에 화면에서 무언가가 돌아가야 하고, 그 무언가가 주장한 바로 그것이어야 한다. 이 제안의 가장 큰 위험은 방법론의 약점이 아니라 **야심의 크기**다. 세 에이전트 전부를 반쯤 만드는 것보다, 두 에이전트를 완전히 만들고 검증 수치 하나를 들고 오는 편이 이 심사에서 훨씬 높은 점수를 받는다.

마지막으로 저자에게. 결론부의 마지막 문장 — "실패는 성공의 부재가 아니라, 아직 조건이 갖추어지지 않은 가능성의 좌표다" — 는 이 보고서 전체에서 가장 잘 쓰인 문장이다. 이 문장을 지키기 위해서라도, **본선에서는 덜 만들고 더 검증하라.**

부기. 본 심사평가서는 제출된 연구보고서 본문에 근거해 작성되었으며, 가정한 배점 체계(문제정의 20 / 방법론 20 / 구현가능성 20 / 데이터·검증 15 / AI윤리 15 / 임팩트 10)는 기술 트랙 AI 해커톤의 일반적 심사 구조를 반영한 것이다. 실제 대회 공고의 배점과 다를 수 있으며, 그 경우 §2의 항목별 사유는 유지한 채 가중치만 재배분하면 된다. §4–§6에서 지적한 사항은 제안의 가치를 부정하기 위한 것이 아니라, 심사장에서 노출될 지점을 사전에 소진시키기 위한 것이다.