

보고편향 보정을 통한 국가 R&D 음성결과 회수 프레임워크

NULLBANK: 다중 에이전트 아키텍처, 실패 온톨로지, 그리고 RAS 추정량

*A Reporting-Bias-Corrected Framework for Recovering Negative Results in National R&D:
NULLBANK Agent Architecture, Failure Ontology, and the RAS Estimator*

추병곤

큐레이터 · 미학 연구자 · AI 연구과정(AIFFEL 18 기)

2026 국가과학기술연구회 국가과학 AI 연구센터(NAIS) AI 해커톤 제출 연구보고서 · 2026 년 8 월

국문초록

대한민국 국가연구개발사업의 과제 성공률은 오랫동안 90~99% 수준으로 보고되어 왔고, 이 수치는 “도전적 연구의 부재”라는 비판과 “성공률 산정 방식 자체의 왜곡”이라는 반론 사이에서 반복적으로 소모되어 왔다. 본 연구는 이 논쟁이 교착 상태에 있는 이유가 어느 한쪽의 오류 때문이 아니라 측정 단위(unit of measurement)의 불일치 때문이라고 진단한다. 국가가 측정하는 것은 과제(project)의 성패이고, 과학적 지식이 실제로 생성·소멸하는 단위는 실험(experiment)이다. 성공으로 종결된 과제 내부에서 수행된 수백 건의 실험 중 상당수는 실패했으며, 그 실패는 과제 성공 판정에 흡수되어 어떤 기록에도 남지 않는다. 즉 문제는 성공률의 크기가 아니라 관측 체제(observation regime)의 구조다.

본 연구는 이 구조를 실험공간에서 관측집합으로 가는 삼중 절단(triple truncation)—기록 절단, 보고 절단, 색인 절단—으로 정식화하고, 그 역상(逆像)을 부분적으로 회수하는 다중 에이전트 시스템 NULLBANK를 제안한다. NULLBANK는 (i) 공개 문헌의 실험방법·보조자료·프로토콜 문서에 잠복한 음성결과를 구조화 레코드로 회수하는 RECOVERY 에이전트, (ii) 회수된 실패를 5축 실패 온톨로지(NFO)와 4단계 증거등급(E1-E4)으로 태깅하고 기관·연구자를 비식별화하는 ONTOLOGY 에이전트, (iii) 신규 실험 설계안을 입력받아 유사 실패 조건을 검색하고 근거와 함께 사전 경보를 발령하는 COLLISION 에이전트로 구성된다.

방법론적 핵심 기여는 보고편향 보정 성공확률(Reporting-Adjusted Success rate, RAS)이다. RAS는 관측된 문헌상 성공률이 아니라 미보고 실험을 포함한 잠재 성공확률을 이변량 프로빗 표본선택 모형으로 추정하며, 저자가 선행 연구에서 미술시장의 미관측 거래 문제를 다루기 위해 개발한 시장관측격차(MOG) 보정 구조를 과학 문헌 영역으로 이식한 것이다. 본 연구는 나아가 RAS의 점추정보다 관측값과 보정값의 차이인 보정폭 Δ 가 더 강건하고 실용적인 산출물임을 논증한다. Δ 는 “문헌을 믿어도 되는 구간”과 “성공만 보고되는 구간”을 구분하는 문헌 신뢰도 지도로 기능한다.

또한 본 연구는 음성결과 회수 시스템이 갖는 고유한 위험—경보를 받은 연구자가 해당 조건을 회피함으로써 그 조건에 관한 새로운 증거가 영원히 생성되지 않는 탐색 붕괴(exploration collapse)—를 식별하고, ϵ -재탐색 유보, 증거 시효 감쇠, 역경보 갱신이라는 세 가지 완화 장치를 아키텍처에 내장한다. 마지막으로 시스템의 주장을 반증 가능하게 만드는 시간분할 후향 검증 프로토콜과 이를 지표화한 벤치마크 KNEG를 제시한다.

주제어 음성결과, 출판편향, 표본선택 보정, 과학 특화 AI, 연구 데이터 인프라, 다중 에이전트 시스템, 자율실험실, 연구윤리

Abstract

Korea's national R&D projects have long reported success rates of 90-99%. The ensuing debate—whether this signals an absence of ambitious research or a distortion in how success is defined—has

stalled because both camps measure the wrong unit. The state measures projects; scientific knowledge is created and lost at the level of experiments. This paper formalises the passage from experiment space to observed corpus as a triple truncation (recording, reporting, indexing) and proposes NULLBANK, a three-agent system that partially inverts it: RECOVERY extracts latent negative results from Methods, Supplementary Information and protocol documents; ONTOLOGY tags them against a five-axis failure ontology with a four-level evidence grade and de-identifies institutions and authors; COLLISION issues evidence-linked pre-registration alerts against new experimental designs. The methodological contribution is RAS (Reporting-Adjusted Success rate), a bivariate-probit sample-selection estimator transplanted from the author's prior work on unobserved art-market transactions. We argue the correction gap Δ is more robust and more useful than the RAS point estimate, functioning as a reliability map over the literature. We identify exploration collapse as a system-specific hazard and embed three mitigations, and we specify KNEG, a falsifiable retrospective benchmark.

1. 서론: 잘못된 단위로 벌어진 논쟁

1.1 성공률 99%라는 교착

2025 년 이후 한국 과학기술 정책의 중심에는 하나의 숫자가 놓여 있다. 국가연구개발사업의 과제 성공률이 90%를 넘는다는 통계다. 이 숫자는 두 가지 상반된 해석을 낳았다. 하나는 “될 만한 것만 골라서 한다” 는 도전성 결핍의 증거라는 해석이고, 다른 하나는 그 수치 자체가 왜곡된 데이터에 기반해 있으므로 이를 근거로 한국 R&D 의 구조적 문제를 진단하는 것은 경험적 타당성이 결여되어 있다는 반론이다. 후자는 한국과학기술한림원이 2026 년 발간한 정책보고서 『실패없는 R&D 역설: 한국과학기술 혁신을 위한 조건』 에서 홍성욱 서울대 과학학과 교수가 제기한 입장이다.

본 연구의 출발점은 이 논쟁의 승패를 가리는 데 있지 않다. 오히려 양쪽 모두가 옳으며, 바로 그 사실이 이 논쟁을 해결 불가능하게 만들고 있다는 관찰에서 출발한다.

1.2 진단: 측정 단위의 불일치

성공률 논쟁이 교착에 빠진 원인은 통계의 정확성이 아니라 통계의 단위에 있다. 국가가 측정하고 관리하는 대상은 과제(project)다. 과제는 협약된 목표치의 달성 여부로 성패가 판정된다. 그러나 과학적 지식이 실제로 생성되고 소멸하는 단위는 실험(experiment)이다. 하나의 3 년짜리 소재 개발 과제 안에서 연구자는 수백 회의 합성 조건을 시도하고, 그중 대다수는 목표 물성에 도달하지 못한다. 과제가 최종적으로 성공 판정을 받는 순간, 그 내부의 수백 건 실패는 성공 판정에 흡수되어 어떤 국가 기록에도 남지 않는다.

핵심 명제 과제 성공률 99%와 실험 성공률 20%는 서로 모순되지 않는다. 두 수치는 다른 층위의 통계이며, 국가는 전자만 측정하고 있다. 따라서 “성공률이 높다” 는 진술과 “실패가 사라지고 있다” 는 진술은 동시에 참일 수 있다. 문제는 수치의 크기가 아니라 관측 체제의 구조다.

이 재정식화는 실천적 함의를 갖는다. 성공률 산정 방식을 바꾸자는 제안은 평가 제도를 둘러싼 이해관계 갈등을 즉시 촉발하며, 실제로 지난 수년간 그 지점에서 논의가 멈춰 왔다. 반면 측정 단위를 실험으로 내리자는 제안은 누구의 평가 등급도 건드리지 않는다. 그것은 평가의 문제가 아니라 기록의 문제이기 때문이다. 본 연구가 제안하는 시스템이 국가 R&D 평가 체계에 대한 비판이 아니라 그 체계가 볼 수 없는 층위를 가시화하는 인프라로 설계된 이유가 여기에 있다.

1.3 기록되지 않은 실패의 비용

실험 단위의 실패가 기록되지 않을 때 발생하는 비용은 세 가지 경로로 나타난다.

- **중복 실패의 재생산.** A 출연연이 3 회에 걸쳐 실패한 합성 조건을, B 출연연이 2 년 뒤 동일하게 시도한다. 국가 예산이 같은 벽에 두 번 부딪힌다. 두 기관 모두 상대의 실패를 알 방법이 없다. 이는 연구자의 태만이 아니라 정보 인프라의 부재다.
- **AI 학습 데이터의 구조적 결함.** 성공 사례만으로 학습된 모델은 실패를 예측하지 못한다. 이는 성능 저하가 아니라 원리적 한계다. 화학·소재 분야 연구는 현 문헌이 기계학습 모델을 만족스럽게 학습시키기에 구조적으로 불충분하며, 그 원인으로 낮은 재현성, 인간의 선택 편향, 그리고 무엇보다 음성 사례의 부재를

지목해 왔다. 편향되고 음성 데이터가 결합된 학습 데이터로 만든 모델의 예측 성능은 전통적 방법을 넘어서지 못한다는 실증이 보고되어 있다.

- **암묵지의 인력 이동 소실.** “그 조건은 안 된다” 는 지식은 연구노트, 개인 하드디스크, 퇴직자의 기억에만 존재한다. 인력이 이동하면 함께 소멸한다. 국가가 비용을 지불하고 획득한 지식이 고용 계약 종료와 함께 사라진다.

1.4 본 연구의 기여

본 연구는 다섯 가지를 기여한다. 첫째, 성공률 논쟁을 관측 체제의 삼중 절단 구조로 재정식화한다(3 장). 둘째, 그 절단의 부분 역상을 수행하는 다중 에이전트 아키텍처 NULLBANK 를 설계한다(4 장). 셋째, 회수된 음성결과를 표준화하는 실패 온톨로지 NFO 와, 근거 강도를 구분하는 4 단계 증거등급 체계를 제시한다(5 장). 넷째, 원리적으로 회수 불가능한 미기록 영역을 통계적으로 보정하는 추정량 RAS 를 정의하고 그 식별 조건과 한계를 논한다(6 장). 다섯째, 시스템의 주장을 반증 가능하게 만드는 후향 검증 프로토콜과 벤치마크 KNEG 를 명세한다(7 장). 아울러 이러한 시스템이 배태하는 고유 위험인 탐색 붕괴를 식별하고 완화 설계를 제시한다(11 장).

2. 관련 연구와 미해결 지점

2.1 출판편향과 파일서랍 문제

출판된 문헌이 체계적으로 편향되어 있다는 인식은 새롭지 않다. Ioannidis(2005)는 사전 승산, 검정력, 연구자 재량을 고려할 때 출판된 발견의 상당수가 거짓일 수 있음을 논증했고, Fanelli(2010)는 학문 분야 전반에서 긍정적 결과의 비율이 증가해 왔음을 문서화했으며, Franco 외(2014)는 선택적 보고와 음성·무효 결과의 파일서랍(file drawer)을 직접 연결했다. 사전등록, 등록 보고서(Registered Reports), 임상시험 등록제는 정확히 이 여과 문제에 대응하기 위해 고안된 제도다.

본 연구가 주목하는 것은 이 편향이 사회학적 배경이 아니라 학습 데이터라는 점이다. 실패한 실험을 과소 기록하는 문헌은, 반증을 과소 학습시키는 말뚝치가 된다. 2026 년 들어 이 문제를 대규모 언어모델의 맥락에서 정면으로 제기하는 연구들이 잇따라 발표되고 있다.

2.2 음성결과 저널은 왜 실패했는가

음성결과를 다루는 전용 학술지는 20 년 넘게 존재해 왔다. Journal of Negative Results in Biomedicine(JNRBM), Journal of Articles in Support of the Null Hypothesis, The All Results Journals, PLOS ONE 의 Missing Pieces 컬렉션 등이다. 이 중 JNRBM 은 2002 년 창간되었으나 2017 년 9 월 발행을 중단했다.

실패의 원인은 명확하다. 이들 모델은 모두 연구자에게 추가 저술 노동을 요구한다. 연구자 대상 조사에 따르면 연구자들은 음성결과의 가치를 높게 평가하면서도 자신의 음성결과는 출판하지 않는데, 그 이유로 시간 부족과 인용되지 않을 것이라는 인식을 든다. 즉 문제는 발표 지면의 부재가 아니라 유인 구조다. 지면을 늘리는 해법은 20 년간 시도되었고 작동하지 않았다.

설계 원칙 1 NULLBANK 는 연구자에게 아무것도 새로 쓰라고 요구하지 않는다. 이미 작성된 문서 안에 잠복해 있는 음성결과를 회수한다. 저술 기반 해법이 실패한 지점이 바로 회수 기반 접근의 출발점이다.

2.3 자율실험실: 음성결과의 새로운 생산지

자율실험실(self-driving lab)은 실험 장비, 로봇, AI 를 연계해 사람의 개입 없이 실험을 반복 수행하는 연구 플랫폼이다. 자율실험실 연구자들은 이 플랫폼이 실패한 실험의 기록을 더 잘 보존하며, 전체 데이터셋의 공개와 표준화된 데이터 형식이 음성결과의 공개를 촉진할 잠재력을 갖는다고 지적해 왔다. 현재의 만연한 출판편향이 기계학습 접근을 저해하며 음성 결과가 양성 결과만큼 모델 학습에 중요하다는 인식이 그 배경이다.

여기에는 종종 간과되는 기술적 필연성이 있다. 자율실험실의 실험 선택은 대개 베이지안 최적화나 능동학습에 의존하는데, 이들 알고리즘의 획득함수는 실패 관측으로부터 불확실성을 갱신한다. 음성결과는 자율실험실의 부산물이 아니라 연료다. 성공만 저장하는 자율실험실은 자기 알고리즘의 입력을 스스로 파괴한다.

2026 년 8 월 11 일 과학기술정보통신부는 자율실험실 산·학·연 협의체를 출범시켰다. 협의체는 서울대 정유성 교수를 위원장으로 하고, 국가과학 AI 연구센터(NAIS)와 한국기초과학지원연구원(KBSI)이 공동간사를 맡으며, 공급기업과 수요기업 50 개사 및 30 여 개 대학·연구기관이 참여한다. 협의체의 핵심 임무에는 데이터 축적과 표준·

인터페이스 정립이 포함된다. 유용균 NAIS 센터장은 자율실험실에서 생산되는 데이터가 AI 학습으로 곧바로 이어지도록 데이터 축적·품질관리 체계를 구축하고 이를 국가 차원의 AI 학습 자산으로 만들겠다고 밝혔다.

본 연구의 관점에서 이 선언에는 아직 채워지지 않은 항목이 있다. 자율실험실이 생산하는 데이터의 대다수는 음성결과이며, 그것을 국가 자산으로 계상하려면 음성결과를 기술하는 스키마가 먼저 있어야 한다. 현재 논의 구조에서 그 스키마를 정의하는 주체는 명시되어 있지 않다. 5 장의 NFO 는 그 빈칸에 대한 제안이다.

2.4 국내 인프라 지형과 중복 회피

국내에는 이미 NTIS, DataON, ScienceON AI(SAI)가 운영 중이며 KISTI 는 AI co-Scientist 를, NST 는 국가과학 AI 통합플랫폼을 추진하고 있다. 국외에는 Elicit, Consensus, SciSpace 등 문헌 탐색 도구가 포화 상태다. 이들은 모두 보고된 지식을 더 빠르게 찾는 방향으로 최적화되어 있다. 본 연구는 이 방향과 정면으로 교차하지 않는다. 검색의 방향이 반대이기 때문이다.

표 1. 기존 접근과 NULLBANK 의 위치

구분	무엇을 하는가	구조적 한계
SAI · Elicit · Consensus · SciSpace	보고된 성공 지식의 검색·요약	관측집합 위에서만 작동. 절단 이전을 볼 수 없음
음성결과 전용 저널 (JNRBM 등)	연구자가 실패를 별도로 저술	추가 저술 노동 요구 → 유인 부재. JNRBM 은 2017 년 발행 중단
사전등록 · 등록 보고서	향후 연구의 보고편향 사전 차단	이미 수행된 과거 실험의 회수는 불가능
전자연구노트(ELN)	기관 내부 기록 보존	기관 간 사일로. 통계적 보정 개념 없음
자율실험실 데이터 파이프라인	신규 실험의 전량 기록	자율실험실 이전 세대의 실패는 포괄하지 못함
NULLBANK (본 연구)	기존 문서에서 음성결과를 회수하고, 원리적 미회수분을 통계적으로 보정	—

자율실험실은 앞으로 발생할 실패를 기록한다. NULLBANK 는 지난 수십 년간 이미 발생했으나 기록되지 않은 실패를 회수한다. 두 경로는 경쟁 관계가 아니라 시간축에서 상보적이다.

2.5 표본선택 보정 방법론

관측된 표본이 결과변수와 상관된 선택 과정을 거쳤을 때 발생하는 편향과 그 보정은 계량경제학에서 확립된 주제다. Heckman(1979)의 2 단계 추정, 이변량 프로빗 선택모형, Tobit 계열 절단회귀가 표준 도구이며, 메타분석 영역에서는 Copas 선택모형이 출판편향 민감도 분석에 사용된다. 본 연구는 이 계보를 과학 문헌의 실험 조건 공간에 적용한다. 저자는 선행 연구에서 미술시장의 미거래 작품으로 인한 가격 미관측 문제를 다루기 위해 시장관측격차(Market Observability Gap, MOG) 보정 프레임워크를 구성한 바 있으며, 본 연구의 RAS 는 그 구조를 이식한 것이다. 두 문제의 수학적 구조는 동일하다. 거래된 작품만 가격이 관측되듯, 성공한 실험만 결과가 보고된다.

3. 문제 정형화: 삼중 절단

3.1 실험공간에서 관측집합으로

Ω 를 특정 기간·도메인에서 실제로 수행된 모든 실험의 집합이라 하자. 각 실험 i 는 조건벡터 x_i 와 잠재 결과 $Y_i^* \in \{\text{성공}, \text{실패}\}$ 를 갖는다. 연구자와 시스템이 접근할 수 있는 것은 Ω 가 아니라 세 개의 여과기를 통과한 잔여 집합이다.

$$O = T_3 \circ T_2 \circ T_1 (\Omega)$$

- **T₁ 기록 절단.** 수행된 실험이 어떤 형태로든 기록되는가. 연구노트에조차 남지 않은 시도는 이 단계에서 소멸한다. 이 절단은 원리적으로 사후 회수가 불가능하다.
- **T₂ 보고 절단.** 기록된 실험이 논문·보고서 등 외부 문서에 등장하는가. 여기서 성공 사례가 체계적으로 우대된다. 다만 실패 조건 중 일부는 실험방법(Methods)과 보조자료(Supplementary Information)에 잔존한다.
- **T₃ 색인 절단.** 문서에 등장한 실험 조건이 검색 가능한 형태로 색인되는가. 현행 학술 검색엔진은 초록·제목·키워드를 중심으로 색인하며, 실험방법 본문에 서술된 “시도했으나 이월하지 않은 조건”은 사실상 색인되지 않는다.

3.2 세 절단에 대한 세 가지 대응

이 구조는 시스템 설계를 곧바로 규정한다. 각 절단은 서로 다른 종류의 개입을 요구하며, 이것이 NULLBANK가 세 개의 에이전트로 구성된 이유다.

표 2. 절단 유형별 대응 전략

절단	성격	대응	담당	실행 시점
T ₃ 색인	기술적 누락	역색인 회수 (T_3^{-1})	RECOVERY	즉시 가능
T ₂ 보고	부분 관측	부분 역상 + 구조화	ONTOLOGY	즉시 가능(부분)
T ₁ 기록	원리적 소실	통계적 보정 (추정)	RAS 모듈	추정만 가능

설계 원칙 2 회수 없는 보정은 근거가 없고, 보정 없는 회수는 여전히 편향이다. T_3^{-1} 만 수행하면 “문헌에서 찾은 실패”만 늘어날 뿐 여전히 보고된 것들의 표본이다. RAS 없이 회수량만 늘리는 시스템은 편향의 크기를 모른 채 편향된 데이터를 확대 재생산한다. 회수와 보정은 선택 사항이 아니라 서로의 전제다.

3.3 편향의 방향과 크기

보고 확률이 결과와 양의 상관을 가질 때—즉 성공한 실험이 더 잘 보고될 때—문헌상 관측 성공률은 잠재 성공률을 체계적으로 과대추정한다. 이 과대추정의 크기는 조건공간 전역에서 균일하지 않다는 점이 중요하다. 잘 연구된 표준 조건은 성공과 실패가 모두 반복 보고되므로 편향이 작고, 탐색이 얕은 변방 조건은 성공 사례 한두 건만 보고되어 편향이 크다. 본 연구가 6.4 절에서 논하듯, 이 편향의 비균일성 자체가 실용적으로 가장 유용한 신호다.

3.4 미술시장 문제와의 구조적 동형성

저자의 선행 연구는 미술품 가치평가에서 다음 문제를 다룬다. 경매 낙찰가는 관측되지만, 유찰된 작품과 애초에 출품되지 않은 작품의 가치는 관측되지 않는다. 출품 결정 자체가 예상 가격에 의존하므로, 낙찰 자료만으로 추정된 가격모형은 상향 편향된다. 이는 절단·표본선택 구조이며 Heckman 계열 방법으로 보정한다.

국가 R&D 의 구조는 이와 동형이다. 보고 결정이 실험 결과에 의존하므로, 보고된 실험만으로 추정한 성공확률은 상향 편향된다. 대응 관계는 다음과 같다.

표 3. 구조적 대응 관계

미술시장 (MOG)	국가 R&D (NULLBANK)	공통 구조
출품·낙찰 결정	논문·보고서 보고 결정	선택식 S
작품의 잠재 가치	실험의 잠재 성공 여부	결과식 Y*
미거래 작품	미보고 실험	미관측 표본
낙찰가 기반 시세의 상향 편향	문헌 성공률의 상향 편향	선택 편향
MOG 보정 가치추정	RAS 보정 성공확률	선택모형 보정 추정량

이 이식은 은유가 아니라 동일한 통계 모형의 재사용이다. 두 영역 모두 선택식과 결과식이 상관된 오차항을 공유하는 이변량 잠재변수 구조를 갖는다.

4. NULLBANK 아키텍처

4.1 전체 구조

NULLBANK는 세 개의 하위 에이전트와 두 개의 저장소, 하나의 판정 게이트로 구성된 오케스트레이션 시스템이다. 상태 그래프 기반 다중 에이전트 프레임워크 (LangGraph 등) 위에서 각 에이전트는 명시적 상태를 주고받으며, 모든 산출물에 근거 문장 포인터가 부착된다.

그림 1. 처리 흐름

[신규 실험 설계안 (자연어 또는 조건 테이블)] → COLLISION: 조건 파싱 및 임베딩 → [음성결과 벡터 저장소] → 유사 실패 조건 검색 → [RAS 모듈: 보고편향 보정] → [Abstain 게이트: 근거 검증] → [출력: 충돌 경보 카드 · 근거 문헌 · 대안 조건 · 탐색 권장 영역]

코퍼스 구축 경로는 이와 병렬로 동작한다. [공개 문헌 API] → RECOVERY: 음성결과 후보 추출 → ONTOLOGY: NFO 태깅 · 증거등급 부여 · 비식별화 → [음성결과 벡터 저장소]

4.2 RECOVERY 에이전트: 색인 절단의 역할

RECOVERY는 문헌의 어느 부분에 음성결과가 잔존하는지에 관한 구조적 지식을 사용한다. 초록과 결론은 성공 서사로 조직되지만, 다음 위치에는 실패가 남는다.

- 실험방법(Methods)의 조건 서술 중 결과 절로 이월되지 않은 조건
- 보조자료(SI)의 스크리닝 표·최적화 격자에서 후속 단계로 진행되지 않은 셀
- 프로토콜 저장소(protocols.io 등)의 문제해결(troubleshooting) 절
- 철회·문제제기 기록(Retraction Watch, PubPeer)에 기술된 재현 실패
- 학위논문 부록의 예비실험 기록 — 학위논문은 지면 제약이 없어 실패 서술 밀도가 논문보다 현저히 높다

각 후보에 대해 RECOVERY는 조건벡터, 실패 양상, 원문 근거 문장 포인터, 문헌 식별자를 포함하는 구조화 레코드를 생성한다. 근거 문장 포인터가 없는 레코드는 생성 단계에서 폐기한다.

4.3 ONTOLOGY 에이전트: 표준화와 비식별화

ONTOLOGY는 자유서술 형태의 실패 사유를 5 축 온톨로지(5 장)로 정규화하고, 증거등급 E1-E4를 부여하며, 기관·연구자·과제번호를 마스킹한다. 이 세 작업은 분리 불가능하다. 표준화되지 않은 실패는 검색되지 않고, 비식별화되지 않은 실패는 공유되지 않기 때문이다.

4.4 COLLISION 에이전트: 사전 경보와 탐색 권장

COLLISION은 연구자가 입력한 신규 실험 설계안을 조건벡터로 파싱하고, 벡터 저장소에서 유사 실패 조건을 검색한 뒤, 다음 네 가지를 산출한다.

- **충돌 경보.** 유사 조건에서 관측된 실패 사례 수와 주요 실패 양상. 각 사례에 근거 문장과 문헌 식별자를 부착한다.
- **RAS와 보정폭.** 문헌상 성공률과 보고편향 보정 성공률을 구간추정으로 병기하고, 그 차이 Δ 를 명시한다.
- **대안 조건.** 조건공간에서 근접하되 실패율이 유의하게 낮은 3개 후보를 근거와 함께 제시한다.

- **탐색 권장 영역.** 요인설계 공간에서 성공도 실패도 보고된 바 없는 미탐색 조합(증거등급 E4)을 별도로 표기한다. 5.3 절에서 논하듯 이는 경보가 아니라 기회 신호다.

그림 2. COLLISION 출력 카드 예시 (소재 합성 도메인)

⚠ **조건 충돌 경보** 증거등급 E2 · 유사 사례 $n = 12$

입력 조건: 전구체 조성 A / 용매비 4:1 / 반응매 처리 / 어닐링 150°C 10 분 / 상대습도 45%

문헌 보고 성공률 82% (보고된 사례 $n = 34$ 기준)

보고편향 보정 RAS 31% [95% 신뢰구간 24 - 39%]

보정폭 $\Delta = -51\%p \rightarrow$ 이 조건은 성공 사례가 선택적으로 보고된 구간에 해당합니다.

주요 실패 양상: 상분리 7 건 · 재현성 붕괴 3 건 · 미상 2 건

근거: 문헌 4 편(식별자 링크) + 프로토콜 문제해결 기록 2 건

대안 조건 3 안

① 상대습도 30% 미만 환경 이관 — 유사 실패 0/9

② 첨가제 도입 — 실패율 12%, $n = 17$

③ 2 단 어닐링 — 실패율 18%, $n = 11$

본 경보는 주의 신호이며 실패의 확정적이지 않습니다. 모든 수치는 구간추정입니다.

4.5 Abstain 게이트

모든 경보는 출력 직전 근거 검증 게이트를 통과한다. 게이트는 (i) 근거 문장이 실제 원문에 존재하는가, (ii) 근거 문장이 주장하는 실패 양상과 태깅된 온톨로지 항목이 일치하는가, (iii) 근거 문헌의 식별자가 외부 API 에서 검증되는가를 확인한다. 하나라도 실패하면 경보를 발령하지 않고 기권한다. 기권은 오류가 아니라 정상 동작이며, 기권율은 7 장에서 성능 지표로 보고된다.

5. NFO: 음성결과 실패 온톨로지

5.1 설계 원칙

실패를 기술하는 어휘는 세 가지 요건을 동시에 만족해야 한다. 첫째, 도메인 간 이식 가능해야 한다. 소재 합성과 세포 배양의 실패는 하위 어휘가 다르지만 상위 구조는 공유되어야 한다. 둘째, 책임 소재를 지시하지 않아야 한다. 셋째, 근거 강도를 구분해야 한다. 세 번째 요건은 기존 어떤 실패 분류 체계에도 없으며 본 연구의 고유 기여다.

5.2 5 축 실패 분류

표 4. NFO 상위 5 축

축	정의	예시 (소재 합성)	예시 (생명과학)
재료	투입 물질의 속성에 귀속되는 실패	전구체 수분 함량, 순도 등급, 로트 편차	시약 역가 저하, 배지 조성
장비	기기·설비의 물리적 한계나 상태	온도 균일도, 진공도, 교반 효율	인큐베이터 CO ₂ 제어 편차
절차	수행 순서·시점·조작 방식	투입 순서, 승온 속도, 대기 시간	계대 시점, 시약 첨가 순서
환경	제어되지 않은 외부 조건	상대습도, 실온, 광노출	실내 온습도, 진동, 조명 주기
설계	가설·조건 설정 자체의 오류	조건공간 설정 오류, 대조군 부재	검정력 부족, 교란변수 미통제

각 축은 도메인별 하위 어휘로 확장되며, 상위 5 축은 불변으로 유지한다. 이 이층 구조가 도메인 간 통계 집계와 도메인 내 정밀도를 동시에 확보한다. 기존 표준과의 정렬 지점으로는 실험 메타데이터 기술을 위한 ISA 모형, 공학 신뢰성 분야의 고장모드영향분석(FMEA) 어휘, 소재 분야 온톨로지 체계를 참조하며, NFO는 이들을 대체하지 않고 음성결과 축을 추가하는 방식으로 결합된다.

5.3 증거등급 E1-E4

회수된 음성결과는 근거의 성격이 매우 다르다. 이를 구분하지 않고 동일하게 취급하면 시스템은 곧바로 신뢰를 잃는다. NFO는 네 등급을 정의한다.

표 5. 증거등급 체계

등급	정의	전형적 출처	경보 사용
E1 정량 실패	실패가 명시되고 수치가 병기됨	본문·SI의 정량 결과표	가중치 1.0
E2 서술 실패	실패가 명시되나 비정량	Methods 서술, 문제해결 절	가중치 0.6
E3 구조 추론	스크리닝 표에서 후속 단계로 이월되지 않은 조건	SI 최적화 격자	가중치 0.3 · 추론임을 표기
E4 부재 추론	조건공간에서 한 번도 보고되지 않은 조합	요인설계 공간의 공백	경보 금지 · 탐색 신호로 전환

설계 원칙 3 — 부재는 실패의 증거가 아니다. E4를 경보로 사용하는 순간 시스템은 미탐색 영역을 위험 영역으로 오인하고, 정확히 과학이 가야 할 방향을 가로막는다. NULLBANK는 E4를 반전시켜 탐색 권장 신호로 출력한다. 이 반전으로 시스템은 회피 도구인 동시에 실험 설계 도구가 된다.

이 설계는 자율실험실과의 접합점이기도 하다. 자율실험실의 다음 실험 선택 문제는 본질적으로 “아직 아무도 시도하지 않았고 실패 근거도 없는 영역”을 찾는 문제이며, E4 집합이 곧 그 후보 목록이다.

5.4 비식별화 3 단계

원문 → 기관·저자·과제번호 마스킹 → 조건벡터와 실패양상만 공유의 3 단계를 거친다. 공유 계층에서는 어떤 실패도 특정 기관이나 개인에게 귀속되지 않는다. 이는 기술적 선택이 아니라 시스템 성립의 전제 조건이다. 실패 공개가 평가상 불이익으로 이어질 수 있다는 합리적 우려가 해소되지 않는 한 2 단계 이후의 자율 기여는 발생하지 않는다.

5.5 레코드 스키마 (요약)

record_id · domain · condition_vector{ } · failure_axis[5 축] · failure_mode · evidence_grade{E1-E4} · evidence_span{doc_id, char_offset, quoted_span_id} · source_type · publication_year · deidentification_level · confidence · exploration_flag · evidence_half-life_weight

evidence_span은 원문 위치를 가리키는 포인터이며 원문 텍스트 자체를 복제하지 않는다. 이는 저작권 준수와 검증 가능성을 동시에 만족시키는 설계다.

6. RAS: 보고편향 보정 성공확률

6.1 정의

조건벡터 x 에 대해 RAS는 미보고 실험을 포함한 잠재 성공확률로 정의된다. 이는 문헌에서 직접 계산되는 관측 성공률과 다르다.

$$RAS(x) = \Pr[Y^* = 1 \mid X = x] \quad (\text{목표량})$$

$$\hat{p}(x) = \Pr[Y = 1 \mid X = x, S = 1] \quad (\text{문헌에서 관측되는 양})$$

여기서 S 는 보고 여부 지시변수다. S 가 Y^* 와 독립이 아닐 때 $\hat{p}(x)$ 는 $RAS(x)$ 의 일치추정량이 아니다.

6.2 이변량 프로빗 선택모형

선택식과 결과식을 상관된 오차항으로 결합한다.

$$\text{선택식: } S = 1[z'\gamma + u > 0]$$

$$\text{결과식: } Y^* = 1[x'\beta + \varepsilon > 0]$$

$$(u, \varepsilon) \sim \text{BVN}(0, 0, 1, 1, \rho), \quad \rho > 0$$

$\rho > 0$ 은 성공한 실험이 더 보고되기 쉽다는 가정을 표현한다. 최대우도 추정 후 $RAS(x) = \Phi(x'\hat{\beta})$ 로 산출한다. $\rho = 0$ 이면 선택 편향이 없고 RAS는 관측 성공률과 일치한다. 따라서 ρ 의 유의성 검정 자체가 “이 도메인에 보고편향이 존재하는가”에 대한 통계적 답이 된다.

6.3 배제제약: 무엇을 도구로 쓸 것인가

식별을 위해서는 보고 확률에는 영향을 주되 실험의 물리적 성공 여부에는 영향을 주지 않는 변수 z 가 필요하다. 후보는 다음과 같다.

표 6. 배제제약 후보와 타당성 평가

도구변수 후보	보고에 영향을 주는 경로	타당성 쟁점
게재지의 보조자료 분량 정책	SI 분량 제한이 느슨할수록 실패 조건 노출 증가	비교적 강함. 정책은 출판사가 설정하며 개별 조건의 화학과 무관
소속기관 오픈액세스 의무화 여부	의무화 기관일수록 전체 데이터 공개 성향 증가	기관 역량과 상관될 수 있어 통제 필요
과제 종료 시점 대비 실험 수행 시점	마감 임박 실험은 성패 무관하게 최종보고서에 포함	강함. 다만 시점 데이터 확보가 과제
사전등록 여부	사전등록 연구는 결과와 무관하게 보고 의무 발생	매우 강하나 해당 표본이 제한적
공동저자 기관 수	다기관 연구는 기록 규율이 상대적으로 엄격	연구 난이도와 상관 가능. 약한 도구

본 연구는 배제제약의 타당성이 논쟁 가능함을 인정한다. 따라서 RAS는 단일 점추정으로 제시되지 않으며, 다음 세 가지를 함께 보고하는 것을 원칙으로 한다. (i) ρ 를 -1에서 1까지 격자 탐색한 민감도 곡선, (ii) 도구변수를

하나씩 제거한 강건성 검정, (iii) 미관측 교란의 크기에 대한 경계값 분석. 어떤 도구 조합에서도 부호가 뒤집히지 않는 구간만을 실사용 경보에 반영한다.

6.4 보정폭 Δ : 점추정보다 중요한 산출물

본 연구가 강조하는 실천적 논점은 다음과 같다. RAS의 절대 수준은 배제제약에 민감하지만, 관측값과 보정값의 차이

$$\Delta(x) = \hat{p}(x) - \text{RAS}(x)$$

의 조건 간 순위는 훨씬 강건하다. Δ 가 큰 조건은 성공만 선택적으로 보고된 구간이고, Δ 가 작은 조건은 성공과 실패가 함께 보고되어 문헌을 비교적 신뢰할 수 있는 구간이다. 즉 Δ 는 성공확률의 보정치이기 이전에 문헌 신뢰도의 지도다.

실무적 함의 연구자에게 “이 조건의 진짜 성공률은 31%입니다”라고 말하는 것보다 “이 조건은 문헌을 믿기 어려운 구간이고, 저 조건은 문헌이 비교적 정직한 구간입니다”라고 말하는 편이 더 정확하고 더 유용하다. 전자는 강한 식별 가정을 필요로 하지만 후자는 순위 정보만으로 성립한다. NULLBANK의 기본 표시 모드는 Δ 기반 신뢰도 등급이며, RAS 수치는 보조 정보로 제시된다.

6.5 독립적 교차검증: 포획-재포획

선택모형과 완전히 다른 가정에 기반한 두 번째 추정 경로를 병행한다. 특정 조건 c 를 시도한 흔적이 서로 독립적인 출처—학술 문헌, 프로토콜 저장소, 학위논문—에 각각 나타날 때, 역학에서 사용하는 다중출처 포획-재포획 추정으로 실제 시도 집단의 크기를 추정할 수 있다.

$$\hat{N}(c) \approx n_A \cdot n_B / m_{AB} \quad (\text{Lincoln-Petersen 형태})$$

$$\text{암흑비 } DR(c) = 1 - |O_c| / \hat{N}(c)$$

암흑비는 조건 c 에 대해 실제 시도 중 몇 비율이 어떤 문헌에도 나타나지 않는지를 추정한다. 선택모형과 포획-재포획은 서로 다른 가정에 의존하므로, 두 방법이 유사한 결론에 수렴하면 신뢰도가 실질적으로 상승한다. 수렴하지 않으면 그 불일치 자체를 보고한다.

6.6 해커톤 스코프에서의 축약형

본선 19 시간 내에 완전한 이변량 프로빗 추정과 민감도 분석을 수행하는 것은 현실적이지 않다. 따라서 시연 스코프에서는 (i) 단일 도구변수를 사용한 Heckman 2 단계 근사 또는 역확률가중 로지스틱 근사로 RAS를 산출하고, (ii) ρ 격자 민감도 곡선은 사전 계산된 소규모 격자로 표시하며, (iii) 화면과 발표자료에 축약 추정임을 명시한다. 추정 정밀도를 과장하지 않는 것은 성능이 아니라 신뢰성의 문제이며, 7장의 지표 체계는 이 축약형에서도 산출 가능하도록 설계되었다.

7. KNEG: 평가 프로토콜과 벤치마크

7.1 왜 벤치마크가 필요한가

음성결과 회수 시스템은 그 성격상 “정답”이 공개되어 있지 않은 대상을 다룬다. 따라서 시스템의 주장을 검증 가능하게 만드는 평가 체계 없이는 어떤 성능 주장도 신뢰할 수 없다. 본 연구는 회수 시스템 전용 벤치마크 KNEG(Korean Negative-results Evaluation for scientific aGents)를 함께 제안한다. 벤치마크는 시스템의 부속물이 아니라 독립적 공공재이며, 후속 연구가 비교 대상으로 삼을 수 있는 자산이다.

7.2 과제 정의

- **과제 1 — 음성결과 탐지.** 주어진 문서에서 음성결과 서술 구간을 식별한다.
- **과제 2 — 증거등급 부여.** 탐지된 구간에 E1-E4를 부여한다.
- **과제 3 — 온톨로지 태깅.** 5축 실패 분류를 부여한다.
- **과제 4 — 조건 충돌 예측.** T_0 시점 코퍼스만으로 이후 문헌에서 보고될 실패를 예측한다.

7.3 지표

표 7. KNEG 지표 체계

지표	측정 대상	산출	목표 방향
NRR	음성결과 회수율	전문가 주석 대비 재현율	높을수록 좋음
EGA	증거등급 일치도	Cohen's κ	높을수록 좋음
FOA	온톨로지 태깅 정확도	5축 매크로 F1	높을수록 좋음
CAP@k	경보 정밀도	후향 검증 기준 상위 k 정밀도	높을수록 좋음
ECE	RAS 보정도	기대 보정 오차	낮을수록 좋음
HAR	무근거 경보 비율	근거 미연결 경보 / 전체 경보	0이 목표
AbR	기권율	기권 건수 / 요청 건수	HAR과 병기하여 곡선으로 보고

HAR과 AbR은 상충 관계에 있다. 기권을 늘리면 무근거 경보는 줄지만 유용성이 감소한다. 단일 지표로 보고하면 조작이 가능하므로, 본 연구는 정밀도-재현율 곡선과 동일한 방식으로 HAR-AbR 곡선 전체를 보고할 것을 규범으로 제시한다.

7.4 시간분할 후향 검증

이 시스템이 반증 가능한 과학적 주장을 하려면 다음 절차를 통과해야 한다.

- 코퍼스를 시점 T_0 에서 동결한다 (예: 2022년 이전 문헌만 사용).
- T_0 시점 데이터만으로 조건 집합에 대한 경보와 RAS를 생성한다.
- T_0 이후 문헌(2023-2025)에서 해당 조건의 실제 보고 결과를 확인한다.
- 경보 발령 조건과 미발령 조건의 사후 실패율 차이를 검정하고, CAP@k와 ECE를 산출한다.

이 절차의 의미 후향 검증은 “우리 시스템이 유용해 보인다” 는 주장을 “우리 시스템의 2022 년 경보 중 상위 20 건에서 사후 실패율이 대조군 대비 유의하게 높았다” 는 검정 가능한 진술로 바꾼다. 반증 가능성은 시연의 화려함으로 대체할 수 없는 종류의 설득력이다. 해커톤 스코프에서는 단일 도메인 50 개 조건 규모의 축소판으로 수행 가능하다.

7.5 기준선

비교 기준선으로 (i) 키워드 검색 기반 회수, (ii) 온톨로지·증거등급 없는 단순 RAG, (iii) 보정 없는 관측 성공률, (iv) 인간 전문가 단독 판단을 설정한다. 특히 (iii) 대비 개선이 RAS 의 존재 이유를 직접 증명하는 비교이며, (ii) 대비 개선이 NFO 의 존재 이유를 증명한다.

8. 구현 계획

8.1 본선 19 시간 스코프 원칙

본 대회는 실제 개발 전 과정이 본선 대회 기간 내에 진행될 것을 요구한다. 따라서 사전에 준비 가능한 것은 설계도, 프롬프트 설계 방침, 데이터 출처 목록, 환경 숙련도뿐이며 코드는 본선에서 작성한다. 이 제약은 아키텍처 선택을 규정한다. 사전 학습이나 대규모 파인튜닝을 요구하지 않고, 공개 API 와 언어모델 오케스트레이션만으로 완결되는 구조여야 한다.

도메인은 하나로 좁힌다. 문헌에 실패 조건이 상대적으로 명시적으로 남는 소재 합성 또는 촉매 분야를 권장한다. 도메인 확장 가능성은 NFO 상위 5 축의 도메인 불변성으로 논증하되, 시연은 단일 도메인에서 완결도를 확보하는 데 집중한다.

8.2 데이터 및 기술 스택

표 8. 데이터 출처 및 스택

구분	구성	역할
문헌 수집	OpenAlex, PubMed Central OA, arXiv 전문	코퍼스 원천. 본선 기간 중 API 수집
실패 근거 보강	protocols.io 문제해결 질, Retraction Watch, PubPeer	E2 등급 근거의 주요 공급원
오케스트레이션	상태 그래프 기반 다중 에이전트 프레임워크	에이전트 간 상태 전달 및 게이트 제어
검색	임베딩 + 벡터 인덱스(FAISS 또는 Chroma)	조건벡터 유사도 검색
보정 추정	Heckman 2 단계 근사 / 역확률가중 로지스틱	RAS 및 Δ 산출
인터페이스	경량 웹 UI (Streamlit 또는 Gradio)	경보 카드 시연
산출물	소스코드 공개 저장소, 발표자료	제출 요건

합성 연구노트를 데모 보조 데이터로 사용할 경우 화면과 저장소 문서에 생성 데이터임을 반드시 명시한다. 공고 유의사항은 생성형 AI·오픈소스·외부 데이터 출처의 명확한 기재를 요구하며 고의 누락을 실격 사유로 규정하고 있다.

8.3 19 시간 작업 배분

표 9. 본선 시간 계획 (9 월 30 일 17:00 → 10 월 1 일 12:00)

시간	작업	완료 기준
17:00-19:00	저장소 구성, API 키, 코퍼스 수집 스크립트	문헌 300-500 편 확보
19:00-22:00	RECOVERY: 음성결과 추출 및 근거 포인터 부착	구조화 레코드 200 건
22:00-01:00	ONTOLOGY: NFO 태깅, 증거등급, 비식별화, 인덱싱	벡터 저장소 구축
01:00-04:00	COLLISION: 검색·경보 로직, RAS 축약 추정, Abstain 게이트	핵심 기능 end-to-end 동작
04:00-06:00	인터페이스 및 경보 카드 렌더링	시연 가능 화면
06:00-08:00	축소 후향 검증 실행 + 버퍼	CAP@k 수치 1 개 확보

시간	작업	완료 기준
08:00-10:00	시나리오 3 종 리허설, 실패 경로 제거	시연 대본 확정
10:00-12:00	발표자료 마감, 5 분 발표 리허설 3 회	제출 완료

06:00-08:00 구간의 버퍼는 협상 대상이 아니다. 19 시간 개발에서 가장 흔한 실패 원인은 기능 부족이 아니라 시연 직전의 미검증 통합이다. 이 구간에서 축소 후향 검증 수치를 하나라도 확보하면, 발표에서 “동작합니다”가 아니라 “검증했습니다”라고 말할 수 있게 된다.

8.4 시연 시나리오

- **시나리오 A — 경보.** 문헌상 유망해 보이는 조건을 입력한다. 시스템이 유사 실패 사례와 보정폭을 제시하며 주의 신호를 발령한다.
- **시나리오 B — 기권.** 근거가 부족한 조건을 입력한다. 시스템이 경보를 발령하지 않고 기권한다. 이 장면이 신뢰성 설계를 증명하는 가장 강력한 시연이다.
- **시나리오 C — 탐색 권장.** 미탐색 조합(E4)을 입력한다. 시스템이 위험이 아니라 기회로 분류하고 탐색 우선순위를 제시한다.

세 시나리오의 순서가 중요하다. 경보 → 기권 → 탐색 권장의 순서는 “이 시스템은 겁을 주는 도구가 아니라 판단을 돕는 도구”라는 메시지를 3 분 안에 전달한다.

9. AI 윤리 및 신뢰성

9.1 낙인화 방지: 이 시스템이 하지 않는 일

실패 데이터를 다루는 시스템의 가장 큰 위험은 기술적 오류가 아니라 사회적 오용이다. NFO는 책임 소재를 태깅하지 않고 물리적·절차적 원인만 태깅한다. 데이터 거버넌스 조항으로 다음을 명문화한다.

- 개인·연구팀·기관에 대한 평가, 인사, 예산 배분 목적의 사용 금지
- 특정 기관의 실패율 산출 및 기관 간 순위화 금지
- 공유 계층에서 기관·저자·과제번호 복원이 가능한 형태의 조회 금지

이 금지 조항들은 부가적 배려가 아니라 시스템의 작동 조건이다. 2 단계 이후 기관 자율 기여를 유도하려면 기여가 불이익으로 이어지지 않는다는 보장이 선행되어야 한다.

9.2 환각 통제

모든 경보에는 원문 근거 문장 포인터와 문헌 식별자가 필수로 부착된다. 근거를 찾지 못하면 경보를 발령하지 않는다(4.5 절 Abstain 게이트). 무근거 추론 0 건이 설계 목표이며, HAR 지표로 상시 측정한다. 원문 텍스트는 복제하지 않고 위치 포인터만 저장하여 저작권을 준수하면서도 검증 가능성을 확보한다.

9.3 불확실성 커뮤니케이션

RAS는 점추정으로 제시되지 않으며 신뢰구간과 함께 표시한다. 인터페이스 문구는 “AI가 실패를 예측했습니다”가 아니라 “주의 신호입니다”로 고정한다. 6.4 절에 따라 기본 표시 모드는 문헌 신뢰도 등급이며 확률 수치는 보조 정보다. 이는 사용자가 시스템의 확실성을 과대 해석하지 않도록 하는 인터페이스 차원의 안전장치다.

9.4 개인정보와 보안

공개 문헌 기반 1 단계에서는 개인정보 처리가 발생하지 않는다. 2 단계 기관 기여 이후에는 수집 시점 비식별화를 원칙으로 하며, 원문 접근 권한과 공유 계층 접근 권한을 분리한다. 출연연의 민감 연구 데이터를 외부 상용 AI에 입력하기 어렵다는 현장의 제약을 고려할 때, 기관 내부 접근에 한정된 배치 구성을 기본 옵션으로 설계한다.

9.5 출처 공개

사용한 생성형 AI 모델, 오픈소스 라이브러리, 외부 데이터셋의 출처를 저장소 문서에 표 형태로 전면 공개한다. 이는 대회 요건이자 본 시스템이 주장하는 투명성 원칙의 자기 적용이다. 음성결과의 투명성을 요구하는 시스템이 자기 구성의 투명성을 지키지 않는다면 그 주장은 성립하지 않는다.

10. 기대효과와 확장성

10.1 3 단계 데이터 확보 로드맵

표 10. 단계별 확보 전략

단계	데이터 원천	필요 조건	시점
1 단계 회수	공개 문헌, 프로토콜 저장소, 학위논문	추가 제도 없이 즉시 가능	현재 · 본선 시연
2 단계 자율기여	기관 자율 등록 음성결과	과제 평가 가점, 레코드 식별자 발급을 통한 업적 계상	6-18 개월
3 단계 네이티브	자율실험실, 전자연구노트 자동 연동	장비·데이터 표준 정립	18 개월 이후

1 단계가 다른 두 단계와 독립적으로 작동한다는 점이 이 로드맵의 핵심이다. 제도 변화나 표준 합의를 기다리지 않고 오늘 시연할 수 있으며, 그 시연이 2·3 단계의 필요성을 실증하는 근거가 된다.

10.2 자율실험실 협의체 연계

2.3 절에서 논한 바와 같이, 2026 년 8 월 출범한 자율실험실 산·학·연 협의체는 데이터 축적과 표준 인터페이스 정립을 핵심 임무로 하며 NAIS 가 공동간사를 맡고 있다. NFO 는 이 표준 논의에 즉시 투입 가능한 음성결과 스키마 제안이다.

시간축에서의 상보성이 특히 중요하다. 자율실험실은 앞으로 발생할 실패를 기록하지만, 지난 수십 년간 국가 예산으로 수행되어 실패한 실험들은 오직 문헌 속에만 남아 있다. NULLBANK 의 1 단계 회수는 그 과거 자산에 접근하는 유일한 경로다. 자율실험실 데이터만으로 구축한 음성결과 자산은 출발 시점 이전의 역사를 갖지 못한다.

10.3 파운데이션 모델 학습 자산

회수된 음성결과 코퍼스는 과학 특화 모델의 음성 표본이 된다. 성공 사례만으로 학습된 모델이 실패를 예측하지 못하는 것은 원리적 한계이며, 이 한계는 모델 규모 확대로 해소되지 않는다. 편향된 학습 데이터로 만든 모델의 예측 성능이 전통적 방법을 넘어서지 못한다는 실증은 이미 보고되어 있다. 음성결과 자산은 국가 차원 과학 AI 구축에서 선택 사항이 아니라 전제 조건이다.

10.4 왜 이 일은 NST·NAIS 여야 하는가

NULLBANK 의 병목은 기술이 아니라 제도다. 1 단계는 기술만으로 가능하지만 2 단계는 평가 제도의 변경을 요구하고, 3 단계는 기관 간 표준 합의를 요구한다. 음성결과 등록을 연구 업적으로 계상하려면 평가 체계에 손을 대야 하고, 그 권한을 가진 주체는 대학도 기업도 개인 연구자도 아니다.

적합성 논거 국가과학기술연구회는 소관 출연연 전체를 아우르는 제도 설계 권한과 데이터 표준 조정 권한을 동시에 가진 사실상 유일한 기관이다. NULLBANK 는 편리한 도구를 하나 더 만드는 제안이 아니라, NST 가 아니면 만들 수 없는 공통 자산—데이터셋, 표준(NFO), 평가체계(RAS·KNEG)—을 만드는 제안이다. 이는 허브가 스포크에 제공해야 할 항목의 정의와 정확히 일치한다.

10.5 후속 연구 연계

- **벤치마크·데이터셋 논문.** KNEG: 과학 에이전트를 위한 음성결과 벤치마크 — 기계학습 데이터셋·벤치마크 트랙
- **방법론 논문.** 표본선택 보정을 통한 보고편향 조정 성공확률 추정 — 과학계량학 및 기술혁신 분야 학술지
- **정책 논문.** 음성결과를 국가 연구자산으로 계상하기 위한 제도 설계 — 과학기술정책 연구기관 및 기술혁신학회
- **표준 기여.** NFO 를 자율실험실 협의체 데이터 표준 논의에 스키마 초안으로 제안

11. 한계와 위험

11.1 탐색 붕괴: 이 시스템 고유의 위험

가장 심각한 위험은 정확도가 아니라 시스템이 자신이 예측하는 세계에 개입한다는 사실에서 발생한다. NULLBANK가 널리 사용되어 연구자들이 경보 조건을 회피하면, 그 조건에 관한 새로운 증거는 더 이상 생성되지 않는다. 시스템의 믿음은 갱신되지 않은 채 고착된다.

더 나쁜 시나리오가 있다. 2015년의 장비 한계 때문에 실패했던 조건이 2027년의 장비로는 성공할 수 있다. 그러나 NULLBANK가 그 조건에 경보를 유지하는 한 아무도 시도하지 않으므로, 시스템은 이 사실을 영원히 학습하지 못한다. 실패를 회수하려는 시스템이 새로운 지식의 생성을 차단하는 역설이다.

표 11. 완화 설계

장치	작동 방식	근거
ϵ -재탐색 유보	경보 대상 조건 중 무작위 ϵ 비율(초기 5-10%)을 재검증 권장으로 재분류	다중슬롯머신 문제의 탐색 항. 활용만 하는 정책은 최적해를 놓친다
증거 시효 감쇠	실패 근거의 가중치를 시간에 따라 감쇠. $w(t)=2^{(-\Delta t/h)}$, h 는 도메인별 반감기	장비·재료 세대 교체 시 과거 실패의 정보량 감소
역경보 갱신	경보 이후 성공 사례 보고 시 즉시 상향 갱신하고 해당 경보의 오류를 공개 기록	시스템 오류의 은폐 방지. 자기 적용 원칙

이 절의 위상 탐색 붕괴는 본 연구가 이 시스템을 설계하면서 발견한 문제이며, 문헌 회수나 편향 보정 어느 쪽에서도 자동으로 도출되지 않는다. 예측 시스템이 예측 대상 세계에 배치될 때 발생하는 수행적 되먹임의 한 사례이며, 이를 사후 대응이 아니라 아키텍처 구성 요소로 내장한 것이 본 설계의 특징이다.

11.2 식별 가정의 취약성

6.3 절에서 논한 대로 배제제약의 타당성은 논쟁 가능하다. 본 연구는 이를 은폐하지 않고 민감도 곡선과 경계값 분석을 병행 보고하며, 어떤 가정 조합에서도 결론이 뒤집히지 않는 구간만 실사용 경보에 반영한다. 나아가 6.4 절에서 제시한 Δ 기반 신뢰도 등급은 식별 가정에 대한 의존도가 현저히 낮은 대안적 산출물이다.

11.3 추출 오류와 문헌 편중

언어모델의 실험방법 서술 이해는 완전하지 않으며, 특히 조건의 미묘한 차이를 동일 조건으로 잘못 병합할 위험이 있다. 근거 문장 강제 연결과 전문가 표본 검수가 1차 방어선이고, EGA·FOA 지표가 상시 감시 수단이다. 또한 현 코퍼스는 영어권 오픈엑세스 문헌에 편중되어 있어, 국내 기관의 미보고 연구는 여전히 암흑 영역에 남는다. 이는 2·3 단계의 필요성을 뒷받침하는 근거이자 1 단계의 명시적 한계다.

11.4 온톨로지 이식성

NFO 상위 5 축의 도메인 불변성은 설계상의 주장이며 실증이 필요하다. 최소 3개 이질적 도메인에서 태깅 일치도를 측정하는 것이 후속 과제다. 하위 어휘는 도메인별 확장을 전제하되, 확장이 상위 축의 의미를 침식하지 않도록 축 정의를 형식적으로 고정한다.

12. 결론

본 연구는 성공률 99%를 둘러싼 논쟁이 측정 단위의 불일치에서 비롯되었음을 논증하고, 논쟁의 층위를 과제에서 실험으로 이동시켰다. 이 이동은 평가 제도를 건드리지 않으면서 문제의 실체에 접근하는 경로를 연다.

제한한 시스템 NULLBANK는 실험공간에서 관측집합으로 가는 삼중 절단에 대해 각각 다른 개입을 수행한다. 색인 절단은 역상 회수로, 보고 절단은 구조화된 부분 회수로, 원리적으로 회수 불가능한 기록 절단은 통계적 보정으로 대응한다. 회수와 보정은 서로의 전제이며, 어느 한쪽만으로는 편향된 데이터를 확대하거나 근거 없는 추정치를 생산할 뿐이다.

방법론적으로는 미술시장의 미관측 거래 보정 구조를 과학 문헌 영역으로 이식하여 RAS를 정의했고, 점추정보다 보정폭 Δ 가 더 강건하고 실용적인 산출물임을 논증했다. 아울러 근거 강도를 구분하는 증거등급 체계를 도입하고, 부재를 실패로 오인하지 않기 위해 최하위 등급을 경보에서 배제하고 탐색 신호로 반전시켰다.

마지막으로 본 연구는 이 시스템이 성공할 경우 발생하는 고유 위험—탐색 붕괴—을 식별하고 세 가지 완화 장치를 아키텍처에 내장했으며, 시스템의 주장을 반증 가능하게 만드는 후향 검증 프로토콜과 벤치마크 KNEG를 제시했다.

국가 연구개발의 성패를 판정하는 일은 오래된 논쟁이다. 그러나 판정 이전에 기록의 문제가 있다. 기록되지 않은 것은 판정될 수 없고, 판정될 수 없는 것은 학습될 수 없으며, 학습될 수 없는 것은 같은 자리에서 다시 실패한다. 실패는 성공의 부재가 아니라, 아직 조건이 갖추어지지 않은 가능성의 좌표다. 그 좌표를 국가 자산으로 계상하는 일이 본 연구의 목적이다.

13. 참고문헌 및 출처

정책 · 제도

한국과학기술한림원, 『실패없는 R&D 역설: 한국과학기술 혁신을 위한 조건』, 정책보고서, 2026. (홍성욱 서울대 과학학과 교수 집필 부분 포함)

「"한국 R&D 문제는 99% 성공률이 아니라, 거시적 정책설계 미흡이다"」, ZDNet Korea, 2026. 6. 30.

「유용균 국가과학 AI 센터 단장 "'AI 과학자'로 노벨상급 성과 목표"」, ZDNet Korea, 2026. 5. 22.

「유용균 단장 "2035 년되면 과학자가 곧 하나의 연구소"」, ZDNet Korea, 2026. 7. 29.

과학기술정보통신부, 「자율실험실 산·학·연 협의체 출범」 관련 보도, 2026. 8. 11. (이데일리·헬로디디·서울경제 등)

국가과학 AI 연구센터(NAIS) 센터 개요 및 인사말, <https://nais.re.kr/about>

국가과학기술연구회, 「2026 NAIS AI 해커톤 모집 공고 및 참가자 가이드라인」, 2026.

출판편향 · 음성결과

Ioannidis, J. P. A. (2005). Why Most Published Research Findings Are False. PLoS Medicine, 2(8).

Fanelli, D. (2010). Do Pressures to Publish Increase Scientists' Bias? PLoS ONE, 5(4).

Franco, A., Malhotra, N., & Simonovits, G. (2014). Publication Bias in the Social Sciences: Unlocking the File Drawer. Science, 345(6203).

Echevarría, L., Malerba, A., & Arechavala-Gomez, V. (2021). Researchers' Perceptions on Publishing "Negative" Results and Open Access. Nucleic Acid Therapeutics, 31(3).

Journal of Negative Results in Biomedicine, 발행 중단 공지(2017. 9.), BioMed Central.

Dead Science Walking: Publication Bias and the AI Scientist Pipeline, arXiv preprint, 2026.

LLMs Have Made Failure Worth Publishing, arXiv preprint, 2026.

자율실험실 · AI for Science

Autonomous Chemical Experiments: Challenges and Perspectives on Establishing a Self-Driving Lab. Accounts of Chemical Research, 55(17), 2022.

Autonomous chemistry: Navigating self-driving labs in chemical and material sciences. Matter, 2024.

Performance metrics to unleash the power of self-driving labs in chemistry and materials science. Nature Communications, 15, 2024.

표본선택 보정

Heckman, J. J. (1979). Sample Selection Bias as a Specification Error. Econometrica, 47(1).

Copas, J. B., & Shi, J. Q. (2000). Meta-analysis, funnel plots and sensitivity analysis. Biostatistics, 1(3).

Oster, E. (2019). Unobservable Selection and Coefficient Stability. Journal of Business & Economic Statistics, 37(2).

추병근, K-VALUE 연구: 시장관측격차(MOG) 보정 프레임워크, 미간행 연구노트, 2026.

본 보고서에 사용된 수치 중 그림 2의 경보 카드 예시 수치는 시스템 출력 형식을 설명하기 위한 가상 예시이며 실측값이 아니다. 실제 수치는 본선 구현 시 산출된다.