PROJECT REVIEW / SUBMISSION DRAFT

책책책을 읽읍시다

AI 도서 큐레이션 프로젝트 제안서

38쪽 원문 전문 검토 · 10-15분 발표 대본 · 슬라이드별 보완 · 심사위원 Q&A; · 연구설계 재구성

제출물 성격	대상 수상형 재구성 제안서
핵심 연구 주장	장기 대화 메모리가 도서 추천의 적합도와 실행 가능성을 유의하게 높이는가?
원문 기준	사용자 제공 38쪽 제안서 전체
작성 기준일	2026-09-15
근거 표시	원문 근거 / 외부 검증 / 개선 제안으로 구분

심사위원이 한 문장으로 기억해야 할 메시지

이 프로젝트는 '책을 추천하는 챗봇'이 아니라, 세션이 달라져도 사용자의 독서 맥락을 기억하고 그 기억이 실제 추천 성능을 얼마나 개선하는지 실험으로 증명하는 도서관형 CRS이다.

00 / EXECUTIVE BRIEF

결론 먼저: 원문을 수상작으로 만드는 핵심 전환

원문은 문제의식과 기능 아이디어가 풍부하다. 수상 가능성을 높이려면 기능 목록을 줄이는 것이 아니라, 메모리의 효과를 독립변수로 만들고 정보나루 API를 사실성·실행 가능성의 기준점으로 삼아야 한다.

최종 포지셔닝

대화 누적형 Memory-Augmented Conversational Recommender System for Public Libraries. 단순 개인화가 아니라 세션 간 맥락 유지, 관심사 전환, 다중 프로필 분리, 실제 대출 가능성까지 한 번에 검증한다.

축	원문 상태	수상형 재구성
문제	검색창은 질의만 보고 사용자를 기억하지 못한다	세션 간 맥락 단절이 발견 실패, 재설명 비용, 부정확한 추천으로 이어진다는 검증 가능한 문제로 정의
기여	Session Node + Preference Cluster 아이디어	메모리 없음 대비 메모리 계층이 NDCG, Recall, 전환 적응, 설명 충실성을 얼마나 높이는지 ablation으로 증명
데이터	10만 건 서지 + 정보나루 API + 3개 페르소나	아이템-API-대화-정답 프로필을 분리하고, 합성 데이터는 인간 검수로 보정
평가	F1, Recall@K, NDCG@K, LLM Judge 중심	프로필·메모리·검색·추천·도구 호출·API 사실성의 6층 지표와 신뢰구간을 제시
리스크	API 실시간성, 표본 수, 임계값 근거가 불명확	조회 시각·갱신 지연을 노출하고 표본·임계값·실험시드를 사전 고정

권장 성공 기준은 결과가 아니라 사전 등록할 gate이다. 아래 수치는 개선 제안이며 원문에서 관측된 결과가 아니다.

게이트	제안 기준
메모리 효과	No-memory 대비 NDCG@10 상대 개선 10% 이상, 95% bootstrap CI가 0을 넘는지 보고
프로필 갱신	Keep / Add / Revise / Suppress 분류 macro-F1 0.85 이상
API 사실성	대출 가능 여부 exact accuracy 0.95 이상; 조회 시각과 함께 평가
관심사 전환	전환 이후 3회 이내 새 주제 Recall@10이 기준선보다 유의하게 회복
운영성	API 포함 p95 응답시간, 실패율, 호출비용을 함께 보고

01 / READING THE ORIGINAL

근거를 세 층으로 분리하는 편집 원칙

원문은 기획서와 연구계획서의 경계에 있다. 제출본에서는 문장을 지우기보다 각 주장에 근거의 성격을 붙여 신뢰도를 높인다.

표시	의미	작성 규칙
[원문 근거]	업로드된 38쪽 안에 직접 제시된 내용	페이지 번호를 붙이고, 결과가 아닌 계획은 계획으로 쓴다
[외부 검증]	공식 문서·원 논문으로 확인한 보완 정보	출처 URL과 확인일을 참고문헌에 명시한다
[개선 제안]	원문을 수상형으로 강화하기 위한 설계 판단	목표치·임계값·표본 수는 관측 결과가 아님을 명시한다
[검증 필요]	원문만으로는 사실성·재현성을 판단할 수 없는 부분	담당자, 확인 시점, 통과 조건을 지정한다

전체 판정

- 강점: 문제-기능-평가로 이어지는 뼈대가 이미 있고, Session Node / Preference Cluster / Retrieval / Reranking / 정보나루 API라는 차별화 재료가 구체적이다.

- 가장 큰 약점: 메모리가 좋아진다는 가정은 있으나, 메모리 구성요소가 추천 품질을 개선하는 인과 경로와 비교군이 아직 고정되어 있지 않다.

- 심사 리스크: 경쟁 서비스의 단정적 한계 서술, 2025/2026 통계·논문 표기, '실시간 재고', 3 x 10 시뮬레이션, 80% 수렴 기준은 근거 또는 정의가 부족하다.

- 편집 방향: '대화형 도서 추천 서비스'라는 제품 설명을 '장기 메모리의 증분 효과를 측정하는 연구형 프로토타입'으로 바꾼다.

권장 제목

책책책을 읽읍시다: 도서관 정보나루와 장기 대화 메모리를 결합한 개인화 CRS - 세션 간 맥락 유지가 추천 적합도와 실행 가능성을 높이는가?

02 / FULL 38-PAGE REVIEW

38쪽 원문 전문 검토

각 페이지를 '핵심 내용 - 잘된 점 - 심사 리스크 - 제출본 수정'의 동일한 렌즈로 판독했다. 페이지 31은 실질 내용이 없어 재구성본에서 제거하거나 부록으로 이동.

원문 p.01 | 표지와 문제정의 시작

핵심: 기존 검색은 제목·저자 중심이며 세션 간 탐색 맥락을 잇지 못한다고 제시.
강점: 문제 출발점이 선명하고 단절 예시가 직관적.
리스크: '현재 도서관 AI 서비스'의 범위와 근거가 없음.
제출본 보완: 발견형 질의, 세션 맥락, 재설명 횟수를 상태변수로 정의.

원문 p.02 | 선택 부담과 종합 시사점

핵심: 독서 선택의 인지부담과 조사 통계를 근거로 개인화 맥락 시스템의 필요성을 말함.
강점: 사회적 가치와 사용자 경험을 연결.
리스크: 조사 연도·표본·문항 원문이 없어 수치 단정 위험.
제출본 보완: 공식 원문을 붙이고, 미확인 시 '원문 인용 수치'로 낮춰 표기.

원문 p.03 | CRS와 기대효과

핵심: Cold Start, 대화 적응, Memory-Augmented Recommendation 및 신뢰·발견·장서 활용 효과.
강점: 기능 아이디어가 연구 주장으로 확장될 수 있음.
리스크: 롱테일·신뢰도·인지비용이 측정 정의 없이 기대효과로 남음.
제출본 보완: discovery=coverage/novelty, trust=faithfulness/acceptability, utility=availability@K.

원문 p.04 | 밀리의 서재와 사용후기

핵심: AI 답변이 단발식 문답에 가깝다는 관찰.
강점: 직접 사용 경험을 경쟁 분석의 출발점으로 삼음.
리스크: 사용후기 1건은 대표성 있는 비교가 아님.
제출본 보완: 동일 프롬프트·시나리오 비교를 하거나 '관찰'로 낮춰 씀.

원문 p.05 | 크레마 클럽과 사용후기

핵심: 대화 형식과 설명은 강점이나 직전 대화 연결은 약하다는 관찰.
강점: 우리 차별점이 연속성임을 보여줌.
리스크: 기능 제공 여부는 시점 의존적.
제출본 보완: 조사일·공식 페이지를 붙이고 장기 메모리 성능으로 차별화.

원문 p.06 | 교보문고 트렌드 플러스

핵심: 행동 데이터와 독서지수 기반 컨설팅을 소개.
강점: 공급자 데이터와 이용자 맥락의 대비가 가능.
리스크: 매대 체류·독서지수 범위가 불명확.
제출본 보완: 공식 자료가 없으면 사례 소개로만 쓰고, 우리 시스템의 데이터 범위를 명시.

원문 p.07 | 상용 서비스 비교표

핵심: 세 서비스의 특징·한계와 기존 연구로 전환.
강점: 시장 맥락을 빠르게 보여줌.
리스크: 경쟁사 한계의 단정, 표 비대칭, 출처 부재.
제출본 보완: 대화 연속성·설명·실행 가능성 3개 기준으로 통일.

원문 p.08 | RecLLM·CSUSER/CSI

핵심: LLM 프로필, 합성 대화, 동적 프로필 갱신을 참조.
강점: 연구 재료를 시스템 설계와 연결.
리스크: 기여·한계가 단순화됐고 CSUSER/CSI 서지 검증 필요.
제출본 보완: 원 논문 기여와 우리 적용 가설을 분리하고 일반화 금지.

원문 p.09 | Agent4DL·A-MEM·Profile-aware Judge

핵심: 도서관 시뮬레이션, 동적 메모리, 프로필 기반 평가를 묶음.
강점: 평가 방법론까지 참고.
리스크: 최신 논문은 버전·출판 상태를 고정해야 함.
제출본 보완: 합성 평가의 재현성과 분포 차이를 함께 명시.

원문 p.10 | 문헌 요약과 데이터 확보

핵심: 5개 연구 활용점과 정보나루, 10만 건 DB, 합성 대화를 제시.
강점: 연구-데이터-평가가 연결.
리스크: 클라비 데이터는 제공 예정이지 확보 완료가 아님.
제출본 보완: 권한·필드·수령일·품질검사·대체경로를 데이터 계약표로 추가.

원문 p.11 | 도서관 목록·장서 API

핵심: region, libCode, pageNo, pageSize로 도서관·장서를 조회.
강점: 키 연결 흐름이 시연 친화적.
리스크: 실제 응답 포맷·파라미터 일치 여부 확인 필요.
제출본 보완: API adapter와 요청·응답 스키마 테스트 추가.

원문 p.12 | 장서·소장여부 API

핵심: ISBN13으로 장서와 대출 가능 여부를 연결.
강점: ISBN 공통 조인이 실용적.
리스크: 대출 상태가 실시간인지 확정할 수 없음.
제출본 보완: checked_at, source, freshness_note를 저장·표시.

원문 p.13 | bookExist·인기대출

핵심: hasBook·loanAvailable 필터와 인기대출을 cold-start 풀로 사용.
강점: 실행 가능한 추천으로 연결.
리스크: 인기 편향, 인구통계 파라미터 단순화.
제출본 보완: 인기추천은 후보 생성 baseline으로 제한하고 개인화 점수와 분리.

원문 p.14 | 인기대출 응답·신작

핵심: ranking, isbn13, loan_count와 신작 조회를 설명.
강점: API 결과의 쓰임새가 분명.
리스크: 날짜·KDC·5000건 상한 검증 필요.
제출본 보완: 실제 스키마와 기간·지역·주제 편향을 보고.

원문 p.15 | 신작·추가 활용·전처리

핵심: 신작·이용분석 확장과 서지 전처리 필요성을 제시.
강점: MVP 이후 확장성을 고려.
리스크: 예시 날짜·코드와 크롤링·생성 추천사 리스크.
제출본 보완: MVP 필드를 제한하고 생성 텍스트는 보조필드로 분리.

원문 p.16 | 서지 JSON 예시

핵심: ISBN, 제목, 저자, 소개, 카테고리, 목차, 후기, 표지 등.
강점: 임베딩 입력 후보가 풍부.
리스크: 필드 출처·라이선스·결측률·중복 기준 없음.
제출본 보완: null/duplicate/text length/license 프로파일링 표 추가.

원문 p.17 | 대규모 텍스트 예시

핵심: 목차·출판사 문구가 길고 불규칙할 수 있음을 보여줌.
강점: 전처리 난점을 숨기지 않음.
리스크: 오탈자·불완전 텍스트가 임베딩 노이즈가 됨.
제출본 보완: 정규화·길이제한·문자제거·품질점수·제외규칙 명시.

원문 p.18 | 필드 설명과 페르소나

핵심: 스키마 설명, 결측 보완, 3 persona와 10회 멀티턴 합성.
강점: 합성 데이터 목적과 타깃층이 드러남.
리스크: 자동 추천사·크롤링은 사실성·권리·평가누수 위험.
제출본 보완: 생성 텍스트를 정답 라벨로 사용하지 않고 human gold profile 작성.

원문 p.19 | 문제 해결 방향·기능 1

핵심: 장기 대화, 계층 메모리, 관계 탐색, 정보나루 연계.
강점: 문제에서 방법으로 자연스럽게 넘어감.
리스크: A-MEM 참고가 구현·비교로 내려오지 않음.
제출본 보완: link/update/cluster/retrieval 요소로 분해해 ablation.

원문 p.20 | Session Node 정의

핵심: 세션 스냅샷과 Preference Cluster 두 계층 메모리.
강점: 해석 가능한 메모리 단위.
리스크: LLM 자율 생성만으로 오류 통제가 어려움.
제출본 보완: evidence_span, source_turn, polarity, confidence, expiry, user_editable 추가.

원문 p.21 | Session Node 코드

핵심: intent, context, keywords, tags, description, embedding.
강점: 감정·시간·회피 선호 구조화가 풍부.
리스크: '빠른 수락' 등 암묵 신호는 불확실.
제출본 보완: 명시/추론 선호와 근거 turn을 분리.

원문 p.22 | Preference Cluster 정의

핵심: 복수 세션에서 반복 패턴과 persona를 추상화.
강점: 다층 취향과 상황별 persona를 표현.
리스크: 창발·안정화 조건이 없음.
제출본 보완: purity, stability, merge/split 횟수를 validation에서 평가.

원문 p.23 | Cluster 속성

핵심: 가중치, goal, avoidance, genre affinity, flexibility.
강점: 추천 이유를 설명할 수 있음.
리스크: 0.6/0.7/0.85/1.0 가중치 산식 없음.
제출본 보완: recency·명시성·만족도·재확인 기반 산식과 균등 baseline.

원문 p.24 | 활성화 조건·정체성

핵심: mood, 시간대, trigger, label, description.
강점: 상황 의존 추천의 차별점.
리스크: 감정 추론은 민감정보가 될 수 있음.
제출본 보완: 만료·삭제·수정 정책, label은 보조 신호라는 원칙 추가.

원문 p.25 | Cluster 연결

핵심: 새 세션과 모든 cluster의 유사도 비교.
강점: 구현 가능한 규칙으로 내려옴.
리스크: 선형 비교 비용과 threshold 근거 부족.
제출본 보완: ANN 후보화, validation tune, test 고정.

원문 p.26 | 0.75/0.5 로직

핵심: 강연결·약연결·신규 cluster와 초기 confidence.
강점: 시각적 데모에 적합.
리스크: 모든 수치가 설정값이지 검증 결과가 아님.
제출본 보완: threshold sweep, purity, false merge/split, latency 평가.

원문 p.27 | Retrieval-Reranking

핵심: Bi-Encoder cosine 후보 검색, Cross-Encoder 재순위, 설명 생성.
강점: 2단계 검색 구조가 명확.
리스크: 입력 경계·leakage·후보 K/n이 없음.
제출본 보완: BM25+dense baseline, K/n, 시간·비용, 근거 필드 고정.

원문 p.28 | API 도구·코드베이스

핵심: 대출 상태·운영정보 tool 연결과 A-MEM/CSI 참고.
강점: 추천의 실행 가능성 확보.
리스크: API 실패·stale response·라이선스가 빠짐.
제출본 보완: tool schema, retry/timeout, fallback, provenance, license 문서화.

원문 p.29 | 평가 데이터셋

핵심: 3 persona, 각 10회 멀티턴, 회차별 프로필 기록.
강점: 평가를 실행 단계로 옮김.
리스크: 3 x 10은 변동성 추정에 부족.
제출본 보완: persona는 시연용, 평가 seed와 human audit 확대.

원문 p.30 | Persona A

핵심: 32세 직장인, 이직·경제·철학·심리, 5회 이내 수렴.
강점: 현실적 pain point와 검증 포인트가 맞음.
리스크: 수렴 정답과 Judge 신뢰도 없음.
제출본 보완: gold profile, turn label, paired ranking, human agreement.

원문 p.31 | 실질 내용 없음

핵심: 페이지 번호 외 평가 내용 없음.
강점: 없음.
리스크: 페이지 낭비와 완성도 저하.
제출본 보완: 재구성본에서 삭제 또는 부록 표지로 전환.

원문 p.32 | Persona B

핵심: 43세 학부모, 두 자녀 수준·관심·대출 가능성을 다룸.
강점: 다중 프로필 분리 스트레스 테스트.
리스크: 연령 적합도 라벨과 보호자 권한 없음.
제출본 보완: profile routing, age rubric, 보호자 확인 절차.

원문 p.33 | B 검증 포인트

핵심: AI/로봇과 역사/과학 독립 노드 연결.
강점: KDC로 혼선을 구체화.
리스크: KDC 연결만으로 의미 이해를 대변하지 못함.
제출본 보완: routing F1과 recommendation contamination rate 추가.

원문 p.34 | Persona C

핵심: 17세 학생의 관심사 전환과 단계적 추천.
강점: interest drift를 명시적으로 시험.
리스크: 구형 책 관찰은 데이터 시점 의존.
제출본 보완: time split과 new-topic switch를 만들고 최신성과 적응을 분리.

원문 p.35 | C 검증·AlpsBench

핵심: 1-3회 기존 관심, 4-7회 새 관심과 Extraction/Update/Retrieval.
강점: 메모리 생명주기를 단계로 분리.
리스크: 80% 수렴의 분모·정답 없음.
제출본 보완: switch curve, update macro-F1, memory Recall@5, unseen-topic NDCG.

원문 p.36 | Retrieval/RAG 지표

핵심: Recall@K, NDCG@K, Judge 기반 응답 평가.
강점: 검색·생성 목적을 분리.
리스크: Judge 단독과 relevance label 부족.
제출본 보완: graded labels, API truth set, human audit, judge agreement.

원문 p.37 | API 지표

핵심: Tool Call Accuracy, availability@K, API 사실성.
강점: 실행 가능성을 별도 평가.
리스크: 정확도 정의와 stale 처리 없음.
제출본 보완: tool exact match, field exact accuracy, freshness-aware P/R.

원문 p.38 | 6주 실행계획

핵심: MVP, 고도화, 실험, 발표를 6주 배치.
강점: 발표까지의 일정이 있음.
리스크: 데이터 계약·반복실험·QA가 일정에 없음.
제출본 보완: exit criteria와 fallback. Week 4 결과 없으면 평가 우선.

03 / REBUILT RESEARCH DESIGN

문제정의 -> RQ -> 가설 -> 실험 -> 정량평가

이 장은 원문의 아이디어를 심사위원이 검증할 수 있는 연구 설계로 바꾼다. 목표치는 개선 제안이며 아직 관측된 성과가 아니다.

3.1 문제정의

공공도서관의 발견형 탐색에서 사용자는 주제·상황·독서 목적을 자연어로 표현하지만, 현재 시스템은 이 맥락을 세션 밖으로 보존하지 못한다. 그 결과 사용자는 재설명해야 하고, 시스템은 같은 사람의 관심사 전환·상황별 취향·다중 프로필을 구분하지 못한다. 이 프로젝트는 장기 메모리가 후보 검색과 재순위뿐 아니라 도서관의 실제 이용 가능성까지 개선하는지 검증한다.

3.2 연구질문

RQ	질문	측정 대상
RQ1	장기 대화 메모리가 현재 세션만 사용하는 모델보다 개인화 추천을 개선하는가?	NDCG@10, Recall@20, preference alignment
RQ2	Session Node + Preference Cluster가 단일 요약 또는 전체 대화 concat보다 관심사 전환·상황 의존 추천에 강한가?	switch adaptation, stale memory, routing
RQ3	Bi-Encoder retrieval 뒤 Cross-Encoder reranking이 retrieval-only보다 상위 추천 품질을 높이는가?	Recall@20, NDCG@10, MRR, latency
RQ4	정보나루 tool grounding이 추천을 실제 대출 가능한 행동으로 전환하는가?	tool exact match, availability P/R, freshness
RQ5	근거 기반 설명이 추천의 사실성·납득도·선택 비용을 개선하는가?	faithfulness, human acceptability

3.3 가설과 실험 대응

가설	독립변수	종속변수	예상 방향	검증
H1	메모리 on/off	NDCG@10, Recall@20	on > off	paired bootstrap CI
H2	concat / summary / cluster	switch adaptation, stale rate	cluster가 drift에 강함	condition x turn
H3	retrieval-only / rerank	NDCG@10, MRR	rerank가 상위 품질 향상	paired permutation
H4	tool grounding on/off	availability P, field accuracy	grounding이 향상	exact-match + audit
H5	evidence on/off	faithfulness, acceptability	근거 연결이 향상	blind human rating

인과 연결 문장

Holding the book corpus, encoder, prompt, candidate size, and API snapshot constant, adding memory should improve profile-aligned ranking and reduce stale-memory errors. The improvement should survive paired tests across personas and seeds.

3.4 시스템 설계안

대화 입력	프로필 추출	메모리 갱신	후보 검색	재순위	API 검증	근거 응답
현재 세션 + 사용자 선택	intent / topic / level / mood	Keep / Add / Revise / Suppress	BM25 + dense top-K	profile-book cross score	소장·대출·운영 정보	book fields + checked_at

3.5 Baseline 구성

ID	구성	왜 필요한가
B0	Lexical BM25 / title-category filter, no memory	도서관 검색에 가까운 최소 기준
B1	Dense retrieval, current session only	임베딩 검색의 순수 효과
B2	Dense retrieval + all-history concatenation	장기 맥락을 구조화하지 않은 기준
B3	Structured Session memory, no cluster	세션 메모리 효과
B4	Session + Cluster, retrieval only	계층 메모리 효과
B5	Full: Session + Cluster + rerank + API grounding	제안 시스템
Oracle	gold profile / gold relevant set	모델 상한과 라벨 품질 확인

04 / DATA AND EVALUATION

실행 가능한 평가 체계

평가는 한 점수로 끝내지 않는다. 메모리의 생명주기, 검색의 순위, 도서관 데이터의 사실성, 응답의 근거성을 분리해 병목을 찾는다.

4.1 데이터 설계

층	입력	정답/검수	분할 원칙
도서	10만 건 서지, ISBN, 제목, 저자, 소개, KDC, 목차	중복·결측·품질 리포트	ISBN dedup; temporal holdout
도서관	libCode, 소장, 대출 상태, 운영 정보	원 API 응답 + checked_at	API snapshot별 평가; stale 별도
대화	3 persona x 10회 이상, seed 변형	gold profile, intent, update action	persona/seed/session split
추천	query + memory + candidate set	graded relevance 0-3, availability	평가 시점 정답 고정
설명	추천 이유와 근거 필드	field-level faithfulness, human acceptability	judge calibration + audit

4.2 메모리 스키마 보강

원문의 Session Node와 Preference Cluster를 유지하되, 추천에 사용되는 모든 기억이 어디서 왔는지 추적 가능하도록 한다.

필드	역할	실패 방지
evidence_span / source_turn	기억을 뒷받침하는 원문 구간	추론을 사용자 발화와 혼동하지 않음
polarity / strength	선호·비선호·중립, 강도	좋다와 싫지는 않다를 구분
status	active / tentative / stale / suppressed	관심사 전환 때 과거 취향 재사용 방지
last_confirmed / expires_at	최근 확인·상황성 만료	감정·시간대 취향의 과잉 영속화 방지
confidence / user_editable	추출 확신도와 수정권	사용자 통제와 오류 회복
cluster_id / assignment_score	세션-클러스터 연결	threshold 결정과 오류 분석

4.3 지표 정의

영역	지표	정의/주의
Extraction	micro/macro F1, span F1	장르·주제·목적·수준; 명시/암묵 분리
Update	action accuracy, macro-F1	Keep/Add/Revise/Suppress/Ask 오분류
Memory retrieval	Recall@5, MRR	distractor 규모별 평가
Candidate retrieval	Recall@20	reranker와 분리
Ranking	NDCG@10, MRR	graded relevance와 상위 순위
Coverage	catalog coverage, novelty	인기 편향과 롱테일을 별도
API	tool exact match, field exact accuracy	expected tool/argument 및 반환 필드
Availability	precision@K, recall@K	API snapshot 기준 소장·대출 가능성
Explanation	faithfulness, completeness, acceptability	LLM Judge 단독 금지
Ops	p50/p95 latency, error rate, cost	API 포함/제외를 나눔

4.4 합성 페르소나 평가의 안전장치

- 3개 persona는 시연용으로 유지하되 각 persona에 4-6개 seed를 만들고 발화 순서·표현·관심사 강도를 변형한다.

- 각 session에는 gold profile과 expected update action을 사람이 먼저 작성하고, 생성 모델은 그 범위 안에서 표현만 변형한다.

- 자동평가 외에 최소 100개 응답을 무작위 추출해 2인 human audit을 실시하고 합의율 또는 Cohen kappa를 보고한다.

- LLM Judge는 rubric, pairwise blind comparison, position randomization, calibration examples를 공개한다.

- 평균뿐 아니라 persona·seed·turn별 분포, 95% bootstrap CI, 실패 예시를 함께 제시한다.

05 / SLIDE-BY-SLIDE UPGRADE

발표 슬라이드별 논리·기술 보완점

원문 38쪽은 세부 설계가 풍부하지만 발표 흐름으로는 정보가 분산된다. 아래 12장 구조로 재배열하면 심사위원이 문제와 검증을 한 번에 따라온다.

장	슬라이드	핵심 구성	목적
1	한 문장 문제	'도서관 검색은 질의는 기억하지만 독서 맥락은 기억하지 않는다.' 사용자 여정 + 단절 예시.	대상과 문제를 20초 안에 고정
2	왜 지금인가	선택 부담과 발견 실패를 원문 통계·관찰로 구분.	사회적 가치와 근거 수준 제시
3	연구 질문	'메모리가 추천 성능을 얼마나 개선하는가?'와 RQ1-RQ4.	기능 발표를 연구 발표로 전환
4	데이터 자산	10만 도서 DB, 정보나루 API, 합성 대화, human audit.	데이터 확보·평가 가능성 해소
5	핵심 아이디어	Session Node -> Preference Cluster -> active profile.	차별화 전달
6	메모리 업데이트	evidence_span, status, confidence, Keep/Add/Revise/Suppress.	자율성 위험을 통제
7	검색과 재순위	BM25+dense top-K -> Cross-Encoder -> top-N.	기술 선택과 측정 연결
8	도서관 실행성	libCode/isbn13 -> 소장·대출·운영 정보 -> checked_at.	API 신뢰도 관리
9	실험 매트릭스	B0-B5 baseline과 H1-H5 화살표.	개선의 원인 분해
10	평가지표	Memory / Retrieval / Ranking / API / Explanation / Ops scoreboard.	단일 Judge 점수 방지
11	페르소나 시연	A 누적 정교화, B 분리, C 전환; baseline side-by-side.	기능을 성능 차이로 보여줌
12	효과와 다음 단계	검색→대출 전환, 재방문, 롱테일 노출, 실패율, 6주 exit criteria.	기업 KPI에 답

시각 설계 규칙

- 한 슬라이드 한 주장. JSON과 전체 API 코드는 부록으로 이동한다.
- 모든 수치에 관측값 / 원문 계획 / 외부 검증 / 제안 목표 태그를 붙인다.
- 결과 scoreboard는 빈 상태로 먼저 설계하고, 실험 후 수치만 채운다.
- 아키텍처 그림은 메모리 -> 검색 -> API -> 근거의 순서로 흐르게 한다.

06 / 10-15 MINUTE SCRIPT

12분 30초 발표 대본

아래 대본은 12장의 재구성 슬라이드를 기준으로 한다. 실제 결과가 아직 없으므로 결과를 암시하는 표현 대신 검증 계획과 성공 기준으로 말한다.

0:00-0:45 | 1장

안녕하세요. 저희가 해결하려는 문제는 도서관 검색이 책을 못 찾는다는 문제가 아닙니다. 사용자가 어떤 상황에서 어떤 책을 찾는지, 그리고 지난 대화에서 무엇을 원했는지를 기억하지 못한다는 문제입니다. 오늘 조선 역사 만화를 찾은 사용자가 다음 주 임진왜란 외교 정책을 물어도, 시스템이 두 질문을 같은 탐색으로 연결하지 못한다면 사용자는 매번 처음부터 설명해야 합니다.

0:45-1:35 | 2장

책 선택은 영상이나 음악보다 실패 비용이 큽니다. 읽는 데 시간과 집중이 필요하기 때문입니다. 원문은 직접 살펴보고 판단한다는 독서 선택 행동을 문제의 근거로 제시합니다. 이 수치는 제출 전 공식 원문으로 재검증하되, 저희의 핵심 주장은 숫자 하나가 아니라 발견 과정에서 납득 가능한 개인화가 필요하다는 것입니다.

1:35-2:20 | 3장

그래서 연구질문은 단순합니다. 장기 대화 메모리가 없는 추천보다 있는 추천이 실제로 더 좋은가? 이를 프로필 추출, 메모리 갱신, 메모리 검색, 추천 활용의 네 단계로 나눕니다.

2:20-3:10 | 4장

데이터는 네 층입니다. 10만 건 규모 서지 데이터, ISBN과 libCode로 연결되는 정보나루 데이터, 장기 대화를 모사한 persona 데이터, 사람이 확인한 정답 프로필과 관련성입니다. 합성 대화는 실제 사용자 로그를 대체하는 진실이 아니라 재현 가능한 통제 실험을 위한 데이터입니다.

3:10-4:15 | 5장

핵심 차별점은 두 계층 메모리입니다. Session Node는 한 번의 대화에서 사용자가 원한 목적과 상황을 담고, Preference Cluster는 여러 세션에서 반복된 패턴을 상위 취향으로 묶습니다. 평일 저녁에는 위로가 필요한 사람도, 주말에는 도전적인 책을 원하는 사람일 수 있습니다.

4:15-5:10 | 6장

메모리는 자율적으로 지어내는 요약이 아니라 근거가 추적되는 상태로 관리합니다. 모든 선호에는 source turn과 evidence span을 저장하고 Keep, Add, Revise, Suppress 같은 갱신 행동을 기록합니다. 관심사가 바뀌면 과거 정보를 삭제하는 대신 stale 상태로 낮춥니다.

5:10-6:05 | 7장

먼저 lexical과 dense retrieval을 결합해 후보를 넓게 찾고, Cross-Encoder가 상위 순위를 다시 정합니다. 이렇게 후보를 놓치지 않는 Recall과 상위 결과의 정밀도를 분리해 개선합니다. 추천 이유는 실제 도서 필드에 연결합니다.

6:05-6:55 | 8장

도서관에서 중요한 차이는 지금 이용할 수 있느냐입니다. ISBN으로 후보를 찾고 주변 도서관의 소장과 대출 상태를 조회합니다. 다만 실시간이라고 과장하지 않겠습니다. 조회 시각과 갱신 기준을 함께 노출합니다.

6:55-8:00 | 9장

메모리의 효과를 증명하기 위해 여섯 비교군을 둡니다. 검색어 기준선, 현재 세션 dense, 전체 대화 concat, 세션 메모리, 세션과 클러스터, 최종 시스템입니다. 같은 조건에서 메모리 구조와 reranker의 기여를 분해합니다.

8:00-9:10 | 10장

평가는 프로필, 메모리, 검색, 추천 순위, API 사실성, 설명 충실성, 운영성으로 나눕니다. 대출 가능하다고 말했지만 실제로 대출 중인 책을 추천했다면, 언어가 자연스러워도 실패입니다.

9:10-10:30 | 11장

직장인은 대화 누적 정교화를, 학부모는 두 자녀 프로필 분리를, 학생은 관심사 전환 적응을 시험합니다. 같은 시나리오를 memory off와 on으로 나란히 보여주겠습니다.

10:30-12:00 | 12장

저희가 약속드리는 것은 아직 얻지 않은 성과를 미리 말하는 것이 아닙니다. 메모리 on이 NDCG를 얼마나 개선하는지, 전환에 얼마나 빨리 적응하는지, API 사실성이 어느 수준인지 사전에 정의하고 결과를 공개하는 것입니다. 도서관에는 검색어를 몰라도 시작할 수 있는 발견 경험을, 이용자에게는 매번 처음부터 설명하지 않아도 되는 연속성을 제공하겠습니다. 감사합니다.

07 / JUDGE READINESS

기업 심사위원 예상 질문 20개와 모범답변

현재 사실·검증 예정·범위를 분리해서 답하도록 작성했다.

1. 기존 도서 추천과 무엇이 다른가?

차별점은 추천 목록 자체가 아니라 세션 간 메모리의 증분 효과를 검증한다는 데 있습니다. 현재 세션, 전체 대화 concat, Session+Cluster를 같은 데이터와 모델로 비교해 장기 기억의 기여를 분리하겠습니다.

2. Session과 Cluster가 꼭 필요한가?

필요하다고 가정하지 않습니다. RQ2와 ablation의 대상입니다. 상황 의존 추천과 관심사 전환에서 유리한지 purity, stale rate, NDCG로 판단합니다.

3. LLM이 잘 요약해서 좋아진 것 아닌가?

B2 전체 대화 concat과 B3 구조화 Session을 비교합니다. 모델, 프롬프트, 후보 수를 고정하고 메모리 구조만 바꾸며 update action과 evidence span도 평가합니다.

4. 3개 persona는 너무 적지 않은가?

맞습니다. 원문의 3개는 시연용으로 유지하되 평가에서는 여러 seed와 표현 변형을 추가합니다. 평균뿐 아니라 seed별 분포와 human audit를 공개합니다.

5. 합성 사용자는 실제 사용자와 다른데?

합성 데이터는 실제성의 증명이 아니라 통제 가능한 회귀 테스트입니다. gold profile을 사람이 작성하고, 자동평가 샘플을 사람이 검수하며, 실제 사용자 평가는 후속 pilot으로 분리합니다.

6. LLM Judge를 믿을 수 있는가?

단독 정답으로 쓰지 않습니다. API는 exact match, 검색은 graded label, 설명은 human audit와 judge agreement를 함께 봅니다.

7. 정보나루 데이터가 실시간인가?

원문 표현을 그대로 과장하지 않겠습니다. 조회 시각과 갱신 기준을 노출하는 freshness-aware 설계로 정정하고 오래된 상태는 최종 확인을 권합니다.

8. API가 실패하면?

추천과 재고 확인을 분리합니다. timeout이면 서지 기반 추천을 제공하되 대출 가능 배지는 표시하지 않습니다. 실패율과 fallback 비율을 기록합니다.

9. 개인정보와 감정 정보는?

최소수집, 사용자 수정·삭제, 민감 상태 만료, 원문 대화와 메모리 분리를 기본으로 둡니다. 감정은 고정 정체성이 아닌 상황 신호입니다.

10. 아동 프로필을 다뤄도 되는가?

학부모 시나리오는 설계 검증용입니다. 실제 서비스에서는 미성년자 데이터 정책과 보호자 확인 전까지 데모 범위로 제한합니다.

11. 0.75와 0.5 임계값의 근거는?

원문 초기 설정값일 뿐 검증된 상수가 아닙니다. validation에서 sweep하고 test에는 고정하며 false merge/split, NDCG, latency를 함께 봅니다.

12. 80% 수렴은 무엇을 뜻하는가?

현재 정의로는 불충분합니다. 전환 후 새 주제 관련 추천 비율과 old-topic contamination을 분리 정의하고, 80%는 사전등록 목표치로만 사용합니다.

13. 인기대출이 인기 편향을 키우지 않는가?

그렇습니다. cold-start 후보 생성 baseline으로 제한하고 catalog coverage와 novelty를 함께 보고합니다.

14. 설명이 환각이면?

설명 입력을 제목·저자·소개·KDC·API 필드로 제한하고 각 주장에 source field를 붙입니다. 근거 없는 문장은 감점합니다.

15. 왜 Bi-Encoder와 Cross-Encoder를 둘 다 쓰는가?

Bi-Encoder는 10만 건에서 빠르게 후보를 만들고 Cross-Encoder는 작은 후보에서 정밀하게 봅니다. Recall과 NDCG를 분리해 병목을 확인할 수 있습니다.

16. 기업 KPI는?

추천 후 상세 확인, 대출 가능 결과 비율, 재방문 시 재설명 감소, 실패 응답률, 롱테일 노출을 제안합니다. 실제 대출 전환과 만족도는 pilot으로 검증합니다.

17. 6주에 가능한가?

전체 비전을 한 번에 제품화하지 않습니다. 1-2주 baseline·최소 메모리, 3-4주 API·reranker, 5주 고정 실험, 6주 발표입니다. 결과가 없으면 기능보다 평가를 우선합니다.

18. 가장 큰 실패 가능성은?

잘못된 선호가 오래 유지되는 것입니다. stale/suppressed, 사용자 수정, 전환 시나리오와 contamination metric을 설계에 포함했습니다.

19. 외부 논문을 그대로 가져온 것 아닌가?

RecLLM은 CRS·합성 대화, A-MEM은 동적 연결, Agent4DL은 도서관 시뮬레이션, AlpsBench는 메모리 생명주기의 참고입니다. 한국어 도서관 도메인과 정보나루 실행성은 우리 검증 대상입니다.

20. 결과가 안 좋으면?

메모리가 도움이 되는 조건과 해가 되는 조건을 분리하고 실패한 cluster assignment와 API freshness 사례를 공개합니다. 재현 가능한 실패 분석도 결과입니다.

08 / EXECUTION

6주 실행계획과 제출용 제안서 구조

기능 완료가 아니라 검증 가능한 산출물 중심으로 바꾼다.

주차	목표	산출물	통과 기준
1	데이터·기준선	서지 정제 리포트, API adapter 초안, B0/B1	100개 샘플 스키마 테스트, baseline 로그
2	최소 메모리	Session Node, extraction/update 라벨, B2/B3	evidence span과 update action 출력
3	Cluster·전환	Preference Cluster, stale/suppress, persona seeds	purity와 switch 회귀 테스트
4	Retrieval·API	hybrid retrieval, reranker, tool grounding	API snapshot field exact test
5	고정 실험	B0-B5, ablation, human audit	seed·prompt·snapshot freeze, CI와 실패 사례
6	발표·문서화	12장 deck, demo, 최종 PDF	결과-주장 일치, 출처·한계 확인

제출용 제안서 권장 목차

순서	장	핵심 질문
1	Executive summary	무엇이 문제이고 무엇을 검증하며 왜 도서관에 중요한가?
2	User problem and value	세션 단절이 어떤 사용자 비용과 장서 비용을 만드는가?
3	RQ and hypotheses	메모리·검색·API·설명의 효과를 어떻게 분리하는가?
4	Data and governance	어떤 데이터와 권한·품질기준을 쓰는가?
5	System architecture	프로필, 메모리, retrieval, reranking, tool이 어떻게 연결되는가?
6	Memory design	Session/Cluster가 언제 생기고 갱신·억제되는가?
7	Evaluation protocol	baseline, 라벨, 지표, 표본, 통계를 사전 고정했는가?
8	Personas and demo	A/B/C가 어떤 실패 모드를 검증하는가?
9	Impact and limits	도서관 KPI와 한계를 어떻게 연결하는가?
10	Milestones and fallback	6주 안에 무엇을 완성하고 무엇을 포기하는가?

최종 제출 체크리스트

- 외부 수치·경쟁사 기능·논문 상태에 출처와 확인일이 붙어 있는가.
- 원문 계획과 실제 결과가 문장 수준에서 구분되는가.
- B0-B5가 같은 corpus, snapshot, candidate size, prompt에서 비교되는가.
- threshold, seed, persona, API snapshot, judge rubric이 고정·기록되는가.
- 대출 가능 여부에 조회 시각과 freshness가 표시되는가.
- LLM Judge에 human audit과 exact-match 지표가 함께 있는가.
- 관심사 전환·자녀 분리·오래된 기억 억제 실패가 데모에 포함되는가.
- 결과가 음수여도 해석 가능한 실패 분석 구조가 있는가.

09 / SOURCES

근거·외부 검증·범위 주의사항

외부 자료는 원문에 없는 사실을 보충하기 위해 사용했다. 원문 주장과 외부 확인 사실을 섞지 않도록 참고문헌을 분리한다.

A. 원문 근거

- [S1] 사용자 제공 PDF, '책책책을 읽읍시다 - AI 도서 큐레이션 프로젝트 제안서', 38쪽 전체. 본문 표기는 원문 p.1-38.

B. 외부 검증 자료

ID	자료	사용 범위
E1	도서관 정보나루 Open API 활용방법, https://www.data4library.kr/apiUtilization (확인일 2026-09-15)	API 기능·인증키·응답 형식·소장/대출 조회의 공식 안내. freshness는 별도 확인.
E2	Friedman et al., RecLLM, arXiv:2305.07961, https://arxiv.org/abs/2305.07961	CRS, 자연어 프로필, 합성 사용자 시뮬레이션의 원 논문 선례.
E3	Xu et al., A-MEM, arXiv:2502.12110, https://arxiv.org/abs/2502.12110	동적 링크·메모리 진화·구조화 note의 설계 영감.
E4	Zerhoudi & Granitzer, Agent4DL, arXiv:2602.22529, https://arxiv.org/abs/2602.22529	도서관 사용자 검색행동 시뮬레이터의 방법론적 참고.
E5	Xiao et al., AlpsBench, arXiv:2603.26680, https://arxiv.org/abs/2603.26680	Extraction, Update, Retrieval, Utilization의 메모리 생명주기 평가 틀.

C. 검증 필요 목록

- 원문 p.2의 2025 국민독서실태조사 수치(성인 29.3%, 학생 41.6%)와 조사 문항·표본.
- 원문 p.8-10의 CSUSER/CSI 서지정보, 출판 상태와 재현 가능 코드.
- 원문 p.10의 클라비 제공 10만 건 서지 데이터 확보 여부, 사용 권한, 필드 품질.
- 정보나루 API의 현재 파라미터·응답 필드·호출한도·갱신 주기와 예시 코드의 일치 여부.
- 경쟁 서비스 기능·한계가 조사일 현재에도 유효한지.
- 도서 소개·추천사·표지 URL을 임베딩·생성·저장할 때의 이용권한과 표시정책.

제출 전 마지막 원칙

원문에 결과가 없으면 결과처럼 쓰지 않는다. 외부 자료가 최신이어도 우리 도메인 성능을 대신 증명하지 않는다. 대신 무엇을 언제 어떤 정답과 비교해 검증할지 명확하게 쓴다.

문서 끝