



Stephanie Arnett/MIT Technology Review | Adobe Stock

인공지능

A startup claims it broke through a bottleneck that's holding back LLMs

“트랜스포머 시대 끝낼 것”...LLM 병목 문제 해결했다는 스타트업 등장

미국 AI 스타트업 서브쿼드래틱이 AI가 방대한 문서를 처리할 때 발생하는 계산량 폭증 문제를 해결했다고 주장하며 새로운 AI 모델 '서브큐(SubQ)'를 공개했다. 독립 평가 결과도 긍정적으로 나오면서 AI 업계의 주목을 받고 있다.

Will Douglas Heaven

2026년 6월 24일

 한눈에 보는 AI 요약 AI 자동 요약 펼쳐보기

미국 마이애미에 기반을 둔 AI 스타트업 서브쿼드래틱(Subquadratic)은 지난 5월 비공개 개발을 마치고 모습을 드러내며 대담한 주장을 펼쳤다. 10년 가까이 대형언어모델(LLM)의 발전을 가로막아온 수학적 병목 문제를 해결했다는 것이다.

처음에는 많은 정보를 공개하지 않았기 때문에 업계의 반응은 냉담했다. 그러나 서브쿼드래틱은 새 기술에 대한 독립 평가 결과를 공개하며 근거를 제시하기 시작했다. 평가 결과를 보면 이들의 주장을 그냥 흘려듣기가 어려울 수도 있다.

서브쿼드래틱은 '서브큐(SubQ)'라는 새로운 종류의 LLM을 개발했다고 밝혔다. 그러면서 서브큐가 현재 시장에 나온 다른 어떤 모델보다 빠르고 비용과 에너지 소비가 적으며, 한번에 최대 12배 많은 텍스트를 처리할 수 있다고도 주장했다. 수백 건의 문서를 분석하거나 대규모 코드베이스를 검토하는 작업에 특히 강점을 가졌다는 설명이다.

서브쿼드래틱은 또한 서브큐가 대규모 텍스트를 처리하면서도 코딩 같은 핵심 작업에서는 구글 딥마인드와 오픈AI, 앤트로픽이 내놓은 최고 수준 모델과 비견할 만한 성능을 보인다고 주장했다.

문제는 서브쿼드래틱이 처음에는 이런 주장을 뒷받침할 만한 근거를 거의 내놓지 않았다는 점이다. 자체적으로 공개한 몇 가지 테스트 점수가 전부였다. 서브큐 또한 아직 사람들이 직접 사용해볼 수 있을 만큼 널리 공개되지 않았다.

따라서 서브쿼드래틱의 주장에 회의적인 반응이 나온 것은 당연한 일이었다. 댄 매커티어(Dan McAteer) AI 엔지니어는 X에 올린 글을 통해 서브큐에 대한 전반적인 반응을 다음과 같이

요약했다. “서브큐는 트랜스포머 이후 최대 돌파구이거나 AI판 테라노스(Theranos, 실리콘밸리 최대 사기극을 벌이고 허위 기술 논란으로 몰락한 스타트업)이다.”

그로부터 한 달이 지나 서브쿼드래틱은 자사 모델에 관한 정보를 더 공개했다. 공개한 정보에는 제3자 평가 기업 에펜(Appen)이 추가로 진행한 독립 테스트 결과도 포함됐다.

서브쿼드래틱의 알렉스 휘던(Alex Whedon) 공동창업자 겸 CTO는 “회의론이 나올 것으로 예상했다”고 말했다. 그는 “돌이켜보면 처음 발표할 때 제3자 벤치마크 결과를 함께 공개했다면 회의론의 상당 부분을 미리 줄일 수 있었을 것”이라면서 “따라서 앞으로 내놓는 결과는 공개 전에 충분히 검증되도록 시간을 들이고 있다”고 덧붙였다.

서브쿼드래틱은 다른 기업의 모델을 평가하는 에펜에 서브큐에 대한 테스트를 의뢰했다. 테스트 결과는 서브쿼드래틱의 주장 상당 부분을 뒷받침하는 것으로 보인다. 에펜의 생성형 AI 연구 담당 지닌 시나난싱(Jeanine Sinanan-Singh) 이사는 “테스트 결과가 정말 흥미로웠다”며 “서브쿼드래틱의 모델 구조가 실제로 작동할 수 있다는 근거가 됐기 때문”이라고 말했다.

시나난싱 이사는 이어 “LLM이 속도와 효율성 면에서 한계를 안고 있는 만큼 서브큐가 이를 개선할 가능성에 주목했다”고 말했다. 다만 “성능 개선 폭이 클수록 회사의 자체 발표만으로는 신뢰를 얻기 어렵다”며 제3자 검증의 필요성을 강조했다.

서브큐가 기존 최상위 모델을 전면적으로 대체하지는 않을 것이다. 그러나 특정 작업에서는 기존 모델보다 훨씬 낮은 비용으로 처리 속도를 크게 높일 수 있을지도 모른다. 서브쿼드래틱은 “장기적으로는 이번 돌파구가 LLM을 구축하는 방식 자체를 바꿀 수 있다”고 주장했다.

서브쿼드래틱의 저스틴 데인절(Justin Dangel) 공동창립자 겸 CEO는 “우리는 효율성의 새 시대를 여는 출발점이 되기를 바란다”며 “몇 년 뒤에는 아무도 트랜스포머를 기반으로 모델을 만들지 않을 것”이라고 말했다.

트랜스포머 한계 넘었나...서브큐 둘러싼 기대와 회의론

서브쿼드래틱의 주장이 중요한 이유를 이해하려면 대부분의 LLM이 어떻게 작동하는지 살펴볼 필요가 있다. LLM 내부의 핵심 메커니즘은 트랜스포머(transformer)라는 신경망 구조다. 트랜스포머는 밀집 어텐션(dense attention)이라고 불리는 과정을 수행하는데, 밀집 어텐션은 텍스트 안의 각 요소가 다른 모든 요소와 어떤 관계를 갖는지 촘촘히 계산하는 방식이다. 오늘날 LLM은 보통 여러 개의 트랜스포머를 이어 붙인 구조를 사용한다. LLM 시대의 토대가 된 2017년 구글 연구진의 논문 제목도 '어텐션만 있으면 된다(Attention Is All You Need)'였다.

밀집 어텐션은 다음과 같이 작동한다. 트랜스포머가 텍스트 덩어리를 처리할 때 먼저 각 단어를 숫자로 바꾼다. (여기서 단어 전체 또는 단어의 일부를 토큰(token)이라고 한다.) 그런 다음 전체 텍스트의 의미를 파악하기 위해 각 숫자를 같은 텍스트 안의 다른 모든 숫자와 비교하듯 곱한다. 예를 들어 1만 단어 길이의 텍스트를 처리하려면 거의 5천만 번에 가까운 개별 곱셈이 필요하다. 이것이 계산량이 막대해지는 이유이자 LLM이 전력을 많이 사용하는 것으로 악명 높아진 주된 이유다.

데인절 CEO는 "만약 《위대한 개츠비》를 요약한다고 하면 첫 단어와 마지막 단어의 관계까지 계산해야 하며 그 밖의 가능한 모든 단어 조합도 살펴봐야 한다"고 말했다.

따라서 텍스트가 길어질수록 계산량은 폭발적으로 늘어난다. 숫자가 하나 추가될 때마다 그 숫자를 앞서 나온 다른 모든 숫자와 곱해야 하기 때문이다. 단어 수가 두 배가 되면 계산량은 대략 네 배가 된다. 이렇게 입력 길이가 늘어날수록 계산량이 제곱에 가깝게 증가하는 현상을 이차적 증가(quadratic expansion)라고 한다.

그림으로 생각해볼 수도 있다. 원을 하나 그리고 가장자리에 점을 여러 개 찍어보자. 각 점은 토큰 하나를 뜻한다. 그런 다음 두 토큰을 곱하는 과정을 나타내기 위해 점과 점 사이에 선을 그어보자. 점이 5개인 원에는 선이 10개 생긴다. 점을 10개로 늘리면 선은 45개가 되고 20개로 늘리면 190개가 된다. 이런 식으로 선의 개수는 빠르게 늘어난다.

‘밀집 어텐션’ 대신 ‘희소 어텐션’...계산량·비용 대폭 절감

서브쿼드래틱의 해법은 트랜스포머의 핵심 연산인 밀집 어텐션 대신 희소 어텐션(sparse attention)을 사용하는 것이다. 희소 어텐션은 필요한 계산량을 크게 줄인다. 각 토큰에 배정된 숫자를 다른 모든 숫자와 곱하지 않고 곱셈에 사용할 숫자 일부만 선택하는 방식이기 때문이다. 희소 어텐션은 텍스트 안에서 단어와 단어 사이의 모든 관계가 다 중요한 것은 아니라는 생각을 기반으로 한다.

휘던 CTO는 “희소 어텐션은 단어들의 모든 관계가 중요한 것은 아니라는 생각을 바탕으로 한다”고 말했다. 그는 “당연히 실제로도 그렇지 않다”면서 “책을 읽을 때 첫 번째 단어와 두 번째 단어, 첫 번째 단어와 세 번째 단어를 일일이 비교하며 읽지는 않는다. 그건 말이 안 된다”고 강조했다.

접근법 자체는 단순하다. 희소 어텐션을 서브쿼드래틱이 처음 시도한 것도 아니다. 과거 오픈AI에서 일했던 윌 디퓨(Will Depue) 독립 AI 연구자는 “희소 어텐션과 관련해서는 생각할 수 있는 거의 모든 방법이 이미 시도됐다”며 “불가능한 일은 아니지만 오랫동안 깨기 어려운 장벽으로 여겨져온 문제를 푸는 것만큼이나 어려운 일”이라고 말했다.

지금까지는 어떤 숫자를 곱하고 어떤 숫자를 무시할지 선택하는 기존 희소 어텐션 기법들이 밀집 어텐션만큼 문서의 의미를 잘 파악하는 메커니즘을 만들어내지 못했다.

서브쿼드래틱은 마침내 이 문제를 해결했다고 주장하면서, 서브큐를 주류 밀집 어텐션 모델과 성능 면에서 경쟁할 수 있는 첫 희소 어텐션 LLM으로 내세우고 있다.

휘던 CTO는 “과거에는 대부분의 메커니즘이 첫 번째 단어를 항상 다섯 번째 단어와 비교하는 식의 고정된 패턴을 사용했다”며 “이는 상당히 제한적이지만 언어는 그보다 훨씬 정교하다”고 설명했다. 그는 “우리가 개발한 메커니즘을 특별하게 만드는 요소 중 하나는 어떤 관계가 중요한지를 동적으로 선택한다는 점”이라고 강조했다.

서브쿼드래틱은 서브큐가 어떤 단어에 집중할지를 정확히 어떤 방식으로 선택하는지 밝히지 않고 있다. 다만 선택은 모델이 텍스트를 처리하는 순간마다 계산되며 주어진 텍스트마다 달라진다. 휘던 CTO는 “그 부분이 일종의 핵심 비법”이라고 말했다.

벤치마크 통과에도 실사용 검증은 아직 과제

결과적으로 특정 작업에서는 서브큐가 대부분의 다른 모델보다 더 낮은 비용으로 더 빠르게 작동할 수 있을지도 모른다. 에펜은 몇 가지 표준 테스트로 서브큐를 평가했다. 먼저 순수 속도 테스트를 진행했다. 이 테스트는 모델이 실제 작업을 얼마나 잘 수행하는지 평가하기보다 이론적으로 얼마나 빠르게 작동할 수 있는지를 측정하는 기준선에 가깝다. 이 테스트에서 서브큐는 기존 희소 어텐션 기법인 플래시어텐션(FlashAttention)을 사용하는 모델보다 56배 빨랐다.

실제 대회에 출제된 프로그래밍 문제를 모델이 얼마나 잘 해결하는지 평가하는 라이브코드벤치(LiveCodeBench)에서 서브큐는 89.7%를 기록했다. 다른 최상위 코딩 모델들과 비슷한 수준이다. 에펜의 시나난싱 이사는 “서브큐는 코딩에서 최고 수준의 성능을 보여준다”고 말했다.

서브쿼드래틱의 비용 관련 주장은 확인하기가 어렵다. 서브큐가 아직 대중에게 공개되지 않았기 때문이다. 데인절 CEO에 따르면 엔트로픽의 LLM 클로드 오퍼스 4.6을 룰러 128(RULER 128)로 테스트하는 데는 2,600달러(약 400만 원)가 소요된다(룰러 128은 엔비디아가 개발한 테스트로 모델이 대규모 데이터세트에서 정보를 얼마나 잘 찾아내는지 평가한다). 그렇다면 서브큐는 어떨을까? 데인절 CEO는 “서브큐를 테스트하는 데는 8달러가 들었다”고 말했다.

서브큐는 규모가 매우 큰 데이터세트도 처리할 수 있는 것으로 보인다. 서브큐의 컨텍스트 윈도우(context window)는 최대 1,200만 토큰에 이른다. 컨텍스트 윈도우는 모델이 한 번에 참고할 수 있는 작업 기억에 가까운 개념이다. 오늘날 대부분의 최상위 모델은 컨텍스트 윈도우가 100만 토큰 수준이다. 휘던 CTO가 필자에게 보여준 시연에서 그는 서브큐에 문서 400건에 담긴 정보를 바탕으로 추론해야 하는 작업을 요청했다. 서브큐가 답변을 생성하는 데는 몇 초밖에 걸리지 않았다. 같은 작업을 LLM 기반 검색엔진으로 널리 쓰이는 퍼플렉시티(Perplexity)에 맡기자 퍼플렉시티는 문서 400건을 모두 불러오지 못했다.

에펜은 NIAH(needle-in-a-haystack) 벤치마크 테스트도 진행했다. 이 테스트는 많은 데이터 속에 묻힌 특정 정보를 모델이 얼마나 잘 찾아내는지 평가한다. 에펜은 보고서에서 “서브큐가 600만 토큰과 1,200만 토큰 길이의 컨텍스트 윈도우를 사용하는 테스트에서도 필요한 정보를 찾아내는 과제에서 98%의 정확도를 기록했다”며 “대부분의 모델은 테스트조차 할 수 없는 긴 컨텍스트 조건에서도 거의 완벽에 가까운 정보 검색 성능을 유지했다”고 밝혔다.

“몇 년 뒤 트랜스포머는 사라질 것”...창업자의 자신감

높은 점수에도 불구하고 벤치마크는 사실 모델이 무엇을 할 수 있고 무엇을 할 수 없는지 완전하게 보여주지 못한다. 매우 특정한 조건에서 진행한 테스트는 실제의 다양한 작업에서 모델을 실행해보는 일을 대신할 수 없기 때문이다.

서브쿼드래틱은 서브큐를 코딩과 대규모 데이터세트 검색에 최적화된 모델로 제공하고 있다. 서브쿼드래틱에 따르면 서브큐 조기 이용 신청자가 이미 수만 명에 이르며 그중에는 500곳이 넘는 기업 고객도 포함되어 있다. 그러나 긴 대기자 명단에도 불구하고 지금까지 극소수에게만 접근 권한이 부여됐다. 서브쿼드래틱은 아직 자원이 제한된 작은 신생 기업이어서 한꺼번에 너무 많은 사용자를 감당할 수 없다고 설명했다.

더 많은 이용자가 서브큐를 직접 사용해보고 성능을 검증하기 전까지는 회의적인 시각이 남을 수밖에 없다. 특히 서브쿼드래틱이 서브큐를 처음부터 새로 훈련하지 않았다는 점은 의문을 키우는 대목이다. 서브쿼드래틱은 서브큐 개발의 출발점으로 중국 오픈소스 모델 큐원(Qwen)의 한 버전에서 가져온 가중치를 재사용했다(가중치는 훈련 과정에서 모델 내부에 설정되는 값으로 모델이 어떻게 행동할지를 결정한다). 이는 모델 개발자들이 흔히 사용하는 방식이지만 LLM 작동 방식을 완전히 새로 만들었다는 서브쿼드래틱의 주장과는 다소 맞지 않는다.

디퓨 연구자는 “그들이 실제로 유용한 기술을 개발했을 가능성은 있다”면서도 “그러나 공개된 증거만으로는 이들이 어텐션 계산량 병목을 해결했다는 주장을 뒷받침하기에 아직 부족하다”고 지적했다.

그럼에도 서브쿼드래틱 공동창업자인 휘던 CTO는 “대형 AI 기업과 경쟁하려면 기존 방식과 다른 접근법을 택할 수밖에 없었다”고 말했다. 그는 “경쟁력 있는 모델을 만들려면 새로운 아이디어가 필요하다”며 “우리는 오픈AI보다 훨씬 큰 압박을 받고 있다”고 강조했다.

MIT Technology Review

Published by DMK

MIT 테크놀로지 리뷰는 기술로 세상을 이롭게 한다는 미션을 추구합니다.

MIT Technology Review Korean Edition 편집장 : Mat Honan | 한국 에디션 발행인 & 편집인 : 박세정 | 개인정보관리책임자 : 박세정

주소 : 서울특별시 종로구 새문안로 92 (신문로1가), 5층 503호 | 대표번호 : 02-2038-3690 | 이메일 : customer@technologyreview.kr

사업자등록번호 : 주식회사 디엠케이글로벌 451-88-00827 [사업자정보확인] | 통신판매업 신고번호 : 제 2018-서울영등포-0513호

정보간행물 신고번호 : 종로 다00053

copyright © 2026 MIT 테크놀로지 리뷰 | MIT Technology Review Korea